Resumen Probabilidad y Estadística

Anthonny Flores Rojas

Buenos días Costa Rica. No se complique,
viva feliz. Vivan la vida como una lombriz.

Contenido

Prefacio **1**

1 Un poco de combinatoria enumerativa **3**
1.1 El principio básico de conteo 3
1.2 Permutaciones básicas 4
1.3 Combinaciones y selecciones 5
1.4 Teorema multinomial 6

2 Teoría de la medida y probabilidad. **8**
2.1 Anillos y funciones en anillos 8
2.1.1 Funciones en anillos 9
2.1.2 Medidas 11
2.2 Álgebras y medidas de probabilidad 12
2.2.1 Álgebra 12
2.2.2 Medidas de probabilidad 13
2.2.3 Semialgebra y sistemas 15
2.3 Más sobre la medida 16
2.3.1 Medida exterior 17
2.3.2 Medida de Stieltjes 20
2.3.3 Integración de funciones simples 20
2.3.4 Integración para funciones acotadas 21
2.3.5 Integración para funciones no negativas 22
2.3.6 Integración para funciones medibles 23
2.3.7 Sucesiones de funciones 24
2.3.8 Teorema Riemann-Lebesgue 26
2.3.9 Medida del producto 27
2.3.10 Teorema de Fubini-Tonelli 29
2.4 L^p 29
2.4.1 Desigualda de Hölder y Minkowski 30
2.4.2 Propiedades de L^p 31
2.4.3 Medida signada 33
2.4.4 Descomposición de Hahn y Jordan 34
2.4.5 Radon-Nikodym 37
2.5 Probabilidades curiosas 37
2.6 Probabilidades condicionales 38
2.7 Eventos independientes 39

3 Variables aleatorias **41**
3.1 Funciones medibles 41
3.2 Propiedades de la variables aleatorias 42
3.3 Distribución de probabilidad 45
3.3.1 Distribucion acumulada 45
3.3.2 Función de Stieltjes 47
3.4 V.A. continua y absolutamente continua 49

3.5 Esperanza . . . 50
3.5.1 Propiedades de la esperanza . . . 50
3.6 Media, varianza y momentos . . . 53
3.7 Función generadora de momentos . . . 54
3.7.1 Propiedades de la función generadora de momentos . . . 54
3.8 Función característica . . . 56

4 Vectores aleatorias . . . 60
4.0.1 Distribucion de vectores aleatorios . . . 60
4.1 Esperanza de vectores aleatorios . . . 63
4.2 Varianza, covarianza y correlación . . . 65
4.3 Independencia de vectores aleatorios . . . 66
4.3.1 Esperanza independiente . . . 67
4.3.2 Propiedades de la distribucion condicional . . . 68
4.4 Esperanza condicional . . . 69
4.4.1 Propiedades de la esperanza regular . . . 70
4.5 Convergencia de variables aleatorias . . . 72
4.5.1 Convergencia casi segura . . . 72
4.5.2 Convergencia en L^p . . . 73
4.5.3 Convergencia en distribucion . . . 73
4.5.4 Convergencia en probabilidad . . . 73
4.5.5 Teorema de convergencia . . . 73
4.5.6 Desigualdad de Chebyshev . . . 75

5 Ley de los grandes números. . . . 77
5.0.1 Variables no correlacionadas . . . 77
5.0.2 Ley debil en L^2 . . . 78
5.0.3 Ley de los Grandes Números con truncamiento para colas ligeras . . . 80
5.1 Lema de Borel-Cantelli . . . 81
5.1.1 Ley débil de los grandes números . . . 83
5.1.2 Segundo lema de Borel-Cantelli . . . 85
5.1.3 Ley fuerte de los grandes números . . . 88
5.2 Teoria de Renovación . . . 88
5.3 Desviación grande . . . 90

6 Teorema del limite central . . . 92
6.1 Convergencia débil . . . 93
6.2 Teorema de limite local . . . 98
6.3 Convergencia de Poisson . . . 99
6.4 Ley estable . . . 100
6.5 Distribuciones infinitamente divisibles . . . 102
6.6 Teorema limite en $\mathbb{R}$ . . . 102

7 Cadenas de Markov . . . 106
7.1 Procesos Estocásticos y Caminatas Aleatorias . . . 106
7.2 Cadenas de Markov . . . 107
7.3 Propiedad de Markov en Espacios de Estados Generales . . . 109
7.4 Clasificación de Estados . . . 110
7.5 Cadenas de Nacimiento y Muerte y Criterios de Recurrencia . . . 118
7.6 Recurrencia de Caminatas Aleatorias . . . 119
7.7 Distribucion estacionaria . . . 121
7.8 Comportamiento Asintótico y Periodicidad . . . 123
7.9 Algebra de Cola de una Cadena . . . 125
7.10 Cadenas de Harris . . . 125
7.11 Sucesiones Estacionarias y Teoremas Ergódicos . . . 127

8 Martingales . . . **129**
8.1 xxx . . . 129
8.2 Definición y Propiedades Básicas . . . 130
8.3 Tiempos de Parada . . . 133
8.4 Parada Opcional . . . 133
8.5 Desigualdades para Submartingalas . . . 134
8.6 Convergencia de Martingalas . . . 135
8.7 Aplicaciones de la Convergencia de Martingalas . . . 138
8.8 Martingalas Cuadrado Integrables . . . 139
8.9 Integrabilidad Uniforme y Convergencia en L^1 . . . 140
8.10 Martingalas hacia Atrás y Sucesiones Intercambiables . . . 141
8.11 Teoremas de Paro Opcional y Aplicaciones . . . 142
8.12 Combinatoria de la Caminata Aleatoria Simple . . . 144

9 Martingalas en Tiempo Continuo . . . **145**
9.1 Martingalas en Tiempo Continuo . . . 145
9.2 Procesos de Poisson . . . 147
9.3 Procesos Compuestos de Poisson . . . 151
9.4 El Movimiento Browniano . . . 153
9.4.1 Movimiento Browniano y Procesos Gaussianos . . . 153
9.4.2 Las Trayectorias del Movimiento Browniano . . . 157
9.4.3 Movimiento Browniano y Procesos de Markov . . . 160
9.4.4 Martingalas del Browniano y Martingalas Locales . . . 164
9.4.5 Teorema de Donsker y Límites Funcionales . . . 165

10 Integrales estocásticas . . . **170**
10.1 Integral Estocástica para Integrandos Simples . . . 170
10.2 Integral Estocástica para Integrandos en $H^2(T)$ . . . 172
10.3 Integral Estocástica General . . . 174
10.4 Fórmula de Itô . . . 175
10.5 Procesos de Itô . . . 177
10.6 Caso Multidimensional . . . 179

11 Ecuaciones diferenciales estocásticas . . . **181**
11.1 Definiciones Básicas . . . 181
11.2 Ecuaciones Diferenciales Estocásticas Lineales . . . 182
11.3 Aproximaciones Numéricas . . . 183

12 Inferencia . . . **186**
12.1 Tipos de inferencia . . . 187
12.2 Densidades previas y conjugadas . . . 187
12.3 Distribucion posterior . . . 188
12.4 Distribuciones previas conjugadas . . . 189
12.5 Estimador bayesiano y las funciones de perdida . . . 191
12.6 Estimador de bayes para muestras grandes . . . 193
12.6.1 Consistencia . . . 193
12.7 Estimadores de máxima verosimilitud y sus propiedades . . . 193
12.8 Estadístico suficiente . . . 195
12.9 Estimadores insesgados . . . 195
12.10Mejorando el estimador . . . 197

13 Distribuciones Muestrales de Estimadores . . . **199**
13.1 Distribución t de Student . . . 200

14 Intervalos de Confianza . . . **202**

15 Pruebas de Hipótesis . . . 205

16 Pruebas con Hipótesis Simples . . . 208

17 Pruebas Paramétricas Clásicas . . . 210

18 Bondad de Ajuste . . . 212

19 Tablas de Contingencia . . . 214

20 Pruebas de Kolmogorov-Smirnov . . . 217

21 Pruebas No Paramétricas: Signo y Rango . . . 219

22 Anexo . . . 221
22.1 Distribuciones de probabilidad discretas . . . 222
22.1.1 Distribución de Bernoulli . . . 222
22.1.2 Distribución binomial . . . 223
22.1.3 Distribución Geométrica . . . 224
22.1.4 Distribución de Poisson . . . 225
22.1.5 Distribución hipergeométrica . . . 226
22.1.6 Distribución de Pascal . . . 226
22.1.7 Distribución uniforme discreta . . . 227
22.1.8 Distribución zeta . . . 228
22.1.9 Distribución zipf . . . 229
22.1.10 Distribución beta-binomial . . . 230
22.1.11 Distribución hipergeométrica negativa . . . 231
22.1.12 Distribución de Polya . . . 231
22.1.13 Distribución logarítmica . . . 232
22.1.14 Distribución gamma-poisson . . . 232
22.1.15 Distribución beta-pascal . . . 233
22.1.16 Distribución power series . . . 234
22.1.17 Distribución Weibull discreta . . . 234
22.1.18 Distribución rectangular discreta . . . 235
22.1.19 Distribución Benford . . . 236
22.2 Distribuciones de probabilidad continuas . . . 237
22.2.1 Distribución normal . . . 237
22.2.2 Distribución exponencial . . . 238
22.2.3 Distribución uniforme continua . . . 239
22.2.4 Distribución gamma . . . 241
22.2.5 Distribución beta . . . 242
22.2.6 Distribución chi-cuadrado . . . 242
22.2.7 Distribución t de student . . . 243
22.2.8 Distribución F de Fisher-Snedecor . . . 244
22.2.9 Distribución Log-normal . . . 245
22.2.10 Distribución Weibull . . . 246
22.2.11 Distribución Laplace Asimétrica . . . 247
22.2.12 Distribución logística generalizada . . . 248
22.2.13 Distribución Rayleigh . . . 249
22.2.14 Distribución gaussiana inversa . . . 250
22.2.15 Distribución Pareto . . . 251
22.2.16 Distribución Cauchy . . . 252
22.2.17 Distribución Gompertz . . . 252
22.2.18 Distribución valor extremo . . . 253
22.2.19 Distribución gamma generalizada . . . 254

22.2.20 Distribución Pareto generalizada . . . 254
22.2.21 Distribución t no central . . . 255
22.2.22 Distribución F no central . . . 256
22.2.23 Distribución chicuadrado no central . . . 256
22.2.24 Distribución beta no central . . . 257
22.2.25 Distribución F doble no central . . . 257
22.2.26 Distribución log-gamma . . . 257
22.2.27 Distribución log-logística . . . 258
22.2.28 Distribución hiperexponencial . . . 259
22.2.29 Distribución hipoexponencial . . . 260
22.2.30 Distribución Makeham . . . 260
22.2.31 Distribución lomax . . . 261
22.2.32 Distribución Muth . . . 262
22.2.33 Distribución Von Mises . . . 263
22.2.34 Distribución arcsin . . . 263
22.2.35 Distribución arctangent . . . 264
22.2.36 Distribución power . . . 265
22.2.37 Distribución power estándar . . . 266
22.2.38 Distribución normal estándar . . . 267
22.2.39 Distribución Cauchy estándar . . . 268
22.2.40 Distribución triangular estándar . . . 269
22.2.41 Distribución Wald estándar . . . 270
22.2.42 Distribución minimax . . . 270
22.2.43 Distribución IDB . . . 271
22.2.44 Distribución error . . . 271
22.2.45 Distribución exponential power . . . 272
22.2.46 Distribución triangular . . . 273
22.2.47 Distribución TSP . . . 274
22.3 Transformadas . . . 275

A Índice de definiciones y teoremas . . . I

Prefacio

Este documento no solo toma como referencia las notas del curso tomadas por mi persona, se le suma el documento de el libro *Probability: Theory and Examples by Rick Durrett*, *Introducción a la Probabilidad de Jose David Cambos*, el libro *A First Course in Probability by Sheldon Ross*, *Combinatoria enumerativa de Eduardo Piza* y demás apuntes tomados de diferentes libros o artículos. Cabe aclarar que no todas las demostraciones son propias, sumado a ello se requieren conocimientos en calculo en varias variables y análisis real.

Parte I

1

Un poco de combinatoria enumerativa

1.1. El principio básico de conteo

Para empezar, primero se vera conceptos básicos de combinatoria como una introducción a la probabilidad, ya que la combinatoria nos permite conocer la cantidad de variaciones que podemos obtener poniendo ciertas condiciones a un conjunto de elementos.

Proposición 1.1.1 El principio básico de conteo. Suponga que un experimento a puede tener cualquiera de n posible resultados, y un experimento b puede tener cualquiera de m posibles resultados, en consecuencia, hay mn posibilidades resultados al realizar los dos experimentos a la vez.

Demostración. Note que para cada posible resultado del experimento a, existen m posible resultados del experimento b, donde podemos enumerar entonces todos los resultados de ambos elementos de la siguiente forma

$$\begin{matrix} (1,1) & (1,2) & \cdots & (1,n) \\ (2,1) & 2,2 & \cdots & (2,n) \\ \vdots & \vdots & \ddots & \vdots \\ (m,1) & (m,2) & \cdots & (m,n) \end{matrix} . \tag{1.1}$$

Donde cada (i,j) son los posibles resultados de los dos experimentos a la vez, en cuyo caso, tenemos que hay nm posibles resultados.

□

1.2. Permutaciones básicas

El siguiente resultado es uno de los mas utilizados e importantes es cuanto a permutaciones.

Proposición 1.2.1 Conteo de permutaciones. Si tenemos n objetos distintos entre si, entonces el numero de permutaciones tomando n de los mismo, es $n!$.

Demostración. Note que para la primera concrescencia tenemos n posibles elecciones, para la siguiente tenemos todos excepto ese mismo o lo que es igual a $n-1$ elecciones, para la siguiente tendremos $n-2$ posibles elecciones, así hasta que nos quedemos con el ultimo y restante objetos que elegir; utilizando la Proposición del principio básico de conteo, tenemos que el total de los posibles resultados del experimento es la multiplicación de los posibles resultados individuales, en consecuencia el numero de permutaciones totales es $n(n-1)(n-2)\cdots 1 =: n!$.

□

Ahora, si tenemos en cuenta que alguno o varios de los objetos se pueden repetir, claramente esto nos disminuiría la cantidad de objetos que podemos elegir para las permutaciones, mejor dicho, nos quita la cantidad de permutaciones que involucran a ese objeto.

Teorema 1.2.1 Teorema del coeficiente multinomial. Suponga que tenemos n objetos, y hay m diferentes tipos de objetos entre si con n_i la cantidad de cada distinción, entonces la cantidad de permutaciones totales es

$$\binom{n}{n_1, n_2, \cdots, n_{m-1}} := \frac{n!}{n_1! n_2! \cdots n_m!}. \tag{1.2}$$

Con $n_1 + n_2 + \cdots + n_m = n$.

Demostración. Note que si tenemos que n_1 objetos se repiten, entonces estos se puede permutar de $n_1!$ formas, en cuyo caso tenemos que el numero que posibles permutaciones sin que ningún objeto n_1 permute es $n!/n_1!$, si repetimos esto con cada grupo distinguible tenemos que el numero total de permutaciones sin que ninguno de ellos se repita es

$$\frac{n!}{n_1! n_2! \cdots n_m!}.$$

□

Ahora, tomemos el primer caso de las permutaciones, si solo tomamos m objetos de los n con cuantos nos quedaríamos

Proposición 1.2.2 Permutaciones sin repetición. El numero de permutaciones de n objetos distintos entre si, solo tomando $m \leq n$ de ellos es

$$[n]_m := \frac{n!}{(n-m)!}. \tag{1.3}$$

Demostración. Note que solo estamos tomando m de estos objetos, entonces estamos eliminando $n-m$ de estos utilizando la Proposición de conteo de permutaciones podríamos asumir que estos objetos que no tenemos tan solo están repetidos, con esto concluiría la demostración

□

Note que si no nos interesa el orden de los mismo, solo habría que eliminar las m permutaciones de los m objetos seleccionados.

Para el siguiente caso se va a ver el numero de permutaciones eligiendo de un conjunto de n objetos con la posibilidad de repetición.

Proposición 1.2.3 Permutaciones con repetición. Si tomamos m objetos de un conjunto de n objetos permitiendo la repetición de los mismo, la cantidad de posibles permutaciones es n^m.

Demostración. Note que para cada elecciones independiente tenemos que hay n posibles objetos a elegir, utilizando el principio básico de conteo, tenemos m experimentos realizados a la vez, en cuyo caso el numero total de permutaciones sera

$$\underbrace{n \cdots n}_{m} = n^m. \tag{1.4}$$

□

1.3. Combinaciones y selecciones

Teorema 1.3.1 Teorema de las estrellas y barras. Suponga que tenemos m objetos distintos entre si, y tenemos n cajas ordenadas, entonces la cantidad de posibles distribuciones ordenadas de los mismo es

$$[n]^m := \frac{(n+m-1)!}{(n-1)!}. \tag{1.5}$$

Demostración. Note que podemos tomar la separación de cada caja como un objeto mas, ya que nos define el momento en el que se dio un cambio en el orden de los objetos

$$\underbrace{i_1 \cdots i_k}_{\text{caja 1}} \mid \underbrace{i_{k+1} \cdots i_{j+k}}_{\text{caja 2}} \mid \cdots \mid \underbrace{\cdots i_m}_{\text{caja n}}. \tag{1.6}$$

□

Utilizando la Proposición de las permutaciones sin reposición, podemos ver que cada caja se puede tomar como un objeto del tipo raya |, que son todos iguales entre si, teniendo $n-1$ de ellos en las permutaciones; mientras que los m objetos son distintos entre si, entonces tenemos $m+n-1$ objetos con $n-1$ iguales entre si, en consecuencia hay $[n]^m$ posibles permutaciones.

Proposición 1.3.1 Principio del producto. Suponga que tenemos m objetos distintos entre si, y tenemos n cajas ordenadas, entonces la cantidad de posibles distribuciones sin importar el orden de los mismo es n^m.

La demostración queda como ejercicio para el lector.

Teorema 1.3.2 Soluciones de una ecuación lineal. El numero de soluciones en $\mathbb{N}_0$ de la ecuación linea $x_1 + x_2 + \cdots x_n = m$ es

$$\frac{[n]^m}{m!}.$$

Demostración. Tome cada elemento x_i como una caja, y note que análogamente al Teorema de estrellas y barras tenemos $[n]^m$ posibles maneras de distribuir 1 (Donde si distribuimos $j \leq m$ de los objetos 1 en x_i, entonces $x_i = j$) en cada una de las cajas. Dado que cada objeto 1 es igual entre si, tenemos que eliminar las posible m permutaciones de los mismo.

□

Una consecuencia de esto es que si uno de los $x_i \geq k$ entonces $x_i - k \geq 0$ y podemos escribir en su lugar $x_1 + \cdots + (x_i - k) \cdots + x_n = m - k$.

Proposición 1.3.2 Principio multiplicativo para selecciones independientes. Suponga que tenemos N objetos divididos en r grupos conteniendo cada uno N_r objetos, entonces si tomamos n objetos de los N iniciales, el total de diferentes selecciones sin importar el orden de los objetos es

$$\binom{N_1}{n_1}\binom{N_2}{n_2}\cdots\binom{N_r}{n_r}. \tag{1.7}$$

Donde $n_i \leq N_i$ es la cantidad de objetos tomados de N_I.

La demostración queda como ejercicio para el lector. Note simplemente que cada caso de selección es independiente y el orden de la misma no importa.

Proposición 1.3.3 selección no consecutiva.. Si tenemos n objetos en linea recta, y seleccionamos m de ellos de manera no consecutiva, el numero de posible selecciones es.

$$\binom{n-m+1}{m}.$$

Demostración. Utilizando la ilustración de las cajas y el Teorema de estrellas y barras, tenemos que de los n objetos $m-1$ no los podemos seleccionar (Son los objetos que separan a los que vamos a seleccionar), entonces en realidad tendremos $n-m+1$ objetos a seleccionar, de los cuales seleccionaremos somo m de ellos, entonces tenemos $[n]_m$ posibles selecciones, pero tenemos que recordar que los elementos m pueden permutar entre si a la hora de la selección, en consecuencia tendremos que eliminar estas permutaciones de las selecciones, entonces tenemos que el numero de posibles selecciones es

$$\frac{[n-m+1]_m}{m!} = \binom{n-m+1}{m}. \tag{1.8}$$

□

1.4. Teorema multinomial

Teorema 1.4.1 Teorema multinomial. Sea $x_i \in \mathbb{C}, \forall_{i\leq k}$, entonces

$$(x_1+x_2+\cdots+x_k)^n = \sum_{n_1+\cdots+n_k=n}\binom{n}{n_1,\cdots,n_k}x_1^{n_1}\cdots x_k^{n_k}. \tag{1.9}$$

Demostración. Note que para $k=1$ es el teorema del binomio de newton, cuya demostración se deja al lector.

Suponga entonces que se cumple para k, entonces podemos tomar

$$(x_1+\cdots+x_k+x_{k+1})^n\,(y+x_{k+1})^n \mid y = x_1+\cdots+x_k.$$

Lo ponemos tomar como

$$(y+x_{k+1})^n = \sum_{1=0}^{n}\frac{n!}{l!(n-l)!}y^l x_{k+1}^{n-l} = \sum_{1=0}^{n}\frac{n!}{l!(n-l)!}\left(\sum_{n_1+\cdots+n_k=l}\binom{l}{n_1,\cdots,n_k}x_1^{n_1}\cdots x_k^{n_k}\right)x_{k+1}^{n-l}$$

$$= \sum_{1=0}^{n} \sum_{n_1+\cdots+n_k=l} \frac{n!}{l!(n-l)!} \binom{l}{n_1,\cdots,n_k} x_1^{n_1} \cdots x_k^{n_k} x_{k+1}^{n-l}$$

$$= \sum_{1=0}^{n} \sum_{n_1+\cdots+n_k=l} \frac{n!}{l!(n-l)!} \frac{l!}{n_1!\cdots n_k!} x_1^{n_1} \cdots x_k^{n_k} x_{k+1}^{n-l}$$

$$= \sum_{n_1+\cdots+n_k+n_{k+1}=n} \binom{n}{n_1,\cdots,n_{k+1}} x_1^{n_1} \cdots x_{k+1}^{n_{k+1}}.$$

□

2

Teoría de la medida y probabilidad.

2.1. Anillos y funciones en anillos

Definición 2.1.1 Anillos conjuntivos. Un anillo es una familia $\mathscr{R}$ de conjuntos si para $A, B \in \mathscr{R}$ entonces

$$A \cup B \in \mathscr{R}, \tag{2.1}$$

$$A \setminus B \in \mathscr{R}. \tag{2.2}$$

Más aun, si $A_n \in \mathscr{R}, \forall_{n\in\mathbb{N}}$ es llamado un σ-anillo si

$$\bigcup_{n=1}^{\infty} A_n \in \mathscr{R}. \tag{2.3}$$

Proposición 2.1.1 Intersección y unión de anillos. Sea $\mathscr{R}$ un anillo con $A_i \in \mathscr{R}, \forall_{i\in\mathbb{N}_{\leq n}}$ entonces

$$\bigcup_{i=1}^{n} A_i \in \mathscr{R}, \tag{2.4}$$

$$\bigcap_{i=1}^{n} A_i \in \mathscr{R}, \tag{2.5}$$

Demostración. Sean $A_i \in \mathscr{R}$ con $1 \leq i \leq n$. Utilizando la propiedad de la unión del anillo se tiene que

$$\left(((A_1 \in \mathscr{A} \wedge A_2 \in \mathscr{R} \Rightarrow A_1 \cup A_2 \in \mathscr{R}) \wedge A_3 \in \mathscr{R} \Rightarrow \cdots) \Rightarrow \bigcup_{i=1}^{n-1} A_i \in \mathscr{R} \right) \wedge A_n \in \mathscr{R} \Rightarrow \bigcup_{i=1}^{n} A_i \in \mathscr{R}.$$

Para la segunda propiedad, utilizando lo anteriormente demostrado y la definición de anillo, se tiene que

$$\mathscr{R} \ni \bigcap_{i=1}^{n} A_i = A_1 \setminus \bigcup_{i=1}^{n} (A_1 \setminus A_n).$$

□

Proposición 2.1.2 Intersección de σ-anillos. Sea $\mathscr{R}$ un σ-anillo, entonces $\mathscr{R}$ es un anillo. Sumado a ello si tenemos que $A_n \in \mathscr{R}, \forall_{n\in\mathbb{N}}$, entonces

$$\bigcap_{n=1}^{\infty} A_n \in \mathscr{R}. \tag{2.6}$$

Sea $\mathscr{A}$ otro σ-anillo, si $\mathscr{R} \cap \mathscr{A} \neq \varnothing$, entonces

$$\mathscr{R} \cap \mathscr{A} \text{ es un } \sigma\text{-anillo.} \tag{2.7}$$

Demostración. Tome $B_i := \{B_1 = A_1, B_2 = A_2, A_{i>2} = \varnothing\}$ entonces es claro que $A_1 \cup A_2 \in \mathscr{R}$. Ahora note que utilizando la proposición anterior podemos ver como

$$\mathscr{A} \ni \bigcap_{i=1}^{\infty} A_i = A_1 \setminus \bigcup_{i=1}^{\infty} (A_1 \setminus A_n).$$

Para la intersección de anillos se puede ver que si

$$A, B \in \mathscr{R} \cap \mathscr{A} \Rightarrow A \cup B \in \mathscr{R} \wedge A \cup B \in \mathscr{A} \Rightarrow A \cup B \in \mathscr{R} \cap \mathscr{A},$$

$$A, B \in \mathscr{R} \cap \mathscr{A} \Rightarrow A \setminus B \in \mathscr{R} \wedge A \setminus B \in \mathscr{A} \Rightarrow A \setminus B \in \mathscr{R} \cap \mathscr{A},$$

$$A_i \in \mathscr{A} \cap \mathscr{R}, \forall_{i\geq 1} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathscr{R} \wedge \bigcup_{n=1}^{\infty} A_n \in \mathscr{A} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathscr{R} \cap \mathscr{A},$$

por lo tanto $\mathscr{R} \cap \mathscr{A}$ es una σ-anillo.

□

2.1.1. Funciones en anillos

Definición 2.1.2 Recta real extendida.

$$\overline{\mathbb{R}} := \mathbb{R} \cup \{\infty\}. \tag{2.8}$$

Definición 2.1.3 Unión disjunta.

$$\bigsqcup_{n=1}^{\infty} A_n \tag{2.9}$$

denota la unión de conjuntos disjuntos, es decir, $A_i \cap A_j = \varnothing$ si $i \neq j$.

Definición 2.1.4 Función aditiva. La función $\phi : \mathscr{R} \to \overline{\mathbb{R}}$ es aditiva si para $A, B \in \mathscr{R}$ disjuntos, tenemos que

$$\phi(A \cup B) = \phi(A) + \phi(B) \tag{2.10}$$

Se le llama aditiva contable si

$$\phi\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \phi(A_n) \tag{2.11}$$

Teorema 2.1.1 Aditividad. Sea ϕ contable aditiva sobre un anillo $\mathscr{R}$ si $A_n \in \mathscr{R}, \forall_{n\in\mathbb{N}}$, entonces

$$\phi(\varnothing) = 0, \tag{2.12}$$

$$\text{Si } \phi \text{ es aditiva contable entonces es aditiva,} \tag{2.13}$$

$$\text{Si } A_1 \subset A_2 \text{ y } \forall_{i\in\mathbb{N}}(\phi(A_i) \geq 0) \text{ entonces } \phi(A_1) \leq \phi(A_2), \tag{2.14}$$

$$\text{Si } |\phi(A_1)| < \infty \text{ entonces } \phi(A_2 \setminus A_1) = \phi(A_2) - \phi(A_1), \tag{2.15}$$

$$\phi(A_1 \cup A_2) = \phi(A_1) + \phi(A_2) - \phi(A_1 \cap A_2). \tag{2.16}$$

Si A_n es una sucesión creciente (o decreciente) y $\lim_{n\to\infty} A_n = \bigcup_{n=1}^{\infty} A_n$ o $\left(\lim_{n\to\infty} A_n = \bigcap_{n=1}^{\infty} A_n\right)$ entonces

$$\phi\left(\lim_{n\to\infty} A_n\right) = \lim_{n\to\infty} \phi(A_n). \tag{2.17}$$

Demostración. Para la primera propiedad note que por la definicion de contabilidad aditiva tenemos que

$$\phi(A_1) = \phi(A_1 \cup \varnothing \cup \varnothing \cdots) = \phi(A_i) + \sum_{k=1}^{n} \phi(\varnothing) \Rightarrow \phi(\varnothing) = 0.$$

Continuando con la segunda propiedad, dado que $A_1 \cap A_2 = \varnothing$ y utilizando la definicion de contable aditiva se puede ver que

$$\phi(A_1 \cup A_2 \cup \varnothing \cup \varnothing \cdots) = \phi(A_1) + \phi(A_2) + \sum_{k=1}^{\infty} \phi(\varnothing) \ = \phi(A_1) + \phi(A_2).$$

Para las siguientes dos podemos ver que $A_2 = A_1 \cup (A_2 \setminus A_1)$, donde $(A_2 \setminus A_1) \cap A_1 = \varnothing$, entonces

$$\phi(A_2) = \phi(A_1) + \phi(A_2 \setminus A_1),$$

$$\Rightarrow \quad \phi(A_2) - \phi(A_1) = \phi(A_2 \setminus A_1) \quad \wedge \quad \phi(A_1) \leq \phi(A_1) + \phi(A_2 \setminus A_1) = \phi(A_2).$$

Al igual que en la demostración anterior, podemos tomar uniones disjuntas tales que

$$A_1 = A_1 \setminus A_2 \cup (A_1 \cap A_2) \quad \wedge \quad A_1 \cup A_2 = A_2 \setminus A_2 \cup A_2 \setminus A_1 \cup (A_1 \cap A_2),$$

entonces

$$\phi(A_1 \cup A_2) = \phi(A_1 \setminus A_2) + \phi(A_2 \setminus A_1) + \phi(A_1 \cap A_2) = \phi(A_1) + \phi(A_2) - \phi(A_1 \cap A_2).$$

Para la ultima, si la sucesión es creciente tenemos que $A_n \subset A_{n+1}$, entonces podemos tomar $B_n :=$

$A_n - A_{n-1}$ con $B_1 := A_1$, entonces $B_n \cap B_{n+1} = \varnothing$ y $\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n = A_n$, en consecuencia

$$\phi\left(\lim_{n\to\infty} A_n\right) = \phi\left(\bigcup_{n=1}^{\infty} A_n\right) = \phi\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \phi(B_n) = \sum_{n=1}^{\infty} \phi(A_n) - \phi(A_{n-1}) = \lim_{n\to\infty} \phi(A_n).$$

Para el otro caso tome $A_i \setminus A_n$ de forma que $\exists_{i\in\mathbb{N}} \mid \phi(A_i) < \infty$ (note que es sucesión decreciente convergente a $A_i \setminus A$), entonces $\phi(A_i \setminus A_n)$ converge a $\phi(A_i \setminus A)$ y dado que $A \subset A_i$ tenemos que

$$\phi(A_n) = \phi(A_i \setminus A_n) + \phi(A_i) \xrightarrow{n\to\infty} \phi(A_i \setminus A) + \phi(A_i) = \phi(A).$$

□

Corolario 2.1.1 Separación de la suma de una función contable aditiva. Sea ϕ contable aditiva sobre $\mathscr{R}$ si $A_n \in \mathscr{R}, \forall_{n\in\mathbb{N}}$, entonces

$$\phi\left(\bigcup_{i=1}^{n} A_i\right) \leq \sum_{i=1}^{n} \phi(A_i). \tag{2.18}$$

Sumado a ello

$$\phi\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} \phi(A_i). \tag{2.19}$$

La demostración queda al lector.

Lema 2.1.1 Monotonía. Si $\phi : \mathscr{R} \to \overline{\mathbb{R}}$ es contablemente aditiva y no negativa, y $A \subseteq B$ con $A, B \in \mathscr{R}$, entonces

$$\phi(A) \leq \phi(B). \tag{2.20}$$

La demostración queda al lector.

2.1.2. Medidas

Definición 2.1.5 Medida. Una medida es una función $\mu : \mathscr{R} \to \overline{\mathbb{R}}$ contable aditiva no negativa.

La anterior definicion tiene ciertos equivalente, como cambiar el hecho de no negativa equivale a $\mu(\varnothing) = 0$ y demás.

Definición 2.1.6 Espacio medible. Se dice que $(X, \mathscr{R})$ es un espacio medible si existe un σ-anillo $\mathscr{R}$ de los subconjuntos de X y μ es una medida sobre $\mathscr{R}$. Sumado a ello si $X \in \mathscr{R}$, $(X, \mathscr{R}, \mu)$ se dice ser un espacio de medida.

Definición 2.1.7 σ-finidad. Se dice que μ es σ-finita si existe una secesión $B_n \in \mathscr{R}$ talque $\mu(B_n) < \infty$ y $\cup_n B_n = A$. Si $\mu(A) < \infty$ entonces μ es llamada finita.

2.2. Álgebras y medidas de probabilidad

Definición 2.2.1 Espacio muestral. El conjunto de todos los posibles resultados de un experimento es llamado *espacio muestral* lo denotamos por Ω, a los elementos $\omega \in \Omega$ se les llama resultado o evento elemental.

Definición 2.2.2 Experimento. Un experimento es aleatorio si todos sus posible resultados son conocidos, pero no se puede determinar el resultado hasta que ocurre.

Definición 2.2.3 Finito, cantable o no. Se dice que el espacio muestral Ω es finito, discreto o continuo, cuando es un conjunto finito, contable o no contable.

2.2.1. Álgebra

Definición 2.2.4 Álgebra conjuntiva. La colección $\mathscr{A}$ de subconjuntos de Ω es llamada un campo o (álgebra) si

$$\mathscr{A} \text{ es no vació}, \tag{2.21}$$

$$\text{si } A \in \mathscr{A} \text{ entonces } A^c \in \mathscr{A}, \tag{2.22}$$

$$\text{si } A, B \in \mathscr{A} \text{ entonces } A \cup B \in \mathscr{A}. \tag{2.23}$$

Ademas es llamado un σ-campo o (σ-álgebra o espacio de eventos) si

$$A_i \in \mathscr{A}, \forall_{i\in\mathbb{R}} \text{ entonces } \bigcup_{i\in\mathbb{R}} A_n \in \mathscr{A}. \tag{2.24}$$

Proposición 2.2.1 Relación entre anillos y álgebras. Todo álgebra de conjuntos es un anillo, pero no todo anillo es un álgebra.

La demostración queda al lector.

Proposición 2.2.2 Union, intersección y diferencia de álgebras. Sea $\mathscr{A}$ una álgebra con $A_n \in \mathscr{A}, \forall_{i\in\mathbb{N}_{\leq n}}$ entonces

$$\bigcup_{i=1}^{n} A_i \in \mathscr{A}, \tag{2.25}$$

$$\bigcap_{i=1}^{n} A_i \in \mathscr{A}, \tag{2.26}$$

$$A_1 \setminus A_2 \in \mathscr{A}. \tag{2.27}$$

Demostración. Para la primera propiedad observe que son propiedades hereditarias de los anillos.

Para la segunda utilizando lo anteriormente demostrado y la anterior se tiene que

$$\forall_{i\leq n}\left(A_i^c \in \mathscr{A}\right) \Rightarrow \bigcup_{i=1}^{n} A_i^c \in \mathscr{A} \Rightarrow \left(\bigcup_{i=1}^{n} A_i^c\right)^c \in \mathscr{A} \Rightarrow \bigcap_{i=1}^{n} A_i \in \mathscr{A}.$$

Y por ultimo simplemente note que

$$(A_1 \wedge A_2) \in \mathscr{A} \Rightarrow A_1^c \in \mathscr{A} \Rightarrow A_1^c \cup A_2 \in \mathscr{A} \Rightarrow A_1 \cap A_2^c = A_1 \setminus A_2 \in \mathscr{A} \in \mathscr{A}.$$

□

Proposición 2.2.3 Intersección de σ-álgebras. Sea $\mathscr{A}$ una σ-álgebra entonces $\mathscr{A}$ es una álgebra, y con $A_n \in \mathscr{A}, \forall_{n\in\mathbb{N}}$ tenemos que

$$\bigcap_{n=1}^{\infty} A_n \in \mathscr{A}. \tag{2.28}$$

Si $\mathscr{F}$ es otra σ-álgebra, entonces

$$\mathscr{A} \cap \mathscr{F}. \tag{2.29}$$

es una σ-álgebra.

Al igual que la unión, la condición suficiente es que la sucesión sea contable. La demostración de la propiedad anterior es hereditaria de los anillos.

Corolario 2.2.1 La más pequeña σ-álgebra $\sigma(\cdot)$. Sea $\mathscr{F}$ una familia de conjuntos de Ω, entonces existe una única σ-álgebra sobre Ω, la cual es la más pequeña y $\mathscr{F}$ esta en ella. Usualmente es llamada $\sigma(\mathscr{F})$ o sigma álgebra de Borel .

La demostración queda al lector.

2.2.2. Medidas de probabilidad

Definición 2.2.5 Probabilidad. Si $(\Omega, \mathscr{F})$ es un espacio medible y $\mathbb{P}$ (también llamado μ) es una medida sobre $\mathscr{F}$ talque $\mathbb{P}(\Omega) = 1$ entonces, $\mathbb{P}$ es llamada una medida de probabilidad sobre $(\Omega, \mathscr{F})$

Definición 2.2.6 Espacio de probabilidad. Un espacio de probabilidad es la tripleta $(\Omega, \mathscr{F}, \mathbb{P})$ de los objetos tales que

$$\Omega \text{ es no vació}, \tag{2.30}$$

$$\mathscr{F} \text{ es un espacio de eventos de } \Omega, \tag{2.31}$$

$$\mathbb{P} \text{ es una medida de probabilidad sobre } (\Omega, \mathscr{F}). \tag{2.32}$$

Teorema 2.2.1 Propiedades. Sea $(\Omega, \mathscr{F}, \mathbb{P})$ un espacio de probabilidad con $A_1, A_2 \in \mathscr{F}$, entonces

$$\mathbb{P}(\varnothing) = 0, \tag{2.33}$$

$$\text{Si } A_1 \cap A_2 = \varnothing, \text{ entonces } \mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2), \tag{2.34}$$

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c), \forall_{A\in\mathscr{F}}, \tag{2.35}$$

$$\text{Si } A_1 \subset A_2 \text{ entonces } \mathbb{P}(A_1) \leq \mathbb{P}(A_2), \mathbb{P}(A_2 \setminus A_1) = \mathbb{P}(A_2) - \mathbb{P}(A_1) \text{ y } \mathbb{P}(A) \leq 1 \forall_{A\in\mathscr{F}}, \tag{2.36}$$

$$\mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2). \tag{2.37}$$

Si $(A_n)_n$ es una sucesión creciente o decreciente de conjuntos sobre $\mathscr{F}$, entonces

$$\mathbb{P}\left(\lim_{n\to\infty} A_n\right) = \lim_{n\to\infty} \mathbb{P}(A_n) \tag{2.38}$$

Demostración. Con lo demostrado anteriormente y con la definicion de medida podemos obtener que

$$\mathbb{P}(\Omega) = 1 = \mathbb{P}(A) + \mathbb{P}(A^c) \Rightarrow \mathbb{P}(A) = 1 - \mathbb{P}(A^c).$$

Las otras propiedades ya están demostradas.

□

Corolario 2.2.2 Union de probabilidades. Sean $(\Omega, \mathscr{F}, \mathbb{P})$ un espacio de probabilidad con $A_1, \dots, A_n \in \mathscr{F}$, entonces

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{k=1}^{n} (-1)^{k+1} \sum_{1\le i_1<\cdots<i_k\le n} \mathbb{P}(A_{i_1} \cap \cdots \cap A_{i_k}). \tag{2.39}$$

Demostración. Caso $n = 1$ es trivial, suponga que se cumple para n, entonces note que

$$\mathbb{P}\left(\bigcup_{n=1}^{n} A_i\right) = \sum_{i=1}^{n} \mathbb{P}(A_i) - \sum_{1\le i_1<i_2\le n} \sum \mathbb{P}(A_{i_1} \cap A_{i_2}) + \sum_{1\le i_1<i_2<i_3\le n} \sum \sum \mathbb{P}(A_{i_1} \cap A_{i_2} \cap A_{i_3}) - \cdots + \cdots$$

$$+(-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right).$$

En cuyo caso

$$\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) = \mathbb{P}\left(A_{n+1} \bigcup \bigcup_{i=1}^{n} A_i\right) = \mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) + \mathbb{P}(A_{n+1}) - \mathbb{P}\left(\bigcup_{i=1}^{n} A_i \bigcap A_{n+1}\right).$$

Donde

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i \bigcap A_{n+1}\right) = \sum_{i=1}^{n} \mathbb{P}(A_i \cap A_{n+1}) - \sum_{1\le i_1<i_2\le n} \sum \mathbb{P}(A_{i_1} \cap A_{i_2} \cap A_{n+1}) + \sum_{1\le i_1<i_2<i_3\le n} \sum \sum \mathbb{P}(A_{i_1} \cap A_{i_2} \cap A_{i_3} \cap A_{n+1}) -$$

$$\cdots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^{n} A_i \bigcap A_{n+1}\right).$$

Entonces se tiene que

$$\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) = \sum_{i=1}^{n+1} \mathbb{P}(A_i) - \sum_{1\le i_1<i_2\le n+1} \sum \mathbb{P}(A_{i_1} \cap A_{i_2}) + \sum_{1\le i_1<i_2<i_3\le n+1} \sum \sum \mathbb{P}(A_{i_1} \cap A_{i_2} \cap A_{i_3}) - \cdots + \cdots$$

$$+(-1)^{n} \mathbb{P}\left(\bigcap_{i=1}^{n+1} A_i\right).$$

$$\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) = \sum_{k=1}^{n+1} (-1)^{k+1} \sum_{1\le i_1<\cdots<i_k\le n+1} \mathbb{P}(A_{i_1} \cap \cdots \cap A_{i_k}).$$

□

La siguiente parte se puede saltar hasta el (*), ya que la siguiente sección es solo una pincelada de algunos resultados de teoría de la medida.

2.2.3. Semialgebra y sistemas

Definición 2.2.7 Semialgebra. Una colección de conjuntos $\mathscr{S}$ es llamada una semialgebra si

$$A_1, A_2 \in \mathscr{S} \text{ entonces } A_1 \cap A_2 \in \mathscr{S}, \tag{2.40}$$

$$\text{Si } A \in \mathscr{S} \text{ entonces } A^c = \bigsqcup_i^n A_i, \text{ con } A_i \in \mathscr{S}. \tag{2.41}$$

Para dejar más claro lo anterior, A^c tiene que ser la unión finita de conjuntos disjuntos de $\mathscr{S}$.

Lema 2.2.1 Álgebra de semialgebra. Si $\mathscr{S}$ es una semialgebra, entonces

$$\overline{\mathscr{S}} := \left\{ \bigsqcup_{i=1}^n A_n : A_i \in \mathscr{S} \right\} \text{ es un álgebra.} \tag{2.42}$$

Demostración. Sean $A, B \in \overline{\mathscr{S}}$, de modo que $A = \bigsqcup_{i=1}^n A_i$ y $B = \bigsqcup_{j=1}^m B_j$ con $A_i, B_j \in \mathscr{S}$. Como $\mathscr{S}$ es semialgebra, $A_i \cap B_j \in \mathscr{S}, \forall_{i,j}$. Entonces

$$A \cap B = \bigsqcup_{i=1}^n \bigsqcup_{j=1}^m (A_i \cap B_j) \in \overline{\mathscr{S}},$$

Para el complemento, dado $A = \bigsqcup_{i=1}^n A_i$ se tiene $A^c = \bigcap_{i=1}^n A_i^c$. Como $\mathscr{S}$ es semialgebra, cada $A_i^c = \bigsqcup_k C_{i,k}$ con $C_{i,k} \in \mathscr{S}$, luego $A_i^c \in \overline{\mathscr{S}}$. Por lo anterior, la intersección finita $A^c = \bigcap_{i=1}^n A_i^c$ pertenece a $\overline{\mathscr{S}}$. Las demás propiedades son triviales.

□

Definición 2.2.8 π-sistema. Si $\mathscr{P}$ es una colección de conjunto cerrada ante intersección finita, entonces es llamado un π-sistema.

Definición 2.2.9 λ-sistema. Se le llama λ-sistema a la colección de conjuntos $\mathscr{L}$ si

$$A, B \in \mathscr{L} \text{ y } A \subset B \text{ entonces } B - A \in \mathscr{L}, \tag{2.43}$$

$$\text{si } A_n \in \mathscr{L}, \forall_{n\in\mathbb{N}} \text{ y } A_1 \subset A_2 \subset \cdots \mid A_n \to A, \text{ entonces } A \in \mathscr{L}. \tag{2.44}$$

Teorema 2.2.2 Teorema $\pi - \lambda$ de Dynkin. Si $\mathscr{P}$ es un π-sistema y $\mathscr{L}$ es un λ-sistema que contiene a $\mathscr{P}$, entonces $\sigma(\mathscr{P}) \subset \mathscr{L}$.

Demostración. Sea $\ell(\mathscr{P})$ el λ-sistema más pequeño que contiene a $\mathscr{P}$. Para cada $A \in \ell(\mathscr{P})$ se define

$$\mathscr{G}_A := \{B \in \ell(\mathscr{P}) : A \cap B \in \ell(\mathscr{P})\}.$$

$\Omega \in \mathscr{G}_A$ pues $A \cap \Omega = A$; si $C \subseteq B$ están en $\mathscr{G}_A$, entonces $A \cap (B \setminus C) = (A \cap B) \setminus (A \cap C) \in \ell(\mathscr{P})$; y si $B_n \nearrow B$ en $\mathscr{G}_A$, entonces $A \cap B_n \nearrow A \cap B \in \ell(\mathscr{P})$.

Si $A \in \mathscr{P}$, la propiedad de π permite que $A \cap B \in \mathscr{P} \subseteq \ell(\mathscr{P})$ para todo $B \in \mathscr{P}$, así que $\mathscr{P} \subseteq \mathscr{G}_A$ y por minimalidad $\mathscr{G}_A = \ell(\mathscr{P})$. Luego para todo $A \in \mathscr{P}$ y $B \in \ell(\mathscr{P})$ se tiene $A \cap B \in \ell(\mathscr{P})$. Esto muestra que $\mathscr{P} \subseteq \mathscr{G}_B$, y por minimalidad $\mathscr{G}_B = \ell(\mathscr{P})$. Por tanto $\ell(\mathscr{P})$ es cerrado bajo intersecciones finitas.

Como $\Omega \in \ell(\mathscr{P})$, todo $A \in \ell(\mathscr{P})$ cumple $A^c = \Omega \setminus A \in \ell(\mathscr{P})$. Junto con la cerradura bajo intersecciones finitas, y por De Morgan, $\ell(\mathscr{P})$ es cerrado bajo uniones finitas. Si $A_n \in \ell(\mathscr{P})$, entonces $B_n := \bigcup_{k\leq n} A_k \in \ell(\mathscr{P})$ y $B_n \nearrow \bigcup_n A_n$, luego $\bigcup_n A_n \in \ell(\mathscr{P})$. Así, $\ell(\mathscr{P})$ es una σ-álgebra que contiene a $\mathscr{P}$, por lo que $\sigma(\mathscr{P}) \subseteq \ell(\mathscr{P})$. Finalmente, $\mathscr{L}$ es un λ-sistema que contiene a $\mathscr{P}$, y por minimalidad de $\ell(\mathscr{P})$ se tiene $\ell(\mathscr{P}) \subseteq \mathscr{L}$.

□

2.3. Más sobre la medida

Teorema 2.3.1 Teorema de unicidad de medidas. Sea $\mathscr{P}$ un π-sistema. Si ν_1, ν_2 son medidas respectivamente sobre $\mathscr{F}_1, \mathscr{F}_2$ que coinciden sobre $\mathscr{P}$ y ademas existe una sucesión creciente sobre Ω con $\nu_1(A_n), \nu_2(A_n) < \infty$, entonces v_1 y v_2 coinciden sobre $\sigma(\mathscr{P})$.

Demostración. Suponga que $\nu_1(\Omega) = \nu_2(\Omega) < \infty$. Fijese $A \in \mathscr{P}$ y definase

$$\mathscr{L} := \{B \in \sigma(\mathscr{P}) : \nu_1(A \cap B) = \nu_2(A \cap B)\}.$$

Como ν_1 y ν_2 coinciden en $\mathscr{P}$, se tiene $\nu_1(A \cap \Omega) = \nu_1(A) = \nu_2(A) = \nu_2(A \cap \Omega)$, luego $\Omega \in \mathscr{L}$. Si $B, C \in \mathscr{L}$ con $C \subseteq B$, como $\nu_1(\Omega) < \infty$ en particular $\nu_1(A \cap B) < \infty$, y entonces

$$\nu_1(A \cap (B \setminus C)) = \nu_1(A \cap B) - \nu_1(A \cap C) = \nu_2(A \cap B) - \nu_2(A \cap C) = \nu_2(A \cap (B \setminus C)),$$

entoncs $B \setminus C \in \mathscr{L}$. Si $(B_n)_{n\geq 1} \subseteq \mathscr{L}$ es creciente con $B_n \nearrow B$, entonces $A \cap B_n \nearrow A \cap B$, y por continuidad de las medidas desde abajo (aditividad no negativa)

$$\nu_1(A \cap B) = \lim_{n\to\infty} \nu_1(A \cap B_n) = \lim_{n\to\infty} \nu_2(A \cap B_n) = \nu_2(A \cap B),$$

luego $B \in \mathscr{L}$. Por tanto $\mathscr{L}$ es un λ-sistema que contiene a $\mathscr{P}$, y por el teorema de Dynkin $\sigma(\mathscr{P}) \subseteq \mathscr{L}$, es decir $\nu_1(A \cap B) = \nu_2(A \cap B)$ para todo $B \in \sigma(\mathscr{P})$ y todo $A \in \mathscr{P}$. Tomando $A = \Omega$ se concluye $\nu_1 = \nu_2$ sobre $\sigma(\mathscr{P})$ en el caso finito.

Para el caso general, sea $(A_n)_{n\geq 1} \subseteq \mathscr{P}$ creciente con $A_n \nearrow \Omega$ y $\nu_1(A_n), \nu_2(A_n) < \infty$ para todo n. Fijese $B \in \sigma(\mathscr{P})$. Las medidas $\nu_i(\cdot \cap A_n)$ son finitas y coinciden en $\mathscr{P}$, luego por el caso anterior $\nu_1(B \cap A_n) = \nu_2(B \cap A_n)$ para todo n. Como $B \cap A_n \nearrow B$, la continuidad desde abajo permite que

$$\nu_1(B) = \lim_{n\to\infty} \nu_1(B \cap A_n) = \lim_{n\to\infty} \nu_2(B \cap A_n) = \nu_2(B).$$

□

Lema 2.3.1 σ-aditividad heredada. Suponga que μ es una medida sobre $\mathscr{S}$ y que $\bar{\mu}$ medida de $\overline{\mathscr{S}}$ es una extensión de μ, entonces

$$\text{Si } A = \bigcup_{i=1}^{n} B_i \mid A, B_i \in \overline{\mathscr{S}}, \text{ entonces } \bar{\mu}(A) = \sum_{i=1}^{n} \bar{\mu}(B_i). \tag{2.45}$$

$$\text{Si } A \subset \bigcup_{i=1}^{n} B_i \mid A, B_i \in \overline{\mathscr{S}}, \text{ entonces } \bar{\mu}(A) \leq \sum_{i=1}^{n} \bar{\mu}(B_i). \tag{2.46}$$

Demostración. Como $B_i \in \overline{\mathscr{S}}$, existe una descomposición $B_i = \bigsqcup_j S_{i,j}$ con $S_{i,j} \in \mathscr{S}$ unión finita disjunta. Si $A = \bigsqcup_{i=1}^{n} B_i$, entonces $A = \bigsqcup_{i,j} S_{i,j}$ es también una unión finita disjunta de elementos de $\mathscr{S}$, luego por

definición de $\bar{\mu}$ y porque $\bar{\mu}$ extiende a μ,

$$\bar{\mu}(A) = \sum_{i,j} \mu(S_{i,j}) = \sum_{i=1}^{n} \sum_{j} \mu(S_{i,j}) = \sum_{i=1}^{n} \bar{\mu}(B_i).$$

Para la segunda afirmación, definace $C_1 = B_1$ y $C_i = B_i \setminus (B_1 \cup \cdots \cup B_{i-1})$ para $i \geq 2$. Entonces $C_i \subseteq B_i$, los C_i son disjuntos, $\bigsqcup_{i=1}^{n} C_i = \bigcup_{i=1}^{n} B_i$, y $A = \bigsqcup_{i=1}^{n} (A \cap C_i)$. Por la primera parte y la monotonía de $\bar{\mu}$,

$$\bar{\mu}(A) = \sum_{i=1}^{n} \bar{\mu}(A \cap C_i) \leq \sum_{i=1}^{n} \bar{\mu}(C_i) \leq \sum_{i=1}^{n} \bar{\mu}(B_i).$$

□

2.3.1. Medida exterior

Definición 2.3.1 Medida exterior de Carathéodory. Sea μ una medida en una álgebra $\mathscr{F}$, si $E \subset \Omega$ y $\{A_i\}$ un recubrimiento sobre E, entonces se define

$$\mu^*(E) := \text{ínf} \sum_{n=1}^{\infty} \mu(A_n). \tag{2.47}$$

Definición 2.3.2 Medida exterior. Una función $\mu^* : \mathscr{F} \to \overline{\mathbb{R}}$ se le dice medida exterior si

$$\mu^*(\varnothing) = 0 \tag{2.48}$$

$$\text{Si } E \subset F, \text{ entonces } \mu^*(E) \leq \mu^*(F) \tag{2.49}$$

$$\text{Si } E \subset \bigcup_i F_i, \text{ entonces } \mu^*(E) \leq \sum_i \mu^*(F_i) \tag{2.50}$$

Definición 2.3.3 Criterio de medibilidad de Carathéodory. Sea μ^* una medida exterior sobre $\mathscr{F}$. Un conjunto $E \subset \Omega$ se dice medible si para todo conjunto $F \subset \Omega$ se cumple

$$\mu^*(F) = \mu^*(F \cap E) + \mu^*(F \cap E^c). \tag{2.51}$$

Lema 2.3.2 Coherencia con la medida original. Si $A \in \mathscr{A}$ entonces $\mu^*(A) = \mu(A)$ y A es medible.

Demostración. Es claro que si $A \subset \bigcup_i A$ entonces

$$\mu(A) \leq \sum_i A_i,$$

Entonces $\mu(A) \leq \mu^*(A)$, dado que $A \subset A$ entonces $\mu^*(A) \leq \mu(A)$. Ahora si $\mu^*(F) = \infty$ la condición de medible es trivial; entonces tome $\mu^*(F) < \infty$ y $E = A$ por propiedades del ínfimo si $F \subset \bigcup_i B_i$ si $\varepsilon > 0$ se tiene que

$$\sum_i \mu(B_i) \leq \mu^*(F) + \varepsilon.$$

Dado que $\mu = \mu^*$, entonces

$$\mu^*(F \cap A) + \mu^*(F \cap A^c) \leq \sum_i \mu^*(B_i \cap A) + \mu^*(B_i \cap A^c) = \sum_i \mu(B_i) \leq \mu^*(F) + \varepsilon.$$

Para la otra desigualdad tan solo note que por definicion

$$\mu^*(F \cap A) + \mu^*(F \cap A^c) \geq \mu^*(F).$$

□

Teorema 2.3.2 Teorema de Carathéodory. La clase $\mathscr{A}^*$ de conjuntos medibles de una σ-álgebra y la restricción μ^* sobre $\mathscr{A}^*$ es una medida.

Demostración. Primero note que el hecho de que $E^c \mid E \in \mathscr{A}^*$ es trivial.

Ahora, note que si $E_1, E_2 \in \mathscr{A}^*$ se tiene que

$$\mu^*(F \cap (E_1 \cup E_2)) + \mu^*(F \cap (E_1^c \cap E_2^c))$$

$$\leq \mu^*(F \cap E_1) + \mu^*(F \cap E_1^c \cap E_2)) + \mu^*(F \cap (E_1^c \cap E_2^c)) = \mu^*(F \cap E_1) + \mu^*(F \cap E_1^c) = \mu^*(F)$$

En cuyo caso $E_1 \cup E_2$ es medible. Para $E_1 \cap E_2$ bastan notar que $(E_1^c \cup E_2^c)^c$, entonces $E_1 \cap E_2$ es medible.

Ahora si $E_1, \dots, E_n \in \mathscr{A}^*$ conjuntos disjuntos medibles, si tomamos $C_m = \bigsqcup_{i \leq m} E_i$. Dado que $F_n \supset E_n$, y $F_{n-1} \cap E_n = \varnothing$, se tiene

$$\mu^*(G \cap F_n) = \mu^*(G \cap F_n \cap E_n) + \mu^*(G \cap F_n \cap E_n^c) = \mu^*(G \cap E_n) + \mu^*(G \cap F_{n-1}).$$

Por inducción sobre n, se sigue que

$$\mu^*\left(G \cap \bigsqcup_{i=1}^n E_i\right) = \sum_{i=1}^n \mu^*(G \cap E_i).$$

Para probar que si $E_i \in \mathscr{A}^*$, entonces $E = \bigcup_{i=1}^\infty E_i \in \mathscr{A}^*$, defina ${E_i}' = E_i \bigcap_{j<i} E_j^c$. Por lo anterior, $E_i^{'} \in \mathscr{A}^*$, por lo que se puede asumir sin pérdida de generalidad que los $E_i^{'}$ son disjuntos dos a dos. Sea $F_n = \bigcup_{i=1}^n E_i^{'}$. Por lo anterior, $F_n \in \mathscr{A}^*$. Utilizando lo anteriormente demostrados y dado que $E^c \subset F_n^c$ se tiene

$$\mu^*(G) = \mu^*(G \cap F_n) + \mu^*(G \cap F_n^c) \geq \sum_{i=1}^n \mu^*(G \cap E_i^{'}) + \mu^*(G \cap E^c).$$

Dejando $n \to \infty$ se sigue que

$$\mu^*(G) \geq \sum_{i=1}^\infty \mu^*(G \cap E_i) + \mu^*(G \bigcap E^c) \geq \mu^*(G \cap E) + \mu^*(G \cap E^c),$$

Demostrando que E es medible.

Finalmente, si $E = \bigcup_i E_i$ con $E_1, E_2, \cdots \in \mathscr{A}^*$ disjuntos, sea $F_n = \bigsqcup_{i=1}^n E_i$. Entonces se sigue que $\mu^*(E) \geq \mu^*(F_n) = \sum_{i=1}^n \mu^*(E_i)$, tomando el límite cuando $n \to \infty$ se tiene que

$$\mu^*(E) \leq \sum_{i=1}^\infty \mu^*(E_i).$$

Dado que la desigualdad opuesta de la definicion de μ^*, concluimos que $\mu^*(E) = \sum_{i=1}^\infty \mu^*(E_i)$.

□

Teorema 2.3.3 Teorema de la extensión de Carathodory. Sea μ σ-finita sobre una álgebra $\mathscr{A}$, entonces μ tiene una única extensión ν para $\sigma(\mathscr{A})$.

Demostración. La unicidad ya esta probada por el teorema de coincidencia de π-sistemas.Y la existencia el lema anterior la prueba.

□

Teorema 2.3.4 Teorema de Hahn-Kolmogorov. Sea $\mathscr{S}$ una semialgebra y μ una medida exterior sobre $\mathscr{S}$, entonces si $A \in \mathscr{S}$ es una colección finita de conjuntos disjuntos de $A_i \in \mathscr{S}$ se tiene que

$$\mu(A) = \sum_i \mu(A_i). \tag{2.52}$$

Y si $A = \bigcap_{i \leq n}^{n} A_i$ se sigue que

$$\mu(A) \leq \sum_i \mu(A_i). \tag{2.53}$$

Sumado a ello, μ tiene una única extensión $\bar{\mu}$ que es una medida sobre $\bar{\mathscr{S}}$. Si la extensión es $\sigma-$finita, entonces existe una única extensión ν que es una medida sobre $\sigma(\mathscr{S})$.

Demostración. Definimos $\overline{\mu}$ sobre $\bar{\mathscr{S}}$ como

$$\overline{\mu}(A) = \sum_i \mu(S_i) \quad \text{si } A = \bigsqcup_i S_i \mid S_i \in S.$$

Para verificar que $\overline{\mu}$ está bien definida, suponga que $A = \bigsqcup_j T_j$ con $T_j \in S$. Entonces se sigue que $S_i = \bigsqcup_j (S_i \cap T_j)$ y $T_j = \bigsqcup_i (S_i \cap T_j)$, por la aditividad finita se tiene que

$$\sum_i \mu(S_i) = \sum_{i,j} \mu(S_i \cap T_j) = \sum_j \mu(T_j),$$

lo que prueba que $\overline{\mu}$ no depende de la representación.

Para extender la aditividad a uniones disjuntas numerables $A = \bigsqcup_{i \geq 1}^{\infty} B_i$, con $B_i \in \overline{S}$, observamos que cada $B_i = \bigsqcup_j S_{i,j}$ con $S_{i,j} \in S$, y entonces

$$\sum_{i \geq 1}^{\infty} \overline{\mu}(B_i) = \sum_{i \geq 1, j} \mu(S_{i,j}).$$

Reemplazando los B_i por los $S_{i,j}$, se puede suponer que $B_i \in S$. Dado que $A \in \overline{S}$, existe una unión finita disjunta $A = \bigsqcup_j T_j$ con $T_j \in S$, y cada $T_j = \bigcup_{i \geq 1} (T_j \cap B_i)$. Por la subaditividad

$$\mu(T_j) \leq \sum_{i=1}^{\infty} \mu(T_j \cap B_i).$$

Sumando sobre j

$$\overline{\mu}(A) = \sum_j \mu(T_j) \leq \sum_{i=1}^{\infty} \sum_j \mu(T_j \cap B_i) = \sum_{i=1}^{\infty} \mu(B_i).$$

Para la desigualdad opuesta, definimos $A_n = \bigsqcup_{i=1}^{n} B_i$ y $C_n = A \cap A_n^c$. Como $\overline{S}$ es un álgebra, $C_n \in \overline{S}$, y por aditividad finita

$$\overline{\mu}(A) = \overline{\mu}(A_n) + \overline{\mu}(C_n) \geq \sum_{i=1}^{n} \overline{\mu}(B_i).$$

Tomando el límite cuando $n \to \infty$, se concluye

$$\overline{\mu}(A) \geq \sum_{i\geq 1}^{\infty} \overline{\mu}(B_i).$$

Por tanto, $\overline{\mu}$ es aditiva contable sobre $\overline{S}$, y define una medida.

Ahora para la primera parte la unicidad es clara por el teorema de coincidencia de en π-sistemas. Y si es σ-finita por el Teorema de la extensión de Carathodory. La extensión es unica sobre $\sigma(\mathscr{S})$.

□

2.3.2. Medida de Stieltjes

Definición 2.3.4 Medida de Stieltjes. Las medidas sobre $(\mathbb{R}, \mathscr{B}(E))$ se definen a partir de una función de medida de Stieltjes $F : \mathscr{B}(E) \to \mathbb{R}$ que satisface las siguientes propiedades

$$F \text{ es no decreciente, es decir, si } x \leq y \text{ entonces } F(x) \leq F(y). \tag{2.54}$$

$$F \text{ es continua por la derecha, es decir } \lim_{y \to x^+} F(y) = F(x), \text{para todo } x \in \mathbb{R}. \tag{2.55}$$

2.3.3. Integración de funciones simples

Definición 2.3.5 Función indicadora y medida de Dirac. Sea $(\Omega, \mathscr{F})$ un espacio medible. La función indicadora de un conjunto $A \in \mathscr{F}$ y la medida de Dirac en un punto $x_0 \in \Omega$ se definen respectivamente como

$$\mathbf{1}_A(x) := \begin{cases} 1 & \text{si } x \in A, \\ 0 & \text{si } x \notin A, \end{cases} \qquad \delta_{x_0}(A) := \mathbf{1}_A(x_0), \tag{2.56}$$

también denotada $\mathbb{1}_{\{x \in A\}}$. La medida de Dirac satisface $\int f \, d\delta_{x_0} = f(x_0)$ para toda función medible f.

Definición 2.3.6 Función simple. Sea $(\Omega, \mathscr{F}, \mu)$ un espacio de medida. Se dice que una función $\varphi : \Omega \to \mathbb{R}$ es simple si existe una colección finita de conjuntos disjuntos $A_1, A_2, \ldots, A_n \in \mathscr{F}$ con $\mu(A_i) < \infty$ para cada i, y constantes reales $a_1, a_2, \ldots, a_n$, tales que

$$\varphi(\omega) = \sum_{i=1}^{n} a_i \, \mathbf{1}_{A_i}(\omega). \tag{2.57}$$

Definición 2.3.7 Integral de una función simple. Sea μ una medida sobre un espacio medible $(\Omega, \mathscr{F})$. La integral de una función simple se define como

$$\int \varphi \, d\mu := \sum_{i=1}^{n} a_i \, \mu(A_i). \tag{2.58}$$

Lema 2.3.3 Propiedades básicas de la integral para funciones simples. Sean φ y ψ funciones

simples. Entonces se cumple

$$\varphi \geq 0 \text{ en casi todas partes} \Rightarrow \int \varphi \, d\mu \geq 0. \tag{2.59}$$

$$a \in \mathbb{R} \Rightarrow \int a\varphi \, d\mu = a \int \varphi \, d\mu. \tag{2.60}$$

$$\int (\varphi + \psi) \, d\mu = \int \varphi \, d\mu + \int \psi \, d\mu. \tag{2.61}$$

$$\varphi \leq \psi \text{ en casi todas partes} \Rightarrow \int \varphi \, d\mu \leq \int \psi \, d\mu. \tag{2.62}$$

$$\varphi = \psi \text{ en casi todas partes} \Rightarrow \int \varphi \, d\mu = \int \psi \, d\mu. \tag{2.63}$$

$$\left| \int \varphi \, d\mu \right| \leq \int |\varphi| \, d\mu. \tag{2.64}$$

Demostración. Las dos primeras demostraciones son triviales. Para demostrar la tercera suponga que

$$\varphi = \sum_{i=1}^{m} a_i \, \mathbf{1}_{A_i}, \quad \psi = \sum_{j=1}^{n} b_j \, \mathbf{1}_{B_j}.$$

Para unificar los dominios de las funciones simples φ y ψ, definase los conjuntos complementarios residuales $A_0 := \left(\bigcup_j B_j\right) - \left(\bigcup_i A_i\right), B_0 := \left(\bigcup_i A_i\right) - \left(\bigcup_j B_j\right)$ y tomamos $a_0 = b_0 = 0$. Entonces se tiene

$$\varphi + \psi = \sum_{i=0}^{m} \sum_{j=0}^{n} (a_i + b_j) \, \mathbf{1}_{A_i \cap B_j},$$

donde $A_i = \bigsqcup_j (A_i \cap B_j)$ y $B_j = \bigsqcup_i (A_i \cap B_j)$. Por tanto

$$\int (\varphi + \psi) \, d\mu = \sum_{i=0}^{m} \sum_{j=0}^{n} (a_i + b_j) \, \mu(A_i \cap B_j) = \sum_{i=0}^{m} \sum_{j=0}^{n} a_i \, \mu(A_i \cap B_j) + \sum_{j=0}^{n} \sum_{i=0}^{m} b_j \, \mu(A_i \cap B_j)$$

$$= \sum_{i=0}^{m} a_i \, \mu(A_i) + \sum_{j=0}^{n} b_j \, \mu(B_j) = \int \varphi \, d\mu + \int \psi \, d\mu.$$

Por la aditividad, se tiene $\int \psi \, d\mu = \int \varphi \, d\mu + \int (\psi - \varphi) \, d\mu$, y como $\psi - \varphi \geq 0$ la desigualdad se cumple por la primera demostración. Si $\varphi = \psi$ casi en todas partes, entonces simultáneamente $\varphi \leq \psi$ y $\psi \leq \varphi$ casi en todas partes. Aplicando la desigualdad anterior en ambas direcciones se concluye que las integrales son iguales. Como $\varphi \leq |\varphi|$ y también $-\varphi \leq |\varphi|$, se obtiene que la integral de φ es menor o igual que la de $|\varphi|$, y que la integral de $-\varphi$ también lo es. Esto implica que el valor absoluto de la integral de φ está acotado por la integral de $|\varphi|$, lo que concluye la demostración.

□

2.3.4. Integración para funciones acotadas

Definición 2.3.8 Definición de la integral de Lebesgue vía funciones simples. Sea $E \subset \Omega$ con $\mu(E) < \infty$, y sea f una función acotada que se anula fuera de E. Para definir $\int f \, d\mu$, si φ y ψ

son funciones simples tales que $\varphi \leq f \leq \psi$, entonces se define

$$\int f\,d\mu := \sup_{\varphi \leq f} \int \varphi\,d\mu = \inf_{\psi \geq f} \int \psi\,d\mu. \tag{2.65}$$

Lema 2.3.4 propiedades elementales de la integral de Lebesgue para funciones acotadas de soporte de medida finita. Sea $E \subset \Omega$ con $\mu(E) < \infty$. Si f y g son funciones acotadas que se anulan fuera de E, entonces:

$$f \geq 0 \text{ en casi todas partes} \Rightarrow \int f\,d\mu \geq 0. \tag{2.66}$$

$$a \in \mathbb{R} \Rightarrow \int af\,d\mu = a\int f\,d\mu. \tag{2.67}$$

$$\int (f+g)\,d\mu = \int f\,d\mu + \int g\,d\mu. \tag{2.68}$$

$$g \leq f \text{ en casi todas partes} \Rightarrow \int g\,d\mu \leq \int f\,d\mu. \tag{2.69}$$

$$g = f \text{ en casi todas partes} \Rightarrow \int g\,d\mu = \int f\,d\mu. \tag{2.70}$$

$$\left|\int f\,d\mu\right| \leq \int |f|\,d\mu. \tag{2.71}$$

La demostración se deja al lector.

Definición 2.3.9 Integral de f sobre el conjunto E. Definimos la integral de f sobre el conjunto E como

$$\int_E f\,d\mu := \int f \cdot \mathbf{1}_E\,d\mu. \tag{2.72}$$

2.3.5. Integración para funciones no negativas

Definición 2.3.10 Integral de Lebesgue para funciones medibles no negativas. Si $f \geq 0$, se define

$$\int f\,d\mu := \sup\left\{\int h\,d\mu : 0 \leq h \leq f,\ h \leq M \mid M \in \mathbb{R},\ \mu(\{x : h(x) > 0\}) < \infty\right\}. \tag{2.73}$$

Lema 2.3.5 Aproximación por truncamiento. Sea $E_n \to \Omega \mid E_{n-1} \subset E_n$ con $\mu(E_n) < \infty$. Entonces

$$\int_{E_n} \min\{f, n\}\,d\mu \to \int f\,d\mu \text{ creciente, cuando } n \to \infty. \tag{2.74}$$

Demostración. Sea h tal que $0 \leq h \leq f$, $h \leq M$, y $\mu(\{x : h(x) > 0\}) < \infty$. Para $n \geq M$, se tiene

$$\int_{E_n} \min\{f, n\}\,d\mu \geq \int_{E_n} h\,d\mu = \int h\,d\mu - \int_{E_n^c} h\,d\mu.$$

Como $0 \leq \int_{E_n^c} h\,d\mu \leq M$, $\mu(E_n^c \cap \{x : h(x) > 0\}) \to 0$ cuando $n \to \infty$, se concluye que

$$\liminf_{n\to\infty} \int_{E_n} \text{mín}\{f, n\}\,d\mu \geq \int h\,d\mu,$$

y como h es arbitraria, se obtiene el resultado.

□

Lema 2.3.6 Propiedades elementales de la integral de Lebesgue.. Supóngase que $f, g \geq 0$. Entonces

$$\int f\,d\mu \geq 0. \tag{2.75}$$

$$a > 0 \Rightarrow \int af\,d\mu = a\int f\,d\mu. \tag{2.76}$$

$$\int (f+g)\,d\mu = \int f\,d\mu + \int g\,d\mu. \tag{2.77}$$

$$0 \leq g \leq f \text{ en casi todas partes} \Rightarrow \int g\,d\mu \leq \int f\,d\mu. \tag{2.78}$$

$$0 \leq g = f \text{ en casi todas partes} \Rightarrow \int g\,d\mu = \int f\,d\mu. \tag{2.79}$$

La demostración queda al lector, solo cabe recalcar que para la suma de integral hay que utilizar el lema anterior.

2.3.6. Integración para funciones medibles

Definición 2.3.11 Extensión de la integral de Lebesgue a funciones medibles de signo arbitrario. Se dice que una funcion cualquiera f es integrable si $\int |f|\,d\mu < \infty$. Definimos

$$f^+(x) := \text{máx}\{f(x), 0\}, \quad f^-(x) := \text{mín}\{f(x), 0\} \tag{2.80}$$

Entonces se tiene $f(x) = f^+(x) - f^-(x), \quad |f(x)| = f^+(x) + f^-(x)$.. Definimos la integral de f como

$$\int f\,d\mu := \int f^+\,d\mu - \int f^-\,d\mu. \tag{2.81}$$

Lema 2.3.7 Linealidad para la diferencia. Si $f = f_1 - f_2$ con $f_1, f_2 \geq 0$ y $\int f_i\,d\mu < \infty$, entonces

$$\int f\,d\mu = \int f_1\,d\mu - \int f_2\,d\mu. \tag{2.82}$$

La demostración queda al lector.

Teorema 2.3.5 Teorema de las propiedades fundamentales de la integral de Lebesgue. Supóngase que f y g son integrables. Entonces

$$f \geq 0 \text{ en casi todas partes} \Rightarrow \int f\,d\mu \geq 0. \tag{2.83}$$

$$a \in \mathbb{R} \Rightarrow \int af\,d\mu = a\int f\,d\mu. \tag{2.84}$$

$$\int (f+g)\,d\mu = \int f\,d\mu + \int g\,d\mu. \tag{2.85}$$

$$g \leq f \text{ en casi todas partes} \Rightarrow \int g\,d\mu \leq \int f\,d\mu. \tag{2.86}$$

$$g = f \text{ en casi todas partes} \Rightarrow \int g\,d\mu = \int f\,d\mu. \tag{2.87}$$

$$\left|\int f\,d\mu\right| \leq \int |f|\,d\mu. \tag{2.88}$$

La demostración se deja al lector.

Teorema 2.3.6 Desigualdad de Jensen. Sea $\varphi : \mathbb{R} \to \mathbb{R}$ una función convexa, es decir, para todo $\lambda \in (0,1)$ y $x, y \in \mathbb{R}$ se cumple

$$\lambda\varphi(x) + (1-\lambda)\varphi(y) \geq \varphi(\lambda x + (1-\lambda)y). \tag{2.89}$$

Sea μ una medida de probabilidad sobre $(\Omega, \mathcal{A})$, y sea $f : \Omega \to \mathbb{R}$ tal que f y $\varphi \circ f$ son integrables. Entonces

$$\varphi\left(\int f\,d\mu\right) \leq \int \varphi(f)\,d\mu. \tag{2.90}$$

Demostración. Sea $c := \int f\,d\mu$. Por la convexidad de φ, existe una función lineal $\ell(x) = ax + b$ tal que $\ell(c) = \varphi(c)$ y $\varphi(x) \geq \ell(x)$ para todo $x \in \mathbb{R}$. Para ver que tal función existe, se considera que la convexidad implica

$$\lim_{h\to 0^+} \frac{\varphi(c) - \varphi(c-h)}{h} \leq \lim_{h\to 0^+} \frac{\varphi(c+h) - \varphi(c)}{h}.$$

Si se toma cualquier a entre ambos límites y se define $\ell(x) := a(x-c) + \varphi(c)$. Dado que $\varphi(f) \geq \ell(f)$, se tiene que

$$\int \varphi(f)\,d\mu \geq \int \ell(f)\,d\mu = \int (af+b)\,d\mu = a\int f\,d\mu + b = \ell\left(\int f\,d\mu\right) = \varphi(c).$$

□

2.3.7. Sucesiones de funciones

Teorema 2.3.7 Teorema de convergencia acotada. Sea $E \subset \Omega$ con $\mu(E) < \infty$. Supóngase que f_n es una sucesión de funciones medibles tales que $f_n = 0$ en E^c, $|f_n(x)| \leq M$ para todo $x \in E$, y que $f_n \to f$ en medida. Entonces

$$\int f\,d\mu = \lim_{n\to\infty} \int f_n\,d\mu. \tag{2.91}$$

Demostración. Sea $\varepsilon > 0$ fijo. Definace $G_n := \{x \in E : |f_n(x) - f(x)| < \varepsilon\}$ y $B_n := E \setminus G_n$, se tiene que

$$\left|\int f\,d\mu - \int f_n\,d\mu\right| = \left|\int (f - f_n)\,d\mu\right| \leq \int |f - f_n|\,d\mu.$$

Separando la integral sobre G_n y B_n, se obtiene

$$\int |f - f_n|\, d\mu = \int_{G_n} |f - f_n|\, d\mu + \int_{B_n} |f - f_n|\, d\mu.$$

En G_n, se cumple $|f - f_n| < \varepsilon$, por lo que

$$\int_{G_n} |f - f_n|\, d\mu \leq \varepsilon\, \mu(E).$$

En B_n, como $|f_n(x)| \leq M$ y $|f(x)| \leq M$ casi en todas partes, se tiene $|f(x) - f_n(x)| \leq 2M$, y por tanto

$$\int_{B_n} |f - f_n|\, d\mu \leq 2M\, \mu(B_n).$$

Combinando ambas estimaciones

$$\left| \int f\, d\mu - \int f_n\, d\mu \right| \leq \varepsilon\, \mu(E) + 2M\, \mu(B_n).$$

Como $f_n \to f$ en medida, se tiene $\mu(B_n) \to 0$ cuando $n \to \infty$. Dado que $\varepsilon > 0$ es arbitrario y $\mu(E) < \infty$, se concluye que

$$\lim_{n\to\infty} \int f_n\, d\mu = \int f\, d\mu.$$

□

Lema 2.3.8 Lema de Fatou. Sea $\{f_n\}$ una sucesión de funciones medibles no negativas. Entonces

$$\liminf_{n\to\infty} \int f_n\, d\mu \geq \int \liminf_{n\to\infty} f_n\, d\mu. \tag{2.92}$$

Demostración. Sea $g_n(x) := \inf_{m\geq n} f_m(x)$. Entonces $f_n(x) \geq g_n(x)$ se tiene

$$\liminf_{n\to\infty} \int f_n\, d\mu \geq \liminf_{n\to\infty} \int g_n\, d\mu.$$

Por tanto, basta probar que $\liminf_{n\to\infty} \int g_n\, d\mu \geq \int g\, d\mu$. Sea $E_m \to \Omega$ una sucesión de conjuntos medibles creciente con $\mu(E_m) < \infty$. Como $g_n \geq 0$, y para cada m fijo se tiene que $\min\{g_n, m\}\mathbf{1}_{E_m} \to \min\{g, m\}\mathbf{1}_{E_m}$ casi en todas partes, el teorema de convergencia acotada implica

$$\lim_{n\to\infty} \int_{E_m} \min\{g_n, m\}\, d\mu = \int_{E_m} \min\{g, m\}\, d\mu.$$

Como $g_n \geq g_n \wedge m$, se tiene

$$\liminf_{n\to\infty} \int g_n\, d\mu \geq \int_{E_m} \min\{g, m\}\, d\mu.$$

Tomando el supremo sobre m se concluye que

$$\liminf_{n\to\infty} \int f_n\, d\mu \geq \int g\, d\mu = \int \liminf_{n\to\infty} f_n\, d\mu.$$

□

Teorema 2.3.8 Teorema de convergencia monotona. Sea $\{f_n\}$ una sucesión de funciones medibles no negativas tal que $f_n \to f$ crecientes. Entonces

$$\int f_n \, d\mu \to \int f \, d\mu. \tag{2.93}$$

Demostración. Por el Lema de Fatou, se tiene

$$\liminf_{n\to\infty} \int f_n \, d\mu \geq \int f \, d\mu.$$

Como $f_n \leq f$, también se tiene

$$\limsup_{n\to\infty} \int f_n \, d\mu \leq \int f \, d\mu.$$

Por tanto

$$\lim_{n\to\infty} \int f_n \, d\mu = \int f \, d\mu.$$

□

Teorema 2.3.9 Teorema de convergencia dominada. Sea $\{f_n\}$ una sucesión de funciones medibles tal que $f_n \to f$ casi en todas partes, $|f_n| \leq g$ para todo n, y g integrable. Entonces

$$\lim_{n\to\infty} \int f_n \, d\mu = \int f \, d\mu. \tag{2.94}$$

Demostración. Como $f_n + g \geq 0$, el Lema de Fatou implica

$$\liminf_{n\to\infty} \int (f_n + g) \, d\mu \geq \int (f + g) \, d\mu.$$

Restando $\int g \, d\mu$ en ambos lados se obtiene

$$\liminf_{n\to\infty} \int f_n \, d\mu \geq \int f \, d\mu.$$

Aplicando el mismo argumento a $-f_n$, se obtiene

$$\limsup_{n\to\infty} \int f_n \, d\mu \leq \int f \, d\mu.$$

Por tanto,

$$\lim_{n\to\infty} \int f_n \, d\mu = \int f \, d\mu.$$

Esto concluye la demostración.

□

2.3.8. Teorema Riemann-Lebesgue

Teorema 2.3.10 Teorema Riemann-Lebesgue. Sea $f : [a, b] \to \mathbb{R}$ una función acotada y

Riemann-integrable. Entonces f es medible y Lebesgue-integrable, y se cumple

$$\int_{[a,b]} f(x)\,dx = \int_{[a,b]} f(x)\,d\mu(x). \tag{2.95}$$

La demostración queda al lector. Nada mas note las sumas inferiores y superiores puede acotar la integral, en cuyo caso como es Riemann integrable todas las sumas de Riemann convergen entre si.

2.3.9. Medida del producto

Definición 2.3.12 Espacio de medida producto. Sean $(X, \mathscr{A}, \mu_1)$ y $(Y, \mathscr{B}, \mu_2)$ dos espacios de medida σ-finitos. Definimos el espacio producto como

$$\Omega = X \times Y = \{(x, y) : x \in X, y \in Y\}.$$

La colección de rectángulos como

$$\mathscr{S} = \{A \times B : A \in \mathscr{A}, B \in \mathscr{B}\}.$$

Definición 2.3.13 Medida producto. La σ-álgebra generada por $\mathscr{S}$ se denota $\mathscr{F} = \sigma(\mathscr{S})$. La medida μ en $\mathscr{F}$ tal que

$$\mu(A \times B) = \mu_1(A)\mu_2(B) \tag{2.96}$$

se denota comúnmente como $\mu_1 \times \mu_2$.

Teorema 2.3.11 Teorema de la medida producto. Existe una única medida μ en $\mathscr{F}$ tal que

$$\mu(A \times B) = \mu_1(A)\mu_2(B). \tag{2.97}$$

Demostración. Para probar la unicidad, consideremos que si $A \times B = \bigsqcup_i (A_i \times B_i)$ contable, entonces

$$\mu(A \times B) = \sum_i \mu(A_i \times B_i).$$

Para cada $x \in A$, definimos $I(x) = \{i : x \in A_i\}$. Entonces $B = \bigcup_{i \in I(x)} B_i$, por lo que

$$1_A(x)\mu_2(B) = \sum_i 1_{A_i}(x)\mu_2(B_i).$$

Integrando con respecto a μ_1, se obtiene

$$\mu_1(A)\mu_2(B) = \sum_i \mu_1(A_i)\mu_2(B_i),$$

□

Usando este teorema y el principio de inducción, se deduce que si $(\Omega_i, \mathscr{F}_i, \mu_i)$, $i = 1, \ldots, n$, son espacios de medida σ-finitos y $\Omega = \Omega_1 \times \cdots \times \Omega_n$, existe una única medida μ en la σ-álgebra $\mathscr{F}$ generada por conjuntos de la forma $A_1 \times \cdots \times A_n$, $A_i \in \mathscr{F}_i$, tal que

$$\mu(A_1 \times \cdots \times A_n) = \prod_{m=1}^{n} \mu_m(A_m). \tag{2.98}$$

Cuando $(\Omega_i, \mathscr{F}_i, \mu_i) = (\mathbb{R}, \mathscr{R}, \lambda)$ para todo i, el resultado es la medida de Lebesgue en los subconjuntos de Borel del espacio euclídeo n-dimensional $\mathbb{R}^n$.

Lema 2.3.9 Lema de las secciones medibles. Sea $E_x = \{y : (x, y) \in E\}$ la sección transversal en x. Si $E \in \mathscr{F}$, entonces $E_x \in \mathscr{B}$.

Demostración. Dado que $(E^c)_x = (E_x)^c$ y $(\bigcup_i E_i)_x = \bigcup_i (E_i)_x$, como $\mathscr{E}$ contiene rectángulos $\in \mathscr{B}$, la colección $\mathscr{E} = \{E : E_x \in \mathscr{B}\}$ es una σ-álgebra.

□

Lema 2.3.10 Lema de Tonelli para funciones indicadoras. Si $E \in \mathscr{F}$, entonces $g(x) \equiv \mu_2(E_x)$ es $\mathscr{A}$-medible y

$$\int_X g \, d\mu_1 = \mu(E).$$

Demostración. Sea $\mathscr{L}$ la colección de conjuntos $E \in \mathscr{F}$ tales que $x \mapsto \mu_2(E_x)$ es $\mathscr{A}$-medible y $\int_X \mu_2(E_x)\, d\mu_1 = \mu(E)$.

Si $E = A \times B$ con $A \in \mathscr{A}$, $B \in \mathscr{B}$, entonces $E_x = B$ si $x \in A$ y $E_x = \varnothing$ si $x \notin A$, luego $\mu_2(E_x) = \mu_2(B)\, \mathbf{1}_A(x)$, que es $\mathscr{A}$-medible, y

$$\int_X \mu_2(E_x)\, d\mu_1 = \mu_2(B)\, \mu_1(A) = \mu(A \times B).$$

Por tanto los rectángulos medibles pertenecen a $\mathscr{L}$, y forman un π-sistema que genera $\mathscr{F}$.

Verificamos que $\mathscr{L}$ es un λ-sistema en el caso $\mu_1(X), \mu_2(Y) < \infty$. El total $\Omega = X \times Y$ pertenece a $\mathscr{L}$ pues $\mu_2(\Omega_x) = \mu_2(Y)$ es constante y $\int_X \mu_2(Y)\, d\mu_1 = \mu_2(Y)\mu_1(X) = \mu(\Omega)$. Si $A \subseteq B$ con $A, B \in \mathscr{L}$, entonces $\mu_2((B \setminus A)_x) = \mu_2(B_x) - \mu_2(A_x)$, diferencia de funciones $\mathscr{A}$-medibles, luego también $\mathscr{A}$-medible. Como $\mu_1(X) < \infty$ y $\mu_2(Y) < \infty$ las integrales son finitas y

$$\int_X \mu_2((B \setminus A)_x)\, d\mu_1 = \int_X \mu_2(B_x)\, d\mu_1 - \int_X \mu_2(A_x)\, d\mu_1 = \mu(B) - \mu(A) = \mu(B \setminus A),$$

luego $B \setminus A \in \mathscr{L}$. Si $(E_n) \subseteq \mathscr{L}$ es creciente con $E_n \nearrow E$, entonces $(E_n)_x \nearrow E_x$ y por continuidad de μ_2 desde abajo $\mu_2((E_n)_x) \nearrow \mu_2(E_x)$, que es $\mathscr{A}$-medible por ser límite puntual de funciones medibles. Por el teorema de convergencia monótona,

$$\int_X \mu_2(E_x)\, d\mu_1 = \lim_{n\to\infty} \int_X \mu_2((E_n)_x)\, d\mu_1 = \lim_{n\to\infty} \mu(E_n) = \mu(E),$$

luego $E \in \mathscr{L}$. Por tanto $\mathscr{L}$ es un λ-sistema que contiene al π-sistema de rectángulos, y por el teorema de Dynkin $\mathscr{F} = \sigma(\text{rectángulos}) \subseteq \mathscr{L}$, es decir $\mathscr{L} = \mathscr{F}$.

Para el caso σ-finito, sea $\Omega_n = X_n \times Y_n \nearrow \Omega$ con $\mu_1(X_n), \mu_2(Y_n) < \infty$. Dado $E \in \mathscr{F}$, el caso finito da $\mu_2((E \cap \Omega_n)_x) = \mu_2(E_x \cap Y_n)$ medible e $\int_X \mu_2(E_x \cap Y_n)\, d\mu_1 = \mu(E \cap \Omega_n)$. Como $E_x \cap Y_n \nearrow E_x$, el teorema de convergencia monótona aplicado dos veces da

$$\int_X \mu_2(E_x)\, d\mu_1 = \lim_{n\to\infty} \int_X \mu_2(E_x \cap Y_n)\, d\mu_1 = \lim_{n\to\infty} \mu(E \cap \Omega_n) = \mu(E).$$

□

2.3.10. Teorema de Fubini-Tonelli

Teorema 2.3.12 Teorema de Fubini-Tonelli. Sean $(X, \mathscr{A}, \mu_1)$ y $(Y, \mathscr{B}, \mu_2)$ dos espacios de medida σ-finitos, con $\Omega = X \times Y$, $\mathscr{S} = \{A \times B : A \in \mathscr{A}, B \in \mathscr{B}\}$ y $\mathscr{F} = \sigma(\mathscr{S})$. Si $f \geq 0$ o $\int |f|\, d\mu < \infty$, entonces

$$\int_X \left(\int_Y f(x,y)\, \mu_2(dy) \right) \mu_1(dx) = \int_{X\times Y} f\, d\mu = \int_Y \left(\int_X f(x,y)\, \mu_1(dx) \right) \mu_2(dy). \tag{2.99}$$

Demostración. El lema de Tonelli para indicadoras garantiza que para todo $E \in \mathscr{F}$, la función $y \mapsto \mathbf{1}_{E_x}(y)$ es $\mathscr{B}$-medible, $x \mapsto \mu_2(E_x)$ es $\mathscr{A}$-medible, y

$$\int_X \mu_2(E_x)\, d\mu_1 = \mu(E),$$

lo que establece el resultado para $f = \mathbf{1}_E$. Por linealidad de la integral, el resultado se extiende a funciones simples no negativas.

Si $f \geq 0$, definamos

$$f_n = \text{mín}\left(\frac{\lfloor 2^n f \rfloor}{2^n},\, n \right).$$

Las f_n son funciones simples no negativas, forman una sucesión creciente y $f_n \nearrow f$ puntualmente. Por el caso anterior,

$$\int_X \left(\int_Y f_n(x,y)\, \mu_2(dy) \right) \mu_1(dx) = \int_{X\times Y} f_n\, d\mu = \int_Y \left(\int_X f_n(x,y)\, \mu_1(dx) \right) \mu_2(dy).$$

Las integrales interiores $\int_Y f_n(x,y)\, \mu_2(dy)$ crecen puntualmente en x hacia $\int_Y f(x,y)\, \mu_2(dy)$, y análogamente en y. Aplicando el teorema de convergencia monótona a cada una de las tres integrales,

$$\int_X \left(\int_Y f(x,y)\, \mu_2(dy) \right) \mu_1(dx) = \int_{X\times Y} f\, d\mu = \int_Y \left(\int_X f(x,y)\, \mu_1(dx) \right) \mu_2(dy).$$

Para el caso general, escribimos $f = f^+ - f^-$. Como $\int |f|\, d\mu < \infty$, se tiene $\int f^+\, d\mu < \infty$ y $\int f^-\, d\mu < \infty$. Aplicando el caso no negativo a f^+ y f^- por separado y restando, la linealidad de la integral permite concluir

$$\int_X \left(\int_Y f(x,y)\, \mu_2(dy) \right) \mu_1(dx) = \int_{X\times Y} f\, d\mu = \int_Y \left(\int_X f(x,y)\, \mu_1(dx) \right) \mu_2(dy).$$

□

2.4. L^p

Definición 2.4.1 Espacio $L^p(\mu)$. Sea $(\Omega, \mathscr{F}, \mu)$ un espacio de medida y $1 \leq p < \infty$. Definimos

$$L^p(\mu) = \left\{ f : \Omega \to \mathbb{R} \text{ medible} : \int_\Omega |f|^p\, d\mu < \infty \right\} / \sim, \tag{2.100}$$

donde $f \sim g$ si $f = g$ μ-casi en todas partes. La norma en este espacio se define como

$$\|f\|_p = \left(\int_\Omega |f|^p\, d\mu \right)^{1/p}. \tag{2.101}$$

Para $p = \infty$ definimos $L^\infty(\mu)$ como el espacio de funciones medibles esencialmente acotadas, con norma

$$\|f\|_\infty = \inf\{M \geq 0 : |f| \leq M \ \mu\text{-c.s.}\}. \tag{2.102}$$

Definición 2.4.2 Exponente conjugado. Dado $1 \leq p \leq \infty$, se llama exponente conjugado de p al valor q determinado por

$$\frac{1}{p} + \frac{1}{q} = 1, \tag{2.103}$$

con las convenciones $q = \infty$ si $p = 1$ y $q = 1$ si $p = \infty$.

2.4.1. Desigualda de Hölder y Minkowski

Teorema 2.4.1 Desigualdad de Hölder. Sean $1 \leq p \leq \infty$ y q su exponente conjugado. Si $f \in L^p(\mu)$ y $g \in L^q(\mu)$, entonces $fg \in L^1(\mu)$ y

$$\int_\Omega |fg| \, d\mu \leq \|f\|_p \|g\|_q. \tag{2.104}$$

Demostración. Si $\|f\|_p = 0$ o $\|g\|_q = 0$, entonces $|fg| = 0$ casi en todas partes, y la desigualdad es trivial. Por tanto, basta probar el resultado cuando $\|f\|_p = \|g\|_q = 1$, ya que el caso general se obtiene multiplicado ambos lados por $\|f\|_p \, \|g\|_q$. Definace

$$\varphi(x) := \frac{x^p}{p} + \frac{y^q}{q} - xy \quad \text{para } x \geq 0.$$

Entonces $\varphi'(x) = x^{p-1} - y, \quad \varphi''(x) = (p-1)x^{p-2}$, por lo que φ tiene un mínimo en $x_0 = y^{1/(p-1)}$, como $q = \frac{p}{p-1}$, se tiene $x_0^p = y^q$, y por tanto

$$\varphi(x_0) = \frac{y^q}{p} + \frac{y^q}{q} - y^{1/(p-1)}y = y^q \left(\frac{1}{p} + \frac{1}{q}\right) - y^{1/(p-1)}y = y^q - y^q = 0.$$

Como x_0 es el mínimo, se concluye que

$$xy \leq \frac{x^p}{p} + \frac{y^q}{q}.$$

Tomando $x = |f|$, $y = |g|$, e integrando, se obtiene

$$\int |fg| \, d\mu \leq \int \frac{|f|^p}{p} \, d\mu + \int \frac{|g|^q}{q} \, d\mu = \frac{1}{p} + \frac{1}{q} = 1.$$

El caso general se deduce multiplicando por $\|f\|_p \, \|g\|_q$. Ya que podemos asumir que $f' = \frac{f}{\|f\|_p}$, de forma que $\|f'\|_p = 1$.

□

Teorema 2.4.2 Desigualdad de Minkowski. Sean $1 \leq p \leq \infty$ y $f, g \in L^p(\mu)$. Entonces $f + g \in L^p(\mu)$ y

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p. \tag{2.105}$$

La demostración se deja al lector.

2.4.2. Propiedades de L^p

Teorema 2.4.3 Relación entre espacios L^p en medida finita. Si $\mu(\Omega) < \infty$ y $1 \leq p \leq r \leq \infty$, entonces $L^r(\mu) \subseteq L^p(\mu)$ y

$$\|f\|_p \leq \mu(\Omega)^{1/p-1/r}\|f\|_r. \tag{2.106}$$

Demostración. Como se puede intuir, para este caso hay que aplicar la desigualdad de Hölder pero con las funciones $|f|^p$ y 1. Donde se ocupa de q de forma que $\frac{p}{r} + \frac{1}{q} = 1$, en cuyo caso $q = \frac{r}{r-p}$. Entonces aplicando la desigualdad de Hölder se tiene que

$$\|f\|_p^p \leq \left(\int_\Omega |f|^r \, d\mu\right)^{\frac{p}{r}} \left(\int_\Omega 1 \, d\mu\right)^{\frac{r-p}{r}}$$

ahora, basta con elevar a ambos lados por $\frac{1}{p}$, manteniendo la desigualdad (ya que las desigualdades se sostienen ante transformaciones monótonas crecientes)

$$\|f\|_p \leq \left(\int_\Omega |f|^r \, d\mu\right)^{\frac{1}{r}} \left(\int_\Omega 1 \, d\mu\right)^{\frac{r-p}{rp}} = \mu(\Omega)^{1/p-1/r}\|f\|_r.$$

□

Definición 2.4.3 Espacio métrico completo. Un espacio métrico (X, d) se dice completo si toda sucesión de Cauchy en X converge a un elemento de X, es decir, si para toda sucesión $(x_n)_{n\geq 1}$ en X tal que

$$\lim_{n,m\to\infty} d(x_n, x_m) = 0, \tag{2.107}$$

existe $x \in X$ tal que $x_n \to x$.

Definición 2.4.4 Espacio de Banach. Un espacio vectorial normado $(X, \|\cdot\|)$ se dice un espacio de Banach si es completo respecto a la métrica inducida por su norma, es decir, si toda sucesión de Cauchy $(x_n)_{n\geq 1}$ en X con

$$\lim_{n,m\to\infty} \|x_n - x_m\| = 0 \tag{2.108}$$

converge a algún $x \in X$ con $\|x_n - x\| \to 0$.

Teorema 2.4.4 Riesz-Fischer. Para $1 \leq p \leq \infty$, el espacio $L^p(\mu)$ es completo, es decir, toda sucesión de Cauchy en $L^p(\mu)$ converge en $L^p(\mu)$. En particular, $L^p(\mu)$ es un espacio de Banach.

La demostración se deja al lector. La parte de la completitud es consecuencia directa de la desigualdad de Minkowski. Por otro lado la parte de Banach se utilizan las ultimas dos desigualdades.

Definición 2.4.5 Conjunto denso. Sea (X, d) un espacio métrico y $A, B \subseteq X$. Se dice que A es denso en B si para todo $x \in B$ y todo $\varepsilon > 0$ existe $a \in A$ tal que

$$d(a, x) < \varepsilon, \tag{2.109}$$

o equivalentemente si $\overline{A} \supseteq B$, donde $\overline{A}$ denota la clausura de A en X.

Teorema 2.4.5 Densidad de funciones simples en L^p. Sea $1 \leq p < \infty$. El conjunto de funciones simples es denso en $L^p(\mu)$, es decir, para todo $f \in L^p(\mu)$ y todo $\varepsilon > 0$ existe una función simple φ tal que

$$\|f - \varphi\|_p < \varepsilon. \tag{2.110}$$

De aquí para abajo cuando tenga tiempo xd.

Teorema 2.4.6 Densidad de C_c en L^p. Sea $1 \leq p < \infty$ y μ la medida de Lebesgue en $\mathbb{R}^n$. El espacio de funciones continuas con soporte compacto $C_c(\mathbb{R}^n)$ es denso en $L^p(\mu)$.

Definición 2.4.6 Producto interno en L^2. En el espacio $L^2(\mu)$ se define el producto interno

$$\langle f, g \rangle = \int_\Omega f g \, d\mu, \tag{2.111}$$

el cual induce la norma $\|f\|_2 = \langle f, f \rangle^{1/2}$.

Definición 2.4.7 Espacio de Hilbert. Un espacio vectorial H sobre $\mathbb{R}$ o $\mathbb{C}$ se dice un espacio de Hilbert si está dotado de un producto interno $\langle \cdot, \cdot \rangle : H \times H \to \mathbb{R}$ que satisface para todo $x, y, z \in H$ y $\alpha \in \mathbb{R}$:

$$\langle \alpha x + y, z \rangle = \alpha \langle x, z \rangle + \langle y, z \rangle, \tag{2.112}$$

$$\langle x, y \rangle = \langle y, x \rangle, \tag{2.113}$$

$$\langle x, x \rangle \geq 0, \quad \text{con } \langle x, x \rangle = 0 \text{ si y solo si } x = 0; \tag{2.114}$$

y además es completo respecto a la norma inducida

$$\|x\| = \sqrt{\langle x, x \rangle}. \tag{2.115}$$

En particular, todo espacio de Hilbert es un espacio de Banach.

Teorema 2.4.7 $L^2(\mu$ es un espacio de Hilbert). El espacio $L^2(\mu)$ dotado del producto interno anterior es un espacio de Hilbert, es decir, es completo respecto a la norma inducida por dicho producto interno.

Teorema 2.4.8 Identidad de Parseval. Sea $\{e_n\}_{n \geq 1}$ una base ortonormal de $L^2(\mu)$. Entonces para todo $f \in L^2(\mu)$,

$$\|f\|_2^2 = \sum_{n=1}^{\infty} |\langle f, e_n \rangle|^2, \tag{2.116}$$

y además $f = \sum_{n=1}^{\infty} \langle f, e_n \rangle e_n$ con convergencia en $L^2(\mu)$.

Teorema 2.4.9 Proyección ortogonal. Sea H un subespacio cerrado de $L^2(\mu)$. Para todo $f \in L^2(\mu)$ existe un único $g \in H$ tal que

$$\|f - g\|_2 = \inf_{h \in H} \|f - h\|_2, \tag{2.117}$$

y se tiene la descomposición ortogonal $f = g + (f - g)$ con $f - g \perp H$.

Definición 2.4.8 Funcional lineal acotado y dual. Un funcional lineal $\Lambda : L^p(\mu) \to \mathbb{R}$ se dice acotado si existe $C > 0$ tal que $|\Lambda(f)| \leq C\|f\|_p$ para todo $f \in L^p(\mu)$. El espacio dual $(L^p(\mu))^*$ es el espacio de todos los funcionales lineales acotados sobre $L^p(\mu)$.

Teorema 2.4.10 Dualidad de L^p. Sean $1 < p < \infty$ y q su exponente conjugado. Para todo funcional lineal acotado $\Lambda \in (L^p(\mu))^*$ existe un único $g \in L^q(\mu)$ tal que

$$\Lambda(f) = \int_\Omega fg\, d\mu \quad \forall f \in L^p(\mu), \tag{2.118}$$

y además $\|\Lambda\| = \|g\|_q$. En consecuencia $(L^p(\mu))^* \cong L^q(\mu)$.

Teorema 2.4.11 Dualidad de L^1. El dual de $L^1(\mu)$ es isométricamente isomorfo a $L^\infty(\mu)$: para todo $\Lambda \in (L^1(\mu))^*$ existe un único $g \in L^\infty(\mu)$ tal que

$$\Lambda(f) = \int_\Omega fg\, d\mu \quad \forall f \in L^1(\mu), \tag{2.119}$$

con $\|\Lambda\| = \|g\|_\infty$.

Teorema 2.4.12 Convergencia en L^p implica convergencia en medida. Si $f_n \to f$ en $L^p(\mu)$ con $1 \leq p < \infty$, entonces $f_n \to f$ en medida. Si además $\mu(\Omega) < \infty$, existe una subsucesión que converge μ-casi en todas partes.

Teorema 2.4.13 Criterio de uniformemente integrabilidad en L^1. Una sucesión $\{f_n\} \subset L^1(\mu)$ con $\mu(\Omega) < \infty$ satisface $f_n \to f$ en $L^1(\mu)$ si y solo si $f_n \to f$ en medida y la sucesión es uniformemente integrable, es decir,

$$\lim_{M\to\infty} \sup_n \int_{\{|f_n|>M\}} |f_n|\, d\mu = 0. \tag{2.120}$$

2.4.3. Medida signada

Definición 2.4.9 Medida signada. Sea $(\Omega, \mathscr{F})$ un espacio medible. Una función $\alpha\colon \mathscr{F} \to (-\infty, \infty]$ se llama una medida signada si

$$\alpha(\varnothing) = 0. \tag{2.121}$$

$$\text{Si } E = \bigsqcup_i E_i \text{ es una unión disjunta, entonces } \alpha(E) = \sum_i \alpha(E_i). \tag{2.122}$$

con las siguientes condiciones

$$\text{Si } \alpha(E) < \infty, \sum_i |\alpha(E_i)| \leq \infty \text{ y } \sum_i \alpha(E_i) = \alpha(E).$$

$$\text{Si } \alpha(E) = \infty, \text{ entonces } \sum_i \alpha(E_i)^- < \infty \text{ y } \sum_i \alpha(E_i)^+ = \infty.$$

Definición 2.4.10 Conjuntos positivos y negativos respecto de una medida signada. Un conjunto $A \in \mathscr{F}$ es positivo si

$$\forall_{B \subset A}(\alpha(B) \geq 0). \tag{2.123}$$

Es negativo si

$$\forall_{B \subset A}(\alpha(B) \leq 0). \tag{2.124}$$

Lema 2.4.1 Herencia y unión contable de conjuntos positivos. Todo subconjunto medible de un conjunto positivo es positivo y si A_n son conjuntos positivos, entonces $A = \bigcup_n A_n$ también es positivo.

Demostración. Lo primero es trivial. Para lo segundo defina $B_n = A_n \bigcap_{m=1}^{n-1} A_m^c$, que son disjuntos y positivos. Sea $E \subset A$ medible, entonces $E = \bigcup_n E \cap B_n = \bigcup_n E_n$. Como cada B_n es positivo, se tiene $\alpha(E_n) \geq 0$, y por definición de medida signada

$$\alpha(E) = \sum_n \alpha(E_n) \geq 0.$$

□

Lema 2.4.2 Existencia de un subconjunto negativo. Si $\alpha(E) < 0$, entonces existe $F \subset E$ tal que:

$$F \text{ es negativo y } \alpha(F) < 0. \tag{2.125}$$

Demostración. Si E es negativo, ya está hecho. Si no, construimos una sucesión de subconjuntos $E_k \subset E$ tal que $\alpha(E_k) \geq 1/n_k$. Definimos $F_k = E - \bigcup_{j=1}^{k-1} E_j$. Si alguno F_k es negativo, terminamos. Si no, seguimos indefinidamente y definimos

$$F = E - \bigcup_k E_k = \bigcap_k F_k \Rightarrow \alpha(E) = \alpha(F) + \sum_k \alpha(E_k)$$

Como $\alpha(E) < 0$ y $\alpha(E_k) \geq 0$, se concluye que $\alpha(F) < 0$. Además, ningún subconjunto de F puede tener medida positiva, pues eso contradice la construcción.

□

2.4.4. Descomposición de Hahn y Jordan

Teorema 2.4.14 Descomposicion de Hahn. Sea α una medida signada. Entonces existen conjuntos $A, B \in \mathscr{F}$ tales que$A$ es positivo, B es negativo, $\Omega = A \cup B$ y $A \cap B = \varnothing$.

Demostración. Sea $c = \text{ínf}\{\alpha(B) : \alpha(B) \leq 0, \forall_{A \subset B}\} \leq 0$. Consideramos una sucesión $\{B_i\}$ de conjuntos negativos tal que $\alpha(B_i) \to c^+$, y definimos $B = \bigcup_i B_i$, es claro que $\alpha(B) \geq c$; para demostrar que $\alpha(B) \leq c$, observe que $\alpha(B) = \alpha(B_i) + \alpha(B - B_i) \leq \alpha(B_i)$, ya que B es negativo y $B - B_i \subset B$. Al tomar el límite cuando $i \to \infty$, obtenemos $\alpha(B) \leq c$, y por lo tanto $\alpha(B) = c$.

Ahora definimos $A = B^c$, y queremos probar que A es positivo. Supongamos que existe un conjunto medible $E \subset A$ tal que $\alpha(E) < 0$. Entonces, por el anterior, existe un subconjunto $F \subset E$ tal que F es negativo y $\alpha(F) < 0$. En ese caso, $B \cup F$ sería un conjunto negativo, y se tendría $\alpha(B \cup F) = \alpha(B) + \alpha(F) < c$, lo cual contradice la definición de c como ínfimo. Por lo tanto, tal conjunto E no puede existir, y se concluye que A es positivo. Así, hemos construido una partición $\Omega = A \cup B$ con A positivo y B negativo, y $A \cap B = \varnothing$.

□

Definición 2.4.11 Medidas mutuamente singulares. Sean μ_1 y μ_2 dos medidas sobre un espacio medible $(\Omega, \mathscr{F})$. Se dice que son *mutuamente singulares* si existe un conjunto $A \in \mathscr{F}$ tal que $\mu_1(A) = 0 \quad$ y $\quad \mu_2(A^c) = 0$ En este caso, también se dice que μ_1 es singular con respecto a μ_2, y se denota por $\mu_1 \perp \mu_2$.

Teorema 2.4.15 Descomposicion de Jordan. Sea α una medida signada. Entonces existen medidas α^+, α^- mutuamente singulares tales que

$$\alpha = \alpha^+ - \alpha^-. \tag{2.126}$$

Demostración. Sea $c = \text{ínf}\{\alpha(B) : B \text{ es negativo}\} \leq 0$. Consideramos una sucesión $\{B_i\}$ de conjuntos negativos tal que $\alpha(B_i) \to c^+$, y definimos $B = \bigcup_i B_i$. Dado que B es negativo, y por construcción se tiene que $\alpha(B) \geq c$. Para demostrar que $\alpha(B) \leq c$, observamos que $\alpha(B) = \alpha(B_i) + \alpha(B - B_i) \leq \alpha(B_i)$, ya que $B - B_i \subset B$ y B es negativo. Al tomar el límite cuando $i \to \infty$, obtenemos $\alpha(B) \leq c$, y por lo tanto $\alpha(B) = c$.

Definimos ahora $A = B^c$, y queremos probar que A es positivo. Supongamos que existe un conjunto medible $E \subset A$ tal que $\alpha(E) < 0$. Entonces, por el lema anterior, existe un subconjunto $F \subset E$ tal que F es negativo y $\alpha(F) < 0$. En ese caso, $B \cup F$ sería un conjunto negativo, y se tendría $\alpha(B \cup F) = \alpha(B) + \alpha(F) < c$, lo cual contradice la definición de c como ínfimo. Por lo tanto, tal conjunto E no puede existir, y se concluye que A es positivo. Así, hemos construido una partición $\Omega = A \cup B$ con A positivo y B negativo, y $A \cap B = \varnothing$.

A partir de esta descomposición de Hahn, definimos las medidas α^+ y α^- como sigue

$$\alpha^+(E) = \alpha(E \cap A), \quad \alpha^-(E) = -\alpha(E \cap B).$$

Como A es positivo y B es negativo, se tiene que α^+ y α^- son medidas no negativas. Además, $\alpha^+(B) = 0$ y $\alpha^-(A) = 0$, por lo que son mutuamente singulares. Se verifica que $\alpha = \alpha^+ - \alpha^-$ por construcción.

Para probar la unicidad de esta descomposición, supongamos que existe otra pareja de medidas ν_1, ν_2 tales que $\alpha = \nu_1 - \nu_2$, y que existe un conjunto $D \in \mathscr{F}$ tal que $\nu_1(D) = 0$ y $\nu_2(D^c) = 0$. Definimos $C = D^c$, de modo que $\Omega = C \cup D$ es otra descomposición de Hahn. Por la elección de D, se tiene

$$\nu_1(E) = \alpha(E \cap C), \quad \nu_2(E) = -\alpha(E \cap D).$$

La unicidad de la descomposición de Hahn implica que las intersecciones $A \cap D$ y $B \cap C$ son conjuntos nulos, es decir, tienen medida cero. Por lo tanto

$$\alpha(E \cap C) = \alpha(E \cap (A \cup C)) = \alpha(E \cap A),$$

lo que implica que $\nu_1 = \alpha^+$. De manera análoga, se concluye que $\nu_2 = \alpha^-$, lo que demuestra la unicidad de la descomposición de Jordan.

□

Definición 2.4.12 Absoluta continuidad. Se dice que ν es absolutamente continua con respecto de μ $\nu \ll \mu$ si

$$\mu(A) = 0 \Rightarrow \nu(A) = 0. \tag{2.127}$$

Teorema 2.4.16 Descomposición de Lebesgue. Sean μ y ν medidas σ-finitas sobre un espacio medible $(\Omega, \mathscr{F})$. Entonces existe una descomposición única $\nu = \nu_r + \nu_s$ donde $\nu_r \ll \mu$, $\nu_s \perp \mu$, y existe una función $g \geq 0$ medible tal que

$$\nu_r(E) = \int_E g \, d\mu \quad \text{para todo } E \in \mathscr{F}. \tag{2.128}$$

Demostración. Supongamos primero que μ y ν son finitas. Sea

$$\mathcal{G} = \left\{ g \geq 0 \text{ medible} : \int_E g\, d\mu \leq \nu(E) \ \forall E \in \mathscr{F} \right\}$$

y $\kappa = \sup\{\int g\, d\mu : g \in \mathcal{G}\} \leq \nu(\Omega) < \infty$. Si $g, h \in \mathcal{G}$ y $A = \{g > h\}$, entonces

$$\int_E (g \vee h)\, d\mu = \int_{E\cap A} g\, d\mu + \int_{E\cap A^c} h\, d\mu \leq \nu(E \cap A) + \nu(E \cap A^c) = \nu(E),$$

luego $g \vee h \in \mathcal{G}$. Tomemos $g_n \in \mathcal{G}$ con $\int g_n\, d\mu > \kappa - 1/n$ y definamos $h_n = g_1 \vee \cdots \vee g_n$. Entonces $h_n \in \mathcal{G}$, $h_n \nearrow h$, y por convergencia monótona

$$\int h\, d\mu = \lim_{n\to\infty} \int h_n\, d\mu \geq \lim_{n\to\infty} \int g_n\, d\mu = \kappa.$$

Como $h \in \mathcal{G}$ también $\int h\, d\mu \leq \kappa$, luego $\int h\, d\mu = \kappa$. Definimos

$$\nu_r(E) = \int_E h\, d\mu, \qquad \nu_s(E) = \nu(E) - \nu_r(E).$$

Como $h \in \mathcal{G}$ se tiene $\nu_r(E) \leq \nu(E)$ para todo E, luego $\nu_s \geq 0$ y $\nu_r \ll \mu$ por definición.

Probamos que $\nu_s \perp \mu$. Para cada $\varepsilon > 0$, la medida signada $\nu_s - \varepsilon\mu$ es finita, y por la descomposición de Hahn existe $A_\varepsilon \in \mathscr{F}$ positivo para $\nu_s - \varepsilon\mu$, con $B_\varepsilon = A_\varepsilon^c$ negativo. Si $\mu(A_\varepsilon) > 0$, entonces para todo $E \in \mathscr{F}$,

$$\int_E (h + \varepsilon \mathbf{1}_{A_\varepsilon})\, d\mu = \nu_r(E) + \varepsilon\mu(E \cap A_\varepsilon) \leq \nu_r(E) + \nu_s(E \cap A_\varepsilon) \leq \nu(E),$$

donde en la primera desigualdad usamos que A_ε es positivo para $\nu_s - \varepsilon\mu$. Entonces $h + \varepsilon\mathbf{1}_{A_\varepsilon} \in \mathcal{G}$ y $\int (h + \varepsilon\mathbf{1}_{A_\varepsilon})\, d\mu = \kappa + \varepsilon\mu(A_\varepsilon) > \kappa$, contradiciendo la definición de κ. Luego $\mu(A_\varepsilon) = 0$.

Sea $A = \bigcup_{n=1}^{\infty} A_{1/n}$, de modo que $\mu(A) = 0$. Para todo $E \subseteq A^c$ y todo $n \geq 1$, como $A^c \subseteq B_{1/n}$ es negativo para $\nu_s - \frac{1}{n}\mu$,

$$\nu_s(E) \leq \tfrac{1}{n}\mu(E).$$

Tomando $n \to \infty$ se obtiene $\nu_s(E) = 0$ para todo $E \subseteq A^c$, luego $\nu_s(A^c) = 0$ y por tanto $\nu_s \perp \mu$.

Para la unicidad, supongamos $\nu = \nu_r + \nu_s = \nu_r' + \nu_s'$ con $\nu_r, \nu_r' \ll \mu$ y $\nu_s, \nu_s' \perp \mu$. Entonces $\nu_r - \nu_r' = \nu_s' - \nu_s$. El lado izquierdo es absolutamente continuo respecto a μ y el derecho es singular respecto a μ, luego ambos son cero, es decir $\nu_r = \nu_r'$ y $\nu_s = \nu_s'$.

El caso σ-finito se reduce al finito tomando una partición $\Omega = \bigsqcup_n \Omega_n$ con $\mu(\Omega_n), \nu(\Omega_n) < \infty$, aplicando el resultado en cada Ω_n y definiendo $g = \sum_n g_n \mathbf{1}_{\Omega_n}$, $\nu_s = \sum_n \nu_s^{(n)}$.

□

Definición 2.4.13 Completitud de la medida. Sea $(\Omega, \mathscr{F}, \mu)$ un espacio de medida. Decimos que la medida μ es *completa* si para todo conjunto $A \in \mathscr{F}$ con $\mu(A) = 0$, se cumple que cualquier subconjunto $B \subseteq A$ también pertenece a $\mathscr{F}$ y satisface $\mu(B) = 0$.

Lema 2.4.3 Extensión de la σ–álgebra. Dado un espacio de medida $(\Omega, \mathscr{F}, \mu)$ no necesariamente completo, existe una extensión $\overline{\mathscr{F}}$ de la σ–álgebra $\mathscr{F}$ definida como

$$\overline{\mathscr{F}} := \{E \cup N : E \in \mathscr{F},\ N \subseteq A \text{ con } A \in \mathscr{F},\ \mu(A) = 0\}.$$

La medida extendida $\overline{\mu}$ sobre $\overline{\mathscr{F}}$ se define por

$$\overline{\mu}(E \cup N) := \mu(E).$$

Se prueba después.

Teorema 2.4.17 Completitud de la extensión. La extensión $(\Omega, \overline{\mathscr{F}}, \overline{\mu})$ es un espacio de medida completo, y $\overline{\mu}$ coincide con μ sobre $\mathscr{F}$.

Se prueba después.

2.4.5. Radon-Nikodym

Teorema 2.4.18 Radon-Nikodym. Sean μ, ν medidas σ-finitas con $\nu \ll \mu$. Entonces existe una función $g \geq 0$ tal que:

$$\nu(E) = \int_E g \, d\mu \quad \forall_{E \in \mathscr{F}} \tag{2.129}$$

Además, si h también satisface esta propiedad, entonces:

$$g = h \quad \mu \text{ en casi todas partes.} \tag{2.130}$$

Demostración. Por el teorema de descomposición de Lebesgue existe $\nu = \nu_r + \nu_s$ con $\nu_r \ll \mu$, $\nu_s \perp \mu$ y $\nu_r(E) = \int_E g \, d\mu$ para cierta $g \geq 0$ medible. Sea $A \in \mathscr{F}$ tal que $\mu(A) = 0$ y $\nu_s(A^c) = 0$. Como $\nu \ll \mu$, se tiene $\nu(A) = 0$, luego $\nu_s(A) \leq \nu(A) = 0$. Junto con $\nu_s(A^c) = 0$ se concluye $\nu_s \equiv 0$, de modo que $\nu = \nu_r$ y

$$\nu(E) = \int_E g \, d\mu \quad \forall E \in \mathscr{F}.$$

Para la unicidad, supongamos que $h \geq 0$ satisface también $\nu(E) = \int_E h \, d\mu$ para todo $E \in \mathscr{F}$. Entonces $\int_E (g - h) \, d\mu = 0$ para todo E. Para cada $n \in \mathbb{N}$ tomemos $E_n = \{g > h, g \leq n\}$. En E_n se tiene $g - h > 0$ y la integral es cero, luego $\mu(E_n) = 0$. Como $\{g > h\} = \bigcup_n E_n$, se obtiene $\mu(\{g > h\}) = 0$. Análogamente $\mu(\{h > g\}) = 0$, luego $g = h$ μ c.s.

□

* Cabe recalcar que esta anterior parte tiene diferentes errores que futuramente serán corregidos.

2.5. Probabilidades curiosas

Definición 2.5.1 Distribución de probabilidad en un espacio contable. Sea $(\Omega, \mathscr{F}, \mathbb{P})$ un espacio de probabilidad, con $\Omega = \{\omega_1, \omega_2, ...\}$ contable o finito y $\mathscr{F} = \mathcal{P}(\Omega)$, si $A \subset \Omega$ y $A \neq \varnothing$ se define

$$\mathbb{P}(A) = \sum_{\omega_i} p_i. \tag{2.131}$$

Con $p_i := \mathbb{P}(\omega_i)$, al vector $p := (p_1, p_2, ...)$ se le llama vector de probabilidad

Definición 2.5.2 Probabilidad geométrica. Si $(\Omega, \mathscr{F})$ es un espacio de medible. Con m una medida geométrica sobre $\mathscr{F}$ con $m(\Omega) < \infty$, entonces la probabilidad geométrica se define por

$$\mathbb{P}(A) = \frac{m(A)}{m(\Omega)}. \tag{2.132}$$

Con $A \in \mathscr{F}$

Definición 2.5.3 Probabilidad de Laplace. Un espacio de probabilidad de Laplace, es un espacio de probabilidad $(\Omega, \mathscr{F}, \mathbb{P})$ que cumple que

$$|\Omega| < \infty, \tag{2.133}$$

$$\mathscr{F} = \mathcal{P}(\Omega), \tag{2.134}$$

$$\mathbb{P}(\omega) = \frac{1}{|\Omega|}, \forall_{\omega \in \Omega}. \tag{2.135}$$

A esta medida se le llama distribución clásica o uniforme.

2.6. Probabilidades condicionales

Definición 2.6.1 Probabilidad condicional. Si $A, B \in \mathscr{F}$ en un espacio de probabilidad y $\mathbb{P}(B) > 0$, entonces la probabilidad condicional de A condicionada a B se denota y define por

$$\mathbb{P}(A|B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \tag{2.136}$$

Teorema 2.6.1 Teorema fundamental de la probabilidad condicional. Si $A, B \in \mathscr{F}$ en un espacio de probabilidad y $\mathbb{P}(B) > 0$, entonces

$$\mathbb{D}(A) := \mathbb{P}(A|B) \text{ es una medida de probabilidad,} \tag{2.137}$$

$$\mathbb{P}(A \cap C|B) = \mathbb{P}(A|B \cap C)\mathbb{P}(C|B) \text{ si } \mathbb{P}(B \cap C) > 0. \tag{2.138}$$

Sumado a ello si $A_1, \dots, A_n \in \mathscr{F}$ con $\mathbb{P}(A_1 \cap \cdots \cap A_i) > 0, \forall_{i \leq n-1}$entonces

$$\mathbb{P}(A_1 \cap \cdots \cap A_n) = \mathbb{P}(A_1)\mathbb{P}(A_2|A_1)\mathbb{P}(A_3|A_1 \cap A_2) \cdots \mathbb{P}(A_n|A_1 \cap \cdots \cap A_{n-1}) \tag{2.139}$$

Demostración. Note que

$$\mathbb{D}(\Omega) = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1.$$

Sumado a ello es trivial demostrar que $\mathbb{D} \geq 0$. Ahora note que

$$\mathbb{D}\left(\bigsqcup_{i=1}^{\infty} A_i\right) = \frac{\mathbb{P}\left(\bigsqcup_{i=1}^{\infty} A_i \cap B\right)}{\mathbb{P}(B)} = \sum_{i=1}^{\infty} \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \sum_{i=1}^{\infty} \mathbb{D}(A_i).$$

Para el segundo caso, note simplemente que

$$\mathbb{P}(A \cap C|B) = \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A \cap B \cap C)\mathbb{P}(B \cap C)}{\mathbb{P}(B \cap C)\mathbb{P}(B)} = \mathbb{P}(A|B \cap C)\mathbb{P}(C|B).$$

Y por ultimo es simplemente tomar lo anterior por inducción.

□

Teorema 2.6.2 Teorema de probabilidad total. Si $\{B_1, B_2, ...\}$ es una partición de Ω (Donde $B_i \cap B_j = \varnothing$ si $i \neq j$ y $\bigcup B_i = \Omega$) con $\mathbb{P}(B_i) > 0, \forall_{B_i \in \mathscr{F}}$, entonces

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A|B_i)\mathbb{P}(B_i). \tag{2.140}$$

Con $A \in \mathscr{F}$.

Demostración. Note que

$$\mathbb{P}(A) = \mathbb{P}(A \cap \Omega) = \mathbb{P}\left(\bigcup_i B_i \cap A\right) = \sum_i \mathbb{P}\left(B_i \cap A\right) = \sum_i \mathbb{P}(A|B_i)\mathbb{P}(B_i)$$

□

Teorema 2.6.3 Teorema de Bayes. Sea $\{B_1, B_2, ...\}$ una partición de Ω con $\mathbb{P}(B_i) > 0, \forall_{B_i \in \mathscr{F}}$, entonces para cualquier evento $\mathbb{P}(A) >)$ tenemos que

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_i \mathbb{P}(A|B_i)\mathbb{P}(B_i)}. \tag{2.141}$$

Demostración. Note que por definición de probabilidad condicional y el teorema anterior

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_i \mathbb{P}(A|B_i)\mathbb{P}(B_i)}.$$

□

2.7. Eventos independientes

Definición 2.7.1 Independencia de eventos. Eventos A y B sobre un mismo espacio de probabilidad son llamados independientes si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B). \tag{2.142}$$

Si no se cumple la condición se les llama dependientes.

Cabe recalcar que dos eventos sean independientes no esta conectado directamente con que sea mutuamente excluyentes (Dos eventos son mutuamente excluyentes si $A \cap B = \varnothing$).

Definición 2.7.2 Familias independientes. Las familias $\mathscr{A}_i \subset \mathscr{F}$ se dicen ser independientes si

$$\mathbb{P}\left(\bigcap_i A_i\right) = \prod_i \mathbb{P}(A_i), \forall_{(i \leq n \wedge A_i \in \mathscr{A}_i)}. \tag{2.143}$$

Mas aun, se que las familias de eventos $(A_k)_{k \in I}$son independientes si

$$\mathbb{P}\left(\bigcap_k A_k\right) = \prod_k \mathbb{P}(A_k), \forall_{(k\in J \wedge (A_k)_{k\in J})}. \tag{2.144}$$

Con $J \subset I$ finito no vació (Estos eventos son llamados mutualmente independientes). Por ultimo, son independientes 2 a 2 o en pares si

$$\mathbb{P}(A_i \cap A_j) = \mathbb{P}(A_i)\mathbb{P}(A_j), \forall_{i\neq j} \tag{2.145}$$

3

Variables aleatorias

3.1. Funciones medibles

Definición 3.1.1 Función medible. Una función $X : \Omega \to S$ se dice que es una función medible de $(\Omega, \mathscr{F})$ a $(S, \mathscr{S})$ si

$$X^{-1}(A) \equiv \{\omega \in \Omega : X(\omega) \in A\} \in \mathscr{F} \quad \text{para todo } A \in \mathscr{S}. \tag{3.1}$$

Teorema 3.1.1 Teorema de la medibilidad por generador. Sea $X : \Omega \to S$ una función entre espacios medibles. Si $\{\omega : X(\omega) \in A\} \in \mathscr{F}$ para todo $A \in \mathscr{A}$, y $\mathscr{A}$ genera $\mathscr{S}$ (es decir, $\mathscr{S}$ es la σ-álgebra más pequeña que contiene a $\mathscr{A}$), entonces X es medible.

Demostración. Note que

$$\{X \in \bigcup_i B_i\} = \bigcup_i \{X \in B_i\}, \quad \{X \in B^c\} = (\{X \in B\})^c .$$

Esto muestra que la clase de conjuntos $\mathscr{B} = \{B : \{X \in B\} \in \mathscr{F}\}$ es una σ-álgebra. Como $\mathscr{B} \supset \mathscr{A}$ y $\mathscr{A}$ genera $\mathscr{S}$, se concluye que $\mathscr{B} \supset \mathscr{S}$. Por lo tanto, X es medible.

□

Teorema 3.1.2 Teorema de la composición de funciones medibles. Sea $X : (\Omega, \mathscr{F}) \to (S, \mathscr{S})$ y $f : (S, \mathscr{S}) \to (T, \mathscr{T})$ aplicaciones medibles. Entonces $f(X)$ es una aplicación medible de $(\Omega, \mathscr{F})$ a

$(T, \mathscr{T})$.

Demostración. Sea $B \in \mathscr{T}$. Entonces

$$\{\omega \in \Omega : f(X(\omega)) \in B\} = \{\omega \in \Omega : X(\omega) \in f^{-1}(B)\}$$

Como f es medible, se tiene que $f^{-1}(B) \in \mathscr{S}$, y como X es medible, se concluye que $\{\omega : X(\omega) \in f^{-1}(B)\} \in \mathscr{F}$. Por lo tanto, $f(X)$ es medible.

□

Definición 3.1.2 σ-álgebra de Borel. Sea $\Omega = \mathbb{R}^d$ con $d \in \mathbb{N}$, entonces la menor *sigma*-álgebra sobre $\mathbb{R}^d$ que contiene todos los abiertos $A \subset \mathbb{R}^d$ se detona por $\mathscr{B}(\mathbb{R}^d)$ y es llamada σ-álgebra de Borel.

Teorema 3.1.3 Caracterización de la σ-álgebra de Borel. Sea $\mathscr{B}(\mathbb{R}^d)$ la σ-álgebra de Borel, entonces

$$\mathscr{B}(\mathbb{R}) = \sigma\left(\{(a, b] \mid -\infty \leq a < b < \infty\}\right) = \sigma\left(\{(-\infty, b] \mid b \in \mathbb{R}\}\right). \tag{3.2}$$

De forma general

$$\mathscr{B}(\mathbb{R}^d) = \sigma\left(\left\{\bigtimes_{i=1}^{d}(a_i, b_i] \mid -\infty \leq a_i < b_i < \infty, \forall_{i\leq d}\right\}\right) \tag{3.3}$$

Demostración. Tome $A \in \mathscr{B}(\mathbb{R})$, dado que todo abierto es la unión de abiertos de la forma $(c, d) \mid c < d \wedge c, d \in \mathbb{R}$, se va a demostrar que todo abierto de la forma $(c, d) \in \sigma(\cdot)$. Note que.

$$(c, d) = (-\infty, c]^c \bigcap \bigcup_{n\geq 1}(-\infty, d - 1/n] \Rightarrow \sigma\left(\{(a, b] \mid -\infty \leq a < b < \infty\}\right) \subset \mathscr{B}(\mathbb{R}) = \sigma\left(\{(-\infty, b] \mid b \in \mathbb{R}\}\right)$$

Ahora tome $(-\infty, d]$ y note que.

$$(-\infty, d] = (d, \infty)^c \Rightarrow \sigma\left(\{(a, b] \mid -\infty \leq a < b < \infty\}\right) = \mathscr{B}(\mathbb{R}) \subset \sigma\left(\{(-\infty, b] \mid b \in \mathbb{R}\}\right) \Rightarrow \mathscr{B}(\mathbb{R}) = \sigma(\cdot)$$

La segunda parte del ejercicio es consecuencia directa de lo anteriormente demostrado.

□

3.2. Propiedades de la variables aleatorias

Definición 3.2.1 Variable aleatoria. Sea $(\Omega, \mathscr{F})$ un espacio medible. Un función $X : \Omega \to \mathbb{R}$ es llamado una variable aleatoria si para todo $A \in \mathscr{B}(\mathbb{R})$

$$X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\} \in \mathscr{F}. \tag{3.4}$$

Donde $X^{-1}(A) \in \mathscr{F}$

Usualmente se utiliza la notación $X^{-1}(A) = \{X \in A\}$ para referirse a los subconjuntos de $\mathscr{F}$.

Proposición 3.2.1 Equivalente de variable aleatoria. Sea $X : \Omega \to \mathbb{R}$, entonces es equivalente

$$X \text{ es una variable aleatoria,} \tag{3.5}$$

$$\{X \leq y\} := X^{-1}((-\infty, y]) \in \mathscr{F} \text{ o } \{X < y\} := X^{-1}((-\infty, y)) \in \mathscr{F} \tag{3.6}$$

$$\{a < X \leq b\} := X^{-1}((a, b]) \mid -\infty \leq a < b < \infty \tag{3.7}$$

La demostración es consecuencia directa de la σ-álgebra de Borel y la definición anterior.

Normalmente los libros dividen la siguiente sección en variables aleatorias discretas y continuas, pero es casi lo mismo entonces solo se va a ver generalizado.

Teorema 3.2.1 Operaciones algebraicas con variables aleatorias. Si X, Y dos variables aleatorias, entonces

$$X + Y \text{ es variable aleatoria,} \tag{3.8}$$

$$k \cdot X \text{ es variable aleatoria con } k \in \mathbb{R}, \tag{3.9}$$

$$X \cdot Y \text{ es variable aleatoria .} \tag{3.10}$$

Más aun, si $\{Y = 0\} \neq \varnothing$, entonces

$$\frac{X}{Y} \text{ es variable aleatoria.} \tag{3.11}$$

Demostración. Para el primer caso note que si definimos

$$A := \bigcup_{r \in \mathbb{Q}} (\{X < r\} \cap \{Y < z - r\}) .$$

Entonces $A \in \mathscr{F}$ ya que es una unión contable de elementos de $\mathscr{F}$. Dado que

$$\{X < r\} \cap \{Y < z - r\} = \{\omega \in \Omega \mid X(\omega) \in (-\infty, r)\} \cap \{\omega \in \Omega \mid Y(\omega) \in (-\infty, z - r)\}.$$

Se puede inferir que

$$\bigcup_{r \in \mathbb{Q}} (\{\omega \in \Omega \mid X(\omega) \in (-\infty, r)\} \cap \{\omega \in \Omega \mid Y(\omega) \in (-\infty, z - r)\}) \subset (X + Y)^{-1}((-\infty, z)).$$

Donde

$$(X + Y)^{-1}((-\infty, z)) = \{\omega \in \Omega \mid X(\omega) + Y(\omega) \in (-\infty, z)\}.$$

Ahora note que si $\omega \in \{A + Y < z\}$ entonces $X(\omega < z - Y(\omega))$, en cuyo caso, por densidad de $\mathbb{Q}$ en $\mathbb{R}$ tenemos que $\exists_{l \in \mathbb{Q}} \mid X(\omega) < l < z - Y(\omega)$, entonces se sigue que $\{X + Y < z\} \subset A$, en consecuencia $A = \{X + Y < z\}$.

Siguiendo con la demostración simplemente note que si $k = 0$ tenemos que si $z < 0$ se sigue que $\{kX \leq z\} = \varnothing$ ya que no hay $z \in \mathbb{R} \mid z < 0 < z$, caso contrario si $z \geq 0$ entonces $\{kX \leq z\} = \Omega$ claramente, y en consecuencia kX cumple con la definición de variable aleatoria. Ahora si $k > 0$ entonces $\{kX \leq z\} = \{X \leq \frac{z}{k}\}$, caso similar si $k < 0$ se sigue que $\{kX \leq z\} = \{X \geq \frac{z}{k}\}$ entonces kX es una variable aleatoria.

Para (3.11) primero note que X^2 es una variable aleatoria, ya que si $z < 0$ entonces $\{X^2 \leq z\} = \varnothing$, y si $z \geq 0$ entonces $\{X^2 \leq z\} = \{-\sqrt{z} \leq X \leq \sqrt{z}\} = \{X \leq \sqrt{z}\} \cap \{X \geq -\sqrt{z}\} \in \mathscr{F}$, entonces simplemente note que

$$X \cdot Y = \frac{(X + Y)^2 - (X - Y)^2}{4}.$$

En consecuencia $X \cdot Y$ es una variable aleatoria.

Y por ultimo para (3.12) note que

$$\left\{\frac{X}{Y} \leq z\right\} = \left(\left\{\frac{X}{Y} \leq z\right\} \cap \{Y < 0\}\right) \cup \left(\left\{\frac{X}{Y} \leq z\right\} \cap \{Y > 0\}\right)$$
$$= \left(\{X - zY \geq 0\} \cap \{Y < 0\}\right) \cup \left(\{X - zY \leq 0\} \cap \{Y > 0\}\right).$$

Lo cual es la unión de los eventos de la suma de dos σ-álgebras X, Y, por (3.9) esto es una variable aleatoria.

□

Teorema 3.2.2 Máximo y mínimo de variables aleatorias. Sean $X_1, \dots, X_n$ variables aleatorias, entonces $\max_{1\leq k\leq n} X_k$ y $\min_{1\leq k\leq n} X_k$ son variables aleatorias.

Demostración. Tome $y \in \mathbb{R}$, entonces note que

$$\{\max_{1\leq k\leq n} X_k \leq y\} = \left(\bigcup_{k=1}^{n}\{X_k > y\}\right)^c = \bigcap_{k=1}^{n}\{X_k \leq y\} \in \mathscr{F}.$$

Ya para que $\max_{1\leq k\leq n} X_k \leq y$ todos los $X_k \leq y$, si alguno de los $X_k > y$ entonces $\max_{1\leq k\leq n} X_k > y$, en cuyo caso seria el evento complemento. De forma similar podemos llegar a que

$$\{\min_{1\leq k\leq n} X_k \leq y\} = \bigcup_{k=1}^{n}\{X_k \leq y\} \in \mathscr{F}.$$

□

Teorema 3.2.3 Composición de variables aleatorias. Si $X_1, \dots, X_n$ son variables aleatorias y $f : (\mathbb{R}^n, \mathcal{R}^n) \to (\mathbb{R}, \mathcal{R})$ es una función medible, entonces $f(X_1, \dots, X_n)$ es una variable aleatoria.

Demostración. Note que si $A_1, \dots, A_n$ son conjuntos de Borel, entonces

$$\{(X_1, \dots, X_n) \in A_1 \times \cdots \times A_n\} = \bigcap_{i=1}^{n}\{X_i \in A_i\} \in \mathcal{F}$$

Dado que los conjuntos de la forma $A_1 \times \cdots \times A_n$ generan la σ-álgebra de Borel en $\mathbb{R}^n$, entonces $f(X)$ es una variable aleatoria.

□

Este concepto anterior permite manipular las variables aleatorias mediante cualquier tipo de mapeo que sea una función.

Definición 3.2.2 σ-álgebra generada por una variable aleatoria. La *sigma*-álgebra generada por la variable aleatoria X es la colección

$$\sigma(X) := X^{-1}(A) \mid A \in \mathscr{B}(\mathbb{R}) \tag{3.12}$$

Donde $\sigma(X)$ es toda la información generada por X (Toda la información conocida por definición).

3.3. Distribución de probabilidad

Definición 3.3.1 Distribución inducida por una variable aleatoria. Si $\mathbb{P}$ es una medida de probabilidad sobre $(\Omega, \mathscr{F})$, se le llama distribución de probabilidad de X a $\mathbb{P}_X$ definida sobre $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$ y esta definida por

$$\mathbb{P}_X(A) := \mathbb{P}(\{X \in A\}), \forall_{A \in \mathscr{B}(\mathbb{R})}. \tag{3.13}$$

Proposición 3.3.1 La distribución inducida por una variable aleatoria es una medida de probabilidad. $\mathbb{P}_X$ es una medida de probabilidad sobre $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$.

Demostración. Primero note que

$$\mathbb{P}_X(\mathbb{R}) = \mathbb{P}\left(\{X \in \mathbb{R}\}\right) = \mathbb{P}\left(X^{-1}(\mathbb{R})\right).$$

Y dado que $\forall_{\omega \in \Omega}\left(X(\omega) \in \mathscr{B}(\mathbb{R})\right)$, entonces $\mathbb{P}\left(X^{-1}(\mathbb{R})\right) = \mathbb{P}(\Omega) = 1$. Ahora para la segunda propiedad tome $(A_i)_i$ una secesión disjunta de subconjuntos de $\mathbb{R}$, entonces note que

$$\mathbb{P}_X\left(\bigcup_{i=1}^{\infty} A_i\right) = \mathbb{P}\left(\left\{X \in \bigcup_{i=1}^{\infty} A_i\right\}\right) = \mathbb{P}\left(\bigcup_{i=1}^{\infty} X^{-1}(A_i)\right).$$

Dado que $A_i \cap A_j = \varnothing \iff i \neq j$, entonces por el hecho de pertenencia de cada uno de estos conjuntos, tenemos que $X^{-1}(A_i) \neq X^{-1}(A_j) \iff i \neq j$, entonces

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} X^{-1}(A_i)\right) = \sum_{i=1}^{\infty} \mathbb{P}(X^{-1}(A_i)) = \sum_{i=1}^{\infty} \mathbb{P}_X(A_i).$$

□

3.3.1. Distribucion acumulada

Definición 3.3.2 Función de distribución acumulada. Se le llama función de distribución a la función $F_X : \mathbb{R} \to [0, 1]$, con X variable aleatoria sobre $(\Omega, \mathscr{F}, \mathbb{P})$, y se define como

$$F_X(y) := \mathbb{P}(X \leq y), \forall_{y \in \mathbb{R}}. \tag{3.14}$$

Teorema 3.3.1 Propiedades de la función de distribución acumulada. Sea F_X una función de distribución de una variable aleatoria sobre $(\Omega, \mathscr{F}, \mathbb{P})$, entonces

$$x < y \Rightarrow F_X(x) \leq F_X(y), \tag{3.15}$$

$$F_X(y^+) := \lim_{h \to 0^+} F_X(y + h) = F_X(y), \forall_{y \in \mathbb{R}}, \tag{3.16}$$

$$F_X(y^-) := \lim_{h \to 0^-} F_X(y + h) = \mathbb{P}(X < y), \forall_{y \in \mathbb{R}}, \tag{3.17}$$

$$\lim_{y \to \infty} F_X(y) = 1, \tag{3.18}$$

$$\lim_{y\to-\infty} F_X(y) = 0. \tag{3.19}$$

Demostración. Primero note simplemente que si $x < y$ entonces $\{X \leq x\} \subset \{X \leq y\}$ entonces $F_X(x) \leq F_X(y)$.

Para la segunda tome

$$A_n = \left\{X \leq y + \frac{1}{n}\right\}.$$

Y note que $\{X \leq y\} = \bigcap_{n=i}^{\infty} A_n$ con $i \in \mathbb{N}$, entonces

$$F_X(y^+) = \lim_{h\to 0^+} F_X(y+h) = \lim_{n\to\infty} \mathbb{P}\left(\left\{X \leq y + \frac{1}{n}\right\}\right) = \mathbb{P}\left(\bigcap_{n=i}^{\infty} A_n\right) = \mathbb{P}(\{X \leq y\}) = F_X(y).$$

Ahora para tercera podemos tomar

$$A_n = \left\{X \leq y - \frac{1}{n}\right\}.$$

Entonces $\{X < y\} = \bigcup_{n=i}^{\infty} A_n$ con $i \in \mathbb{N}$, entonces

$$F_X(y^-) = \lim_{h\to 0^-} F_X(y+h) = \lim_{n\to\infty} \mathbb{P}\left(\left\{X \leq y - \frac{1}{n}\right\}\right) = \mathbb{P}\left(\bigcup_{n=i}^{\infty} A_n\right) = \mathbb{P}(\{X < y\}) = \mathbb{P}(X < y).$$

Continuando, es claro que $\{X \leq n\} \subset \{X \leq n+1\}$, entonces $\bigcup_{n=i}^{\infty}\{X \leq n\} = \Omega$. De igual forma note que $\{X \leq -n\} \supset \{X \leq -(n+1)\}$, entonces $\bigcap_{n=i}^{\infty}\{X \leq -n\} = \varnothing$, en consecuencia.

$$\mathbb{P}\left(\bigcup_{n=i}^{\infty}\{X \leq n\}\right) = \mathbb{P}(\Omega) = 1$$

$$\mathbb{P}\left(\bigcap_{n=i}^{\infty}\{X \leq -n\}\right) = \mathbb{P}(\varnothing) = 0.$$

□

Corolario 3.3.1 Cálculo de probabilidades mediante la función de distribución acumulada. Sea F_X una función de distribución de una variable aleatoria sobre $(\Omega, \mathscr{F}, \mathbb{P})$, entonces

$$\mathbb{P}(a \leq X \leq b) = F_X(b) - F_X(a^-) \tag{3.20}$$

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a) \tag{3.21}$$

$$\mathbb{P}(a \leq X < b) = F_X(b^-) - F_X(a^-) \tag{3.22}$$

$$\mathbb{P}(a < X < b) = F_X(b^-) - F_X(a) \tag{3.23}$$

$$\mathbb{P}(X = a) = F_X(a) - F_X(a^-) \tag{3.24}$$

La demostración queda al lector.

Definición 3.3.3 Salto de la función de distribución acumulada. Si $a \in \mathbb{R}$ y $\Delta F_X(a) := F_X(a) - F_X(a^-) \neq 0$ entonces se dice que F_X tiene un salto en a.

3.3.2. Función de Stieltjes

Definición 3.3.4 Función de Stieltjes. Una función $F\colon \mathbb{R} \to \mathbb{R}$ se denomina función de medida de Stieltjes si cumple las $x \leq y \Rightarrow F(x) \leq F(y)$ y $\forall_{x\in\mathbb{R}} \lim_{y\to x^-} F(y) = F(x)$.

Teorema 3.3.2 Teorema de Stieltjes. Asociada a cada función de medida de Stieltjes F (o también llamada función de distribución), existe una medida única μ sobre $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$ tal que

$$\mu((a,b]) = F(b) - F(a) \tag{3.25}$$

Cuando $F(x) = x$, la medida resultante se denomina (λ) medida de Lebesgue.

Demostración. Sea S la semiálgebra de intervalos semiabiertos $(a,b]$ con $-\infty \leq a < b \leq \infty$. Para definir μ sobre S, comenzamos observando que

$$F(\infty) = \lim_{x\to\infty^-} F(x) \quad \text{y} \quad F(-\infty) = \lim_{x\to-\infty^+} F(x)$$

existen, y que $\mu((a,b]) = F(b) - F(a)$ tiene sentido para todo $-\infty \leq a < b \leq \infty$, dado que $F(\infty) > -\infty$ y $F(-\infty) < \infty$. Si $(a,b] = \bigcup_{i=1}^n (a_i, b_i]$, entonces, tras reordenar los intervalos, se debe tener $a_1 = a$, $b_n = b$, y $a_i = b_{i-1}$ para $2 \leq i \leq n$, entonces la primera condición de *Teorema 2.2.5.*.

Para la segunda condición, supongamos primero que $-\infty < a < b < \infty$, y que $(a,b] \subset \bigcup_{i\geq 1} (a_i, b_i]$, donde $-\infty < a_i < b_i < \infty$. Sea $\delta > 0$ tal que $F(a+\delta) < F(a) + \varepsilon$, y elijamos $\eta_i > 0$ tal que

$$F(b_i + \eta_i) < F(b_i) + \varepsilon 2^{-i}.$$

Los intervalos abiertos $(a_i, b_i + \eta_i)$ cubren $[a+\delta, b]$, por lo que existe un subcubrimiento finito (α_j, β_j), $1 \leq j \leq J$. Como $(a+\delta, b] \subset \bigcup_{j=1}^J (\alpha_j, \beta_j]$, se sigue entonces que

$$F(b) - F(a+\delta) \leq \sum_{j=1}^J F(\beta_j) - F(\alpha_j) \leq \sum_{i=1}^\infty \left(F(b_i + \eta_i) - F(a_i)\right).$$

Por la elección de δ y η_i,

$$F(b) - F(a) \leq 2\varepsilon + \sum_{i=1}^\infty \left(F(b_i) - F(a_i)\right),$$

y como ε es arbitrario, se ha demostrado el resultado en el caso $-\infty < a < b < \infty$.

Ahora si $-\infty \leq a < b \leq \infty$, observemos que si $(a,b] \subset \bigcup_i (a_i, b_i]$ y $(A,B] \subset (a,b]$ con $-\infty < A < B < \infty$, entonces

$$F(B) - F(A) \leq \sum_{i=1}^\infty \left(F(b_i) - F(a_i)\right).$$

Como este resultado es válido para cualquier intervalo finito $(A,B] \subset (a,b]$, se concluye el resultado deseado.

□

El resultado anterior se puede generalizar para $\mathbb{R}^d$.

Definición 3.3.5 Función de distribución en $\mathbb{R}^d$. Una función $F : \mathbb{R}^d \to [0,1]$ se dice una función de distribución en $\mathbb{R}^d$ si satisface

$$F \text{ es no decreciente, es decir, si } x \leq y \text{ coordenada a coordenada entonces } F(x) \leq F(y). \tag{3.26}$$

$$F \text{ es continua por derecha, es decir, } \lim_{y \downarrow x} F(y) = F(x). \tag{3.27}$$

Si $x_n \downarrow -\infty$ coordenada a coordenada entonces

$$F(x_n) \downarrow 0 \tag{3.28}$$

y si $x_n \uparrow \infty$ coordenada a coordenada entonces.

$$F(x_n) \uparrow 1. \tag{3.29}$$

Para todo rectángulo finito $A = (a_1, b_1] \times \cdots \times (a_d, b_d]$ con vértices $V = \{a_1, b_1\} \times \cdots \times \{a_d, b_d\}$, se cumple

$$\Delta_A F := \sum_{v \in V} \operatorname{sgn}(v)\, F(v) \geq 0, \tag{3.30}$$

donde $\operatorname{sgn}(v) = (-1)^{|\{i \in \{1,\ldots,d\} : \nu_i = a_i\}|}$.

Teorema 3.3.3 Teorema de Stieltjes en $\mathbb{R}^d$. Suponga que $F : \mathbb{R}^d \to [0,1]$ satisface las condiciones anteriores. Entonces existe una única medida de probabilidad μ sobre $(\mathbb{R}^d, \mathscr{B}(\mathbb{R}^d))$ tal que

$$\mu(A) = \Delta_A F \tag{3.31}$$

para todo rectángulo finito $A = (a_1, b_1] \times \cdots \times (a_d, b_d]$. En particular, para $d = 1$ se recupera el teorema de Stieltjes clásico

$$\mu((a, b]) = F(b) - F(a), \tag{3.32}$$

y cuando $F(x_1, \ldots, x_d) = x_1 \cdots x_d$ la medida resultante es la medida de Lebesgue λ^d en $\mathbb{R}^d$.

La demostracion se deja al lector.

Teorema 3.3.4 Correspondencia biyectiva entre funciones de distribución y medidas de probabilidad en $\mathbb{R}$. Dada una función de distribución $F : \mathbb{R} \to \mathbb{R}$, existe una única medida de probabilidad μ sobre el espacio medible $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$ tal que

$$F(y) = \mu((-\infty, y]) \quad \text{para todo } y \in \mathbb{R}. \tag{3.33}$$

En particular, si X es la variable aleatoria sobre el espacio de probabilidad $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mu)$ definida por $X(\omega) = \omega$, entonces F es la función de distribución de X, es decir

$$F(y) = \mathbb{P}(X \leq y) = \mu((-\infty, y]). \tag{3.34}$$

La demostración es directa del teorema anterior.

3.4. V.A. continua y absolutamente continua

Definición 3.4.1 Variable aleatoria continua. Una variable aleatoria X se dice continua si su función de distribución F_X es continua.

Definición 3.4.2 Igualdad en distribución. Cuando X y Y tienen la misma distribución, escribimos $X \overset{d}{=} Y$. Por razones tipográficas, también se utiliza la notación $X =_d Y$.

Definición 3.4.3 Variable aleatoria absolutamente continua. Una variable aleatoria X se dice absolutamente continua si su medida inducida $\mathbb{P} \circ X^{-1}$ es absolutamente continua respecto a la medida de Lebesgue λ, es decir

$$\lambda(B) = 0 \implies \mathbb{P}(X \in B) = 0 \quad \forall B \in \mathscr{B}(\mathbb{R}). \tag{3.35}$$

Teorema 3.4.1 Variable aleatoria absolutamente continua. Una variable aleatoria X es absolutamente continua si existe una función $f_X \geq 0$ medible tal que

$$F_X(x) := \mathbb{P}(X \leq x) = \int_{-\infty}^{x} f_X(t)\, dt, \tag{3.36}$$

a f_X se le llama la función de densidad de X.

La demostracion se deja al lector.

Teorema 3.4.2 Transformación de densidades. Sea X una variable aleatoria absolutamente continua con función de densidad f_X. Sea $g\colon \mathbb{R} \to \mathbb{R}$ una función estrictamente monótona y diferenciable. Entonces la variable aleatoria $Y = g(X)$ es también absolutamente continua y su función de densidad f_Y está dada por

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \left| \dfrac{d}{dy} g^{-1}(y) \right|, & \text{si } y \in \operatorname{Ran}(g) \\ 0, & \text{en otro caso} \end{cases} \tag{3.37}$$

Demostración. Note que si g es creciente, por el teorema de la función y derivada inversa tenemos que g^{-1} es estrictamente creciente. Sea $y \in \operatorname{Ran}(g)$, entonces existe $x \in \mathbb{R}$ tal que $g(x) = y$. Por definición de función de distribución de Y, se tiene

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq g^{-1}(y)) = F_X(g^{-1}(y))$$

Aplicando la regla de la cadena

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{d}{dy} F_X(g^{-1}(y)) = f_X(g^{-1}(y)) \cdot \frac{d}{dy} g^{-1}(y)$$

Por otro lado, si $y \notin \operatorname{Ran}(g)$, entonces $F_Y(y) = 0$ o $F_Y(y) = 1$, y por tanto

$$f_Y(y) = \frac{d}{dy} F_Y(y) = 0$$

Por el teorema fundamental del cálculo, f_Y es la función densidad de Y, lo que implica que Y es absolutamente continua.

□

Definición 3.4.4 Variable aleatoria discreta. Se dice que X es discreta si existe un conjunto contable $\{y_i\}_{i\in J} \subseteq \mathbb{R}$ tal que

$$\mathbb{P}\left(X \in \{y_i\}_{i\in J}\right) = \sum_{i\in J} \mathbb{P}(X = y_i) = 1. \tag{3.38}$$

sumado a ellos se define $p(y_i) := \mathbb{P}(X = y_i)$ como la función de masa de probabilidad.

Proposición 3.4.1. Sea X una variable aleatoria discreta con valores $\{y_i\}_{i\in J}$. Entonces

$$\mathbb{P} \circ X^{-1} = \sum_{i\in J} p_X(y_i)\, \delta_{y_i}, \tag{3.39}$$

donde δ_{y_i} es la medida de Dirac en y_i y $p_X(y_i) = \mathbb{P}(X = y_i)$, y la función de distribución se expresa como

$$F_X(y) = \mathbb{P}(X \leq y) = \int \mathbf{1}_{(-\infty,y]}(x)\, d(\mathbb{P} \circ X^{-1})(x) = \sum_{y_i \leq y} p_X(y_i). \tag{3.40}$$

La demostracion se deja al lector.

3.5. Esperanza

Definición 3.5.1 Esperanza. Sea X una variable aleatoria sobre $(\Omega, \mathscr{F}, \mathbb{P})$. Se dice que la esperanza de X existe si

$$\int_\Omega |X|\, d\mathbb{P} < \infty, \tag{3.41}$$

en tal caso la esperanza de X se define como

$$\mathbb{E}[X] := \int_\Omega X\, d\mathbb{P} \tag{3.42}$$

3.5.1. Propiedades de la esperanza

Lema 3.5.1 Esperanza en $\mathbb{R}$. Sea X una variable aleatoria con esperanza finita. Entonces

$$\int_\Omega X\, d\mathbb{P} = \int_{\mathbb{R}} x\, d(\mathbb{P} \circ X^{-1})(x) = \int_{\mathbb{R}} x\, dF_X(x) = \int_{\mathbb{R}} x f_X(x)\, dx, \tag{3.43}$$

donde la última igualdad aplica cuando X es absolutamente continua con densidad f_X.

La demostracion es trivial.

Lema 3.5.2. Sea X una variable aleatoria discreta con valores $\{y_i\}_{i\in J}$ y esperanza finita. Entonces

$$\mathbb{E}[X] = \int_\Omega X\, d\mathbb{P} = \int_{\mathbb{R}} x\, d(\mathbb{P} \circ X^{-1})(x) = \sum_{i\in J} y_i\, p_X(y_i). \tag{3.44}$$

La demostracion se deja al lector.

Lema 3.5.3 Fórmula de Fubini para la esperanza. Sea X una variable aleatoria absolutamente continua tal que $\mathbb{E}(X)$ existe. Entonces

$$\mathbb{E}[X] = \int_{\mathbb{R}^+} \mathbb{P}(X > y)\, dy - \int_{\mathbb{R}^-} \mathbb{P}(X \leq y)\, dy = \int_{\mathbb{R}^+} [1 - F_X(y)]\, dy - \int_{\mathbb{R}^+} F_X(-y)\, dy. \tag{3.45}$$

Demostración. Por definición de esperanza

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x)\, dx = \int_0^{\infty} x f_X(x)\, dx + \int_{-\infty}^{0} x f_X(x)\, dx.$$

Entonces

$$\int_0^{\infty} x f_X(x)\, dx = \int_0^{\infty} \left(\int_0^x dy \right) f_X(x)\, dx = \int_0^{\infty} \left(\int_y^{\infty} f_X(x)\, dx \right) dy = \int_0^{\infty} \mathbb{P}(X > y)\, dy.$$

$$\int_{-\infty}^{0} x f_X(x)\, dx = -\int_{-\infty}^{0} \left(\int_x^0 dy \right) f_X(x)\, dx = -\int_{-\infty}^{0} \left(\int_{-\infty}^{y} f_X(x)\, dx \right) dy = -\int_{-\infty}^{0} \mathbb{P}(X \leq y)\, dy.$$

Por tanto

$$\mathbb{E}(X) = \int_0^{\infty} \mathbb{P}(X > y)\, dy - \int_{-\infty}^{0} \mathbb{P}(X \leq y)\, dy = \int_0^{\infty} [1 - F_X(y)]\, dy - \int_0^{\infty} F_X(-y)\, dy.$$

□

Teorema 3.5.1 LOTUS para la esperanza. Sea X una variable aleatoria absolutamente continua con función de densidad f_X y sea g una función medible tal que $\mathbb{E}[|g(X)|] \leq \infty$, entonces $g(X)$ es integrable y se cumple

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(y) f_X(y)\, dy. \tag{3.46}$$

Demostración. Por el teorema de cambio de variable,

$$\mathbb{E}[g(X)] = \int_{\Omega} g(X)\, d\mathbb{P} = \int_{\mathbb{R}} g(y)\, d(\mathbb{P} \circ X^{-1})(y).$$

Como X es absolutamente continua, $\mathbb{P} \circ X^{-1} \ll \lambda$ con derivada de Radon-Nikodym f_X, luego

$$\int_{\mathbb{R}} g(y)\, d(\mathbb{P} \circ X^{-1})(y) = \int_{\mathbb{R}} g(y) f_X(y)\, dy.$$

□

Para demostrarlo sin el uso de Radon-Nikodym.

Demostración. Primero se va a probar para funciones indicadoras. Sea $B \in \mathscr{B}(\mathbb{R})$ y sea $g = \mathbf{1}_B$. Entonces

$$\mathbb{E}[\mathbf{1}_B(X)] = \mathbb{P}(X \in B) = \mu_X(B) = \int_{\mathbb{R}} \mathbf{1}_B(y) f_X(y)\, dy.$$

Ahora con funciones simples. Sea $g(y) = \sum_{m=1}^{n} c_m \mathbf{1}_{B_m}(y)$, con $c_m \in \mathbb{R}$, $B_m \in \mathcal{B}(\mathbb{R})$. Por linealidad de

la esperanza, el resultado del caso 1 y la linealidad de la integral, se tiene

$$\mathbb{E}[g(X)] = \sum_{m=1}^{n} c_m \, \mathbb{E}(\mathbf{1}_{B_m}(X)) = \sum_{m=1}^{n} c_m \int_{\mathbb{R}} \mathbf{1}_{B_m}(y) f_X(y)\, dy = \int_{\mathbb{R}} g(y) f_X(y)\, dy.$$

Funciones no negativas. Sea $g \geq 0$ y definamos

$$g_n(y) := \text{mín}\left\{ \frac{\lfloor 2^n g(y) \rfloor}{2^n},\, n \right\}.$$

Entonces g_n es simple y $g_n \to g$ de forma creciente. Por el resultado del caso 2 y el Teorema de convergencia monótona, se tiene

$$\mathbb{E}[g(X)] = \lim_{n\to\infty} \mathbb{E}[g_n(X)] = \lim_{n\to\infty} \int_{\mathbb{R}} g_n(y) f_X(y)\, dy = \int_{\mathbb{R}} g(y) f_X(y)\, dy.$$

Para funciones integrables. Sea g medible tal que $\mathbb{E}[|g(X)|] < \infty$. Escribimos

$$g(y) = g^+(y) - g^-(y), \quad |g(y)| = g^+(y) + g^-(y).$$

Como $\mathbb{E}(|g(X)|) < \infty$, se tiene que $\mathbb{E}(g^+(X))$ y $\mathbb{E}(g^-(X))$ son finitas. Por el caso 3 y la linealidad de la esperanza e integración, se concluye que

$$\mathbb{E}[g(X)] = \mathbb{E}[g^+(X)] - \mathbb{E}[g^-(X)] = \int_{\mathbb{R}} g^+(y) f_X(y)\, dy - \int_{\mathbb{R}} g^-(y) f_X(y)\, dy = \int_{\mathbb{R}} g(y) f_X(y)\, dy.$$

□

Definición 3.5.2 Momento de orden r. Si $\mathbb{E}[|X|^r] < \infty$, diremos que X es r-integrable, si

$$\mathbb{E}[X^r] \tag{3.47}$$

existe y se denomina el momento de orden r de X alrededor de 0. En particular si $r = 1$, diremos que X es integrable; si $r = 2$, diremos que X es cuadrado integrable.

Proposición 3.5.1 Linealidad de la esperanza. Sean X y Y dos variables aleatorias integrables. Entonces

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y], \tag{3.48}$$

$$\text{Si } \mathbb{P}(X \leq Y) = 1, \text{ entonces } \mathbb{E}[X] \leq \mathbb{E}[Y], \tag{3.49}$$

$$\text{Si } X \overset{d}{=} Y, \text{ entonces } \mathbb{E}[X] = \mathbb{E}[Y]. \tag{3.50}$$

Demostración. Como X e Y son integrables, se tiene

$$\int_\Omega |aX + bY|\, d\mathbb{P} \leq |a| \int_\Omega |X|\, d\mathbb{P} + |b| \int_\Omega |Y|\, d\mathbb{P} < \infty,$$

luego $aX + bY$ es integrable y por linealidad de la integral de Lebesgue

$$\mathbb{E}[aX + bY] = \int_\Omega (aX + bY)\, d\mathbb{P} = a \int_\Omega X\, d\mathbb{P} + b \int_\Omega Y\, d\mathbb{P} = a\mathbb{E}[X] + b\mathbb{E}[Y].$$

Para la monotonía, si $\mathbb{P}(X \leq Y) = 1$ entonces $Y - X \geq 0$ c.s., luego

$$\mathbb{E}[Y] - \mathbb{E}[X] = \mathbb{E}[Y - X] = \int_{\Omega} (Y - X)\, d\mathbb{P} \geq 0.$$

Para la última es trivial.

□

Proposición 3.5.2 Desigualdad de Hölder para esperanzas. Si X y Y son variables aleatorias cuadrado integrables, entonces

$$\mathbb{E}(|XY|) \leq \|\mathbb{E}[X^p]\|_p \|\mathbb{E}[Y^q]\|_q. \tag{3.51}$$

La demostracion es consecuencia de la desigualdad de Hölder.

Proposición 3.5.3 Desigualdad de Markov. Sea X una variable aleatoria r-integrable. Entonces, para todo $\varepsilon > 0$

$$\mathbb{P}(|X| \geq \varepsilon) \leq \frac{\mathbb{E}[|X|^r]}{\varepsilon^r}. \tag{3.52}$$

Demostración. Sea $\varepsilon > 0$. Consideramos el conjunto $A := \{\omega \in \Omega : |X(\omega)| \geq \varepsilon\}$. Entonces, por definición de esperanza y usando que $|X|^r \geq \varepsilon^r$ en A, se tiene

$$\mathbb{E}[|X|^r] = \int_{\Omega} |X(\omega)|^r\, d\mathbb{P}(\omega) \geq \int_{A} |X(\omega)|^r\, d\mathbb{P}(\omega) \geq \int_{A} \varepsilon^r\, d\mathbb{P}(\omega) = \varepsilon^r\, \mathbb{P}(A).$$

□

3.6. Media, varianza y momentos

Definición 3.6.1 Media, varianza y momentos. Sea X una variable aleatoria integrable. Se define la media como

$$\mu := \mathbb{E}(X) \tag{3.53}$$

Para $r \geq 2$, si $\mathbb{E}[|X - \mu|^r] < \infty$, entonces el momento centrado de orden r se define como

$$\mu_r := \mathbb{E}[(X - \mu)^r] \tag{3.54}$$

El momento ordinario de orden r se define como

$$m_r := \mathbb{E}[X^r] \tag{3.55}$$

En particular, la varianza de X es

$$\mathrm{Var}(X) := \mathbb{E}[(X - \mu)^2] \text{ y } \sigma := \sqrt{\mathrm{Var}(X)} \text{ se llama desviación estándar.} \tag{3.56}$$

Proposición 3.6.1 Relación entre momentos centrados y momentos ordinarios. Sea X una variable aleatoria r-integrable con $r \geq 2$. Entonces, para todo $s \in \mathbb{N}$, se cumple

$$\mathbb{E}[(X - \mu)^s] = \sum_{k=0}^{s} \binom{s}{k} (-\mu)^{s-k} m_s. \tag{3.57}$$

Demostración. Por la fórmula del binomio y la linealidad de la esperanza, tenemos

$$\mathbb{E}[(X-\mu)^s] = \mathbb{E}\left[\sum_{k=0}^{s}\binom{s}{k}X^k(-\mu)^{s-k})\right] = \sum_{k=0}^{s}\binom{s}{k}\mathbb{E}[X^k](-\mu)^{s-k} = \sum_{k=0}^{s}\binom{s}{k}m_k(-\mu)^{s-k}.$$

□

Corolario 3.6.1 Fórmula de la varianza. Si X es cuadrado integrable, entonces

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2. \tag{3.58}$$

La demostración es trivial.

Corolario 3.6.2 Propiedades fundamentales de la varianza. Si X es cuadrado integrable y $a, b \in \mathbb{R}$, entonces

$$\mathrm{Var}(X) \geq 0. \tag{3.59}$$

$$\mathrm{Var}(aX) = a^2\,\mathrm{Var}(X). \tag{3.60}$$

$$\mathrm{Var}(X+b) = \mathrm{Var}(X). \tag{3.61}$$

$$\mathrm{Var}(X) = 0 \quad \text{si y solo si} \quad \mathbb{P}(X = \mathbb{E}[X]) = 1. \tag{3.62}$$

La demostración se deja al lector.

3.7. Función generadora de momentos

Definición 3.7.1 Función generadora de momentos. Sea X una variable aleatoria tal que existe $\alpha > 0$ tal que $\mathbb{E}[e^{tX}] < \infty$para todo $t \in (-\alpha, \alpha)$. Entonces se define la función generadora de momentos de X, denotada por ϕ_X, como

$$\phi_X(t) := \mathbb{E}[e^{tX}]\text{para todo } t \in (-\alpha, \alpha). \tag{3.63}$$

3.7.1. Propiedades de la función generadora de momentos

Teorema 3.7.1 Teorema fundamental de la función generadora de momentos. Sea X una variable aleatoria tal que su función generadora de momentos $\phi_X(t) = \mathbb{E}[e^{tX}]$ existe en un vecindario de $t = 0$. Entonces, para todo $r \in \mathbb{N}$, el momento de orden r de X está dado por

$$\mathbb{E}[X^r] = \left.\frac{d^r\phi_X(t)}{dt^r}\right|_{t=0}. \tag{3.64}$$

Demostración. Note que si existe $a > 0$ tal que $\phi_X(t) < \infty$ para todo $t \in (-a, a)$. Tenemos que $\mathbb{E}[e^{aX}] < \infty$ y $\mathbb{E}[e^{-aX}] < \infty$, de donde

$$\mathbb{E}[e^{c|X|}] \leq \mathbb{E}[e^{cX}] + \mathbb{E}[e^{-cX}] < \infty \quad \text{para todo } c \in (0, a).$$

Note que por desarrollos de Taylor la siguiente desigualdad es cierta si $r \in \mathbb{N}$

$$|x|^r \leq \frac{r!}{c^r} e^{c|x|}.$$

Ahora fijado $t \in (-a/2, a/2)$ y tomando $c \in (0, a - |t|)$, se obtiene

$$|X|^r e^{tX} \leq |X|^r e^{|t||X|} \leq \frac{r!}{c^r} e^{(c+|t|)|X|} \leq \frac{r!}{c^r} e^{a|X|}.$$

Considere primero $r = 1$. Para $h \to 0$

$$\frac{e^{(t+h)X} - e^{tX}}{h} = Xe^{tX} \cdot \frac{e^{hX} - 1}{hX},$$

donde $\frac{e^{hX}-1}{hX} \to 1$ puntualmente cuando $h \to 0$. Además

$$\left| \frac{e^{(t+h)X} - e^{tX}}{h} \right| \leq |X| e^{(t+h)_* |X|} \leq \frac{1!}{c^1} e^{a|X|},$$

para $|t|, |h|$ suficientemente pequeños y algún $c \in (0, a - |t| - |h|)$. Por convergencia dominada

$$\phi'_X(t) = \lim_{h \to 0} \mathbb{E}\left[\frac{e^{(t+h)X} - e^{tX}}{h} \right] = \mathbb{E}[Xe^{tX}].$$

Procediendo por inducción, si $\phi_X^{(k)}(t) = \mathbb{E}[X^k e^{tX}]$ para cierto k, entonces para $h \to 0$

$$\frac{\phi_X^{(k)}(t+h) - \phi_X^{(k)}(t)}{h} = \mathbb{E}\left[X^k e^{tX} \cdot \frac{e^{hX} - 1}{h} \right] \to \mathbb{E}[X^{k+1} e^{tX}],$$

y el numerador $|X|^{k+1} e^{tX}$ es integrable por la cota $|X|^{k+1} \leq \frac{(k+1)!}{c^{k+1}} e^{c|X|}$ y el mismo argumento de arriba. Por convergencia dominada se concluye

$$\phi_X^{(k+1)}(t) = \mathbb{E}[X^{k+1} e^{tX}] \quad \text{para } t \in (-a/2, a/2).$$

□

Teorema 3.7.2 Colas exponenciales de la función generadora de momentos. Sea X una variable aleatoria. La función generadora de momentos $m_X(t) = \mathbb{E}[e^{tX}]$ es finita en un intervalo abierto (a, b) que contiene a 0 si y solo si las colas de la función de distribución F_X están exponencialmente acotadas, es decir

$$\mathbb{P}(X > x) \leq Ce^{-t_0 x} \quad \text{para algunos } C > 0,\ t_0 > 0. \tag{3.65}$$

La demostración se deja al lector. Es consecuencia directa de los desarrollos de Taylor.

Teorema 3.7.3 Teorema de unicidad de la función generadora de momentos. Sean X y Y dos variables aleatorias tales que sus funciones generadoras de momentos ϕ_X y ϕ_Y existen. Si

$$\phi_X(t) = \phi_Y(t) \quad \text{para todo } t \in (-\varepsilon, \varepsilon), \tag{3.66}$$

para algún $\varepsilon > 0$, entonces

$$X \overset{d}{=} Y. \tag{3.67}$$

Demostración. Sea $\phi_X(t) := \mathbb{E}[e^{tX}]$ y $\phi_Y(t) := \mathbb{E}[e^{tY}]$ las funciones generadoras de momentos de X y Y,

respectivamente. Por hipótesis, existe $\varepsilon > 0$ tal que

$$\phi_X(t) = \phi_Y(t) \quad \text{para todo } t \in (-\varepsilon, \varepsilon).$$

Como ϕ_X y ϕ_Y son finitas en un intervalo abierto que contiene al cero, admiten desarrollo en serie de potencias alrededor de $t = 0$

$$\phi_X(t) = \sum_{n=0}^{\infty} \frac{\mathbb{E}[X^n]}{n!} t^n, \quad \phi_Y(t) = \sum_{n=0}^{\infty} \frac{\mathbb{E}[Y^n]}{n!} t^n,$$

con radio de convergencia al menos ε. La igualdad $\phi_X(t) = \phi_Y(t)$ para todo $t \in (-\varepsilon, \varepsilon)$ implica la igualdad de coeficientes en las series de potencias, por unicidad del desarrollo de Taylor

$$\mathbb{E}[X^n] = \mathbb{E}[Y^n] \quad \text{para todo } n \geq 0.$$

Por lo tanto, la igualdad de todos los momentos implica $X \overset{d}{=} Y$.

□

3.8. Función característica

Definición 3.8.1 Función característica. Sea X una variable aleatoria sobre $(\Omega, \mathcal{F}, \mathbb{P})$. Se define la función característica de X como la función $\varphi_X \colon \mathbb{R} \to \mathbb{C}$ dada por

$$\varphi_X(t) := \mathbb{E}[e^{itX}] = \mathbb{E}[\cos(tX)] + i\mathbb{E}[\sin(tX)]. \tag{3.68}$$

Proposición 3.8.1 Propiedades básicas de la función característica. Para todo $t \in \mathbb{R}$, se cumple

$$\varphi_X(0) = 1. \tag{3.69}$$

$$\varphi_X(-t) = \overline{\varphi_X(t)}. \tag{3.70}$$

$$|\varphi_X(t)| \leq 1. \tag{3.71}$$

$$|\varphi_X(t+h) - \varphi_X(t)| \leq \mathbb{E}[|e^{ihX} - 1|]. \tag{3.72}$$

$$\varphi_{aX+b}(t) = e^{itb}\varphi_X(at). \tag{3.73}$$

La demostración es trivial.

Teorema 3.8.1 Fórmula de inversión de Lévy. Si X es una variable aleatoria y $a < b$, entonces

$$\mathbb{P}(a < X < b) + \mathbb{P}(X = a)/2 + \mathbb{P}(X = b)/2 = \lim_{T \to \infty} \frac{1}{2\pi} \int_{-T}^{T} \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t)\, dt. \tag{3.74}$$

Demostración. El resultado anterior se puede obtener mediante transformada de Furrier con la función de compuerta y el teorema de Fubini. Utilizando los mismos resultados de la transformada pero sin utilizarla se tiene que si

$$\varphi_X(t) = \int_{\mathbb{R}} e^{itx}\, dP_X(x)$$

Se sigue que

$$\frac{e^{-ita}-e^{-itb}}{it}\varphi_X(t)=\int_{\mathbb{R}}\frac{e^{-it(x-a)}-e^{-it(x-b)}}{it}\,dP_X(x)$$

Ahora note que

$$\left|\frac{e^{it(x-a)}-e^{it(x-b)}}{it}\right|\leq\left|e^{-ita}\right|\left|\frac{1-e^{it(b-a}}{it}\right|\leq\frac{\left|2\sin\left(\frac{t(b-a)}{2}\right)\right|}{|t|}$$

Entonces

$$\int_{-T}^{T}\frac{\left|2\sin\left(\frac{t(b-a)}{2}\right)\right|}{|t|}\int_{\mathbb{R}}dP_X(x)\leq 1|b-a|\pi$$

En cuyo caso podemos utilizar el teorema de Fubini para

$$\int_{-T}^{T}\frac{e^{-ita}-e^{-itb}}{it}\varphi_X(t)\,dt.=\int_{\mathbb{R}}\int_{-T}^{T}\frac{e^{-it(x-a)}-e^{-it(x-b)}}{it}\,dt\,dP_X(x).$$

Nota que

$$\int_{x-a}^{x-b}e^{ity}\,dy=\left[\frac{e^{ity}}{it}\right]_{x-a}^{x-b}=\frac{e^{it(x-b)}-e^{it(x-a)}}{it}.$$

Entonces

$$\int_{-T}^{T}\frac{e^{it(x-a)}-e^{it(x-b)}}{it}\,dt=\int_{x-b}^{x-a}\int_{-T}^{T}e^{ity}\,dt\,dy.$$

Evaluamos la integral interna en t

$$\int_{-T}^{T}e^{ity}\,dt=\frac{e^{iTy}-e^{-iTy}}{iy}=\frac{2\sin(Ty)}{y}.$$

Por lo tanto

$$\frac{1}{2\pi}\int_{x-b}^{x-a}\frac{2\sin(Ty)}{y}\,dy=\frac{1}{\pi}\int_{x-b}^{x-a}\frac{\sin(Ty)}{y}\,dy.$$

Realizamos el cambio de variable $u=Ty$, $du=T\,dy$, $dy=\frac{du}{T}$ la integral doble queda como

$$\int_{-\infty}^{\infty}\left(\frac{1}{\pi}\int_{T(x-b)}^{T(x-a)}\frac{\sin(u)}{u}\,du\right)dF_X(x).$$

Note que el comportamiento de la integral interna cuando $T\to\infty$ depende de x, por lo tanto tenemos tres casos

Caso 1, para $x\in(a,b)$ tenemos que $x-b<0$ y $x-a>0$, así que $T(x-b)\to-\infty$, $T(x-a)\to\infty$. Entonces

$$\frac{1}{\pi}\int_{T(x-b)}^{T(x-a)}\frac{\sin(u)}{u}\,du\to\frac{1}{\pi}\int_{-\infty}^{\infty}\frac{\sin(u)}{u}\,du=1,$$

Caso 2, para $x=a$ tenemos que $T(a-b)\to-\infty$, $T(a-a)=0$. Entonces

$$\frac{1}{\pi}\int_{T(a-b)}^{0}\frac{\sin(u)}{u}\,du\to\frac{1}{\pi}\int_{-\infty}^{0}\frac{\sin(u)}{u}\,du=\frac{1}{2},$$

Caso 3, para $x=b$ tenemos que $T(b-b)=0$, $T(b-a)\to\infty$. Entonces

$$\frac{1}{\pi}\int_{0}^{T(b-a)}\frac{\sin(u)}{u}\,du\to\frac{1}{\pi}\int_{0}^{\infty}\frac{\sin(u)}{u}\,du=\frac{1}{2}.$$

Caso 4, para $x<a$ o $x>b$ tenemos que los límites $T(x-b)$ y $T(x-a)$ tienden ambos a $-\infty$ o ∞, y la

integral interna tiende a 0.

Con estos casos tenemos que

$$g(x) = \lim_{T\to\infty} \frac{1}{\pi} \int_{T(x-b)}^{T(x-a)} \frac{\sin(u)}{u}\, du = \begin{cases} 1 & \text{si } x \in (a,b), \\ \frac{1}{2} & \text{si } x = a \text{ o } x = b, \\ 0 & \text{si } x < a \text{ o } x > b. \end{cases}$$

Entonces tenemos que

$$\int_{\mathbb{R}} \left(\lim_{T\to\infty} \frac{1}{\pi} \int_{T(x-b)}^{T(x-a)} \frac{\sin(u)}{u}\, du \right) dF_X(x) = \int_{\mathbb{R}} g(x)\, dF_X(x),$$

donde

$$g(x) = \begin{cases} 1 & \text{si } x \in (a,b), \\ \frac{1}{2} & \text{si } x = a \text{ o } x = b, \\ 0 & \text{si } x < a \text{ o } x > b. \end{cases}$$

Descomponemos la integral

$$\int_{\mathbb{R}} g(x)\, dF_X(x) = \int_{(a,b)} 1\, dF_X(x) + \frac{1}{2}\mathbb{P}(X = a) + \frac{1}{2}\mathbb{P}(X = b)$$

En cuyo caso

$$\mathbb{P}(a < X < b) + \mathbb{P}(X = a)/2 + \mathbb{P}(X = b)/2 = \lim_{T\to\infty} \frac{1}{2\pi} \int_{-T}^{T} \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t)\, dt.$$

□

Corolario 3.8.1 Unicidad de la función característica. Si $\varphi_X(t) = \varphi_Y(t)$ para todo $t \in \mathbb{R}$, entonces

$$X \overset{d}{=} Y. \tag{3.75}$$

La demostración es consecuencia de la igualdad en funciones generadas de momentos.

Teorema 3.8.2 Diferenciación de la función característica. Suponga que X es r-integrable. Entonces

$$\varphi_X^{(r)}(t) = \mathbb{E}[(iX)^r e^{itX}]. \tag{3.76}$$

En particular

$$\varphi_X^{(r)}(0) = i^r \mathbb{E}[X^r]. \tag{3.77}$$

Además, el desarrollo de Taylor alrededor de $t = 0$ está dado por

$$\varphi_X(t) = \sum_{k=0}^{r} \frac{(it)^k}{k!} \mathbb{E}[X^k] + o(t^r). \tag{3.78}$$

Demostración. Utilizando el resultado para la funcion generadora de momentos tenemos que

$$\frac{\varphi_X^{(k)}(t+h) - \varphi_X^{(k)}(t)}{h} = \mathbb{E}\left[(iX)^k e^{itX} \cdot \frac{e^{ihX} - 1}{h} \right] \xrightarrow{h\to 0} \mathbb{E}[(iX)^{k+1} e^{itX}],$$

□

Teorema 3.8.3 Fórmula de inversión de Fourier para la densidad. Si

$$\int_{\mathbb{R}} |\varphi_X(t)|\, dt < \infty, \tag{3.79}$$

entonces X es absolutamente continua con densidad dada por

$$f_X(y) = \frac{1}{2\pi} \int_{\mathbb{R}} e^{-ity} \varphi_X(t)\, dt. \tag{3.80}$$

Demostración. Este ejercicio igual se puede obtener por transformada de furrier. Pero de igual forma note que utilizando el hecho de que X es absolutamente continua tenemos que

$$\left(\frac{F_X(b) + F_X(b^-)}{2} - \frac{F_x(a) + F_X(a^-)}{2} \right) = F_X(b) - F_X(a) = \lim_{T\to\infty} \frac{1}{2\pi} \int_{-T}^{T} \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t)\, dt.$$

Ahora tomado $b = x$ y $a \to \infty$ se tiene que

$$F_X(x) - 1 = \lim_{T\to\infty} \frac{1}{2\pi} \int_{-T}^{T} \frac{-e^{-itx}}{it} \varphi_X(t)\, dt.$$

Derivando con respecto de x tenemos que

$$F_X'(x) = f(x) = \lim_{T\to\infty} \frac{1}{2\pi} \int_{-T}^{T} e^{-itx} \varphi_X(t)\, dt.$$

□

4

Vectores aleatorias

Definición 4.0.1 Variable aleatoria en varias variables. Una variable aleatoria en $\mathbb{R}^n$ sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ es una función $X\colon \Omega \to \mathbb{R}^n$ que es medible para todo $A \in \mathscr{B}(\mathbb{R}^n)$, es decir

$$X^{-1}(A) \in \mathscr{F}. \tag{4.1}$$

4.0.1. Distribucion de vectores aleatorios

Definición 4.0.2 Función de distribución conjunta. Sea $X = (X_1, X_2 \dots, X_n)$ un vector aleatorio. La función de distribución conjunta de X es la función $F_X\colon \mathbb{R}^n \to [0,1]$ dada por

$$F_X(x_1, \dots, x_n) := \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n). \tag{4.2}$$

Teorema 4.0.1 Propiedades básicas de la función de distribución conjunta. Sea $X = (X_1, X_2, \dots, X_n)$ un vector aleatorio en $\mathbb{R}^n$ con función de distribución conjunta $F_X(x_1, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n)$. Entonces se verifican las siguientes propiedades

$$F_X(a_1, \dots, a_n) \leq F_X(b_1, \dots, b_n) \text{ si } \forall_{i\in\{1,\dots,n\}}(a_i \leq b_i) \tag{4.3}$$

$$\lim_{x_i \to a_i^+} F_X(x_1, \dots, x_i, \dots, x_n) = F_X(x_1, \dots, x_i, \dots, a_i, \dots, x_n), \forall_{i\in\{1,\dots,n\}} \tag{4.4}$$

$$\lim_{x_i \to -\infty} F_X(x_1, \dots, x_i, \dots, x_n) = 0, \forall_{i \in \{1,\dots,n\}} \tag{4.5}$$

$$\lim_{(x_1,\dots,x_n)\to\infty} F_X(x_1, \dots, x_d) = 1 \tag{4.6}$$

Demostración. Primero si $a_i \leq b_i$ para todo i, entonces el evento $\{X_i \leq a_i\} \subseteq \{X_i \leq b_i\}$, por lo tanto

$$\bigcap_{i=1}^{d} \{X_i \leq a_i\} \subseteq \bigcap_{i=1}^{d} \{X_i \leq b_i\}$$

y se sigue que $F_X(a_1, \dots, a_d) \leq F_X(b_1, \dots, b_d)$. Ahora sea $\{x_i^m\}_m \to a_i^+$ para algún i, entonces

$$\lim_{x_i \to a_i^+} F_X(x_1, \dots, x_i, \dots, x_n) = \mathbb{P}_X \left(\bigcap_{n=1}^{\infty} \{X_1 \leq x_1, \dots, X_i \leq x_i^m, \dots, X_n \leq x_n\} \right)$$

$$= \mathbb{P}_X \left(X_1 \leq x_1, \dots, X_i \leq a_i, \dots, X_n \leq x_n \right) = F_X(x_1, \dots, x_i, \dots, a_i, \dots, x_n)$$

Como tercero si $\{x_i^m\}_m \to -\infty$ para algún i, se sigue que

$$\bigcap_{m=1}^{\infty} \{X_1 \leq x_1, \dots, X_i \leq x_i^m, \dots, X_n \leq x_n\} = \varnothing \Rightarrow F_X(x_1, \dots, x_i^m, \dots, x_n) \to \mathbb{P}(\varnothing) = 0$$

Y la ultima se sigue que si $x_i^{(n)} \to +\infty$ para todo i, entonces

$$\bigcap_{i=1}^{d} \{X_i \leq x_i^{(n)}\} \to \Omega \Rightarrow F_X(x_1^{(n)}, \dots, x_d^{(n)}) \to \mathbb{P}(\Omega) = 1.$$

□

Definición 4.0.3 Función de distribución marginal. Si $X = (X_1, X_2, \dots, X_n)$ es un vector aleatorio, a la función de distribución F_{X_k} de X_k (para todo $k = 1, 2, \dots, n$) se le llama función de distribución marginal de la variable X_k

$$F_{X_k}(x_k) := \mathbb{P}(X_k \leq x_k) \tag{4.7}$$

Teorema 4.0.2 Teorema de las marginales. Sea $X = (X_1, X_2, \dots, X_n)$ un vector aleatorio en $\mathbb{R}^n$ con función de distribución conjunta

$$F_X(x_1, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n). \tag{4.8}$$

Entonces, para cada $k \in \{1, \dots, n\}$, la función de distribución marginal de X_k se obtiene como

$$F_{X_k}(x_k) = \lim_{x_i \to +\infty, \forall_{i \neq k}} F_X(x_1, \dots, x_n). \tag{4.9}$$

Demostración. Considere sucesiones $\{x_i^{(m)}\}_m \to +\infty$ para cada $i \neq k$, entonces

$$\bigcap_{i=1}^{d} \{X_i \leq x_i^{(n)}\} \to \Omega \Rightarrow \bigcap_{\substack{i=1 \\ i \neq k}}^{d} \{X_i \leq x_i^{(n)}\} \cap \{X_k \leq x_k\} \to \Omega \cap \{X_k \leq x_k\}$$

Entonces se sigue que

$$\lim_{\substack{x_i \to +\infty \\ i \neq k}} \mathbb{P}\left(\bigcap_{\substack{i=1 \\ i \neq k}}^{d} \{X_i \leq x_i^{(n)}\} \cap \{X_k \leq x_k\} \right) = F_X\left(\Omega \cap \{X_k \leq x_k\}\right) = F_{X_k}(x_k).$$

□

Aquí cabe recalcar que no siempre de las funciones de distribución marginal podemos obtener la función de distribución conjunta.

Proposición 4.0.1 Función de masa de probabilidad conjunta. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio discreto. Entonces la medida inducida $\mathbb{P} \circ X^{-1}$ sobre $\mathbb{R}^n$ admite la representación

$$\mathbb{P} \circ X^{-1} = \sum_{(x_1,\dots,x_n)} p_{X_1,\dots,X_n}(x_1, \dots, x_n)\, \delta_{(x_1,\dots,x_n)}, \tag{4.10}$$

donde la suma recorre $\mathrm{Ran}(X)$ y

$$p_{X_1,\dots,X_n}(x_1, \dots, x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = (\mathbb{P} \circ X^{-1})(\{(x_1, \dots, x_n)\}), \tag{4.11}$$

con $p_{X_1,\dots,X_n}(x_1, \dots, x_n) = 0$ para $(x_1, \dots, x_n) \notin \mathrm{Ran}(X)$.

Teorema 4.0.3 Distribución inducida. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio discreto con $\mathrm{Ran}(X) \subset A$, y sean $g_1, \dots, g_k : A \subseteq \mathbb{R}^n \to \mathbb{R}$ campos escalares. Para cada $j \in \{1, \dots, k\}$ sea $Y_j = g_j(X_1, \dots, X_n)$. Entonces $Y = (Y_1, \dots, Y_k)$ es un vector aleatorio discreto con distribución conjunta

$$\mathbb{P}(Y_1 = y_1, \dots, Y_k = y_k) = \sum_{\substack{(x_1,\dots,x_n) \in \mathrm{Ran}(X) \\ g_j(x_1,\dots,x_n) = y_j \ \forall j}} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n). \tag{4.12}$$

Demostración. Note que para cada $j = 1 \dots k$, se tiene

$$\{\omega : g_j(X(\omega)) = y_j\} = \bigcup_{\substack{(x_1,\dots,x_n) \in \mathbb{R}^n \\ g_j(x_1,\dots,x_n) = y_j}} \{\omega : X(\omega) = (x_1, \dots, x_n)\}$$

Por lo tanto, la intersección de esos eventos es

$$\bigcap_{j=1}^{k} \{\omega : g_j(X(\omega)) = y_j\} = \bigcup_{\substack{(x_1,\dots,x_n) \in \mathbb{R}^n \\ g_j(x_1,\dots,x_n) = y_j \ ,\forall j}} \{\omega : X(\omega) = (x_1, \dots, x_n)\}$$

Y entonces

$$\mathbb{P}(Y_1 = y_1, \dots, Y_k = y_k) = \sum_{\substack{(x_1,\dots,x_n) \in \mathbb{R}^n \\ g_j(x_1,\dots,x_n) = y_j \ ,\forall j}} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$$

□

Definición 4.0.4 Función de densidad conjunta. Un vector aleatorio $X = (X_1, \dots, X_n)$ se dice absolutamente continuo si su medida inducida $\mathbb{P} \circ X^{-1} \ll \lambda^n$, donde λ^n es la medida de Lebesgue en $\mathbb{R}^n$. Por Radon-Nikodym existe $f_{X_1,\dots,X_n} \geq 0$ medible tal que

$$\mathbb{P}(X \in B) = \int_B f_{X_1,\dots,X_n}\, d\lambda^n \quad \forall B \in \mathscr{B}(\mathbb{R}^n), \tag{4.13}$$

a $f_{X_1,\dots,X_n}$ se le llama la densidad conjunta de X, y corresponde a la derivada de Radon-Nikodym $f_{X_1,\dots,X_n} = d(\mathbb{P}\circ X^{-1})/d\lambda^n$.

Proposición 4.0.2 LOTUS multivariable. Sea $X=(X_1,\dots,X_n)$ un vector aleatorio absolutamente continuo con densidad conjunta $f_{X_1,\dots,X_n}$. Entonces para cada $k\in\{1,\dots,n\}$ la medida inducida de X_k satisface $\mathbb{P}\circ X_k^{-1}\ll\lambda$ con densidad marginal

$$f_{X_k}(y)=\frac{d(\mathbb{P}\circ X_k^{-1})}{d\lambda}(y)=\int_{\mathbb{R}^{n-1}} f_{X_1,\dots,X_n}(t_1,\dots,t_{k-1},y,t_{k+1},\dots,t_n)\,d\lambda^{n-1}(t), \tag{4.14}$$

resultado que se obtiene aplicando el teorema de Fubini a la medida $\mathbb{P}\circ X^{-1}$.

La demostración es consecuencia directa del teorema de Fubini y la fórmula de Leibniz.

4.1. Esperanza de vectores aleatorios

Definición 4.1.1 Esperanza de un vector aleatorio. Sea $X=(X_1,\dots,X_n)$ un vector aleatorio sobre $(\Omega,\mathscr{F},\mathbb{P})$. La esperanza de X se define componente a componente como

$$\mathbb{E}[X]:=(\mathbb{E}[X_1],\dots,\mathbb{E}[X_n]), \tag{4.15}$$

siempre que cada $\mathbb{E}[|X_k|]<\infty$.

Teorema 4.1.1 LOTUS para esperanza multivariable. Si $(X_1,\dots,X_n)$ es un vector aleatorio y $g\colon\mathbb{R}^n\to\mathbb{R}$ es integrable, entonces

$$\mathbb{E}[g(X_1,\dots,X_n)]=\int_{\mathbb{R}^n} g(t_1,\dots,t_n)f_{X_1,\dots,X_n}(t_1,\dots,t_n)\,dt_1\dots dt_n \tag{4.16}$$

Demostración. Sea $X=(X_1,\dots,X_n)$ un vector aleatorio definido sobre un espacio de probabilidad $(\Omega,\mathscr{F},\mathbb{P})$, y sea $g\colon\mathbb{R}^n\to\mathbb{R}$ una función medible tal que $g(X)$ es integrable, es decir, $\mathbb{E}(|g(X)|)<\infty$.

El vector aleatorio X induce una medida de probabilidad μ sobre $\mathbb{R}^n$, definida por

$$\mu(B)=\mathbb{P}(X\in B),\quad \text{para todo } B\in\mathscr{B}(\mathbb{R}^n),$$

donde $\mathscr{B}(\mathbb{R}^n)$ es la σ-álgebra de Borel.

La esperanza de $g(X)$ se puede expresar como una integral respecto a esta medida

$$\mathbb{E}[g(X)]=\int_{\mathbb{R}^n} g(x)\,d\mu(x).$$

Si X tiene una densidad conjunta $f_{X_1,\dots,X_n}\colon\mathbb{R}^n\to\mathbb{R}^+$, entonces la medida μ es absolutamente continua respecto a la medida de Lebesgue, y por el teorema de Radon-Nikodym, existe una función f talque $d\mu(x)=f(x)\,dx.$, por lo tanto, la esperanza se puede escribir como

$$\mathbb{E}[g(X)]=\int_{\mathbb{R}^n} g(x)f(x)\,dx,$$

lo que en coordenadas se expresa como

$$\mathbb{E}(g(X_1,\dots,X_n)) = \int_{\mathbb{R}^n} g(t_1,\dots,t_n) f_{X_1,\dots,X_n}(t_1,\dots,t_n)\,dt_1\dots dt_n.$$

□

Teorema 4.1.2 Teorema del Jacobiano. Sea $R = [a_1 b_1] \times [a_2 b_2] \times \cdots \times [a_n b_n]$ un rectángulo n-dimensional y $u = (u_1(x_1,\dots,x_n),\dots,u_n(x_1,\dots,x_n))$ un campo vectorial de clase C^1 en un vecindario del rectángulo R, que tiene inversa $x = (x_1(u_1,\dots,u_n),\dots,x_n(u_1,\dots,u_n))$. Suponga que el jacobiano $\frac{\partial(x_1\dots x_n)}{\partial(u_1\dots u_n)} \neq 0$ sobre $u(R)$. Entonces, si f es un campo escalar integrable sobre R, se tiene

$$\int_R f(x_1,\dots,x_n)\,dx_1\dots dx_n = \int_{u(R)} f(x) \quad \times \left|\frac{\partial(x_1,\dots,x_n)}{\partial(u_1,\dots,u_n)}\right| du_1\dots du_n. \tag{4.17}$$

Demostración. Sea $(u_1,\dots,u_n) \in u(R) \subset \mathbb{R}^n$, y considere

$$R = \{(x_1,\dots,x_n) \in \mathbb{R}^n : u(x_1,\dots,x_n) \in u(R)\} = u^{-1}(u(R)),$$

donde $u : R \to u(R)$ es biyectiva con de clase C^1 con inversa $x = (x_1(u_1,\dots,u_n),\dots,x_n(u_1,\dots,u_n))$ igual de clase C^1, y el jacobiano $\frac{\partial(x_1,\dots,x_n)}{\partial(u_1,\dots,u_n)} \neq 0$ en $u(R)$.

Tenemos que

$$\int_R f(x_1,\dots,x_n)\,dx_1\dots dx_n,$$

donde $f : R \to \mathbb{R}$ es integrable, debe transformarse bajo el cambio de coordenadas $x = x(u)$.

Por el teorema del cambio de variables para integrales múltiples, obtenemos que

$$\int_R f(x_1,\dots,x_n)\,dx_1\dots dx_n = \int_{u(R)} f(x_1(u_1,\dots,u_n),\dots,x_n(u_1,\dots,u_n)) \left|\frac{\partial(x_1,\dots,x_n)}{\partial(u_1,\dots,u_n)}\right| du_1\dots du_n.$$

□

Teorema 4.1.3 Teorema del cambio de variable. Suponga que $X = (X_1,\dots,X_n)$ tiene distribución absolutamente continua conjunta y $U = (U_1,\dots,U_n)$, donde $U_k = u_k(X_1,\dots,X_n)$ para cada $k = 1,\dots,n$. Suponga que $X_k = x_k(U_1,\dots,U_n)$ para cada $k = 1,\dots,n$. Entonces $U_1,\dots,U_n$ tiene distribución absolutamente continua conjunta dada por

$$f_{U_1,\dots,U_n}(u_1,\dots,u_n) = f_{X_1,\dots,X_n}(x_1(u_1,\dots,u_n),\dots,x_n(u_1,\dots,u_n)) \left|\frac{\partial(x_1,\dots,x_n)}{\partial(u_1,\dots,u_n)}\right|. \tag{4.18}$$

Demostración. Sea $(y_1,\dots,y_n) \in \mathbb{R}^n$, y considere

$$R = \{(x_1,\dots,x_n) : u(x_1,\dots,x_n) \leq (y_1,\dots,y_n)\} = u^{-1}([-\infty,y_1] \times \cdots \times [-\infty,y_n]).$$

Tenemos que

$$\begin{aligned} F_{U_1,\dots,U_n}(y_1,\dots,y_n) &= \mathbb{P}(U_1 \leq y_1,\dots,U_n \leq y_n) \\ &= \mathbb{P}((X_1,\dots,X_n) \in R) \\ &= \int_R f_{X_1,\dots,X_n}(x_1,\dots,x_n)\,dx_1\dots dx_n. \end{aligned}$$

De donde obtenemos

$$F_{U_1,\dots,U_n}(y_1,\dots,y_n) = \int_{-\infty}^{y_1} \cdots \int_{-\infty}^{y_n} f_{X_1,\dots,X_n}(x_1(u_1,\dots,u_n),\dots,x_n(u_1,\dots,u_n)) \left|\frac{\partial(x_1,\dots,x_n)}{\partial(u_1,\dots,u_n)}\right| du_1 \dots du_n.$$

□

4.2. Varianza, covarianza y correlación

Definición 4.2.1 Covarianza. Si X, Y son variables aleatorias tales que $\mathbb{E}[X^2] < \infty$ y $\mathbb{E}[Y^2] < \infty$, la covarianza de X y Y se define como

$$\mathrm{Cov}(X,Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]. \tag{4.19}$$

Proposición 4.2.1 Propiedades fundamentales de la covarianza. Si $\mathbb{E}(X^2) < \infty$ y $\mathbb{E}(Y^2) < \infty$, entonces

$$\mathrm{Cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] \tag{4.20}$$

$$\mathrm{Cov}(X,Y) = \mathrm{Cov}(Y,X) \tag{4.21}$$

$$\mathrm{Var}(X) = \mathrm{Cov}(X,X) \tag{4.22}$$

$$\mathrm{Cov}(aX + bY, Zc) = ac \cdot \mathrm{Cov}(X,Z) + bc \cdot \mathrm{Cov}(Y,Z) \quad \text{para todo } a,b,c \in \mathbb{R} \tag{4.23}$$

La demostración queda al lector.

Definición 4.2.2 Correlación. El coeficiente de correlación de X y Y se define como

$$\rho(X,Y) := \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)} \cdot \sqrt{\mathrm{Var}(Y)}} \tag{4.24}$$

siempre y cuando el denominador esté bien definido.

Teorema 4.2.1 Propiedades fundamentales del coeficiente de correlación lineal. Si está definido, entonces $-1 \leq \rho(X,Y) \leq 1$. Además

$$\rho(X,Y) = 1 \quad \text{si y sólo si existe } \lambda > 0 \text{ tal que } Y - \mathbb{E}[Y] = \lambda(X - \mathbb{E}[X]) \tag{4.25}$$

$$\rho(X,Y) = -1 \quad \text{si y sólo si existe } \lambda < 0 \text{ tal que } Y - \mathbb{E}[Y] = \lambda(X - \mathbb{E}[X]) \tag{4.26}$$

Demostración. Usando la desigualdad de Cauchy-Schwartz tenemos

$$[\mathbb{E}((X - \mathbb{E}[X])(Y - \mathbb{E}[Y]))]^2 \leq \mathbb{E}[(X - \mathbb{E}[X])^2] \cdot \mathbb{E}[(Y - \mathbb{E}[Y])^2].$$

Esto implica que

$$-1 \leq \rho(X,Y) \leq 1.$$

Para demostrar las igualdades, se utiliza el hecho de que la igualdad en la desigualdad de Cauchy-

Schwartz se obtiene si y sólo si existe un $t \in \mathbb{R}$ tal que

$$Y - \mathbb{E}[Y] = t(X - \mathbb{E}[X])$$

□

Proposición 4.2.2 Fórmula de la varianza de una suma. Sean $X_1, \dots, X_n$ variables aleatorias tales que $\mathbb{E}[X_k^2] < \infty$ para todo $k = 1, \dots, n$. Entonces

$$\operatorname{Var}\left(\sum_{k=1}^{n} X_k\right) = \sum_{k=1}^{n} \operatorname{Var}(X_k) + 2\sum_{i<j} \operatorname{Cov}(X_i, X_j) \tag{4.27}$$

La demostración queda al lector.

Definición 4.2.3 Matriz de covarianza. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio tal que $\mathbb{E}(X_k^2) < \infty$ para todo $k = 1, \dots, n$. La matriz de covarianza de X, denotada por Σ, se define como

$$\Sigma := \begin{pmatrix} \operatorname{Cov}(X_1, X_1) & \operatorname{Cov}(X_1, X_2) & \dots & \operatorname{Cov}(X_1, X_n) \\ \operatorname{Cov}(X_2, X_1) & \operatorname{Cov}(X_2, X_2) & \dots & \operatorname{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \operatorname{Cov}(X_n, X_1) & \operatorname{Cov}(X_n, X_2) & \dots & \operatorname{Cov}(X_n, X_n) \end{pmatrix} \tag{4.28}$$

Y la matriz de correlación de X, denotada por R, se define como

$$R := \begin{pmatrix} \rho(X_1, X_1) & \rho(X_1, X_2) & \dots & \rho(X_1, X_n) \\ \rho(X_2, X_1) & \rho(X_2, X_2) & \dots & \rho(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \rho(X_n, X_1) & \rho(X_n, X_2) & \dots & \rho(X_n, X_n) \end{pmatrix} \tag{4.29}$$

4.3. Independencia de vectores aleatorios

Definición 4.3.1 Independencia de vectores aleatorios. Sean $X_1, \dots, X_n$ variables aleatorias. Decimos que estas variables son independientes si para cada escogencia de números reales $a_k < b_k$, los eventos

$$a_1 < X_1 < b_1, \quad a_2 < X_2 < b_2, \quad \dots, \quad a_n < X_n < b_n \tag{4.30}$$

son independientes. En particular, para todo $m \leq n$ se cumple que

$$\mathbb{P}\left(\bigcap_{k=1}^{m} \{a_k < X_k < b_k\}\right) = \prod_{k=1}^{m} \mathbb{P}(a_k < X_k < b_k). \tag{4.31}$$

En realidad todo esto y lo anterior se puede generalizar tomando variables aleatorias no a $\mathbb{R}$ sino a cualquier conjunto o espacio métrico para mejor manejo.

Teorema 4.3.1 Independencia mediante la función de distribución conjunta. Sean $X_1, \dots, X_n$ variables aleatorias. Una condición necesaria y suficiente para que las variables sean independientes es que

$$F_{X_1,\dots,X_n}(x_1, \dots, x_n) = F_{X_1}(x_1) F_{X_2}(x_2) \dots F_{X_n}(x_n). \tag{4.32}$$

para todo $(x_1, \dots, x_n) \in \mathbb{R}^n$.

La demostracion queda al lector.

Proposición 4.3.1 Independencia mediante factorización de la distribución conjunta. Sean $X_1, \dots, X_n$ variables aleatorias. Entonces, si todas son discretas, son independientes si y sólo si

$$\mathbb{P}\left(\bigcap_{k=1}^{n}\{X_k = x_k\}\right) = \prod_{k=1}^{n} p(x_k). \tag{4.33}$$

para todo $x_k \in \text{Ran}(X_k)$, $k = 1, \dots, n$. Si todas son absolutamente continuas, entonces son independientes si y sólo si

$$f_{X_1,\dots,X_n}(x_1, \dots, x_n) = f_{X_1}(x_1) \dots f_{X_n}(x_n). \tag{4.34}$$

para todo $x_k \in \mathbb{R}$, $k = 1, \dots, n$.

La demostracion queda al lector.

Teorema 4.3.2 Preservación de independencia por funciones medibles. Si $X_1, \dots, X_n$ son variables aleatorias independientes, y $f_1, \dots, f_n$ son funciones Borel-medible, entonces $f_1(X_1), \dots, f_n(X_n)$ también son variables aleatorias independientes.

La demostracion queda al lector.

4.3.1. Esperanza independiente

Teorema 4.3.3 Factorización de la esperanza bajo independencia. Si $X_1, \dots, X_n$ son variables aleatorias independientes, y si $\mathbb{E}[X_k] < \infty$ para todo $k = 1, \dots, n$, entonces se cumple que

$$\mathbb{E}[X_1 \dots X_n] = \mathbb{E}[X_1] \dots \mathbb{E}[X_n]. \tag{4.35}$$

La demostracion queda al lector.

Corolario 4.3.1 Independencia implica incorrelación. Si X y Y son independientes, entonces

$$\text{Cov}(X, Y) = 0. \tag{4.36}$$

La demostracion queda al lector.

Corolario 4.3.2 Varianza aditiva bajo independencia. Si $X_1, \dots, X_n$ son independientes y $\mathbb{E}[X_k^2] < \infty$ para todo $k = 1, \dots, n$, entonces

$$\text{Var}\left(\sum_{k=1}^{n} X_k\right) = \sum_{k=1}^{n} \text{Var}(X_k). \tag{4.37}$$

La demostracion queda al lector.

Definición 4.3.2 Función generadora de momentos multivariable. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio. Suponga que existe un $M > 0$ tal que $\mathbb{E}[e^{X \cdot t}] < \infty$ para todo $t = (t_1, \dots, t_n) \in \mathbb{R}^n$ tal que $\|t\| < M$. Entonces, la función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{X \cdot t}]. \tag{4.38}$$

Teorema 4.3.4 Factorización de la función generadora de momentos bajo independencia. Si $X = (X_1, \dots, X_n)$, entonces m_X existe si y sólo si ϕ_{X_k} existe para todo $k = 1, \dots, n$. Más aún, si $X_1, \dots, X_n$ son independientes, entonces

$$\phi_X(t) = \phi_{X_1}(t_1) \dots \phi_{X_n}(t_n). \tag{4.39}$$

La demostracion queda al lector.

Definición 4.3.3 Función características multivariable. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio. La función característica de X se define como

$$\varphi_X(t) = \mathbb{E}[e^{iX \cdot t}] \tag{4.40}$$

para todo $t = (t_1, \dots, t_n) \in \mathbb{R}^n$.

Teorema 4.3.5 Factorización de la función característica bajo independencia. Si $X = (X_1, \dots, X_n)$ es un vector aleatorio, este queda determinado en forma única por φ_X. Más aún, si $X_1, \dots, X_n$ son independientes, entonces

$$\varphi_X(t) = \varphi_{X_1}(t_1) \dots \varphi_{X_n}(t_n). \tag{4.41}$$

La demostracion se deja al lector.

Distribución condicional

Definición 4.3.4 Distribución acumulada condicional. La distribución condicional de X dado $Y = y$ se define como

$$F_{X|Y}(x \mid y) := \mathbb{P}(X \leq x \mid Y = y). \tag{4.42}$$

para todo $x \in \mathbb{R}$, siempre y cuando la probabilidad condicional esté bien definida.

4.3.2. Propiedades de la distribucion condicional

Proposición 4.3.2 Densidad condicional. Sean X, Y variables aleatorias absolutamente continuas con densidad conjunta $f_{X,Y}$ y densidad marginal f_Y. Entonces para todo y con $f_Y(y) > 0$, la medida condicional $\mu_{X|Y=y} \ll \lambda$ con derivada de Radon-Nikodym

$$f_{X|Y}(x \mid y) = \frac{d\mu_{X|Y=y}}{d\lambda}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \tag{4.43}$$

y en consecuencia

$$F_{X|Y}(x \mid y) = \int_{-\infty}^{x} f_{X|Y}(t \mid y)\, dt. \tag{4.44}$$

La demostracion se deja al lector.

Proposición 4.3.3 Función de masa condicional. Sean X, Y variables aleatorias discretas con función de masa conjunta $p_{X,Y}$ y función de masa marginal p_Y. Entonces para todo y con $p_Y(y) > 0$,

la medida condicional $\mu_{X|Y=y} \ll \mu_c$ con derivada de Radon-Nikodym respecto a la medida de conteo μ_c

$$p_{X|Y}(x \mid y) = \frac{d\mu_{X|Y=y}}{d\mu_c}(x) = \frac{p_{X,Y}(x,y)}{p_Y(y)}, \tag{4.45}$$

y en consecuencia

$$F_{X|Y}(x \mid y) = \sum_{t \le x} p_{X|Y}(t \mid y). \tag{4.46}$$

La demostracion se deja al lector.

Teorema 4.3.6 Regla de Bayes para mezclas discreto–continuas. Suponga que Z es absolutamente continua y que N es discreta. Entonces

$$\frac{d}{dz} F_{Z|N}(z \mid n) = \lim_{h \to 0} \frac{\mathbb{P}(z < Z \le z + h \mid N = n)}{h} \tag{4.47}$$

$$= \lim_{h \to 0} \frac{\mathbb{P}(N = n \mid z < Z \le z + h)}{p(N = n)} \cdot \frac{\mathbb{P}(z < Z \le z + h)}{h} \tag{4.48}$$

$$= \mathbb{P}(N = n \mid Z = z) \cdot \frac{f_Z(z)}{p(N = n)} \tag{4.49}$$

Por lo tanto, se tiene que

$$f_{Z|N}(z \mid n) = \mathbb{P}(N = n \mid Z = z) \cdot \frac{f_Z(z)}{p(N = n)} \tag{4.50}$$

Si $f_Z(z) > 0$, de lo anterior es razonable definir

$$F_{N|Z}(n \mid z) := \frac{f_{Z|N}(z \mid n)}{f_Z(z)} p(N = n) \tag{4.51}$$

En particular, se puede comprobar que

$$p(N = n) = \int_{\mathbb{R}} \mathbb{P}(N = n \mid Z = z) f_Z(z)\, dz \tag{4.52}$$

Demostración. Para

$$\frac{d}{dz} F_{Z|N}(z \mid n) = \lim_{h \to 0} \frac{\mathbb{P}(z < Z \le z + h, N = n)}{h},$$

se deriva del teorema fundamental del calculo y la definición de distribución condicional. Las igualdades se derivan trivialmente de el argumento anterior. Y para la ultima simplemente integre sobre $\mathbb{R}$ con respecto a z. □

4.4. Esperanza condicional

Definición 4.4.1 Esperanza condicional. Sea $(\Omega, \mathscr{F}_0, \mathbb{P})$ un espacio de probabilidad, $\mathscr{G} \subseteq \mathscr{F}_0$ una σ-álgebra, y X una variable aleatoria con $\mathbb{E}[|X|] < \infty$. Se dice que Y es una versión de $\mathbb{E}[X \mid \mathscr{G}]$ si

$$Y \in \mathscr{G}, \quad \text{y} \quad \int_A X\, d\mathbb{P} = \int_A Y\, d\mathbb{P} \quad \forall A \in \mathscr{G}. \tag{4.53}$$

Si Y es una variable aleatoria, definimos $\mathbb{E}[X \mid Y] := \mathbb{E}[X \mid \sigma(Y)]$, donde $\sigma(Y)$ es la σ-álgebra generada por Y.

Definición 4.4.2 Distribución condicional regular. Sea $(\Omega, \mathscr{F}, \mathbb{P})$ un espacio de probabilidad, $X : (\Omega, \mathscr{F}) \to (S, \mathscr{S})$ una función medible y $\mathscr{G} \subseteq \mathscr{F}$ una σ-álgebra. Una función $\mu : \Omega \times \mathscr{S} \to [0,1]$ se dice una distribución condicional regular de X dado $\mathscr{G}$ si

$$\text{para cada } A \in \mathscr{S}, \quad \omega \mapsto \mu(\omega, A) \text{ es una versión de } \mathbb{P}(X \in A \mid \mathscr{G}), \tag{4.54}$$

$$\text{para c.t.p. } \omega, \quad A \mapsto \mu(\omega, A) \text{ es una medida de probabilidad sobre } (S, \mathscr{S}). \tag{4.55}$$

Cuando $S = \Omega$ y X es la identidad, μ se llama una probabilidad condicional regular.

4.4.1. Propiedades de la esperanza regular

Lema 4.4.1 Unicidad casi segura. Si Y_1 e Y_2 son dos versiones de $\mathbb{E}[X \mid \mathscr{G}]$, entonces $\mathbb{P}(Y_1 = Y_2) = 1$.

Demostración. Sea $Z = Y_1 - Y_2$. Como ambas satisfacen la definición, $\int_A Z\, d\mathbb{P} = 0$ para todo $A \in \mathscr{G}$. Tomando $A^+ = \{Z > 0\}$ y $A^- = \{Z < 0\}$, que pertenecen a $\mathscr{G}$, se tiene $\int_{A^+} Z\, d\mathbb{P} = 0$ con $Z > 0$ en A^+, luego $\mathbb{P}(A^+) = 0$, y análogamente $\mathbb{P}(A^-) = 0$. Por tanto $\mathbb{P}(Z \neq 0) \leq \mathbb{P}(A^+) + \mathbb{P}(A^-) = 0$.

□

Teorema 4.4.1 Existencia de la esperanza condicional. Si $\mathbb{E}[|X|] < \infty$, entonces $\mathbb{E}[X \mid \mathscr{G}]$ existe.

Demostración. Escribimos $X = X^+ - X^-$ con $X^+, X^- \geq 0$ e integrables. Para $Y \geq 0$ con $Y \in L^1(\mathscr{F}_0)$, la medida $\nu(A) = \int_A Y\, d\mathbb{P}$ sobre $\mathscr{G}$ satisface $\nu \ll \mathbb{P}|_{\mathscr{G}}$. Por Radon-Nikodym existe $Z \in \mathscr{G}$, $Z \geq 0$, tal que $\nu(A) = \int_A Z\, d\mathbb{P}$ para todo $A \in \mathscr{G}$. Aplicando esto a X^+ y X^- se obtienen $Y^+, Y^- \in \mathscr{G}$ no negativos con $\int_A X^{\pm}\, d\mathbb{P} = \int_A Y^{\pm}\, d\mathbb{P}$. Entonces $Y = Y^+ - Y^-$ satisface la definición.

□

Teorema 4.4.2 Propiedades de la esperanza condicional. Sean X, Y variables aleatorias integrables, $a, b \in \mathbb{R}$, $\mathscr{G}_1 \subseteq \mathscr{G}_2 \subseteq \mathscr{F}_0$ σ-álgebras y φ convexa. Entonces:

$$\mathbb{E}[\mathbb{E}[X \mid \mathscr{G}]] = \mathbb{E}[X]. \tag{4.56}$$

$$X \geq 0 \implies \mathbb{E}[X \mid \mathscr{G}] \geq 0 \quad \wedge \quad X \leq Y \implies \mathbb{E}[X \mid \mathscr{G}] \leq \mathbb{E}[Y \mid \mathscr{G}]. \tag{4.57}$$

$$\mathbb{E}[aX + bY \mid \mathscr{G}] = a\mathbb{E}[X \mid \mathscr{G}] + b\mathbb{E}[Y \mid \mathscr{G}]. \tag{4.58}$$

$$\text{Si } \sigma(X) \perp \mathscr{G}, \text{ entonces } \mathbb{E}[X \mid \mathscr{G}] = \mathbb{E}[X]. \tag{4.59}$$

$$\text{Si } Y \in \mathscr{G}, \text{ entonces } \mathbb{E}[XY \mid \mathscr{G}] = Y\,\mathbb{E}[X \mid \mathscr{G}]. \tag{4.60}$$

$$\mathbb{E}[\varphi(X) \mid \mathscr{G}] \geq \varphi(\mathbb{E}[X \mid \mathscr{G}]). \tag{4.61}$$

$$\mathbb{E}[\mathbb{E}[X \mid \mathscr{G}_2] \mid \mathscr{G}_1] = \mathbb{E}[\mathbb{E}[X \mid \mathscr{G}_1] \mid \mathscr{G}_2] = \mathbb{E}[X \mid \mathscr{G}_1]. \tag{4.62}$$

$$X_n \uparrow X,\ X_n \geq 0,\ \mathbb{E}[X] < \infty \implies \mathbb{E}[X_n \mid \mathscr{G}] \uparrow \mathbb{E}[X \mid \mathscr{G}]. \tag{4.63}$$

La demostracion se deja al lector.

Teorema 4.4.3 Contracción en L^p y proyección ortogonal en L^2. Para $p \geq 1$, la esperanza condicional es una contracción en L^p:

$$\|\mathbb{E}[X \mid \mathscr{G}]\|_p \leq \|X\|_p. \tag{4.64}$$

En particular para $p = 2$, $\mathbb{E}[X \mid \mathscr{G}]$ es la única variable $Y \in \mathscr{G}$ que minimiza

$$\mathbb{E}[(X - Y)^2], \tag{4.65}$$

es decir, es la proyección ortogonal de X sobre $L^2(\mathscr{G})$.

La demostracion se deja al lector.

Teorema 4.4.4 LOTUS condicional. Sea $\mu(\omega, \cdot)$ una distribución condicional regular de X dado $\mathscr{G}$, y sea g medible con $\mathbb{E}[|g(X)|] < \infty$. Entonces

$$\mathbb{E}[g(X) \mid \mathscr{G}](\omega) = \int \mu(\omega, dx)\, g(x) \quad \text{c.s.} \tag{4.66}$$

En los casos particulares, si Y es discreta o absolutamente continua

$$\mathbb{E}[g(X) \mid Y = y] = \sum_x g(x)\, p_{X|Y}(x \mid y) \quad \text{o} \quad \mathbb{E}[g(X) \mid Y = y] = \int_{-\infty}^{\infty} g(x)\, f_{X|Y}(x \mid y)\, dx. \tag{4.67}$$

La demostración se deja al lector.

Proposición 4.4.1 Varianza condicional. Sea X una variable aleatoria con $\mathbb{E}[X^2] < \infty$. La varianza condicional de X dado Y es la variable aleatoria

$$\operatorname{Var}(X \mid Y) := \mathbb{E}\big[(X - \mathbb{E}[X \mid Y])^2 \mid Y\big] = \mathbb{E}[X^2 \mid Y] - (\mathbb{E}[X \mid Y])^2\,, \tag{4.68}$$

La demostracion se deja al lector.

Proposición 4.4.2 Ley de la varianza total. Se cumple que

$$\operatorname{Var}(X) = \mathbb{E}[\operatorname{Var}(X \mid Y)] + \operatorname{Var}(\mathbb{E}[X \mid Y]) \tag{4.69}$$

La demostración se deja al lector.

Teorema 4.4.5 Factorización condicional bajo independencia y extracción funciones.

$$\text{Si } X \text{ y } Y \text{ son independientes, entonces } \mathbb{E}[X \mid Y] = \mathbb{E}[X] \tag{4.70}$$

$$\mathbb{E}[X \cdot g(Y) \mid Y] = g(Y) \cdot \mathbb{E}[X \mid Y] \tag{4.71}$$

La primera es trivial, y la segunda es simplemente por que Y esta fijo para un conjunto.

Teorema 4.4.6 Fórmula de convolución. Sean X y Y variables aleatorias independientes con funciones de distribución acumulada $F(x) = \mathbb{P}(X \leq x)$ y $G(y) = \mathbb{P}(Y \leq y)$, respectivamente. Enton-

ces, para todo $z \in \mathbb{R}$, se cumple

$$\mathbb{P}(X+Y \leq z) = \int_{-\infty}^{\infty} F(z-y)\, dG(y). \tag{4.72}$$

Demostración. Dado que son independientes se cumple que $\mathbb{P}(X \leq x, Y \leq y) = F(x)G(y)$ y dado que

$$\mathbb{P}(X \leq z-Y \mid Y) = \mathbb{P}(X \leq z-Y) = F(z-Y).$$

Ahora por el teorema de probabilidad total

$$\mathbb{P}(X+Y \leq z) = \mathbb{E}\left(\mathbb{P}(X+Y \leq z \mid Y)\right) = \mathbb{E}\left(\mathbb{P}(X \leq z-Y \mid Y)\right).$$

Entonces por definición de esperanza de una variable aleatoria continua

$$\mathbb{P}(X+Y \leq z) = \mathbb{E}\left[F(z-Y)\right] = \int_{-\infty}^{\infty} F(z-y)\, dG(y).$$

□

Teorema 4.4.7 Convolución de densidades. Sean X y Y variables aleatorias independientes, donde X tiene densidad f y Y tiene función de distribución acumulada $G(y) = \mathbb{P}(Y \leq y)$. Entonces, la variable aleatoria $X+Y$ tiene densidad h dada por

$$h(x) = \int_{-\infty}^{\infty} f(x-y)\, dG(y). \tag{4.73}$$

Si además Y tiene densidad g, entonces

$$h(x) = \int_{-\infty}^{\infty} f(x-y)\, g(y)\, dy. \tag{4.74}$$

El teorema anterior es consecuencia directa del teorema de Leibniz para integración parcial y el teorema anterior.

4.5. Convergencia de variables aleatorias

4.5.1. Convergencia casi segura

Definición 4.5.1 Convergencia casi segura. La sucesión X_n, $n = 1, 2, 3, ...$, converge casi seguramente a una variable aleatoria X si

$$\mathbb{P}\left(\left\{\omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\}\right) = 1 \tag{4.75}$$

Se denota $X_n \xrightarrow{\text{c.s.}} X$ o $\lim_{n\to\infty} X_n = X$ c.s.

Proposición 4.5.1 Caracterización probabilística de la convergencia casi segura. Se tiene que $X_n \xrightarrow{\text{c.s.}} X$ si y sólo si para todo $\varepsilon > 0$ se cumple

$$\lim_{m\to\infty} \mathbb{P}\left(\sup_{n\geq m} |X_n - X| \geq \varepsilon\right) = 0 \tag{4.76}$$

Demostración. Suponga por contradicción que $X_n \xrightarrow{\text{c.s.}} X$ pero no

$$\lim_{m\to\infty} \mathbb{P}\left(\sup_{n\geq m} |X_n - X| \geq \varepsilon\right) = 0.$$

En cuyo caso eso implica que $\exists_{\omega\in\Omega} \mid \exists_{\varepsilon>0}\forall_{m\in\mathbb{N}}(\sup_{n\geq m} |X_n - X| \geq \varepsilon)$ (Osea, hay un $\omega \mid \mathbb{P}(\omega) > 0$). Entonces se sigue que de igual forma $\exists_\omega \mid \lim_{n\to\infty} X_n(\omega) \neq X(\omega)$, consecuentemente, ya que se esta bajo la misma función de probabilidad esto implica que

$$\mathbb{P}\left(\left\{\omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\}\right) + \mathbb{P}\left(\left\{\omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\}^c\right) = \mathbb{P}(\omega) > 1,$$

lo cual es una contradicción. La otra dirección es básicamente los mismo.

□

4.5.2. Convergencia en L^p

Definición 4.5.2 Convergencia en L^p. Sea $p \geq 1$ entero. Suponga que $\mathbb{E}[|X|^p] < \infty$ y $\mathbb{E}[|X_n|^p] < \infty$ para todo $n \in \mathbb{N}$. Diremos que X_n converge en L^p a X si

$$\lim_{n\to\infty} \mathbb{E}[|X_n - X|^p] = 0 \tag{4.77}$$

Denotamos $X_n \xrightarrow{L^p} X$ o $\lim_{n\to\infty} X_n = X$ en L^p.

4.5.3. Convergencia en distribucion

Definición 4.5.3 Convergencia en distribución. Sean $X_1, X_2, X_3, ...$ variables aleatorias cuyas funciones de distribución están dadas por $F_1, F_2, F_3, ...$ respectivamente. Se dice que X_n converge en distribución a X si

$$\lim_{n\to\infty} F_n(x) = F(x) \tag{4.78}$$

para todo punto de continuidad de F, donde F representa la función de distribución de X. Se denota $X_n \xrightarrow{d} X$.

4.5.4. Convergencia en probabilidad

Definición 4.5.4 Convergencia en probabilidad. Sean $(X_n)_{n\in\mathbb{N}}$ y X variables aleatorias definidas sobre el mismo espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$. Decimos que X_n converge en probabilidad a X si, para todo $\varepsilon > 0$

$$\lim_{n\to\infty} \mathbb{P}(|X_n - X| \geq \varepsilon) = 0. \tag{4.79}$$

Se denota $X_n \xrightarrow{\mathbb{P}} X$ o $X_n \to X$ en probabilidad.

4.5.5. Teorema de convergencia

Teorema 4.5.1 Cadena de implicaciones de convergencia. Si $X_n \xrightarrow{\text{c.s.}} X$, entonces $X_n \xrightarrow{\mathbb{P}} X$. Si $X_n \xrightarrow{\mathbb{P}} X$, entonces $X_n \xrightarrow{d} X$. Si $c \in \mathbb{R}$ y $X_n \xrightarrow{d} c$, entonces $X_n \xrightarrow{\mathbb{P}} c$.

La primera es por pura definición. La segunda se hace por contradicción. Y la tercera se hace tomando epsilons y el valor real de la variable aleatoria.

Teorema 4.5.2 Convergencia dominada. Suponga que $X_n \xrightarrow{\text{c.s.}} X$ y que existe una variable aleatoria Y tal que $\mathbb{E}(Y) < \infty$ y $|X_n| \leq Y$ para todo $n \in \mathbb{N}$. Entonces

$$\lim_{n\to\infty} \mathbb{E}[X_n] = \mathbb{E}[X] \tag{4.80}$$

Demostración. Suponga que $E(X) < \infty$. Ahora tome $Z_n = |X_n - X|$ y note que $Z_n \xrightarrow{c.s.} 0$, entonces $\lim_{n\to\infty} \mathbb{E}[|X_n - X|] = 0$. En cuyo caso se sigue que por la desigualdad de Jensen se tiene $\lim_{n\to\infty} \mathbb{E}[X_n] = \mathbb{E}[X]$. El caso $\mathbb{E}[X] = \infty$ es trivial.

□

Teorema 4.5.3 Convergencia monótona. Suponga que $0 \leq X_n \uparrow X$ y que $X_n \xrightarrow{\text{c.s.}} X$. Entonces

$$\lim_{n\to\infty} \mathbb{E}[X_n] = \mathbb{E}[X] \tag{4.81}$$

Demostración. Dada la convergencia monótona creciente positiva, se tiene que $|X_n| = X_n \leq X$. Ahora suponga que $E[X] = \infty$, entonces se sigue que

$$\lim_{m\to\infty} \mathbb{P}\left(\sup_{n\geq m} |X_n - X| \geq \varepsilon\right) > 0,$$

Lo que contradice en teorema trasanterior. Entonces lo demás se sigue del teorema anterior.

□

Teorema 4.5.4 Teorema de Helly-Bray. Sean F_n funciones de distribución acumulada y F una función de distribución acumulada tal que $X_n \xrightarrow{d} X$. Sea $h : \mathbb{R} \to \mathbb{R}$ una función continua y acotada. Entonces

$$\int_{-\infty}^{\infty} h(x)\, dF_n(x) \to \int_{-\infty}^{\infty} h(x)\, dF(x). \tag{4.82}$$

Demostración. Como h es continua y acotada en $\mathbb{R}$, existe una constante $M > 0$ tal que $|h(x)| \leq M, \forall_{x\in\mathbb{R}}$.
Sea $\varepsilon > 0$. Dado que h es continua y acotada, existe una función escalonada de la forma

$$\varphi(x) = \sum_{k=1}^{m} c_k \mathbf{1}_{(-\infty, d_k]}(x),$$

donde $d_1 < d_2 < \cdots < d_m$ independientes del n, tal que $\sup_{x\in\mathbb{R}} \big|h(x) - \varphi(x)\big| < \varepsilon$.
Por linealidad de la integral de Stieltjes

$$\int h(x)\, dF_n(x) - \int h(x)\, dF(x)$$
$$= \int (h - \varphi)\, dF_n(x) + \int \varphi(x)\, dF_n(x) - \int \varphi(x)\, dF(x) + \int (\varphi - h)\, dF(x).$$

Ahora note

$$\int \varphi(x)\, dF_n(x) = \sum_{k=1}^{m} c_k F_n(d_k) \quad \wedge \quad \int \varphi(x)\, dF(x) = \sum_{k=1}^{m} c_k F(d_k).$$

Elegimos los puntos d_k como puntos de continuidad de F. Por convergencia en distribución

$$\sum_{k=1}^{m} c_k F_n(d_k) \to \sum_{k=1}^{m} c_k F(d_k).$$

De forma que

$$\limsup_{n\to\infty} \left| \int h\, dF_n - \int h\, dF \right| \leq M\varepsilon.$$

Entonces

$$\left| \int_{-\infty}^{\infty} h(x)\, dF_n(x) - \int_{-\infty}^{\infty} h(x)\, dF(x) \right| < \varepsilon(M+1).$$

□

Teorema 4.5.5 Continuidad de Lévy y Cramér. Sean $X_1, X_2, X_3, \ldots$ variables aleatorias con funciones características $\varphi_1, \varphi_2, \varphi_3, \ldots$ respectivamente. Sea X otra variable aleatoria con función característica φ. Entonces $X_n \xrightarrow{d} X$ si y sólo si

$$\lim_{n\to\infty} \varphi_n(t) = \varphi(t) \quad \text{para todo } t \in \mathbb{R} \tag{4.83}$$

Demostración. La parte izquierda derecha se deja al lector.

Para la otra parte note que por el teorema de Helly, toda sucesión de $\{F_n\}$ tiene una subsucesión $\{F_{n_k}\}$ que converge en todos los puntos de continuidad del límite a alguna función de distribución G. Sea entonces $\{F_{n_k}\}$ una subsucesión cualquiera tal que $F_{n_k} \to G$, cuya función característica denotaremos ψ; sea $h(x) = e^{itx}$. Por Helly-Bray aplicado a la subsucesión

$$\varphi_{n_k}(t) = \int e^{itx}\, dF_{n_k}(x) \to \int e^{itx}\, dG(x) = \psi(t).$$

Pero por hipótesis, $\varphi_{n_k}(t) \to \varphi(t)$. Por unicidad del límite, $\psi(t) = \varphi(t)$ para todo $t \in \mathbb{R}$. Es bien conocido (y se prueba usando inversión de Fourier o el teorema de Stone–Weierstrass en intervalos) que dos variables aleatorias con la misma función característica tienen la misma distribución. En particular $G = F$.

Supongamos por contradicción que no $X_n \xrightarrow{d} X$. Entonces existe $\varepsilon > 0$, un punto de continuidad x de F, y una subsucesión n_j tal que

$$|F_{n_j}(x) - F(x)| \geq \varepsilon, \quad \forall j.$$

Pero $\{F_{n_j}\}$ tiene una subsucesión convergente $F_{n_{j_k}} \Rightarrow H$ para alguna f.d. H. Por el teorema de Helly y lo anterior $H = F$, así que $F_{n_{j_k}}(x) \to F(x)$, contradicción.

Por tanto, $F_n(x) \to F(x)$ en todo punto de continuidad de F, es decir, $X_n \xrightarrow{d} X$.

□

4.5.6. Desigualdad de Chebyshev

Teorema 4.5.6 Desigualdad de Chebyshev. Sea X una variable aleatoria con $\mathbb{E}[|X|] < \infty$ y $\mathrm{Var}(X) < \infty$. Entonces, para todo $\varepsilon > 0$,

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \varepsilon) \leq \frac{\mathrm{Var}(X)}{\varepsilon^2}. \tag{4.84}$$

Demostración. Definamos $Y = X - \mathbb{E}[X]$. Entonces

$$\mathbb{E}[Y] = 0, \quad \mathrm{Var}(Y) = \mathrm{Var}(X).$$

Por definición de varianza

$$\mathrm{Var}(Y) = \mathbb{E}[Y^2].$$

Ahora, descomponemos la esperanza usando el evento $\{|Y| \geq \varepsilon\}$

$$\mathbb{E}[Y^2] = \mathbb{E}[Y^2 \cdot 1_{\{|Y| \geq \varepsilon\}}] + \mathbb{E}[Y^2 \cdot 1_{\{|Y| < \varepsilon\}}].$$

El segundo término es no negativo

$$\mathbb{E}[Y^2 \cdot 1_{\{|Y| < \varepsilon\}}] \geq 0.$$

En el primer término, como $|Y| \geq \varepsilon$ en el soporte del indicador

$$Y^2 \cdot 1_{\{|Y| \geq \varepsilon\}} \geq \varepsilon^2 \cdot 1_{\{|Y| \geq \varepsilon\}}.$$

Tomando esperanza

$$\mathbb{E}\big[Y^2 \cdot 1_{\{|Y| \geq \varepsilon\}}\big] \geq \varepsilon^2 \cdot \mathbb{E}\big[1_{\{|Y| \geq \varepsilon\}}\big] = \varepsilon^2 \cdot \mathbb{P}(|Y| \geq \varepsilon).$$

□

5

Ley de los grandes números.

5.0.1. Variables no correlacionadas

Definición 5.0.1 Variables no correlacionadas. Sea $\{X_i\}_{i\in I}$ una familia de variables aleatorias tales que $\mathbb{E}[X_i^2] < \infty$ para todo $i \in I$. Decimos que dicha familia es no correlacionada si, para todo par $i \neq j$, se cumple

$$\mathbb{E}[X_i X_j] = \mathbb{E}[X_i] \cdot \mathbb{E}[X_j]. \tag{5.1}$$

Teorema 5.0.1 Varianza no correlacionada. Sean $X_1, \dots, X_n$ variables aleatorias no correlacionadas tales que $\mathbb{E}[X_i^2] < \infty$ para todo $i = 1, \dots, n$. Entonces, la varianza de la suma es igual a la suma de las varianzas

$$\mathrm{Var}(X_1 + \cdots + X_n) = \mathrm{Var}(X_1) + \cdots + \mathrm{Var}(X_n), \tag{5.2}$$

donde $\mathrm{Var}(Y)$ denota la varianza de la variable aleatoria Y.

La demostración queda al lector. Aplique el binomio de newton y ya.

Lema 5.0.1 Convergencia en probabilidad vía momentos. Sea $\{Z_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias y sea $p > 0$. Si

$$\lim_{n\to\infty} \mathbb{E}(|Z_n|^p) = 0, \tag{5.3}$$

entonces

$$Z_n \xrightarrow{\mathbb{P}} 0, \tag{5.4}$$

es decir, Z_n converge a cero en probabilidad.

La demostración queda al lector. Aplique la desigualad de chebyshev.

5.0.2. Ley debil en L^2

Teorema 5.0.2 Ley débil en L^2. Suponga que $X_1, X_2, X_3, \ldots$ son variables aleatorias no correlacionadas con $\mathbb{E}[X_n] = \mu$ y $\mathrm{Var}(X_n) < \infty$ para todo $n \in \mathbb{N}$. Si $S_n := X_1 + X_2 + \cdots + X_n$, entonces

$$\frac{S_n}{n} \xrightarrow{L^2} \mu \tag{5.5}$$

y por lo tanto

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu \tag{5.6}$$

La demostración queda al lector. Aplique el Teorema del promedio de Cesàro.

Teorema 5.0.3 Ley débil por control de varianza. Sea S_n una sucesión de variables aleatorias con esperanza $\mu_n := \mathbb{E}[S_n]$ y varianza $\sigma_n^2 := \mathrm{Var}(S_n)$. Suponga que existe una sucesión de escalares positivos $b_n > 0$ tal que

$$\frac{\sigma_n^2}{b_n^2} \longrightarrow 0, \tag{5.7}$$

entonces

$$\frac{S_n - \mu_n}{b_n} \xrightarrow{\mathbb{P}} 0. \tag{5.8}$$

Demostración. Note que

$$\mathbb{P}(|S_n - \mu_n| \geq \varepsilon b_n) \leq \frac{\mathrm{Var}(S_n)}{(\varepsilon b_n)^2} = \frac{\sigma_n^2}{\varepsilon^2 b_n^2}.$$

Entonces se sigue que

$$\lim_{n\to\infty} \mathbb{P}\left(\left|\frac{S_n - \mu_n}{b_n}\right| \geq \varepsilon\right) \leq \lim_{n\to\infty} \frac{\sigma_n^2}{\varepsilon^2 b_n^2} = 0.$$

□

Definición 5.0.2 Variable indicadora de ciclos en la descomposición. Para cada $n \in \mathbb{N}$, se define la variable indicadora $X_{n,k}$ como aquella que toma el valor 1 si un paréntesis derecho aparece después del k-ésimo número en la descomposición correspondiente, y 0 en caso contrario. La suma total $S_n := X_{n,1} + X_{n,2} + \cdots + X_{n,n}$ representa el número total de ciclos en dicha descomposición.

Lema 5.0.2 Esperanza del conteo de ciclos vía indicadores. Sean $X_{n,1}, \ldots, X_{n,n}$ variables aleatorias independientes tales que

$$\mathbb{P}(X_{n,j} = 1) = \frac{1}{n - j + 1}. \tag{5.9}$$

Entonces, la suma $S_n = X_{n,1} + X_{n,2} + \cdots + X_{n,n}$ satisface

$$\mathbb{E}[S_n] = \sum_{j=1}^{n} \frac{1}{n-j+1} = H_n, \tag{5.10}$$

donde H_n es el n-ésimo número armónico.

La demostracion es casi trivial.

Definición 5.0.3 Truncamiento. Sea X una variable aleatoria y sea $M > 0$. El truncamiento de X en el nivel M se define como

$$\bar{X} := X \cdot \mathbf{1}_{\{|X| \leq M\}} = \begin{cases} X, & \text{si } |X| \leq M, \\ 0, & \text{si } |X| > M. \end{cases} \tag{5.11}$$

Teorema 5.0.4 Teorema de Bienaymé–Chebyshev, versión débil tipo Lindeberg. Para cada $n \in \mathbb{N}$, sean $X_{n,k}$, con $1 \leq k \leq n$, variables aleatorias independientes. Sea $b_n > 0$ tal que $b_n \to \infty$; y suponga que, cuando $n \to \infty$, se cumplen las siguientes condiciones

$$\sum_{k=1}^{n} \mathbb{P}(|X_{n,k}| > b_n) \to 0, \tag{5.12}$$

$$\frac{1}{b_n^2} \sum_{k=1}^{n} \mathbb{E}[\bar{X}_{n,k}^2] \to 0. \tag{5.13}$$

Si definimos $S_n := X_{n,1} + \cdots + X_{n,n}$ y $a_n := \sum_{k=1}^{n} \mathbb{E}[\bar{X}_{n,k}]$, entonces

$$\frac{S_n - a_n}{b_n} \xrightarrow{\mathbb{P}} 0. \tag{5.14}$$

Demostración. Note que los $\bar{X}_{n,k}$ son independientes y $|\bar{X}_{n,k}| \leq b_n$.

Tome

$$S_n = \sum_{k=1}^{n} \bar{X}_{n,k} + \sum_{k=1}^{n} X_{n,k} \mathbf{1}_{\{|X_{n,k}| > b_n\}} = \bar{S}_n + \hat{S}_n$$

Entonces

$$\mathbb{P}\left(\left| \frac{\hat{S}_n}{b_n} \right| > 0 \right) \leq \mathbb{P}\left(\bigcup_k \{|X_{n,k}| > b_n\} \right) \leq \sum_{k=1}^{n} \mathbb{P}(|X_{n,k}| > b_n) \to 0.$$

Ahora, por independencia note que

$$\mathbb{E}\left[\frac{\bar{X}_{n,k} - \mathbb{E}[\bar{X}_{n,k}]}{b_n} \right] = 0 \quad \wedge \quad \operatorname{Var}\left(\frac{\bar{X}_{n,k} - \mathbb{E}[\bar{X}_{n,k}]}{b_n} \right) = \frac{\mathbb{E}[\bar{X}_{n,k}^2]}{b_n^2}.$$

Por lo tanto

$$\operatorname{Var}\left(\frac{\sum_{k=1}^{n} \bar{X}_{n,k} - \mathbb{E}[\bar{X}_{n,k}]}{b_n} \right) = \frac{1}{b_n^2} \sum_{k=1}^{n} \mathbb{E}[\bar{X}_{n,k}^2] \to 0.$$

Sumado a ello

$$\sum_{k=1}^{n} \frac{\bar{X}_{n,k} - \mathbb{E}[\bar{X}_{n,k}]}{b_n} = \frac{\hat{S}_n - a_n}{b_n}.$$

Aplicando directamente el Teorema de ley débil por control de varianza

$$\frac{\hat{S}_n - a_n}{b_n} \xrightarrow{\mathbb{P}} 0.$$

□

Lema 5.0.3 Fórmula de integración por partes para momentos. Sea Y una variable aleatoria tal que $Y \geq 0$ casi seguramente, y sea $p > 0$. Entonces, el momento p-ésimo de Y se puede expresar como

$$\mathbb{E}[Y^p] = \int_0^\infty p y^{p-1}\, \mathbb{P}(Y > y)\, dy. \tag{5.15}$$

La demostracion se deja al lector.

5.0.3. Ley de los Grandes Números con truncamiento para colas ligeras

Teorema 5.0.5 Ley de los Grandes Números con truncamiento para colas ligeras. Sea $X_1, X_2, X_3, \ldots$ una sucesión de variables aleatorias i.i.d. tales que

$$x \cdot \mathbb{P}(|X_1| > x) \to 0 \quad \text{cuando } x \to \infty. \tag{5.16}$$

Defina $S_n := X_1 + X_2 + \cdots + X_n$ y $\mu_n := \mathbb{E}[X_1 \cdot \mathbf{1}_{\{|X_1| \leq n\}}]$. Entonces, se tiene la siguiente convergencia en probabilidad

$$\frac{S_n}{n} - \mu_n \xrightarrow{\mathbb{P}} 0. \tag{5.17}$$

Demostración. Aplicamos directamente el teorema anterior tomando $X_{n,k} := X_k$ para $k = 1, \ldots, n$ y $b_n := n$. Podemos ver que

$$\sum_{k=1}^n \mathbb{P}(|X_{n,k}| > n) = n \cdot \mathbb{P}(|X_1| > n) = n \cdot \mathbb{P}(|X_1| > b_n) \to 0.$$

Sumando a ello si $\bar{X}_{n,k} := X_k \mathbf{1}_{\{|X_k| \leq n\}}$, entonces

$$\frac{1}{b_n^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] = \frac{1}{n^2} \cdot n \cdot \mathbb{E}\left[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}\right] = \frac{1}{n} \mathbb{E}\left[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}\right] = \frac{2}{n} \int_0^n t\mathbb{P}(|X_1| > t)\, dt..$$

Y dado que $x \cdot \mathbb{P}(|X_1| > x) \to 0$, se tiene que para todo $\varepsilon > 0$ existe t_0 talque si $t \geq t_0$, entonces

$$\left| 2 \int_0^n t\mathbb{P}(|X_1| > t)\, dt \right| \leq 2t_0 + 2n\varepsilon$$

De forma que

$$\left| \frac{1}{b_n^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] \right| \leq 2\frac{t_0}{n} + 2\varepsilon$$

De forma que cuando $n \to \infty$ entonces $\frac{1}{b_n^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] \to 0$. Además

$$a_n = \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}] = n \cdot \mathbb{E}\left[X_1 \mathbf{1}_{\{|X_1| \leq n\}}\right] = n\mu_n.$$

Entonces por el teorema anterior

$$\frac{S_n - a_n}{b_n} = \frac{S_n - n\mu_n}{n} = \frac{S_n}{n} - \mu_n \xrightarrow{\mathbb{P}} 0.$$

□

5.1. Lema de Borel-Cantelli

Teorema 5.1.1 Primer lema de Borel-Cantelli. Sea $\{A_n\}_{n\in\mathbb{N}}$ una sucesión de eventos en un espacio de probabilidad. Si

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty, \tag{5.18}$$

entonces

$$\mathbb{P}(A_n \text{ i.o.}) = 0, \tag{5.19}$$

donde A_n i.o. denota el evento de que ocurren infinitos A_n, es decir

$$A_n \text{ i.o.} := \limsup_{n\to\infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k. \tag{5.20}$$

Demostración. Note que $m \in \mathbb{N}$. Entonces

$$\mathbb{P}\left(\bigcup_{k=m}^{\infty} A_k\right) \leq \sum_{k=m}^{\infty} \mathbb{P}(A_k)$$

Como la serie $\sum \mathbb{P}(A_k)$ converge entonces

$$\mathbb{P}\left(\bigcup_{k=m}^{\infty} A_k\right) \to 0 \quad m \to \infty.$$

Ahora, como

$$A_n \text{ i.o.} = \bigcap_{m=1}^{\infty} \bigcup_{k=m}^{\infty} A_k \subset \bigcup_{k=m}^{\infty} A_k \quad , \forall m$$

tenemos

$$\mathbb{P}(A_n \text{ i.o.}) \leq \mathbb{P}\left(\bigcup_{k=m}^{\infty} A_k\right) \quad , \forall m.$$

Tomando el límite superior cuando $m \to \infty$,

$$\mathbb{P}(A_n \text{ i.o.}) \leq \lim_{m\to\infty} \mathbb{P}\left(\bigcup_{k=m}^{\infty} A_k\right) = 0.$$

□

Teorema 5.1.2 Caracterización de convergencia en probabilidad. Sea $\{X_n\}_{n\in\mathbb{N}}$ una sucesión de variables aleatorias y sea X una variable aleatoria. Entonces

$$X_n \xrightarrow{\mathbb{P}} X \tag{5.21}$$

si y solo si para toda subsucesión $\{X_{n_m}\}_{m\in\mathbb{N}}$ existe una subsucesión adicional $\{X_{n_{m_k}}\}_{k\in\mathbb{N}}$ tal que

$$X_{n_{m_k}} \xrightarrow{\text{c.s.}} X. \tag{5.22}$$

Demostración. ($\Rightarrow$) Suponga que $X_n \xrightarrow{\mathbb{P}} X$. Sea $\{X_{n_m}\}_m$ cualquier subsucesión. Para cada $k \in \mathbb{N}$ definimos el evento

$$A_k := \{|X_{n_m} - X| > \frac{1}{k} \text{ para infinitos } m\} = (|X_{n_m} - X| > \frac{1}{k}) \text{ i.o.}$$

Como $X_n \xrightarrow{\mathbb{P}} X$, se tiene que

$$\mathbb{P}\Big(|X_{n_m} - X| > \frac{1}{k}\Big) = \mathbb{P}\Big(|X_n - X| > \frac{1}{k}\Big) \to 0 \quad n \to \infty,$$

entonces $\mathbb{P}\left(|X_{n_m} - X| > \frac{1}{k}\right) \to 0$ cuando $m \to \infty$. Por el primer lema de Borel-Cantelli

$$\sum_m \mathbb{P}\left(|X_{n_m} - X| > \tfrac{1}{k}\right) < \infty \quad \Rightarrow \quad \mathbb{P}(A_k) = 0.$$

Así

$$\mathbb{P}\left(\bigcup_{k=1}^{\infty} A_k\right) \leq \sum_{k=1}^{\infty} \mathbb{P}(A_k) = 0.$$

Pero

$$\bigcup_{k=1}^{\infty} A_k = \left\{|X_{n_m} - X| \not\to 0\right\}.$$

Por lo tanto

$$\mathbb{P}\left(X_{n_m} \not\to X \text{ c.s.}\right) = 0 \quad \Rightarrow \quad \mathbb{P}(X_{n_m} \xrightarrow{\text{c.s.}} X) = 1.$$

Como esto vale para toda subsucesión $\{n_m\}$, basta tomar una subsubsucesión conveniente para concluir la implicación.

($\Leftarrow$) Supongamos que toda subsucesión tiene una subsubsucesión que converge c.s. a X. Si $X_n \xrightarrow{\mathbb{P}} X$, existen $\varepsilon > 0$ y $\delta > 0$ tales que

$$\mathbb{P}(|X_n - X| > \varepsilon) \geq \delta \quad \text{para infinitos } n.$$

Sea $\{n_m\}$ la subsucesión de esos índices

$$\mathbb{P}\Big(|X_{n_m} - X| > \varepsilon\Big) \geq \delta > 0 \quad \forall m.$$

Por hipótesis, esta subsucesión $\{X_{n_m}\}$ admite una subsubsucesión $\{X_{n_{m_k}}\}$ tal que

$$X_{n_{m_k}} \xrightarrow{\text{c.s.}} X.$$

Pero la convergencia casi segura implica convergencia en probabilidad, luego

$$\mathbb{P}\left(|X_{n_{m_k}} - X| > \varepsilon\right) \to 0,$$

lo cual contradice que $\mathbb{P}(|X_{n_m}|) - X| > \varepsilon) \geq \delta$ para todo m (y en particular para la subsubsucesión). Contradicción. Por tanto $X_n \xrightarrow{\mathbb{P}} X$.

□

Teorema 5.1.3 Criterio secuencial de convergencia. Sea $\{y_n\}_{n\in\mathbb{N}}$ una sucesión de elementos de un espacio topológico. Si toda subsucesión $\{y_{n_m}\}_{m\in\mathbb{N}}$ admite una subsucesión adicional $\{y_{n_{m_k}}\}_{k\in\mathbb{N}}$ que converge a y, entonces se tiene

$$y_n \to y. \tag{5.23}$$

La demostracion se deja al lector.

5.1.1. Ley débil de los grandes números

Teorema 5.1.4 Ley débil de los grandes números. Suponga que $X_1, X_2, X_3, ...$ son variables aleatorias i.i.d. con media μ, y sea $S_n := X_1 + X_2 + \cdots + X_n$. Entonces

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu \tag{5.24}$$

Demostración. Como $\mathbb{E}|X_1| < \infty$, sabemos que

$$n\mathbb{P}(|X_1| > n) \to 0 \quad \text{cuando } n \to \infty.$$

Tomando $\varepsilon > 0$ y definimos la truncación

$$\bar{X}_{n,k} := X_k \, \mathbf{1}_{\{|X_k|\le n\}}, \quad k = 1, \dots, n.$$

Las $\bar{X}_{n,k}$ son i.i.d., con

$$\mathbb{E}[\bar{X}_{n,k}] = \mathbb{E}\left[X_1 \mathbf{1}_{\{|X_1|\le n\}}\right] =: \mu_n, \quad \mathrm{Var}(\bar{X}_{n,k}) \le \mathbb{E}\left[X_1^2 \mathbf{1}_{\{|X_1|\le n\}}\right].$$

Sea $\bar{S}_n := \sum_{k=1}^n \bar{X}_{n,k}$. Por desigualdad de Chebyshev

$$\mathbb{P}\left(\left|\frac{\bar{S}_n}{n} - \mu_n\right| > \varepsilon\right) \le \frac{\mathrm{Var}(\bar{S}_n/n)}{\varepsilon^2} = \frac{1}{n^2\varepsilon^2}\sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] = \frac{\mathbb{E}\left[X_1^2 \mathbf{1}_{\{|X_1|\le n\}}\right]}{n\varepsilon^2}.$$

Ahora, por la convergencia existe un δ talque para todo $n \ge t_0$ se cumple que $n\mathbb{P}(|X_1| > n) < \delta$, entonces

$$\mathbb{E}\left[X_1^2 \mathbf{1}_{\{|X_1|\le n\}}\right] \le 2\int_0^n t\,\mathbb{P}(|X_1| > t)\,dt \le 2t_0^2 + 2\delta n$$

Por lo tanto

$$\frac{\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1|\le n\}}]}{n} = \frac{2t_0^2}{n} + 2\delta$$

de forma que

$$\limsup_{n\to\infty} \frac{\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1|\le n\}}]}{n} \le 2\delta \Rightarrow \frac{\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1|\le n\}}]}{n} \to 0$$

entonces

$$\frac{\bar{S}_n}{n} \xrightarrow{\mathbb{P}} \mu_n.$$

Dado que

$$\left|\frac{S_n}{n} - \frac{\bar{S}_n}{n}\right| \le \frac{1}{n}\sum_{k=1}^n |X_k| \mathbf{1}_{\{|X_k|>n\}},$$

y

$$\mathbb{P}\left(\frac{1}{n}\sum_{k=1}^{n}|X_k|\mathbf{1}_{\{|X_k|>n\}}>0\right)\leq n\,\mathbb{P}(|X_1|>n)\to 0.$$

Por tanto, $S_n/n-\tilde{S}_n/n\xrightarrow{\mathbb{P}}0$. Finalmente, como $\mathbb{E}|X_1|<\infty$ implica (por dominación o teorema de la convergencia monótona)

$$\mu_n=\mathbb{E}[X_1\mathbf{1}_{\{|X_1|\leq n\}}]\longrightarrow\mathbb{E}[X_1]=\mu,$$

entonces

$$\frac{\tilde{S}_n}{n}\xrightarrow{\mathbb{P}}\mu_n\quad\wedge\quad\frac{S_n-\tilde{S}_n}{n}\xrightarrow{\mathbb{P}}0\quad\wedge\quad\mu_n\to\mu$$

□

Teorema 5.1.5 Teorema de continuidad de la convergencia en probabilidad. Sea f una función continua y sea $X_n\xrightarrow{\mathbb{P}}X$. Entonces

$$f(X_n)\xrightarrow{\mathbb{P}}f(X). \tag{5.25}$$

Si además f es acotada, entonces

$$\mathbb{E}[f(X_n)]\longrightarrow\mathbb{E}[f(X)]. \tag{5.26}$$

Demostración. Por continuidad se tiene que $\forall_{\epsilon>0}\exists_{\delta>0}\mid|f(X_n)-f(X)|>\epsilon\Rightarrow|X_n-X|>\delta$. En cuyo caso $\{|f(X_n)-f(X)|>\epsilon\}\subset\{|X_n-X|>\delta\}$. Entonces

$$\mathbb{P}(\{|f(X_n)-f(X)|>\epsilon\})\leq\mathbb{P}(\{|X_n-X|>\delta\})$$

por lo tanto $X_n\xrightarrow{\mathbb{P}}X\Rightarrow f(X_n)\xrightarrow{\mathbb{P}}f(X)$. Por otro lado, dado que $f(X_n)\xrightarrow{\mathbb{P}}f(X)$ entonces existe $\{f(X_{n_k})\}$ talque $f(X_{n_k})\xrightarrow{c.s.}f(X)$, como f es acotada se tiene que $f(X_{n_k})\xrightarrow{L^1}f(X)$ por convergencia dominada. Por continuidad $f(X_{n_k})\xrightarrow{L^1}f(X)\Rightarrow f(X_n)\xrightarrow{L^1}f(X)$. □

Teorema 5.1.6 Ley Fuerte de los Grandes Números con cuarto momento finito. Sean $X_1,X_2,\ldots$ variables aleatorias i.i.d. con $\mathbb{E}[X_i]=\mu$ y $\mathbb{E}[X_i^4]<\infty$. Si definimos $S_n:=X_1+\cdots+X_n$, entonces

$$\frac{S_n}{n}\xrightarrow{\text{c.s.}}\mu. \tag{5.27}$$

Demostración. Tome $Y_k=X_k-\mu$ con $\mathbb{E}[Y_k]=0$. Dado que $\mathbb{E}[Y_k^4]<\infty$ por dominancia en L^p se tiene que $\mathbb{E}[Y_k^2]<\infty$, entonces

$$\mathbb{E}\left[\left(\frac{1}{n}\sum_{k=1}^{n}Y_k\right)^4\right]=\frac{\mathbb{E}[Y_1^4]}{n^3}+\frac{3(n-1)(\mathbb{E}[Y_1^2])^2}{n^3}=c$$

Por la desiguadad de Markov se tiene que

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{k=1}^{n}Y_k\right|>\varepsilon\right)\leq\frac{1}{\varepsilon^4}\mathbb{E}\left[\left(\frac{1}{n}\sum_{k=1}^{n}Y_k\right)^4\right]\leq\frac{c}{\varepsilon^4n^2}$$

Consecuentemente

$$\sum_{n=1}^{\infty}\mathbb{P}\left(\left|\frac{1}{n}\sum_{k=1}^{n}Y_k\right|>\varepsilon\right)\leq\frac{c}{\varepsilon^4}\sum_{n=1}^{\infty}\frac{1}{n^2}<\infty$$

Por Borel-Cantelli

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{k=1}^{n} Y_k\right| > \varepsilon \text{ i.o.}\right) = 0$$

en cuyo caso tomando $\varepsilon = 1/n$ se tiene que

$$\lim_{m\to\infty} \mathbb{P}\left(\sup_{n\geq m}\left|\frac{S_n}{n} - \mu\right| \geq \varepsilon\right) = \lim_{m\to\infty} \mathbb{P}\left(\bigcap_{k=1}^{\infty}\bigcup_{n=m}^{\infty}\left\{\left|\frac{S_n}{n} - \mu\right| > \varepsilon - \frac{1}{k}\right\}\right) \leq \sum_{n=m}^{\infty} \mathbb{P}\left(\left|\frac{1}{n}\sum_{k=1}^{n} Y_k\right| > \varepsilon - \frac{1}{r}\right) \leq \nu$$

donde $\nu \to 0$ por el criterio de Cauchy. □

5.1.2. Segundo lema de Borel-Cantelli

Lema 5.1.1 Segundo lema de Borel-Cantelli. Sean $\{A_n\}_{n\in\mathbb{N}}$ eventos independientes. Si

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty, \tag{5.28}$$

entonces

$$\mathbb{P}(A_n \text{ i.o.}) = 1. \tag{5.29}$$

La demostracion se deja al lector.

Teorema 5.1.7 Divergencia del promedio para medias infinitas. Sean $X_1, X_2, \ldots$ variables aleatorias i.i.d. con $\mathbb{E}[|X_i|] = \infty$. Entonces

$$\mathbb{P}(|X_n| \geq n \text{ i.o.}) = 1, \tag{5.30}$$

y por lo tanto, si $S_n := X_1 + \cdots + X_n$, se tiene

$$\mathbb{P}\left(\lim_{n\to\infty} \frac{S_n}{n} \in (-\infty, \infty)\right) = 0. \tag{5.31}$$

La demostracion se deja al lector.

Teorema 5.1.8 Convergencia casi segura de sucesiones no convergentes. Sean $\{A_n\}_{n\in\mathbb{N}}$ eventos independientes por pares tales que

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty. \tag{5.32}$$

Entonces, cuando $n \to \infty$

$$\frac{1}{\sum_{m=1}^{n} \mathbb{P}(A_m)} \sum_{m=1}^{n} \mathbf{1}_{A_m} \longrightarrow 1 \quad \text{c.s.} \tag{5.33}$$

La demostracion se deja al lector.

Teorema 5.1.9 Ley de los récords. Sea $R_n := \sum_{m=1}^{n} \mathbf{1}_{A_m}$ el número de récords en el tiempo n. Entonces, cuando $n \to \infty$

$$\frac{R_n}{\ln(n)} \longrightarrow 1 \quad \text{c.s.} \tag{5.34}$$

La demostracion se deja al lector.

Lema 5.1.2 Lema de Kochen-Stone. Suponga que $\sum_{k=1}^{\infty} \mathbb{P}(A_k) = \infty$. Si

$$\limsup_{n\to\infty} \frac{\left(\sum_{k=1}^{n} \mathbb{P}(A_k)\right)^2}{\sum_{1\le j,k\le n} \mathbb{P}(A_j \cap A_k)} = \alpha > 0, \tag{5.35}$$

entonces

$$\mathbb{P}(A_n \text{ i.o.}) \ge \alpha. \tag{5.36}$$

La demostracion se deja al lector.

Lema 5.1.3 Truncación para la Ley Fuerte de los Grandes Números. Sea $Y_k := X_k \cdot \mathbf{1}(|X_k| \le k)$ y defina $T_n := Y_1 + \cdots + Y_n$. Es suficiente demostrar que

$$\frac{T_n}{n} \xrightarrow{\text{c.s.}} \mu. \tag{5.37}$$

Lema 5.1.4 Cota de varianza tipo Kolmogórov para variables truncadas. Se cumple que

$$\sum_{k=1}^{\infty} \frac{\operatorname{Var}(Y_k)}{k^2} \le 4\,\mathbb{E}[|X_1|] < \infty. \tag{5.38}$$

La demostracion se deja al lector.

Lema 5.1.5 Desigualdad elemental para series tipo p–serie. Si $y \ge 0$, entonces

$$2y \sum_{k>y} \frac{1}{k^2} \le 4. \tag{5.39}$$

Teorema 5.1.10 Ley Fuerte de los Grandes Números para medias unilaterales infinitas. Sean $X_1, X_2, \ldots$ variables aleatorias i.i.d. tales que $\mathbb{E}[X_i^+] = \infty$ y $\mathbb{E}[X_i^-] < \infty$. Si $S_n := X_1 + \cdots + X_n$, entonces

$$\frac{S_n}{n} \xrightarrow{\text{c.s.}} \infty. \tag{5.40}$$

La demostracion se deja al lector.

Teorema 5.1.11 Ley Fuerte de los Tiempos de Espera. Suponga que $\mathbb{E}[X_1] = \mu \le \infty$. Entonces, cuando $t \to \infty$

$$\frac{N_t}{t} \xrightarrow{\text{c.s.}} \frac{1}{\mu}, \tag{5.41}$$

donde se interpreta $1/\infty := 0$.

La demostracion se deja al lector.

Teorema 5.1.12 Teorema de Glivenko-Cantelli. Sea $F_n(x)$ la función de distribución empírica

asociada a una muestra i.i.d. con función de distribución $F(x)$. Entonces, cuando $n \to \infty$,

$$\sup_{x\in\mathbb{R}} |F_n(x) - F(x)| \xrightarrow{\text{c.s.}} 0. \tag{5.42}$$

La demostracion se deja al lector.

Teorema 5.1.13 Desigualdad máxima de Kolmogorov. Sean $X_1, \dots, X_n$ variables aleatorias independientes con $\mathbb{E}[X_i] = 0$ y $\text{Var}(X_i) < \infty$ para todo i. Si definimos $S_k := X_1 + \cdots + X_k$, entonces para todo $x > 0$,

$$\mathbb{P}\left(\max_{1\le k\le n} |S_k| \ge x\right) \le \frac{\text{Var}(S_n)}{x^2}. \tag{5.43}$$

La demostracion se deja al lector.

Teorema 5.1.14 Convergencia casi segura de series independientes. Sean $X_1, X_2, \dots$ variables aleatorias independientes con $\mathbb{E}[X_n] = 0$ para todo n, y suponga que

$$\sum_{n=1}^{\infty} \text{Var}(X_n) < \infty. \tag{5.44}$$

Entonces, con probabilidad uno, la serie

$$\sum_{n=1}^{\infty} X_n(\omega) \tag{5.45}$$

converge.

La demostracion se deja al lector.

Teorema 5.1.15 Teorema de las tres series de Kolmogorov. Sean $X_1, X_2, \dots$ variables aleatorias independientes y sea $A > 0$. Defina $Y_n := X_n \cdot \mathbf{1}(|X_n| \le A)$. Entonces, la serie $\sum_{n=1}^{\infty} X_n$ converge casi seguramente si y solo si se cumplen las tres condiciones siguientes:

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > A) < \infty, \tag{5.46}$$

$$\sum_{n=1}^{\infty} \mathbb{E}[Y_n] \quad \text{converge}, \tag{5.47}$$

$$\sum_{n=1}^{\infty} \text{Var}(Y_n) < \infty. \tag{5.48}$$

La demostracion se deja al lector.

Teorema 5.1.16 Lema de Kronecker. Sea $\{a_n\}_{n\in\mathbb{N}}$ una sucesión creciente tal que $a_n \to \infty$, y sea $\{x_n\}_{n\in\mathbb{N}}$ una sucesión tal que

$$\sum_{n=1}^{\infty} \frac{x_n}{a_n} \quad \text{converge}. \tag{5.49}$$

Entonces,

$$\frac{1}{a_n} \sum_{m=1}^{n} x_m \longrightarrow 0. \tag{5.50}$$

La demostracion se deja al lector.

5.1.3. Ley fuerte de los grandes números

Teorema 5.1.17 Ley fuerte de los grandes números. Sean $X_1, X_2, X_3, ...$ variables aleatorias independientes en pares e idénticamente distribuidas con media μ. Defina $S_n := X_1 + X_2 + \cdots + X_n$. Entonces

$$\frac{S_n}{n} \xrightarrow{\text{c.s.}} \mu \tag{5.51}$$

La demostracion se deja al lector.

Teorema 5.1.18 Ley del Límite Superior. Sean $X_1, X_2, ...$ variables aleatorias i.i.d. con $\mathbb{E}[X_i] = 0$ y $\mathbb{E}[X_i^2] = \sigma^2 < \infty$. Defina $S_n := X_1 + \cdots + X_n$. Entonces, para todo $\varepsilon > 0$

$$\frac{S_n}{\sqrt{n} \cdot (\log n)^{1/2+\varepsilon}} \xrightarrow{\text{c.s.}} 0. \tag{5.52}$$

La demostracion se deja al lector.

Teorema 5.1.19 Ley Fuerte de los Grandes Números para momentos fraccionarios. Sean $X_1, X_2, ...$ variables aleatorias i.i.d. con $\mathbb{E}[X_1] = 0$ y $\mathbb{E}[|X_1|^p] < \infty$ para algún $1 < p < 2$. Si $S_n := X_1 + \cdots + X_n$, entonces

$$\frac{S_n}{n^{1/p}} \xrightarrow{\text{c.s.}} 0. \tag{5.53}$$

La demostracion se deja al lector.

Teorema 5.1.20 Teorema de Kolmogórov para sumas de variables i.i.d. con media infinita. Sean $X_1, X_2, ...$ variables aleatorias i.i.d. con $\mathbb{E}[|X_1|] = \infty$, y sea $S_n := X_1 + \cdots + X_n$. Sea $\{a_n\}_{n\in\mathbb{N}}$ una sucesión de números positivos tal que a_n/n es creciente. Entonces,

$$\limsup_{n\to\infty} \frac{|S_n|}{a_n} = \begin{cases} 0, & \text{si } \sum_{n=1}^{\infty} \mathbb{P}(|X_1| \geq a_n) < \infty, \\ \infty, & \text{si } \sum_{n=1}^{\infty} \mathbb{P}(|X_1| \geq a_n) = \infty. \end{cases} \tag{5.54}$$

La demostracion se deja al lector.

5.2. Teoria de Renovación

Teorema 5.2.1 Ley Fuerte de los Tiempos de Renovación. Sea $\{\xi_i\}_{i\in\mathbb{N}}$ una sucesión de variables aleatorias positivas con $\mathbb{P}(\xi_i > 0) = 1$ y esperanza $\mu := \mathbb{E}[\xi_i] \in (0, \infty]$. Defina $T_0 := 0$ y $T_k := T_{k-1} + \xi_k$ para $k \geq 1$, y sea $N_t := \text{ínf}\{k : T_k > t\}$. Entonces

$$\frac{N_t}{t} \xrightarrow{\text{c.s.}} \frac{1}{\mu}, \quad \text{donde } \frac{1}{\infty} := 0. \tag{5.55}$$

La demostracion se deja al lector.

Teorema 5.2.2 Ecuación de Wald. Sean $X_1, X_2, ...$ variables aleatorias con $\mathbb{E}[|X_1|] < \infty$, y sea N una variable aleatoria que representa un tiempo de parada con $\mathbb{E}[N] < \infty$. Entonces

$$\mathbb{E}[S_N] = \mathbb{E}[X_1] \cdot \mathbb{E}[N], \tag{5.56}$$

donde $S_N := X_1 + \cdots + X_N$.

La demostracion se deja al lector.

Teorema 5.2.3 Ley Fuerte de los Tiempos de Renovación es el nombre estándar. Sea $U(t) := \mathbb{E}[N_t]$, donde N_t es el número de renovaciones en $[0, t]$. Entonces

$$\frac{U(t)}{t} \longrightarrow \frac{1}{\mu} \quad \text{cuando } t \to \infty. \tag{5.57}$$

La demostracion se deja al lector.

Teorema 5.2.4 Teorema de renovación de Blackwell. Suponga que la distribución F de las variables ξ_i es no aritmética y que $\mu := \mathbb{E}[\xi_i] < \infty$. Entonces, para todo $h > 0$

$$U([t, t+h]) \longrightarrow \frac{h}{\mu} \quad \text{cuando } t \to \infty, \tag{5.58}$$

donde $U([t, t+h]) := \sum_{n=0}^{\infty} \mathbb{P}(T_n \in [t, t+h])$ es la medida de renovación en el intervalo $[t, t+h]$.

La demostracion se deja al lector.

Teorema 5.2.5 Teorema de existencia y unicidad de la ecuación de renovación. Sea h una función acotada. Entonces la función

$$H(t) = \int_0^t h(t-s)\, dU(s) \tag{5.59}$$

es la única solución de la ecuación de renovación $H = h + H * F$ que es acotada en intervalos acotados.

La demostracion se deja al lector.

Teorema 5.2.6 Teorema de renovación. Si F es no aritmética y h es directamente integrable en el sentido de Riemann, entonces

$$\lim_{t\to\infty} H(t) = \frac{1}{\mu} \int_0^{\infty} h(s)\, ds. \tag{5.60}$$

La demostracion se deja al lector.

Lema 5.2.1 Integrabilidad directa para funciones decrecientes no negativas. Si $h(x) \geq 0$ es decreciente, $h(0) < \infty$ y $\int_0^{\infty} h(x)\, dx < \infty$, entonces h es directamente integrable en el sentido de Riemann.

La demostracion se deja al lector.

5.3. Desviación grande

Lema 5.3.1 Subaditividad de Cramér para grandes desviaciones. Sea $\{X_i\}_{i\in\mathbb{N}}$ una sucesión de variables aleatorias i.i.d. con $\mu := \mathbb{E}[X_i]$, y defina $S_n := X_1 + \cdots + X_n$. Sea $a > \mu$ y defina $\pi_n := \mathbb{P}(S_n \geq na)$, así como $\gamma_n := \log \pi_n$. Si se cumple que

$$\gamma_{m+n} \geq \gamma_m + \gamma_n, \tag{5.61}$$

entonces

$$\lim_{n\to\infty} \frac{\gamma_n}{n} = \sup_{m\in\mathbb{N}} \frac{\gamma_m}{m}. \tag{5.62}$$

La demostracion se deja al lector.

Lema 5.3.2 Lema de Cramér sobre crecimiento exponencial de la función generadora de momentos. Sea $X_1, X_2, \ldots$ una sucesión de variables aleatorias i.i.d. con $\mu := \mathbb{E}[X_1]$, y sea $a > \mu$. Suponga que la función generadora de momentos $\varphi(\theta) := \mathbb{E}[e^{\theta X_1}]$ es finita para $\theta > 0$, y defina $\kappa(\theta) := \log \varphi(\theta)$. Entonces, para $\theta > 0$ suficientemente pequeño,

$$a\theta - \kappa(\theta) > 0. \tag{5.63}$$

La demostracion se deja al lector.

Teorema 5.3.1 Teorema de grandes desviaciones de Cramér. Suponga que se cumplen las condiciones

$$\varphi(\theta) := \mathbb{E}(e^{\theta X_1}) < \infty \quad \text{para algún } \theta > 0, \tag{H1}$$

$$\text{existe } \theta_a \in (0, \theta_+) \text{ tal que } a = \frac{\varphi'(\theta_a)}{\varphi(\theta_a)}, \tag{H2}$$

donde $\varphi(\theta)$ es la función generadora de momentos de las variables aleatorias i.i.d. $X_1, X_2, \ldots$ y $S_n := X_1 + \cdots + X_n$. Entonces, cuando $n \to \infty$,

$$\frac{1}{n} \log \mathbb{P}(S_n \geq na) \longrightarrow -a\theta_a + \log \varphi(\theta_a). \tag{5.64}$$

La demostracion se deja al lector.

Lema 5.3.3 Lema de cambio de medida exponencial. Sea $X_1, X_2, \ldots, X_n$ una sucesión de variables aleatorias i.i.d. con función generadora de momentos $\varphi(\lambda) := \mathbb{E}[e^{\lambda X_1}]$. Sea F_n la distribución de la suma $S_n := X_1 + \cdots + X_n$. Entonces, la derivada de F_n respecto a la medida exponencial de parámetro $\lambda > 0$ está dada por:

$$\frac{dF_n}{dF_n^\lambda}(x) = e^{-\lambda x}\varphi(\lambda)^n, \tag{5.65}$$

donde F_n^λ denota la medida de probabilidad sesgada por $e^{\lambda S_n}$.

La demostracion se deja al lector.

Teorema 5.3.2 Teorema de límite de la razón de momentos. Suponga que $x_0 := \sup\{x : F(x) < 1\} < \infty$ y que F no es una masa puntual en x_0. Si $\varphi(\theta) := \mathbb{E}[e^{\theta X_1}] < \infty$ para todo $\theta > 0$,

entonces

$$\frac{\varphi'(\theta)}{\varphi(\theta)} \longrightarrow x_0 \quad \text{cuando } \theta \uparrow \infty. \tag{5.66}$$

La demostracion se deja al lector.

Teorema 5.3.3 Teorema de cola pesada límite lineal. Suponga que $x_0 = \infty$, que $\theta_+ < \infty$, y que $\frac{\varphi'(\theta)}{\varphi(\theta)}$ es creciente y converge a un límite finito a_0 cuando $\theta \uparrow \theta_+$. Si $a_0 \leq a < \infty$, entonces

$$\frac{1}{n} \log \mathbb{P}(S_n \geq na) \longrightarrow -a\theta_+ + \log \varphi(\theta_+), \tag{5.67}$$

es decir, $\gamma(a)$ es lineal para $a \geq a_0$.

La demostracion se deja al lector.

6

Teorema del limite central

Teorema 6.0.1 Teorema de De Moivre-Laplace. Sea $X_1, X_2, \ldots$ una sucesión de variables aleatorias i.i.d. con $\mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = -1) = \frac{1}{2}$, y defina $S_n := X_1 + \cdots + X_n$. Entonces, para enteros n y k

$$\mathbb{P}(S_{2n} = 2k) = \binom{2n}{n+k} \cdot 2^{-2n}, \tag{6.1}$$

ya que $S_{2n} = 2k$ si y solo si hay $n + k$ resultados de $+1$ y $n - k$ resultados de -1 entre los primeros $2n$ lanzamientos.

La demostracion se deja al lector.

Lema 6.0.1 Lema de límite exponencial. Sea $\{c_j\}_{j\in\mathbb{N}}$ una sucesión tal que $c_j \to 0$, y sea $\{a_j\}_{j\in\mathbb{N}}$ una sucesión tal que $a_j \to \infty$ y $a_j c_j \to \lambda$. Entonces

$$(1 + c_j)^{a_j} \longrightarrow e^{\lambda}. \tag{6.2}$$

La demostracion se deja al lector.

Teorema 6.0.2 Teorema de aproximación de De Moivre–Laplace. Sea $X_1, X_2, \ldots$ una sucesión de variables aleatorias i.i.d. con $\mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = -1) = \frac{1}{2}$, y defina $S_n := X_1 + \cdots + X_n$. Si

$x \in \mathbb{R}$ y $k = k(n)$ es tal que

$$\frac{2k}{\sqrt{2n}} \longrightarrow x \quad \text{cuando } n \to \infty, \tag{6.3}$$

entonces

$$\mathbb{P}(S_{2n} = 2k) \sim \frac{1}{\sqrt{\pi n}}\, e^{-x^2/2}. \tag{6.4}$$

La demostracion se deja al lector.

Teorema 6.0.3 El otro Teorema de De Moivre-Laplace. Sea $X_1, X_2, \ldots$ una sucesión de variables aleatorias i.i.d. con $\mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = -1) = \frac{1}{2}$, y defina $S_m := X_1 + \cdots + X_m$. Si $a < b$, entonces cuando $m \to \infty$,

$$\mathbb{P}\left(a \le \frac{S_m}{\sqrt{m}} \le b\right) \longrightarrow \int_a^b \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\, dx. \tag{6.5}$$

La demostracion se deja al lector.

6.1. Convergencia débil

Teorema 6.1.1 Teorema de convergencia de medidas por convergencia puntual de densidades. Suponga que $\{f_n\}_{n\in\mathbb{N}}$ son densidades de probabilidad tales que $f_n \to f_\infty$ puntualmente cuando $n \to \infty$. Entonces, para todo conjunto de Borel B

$$\left| \int_B f_n(x)\, dx - \int_B f_\infty(x)\, dx \right| \le \int_B |f_n(x) - f_\infty(x)|\, dx, \tag{6.6}$$

y si además

$$\int_{\mathbb{R}} (f_\infty(x) - f_n(x))^+\, dx \longrightarrow 0, \tag{6.7}$$

entonces $\int_B f_n(x)\, dx \to \int_B f_\infty(x)\, dx$.

La demostracion se deja al lector.

Lema 6.1.1 Lemma sobre la densidad de V_{n+1}. La variable aleatoria V_{n+1} tiene función de densidad dada por

$$f_{V_{n+1}}(x) = (2n+1)\binom{2n}{n} x^n (1-x)^n. \tag{6.8}$$

La demostracion se deja al lector.

Teorema 6.1.2 Teorema de Skorokhod. Si $F_n \Rightarrow F_\infty$, entonces existen variables aleatorias Y_n, $1 \le n \le \infty$, con distribución F_n, tales que $Y_n \to Y_\infty$ casi seguramente.

La demostracion se deja al lector.

Teorema 6.1.3 Teorema de la convergencia débil. Se tiene $X_n \Rightarrow X_\infty$ si y solo si para toda función continua acotada g

$$\mathbb{E}[g(X_n)] \longrightarrow \mathbb{E}[g(X_\infty)]. \tag{6.9}$$

La demostracion se deja al lector.

Teorema 6.1.4 Teorema del mapeo continuo. Sea g una función medible y sea $D_g := \{x : g \text{ es discontinua en } x\}$. Si $X_n \Rightarrow X_\infty$ y $\mathbb{P}(X_\infty \in D_g) = 0$, entonces $g(X_n) \Rightarrow g(X_\infty)$. Si además g es acotada, entonces

$$\mathbb{E}[g(X_n)] \longrightarrow \mathbb{E}[g(X_\infty)]. \tag{6.10}$$

La demostracion se deja al lector.

Teorema 6.1.5 Teorema de Portmanteau. Las siguientes afirmaciones son equivalentes

$$X_n \Rightarrow X_\infty, \tag{6.11}$$

$$\text{Para todo conjunto abierto } G, \quad \liminf_{n\to\infty} \mathbb{P}(X_n \in G) \geq \mathbb{P}(X_\infty \in G), \tag{6.12}$$

$$\text{Para todo conjunto cerrado } K, \quad \limsup_{n\to\infty} \mathbb{P}(X_n \in K) \leq \mathbb{P}(X_\infty \in K), \tag{6.13}$$

Para todo conjunto de Borel A tal que $\mathbb{P}(X_\infty \in \partial A) = 0$, se tiene

$$\mathbb{P}(X_n \in A) \to \mathbb{P}(X_\infty \in A). \tag{6.14}$$

La demostracion se deja al lector.

Teorema 6.1.6 Teorema de selección de Helly. Para toda sucesión $\{F_n\}$ de funciones de distribución, existe una subsucesión $\{F_{n(k)}\}$ y una función F no decreciente y continua por la derecha tal que

$$\lim_{k\to\infty} F_{n(k)}(y) = F(y) \tag{6.15}$$

en todos los puntos de continuidad de F.

La demostracion se deja al lector.

Teorema 6.1.7 Teorema de Tightness para sucesiones de distribuciones. Toda subsucesión límite es función de distribución de una medida de probabilidad si y solo si la sucesión $\{F_n\}$ es ajustada, es decir, para todo $\varepsilon > 0$ existe $M_\varepsilon > 0$ tal que

$$\limsup_{n\to\infty} [1 - F_n(M_\varepsilon) + F_n(-M_\varepsilon)] \leq \varepsilon. \tag{6.16}$$

La demostracion se deja al lector.

Teorema 6.1.8 Criterio de Prokhorov para tightness. Si existe una función $\varphi \geq 0$ tal que $\varphi(x) \to \infty$ cuando $|x| \to \infty$, y

$$\sup_n \int \varphi(x)\, dF_n(x) < \infty, \tag{6.17}$$

entonces la sucesión $\{F_n\}$ es ajustada.

La demostracion se deja al lector.

Teorema 6.1.9 Teorema de subsecuencias límites para convergencia en distribución. Si toda subsucesión de $\{X_n\}$ tiene una subsucesión adicional que converge en distribución a X, entonces $X_n \Rightarrow X$.

La demostracion se deja al lector.

Teorema 6.1.10 Teorema de continuidad. Sean μ_n, $1 \leq n \leq \infty$, medidas de probabilidad con funciones características φ_n. Entonces

$$\text{Si } \mu_n \Rightarrow \mu_\infty, \text{ entonces } \varphi_n(t) \to \varphi_\infty(t) \quad \text{para todo } t \in \mathbb{R}. \tag{6.18}$$

Si $\{\varphi_n(t)\}_{n\in\mathbb{N}}$ converge puntualmente a una función $\varphi(t)$ que es continua en $t = 0$, entonces $\{\mu_n\}$ es ajustada y

$$\mu_n \Rightarrow \mu, \tag{6.19}$$

donde μ es la única medida de probabilidad con función característica φ.

La demostracion se deja al lector.

Lema 6.1.2 Aproximación de la exponencial compleja mediante su serie de Taylor. Para todo $n \in \mathbb{N}$, se cumple

$$\left| e^{ix} - \sum_{m=0}^{n} \frac{(ix)^m}{m!} \right| \leq \min\left\{ \frac{|x|^{n+1}}{(n+1)!}, \frac{2|x|^n}{n!} \right\}. \tag{6.20}$$

La demostracion se deja al lector.

Teorema 6.1.11 Diferenciabilidad de la función característica. Si $\int |x|^n \, \mu(dx) < \infty$, entonces la función característica $\varphi(t)$ de μ tiene derivada continua de orden n dada por

$$\varphi^{(n)}(t) = \int (ix)^n e^{itx} \, \mu(dx). \tag{6.21}$$

La demostracion se deja al lector.

Teorema 6.1.12 Desarrollo de Taylor de la función característica. Si $\mathbb{E}(|X|^2) < \infty$, entonces la función característica $\varphi(t)$ de X satisface

$$\varphi(t) = 1 + it\,\mathbb{E}(X) - \frac{t^2}{2}\mathbb{E}(X^2) + o(t^2). \tag{6.22}$$

La demostracion se deja al lector.

Teorema 6.1.13 Condición de concavidad limitada para la función característica. Si

$$\limsup_{h\downarrow 0} \frac{\varphi(h) - 2\varphi(0) + \varphi(-h)}{h^2} > -\infty, \tag{6.23}$$

entonces $\mathbb{E}(|X|^2) < \infty$.

La demostracion se deja al lector.

Teorema 6.1.14 Criterio de Pólya. Sea $\varphi(t)$ una función real, no negativa, tal que $\varphi(0) = 1$, $\varphi(t) = \varphi(-t)$, y φ es decreciente y convexa en $(0, \infty)$, con

$$\lim_{t \downarrow 0} \varphi(t) = 1, \quad \lim_{t \uparrow \infty} \varphi(t) = 0. \tag{6.24}$$

Entonces existe una medida de probabilidad ν sobre $(0, \infty)$ tal que

$$\varphi(t) = \int_0^\infty \left(1 - \frac{t}{s}\right)^+ \nu(ds), \tag{6.25}$$

y por lo tanto φ es una función característica.

La demostracion se deja al lector.

Teorema 6.1.15 Unicidad en el problema de momentos. Si

$$\limsup_{k \to \infty} \frac{\mu_{2k}^{1/2k}}{2k} = r < \infty, \tag{6.26}$$

entonces existe a lo sumo una función de distribución F tal que $\mu_k = \int x^k \, dF(x)$ para todo $k \in \mathbb{N}$.

La demostracion se deja al lector.

Teorema 6.1.16 Teorema de continuidad de momentos. Suponga que $\int x^k \, dF_n(x) \to \mu_k$ para cada $k \in \mathbb{N}$, y que

$$\limsup_{k \to \infty} \frac{\mu_{2k}^{1/2k}}{2k} < \infty. \tag{6.27}$$

Entonces F_n converge débilmente a la única distribución con momentos $\{\mu_k\}$.

La demostracion se deja al lector.

Teorema 6.1.17 Teorema de Lindeberg-Lévy. Sean $X_1, X_2, \ldots$ variables aleatorias i.i.d. con $\mathbb{E}(X_i) = \mu$ y $\mathrm{Var}(X_i) = \sigma^2 \in (0, \infty)$. Si $S_n := X_1 + \cdots + X_n$, entonces

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \Rightarrow \chi, \tag{6.28}$$

donde χ tiene distribución normal estándar.

La demostracion se deja al lector.

Teorema 6.1.18 Teorema de límite exponencial. Si $c_n \to c \in \mathbb{C}$, entonces

$$\left(1 + \frac{c_n}{n}\right)^n \longrightarrow e^c. \tag{6.29}$$

La demostracion se deja al lector.

Lema 6.1.3 Diferencias de productos. Sean $z_1, \ldots, z_n$ y $w_1, \ldots, w_n$ números complejos de módulo

menor o igual que θ. Entonces

$$\left|\prod_{m=1}^{n} z_m - \prod_{m=1}^{n} w_m\right| \leq \theta^{n-1} \sum_{m=1}^{n} |z_m - w_m|. \tag{6.30}$$

La demostracion se deja al lector.

Lema 6.1.4 Aproximación exponencial. Si b es un número complejo con $|b| \leq 1$, entonces

$$|e^b - (1+b)| \leq |b|^2. \tag{6.31}$$

La demostracion se deja al lector.

Teorema 6.1.19 Teorema de Lindeberg-Feller. Para cada n, sean $X_{n,1}, \ldots, X_{n,n}$ variables aleatorias independientes con $\mathbb{E}(X_{n,m}) = 0$. Suponga que:

$$\sum_{m=1}^{n} \mathbb{E}(X_{n,m}^2) \longrightarrow \sigma^2 > 0, \tag{6.32}$$

y que para todo $\varepsilon > 0$,

$$\sum_{m=1}^{n} \mathbb{E}(X_{n,m}^2 \,;\, |X_{n,m}| > \varepsilon) \longrightarrow 0. \tag{6.33}$$

Entonces, si $S_n := X_{n,1} + \cdots + X_{n,n}$, se tiene

$$\frac{S_n}{\sigma} \Rightarrow \chi. \tag{6.34}$$

La demostracion se deja al lector.

Teorema 6.1.20 Teorema de Gnedenko-Kolmogorov. Sean $X_1, X_2, \ldots$ variables aleatorias i.i.d. y $S_n := X_1 + \cdots + X_n$. Existen constantes a_n y $b_n > 0$ tales que

$$\frac{S_n - a_n}{b_n} \Rightarrow \chi \tag{6.35}$$

si y solo si

$$\frac{y^2\, \mathbb{P}(|X_1| > y)}{\mathbb{E}(X_1^2 \,;\, |X_1| \leq y)} \longrightarrow 0. \tag{6.36}$$

La demostracion se deja al lector.

Lema 6.1.5 Lemma de selección diagona. Sea $h_n(\varepsilon)$ una función tal que $h_n(\varepsilon) \to 0$ para cada $\varepsilon > 0$. Entonces existe una sucesión $\varepsilon_n \to 0$ tal que $h_n(\varepsilon_n) \to 0$.

La demostracion se deja al lector.

Teorema 6.1.21 Teorema central de Erdős-Kac. Cuando $n \to \infty$,

$$\mathbb{P}\left(\frac{g(m) - \log\log n}{\sqrt{\log\log n}} \leq x\right) \longrightarrow \mathbb{P}(\chi \leq x), \tag{6.37}$$

donde $g(m)$ denota el número de factores primos distintos de m.

La demostracion se deja al lector.

Teorema 6.1.22 Teorema de Berry-Esseen. Sean $X_1, X_2, \ldots$ variables aleatorias i.i.d. con $\mathbb{E}(X_i) = 0$, $\mathbb{E}(X_i^2) = \sigma^2$, y $\mathbb{E}(|X_i|^3) = \rho < \infty$. Si $F_n(x)$ es la función de distribución de $(X_1 + \cdots + X_n)/(\sigma\sqrt{n})$ y $N(x)$ es la distribución normal estándar, entonces

$$|F_n(x) - N(x)| \leq \frac{3\rho}{\sigma^3\sqrt{n}}. \tag{6.38}$$

La demostracion se deja al lector.

Lema 6.1.6 Lema de Esseen. Sean F y G funciones de distribución con $G'(x) \leq \lambda < \infty$. Sea $\Delta(x) := F(x) - G(x)$, $\eta := \sup|\Delta(x)|$, $\Delta_L := \Delta * H_L$, y $\eta_L := \sup|\Delta_L(x)|$. Entonces

$$\eta_L \geq \frac{\eta}{2} - \frac{12\lambda}{\pi L}, \quad \text{o bien} \quad \eta \leq 2\eta_L + \frac{24\lambda}{\pi L}. \tag{6.39}$$

La demostracion se deja al lector.

Lema 6.1.7 Lema de Fourier de Lévy. Sean K_1 y K_2 funciones de distribución con media cero, cuyas funciones características κ_i son integrables. Entonces

$$K_1(x) - K_2(x) = \frac{1}{2\pi}\int \frac{e^{-itx}(\kappa_1(t) - \kappa_2(t))}{it}\, dt. \tag{6.40}$$

La demostracion se deja al lector.

6.2. Teorema de limite local

Teorema 6.2.1 Teorema central del límite. Sean $X_1, X_2, X_3, \ldots$ variables aleatorias i.i.d. con media μ y varianza σ^2. Defina $S_n := X_1 + X_2 + \cdots + X_n$. Entonces

$$\frac{S_n - n\mu}{\sqrt{n}\sigma} \xrightarrow{d} Z \tag{6.41}$$

donde Z es una variable aleatoria normal estándar.

La demostracion se deja al lector.

Teorema 6.2.2 Teorema de Lévy sobre la estructura de la función característica. Sea $\varphi(t) := \mathbb{E}(e^{itX})$ la función característica de una variable aleatoria X. Entonces, solo hay tres posibilidades

$$|\varphi(t)| < 1 \quad \text{para todo } t \neq 0,$$

Existe $\lambda > 0$ tal que $|\varphi(\lambda)| = 1$ y $|\varphi(t)| < 1$ para todo $0 < t < \lambda$; en este caso X es reticular con paso máximo $2\pi/\lambda$.

$|\varphi(t)| = 1$ para todo $t \in \mathbb{R}$. En este caso, $X = b$ casi seguramente para algún $b \in \mathbb{R}$.

La demostracion se deja al lector.

Teorema 6.2.3 Teorema Local del Límite Central. Bajo las hipótesis anteriores, cuando $n \to \infty$,

$$\sup_{x \in L_n} \sqrt{n}\, |p_n(x) - \mathfrak{n}(x)| \longrightarrow 0, \tag{6.42}$$

donde L_n es el soporte de la distribución de S_n, $p_n(x)$ es la función de masa de probabilidad de S_n, y $\mathfrak{n}(x)$ es la densidad de la normal estándar.

Teorema 6.2.4 Teorema Puntual del Límite Central. Bajo las hipótesis anteriores, si $x_n/\sqrt{n} \to x$, entonces

$$\sqrt{n}\, p_n(x_n) \longrightarrow \mathfrak{n}(x), \tag{6.43}$$

donde $\mathfrak{n}(x)$ es la densidad de la normal estándar evaluada en x.

La demostracion se deja al lector.

6.3. Convergencia de Poisson

Teorema 6.3.1 Teorema de Poisson límite. Para cada n, sean $X_{n,1}, \dots, X_{n,n}$ variables aleatorias independientes con $\mathbb{P}(X_{n,m} = 1) = p_{n,m}$ y $\mathbb{P}(X_{n,m} = 0) = 1 - p_{n,m}$. Suponga que

$$\sum_{m=1}^{n} p_{n,m} \longrightarrow \lambda \in (0, \infty), \qquad \max_{1 \le m \le n} p_{n,m} \longrightarrow 0. \tag{6.44}$$

Si $S_n := X_{n,1} + \cdots + X_{n,n}$, entonces

$$S_n \Rightarrow Z, \tag{6.45}$$

donde Z tiene distribución de Poisson con media λ.

La demostracion se deja al lector.

Lema 6.3.1 Lema de convergencia en variación. La distancia $d(\mu, \nu) := \|\mu - \nu\|$ define una métrica sobre las medidas de probabilidad en $\mathbb{Z}$. Se tiene $\|\mu_n - \mu\| \to 0$ si y solo si $\mu_n(x) \to \mu(x)$ para todo $x \in \mathbb{Z}$, lo cual es equivalente a $\mu_n \Rightarrow \mu$.

La demostracion se deja al lector.

Lema 6.3.2 Lema de subaditividad de la norma de variación total para medidas producto. Si $\mu_1 \times \mu_2$ denota la medida producto sobre $\mathbb{Z} \times \mathbb{Z}$ definida por $(\mu_1 \times \mu_2)(x, y) = \mu_1(x)\mu_2(y)$, entonces

$$\|\mu_1 \times \mu_2 - \nu_1 \times \nu_2\| \le \|\mu_1 - \nu_1\| + \|\mu_2 - \nu_2\|. \tag{6.46}$$

La demostracion se deja al lector.

Lema 6.3.3 Lema de contracción de la convolución en variación total. Si $\mu_1 * \mu_2$ denota la convolución de μ_1 y μ_2, definida por

$$(\mu_1 * \mu_2)(x) := \sum_{y \in \mathbb{Z}} \mu_1(x - y)\mu_2(y), \tag{6.47}$$

entonces

$$\|\mu_1 * \mu_2 - \nu_1 * \nu_2\| \leq \|\mu_1 \times \mu_2 - \nu_1 \times \nu_2\|. \tag{6.48}$$

La demostracion se deja al lector.

Lema 6.3.4 Lema de Poisson-Binomial para una sola variable. Sea μ la medida con $\mu(1) = p$ y $\mu(0) = 1 - p$, y sea ν la distribución de Poisson con media p. Entonces

$$\|\mu - \nu\| \leq p^2. \tag{6.49}$$

La demostracion se deja al lector.

Teorema 6.3.2 Teorema de Poisson en el problema de las cajas y bolas. Si $ne^{-r/n} \to \lambda \in [0, \infty)$, entonces el número de cajas vacías converge en distribución a una variable de Poisson con media λ.

La demostracion se deja al lector.

Teorema 6.3.3 Teorema de Poisson extendido. Sean $X_{n,1}, \ldots, X_{n,n}$ variables aleatorias independientes con valores enteros no negativos, tales que:

$$\mathbb{P}(X_{n,m} = 1) = p_{n,m}, \quad \mathbb{P}(X_{n,m} \geq 2) = \varepsilon_{n,m}, \tag{6.50}$$

y suponga que

$$\sum_{m=1}^{n} p_{n,m} \longrightarrow \lambda \in (0, \infty), \quad \max_{1 \leq m \leq n} p_{n,m} \longrightarrow 0, \quad \sum_{m=1}^{n} \varepsilon_{n,m} \longrightarrow 0. \tag{6.51}$$

Entonces, si $S_n := X_{n,1} + \cdots + X_{n,n}$, se tiene

$$S_n \Rightarrow Z, \tag{6.52}$$

donde Z tiene distribución de Poisson con media λ.

La demostracion se deja al lector.

Teorema 6.3.4 Teorema de Poisson para procesos de cuenta. Si la primera y ultima condición se cumplen, entonces $N(0, t)$ tiene distribución de Poisson con media λt.

La demostracion se deja al lector.

6.4. Ley estable

Lema 6.4.1 Lema de la diagonal de Cantor. Si $h_n(\varepsilon) \to g(\varepsilon)$ para cada $\varepsilon > 0$ y $g(\varepsilon) \to g(0)$ cuando $\varepsilon \to 0$, entonces existe una sucesión $\varepsilon_n \to 0$ tal que

$$h_n(\varepsilon_n) \longrightarrow g(0). \tag{6.53}$$

La demostracion se deja al lector.

Teorema 6.4.1 Teorema de Gnedenko-Kolmogorov sobre la convergencia a distribuciones estables. Sean $X_1, X_2, ...$ variables aleatorias i.i.d. con una distribución que satisface:

$$\lim_{x\to\infty} \frac{\mathbb{P}(X_1 > x)}{\mathbb{P}(|X_1| > x)} = \theta \in [0,1], \tag{6.54}$$

y

$$\mathbb{P}(|X_1| > x) = x^{-\alpha} L(x), \tag{6.55}$$

donde $\alpha < 2$ y $L(x)$ es lentamente variable. Sea $S_n := X_1 + \cdots + X_n$, defina

$$a_n := \text{ínf}\{x : \mathbb{P}(|X_1| > x) \leq n^{-1}\}, \quad b_n := n \cdot \mathbb{E}(X_1 \cdot \mathbf{1}(|X_1| \leq a_n)). \tag{6.56}$$

Entonces,

$$\frac{S_n - b_n}{a_n} \Rightarrow Y, \tag{6.57}$$

donde Y tiene una distribución no degenerada.

La demostracion se deja al lector.

Lema 6.4.2 Lema de Potter. Para todo $\delta > 0$, existe una constante $C > 0$ tal que para todo $t \geq t_0$ y $y \leq 1$,

$$\frac{\mathbb{P}(|X_1| > yt)}{\mathbb{P}(|X_1| > t)} \leq C y^{-\alpha-\delta}. \tag{6.58}$$

La demostracion se deja al lector.

Teorema 6.4.2 Teorema de Gnedenko. Una variable aleatoria Y es el límite de

$$\frac{X_1 + \cdots + X_k - b_k}{a_k} \tag{6.59}$$

para alguna sucesión i.i.d. $\{X_i\}$ si y solo si Y tiene una ley estable.

La demostracion se deja al lector.

Teorema 6.4.3 Teorema de convergencia de tipos. Suponga que $W_n \Rightarrow W$ y que existen constantes $\alpha_n > 0$, $\beta_n \in \mathbb{R}$ tales que

$$W_n' := \alpha_n W_n + \beta_n \Rightarrow W', \tag{6.60}$$

donde W y W' son distribuciones no degeneradas. Entonces existen constantes α y β tales que

$$\alpha_n \to \alpha, \quad \beta_n \to \beta. \tag{6.61}$$

La demostracion se deja al lector.

6.5. Distribuciones infinitamente divisibles

Teorema 6.5.1 Teorema de Lévy sobre la divisibilidad infinita. Una variable aleatoria Z es el límite de sumas del tipo

$$Z_n := X_1^{(n)} + \cdots + X_n^{(n)}, \tag{6.62}$$

donde los $X_i^{(n)}$ son independientes y apropiadamente normalizados, si y solo si Z tiene una distribución infinitamente divisible.

La demostracion se deja al lector.

Teorema 6.5.2 Teorema de Lévy-Khinchin. Una variable aleatoria Z tiene una distribución infinitamente divisible si y solo si su función característica $\varphi(t) := \mathbb{E}(e^{itZ})$ satisface

$$\log \varphi(t) = ict - \frac{\sigma^2 t^2}{2} + \int_{\mathbb{R}} \left(e^{itx} - 1 - itx \cdot \mathbf{1}_{\{|x|\leq 1\}} \right) \mu(dx), \tag{6.63}$$

donde $c \in \mathbb{R}$, $\sigma^2 \geq 0$, y μ es una medida de Lévy tal que $\mu(\{0\}) = 0$ y

$$\int_{\mathbb{R}} \frac{x^2}{1+x^2} \, \mu(dx) < \infty. \tag{6.64}$$

La demostracion se deja al lector.

Teorema 6.5.3 Teorema de Kolmogórov. Una variable aleatoria Z tiene una distribución infinitamente divisible con media cero y varianza finita si y solo si su función característica $\varphi(t)$ satisface

$$\log \varphi(t) = \int_{\mathbb{R}} \left(e^{itx} - 1 - itx \right) x^{-2} \, \nu(dx), \tag{6.65}$$

donde ν es la medida canónica asociada a Z, y se cumple

$$\mathrm{Var}(Z) = \nu(\mathbb{R}). \tag{6.66}$$

La demostracion se deja al lector.

6.6. Teorema limite en $\mathbb{R}$

Teorema 6.6.1 Teorema limite en $\mathbb{R}$. Las siguientes afirmaciones son equivalentes

$\mathbb{E}(f(X_n)) \to \mathbb{E}(f(X_\infty))$ para toda función continua y acotada f.

$\mathbb{E}(f(X_n)) \to \mathbb{E}(f(X_\infty))$ para toda función acotada y Lipschitz-continua f.

Para todo conjunto cerrado K, $\limsup_{n\to\infty} \mathbb{P}(X_n \in K) \leq \mathbb{P}(X_\infty \in K)$.

Para todo conjunto abierto G, $\liminf_{n\to\infty} \mathbb{P}(X_n \in G) \geq \mathbb{P}(X_\infty \in G)$.

Para todo conjunto de Borel A tal que $\mathbb{P}(X_\infty \in \partial A) = 0$, $\mathbb{P}(X_n \in A) \to \mathbb{P}(X_\infty \in A)$.

Para toda función acotada f cuyo conjunto de discontinuidades D_f verifica $\mathbb{P}(X_\infty \in D_f) = 0$, $\mathbb{E}(f(X_n)) \to \mathbb{E}(f(X_\infty))$.

La demostracion se deja al lector.

Teorema 6.6.2 Teorema de Prokhorov en dimensión d. En $\mathbb{R}^d$, la convergencia débil definida en términos de convergencia de funciones de distribución $F_n \Rightarrow F$ es equivalente a la noción de convergencia débil definida para espacios métricos generales.

La demostracion se deja al lector.

Teorema 6.6.3 Teorema de Prokhorov. Si la sucesión de medidas μ_n es ajustada, entonces existe una subsucesión que converge débilmente.

La demostracion se deja al lector.

Teorema 6.6.4 Fórmula de inversión. Sea $A = [a_1, b_1] \times \cdots \times [a_d, b_d]$ tal que $\mu(\partial A) = 0$. Entonces,

$$\mu(A) = \lim_{T\to\infty} \frac{1}{(2\pi)^d} \int_{[-T,T]^d} \prod_{j=1}^{d} \psi_j(s_j)\, \varphi(s)\, ds, \tag{6.67}$$

donde $\psi_j(s) := \frac{e^{-isa_j} - e^{-isb_j}}{is}$ y $\varphi(s)$ es la función característica de μ.

La demostracion se deja al lector.

Teorema 6.6.5 Teorema de continuidad de las funciones características. Sean X_n, $1 \leq n \leq \infty$, vectores aleatorios con funciones características φ_n. Una condición necesaria y suficiente para que $X_n \Rightarrow X_\infty$ es que

$$\varphi_n(t) \longrightarrow \varphi_\infty(t) \quad \text{para todo } t \in \mathbb{R}^d. \tag{6.68}$$

La demostracion se deja al lector.

Teorema 6.6.6 Dispositivo de Cramér-Wold. Una condición suficiente para que $X_n \Rightarrow X_\infty$ en $\mathbb{R}^d$ es que

$$\theta \cdot X_n \Rightarrow \theta \cdot X_\infty \quad \text{para todo } \theta \in \mathbb{R}^d. \tag{6.69}$$

La demostracion se deja al lector.

Teorema 6.6.7 Teorema central del límite en $\mathbb{R}^d$. Sean $X_1, X_2, ...$ vectores aleatorios i.i.d. con $\mathbb{E}(X_n) = \mu$ y covarianzas finitas

$$\Gamma_{ij} := \mathbb{E}\left[(X_{n,i} - \mu_i)(X_{n,j} - \mu_j)\right]. \tag{6.70}$$

Si $S_n := X_1 + \cdots + X_n$, entonces

$$\frac{S_n - n\mu}{\sqrt{n}} \Rightarrow \chi, \tag{6.71}$$

donde χ tiene distribución normal multivariada con media cero y matriz de covarianza Γ, es decir,

$$\mathbb{E}\left[e^{i\theta\cdot\chi}\right] = \exp\left(-\frac{1}{2}\sum_{i,j}\theta_i\theta_j\Gamma_{ij}\right). \tag{6.72}$$

La demostracion se deja al lector.
Esta sin terminar.

Parte II

7

Cadenas de Markov

7.1. Procesos Estocásticos y Caminatas Aleatorias

Definición 7.1.1 Proceso estocástico. Un proceso estocástico es una familia de variables aleatorias $\{X_t : t \in T\}$ con $T \neq \varnothing$. Las distribuciones de probabilidad finito-dimensionales del proceso se definen como

$$\mathbb{P}(X_{t_1} = s_1, X_{t_2} = s_2, \dots, X_{t_n} = s_n) \tag{7.1}$$

para $n \in \mathbb{N}_{>0}$, $s_i \in S$ y $t_i < t_{i+1}$.

Cuando $T \subset \mathbb{N}$ se llama de proceso de tiempo discreto y cuando $T \subset \mathbb{R}^+$ se llama de proceso de tiempo continuo.

Definición 7.1.2 Trayectoria. Se llama trayectoria del proceso estocástico al mapeo $t \mapsto X_t(\omega)$.

Definición 7.1.3 Proceso estocástico en $\mathbb{R}^d$. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Un proceso estocástico en $\mathbb{R}^d$ es una familia de variables aleatorias $\{X_t : t \in T\}$ con $X_t = (X_t^1, X_t^2, \dots, X_t^d)$, tales que cada coordenada X_t^i es medible de $\mathcal{F}$ en los borelianos $\mathcal{B}(\mathbb{R})$, para $i = 1, \dots, d$.

En este caso, cada proceso coordenada $\{X_t^i : t \in T\}$ es un proceso estocástico en $\mathbb{R}$. Cuando el conjunto de índices T se toma como un subconjunto de $\mathbb{R}^d$, con $d \geq 1$, la familia de variables aleatorias $\{X_t : t \in T\}$ recibe el nombre de campo aleatorio (random field).

Definición 7.1.4 Caminata aleatoria simple. Un proceso estocástico $\{S_n : n \in \mathbb{N}\}$ con

$$S_n = X_1 + \cdots + X_n \tag{7.2}$$

donde X_i son pasos independientes, es llamado caminata aleatoria simple.

Definición 7.1.5 Caminata aleatoria generalizada. Sean $X_1, X_2, ...$ variables aleatorias i.i.d. , tales que $\mathbb{P}(X_i = k) = a_k \in [0,1], \forall k \in \mathbb{Z}$ con $\sum_{k\in\mathbb{Z}} a_k = 1$. Sea S_0 una variable aleatoria con valores en $\mathbb{Z}$, independiente de X_i. Se define

$$S_n = S_0 + X_1 + \cdots + X_n, \quad \forall n \in \mathbb{N}, \tag{7.3}$$

el proceso $\{S_n : n \in \mathbb{N}\}$ se denomina caminata aleatoria generalizada con valores en $\mathbb{Z}$.

Proposición 7.1.1 Propiedad de Markov. Sea $\{S_n : n \in \mathbb{N}\}$ una caminata aleatoria generalizada en $\mathbb{Z}$ talque $S_i = k_i, \forall k_i \in \mathbb{Z}$. Entonces

$$\mathbb{P}(S_n = k_n \mid S_0 = k_0, S_1 = k_1, \dots, S_{n-1} = k_{n-1}) = \mathbb{P}(X_n = k_n - k_{n-1}). \tag{7.4}$$

$$\mathbb{P}(S_n = k_n \mid S_{n-1} = k_{n-1}) = \mathbb{P}(X_n = k_n - k_{n-1}). \tag{7.5}$$

En particular

$$\mathbb{P}(S_n = k_n \mid S_0 = k_0, S_1 = k_1, \dots, S_{n-1} = k_{n-1}) = \mathbb{P}(S_n = k_n \mid S_{n-1} = k_{n-1}), \tag{7.6}$$

lo cual muestra que $(S_n)_n$ es un proceso de Markov (el futuro depende únicamente del estado presente y no de la historia pasada) en $\mathbb{Z}$.

La demostracion se deja al lector.

7.2. Cadenas de Markov

Definición 7.2.1 Cadena de Markov. Un proceso estocástico se llama una cadena de Markov si satisface la propiedad de Markov

$$\mathbb{P}(X_n = x_n \mid X_0 = x_0, X_1 = x_1, \dots, X_{n-1} = x_{n-1}) = \mathbb{P}(X_n = x_n \mid X_{n-1} = x_{n-1}) \tag{7.7}$$

Definición 7.2.2 Probabilidades de transición. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov con espacio de estados S. Entonces

$$\mathbb{P}(X_{n+1} = y \mid X_n = x) \tag{7.8}$$

es llamado las probabilidades de transición de un paso de la cadena. Si suponemos que son estacionarias, osea

$$\mathbb{P}(X_{n+1} = y \mid X_n = x) = \mathbb{P}(X_1 = y \mid X_0 = x), \quad \forall x, y \in S,\ n \in \mathbb{N}, \tag{7.9}$$

entonces la función de transición de un paso se define como

$$p(x,y) := \mathbb{P}(X_{n+1} = y \mid X_n = x), \quad \forall x, y \in S. \tag{7.10}$$

Definición 7.2.3 Distribución inicial de la cadena. La distribución de probabilidad de una cadena de Markov que también es llamada distribución inicial de la cadena, viene dada por

$$\Pi_0(x) := \mathbb{P}(X_0 = x). \tag{7.11}$$

Lema 7.2.1 Factorización con Markov. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov con espacio de estados S. Sumado a ello $\forall n, m \in \mathbb{N}, x_i \in S$ se tiene que

$$\mathbb{P}(X_0 = x_0, \dots, X_n = x_n) = \Pi_0(x_0)p(x_0, x_1)\cdots p(x_{n-1}, x_n), \tag{7.12}$$

$$\mathbb{P}(X_{n+m} = x_{n+m} \mid X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_{n+m} = x_{n+m} \mid X_n = x_n). \tag{7.13}$$

La demostracion es trivial. La ultima propiedad anterior se le llama propiedad fuerte de Markov.

Definición 7.2.4 Función de transición de m-pasos. Para $m \geq 1$, la función de transición de m-pasos se define como

$$p^m(x, y) := \mathbb{P}(X_m = y \mid X_0 = x), \quad \forall x, y \in S. \tag{7.14}$$

Además, se define

$$p^0(x, y) := \begin{cases} 1 & \text{si } x = y, \\ 0 & \text{en otro caso.} \end{cases} \tag{7.15}$$

Lema 7.2.2 Expansionan de una cadena de Markov. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov. Para todo $m \geq 1$ y $x, y \in S$, se cumple que

$$p^m(x, y) = \sum_{y_1 \in S} \sum_{y_2 \in S} \cdots \sum_{y_{m-1} \in S} p(x, y_1)\, p(y_1, y_2) \cdots p(y_{m-2}, y_{m-1})\, p(y_{m-1}, y). \tag{7.16}$$

La demostracion se deja al lector. Para este caso basta con recordar la probabilidad de eventos disjuntos y la factorización del lema anterior. De ahora en adelante, se asumirá que toda cadena de Markov es homogénea o estacionaria.

Corolario 7.2.1 Equivalencia de transición de n+m pasos. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov. Entonces $\forall n \in \mathbb{N}$, $m \geq 1$ y $x, y \in S$, se cumple que

$$p^m(x, y) = \mathbb{P}(X_{n+m} = y \mid X_n = x). \tag{7.17}$$

La demostracion es trivial.

Teorema 7.2.1 Chapman-Kolmogorov. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov. Entonces $\forall n, m \geq 0$ y $x, y \in S$, se cumple que

$$p^{m+n}(x, y) = \sum_{z \in S} p^n(x, z)\, p^m(z, y). \tag{7.18}$$

A lo anterior se le conoce como las ecuaciones de Chapman-Kolmogorov. Para su demostracion aplique el corolario anterior y la propiedad de Markov.

Definición 7.2.5 Función de transición. La función de transición de m-pasos se define como una matriz (posiblemente de dimensión infinita)

$$P^m := (p^m(x_i, x_j))_{i,j\geq 0} = \begin{pmatrix} p^m(x_0,x_0) & p^m(x_0,x_1) & p^m(x_0,x_2) & \cdots \\ p^m(x_1,x_0) & p^m(x_1,x_1) & p^m(x_1,x_2) & \cdots \\ p^m(x_2,x_0) & p^m(x_2,x_1) & p^m(x_2,x_2) & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}. \tag{7.19}$$

Corolario 7.2.2 Matriz de m-pasos de transición. La matriz de transición de m-pasos P^m es el producto m-veces de la matriz de transición de un paso P.

Utilice el teorema de Chapman-Kolmogorov para la demostracion.

Lema 7.2.3 No se como llamarlo. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov. Se cumple que $\forall m \in \mathbb{N}$ y $y \in S$

$$\mathbb{P}(X_m = y) = \sum_{x\in S} \Pi_0(x)\, p^m(x,y). \tag{7.20}$$

La demostracion es trivial.

7.3. Propiedad de Markov en Espacios de Estados Generales

Definición 7.3.1 Probabilidad de transición y cadena de Markov. Sea $(S, \mathcal{S})$ un espacio medible. Una función $p : S \times \mathcal{S} \to \mathbb{R}$ se dice una *probabilidad de transición* si

(i) para cada $x \in S$, $A \mapsto p(x, A)$ es una medida de probabilidad en $(S, \mathcal{S})$,

(ii) para cada $A \in \mathcal{S}$, $x \mapsto p(x, A)$ es una función medible.

Se dice que X_n es una *cadena de Markov* (respecto a $\mathcal{F}_n$) con probabilidad de transición p si

$$P(X_{n+1} \in B|\mathcal{F}_n) = p(X_n, B). \tag{7.21}$$

Definición 7.3.2 Operadores de desplazamiento. Sobre el espacio canónico $(\Omega_o, \mathcal{F}_\infty) = (S^{\{0,1,\dots\}}, \mathcal{S}^{\{0,1,\dots\}})$ con $X_n(\omega) = \omega_n$, los *operadores de desplazamiento* se definen por

$$\theta_n(\omega_0, \omega_1, \dots) = (\omega_n, \omega_{n+1}, \dots). \tag{7.22}$$

Teorema 7.3.1. Sean p una probabilidad de transición, μ una distribución inicial en un espacio $(S, \mathcal{S})$ agradable y P_μ la medida en el espacio canónico con distribuciones finito-dimensionales

$$P(X_j \in B_j, 0 \leq j \leq n) = \int_{B_0} \mu(dx_0) \int_{B_1} p(x_0, dx_1) \cdots \int_{B_n} p(x_{n-1}, dx_n). \tag{7.23}$$

Entonces X_n es una cadena de Markov (respecto a $\mathcal{F}_n = \sigma(X_0, X_1, \dots, X_n)$) con probabilidad de transición p. Es decir,

$$P_\mu(X_{n+1} \in B|\mathcal{F}_n) = p(X_n, B). \tag{7.24}$$

Teorema 7.3.2 Teorema de la clase monótona. Sea $\mathcal{A}$ un π-sistema que contiene a Ω y sea $\mathcal{H}$ una colección de funciones con valores reales que satisface:

(i) Si $A \in \mathcal{A}$, entonces $1_A \in \mathcal{H}$.

(ii) Si $f, g \in \mathcal{H}$, entonces $f + g$ y $cf \in \mathcal{H}$ para todo número real c.

(iii) Si $f_n \in \mathcal{H}$ son no negativas y crecen a una función acotada f, entonces $f \in \mathcal{H}$.

Entonces $\mathcal{H}$ contiene todas las funciones acotadas medibles respecto a $\sigma(\mathcal{A})$.

Teorema 7.3.3 Propiedad de Markov (operador de desplazamiento). Sea $Y : \Omega_o \to \mathbb{R}$ acotada y medible. Entonces

$$E_\mu(Y \circ \theta_m | \mathcal{F}_m) = E_{X_m} Y. \tag{7.25}$$

Definición 7.3.3 σ-álgebra $\mathcal{F}_N$ y desplazamiento aleatorio. Sea N un tiempo de paro. La información conocida al tiempo N es

$$\mathcal{F}_N = \{A : A \cap \{N = n\} \in \mathcal{F}_n \text{ para todo } n\}, \tag{7.26}$$

y el *operador de desplazamiento aleatorio* se define por

$$\theta_N \omega = \begin{cases} \theta_n \omega & \text{en } \{N = n\}, \\ \Delta & \text{en } \{N = \infty\}, \end{cases} \tag{7.27}$$

donde Δ es un punto extra que se agrega a Ω_o.

Teorema 7.3.4 Propiedad fuerte de Markov (operador de desplazamiento). Suponga que para cada n, $Y_n : \Omega_o \to \mathbb{R}$ es medible y $|Y_n| \leq M$ para todo n. Entonces

$$E_\mu(Y_N \circ \theta_N | \mathcal{F}_N) = E_{X_N} Y_N \quad \text{en } \{N < \infty\}, \tag{7.28}$$

donde el lado derecho es $\varphi(x, n) = E_x Y_n$ evaluada en $x = X_N$, $n = N$.

7.4. Clasificación de Estados

Definición 7.4.1 Comunicación de una cadena. Se dice que un estado $x \in S$ se comunica con un estado $y \in S$ cuando

$$\mathbb{P}(X_n = y \text{ para algún } n \geq 1 \mid X_0 = x) > 0, \tag{7.29}$$

en cuyo caso se utiliza la notación $x \to y$.

Definición 7.4.2 No comunicación. Se afirma que un estado $x \in S$ no se comunica con un estado $y \in S$ cuando

$$\mathbb{P}(X_n = y \text{ para algún } n \geq 1 \mid X_0 = x) = 0, \tag{7.30}$$

en cuyo caso se escribe $x \nrightarrow y$.

Definición 7.4.3 Intercomunicación. Dos estados $x, y \in S$ se consideran intercomunicados cuando se cumple simultáneamente que $x \to y$ y $y \to x$. La notación empleada es

$$x \leftrightarrow y. \tag{7.31}$$

Definición 7.4.4 Cadena irreducible. Una cadena de Markov se denomina irreducible cuando todos los estados del espacio S se intercomunican entre sí, es decir, para todo par $x, y \in S$ se cumple

$$x \leftrightarrow y. \tag{7.32}$$

Lema 7.4.1 Condición para comunicación. Sean $x, y \in S$ con $x \neq y$. Entonces, se cumple que $x \to y$ si y sólo si

$$\exists_{m \geq 1} \mid p^m(x, y) > 0 \tag{7.33}$$

La demostracion es trivial.

Lema 7.4.2 Relación de equivalencia. La relación de intercomunicación es una relación de equivalencia, en consecuencia

$$x \leftrightarrow x \text{ (reflexiva)} \tag{7.34}$$

$$x \leftrightarrow y \Rightarrow y \leftrightarrow x \text{ (simétrica)} \tag{7.35}$$

$$x \leftrightarrow y \text{ y } y \leftrightarrow z \Rightarrow x \leftrightarrow z \text{ (transitiva)} \tag{7.36}$$

La demostracion se deja al lector.

Definición 7.4.5 Notación de comunicación. Sean $x, y \in S$.

$$F_{xy} := \mathbb{P}(X_n = y \text{ para algún } n \geq 1 \mid X_0 = x). \tag{7.37}$$

Definición 7.4.6 Recurrente y transitorio. Un estado $y \in S$ se denomina *recurrente* si

$$F_{yy} = 1. \tag{7.38}$$

En caso contrario, transitorio si

$$F_{yy} < 1, \tag{7.39}$$

Definición 7.4.7 Visita exacta. $\forall x, y \in S$ y $n \geq 1$

$$f^n(x, y) := \mathbb{P}(X_n = y, X_{k<n} \neq y \mid X_0 = x) = \mathbb{P}(\text{ínf}\{m \geq 1 : X_m = y\} = n \mid X_0 = x). \tag{7.40}$$

Definición 7.4.8 Estado absorbente. Un estado $x \in S$ se denomina absorbente si

$$\mathbb{P}(X_{n+1} = x \mid X_n = x) = 1. \tag{7.41}$$

Proposición 7.4.1 Recurrencia en estados no absorbentes. Sea $x \in S$ no absorbente, entonces

$$\exists y \in S - \{x\} \mid p(x, y) > 0 \tag{7.42}$$

La demostracion es trivial.

Lema 7.4.3 Comunicación y visita. $\forall x, y \in S$ se cumple que

$$F_{xy} = \sum_{n=1}^{\infty} f^n(x, y). \tag{7.43}$$

La demostracion se deja al lector.

Lema 7.4.4 Primera visita. $\forall n \geq 1$ y $x, y \in S$ se cumple que

$$p^n(x, y) = \sum_{k=1}^{n} f^k(x, y) p^{n-k}(y, y). \tag{7.44}$$

Demostración. Note que

$$f^k(x, y)\, p^{n-k}(y, y) = \mathbb{P}(X_k = y, X_{i<k} \neq y \mid X_0 = x)\mathbb{P}(X_{n-k} = y \mid X_0 = y)$$

Por transición se tiene que

$$f^k(x, y)\, p^{n-k}(y, y) = \mathbb{P}(X_k = y, X_{i<k} \neq y \mid X_0 = x)\mathbb{P}(X_n = y \mid X_k = y)$$

Dado que $\mathbb{P}(A \mid B) = \mathbb{P}(A \mid B, C)$, se tiene que

$$f^k(x, y)\, p^{n-k}(y, y) = \mathbb{P}(X_n = y \mid X_k = y, X_{i<k} \neq y)\mathbb{P}(X_k = y, X_{i<k} \neq y \mid X_0 = x)$$

Aplicando el teorema Chapman-Kolmogorov, se tiene que la suma de estas probabilidades es igual a $p^n(x, y)$. □

Proposición 7.4.2 Absorción casi segura desde transitorios. Sea $A \subset S$ un conjunto de estados absorbentes y $T = S \setminus A$. Si $\forall\, x \in T\ \exists a \in A \mid p^n(a, x) > 0$, entonces

$$\forall x \in T \quad \mathbb{P}(T_A < \infty \mid X_0 = x) = 1, \quad T_A := \text{ínf}\{n \geq 1 : X_n \in A\} \tag{7.45}$$

La demostracion se deja al lector.

Definición 7.4.9 Tiempos de retorno. Sea $T_y^0 = 0$ y para $k \geq 1$ sea

$$T_y^k = \text{ínf}\{n > T_y^{k-1} : X_n = y\}, \tag{7.46}$$

el tiempo de la k-ésima visita de retorno a y. Se escribe $T_y = T_y^1$ y $\rho_{xy} = P_x(T_y < \infty)$.

Teorema 7.4.1.

$$P_x(T_y^k < \infty) = \rho_{xy}\rho_{yy}^{k-1}. \tag{7.47}$$

Definición 7.4.10 Numero esperado de visitas. $\forall x, y \in S$, se denota mediante $P_{x,y}$ el número esperado de visitas de la cadena al estado y partiendo del estado x

$$P_{x,y} := \mathbb{E}\left[\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n = y\}} \middle| X_0 = x\right], \tag{7.48}$$

donde la variable aleatoria

$$\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=y\}} \tag{7.49}$$

contabiliza el número de veces que la cadena ha visitado el estado y.

Lema 7.4.5 Transiciones y Numero de visitas. $\forall x, y \in S$ se cumple

$$P_{x,y} = \sum_{n=0}^{\infty} p^n(x,y). \tag{7.50}$$

Demostración. Dado que son la suma de variables aleatorias, por linealidad se tiene que

$$\mathbb{E}\left[\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=y\}} \middle| X_0 = x\right] = \sum_{n=0}^{\infty} \mathbb{E}\left[\mathbb{1}_{\{X_n=y\}} \middle| X_0 = x\right]$$

Donde claramente $\mathbb{1}_{\{X_n=y\}}$ nos limita a fijar el valor de la variable aleatoria, de forma que

$$\mathbb{E}\left[\mathbb{1}_{\{X_n=y\}} \middle| X_0 = x\right] = \mathbb{P}(X_n = y \mid X_0 = x).$$

□

Lema 7.4.6 Series de potencia de visitas. $\forall x, y \in S$, las series de potencias

$$P_{x,y}(t) = \sum_{n=0}^{\infty} p^n(x,y)t^n \tag{7.51}$$

$$F_{x,y}(t) = \sum_{n=1}^{\infty} f^n(x,y)t^n, \tag{7.52}$$

son absolutamente convergentes para $|t| < 1$. Además

$$P_{x,y}(t) = \delta_{x,y} + F_{x,y}(t)P_{y,y}(t), \tag{7.53}$$

donde

$$\delta_{x,y} = \begin{cases} 1 & \text{si } x = y, \\ 0 & \text{si } x \neq y. \end{cases} \tag{7.54}$$

Más aún

$$\lim_{t\uparrow 1} P_{x,y}(t) = P_{x,y}, \qquad \lim_{t\uparrow 1} F_{x,y}(t) = F_{x,y}. \tag{7.55}$$

Demostración. La parte de la convergencia es trivial. Para la formula, ahora note que

$$P_{x,y}(t) - \delta_{x,y} = \sum_{n=1}^{\infty} p^n(x,y)t^n$$

Como $p^n(x,y) = \sum_{k=1}^{n} f^k(x,y)p^{n-k}(y,y)$, entonces por el Teorema de Tonelli

$$P_{x,y}(t) - \delta_{x,y} = \sum_{n=1}^{\infty}\left(\sum_{k=1}^{n} f^k(x,y)p^{n-k}(y,y)t^n\right) = \sum_{k=1}^{\infty} f^k(x,y)\sum_{n=k}^{\infty} p^{n-k}(y,y)t^n$$

De forma que

$$P_{x,y}(t) - \delta_{x,y} = \sum_{k=1}^{\infty} f^k(x,y)t^k \sum_{n=0}^{\infty} p^n(y,y)t^n = F_{x,y}(t)P_{y,y}(t)$$

La demostracion de los limites es trivial.

□

Teorema 7.4.2 Consecuencias de recurrencia y transición. Un estado $x \in S$ es recurrente si y sólo si

$$\sum_{n=0}^{\infty} p^n(x,x) = \infty. \tag{7.56}$$

Un estado $x \in S$ es transitorio si y sólo si

$$\sum_{n=0}^{\infty} p^n(x,x) < \infty. \tag{7.57}$$

Si $y \in S$ es transitorio, entonces para todo $x \in S$ se cumple

$$\sum_{n=0}^{\infty} p^n(x,y) < \infty. \tag{7.58}$$

La demostracion se deja al lector.

Teorema 7.4.3 Caracterización de la recurrencia. Un estado $x \in S$ es recurrente si y sólo si

$$\mathbb{P}(X_n = x \text{ para infinitamente muchos } n \mid X_0 = x) = 1. \tag{7.59}$$

La demostracion es consecuencia directa del lema de Borel-Cantelli.

Proposición 7.4.3 Transitorios se visitan finitas veces. Sea $x \in s$ transitorio. Entonces

$$\mathbb{P}(X_n \in T \text{ para infinitamente muchos } n \mid X_0 = x) = 0 \tag{7.60}$$

La demostracion de deja al lector.

Definición 7.4.11 Tiempo medio de recurrencia. Sea $x \in S$ un estado recurrente.

$$m_y := \sum_{n=1}^{\infty} n\, f^n(x,y) \tag{7.61}$$

se denomina el tiempo medio de recurrencia de x. Se dice que

$$x \text{ es nulo-recurrente si } m_x = \infty, \tag{7.62}$$

$$x \text{ es positivo-recurrente si } m_x < \infty. \tag{7.63}$$

Teorema 7.4.4. Sea $N_n(y) = \sum_{m=1}^{n} 1_{\{X_m = y\}}$ el número de visitas a y hasta el tiempo n. Suponga que y es recurrente. Para cualquier $x \in S$, cuando $n \to \infty$,

$$\frac{N_n(y)}{n} \to \frac{1}{E_y T_y} 1_{\{T_y < \infty\}} \quad P_x\text{-c.s.} \tag{7.64}$$

Aquí $1/\infty = 0$.

Proposición 7.4.4 Convergencia cesariana de las transiciones. Para todo $x, y \in S$,

$$\frac{1}{n}\sum_{m=1}^{n} p^m(x,y) \to \frac{\rho_{xy}}{E_y T_y}. \tag{7.65}$$

Demostración. Sea $m_y := \mathbb{E}[\xi_k]$ donde $\xi_k = T_k - T_{k-1}$ son los tiempos entre retornos i.i.d. a y. Por el teorema de renovación,

$$\frac{N_t}{t} \xrightarrow{c.s.} \frac{1}{m_y}, \quad N_t := \text{ínf}\{k : T_k > t\}.$$

Como $x \to y$ e y es recurrente, por el Lema anterior $\mathbb{P}_x(\tau < \infty) = 1$, donde $\tau := \text{ínf}\{m \geq 1 : X_m = y\}$. Por la propiedad fuerte de Markov, las visitas a y tras τ forman el proceso de renovación $\{T_k\}$, por lo que $V_y(n) = N_n - 1$ c.s. para $n \geq \tau$, y entonces

$$\frac{V_y(n)}{n} \xrightarrow{c.s.} \frac{1}{m_y}.$$

Finalmente, como $\frac{1}{n}\sum_{m=1}^{n} p^m(x,y) = \mathbb{E}_x\left[\frac{V_y(n)}{n}\right]$ y la convergencia es dominada,

$$\lim_{n\to\infty} \frac{1}{n}\sum_{m=1}^{n} p^m(x,y) = \frac{1}{m_y}.$$

□

Lema 7.4.7 Equivalencia de nulorecurente. Un estado recurrente $x \in S$ es nulo-recurrente si y sólo si

$$p^n(x,x) \to 0 \text{ cuando } n \to \infty. \tag{7.66}$$

La demostracion se deja al lector. Bastan con utilizar el primer teorema de Cauchy para sumas aritméticas y el lema anterior.

Definición 7.4.12 Estado periódico. Sea $x \in S$. Se define el periodo de un estado como

$$d(x) := mcd\{n \geq 1 : p^n(x,x) > 0\}, \tag{7.67}$$

donde *mcd* denota el máximo común divisor.

$$x \text{ es un estado periódico si } d(x) \geq 2. \tag{7.68}$$

$$x \text{ es un estado aperiódico si } d(x) = 1. \tag{7.69}$$

$$x \text{ es un estado ergódico si es positivo-recurrente y aperiódico.} \tag{7.70}$$

Teorema 7.4.5 Equivalencia entre estados. Sean $x, y \in S$ y supóngase que $x \leftrightarrow y$. Entonces

$$x \text{ es transitorio si y sólo si } y \text{ lo es.} \tag{7.71}$$

$$x \text{ es recurrente si y sólo si } y \text{ lo es.} \tag{7.72}$$
$$x \text{ es nulo-recurrente si y sólo si } y \text{ lo es.} \tag{7.73}$$
$$x \text{ es positivo-recurrente si y sólo si } y \text{ lo es.} \tag{7.74}$$
$$x \text{ es periódico si y sólo si } y \text{ lo es. En ese caso } d(x) = d(y). \tag{7.75}$$
$$x \text{ es aperiódico si y sólo si } y \text{ lo es.} \tag{7.76}$$
$$x \text{ es ergódico si y sólo si } y \text{ lo es.} \tag{7.77}$$

La demostracion se deja al lector.

Lema 7.4.8 Recurrencia y equivalencia. Si x es recurrente y sumado a ello $x \to y$, entonces

$$y \to x, \qquad \rho_{yx} = 1. \tag{7.78}$$
$$y \text{ es recurrente.} \tag{7.79}$$

Demostración. Suponga por contradicción que $y \nrightarrow x$, dado que $p^n(x,y) > 0$ para algún n, si $T_x := \{m : X_m = x\}$ tiene que

$$\mathbb{P}(T_x = \infty \mid X_0 = x) \geq \mathbb{P}(T_x = \infty, X_n = y \mid X_0 = x)$$
$$= \mathbb{P}(T_x = \infty \mid X_n = y, X_0 = x)\mathbb{P}(X_n = y \mid X_0 = x) > \mathbb{P}(X_n = y \mid X_0 = x) > 0$$

Pero $F_{xx} = 1$, lo que implica que $\mathbb{P}(T_x = \infty \mid X_0 = x) = 0$. Por consecuencia, $y \to x$. La parte de la recurrencia es consecuencia del teorema anterior, y de paso es trivial.

□

Definición 7.4.13 Conjunto cerrado e irreducible. Un subconjunto $C \subset S$ se dice cerrado si, una vez que la cadena entra en C, nunca abandona C. Formalmente

$$\mathbb{P}(X_k \in S \setminus C \text{ para algun k } \mid X_0 = x) = 0, \forall x \in C. \tag{7.80}$$

Un subconjunto $C \subset S$ se dice irreducible si

$$\forall x, y \in C,\ x \leftrightarrow y. \tag{7.81}$$

Teorema 7.4.6 Equivalencia de cerrado. Sea $C \subset S$. C es cerrado si y sólo si

$$p(x,y) = 0, \forall x \in C, y \in S \setminus C. \tag{7.82}$$

La demostracion es trivial. Utiliza inducción en izquierda derecha, y sume con respector a $S \setminus C$ y k para la otra dirección.

Lema 7.4.9 Recurrencia en conjunto cerrado. Si $C \subset S$ es un subconjunto finito y cerrado, entonces existe al menos un $x \in C$ que es recurrente.

Demostración. Suponga que $\sum_{n=1}^{\infty} p^n(x,z) < \infty$, note que por distribucion de probabilidad y dado que C es finito

$$\sum_{z \in C} p^n(x,z) = 1 \quad \wedge \quad \sum_{z \in C} \sum_{n=1}^{\infty} p^n(x,z) < \infty$$

pero note que (dado que son sumas finitas)

$$\sum_{n=1}^{\infty}\sum_{z\in C} p^n(x,z) = \sum_{n=1}^{\infty} 1 = \infty$$

□

Teorema 7.4.7 Recurrencia positiva en conjuntos finitos cerrados. Si $C \subset S$ es un subconjunto finito, cerrado e irreducible, entonces

$$\forall x \in C,\ x \text{ es positivo-recurrente.} \tag{7.83}$$

Demostración. Note que por lemas anteriores todos los estados de C ahora son recurrentes. Entonces

$$\sum_{z\in C} p^n(x,z) = 1, \forall n \geq 1.$$

Sumando y dividiendo por N se tiene que

$$\sum_{z\in C} \frac{1}{N}\sum_{n=1}^{N} p^n(x,z) = 1.$$

Por el teorema de convergencia de estado recurrente, para cada $z \in C$ recurrente el límite cesariano existe y satisface

$$\lim_{N\to\infty} \frac{1}{N}\sum_{n=1}^{N} p^n(x,z) = \frac{1}{m_z}$$

Tomando $N \to \infty$ e intercambiando límite

$$\sum_{z\in C} \frac{1}{m_z} = 1.$$

Como la suma es finita, debe existir al menos un $y \in C$ con $m_y < \infty$. Como C es irreducible, todos los estados se pueden acotar entre si mismos, entonces $m_z < \infty$ para todo $z \in C$, es decir todo $x \in C$ es positivo-recurrente.

□

Corolario 7.4.1 Recurrencia positiva en cadenas finitas irreducibles. Si una cadena de Markov es irreducible y tiene un número finito de estados, entonces

$$\text{todos sus estados son positivo-recurrentes.} \tag{7.84}$$

La demostracion es inmediata del teorema anterior.

Teorema 7.4.8 Descomposición del espacio de estados. El espacio de estados S de una cadena de Markov tiene la siguiente descomposición como unión disjunta

$$S = T \cup \bigsqcup_{j=0}^{N} C_j, \tag{7.85}$$

donde T es el subconjunto de todos los estados transitorios, cada C_j es un subconjunto cerrado e irreducible de estados recurrentes, y $N \in \mathbb{N} \cup \{\infty\}$.

Demostración. Sea T el conjunto de estados transitorios y $R = S \setminus T$ el conjunto de estados recurrentes. Entonces $S = T \cup R$, siendo esta unión disjunta. Dentro de R, dos estados $i, j \in R$ se comunican si $i \leftrightarrow j$, esta relación es de equivalencia, por lo que R se particiona en clases de comunicación $\{C_j\}$ cerradas.

Si existiera un camino hacia afuera, hacia algún $y \notin C_j$, entonces habría un $z \in C_j$ con $\mathbb{P}(z, y) > 0$. Pero si z es recurrente, la cadena debe regresar a y con probabilidad 1, lo que implicaría que y comunica de regreso con z, contradiciendo $y \notin C_j$. Por tanto, ninguna clase recurrente tiene salida. Además, cada C_j es irreducible.

Los estados que no pertenecen a ninguna clase C_j son necesariamente transitorios, pues si fueran recurrentes estarían en alguna clase. Así, T absorbe exactamente los estados fuera de las clases recurrentes.

□

Lema 7.4.10 Existencia de descenso estricto. Sea $\{X_n\}$ una cadena de Markov con $S \subset \mathbb{Z}$ finito y $f : S \to \mathbb{R}$ tal que $\sum_{y \in S} f(y)\, p(x, y) = f(x)$ para todo $x \in S$. Si $x \in S$ no es absorbente, entonces

$$\exists y_1, y_2 \in S \mid p(x, y_1) > 0 \wedge p(x, y_2) > 0 \wedge f(y_1) < f(x) < f(y_2) \tag{7.86}$$

La demostracion se deja al lector.

Proposición 7.4.5 Probabilidad de absorción con función harmónica monótona. Sea $\{X_n\}$ una cadena de Markov con $S = \{0, 1, \dots, d\}$ y $f : S \to \mathbb{R}$ estrictamente monótona tal que

$$\sum_{y \in S} f(y) p(x, y) = f(x) \quad \forall x \in S \tag{7.87}$$

Entonces para todo $x \in \{1, \dots, d-1\}$

$$\mathbb{P}\left(\text{absorción en } f^{-1}(\max f) \mid X_0 = x\right) = \frac{f(x) - f(0)}{f(d) - f(0)} \tag{7.88}$$

La demostracion se deja al lector.

Lema 7.4.11 Conjunto de máximo es cerrado. Sea $f : S \to \mathbb{R}$ tal que $\sum_{y \in S} f(y)\, p(x, y) = f(x)$ para todo $x \in S$. Sean $M = \max_{x \in S} f(x)$ y $C = \{x \in S : f(x) = M\}$. Entonces C es cerrado

$$p(x, y) = 0 \quad \forall\, x \in C,\ y \notin C \tag{7.89}$$

La demostracion se deja al lector.

7.5. Cadenas de Nacimiento y Muerte y Criterios de Recurrencia

Teorema 7.5.1. Suponga que S es irreducible y que $\varphi \geq 0$ cumple $E_x \varphi(X_1) \leq \varphi(x)$ para $x \notin F$, un conjunto finito, y $\varphi(x) \to \infty$ cuando $x \to \infty$, es decir, $\{x : \varphi(x) \leq M\}$ es finito para todo $M < \infty$. Entonces la cadena es recurrente.

Definición 7.5.1 Cadena de nacimiento y muerte. Una *cadena de nacimiento y muerte* en $\{0, 1, 2, \dots\}$ es una cadena de Markov con

$$p(i, i+1) = p_i, \qquad p(i, i-1) = q_i, \qquad p(i, i) = r_i, \tag{7.90}$$

con $q_0 = 0$ y $p(i, j) = 0$ en otro caso. Se supone $p_k, q_k > 0$ para $k \geq 1$ y se define $\varphi(0) = 0$, $\varphi(1) = 1$ y

$$\varphi(n) = \sum_{m=0}^{n-1} \prod_{j=1}^{m} \frac{q_j}{p_j} \quad \text{para } n \geq 1, \tag{7.91}$$

interpretando el producto como 1 cuando $m = 0$.

Teorema 7.5.2. Para una cadena de nacimiento y muerte, si $a < x < b$, entonces con $T_c = \text{ínf}\{n \geq 1 : X_n = c\}$,

$$P_x(T_a < T_b) = \frac{\varphi(b) - \varphi(x)}{\varphi(b) - \varphi(a)}, \qquad P_x(T_b < T_a) = \frac{\varphi(x) - \varphi(a)}{\varphi(b) - \varphi(a)}. \tag{7.92}$$

Teorema 7.5.3. Para una cadena de nacimiento y muerte, 0 es recurrente si y sólo si $\varphi(M) \to \infty$ cuando $M \to \infty$, es decir,

$$\varphi(\infty) \equiv \sum_{m=0}^{\infty} \prod_{j=1}^{m} \frac{q_j}{p_j} = \infty. \tag{7.93}$$

Si $\varphi(\infty) < \infty$, entonces $P_x(T_0 = \infty) = \varphi(x)/\varphi(\infty)$.

7.6. Recurrencia de Caminatas Aleatorias

Teorema 7.6.1 Principio de reflexión (caminatas simétricas). Sean $\xi_1, \xi_2, ...$ independientes e idénticamente distribuidas con una distribución simétrica respecto a 0 y sea $S_n = \xi_1 + \cdots + \xi_n$. Si $a > 0$, entonces

$$P\left(\sup_{m \leq n} S_m \geq a\right) \leq 2P(S_n \geq a). \tag{7.94}$$

Definición 7.6.1 Valor recurrente y valor posible. Sea $S_n = X_1 + \cdots + X_n$ una caminata aleatoria, donde $X_1, X_2, ...$ son i.i.d., y sea $\|x\| = \sup_i |x_i|$. Un número $x \in \mathbb{R}^d$ se dice un *valor recurrente* de la caminata aleatoria S_n si para todo $\varepsilon > 0$, $P(\|S_n - x\| < \varepsilon \text{ i.v.}) = 1$. Un número x se dice un *valor posible* si para todo $\varepsilon > 0$ existe n tal que $P(\|S_n - x\| < \varepsilon) > 0$.

Teorema 7.6.2. El conjunto V de valores recurrentes es o bien $\varnothing$ o bien un subgrupo cerrado de $\mathbb{R}^d$. En el segundo caso, $V = U$, el conjunto de valores posibles.

Definición 7.6.2 Caminata aleatoria recurrente y transitoria. Si $V = \varnothing$, la caminata aleatoria se dice *transitoria*; en otro caso se dice *recurrente*.

Teorema 7.6.3. Para cualquier caminata aleatoria, los siguientes enunciados son equivalentes:

(i) $P(\tau_1 < \infty) = 1$,

(ii) $P(S_m = 0 \text{ i.v.}) = 1$,

(iii) $\sum_{m=0}^{\infty} P(S_m = 0) = \infty$,

donde $\tau_0 = 0$ y $\tau_n = \text{ínf}\{m > \tau_{n-1} : S_m = 0\}$ es el tiempo del n-ésimo retorno a 0.

Teorema 7.6.4. La caminata aleatoria simple es recurrente en $d \leq 2$ y transitoria en $d \geq 3$.

Lema 7.6.1. Si $\sum_{n=1}^{\infty} P(\|S_n\| < \varepsilon) < \infty$, entonces $P(\|S_n\| < \varepsilon \text{ i.v.}) = 0$. Si $\sum_{n=1}^{\infty} P(\|S_n\| < \varepsilon) = \infty$, entonces $P(\|S_n\| < 2\varepsilon \text{ i.v.}) = 1$.

Lema 7.6.2. Sea m un entero ≥ 2. Entonces

$$\sum_{n=0}^{\infty} P(\|S_n\| < m\varepsilon) \leq (2m)^d \sum_{n=0}^{\infty} P(\|S_n\| < \varepsilon). \tag{7.95}$$

Teorema 7.6.5. La convergencia (resp. divergencia) de $\sum_n P(\|S_n\| < \varepsilon)$ para un solo valor de $\varepsilon > 0$ es suficiente para la transitoriedad (resp. recurrencia).

Teorema 7.6.6 Teorema de Chung-Fuchs. Suponga $d = 1$. Si la ley débil de los grandes números se cumple en la forma $S_n/n \to 0$ en probabilidad, entonces S_n es recurrente.

Teorema 7.6.7. Si S_n es una caminata aleatoria en $\mathbb{R}^2$ y $S_n/n^{1/2} \Rightarrow$ una distribución normal no degenerada, entonces S_n es recurrente.

Teorema 7.6.8. Sea $\delta > 0$ y sea $\varphi = E\exp\big(it \cdot X_j\big)$ la función característica de un paso de la caminata aleatoria. S_n es recurrente si y sólo si

$$\int_{(-\delta,\delta)^d} \operatorname{Re} \frac{1}{1-\varphi(y)}\, dy = \infty. \tag{7.96}$$

Teorema 7.6.9. Sea $\delta > 0$. S_n es recurrente si y sólo si

$$\sup_{r<1} \int_{(-\delta,\delta)^d} \operatorname{Re} \frac{1}{1-r\varphi(y)}\, dy = \infty. \tag{7.97}$$

Lema 7.6.3 Relación de Parseval. Sean μ y ν medidas de probabilidad en $\mathbb{R}^d$ con funciones características φ y ψ. Entonces

$$\int \psi(t)\, \mu(dt) = \int \varphi(x)\, \nu(dx). \tag{7.98}$$

Lema 7.6.4. Si $|x| \leq \pi/3$, entonces $1 - \cos x \geq x^2/4$.

Definición 7.6.3 Caminata aleatoria verdaderamente tridimensional. Una caminata aleatoria en $\mathbb{R}^3$ es *verdaderamente tridimensional* si la distribución de X_1 cumple $P(X_1 \cdot \theta \neq 0) > 0$ para todo $\theta \neq 0$.

Teorema 7.6.10. Ninguna caminata aleatoria verdaderamente tridimensional es recurrente.

7.7. Distribucion estacionaria

Definición 7.7.1 Medida estacionaria. Una medida μ se dice una *medida estacionaria* si

$$\sum_x \mu(x)p(x,y) = \mu(y). \tag{7.99}$$

Si μ es una medida de probabilidad se llama una *distribución estacionaria*.

Lema 7.7.1 Invariante para probabilidades n-pasos. Supóngase que π es una distribución estacionaria. Entonces

$$\pi(y) = \sum_{x\in S} \pi(x)\, p_n(x,y), \quad \forall y \in S,\ n \geq 1. \tag{7.100}$$

La demostracion de deja al lector, se demuestra por inducción.

Definición 7.7.2 Probabilidad de transición doblemente estocástica. Una probabilidad de transición que cumple $\sum_x p(x,y) = 1$ se llama *doblemente estocástica*.

Definición 7.7.3 Balance detallado y medida reversible. Una medida μ satisface la condición de *balance detallado* si

$$\mu(x)p(x,y) = \mu(y)p(y,x). \tag{7.101}$$

Una medida que satisface esta condición se dice una *medida reversible*.

Teorema 7.7.1. Sea μ una medida estacionaria y suponga que X_0 tiene "distribución" μ. Entonces $Y_m = X_{n-m}$, $0 \leq m \leq n$, es una cadena de Markov con medida inicial μ y probabilidad de transición

$$q(x,y) = \mu(y)p(y,x)/\mu(x). \tag{7.102}$$

q se llama la probabilidad de transición dual. Si μ es una medida reversible, entonces $q = p$.

Teorema 7.7.2 Condición del ciclo de Kolmogorov. Suponga que p es irreducible. Una condición necesaria y suficiente para la existencia de una medida reversible es que

(i) $p(x,y) > 0$ implique $p(y,x) > 0$, y

(ii) para cualquier lazo $x_0, x_1, \ldots, x_n = x_0$ con $\prod_{1\leq i\leq n} p(x_i, x_{i-1}) > 0$,

$$\prod_{i=1}^{n} \frac{p(x_{i-1}, x_i)}{p(x_i, x_{i-1})} = 1. \tag{7.103}$$

Teorema 7.7.3. Sea x un estado recurrente y sea $T = \text{ínf}\{n \geq 1 : X_n = x\}$. Entonces

$$\mu_x(y) = E_x\left(\sum_{n=0}^{T-1} 1_{\{X_n=y\}}\right) = \sum_{n=0}^{\infty} P_x(X_n = y, T > n) \tag{7.104}$$

define una medida estacionaria.

Teorema 7.7.4. Si p es irreducible y recurrente (es decir, todos los estados lo son), entonces la medida estacionaria es única salvo múltiplos constantes.

Teorema 7.7.5 Equivalencia entre recurrencia positiva e invariancia. Supóngase que la cadena $\{X_n : n \in \mathbb{N}\}$ es irreducible. Las siguientes afirmaciones son equivalentes:

$$\text{Todo estado de la cadena es positivo-recurrente.} \tag{7.105}$$

$$\text{La cadena posee una distribución estacionaria } \pi. \tag{7.106}$$

Más aún, en ambos casos se concluye que existe una única distribución estacionaria, la cual satisface

$$\pi(y) = \frac{1}{m_y}, \quad \forall y \in S. \tag{7.107}$$

Demostración. (i) $\Rightarrow$ (ii): Defínase la medida de ocupación de ciclo

$$\gamma(x) := \mathbb{E}_y\left[\sum_{n=0}^{T_y-1} \mathbf{1}_{\{X_n=x\}}\right],$$

que satisface $\gamma(y) = 1$ y la ecuación de balance $\gamma(x) = \sum_z \gamma(z)\, p(z,x)$. Como

$$\sum_{x\in S} \gamma(x) = \mathbb{E}_y[T_y] = m_y < \infty,$$

donde $T_y = \text{ínf}\{n \geq 1 : X_n = y\}$, la medida $\pi(x) := \gamma(x)/m_y$ es una distribución estacionaria.

(ii) $\Rightarrow$ (i): Si y fuera nulo-recurrente, por el teorema de convergencia de recurrencia

$$\frac{1}{n}\sum_{m=1}^{n} p^m(x,y) \to \frac{1}{m_y} = 0 \quad \forall x.$$

Pero $\pi(y) = \sum_x \pi(x)\, p^n(x,y)$ para todo n, y por Convergencia Dominada $\pi(y) = \sum_x \pi(x) \cdot 0 = 0$, contradiciendo $\sum_y \pi(y) = 1$. Luego todo estado es positivo-recurrente. La unicidad se sigue de que toda distribución estacionaria μ satisface $\mu(y) = 1/m_y = \pi(y)$.

□

Corolario 7.7.1 Existencia y unicidad en cadenas finitas irreducibles. Si una cadena de Markov es irreducible y tiene un número finito de estados, entonces posee una única distribución estacionaria π. Más aún, π satisface la relación anterior.

Demostrado anteriormente.

Teorema 7.7.6. Si p es irreducible y tiene una distribución estacionaria π, entonces cualquier otra medida estacionaria es un múltiplo de π.

Lema 7.7.2 Soporte de la distribución estacionaria. Si la cadena $\{X_n : n \in \mathbb{N}\}$ posee una distribución estacionaria π, entonces

$$\pi(x) = 0 \quad \text{para todo estado } x \in S \text{ que sea transitorio o nulo-recurrente.} \tag{7.108}$$

La demostracion queda al lector.

Teorema 7.7.7 Clasificación de distribuciones estacionarias. Denótese mediante S_p el conjunto de los estados positivo-recurrentes de la cadena $\{X_n : n \in \mathbb{N}\}$.

$$\text{Si } S_p = \varnothing, \text{ la cadena no posee distribución estacionaria.} \tag{7.109}$$

$$\text{Si } S_p \neq \varnothing \text{ y } S_p \text{ es irreducible, la cadena tiene una única distribución estacionaria.} \tag{7.110}$$

$$\text{Si } S_p \neq \varnothing \text{ y } S_p \text{ no es irreducible, la cadena posee un número infinito de distribuciones estacionarias.} \tag{7.111}$$

Demostración. Caso $S_p = \varnothing$. Todos los estados son transitorios o nulo-recurrentes. Si existiera una distribución estacionaria π, el Lema de Soporte de la distribución estacionaria daría $\pi(x) = 0$ para todo $x \in S$, lo que contradice $\sum_{x \in S} \pi(x) = 1$. Luego no existe distribución estacionaria.

Caso $S_p \neq \varnothing$, S_p irreducible. Por el Teorema de Equivalencia de cerrado y el Lema de Recurrencia y equivalencia, S_p es un subconjunto cerrado: si existiera $x \in S_p$ e $y \notin S_p$ con $p(x, y) > 0$, entonces por irreducibilidad de S_p la cadena debería retornar a x desde y, lo que forzaría a y a ser positivo-recurrente, contradiciendo $y \notin S_p$. Como S_p es cerrado e irreducible, la cadena restringida a S_p satisface las hipótesis del Teorema de Equivalencia entre recurrencia positiva e invariancia, que garantiza la existencia de una única distribución estacionaria π sobre S_p. Extendiendo con $\pi(x) = 0$ para $x \notin S_p$, lo cual es consistente con el Lema de Soporte, se obtiene la única distribución estacionaria sobre S.

Caso $S_p \neq \varnothing$, S_p no irreducible. Por el Teorema de Descomposición del espacio de estados, S_p contiene al menos dos clases cerradas irreducibles distintas $C_1, C_2 \subset S_p$. Aplicando el caso anterior a cada C_i, se obtienen distribuciones estacionarias π_1 y π_2 soportadas respectivamente en C_1 y C_2. Dado que la ecuación de estacionariedad es lineal, para todo $\alpha \in [0, 1]$ la mezcla convexa

$$\pi_\alpha := \alpha\, \pi_1 + (1 - \alpha)\, \pi_2$$

es también una distribución estacionaria. Como la familia $\{\pi_\alpha : \alpha \in [0, 1]\}$ es no contable, existen infinitas distribuciones estacionarias.

□

7.8. Comportamiento Asintótico y Periodicidad

Corolario 7.8.1 Ergódico de medias temporales. Supóngase que la cadena $\{X_n : n \in \mathbb{N}\}$ es irreducible y que todos sus estados son positivo-recurrentes. Sea π su única distribución estacionaria. Entonces

$$\lim_{n \to \infty} \frac{1}{n} \sum_{m=1}^{n} p^m(x, y) = \pi(y), \quad \forall x, y \in S. \tag{7.112}$$

La demostracion queda al lector.

Lema 7.8.1. Si $d_x = 1$, entonces $p^m(x, x) > 0$ para $m \geq m_0$.

Lema 7.8.2. Suponga que p es irreducible, recurrente y que todos los estados tienen periodo d. Fije $x \in S$ y para cada $y \in S$ sea $K_y = \{n \geq 1 : p^n(x, y) > 0\}$.

(i) Existe $r_y \in \{0, 1, \ldots, d-1\}$ tal que si $n \in K_y$ entonces $n = r_y$ mód d, es decir, $n - r_y$ es múltiplo de d.

(ii) Sea $S_r = \{y : r_y = r\}$ para $0 \leq r < d$. Si $y \in S_i$, $z \in S_j$ y $p^n(y, z) > 0$, entonces $n = (j - i)$ mód d.

(iii) $S_0, S_1, \dots, S_{d-1}$ son clases irreducibles para p^d, y todos los estados tienen periodo 1.

Definición 7.8.1 Descomposición cíclica. Una partición $S_0, S_1, \dots, S_{d-1}$ del espacio de estados que satisface (ii) del lema anterior se llama una *descomposición cíclica* del espacio de estados.

Teorema 7.8.1 Ergódico de convergencia. Supóngase que la cadena $\{X_n : n \in \mathbb{N}\}$ es irreducible y que todos sus estados son positivo-recurrentes. Sea π su única distribución estacionaria y sea d el período común de todos los estados de la cadena.

$$\text{Si } d(x) = 1 \text{ (aperiódicos)}, \ \lim_{n\to\infty} p^n(x,y) = \pi(y), \quad \forall x, y \in S. \tag{7.113}$$

$$\text{Si } d \geq 2 \text{ (periódicos), entonces } \forall x, y \in S \ \exists \, 0 \leq r < d \wedge r \neq n - dm \mid p^n(x,y) = 0, \tag{7.114}$$

y además

$$\lim_{m\to\infty} p^{dm+r}(x,y) = d\,\pi(y). \tag{7.115}$$

Demostración. Caso aperiódico ($d = 1$): Por el Lema de Primera visita,

$$p^n(x,y) = \sum_{k=1}^{n} f^k(x,y)\, p^{n-k}(y,y).$$

Como y es positivo-recurrente, por el teorema ergódico el promedio cesariano satisface

$$\frac{1}{N}\sum_{n=1}^{N} p^n(x,y) \to \pi(y).$$

Para obtener convergencia puntual, nótese que $p^n(x,y)$ es una convolución con una distribución de probabilidad $\{f^k(x,y)\}$ de media finita. Por el teorema de Blackwell-Stone para sumas de Cesàro de convoluciones, si el límite cesariano existe y la distribución es aperiódica, entonces el límite puntual existe e igual al cesariano:

$$p^n(x,y) \xrightarrow{n\to\infty} \pi(y).$$

Caso periódico ($d \geq 2$): Todos los estados comparten período d. Fijado y, las clases cíclicas

$$C_r := \{z \in S : p^{nd+r}(y,z) > 0 \text{ para algún } n\}, \quad r = 0, \dots, d-1,$$

particionan S, y la cadena pasa de C_r a $C_{r+1 \bmod d}$ con probabilidad 1. Para $x \in C_i$, $y \in C_j$ con $r = j - i \bmod d$, se tiene $p^n(x,y) = 0$ salvo cuando $n = dm + r$.

La cadena $Y_m := X_{dm}$ restringida a C_j es irreducible y aperiódica, con tiempo medio de retorno $m_y^{(d)} = m_y/d$. Aplicando el caso aperiódico,

$$p^{dm+r}(x,y) \xrightarrow{m\to\infty} \frac{1}{m_y^{(d)}} = \frac{d}{m_y} = d\,\pi(y).$$

□

7.9. Algebra de Cola de una Cadena

Definición 7.9.1 **σ-álgebra de cola.** Sea $\mathcal{F}'_n = \sigma(X_{n+1}, X_{n+2}, ...)$. La *$\sigma$-álgebra de cola* es $\mathcal{T} = \cap_n \mathcal{F}'_n$.

Teorema 7.9.1. Suponga que p es irreducible, recurrente y que todos los estados tienen periodo d. Entonces $\mathcal{T} = \sigma(\{X_0 \in S_r\} : 0 \leq r < d)$. Más precisamente, si μ es cualquier distribución inicial y $A \in \mathcal{T}$, entonces existe r tal que $A = \{X_0 \in S_r\}$ P_μ-c.s.

Teorema 7.9.2. Suponga que X_0 tiene distribución inicial μ. Las ecuaciones

$$h(X_n, n) = E_\mu(Z|\mathcal{F}_n) \qquad \text{y} \qquad Z = \lim_{n\to\infty} h(X_n, n) \tag{7.116}$$

establecen una correspondencia uno a uno entre las variables acotadas $Z \in \mathcal{T}$ y las funciones espacio-tiempo armónicas acotadas, es decir, las funciones acotadas $h : S \times \{0, 1, ...\} \to \mathbb{R}$ tales que $h(X_n, n)$ es una martingala.

Teorema 7.9.3. Para la caminata aleatoria simple en d dimensiones,

$$\mathcal{T} = \sigma(\{X_0 \in L_i\},\ i = 0, 1), \tag{7.117}$$

donde $L_0 = \{z \in \mathbb{Z}^d : z^1 + \cdots + z^d \text{ es par}\}$ y $L_1 = \mathbb{Z}^d - L_0$.

7.10. Cadenas de Harris

Definición 7.10.1 **Cadena de Harris.** Se dice que una cadena de Markov X_n es una *cadena de Harris* si existen conjuntos $A, B \in \mathcal{S}$, una función q con $q(x, y) \geq \varepsilon > 0$ para $x \in A$, $y \in B$, y una medida de probabilidad ρ concentrada en B tales que:

(i) Si $\tau_A = \text{ínf}\{n \geq 0 : X_n \in A\}$, entonces $P_z(\tau_A < \infty) > 0$ para todo $z \in S$.

(ii) Si $x \in A$ y $C \subset B$, entonces $p(x, C) \geq \int_C q(x, y)\rho(dy)$.

Definición 7.10.2 **Cadena extendida $\bar{X}_n$.** Dada una cadena de Harris en $(S, \mathcal{S})$, se construye una cadena de Markov $\bar{X}_n$ con probabilidad de transición $\bar{p}$ en $(\bar{S}, \bar{\mathcal{S}})$, donde $\bar{S} = S \cup \{\alpha\}$ y $\bar{\mathcal{S}} = \{B, B \cup \{\alpha\} : B \in \mathcal{S}\}$, mediante

$$\text{si } x \in S - A: \quad \bar{p}(x, C) = p(x, C) \text{ para } C \in \mathcal{S}, \tag{7.118}$$

$$\text{si } x \in A: \quad \bar{p}(x, \{\alpha\}) = \varepsilon, \quad \bar{p}(x, C) = p(x, C) - \varepsilon\rho(C) \text{ para } C \in \mathcal{S}, \tag{7.119}$$

$$\text{si } x = \alpha: \quad \bar{p}(\alpha, D) = \int \rho(dx)\bar{p}(x, D) \text{ para } D \in \bar{\mathcal{S}}. \tag{7.120}$$

Se define además la probabilidad de transición v por $v(x, \{x\}) = 1$ si $x \in S$ y $v(\alpha, C) = \rho(C)$.

Lema 7.10.1. $v\bar{p} = \bar{p}$ y $\bar{p}v = p$.

Lema 7.10.2. Sea Y_n una cadena de Markov inhomogénea con $p_{2k} = v$ y $p_{2k+1} = \bar{p}$. Entonces $\bar{X}_n = Y_{2n}$ es una cadena de Markov con probabilidad de transición $\bar{p}$ y $X_n = Y_{2n+1}$ es una cadena de Markov con probabilidad de transición p.

Lema 7.10.3. Si f es una función medible acotada en S, sea $\bar{f} = vf$, es decir, $\bar{f}(x) = f(x)$ para $x \in S$ y $\bar{f}(\alpha) = \int f \, d\rho$. Si μ es una medida de probabilidad en $(S, \mathcal{S})$, entonces

$$E_\mu f(X_n) = E_\mu \bar{f}(\bar{X}_n). \tag{7.121}$$

Definición 7.10.3 Recurrencia y transitoriedad para cadenas de Harris. Sea $R = \text{ínf}\{n \geq 1 : \bar{X}_n = \alpha\}$. Si $P_\alpha(R < \infty) = 1$ se dice que la cadena es *recurrente*; en otro caso se dice *transitoria*.

Teorema 7.10.1. Sea $\lambda(C) = \sum_{n=1}^{\infty} 2^{-n} \bar{p}^n(\alpha, C)$. En el caso recurrente, si $\lambda(C) > 0$ entonces $P_\alpha(\bar{X}_n \in C \text{ i.v.}) = 1$. Para λ-casi todo x, $P_x(R < \infty) = 1$.

Teorema 7.10.2. En el caso recurrente, existe una medida estacionaria σ-finita $\bar{\mu} \ll \lambda$.

Lema 7.10.4. Si ν es una medida estacionaria σ-finita para p, entonces $\nu(A) < \infty$ y $\bar{\nu} = \nu\bar{p}$ es una medida estacionaria para $\bar{p}$ con $\bar{\nu}(\alpha) < \infty$.

Teorema 7.10.3. Suponga que p es recurrente. Si ν es una medida estacionaria σ-finita, entonces $\nu = \bar{\nu}(\alpha)\mu$, donde μ es la medida construida en la demostración del teorema de existencia de medida estacionaria.

Definición 7.10.4 Cadena de Harris aperiódica. Una cadena de Harris recurrente X_n se dice *aperiódica* si $\text{m. c. d.}\{n \geq 1 : \bar{p}^n(\alpha, \alpha) > 0\} = 1$.

Teorema 7.10.4. Sea X_n una cadena de Harris recurrente aperiódica con distribución estacionaria π. Si $P_x(R < \infty) = 1$, entonces cuando $n \to \infty$,

$$\|p^n(x, \cdot) - \pi(\cdot)\| \to 0. \tag{7.122}$$

Lema 7.10.5. Suponga que $X, Y \geq 0$ son independientes y $P(X > x) = e^{-\lambda x}$. Entonces

$$P(X - Y > x) = ae^{-\lambda x}, \qquad \text{donde } a = P(X - Y > 0). \tag{7.123}$$

7.11. Sucesiones Estacionarias y Teoremas Ergódicos

Definición 7.11.1 Sucesión estacionaria. $X_0, X_1, \ldots$ se dice una *sucesión estacionaria* si para todo k la sucesión desplazada $\{X_{k+n}, n \geq 0\}$ tiene la misma distribución, es decir, para cada m, $(X_0, \ldots, X_m)$ y $(X_k, \ldots, X_{k+m})$ tienen la misma distribución.

Definición 7.11.2 Transformación que preserva la medida. Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Una función medible $\varphi : \Omega \to \Omega$ se dice que *preserva la medida* si $P(\varphi^{-1}A) = P(A)$ para todo $A \in \mathcal{F}$. La n-ésima iterada φ^n se define inductivamente por $\varphi^n = \varphi(\varphi^{n-1})$ para $n \geq 1$, con $\varphi^0(\omega) = \omega$.

Proposición 7.11.1. Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad, φ una transformación que preserva la medida y $X \in \mathcal{F}$. Entonces $X_n(\omega) = X(\varphi^n\omega)$ define una sucesión estacionaria.

Proposición 7.11.2. Si $Y_0, Y_1, \ldots$ es una sucesión estacionaria que toma valores en un espacio agradable, existe una medida P en el espacio de sucesiones $(S^{\{0,1,\ldots\}}, \mathcal{S}^{\{0,1,\ldots\}})$ tal que $X_n(\omega) = \omega_n$ tiene la misma distribución que $\{Y_n, n \geq 0\}$. Si φ es el operador de desplazamiento, $\varphi(\omega_0, \omega_1, \ldots) = (\omega_1, \omega_2, \ldots)$, y $X(\omega) = \omega_0$, entonces φ preserva la medida y $X_n(\omega) = X(\varphi^n\omega)$.

Definición 7.11.3 Evento invariante y transformación ergódica. Sea φ una transformación que preserva la medida en $(\Omega, \mathcal{F}, P)$. Un conjunto $A \in \mathcal{F}$ se dice *invariante* si $\varphi^{-1}A = A$ (dos conjuntos se consideran iguales si su diferencia simétrica tiene probabilidad 0). Sea $\mathcal{I}$ la colección de eventos invariantes. Se dice que φ es *ergódica* si $\mathcal{I}$ es trivial, es decir, si para todo $A \in \mathcal{I}$, $P(A) \in \{0, 1\}$.

Lema 7.11.1 Lema ergódico maximal. Sean $X_j(\omega) = X(\varphi^j\omega)$, $S_k(\omega) = X_0(\omega) + \cdots + X_{k-1}(\omega)$ y $M_k(\omega) = \max(0, S_1(\omega), \ldots, S_k(\omega))$. Entonces $E(X; M_k > 0) \geq 0$.

Teorema 7.11.1 Teorema ergódico. Para cualquier $X \in L^1$,

$$\frac{1}{n}\sum_{m=0}^{n-1} X(\varphi^m\omega) \to E(X|\mathcal{I}) \quad \text{c.s. y en } L^1. \tag{7.124}$$

Teorema 7.11.2. Sea $\varphi(\omega) = (\omega + \theta) \bmod 1$ la rotación del círculo en $\Omega = [0, 1)$ con $\theta \in (0, 1)$ irracional. Si $A = [a, b)$, entonces para todo $x \in [0, 1)$

$$\frac{1}{n}\sum_{m=0}^{n-1} 1_A(\varphi^m x) \to b - a, \tag{7.125}$$

es decir, el conjunto excepcional es $\varnothing$.

Teorema 7.11.3. Sea $X_1, X_2, \ldots$ una sucesión estacionaria con valores en $\mathbb{R}^d$, sea $S_k = X_1 + \cdots + X_k$, $A = \{S_k \neq 0 \text{ para todo } k \geq 1\}$ y $R_n = |\{S_1, \ldots, S_n\}|$ el número de puntos visitados al tiempo n. Cuando $n \to \infty$,

$$R_n/n \to E(1_A|\mathcal{I}) \quad \text{c.s.} \tag{7.126}$$

Teorema 7.11.4. Sea $X_1, X_2, ...$ una sucesión estacionaria con valores en $\mathbb{Z}$ y $E|X_i| < \infty$. Sea $S_n = X_1 + \cdots + X_n$ y $A = \{S_1 \neq 0, S_2 \neq 0, ...\}$.

(i) Si $E(X_1|\mathcal{I}) = 0$, entonces $P(A) = 0$.

(ii) Si $P(A) = 0$, entonces $P(S_n = 0 \text{ i.v.}) = 1$.

Teorema 7.11.5 Kac. Sea $X_0, X_1, ...$ una sucesión estacionaria con valores en $(S, \mathcal{S})$. Sean $A \in \mathcal{S}$, $T_0 = 0$ y para $n \geq 1$, $T_n = \text{ínf}\{m > T_{n-1} : X_m \in A\}$ el tiempo del n-ésimo retorno a A. Si $P(X_n \in A \text{ al menos una vez}) = 1$, entonces bajo $P(\cdot|X_0 \in A)$, $t_n = T_n - T_{n-1}$ es una sucesión estacionaria con

$$E(T_1|X_0 \in A) = 1/P(X_0 \in A). \tag{7.127}$$

Teorema 7.11.6 Teorema ergódico subaditivo. Suponga que $X_{m,n}$, $0 \leq m < n$, satisfacen:

(i) $X_{0,m} + X_{m,n} \geq X_{0,n}$.

(ii) $\{X_{nk,(n+1)k}, n \geq 1\}$ es una sucesión estacionaria para cada k.

(iii) La distribución de $\{X_{m,m+k}, k \geq 1\}$ no depende de m.

(iv) $EX_{0,1}^+ < \infty$ y para cada n, $EX_{0,n} \geq \gamma_0 n$, donde $\gamma_0 > -\infty$.

Entonces

(a) $\lim_{n\to\infty} EX_{0,n}/n = \inf_m EX_{0,m}/m \equiv \gamma$.

(b) $X = \lim_{n\to\infty} X_{0,n}/n$ existe c.s. y en L^1, de modo que $EX = \gamma$.

(c) Si todas las sucesiones estacionarias en (ii) son ergódicas, entonces $X = \gamma$ c.s.

Lema 7.11.2. Sea $\tau(n)$ el menor valor de t para el cual hay n puntos de un proceso de Poisson de tasa uno en el plano dentro del cuadrado $R_{0,t}$ con vértices $(0,0), (0,t), (t,t), (t,0)$. Entonces $\tau(n)/\sqrt{n} \to 1$ c.s.

8

Martingales

8.1. xxx

Definición 8.1.1 Distribución condicional regular. Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad, $X : (\Omega, \mathcal{F}) \to (S, \mathcal{S})$ una función medible y $\mathcal{G}$ una σ-álgebra $\subset \mathcal{F}$. Se dice que $\mu : \Omega \times \mathcal{S} \to [0, 1]$ es una *distribución condicional regular* (d.c.r.) para X dado $\mathcal{G}$ si

(i) para cada A, $\omega \mapsto \mu(\omega, A)$ es una versión de $P(X \in A|\mathcal{G})$,

(ii) para casi todo ω, $A \mapsto \mu(\omega, A)$ es una medida de probabilidad en $(S, \mathcal{S})$.

Cuando $S = \Omega$ y X es la función identidad, μ se llama *probabilidad condicional regular*.

Teorema 8.1.1. Sea $\mu(\omega, A)$ una d.c.r. para X dado $\mathcal{F}$. Si $f : (S, \mathcal{S}) \to (\mathbb{R}, \mathcal{R})$ cumple $E|f(X)| < \infty$, entonces

$$E(f(X)|\mathcal{F}) = \int \mu(\omega, dx) f(x) \quad \text{c.s.} \tag{8.1}$$

Teorema 8.1.2. Las d.c.r. existen si $(S, \mathcal{S})$ es "agradable" (*nice*), es decir, si existe una función inyectiva $\varphi : S \to \mathbb{R}$ tal que φ y φ^{-1} son medibles.

Teorema 8.1.3. Suponga que X y Y toman valores en un espacio agradable $(S, \mathcal{S})$ y $\mathcal{G} = \sigma(Y)$. Existe una función $\mu : S \times \mathcal{S} \to [0,1]$ tal que

(i) para cada A, $\mu(Y(\omega), A)$ es una versión de $P(X \in A|\mathcal{G})$,

(ii) para casi todo ω, $A \mapsto \mu(Y(\omega), A)$ es una medida de probabilidad en $(S, \mathcal{S})$.

8.2. Definición y Propiedades Básicas

Definición 8.2.1 martingala en tiempo discreto. Un proceso estocástico en tiempo discreto y de variables aleatorias reales $(M_n : n \geq 1)$ se dice ser una martingala en tiempo discreto con respecto a una sucesión de variables aleatorias $(X_n : n \geq 1)$, siempre que se cumpla con lo siguiente

1. Cada M_n es integrable.
2. Cada M_n es medible con respecto a la sucesión finita $X_1, \ldots, X_n$, es decir, $\forall\, n \geq 1$ existe una función $f_n : \mathbb{R}^n \to \mathbb{R}$ que es (Borel) medible tal que $M_n = f_n(X_1, \ldots, X_n)$.
3. Se cumple la identidad de martingala

$$\mathbb{E}(M_{n+1} \mid X_1, \ldots, X_n) = M_n, \qquad \forall\, n \geq 1. \tag{8.2}$$

Definición 8.2.2 Filtración. Una sucesión de σ-álgebras $(\mathcal{F}_n : n \geq 1)$ de Ω tal que

$$\mathcal{F}_1 \subseteq \mathcal{F}_2 \subseteq \cdots \subseteq \mathcal{F}_n \subseteq \cdots \subseteq \mathcal{F},$$

se llama una filtración.

Definición 8.2.3 Filtración natural. Sea $(X_n : n \geq 1)$ una sucesión de variables aleatorias definidas sobre un espacio de probabilidad $(\Omega, \mathscr{F}, \mathbb{P})$. Para cada $n \in \mathbb{N}$ se define

$$\mathcal{F}_n = \sigma(X_1, X_2, \ldots, X_n), \tag{8.3}$$

es decir, la menor σ–álgebra que contiene todos los eventos de la forma

$$\{X_k \in B_k\}, \qquad B_k \in \mathscr{B}(\mathbb{R}),\ k = 1, \ldots, n. \tag{8.4}$$

La sucesión $(\mathcal{F}_n : n \geq 1)$ constituye una filtración, llamada la filtración natural asociada a (X_n).

Proposición 8.2.1. Sea $(\mathcal{F}_n : n \geq 1)$ la filtración natural de (X_n). Un evento $A \in \mathscr{F}$ pertenece a $\mathcal{F}_n$ si y sólo si su función indicadora 1_A puede escribirse como

$$1_A = f(X_1, \ldots, X_n), \tag{8.5}$$

para alguna función medible $f : \mathbb{R}^n \to \mathbb{R}$.

Para otro dia.

Definición 8.2.4 ($\mathcal{F}_n$-adaptado). Un proceso $(M_n : n \geq 1)$ se dice $(\mathcal{F}_n)$-adaptado si para todo $n \geq 1$, la variable aleatoria M_n es $\mathcal{F}_n$-medible, es decir, si $\{M_n \in B\} \in \mathcal{F}_n\ \forall\, B \in \mathscr{B}(\mathbb{R})$.

Definición 8.2.5 ($\mathcal{F}_n$**-martingala).** Un proceso estocástico $(M_n : n \geq 1)$ es una $(\mathcal{F}_n)$-martingala siempre que se cumpla lo siguiente

1. Cada M_n es integrable.
2. El proceso es $(\mathcal{F}_n)$-adaptado.
3. Se cumple la identidad de martingala

$$\mathbb{E}(M_{n+1} \mid \mathcal{F}_n) = M_n, \qquad \forall\, n \geq 1. \tag{8.6}$$

Si reemplazamos "=" por "$\leq$" (respectivamente "$\geq$") se dice que $(M_n : n \geq 1)$ es una $(\mathcal{F}_n)$-supermartingala (respectivamente una $(\mathcal{F}_n)$-submartingala).

En lo que resta de esta sección, y salvo indicación contraria, se trabajara con una filtración $(\mathcal{F}_n : n \geq 1)$ respecto de la cual todas nuestras martingalas son $(\mathcal{F}_n)$–adaptadas; por ello se utilizara simplemente el término martingala, y de igual forma supermartingala y submartingala.

Lema 8.2.1. Si $(M_n : n \geq 1)$ es una martingala, se tiene que

$$\mathbb{E}(M_1) = \mathbb{E}(M_2) = \cdots = \mathbb{E}(M_n) = \cdots$$

La demostracion es consecuencia de la propiedad de la torre.

Lema 8.2.2. Si $(M_n : n \geq 1)$ es una supermartingala (respectivamente una submartingala) entonces para $n > m$, $\mathbb{E}(M_n \mid \mathcal{F}_m) \leq M_m$ (respectivamente $\mathbb{E}(M_n \mid \mathcal{F}_m) \geq M_m$).

Demostración. Si suponemos que por inducción se cumple para n (ya que para $n = m + 1$ se cumple por definicion), entonces para $m + k + 1 = n + 1$ por propiedad de la torre

$$\mathbb{E}[M_{m+k+1} \mid \mathcal{F}_m] = \mathbb{E}[\mathbb{E}[M_{m+k+1} \mid F_{m+k}] \mid \mathcal{F}_m] \leq \mathbb{E}[M_{m+k} \mid \mathcal{F}_m] \leq M_m$$

Para el segundo caso es lo mismo.

□

Lema 8.2.3. Si $(M_n : n \geq 1)$ es una martingala entonces para $n > m$, $\mathbb{E}(M_n \mid \mathcal{F}_m) = M_m$.

Se aplica lo mismo anterior.

Teorema 8.2.1. Si $(M_n : n \geq 1)$ es una martingala (respectivamente una submartingala) y φ es una función convexa (respectivamente convexa y creciente) para la cual se satisface que $\mathbb{E}|\varphi(M_n)| < \infty$ $\forall_{n\geq 1}$, entonces el proceso $(\varphi(M_n) : n \geq 1)$ es una submartingala. En particular, si para $p \geq 1$ se cumple $\mathbb{E}|M_n|^p < \infty$, entonces $(|M_n|^p : n \geq 1)$ es una submartingala.

Note que esto pasa ya que $\mathbb{E}[\varphi(X) \mid \mathscr{G}] \geq \varphi(\mathbb{E}[X \mid \mathscr{G}])$. Desigualdad de Jensen.

Teorema 8.2.2 Consecuencias para submartingalas y supermartingalas. Si X_n es una submartingala respecto a $\mathcal{F}_n$ y φ es una función convexa creciente con $E|\varphi(X_n)| < \infty$ para todo n, entonces $\varphi(X_n)$ es una submartingala respecto a $\mathcal{F}_n$. En consecuencia

(i) si X_n es una submartingala, entonces $(X_n - a)^+$ es una submartingala;

(ii) si X_n es una supermartingala, entonces $X_n \wedge a$ es una supermartingala.

Definición 8.2.6 ($\mathcal{F}_n$**-predecible).** Un proceso $(A_n : n \geq 1)$ se dice que es $(\mathcal{F}_n)$-predecible si $\forall_{n\geq 1}$, A_n es $\mathcal{F}_{n-1}$-medible, con la convención $\mathcal{F}_0 = \{\varnothing, \Omega\}$.

Teorema 8.2.3 Descomposición de Doob. Una submartingala $(N_n : n \geq 1)$ se puede escribir en forma única como $N_n = M_n + A_n \ \forall_{n\geq 1}$, donde $(M_n : n \geq 1)$ es una martingala y $(A_n : n \geq 1)$ es un proceso predecible creciente.

Demostración. Tome $\Delta A_{n+1} = \mathbb{E}[N_{n+1} - N_n \mid F_n]$, y en consecuencia tome

$$A_n = \sum_{k=1}^{n} \Delta A_n \quad M_n = N_n - A_n$$

por definicion de A_n dado que los valores anteriores ya están determinados, por el ultimo incremento Δ entonces es $\mathcal{F}_{n-1}$-medible, en cuyo caso es predecible y creciente. Ahora, note que

$$\mathbb{E}[M_n \mid \mathcal{F}_{n-1}] = \mathbb{E}[N_n - A_n \mid \mathcal{F}_{n-1}] = \mathbb{E}[N_n \mid \mathcal{F}_{n-1}] - A_n = N_{n-1} + \Delta A_n - \sum_{k=1}^{n} \Delta A_k = M_{n-1}$$

Para la unicidad suponga otros M' y A' y se llegan a que son iguales a los ya encontrados.

□

Definición 8.2.7 Transformada de martingala. Suponga que tenemos un proceso predecible $(A_n : n \geq 1)$ y una martingala $(M_n : n \geq 1)$. Defina el proceso $(\widetilde{M}_n : n \geq 1)$ como

$$\widetilde{M}_n = \sum_{i=1}^{n-1} A_{i+1}(M_{i+1} - M_i), \qquad \forall\, n \geq 1.$$

A $(\widetilde{M}_n : n \geq 1)$ se le llama la transformada de martingala de (M_n) mediante (A_n).

Teorema 8.2.4. Sean $(A_n : n \geq 1)$, $(M_n : n \geq 1)$ y $(\widetilde{M}_n : n \geq 1)$ como la definicion anterior. Suponga que cada A_n es una variable aleatoria acotada. Entonces la transformada de martingala $(\widetilde{M}_n : n \geq 1)$ es una martingala.

Demostración. Simplemente note que $\mathbb{E}\left[|\widetilde{M}_n|\right] < \infty$, sumado a ello tanto A_i y M_i son $\mathcal{F}_n$-medibles por la definicion de filtración. Por ultimo

$$\mathbb{E}\left[\widetilde{M}_n \mid \mathcal{F}_{n-1}\right] = \sum_{i=1}^{n-2} A_{i+1}(M_{i+1} - M_i) + A_n\mathbb{E}[M_n \mid \mathcal{F}_{n-1}] - A_n M_{n-1} = \sum_{i=1}^{n-2} A_{i+1}(M_{i+1} - M_i) = \widetilde{M}_{n-1}$$

□

Definición 8.2.8 Ganancias del sistema H**.** Dados una sucesión X_n y una sucesión predecible H_n, se define

$$(H \cdot X)_n = \sum_{m=1}^{n} H_m(X_m - X_{m-1}). \tag{8.7}$$

Teorema 8.2.5. Sea X_n, $n \geq 0$, una supermartingala. Si $H_n \geq 0$ es predecible y cada H_n es acotada, entonces $(H \cdot X)_n$ es una supermartingala.

8.3. Tiempos de Parada

Definición 8.3.1 ($\mathcal{F}_n$**-tiempo de parada).** Considere una filtración $(\mathcal{F}_n : n \geq 1)$. Una variable aleatoria τ con valores en $\mathbb{N} \cup \{\infty\}$ se llama un $(\mathcal{F}_n)$-tiempo de parada si para cada $n \geq 1$ se cumple que $\{\tau \leq n\} \in \mathcal{F}_n$.

Definición 8.3.2 Variable detenida. Si $(Y_n : n \geq 0)$ es un proceso estocástico $(\mathcal{F}_n)$-adaptado y si τ es un $(\mathcal{F}_n)$-tiempo de parada tal que $\mathbb{P}(\tau < \infty) = 1$, definiremos la variable detenida Y_τ como la variable aleatoria dada por:

$$Y_\tau(\omega) := \sum_{k=1}^{\infty} \mathbf{1}_{\{\tau=k\}}(\omega)\, Y_k(\omega), \qquad \forall\, \omega \in \Omega. \tag{8.8}$$

8.4. Parada Opcional

Definición 8.4.1 Proceso detenido. Sea $(Y_n : n \geq 0)$ un proceso estocástico $(\mathcal{F}_n)$–adaptado y τ un $(\mathcal{F}_n)$–tiempo de parada tal que

$$\mathbb{P}(\tau < \infty) = 1. \tag{8.9}$$

Si τ está acotado, es decir, si existe $M > 0$ tal que

$$\mathbb{P}(\tau \leq M) = 1, \tag{8.10}$$

la suma en la definición de variable detenida involucra un número finito de términos. Para cada $n \in \mathbb{N}$ se define el $(\mathcal{F}_n)$–tiempo de parada

$$\tau \wedge n = \text{mín}\{\tau, n\}, \tag{8.11}$$

el cual está acotado por n. El proceso detenido $(Y_{\tau\wedge n} : n \geq 1)$ se define como

$$Y_{\tau\wedge n}(\omega) = \begin{cases} Y_\tau(\omega), & \text{si } \tau(\omega) < n, \\ Y_n(\omega), & \text{si } \tau(\omega) \geq n. \end{cases} \tag{8.12}$$

Teorema 8.4.1 Parada Opcional de Doob. Si X_n es una supermartingala (en particular, si M_n es una martingala) y τ un tiempo de parada, el proceso detenido $X_{\tau\wedge n}$ es una supermartingala (respectivamente, el proceso $(M_{\tau\wedge n} : n \geq 1)$ es una martingala).

Demostración. Tome $A_n(\omega) = \mathbf{1}_{\{\tau\geq n\}}(\omega) = 1 - \mathbf{1}_{\{\tau<n\}}(\omega)$ es un proceso predecible tal que $\{\tau \leq n-1\} \in \mathcal{F}_{n-1}$ por lo que A_n es $\mathcal{F}_{n-1}$-medible. Ahora note que

$$M_1 + \sum_{k=1}^{n-1} A_{k+1}(M_{k+1} - M_k) = M_\tau \mathbf{1}_{\{\tau<n\}}(\omega) + M_n \mathbf{1}_{\{\tau\geq n\}}(\omega) = M_{\tau\wedge n}$$

es una martingala.

□

Teorema 8.4.2. Si X_n es una submartingala y N es un tiempo de paro con $P(N \leq k) = 1$, entonces

$$EX_0 \leq EX_N \leq EX_k. \tag{8.13}$$

8.5. Desigualdades para Submartingalas

Teorema 8.5.1 Desigualdad Maximal de Doob. Si $(M_n : n \geq 1)$ es una $(\mathcal{F}_n)$-submartingala no-negativa que es p-integrable con $p \geq 1$, entonces $\forall_{\lambda>0, n\geq 1}$ se tiene que

$$\lambda^p \, \mathbb{P}\Big(\max_{1\leq m\leq n} M_m \geq \lambda\Big) \leq \mathbb{E}\Big(M_n^p \, \mathbf{1}_{\{\max_{1\leq m\leq n} M_n \geq \lambda\}}\Big) \leq \mathbb{E}(M_n^p). \tag{8.14}$$

Demostración. Como x^p es convexa y creciente en $x \geq 0$, el proceso $(M_n^p : n \geq 1)$ es una submartingala no-negativa p-integrable. Por tanto, basta probar la desigualdad para $p = 1$ y aplicarla a (M_n^p) con umbral λ^p. Entonces tome $\tau(\omega) = \min\{1 \leq m \leq n : M_m(\omega) \geq \lambda\}$ con la convención $\tau = n$ si el conjunto es vacío. Observe que τ es el primer tiempo de llegada al conjunto $[\lambda, \infty)$, y que se cumple la igualdad de eventos

$$\Big\{\max_{1\leq m\leq n} M_m \geq \lambda\Big\} = \{\tau \leq n\}.$$

Ahora note que en el evento $\{\tau \leq n\}$ se tiene por definición que $M_\tau \geq \lambda$, de donde

$$\lambda \mathbf{1}_{\{\tau\leq n\}} \leq M_\tau \mathbf{1}_{\{\tau\leq n\}} = \sum_{m=1}^{n} M_m \mathbf{1}_{\{\tau=m\}}.$$

Tomando esperanza a ambos lados y usando que (M_n) es submartingala, es decir $\mathbb{E}(M_n \mid \mathcal{F}_m) \geq M_m$ para $m \leq n$, se obtiene

$$\lambda \mathbb{P}(\tau \leq n) \leq \sum_{m=1}^{n} \mathbb{E}\Big(M_m \mathbf{1}_{\{\tau=m\}}\Big) \leq \sum_{m=1}^{n} \mathbb{E}\Big(M_n \mathbf{1}_{\{\tau=m\}}\Big) = \mathbb{E}\Big(M_n \mathbf{1}_{\{\tau\leq n\}}\Big) \leq \mathbb{E}(M_n).$$

Usando la igualdad de eventos $\{\tau \leq n\} = \{\max_{1\leq m\leq n} M_m \geq \lambda\}$ se concluye el caso $p = 1$.

Para $p \geq 1$ basta aplicar lo anterior al proceso (M_n^p) con umbral λ^p, y usar que $\max_{1\leq m\leq n} M_m^p \geq \lambda^p \iff \max_{1\leq m\leq n} M_m \geq \lambda$ dado que x^p es creciente en $x \geq 0$, lo que da directamente

$$\lambda^p \mathbb{P}\Big(\max_{1\leq m\leq n} M_m \geq \lambda\Big) \leq \mathbb{E}\Big(M_n^p \mathbf{1}_{\{\max_{1\leq m\leq n} M_m \geq \lambda\}}\Big) \leq \mathbb{E}(M_n^p).$$

□

Teorema 8.5.2 Desigualdad de Doob. Sea X_m una submartingala, $\bar{X}_n = \max_{0\leq m\leq n} X_m^+$, $\lambda > 0$ y $A = \{\bar{X}_n \geq \lambda\}$. Entonces

$$\lambda P(A) \leq EX_n 1_A \leq EX_n^+. \tag{8.15}$$

Teorema 8.5.3 Desigualdad en L^p de Doob. Si X_n es una submartingala, entonces para $1 < p < \infty$,

$$E(\bar{X}_n^p) \leq \left(\frac{p}{p-1}\right)^p E(X_n^+)^p. \tag{8.16}$$

En consecuencia, si Y_n es una martingala y $Y_n^* = \max_{0\le m\le n} |Y_m|$,

$$E|Y_n^*|^p \le \left(\frac{p}{p-1}\right)^p E(|Y_n|^p). \tag{8.17}$$

Demostración. Sea $M_n^* = \max_{1\le m\le n} M_m$. Por la fórmula de la esperanza mediante la función de distribución y la Desigualdad Maximal de Doob se tiene

$$\mathbb{E}\left((M_n^*)^p\right) = p\int_0^\infty \lambda^{p-1}\mathbb{P}(M_n^*\ge\lambda)\,d\lambda \le p\int_0^\infty \lambda^{p-1}\frac{\mathbb{E}(M_n\mathbf{1}_{\{M_n^*\ge\lambda\}})}{\lambda}\,d\lambda = p\int_0^\infty \lambda^{p-2}\mathbb{E}(M_n\mathbf{1}_{\{M_n^*\ge\lambda\}})\,d\lambda.$$

Intercambiando esperanza e integral mediante el Teorema de Fubini

$$\mathbb{E}\left((M_n^*)^p\right) \le p\,\mathbb{E}\left(M_n\int_0^{M_n^*}\lambda^{p-2}\,d\lambda\right) = \frac{p}{p-1}\mathbb{E}\left(M_n(M_n^*)^{p-1}\right).$$

Aplicando la desigualdad de Hölder con exponentes p y $\frac{p}{p-1}$ al lado derecho,

$$\mathbb{E}\left(M_n(M_n^*)^{p-1}\right) \le \mathbb{E}(M_n^p)^{1/p}\,\mathbb{E}\left((M_n^*)^p\right)^{(p-1)/p}.$$

Sustituyendo y dividiendo ambos lados por $\mathbb{E}((M_n^*)^p)^{(p-1)/p}$ (que es finito y positivo),

$$\mathbb{E}\left((M_n^*)^p\right)^{1/p} \le \frac{p}{p-1}\mathbb{E}(M_n^p)^{1/p},$$

y elevando a la potencia p se concluye

$$\mathbb{E}\left(\max_{1\le m\le n} M_m^p\right) \le \left(\frac{p}{p-1}\right)^p \mathbb{E}(M_n^p).$$

□

8.6. Convergencia de Martingalas

Definición 8.6.1 Cruces ascendentes. Sea X_n, $n\ge 0$, una submartingala y sean $a<b$. Sea $N_0=-1$ y para $k\ge 1$

$$N_{2k-1} = \text{ínf}\{m > N_{2k-2} : X_m \le a\}, \tag{8.18}$$
$$N_{2k} = \text{ínf}\{m > N_{2k-1} : X_m \ge b\}. \tag{8.19}$$

El número de cruces ascendentes de $[a,b]$ completados al tiempo n es $U_n = \sup\{k : N_{2k}\le n\}$.

Teorema 8.6.1 Desigualdad de cruces ascendentes. Si X_m, $m\ge 0$, es una submartingala, entonces

$$(b-a)EU_n \le E(X_n-a)^+ - E(X_0-a)^+. \tag{8.20}$$

Teorema 8.6.2 Convergencia de Martingalas. Sea $(M_n : n\ge 1)$ una martingala que satisface $\mathbb{E}(|M_n|)\le B\ \forall_{n\ge1}$ para cierto $B>0$. Entonces existe una variable aleatoria M_∞ con $\mathbb{E}(|M_\infty|)\le B$

tal que

$$\mathbb{P}\Big(\lim_{n\to\infty} M_n = M_\infty\Big) = 1, \tag{8.21}$$

es decir $M_n \xrightarrow{\text{c.s.}} M_\infty$.
Si más aún se tiene que $\mathbb{E}(|M_n|^p) \le B \ \forall\, n \ge 1$, para $p > 1$, entonces $\mathbb{E}(|M_\infty|^p) \le B$ y además

$$\lim_{n\to\infty} \mathbb{E}(|M_n - M_\infty|^p) = 0, \tag{8.22}$$

es decir $M_n \xrightarrow{L^p} M_\infty$.

Demostración. Convergencia casi segura. Sean $a < b$ racionales. Definase

$$\sigma_1 = \min\{k \ge 1 : M_k \le a\}, \qquad \tau_i = \min\{k > \sigma_i : M_k \ge b\}, \qquad \sigma_{i+1} = \min\{k > \tau_i : M_k \le a\},$$

y sea $U_n[a,b] = \max\{j : \tau_j \le n\}$ el número de upcrossings del intervalo $[a,b]$ hasta el tiempo n. El proceso

$$H_k = \sum_{j\ge 1} \mathbf{1}_{\{\sigma_j < k \le \tau_j\}}$$

es predecible pues $\{\sigma_j < k \le \tau_j\} \in \mathcal{F}_{k-1}$, y por la transformada de martingalas

$$\widetilde{H}_n = \sum_{i=1}^{n-1} H_{i+1}(M_{i+1} - M_i)$$

es una martingala con $\mathbb{E}(\widetilde{H}_n) = 0$. Dado que cada upcrossing completo contribuye al menos $b-a$ a $\widetilde{H}_n$, y los incrementos fuera de los upcrossings satisfacen $(M_n - a)^+ \ge \widetilde{H}_n - U_n[a,b](b-a) + (M_n - a)^+$, se obtiene la desigualdad de upcrossings de Doob:

$$(b-a)\,\mathbb{E}(U_n[a,b]) \le \mathbb{E}((M_n - a)^+) \le \mathbb{E}(|M_n|) + |a| \le B + |a| < \infty.$$

Por monotonía $U_n[a,b] \nearrow U_\infty[a,b]$, y por el Teorema de Convergencia Monótona

$$\mathbb{E}(U_\infty[a,b]) \le \frac{B + |a|}{b-a} < \infty,$$

luego $U_\infty[a,b] < \infty$ c.s. Tomando unión sobre todos los pares $a < b$ racionales,

$$\mathbb{P}\left(\liminf_{n\to\infty} M_n < \limsup_{n\to\infty} M_n\right) = \mathbb{P}\left(\bigcup_{\substack{a,b\in\mathbb{Q}\\ a<b}} \{U_\infty[a,b] = \infty\}\right) = 0,$$

por lo que $\lim_{n\to\infty} M_n = M_\infty$ existe c.s. La cota $\mathbb{E}(|M_\infty|) \le B$ se obtiene aplicando el Lema de Fatou

$$\mathbb{E}(|M_\infty|) = \mathbb{E}\left(\lim_{n\to\infty} |M_n|\right) \le \liminf_{n\to\infty} \mathbb{E}(|M_n|) \le B.$$

Convergencia en L^p. Si $\mathbb{E}(|M_n|^p) \le B$ para todo $n \ge 1$ con $p > 1$, la cota $\mathbb{E}(|M_\infty|^p) \le B$ se obtiene igualmente por el Lema de Fatou. Para la convergencia L^p, note que la sucesión $(|M_n|^p)$ está acotada en L^1 con $p > 1$, lo que implica que la familia $\{M_n\}$ es uniformemente integrable. Junto con la convergencia c.s. ya probada, esto da

$$\lim_{n\to\infty} \mathbb{E}(|M_n - M_\infty|^p) = 0.$$

□

Otra demostracion por si acaso

Demostración. Sean $d_k = M_k - M_{k-1}$ con $M_0 = 0$ las diferencias de la martingala. Como $\mathbb{E}(d_k d_j) = 0$ para $k \neq j$, se tiene

$$\mathbb{E}(M_n^2) = \mathbb{E}\left(\sum_{k=1}^{n} d_k\right)^2 = \sum_{k=1}^{n} \mathbb{E}(|d_k|^2),$$

y de la cota $\mathbb{E}(|M_n|^2) \leq B$ se concluye que $\sum_{k=1}^{\infty} \mathbb{E}(|d_k|^2) \leq B < \infty$.

Para probar la convergencia c.s., note que para $\epsilon > 0$ fijo, la Desigualdad Maximal de Doob aplicada a la martingala $(M_{k+m} - M_m : k \geq 1)$ da

$$\mathbb{P}\left(\sup_{k>m} |M_k - M_m| \geq \epsilon\right) \leq \frac{1}{\epsilon^2} \sum_{k=m+1}^{\infty} \mathbb{E}(|d_k|^2) \to 0, \qquad m \to \infty,$$

pues la cola de una serie convergente tiende a cero. Esto implica que (M_n) es de Cauchy en probabilidad, y por el criterio de convergencia c.s. se concluye que

$$\mathbb{P}\left(\liminf_{n\to\infty} M_n = \limsup_{n\to\infty} M_n\right) = 1.$$

Definimos entonces $M_\infty(\omega) = \lim_{n\to\infty} M_n(\omega)$ en el conjunto de probabilidad 1 donde el límite existe, y $M_\infty(\omega) = 0$ en el complemento, de modo que $M_n \xrightarrow{\text{c.s.}} M_\infty$.

Para la convergencia en L^2, observe que $M_\infty - M_n = \sum_{k=n+1}^{\infty} d_k$, y por ortogonalidad de las diferencias

$$\mathbb{E}(|M_\infty - M_n|^2) = \sum_{k=n+1}^{\infty} \mathbb{E}(|d_k|^2) \to 0, \qquad n \to \infty.$$

□

Teorema 8.6.3 Convergencia de submartingalas. Si $(M_n : n \geq 1)$ es una submartingala que satisface $\mathbb{E}(\text{máx}\{M_n, 0\}) \leq B \ \forall_{n\geq 1}$, entonces $M_n \xrightarrow{\text{c.s.}} M_\infty$ con $\mathbb{E}(|M_\infty|) < \infty$.

Demostración. Por la Descomposición de Doob existe una martingala (N_n) y un proceso predecible creciente (A_n) con $A_1 = 0$ tal que $M_n = N_n + A_n$. Como (A_n) es creciente y

$$\mathbb{E}(A_n) = \mathbb{E}(M_n) - \mathbb{E}(N_n) = \mathbb{E}(M_n) - \mathbb{E}(M_1) \leq \mathbb{E}(\text{máx}\{M_n, 0\}) \leq B,$$

se tiene que $A_n \nearrow A_\infty$ c.s. con $\mathbb{E}(A_\infty) \leq B$. Por otra parte,

$$\mathbb{E}(|N_n|) \leq \mathbb{E}(|M_n|) + \mathbb{E}(A_n) \leq 2B + |\mathbb{E}(M_1)| < \infty,$$

luego (N_n) satisface la hipótesis del Teorema de Convergencia de Martingalas, de donde $N_n \xrightarrow{\text{c.s.}} N_\infty$ con $\mathbb{E}(|N_\infty|) < \infty$. Entonces

$$M_n = N_n + A_n \xrightarrow{\text{c.s.}} N_\infty + A_\infty =: M_\infty,$$

y $\mathbb{E}(|M_\infty|) \leq \mathbb{E}(|N_\infty|) + \mathbb{E}(A_\infty) < \infty$.

□

Teorema 8.6.4 Convergencia de supermartingalas no negativas. Si $(M_n : n \geq 1)$ es una supermartingala que satisface $M_n \geq 0 \ \forall_{n\geq 1}$, entonces $M_n \xrightarrow{\text{c.s.}} M_\infty$ con $\mathbb{E}(M_\infty) \leq \mathbb{E}(M_1)$.

Note que $(-M_n)$ es una submartingala.

8.7. Aplicaciones de la Convergencia de Martingalas

Teorema 8.7.1. Sea $X_1, X_2, \ldots$ una martingala con $|X_{n+1} - X_n| \leq M < \infty$. Sean

$$C = \{\lim X_n \text{ existe y es finito}\}, \tag{8.23}$$
$$D = \{\limsup X_n = +\infty \text{ y } \liminf X_n = -\infty\}. \tag{8.24}$$

Entonces $P(C \cup D) = 1$.

Teorema 8.7.2 Segundo lema de Borel-Cantelli, II. Sea $\mathcal{F}_n$, $n \geq 0$, una filtración con $\mathcal{F}_0 = \{\varnothing, \Omega\}$ y sea B_n, $n \geq 1$, una sucesión de eventos con $B_n \in \mathcal{F}_n$. Entonces

$$\{B_n \text{ i.v.}\} = \left\{\sum_{n=1}^{\infty} P(B_n|\mathcal{F}_{n-1}) = \infty\right\}. \tag{8.25}$$

Teorema 8.7.3. Sean μ una medida finita y ν una medida de probabilidad en $(\Omega, \mathcal{F})$. Sean $\mathcal{F}_n \uparrow \mathcal{F}$ σ-álgebras (es decir, $\sigma(\cup\mathcal{F}_n) = \mathcal{F}$) y sean μ_n y ν_n las restricciones de μ y ν a $\mathcal{F}_n$. Suponga que $\mu_n \ll \nu_n$ para todo n. Sea $X_n = d\mu_n/d\nu_n$ y sea $X = \limsup X_n$. Entonces

$$\mu(A) = \int_A X\, d\nu + \mu(A \cap \{X = \infty\}). \tag{8.26}$$

Lema 8.7.1. X_n (definida en $(\Omega, \mathcal{F}, \nu)$) es una martingala respecto a $\mathcal{F}_n$.

Teorema 8.7.4 Dicotomía de Kakutani. Sean μ y ν medidas en el espacio de sucesiones $(\mathbb{R}^{\mathbb{N}}, \mathcal{R}^{\mathbb{N}})$ que hacen a las coordenadas $\xi_n(\omega) = \omega_n$ independientes. Sean $F_n(x) = \mu(\xi_n \leq x)$, $G_n(x) = \nu(\xi_n \leq x)$, y suponga que $F_n \ll G_n$ y que $q_n = dF_n/dG_n > 0$, G_n-c.s. Entonces $\mu \ll \nu$ o $\mu \perp \nu$, según

$$\prod_{m=1}^{\infty} \int \sqrt{q_m}\, dG_m > 0 \quad \text{o} \quad = 0. \tag{8.27}$$

Definición 8.7.1 Proceso de Galton-Watson. Sean ξ_i^n, $i, n \geq 1$, variables aleatorias i.i.d. no negativas con valores enteros. Se define una sucesión Z_n, $n \geq 0$, mediante $Z_0 = 1$ y

$$Z_{n+1} = \begin{cases} \xi_1^{n+1} + \cdots + \xi_{Z_n}^{n+1} & \text{si } Z_n > 0, \\ 0 & \text{si } Z_n = 0. \end{cases} \tag{8.28}$$

Z_n se llama un *proceso de Galton-Watson*. $p_k = P(\xi_i^n = k)$ se llama la *distribución de descendencia* y $\varphi(s) = \sum_{k\geq 0} p_k s^k$, $s \in [0,1]$, es su función generadora.

Lema 8.7.2. Sean $\mathcal{F}_n = \sigma(\xi_i^m : i \geq 1, 1 \leq m \leq n)$ y $\mu = E\xi_i^m \in (0, \infty)$. Entonces Z_n/μ^n es una martingala respecto a $\mathcal{F}_n$.

Teorema 8.7.5. Si $\mu < 1$, entonces $Z_n = 0$ para todo n suficientemente grande, por lo que $Z_n/\mu^n \to 0$.

Teorema 8.7.6. Si $\mu = 1$ y $P(\xi_i^m = 1) < 1$, entonces $Z_n = 0$ para todo n suficientemente grande.

Teorema 8.7.7. Suponga $\mu > 1$. Si $Z_0 = 1$, entonces $P(Z_n = 0 \text{ para algún } n) = \rho$, donde ρ es la única solución de $\varphi(\rho) = \rho$ en $[0, 1)$.

Teorema 8.7.8 Kesten-Stigum. $W = \lim Z_n/\mu^n$ no es $\equiv 0$ si y sólo si $\sum p_k k \log k < \infty$.

8.8. Martingalas Cuadrado Integrables

Teorema 8.8.1 Ortogonalidad de los incrementos de una martingala. Sea X_n una martingala con $EX_n^2 < \infty$ para todo n. Si $m \leq n$ y $Y \in \mathcal{F}_m$ tiene $EY^2 < \infty$, entonces

$$E((X_n - X_m)Y) = 0 \tag{8.29}$$

y por lo tanto, si $\ell < m < n$,

$$E((X_n - X_m)(X_m - X_\ell)) = 0. \tag{8.30}$$

Teorema 8.8.2 Fórmula de la varianza condicional. Si X_n es una martingala con $EX_n^2 < \infty$ para todo n,

$$E((X_n - X_m)^2|\mathcal{F}_m) = E(X_n^2|\mathcal{F}_m) - X_m^2. \tag{8.31}$$

Definición 8.8.1 Proceso creciente asociado. Sea X_n una martingala con $X_0 = 0$ y $EX_n^2 < \infty$ para todo n. Se escribe $X_n^2 = M_n + A_n$ con M_n martingala (descomposición de Doob), donde

$$A_n = \sum_{m=1}^{n} E(X_m^2|\mathcal{F}_{m-1}) - X_{m-1}^2 = \sum_{m=1}^{n} E((X_m - X_{m-1})^2|\mathcal{F}_{m-1}). \tag{8.32}$$

A_n se llama el *proceso creciente asociado* a X_n, y $A_\infty = \lim A_n$.

Teorema 8.8.3. Sea X_n una martingala con $X_0 = 0$ y $EX_n^2 < \infty$, y sea A_n su proceso creciente asociado. Entonces

$$E\left(\sup_m |X_m|^2\right) \leq 4EA_\infty. \tag{8.33}$$

Teorema 8.8.4. Con la notación anterior, $\lim_{n\to\infty} X_n$ existe y es finito c.s. en $\{A_\infty < \infty\}$.

Teorema 8.8.5. Con la notación anterior, sea $f \geq 1$ creciente con $\int_0^\infty f(t)^{-2}\,dt < \infty$. Entonces $X_n/f(A_n) \to 0$ c.s. en $\{A_\infty = \infty\}$.

Teorema 8.8.6 Segundo lema de Borel-Cantelli, III. Suponga que B_n está adaptada a $\mathcal{F}_n$ y sea $p_n = P(B_n|\mathcal{F}_{n-1})$. Entonces

$$\sum_{m=1}^{n} 1_{B_m} \Big/ \sum_{m=1}^{n} p_m \to 1 \quad \text{c.s. en } \left\{\sum_{m=1}^{\infty} p_m = \infty\right\}. \tag{8.34}$$

Teorema 8.8.7. Con la notación anterior,

$$E\left(\sup_n |X_n|\right) \leq 3EA_\infty^{1/2}. \tag{8.35}$$

8.9. Integrabilidad Uniforme y Convergencia en L^1

Definición 8.9.1 Integrabilidad uniforme. Una colección de variables aleatorias X_i, $i \in I$, se dice *uniformemente integrable* si

$$\lim_{M\to\infty}\left(\sup_{i\in I} E(|X_i|; |X_i| > M)\right) = 0. \tag{8.36}$$

Teorema 8.9.1. Dados un espacio de probabilidad $(\Omega, \mathcal{F}_o, P)$ y $X \in L^1$, la colección $\{E(X|\mathcal{F}) : \mathcal{F}$ es una σ-álgebra $\subset \mathcal{F}_o\}$ es uniformemente integrable.

Teorema 8.9.2. Sea $\varphi \geq 0$ cualquier función con $\varphi(x)/x \to \infty$ cuando $x \to \infty$, por ejemplo $\varphi(x) = x^p$ con $p > 1$ o $\varphi(x) = x\log^+ x$. Si $E\varphi(|X_i|) \leq C$ para todo $i \in I$, entonces $\{X_i : i \in I\}$ es uniformemente integrable.

Teorema 8.9.3. Suponga que $E|X_n| < \infty$ para todo n. Si $X_n \to X$ en probabilidad, entonces los siguientes enunciados son equivalentes:

(i) $\{X_n : n \geq 0\}$ es uniformemente integrable.

(ii) $X_n \to X$ en L^1.

(iii) $E|X_n| \to E|X| < \infty$.

Teorema 8.9.4. Para una submartingala, los siguientes enunciados son equivalentes:

(i) Es uniformemente integrable.

(ii) Converge c.s. y en L^1.

(iii) Converge en L^1.

Lema 8.9.1. Si las variables aleatorias integrables $X_n \to X$ en L^1, entonces

$$E(X_n; A) \to E(X; A). \tag{8.37}$$

Lema 8.9.2. Si una martingala $X_n \to X$ en L^1, entonces $X_n = E(X|\mathcal{F}_n)$.

Teorema 8.9.5. Para una martingala, los siguientes enunciados son equivalentes:

(i) Es uniformemente integrable.

(ii) Converge c.s. y en L^1.

(iii) Converge en L^1.

(iv) Existe una variable aleatoria integrable X tal que $X_n = E(X|\mathcal{F}_n)$.

Teorema 8.9.6. Suponga que $\mathcal{F}_n \uparrow \mathcal{F}_\infty$, es decir, $\mathcal{F}_n$ es una sucesión creciente de σ-álgebras y $\mathcal{F}_\infty = \sigma(\cup_n \mathcal{F}_n)$. Cuando $n \to \infty$,

$$E(X|\mathcal{F}_n) \to E(X|\mathcal{F}_\infty) \quad \text{c.s. y en } L^1. \tag{8.38}$$

Teorema 8.9.7 Ley 0-1 de Lévy. Si $\mathcal{F}_n \uparrow \mathcal{F}_\infty$ y $A \in \mathcal{F}_\infty$, entonces

$$E(1_A|\mathcal{F}_n) \to 1_A \quad \text{c.s.} \tag{8.39}$$

Teorema 8.9.8 Teorema de convergencia dominada para esperanzas condicionales. Suponga que $Y_n \to Y$ c.s. y $|Y_n| \leq Z$ para todo n, donde $EZ < \infty$. Si $\mathcal{F}_n \uparrow \mathcal{F}_\infty$, entonces

$$E(Y_n|\mathcal{F}_n) \to E(Y|\mathcal{F}_\infty) \quad \text{c.s.} \tag{8.40}$$

8.10. Martingalas hacia Atrás y Sucesiones Intercambiables

Definición 8.10.1 Martingala hacia atrás. Una *martingala hacia atrás* es una martingala indexada por los enteros negativos, es decir, X_n, $n \leq 0$, adaptada a una sucesión creciente de σ-álgebras $\mathcal{F}_n$ con

$$E(X_{n+1}|\mathcal{F}_n) = X_n \quad \text{para } n \leq -1. \tag{8.41}$$

Teorema 8.10.1. $X_{-\infty} = \lim_{n\to-\infty} X_n$ existe c.s. y en L^1.

Teorema 8.10.2. Si $X_{-\infty} = \lim_{n\to-\infty} X_n$ y $\mathcal{F}_{-\infty} = \cap_n \mathcal{F}_n$, entonces $X_{-\infty} = E(X_0|\mathcal{F}_{-\infty})$.

Teorema 8.10.3. Si $\mathcal{F}_n \downarrow \mathcal{F}_{-\infty}$ cuando $n \downarrow -\infty$ (es decir, $\mathcal{F}_{-\infty} = \cap_n \mathcal{F}_n$), entonces

$$E(Y|\mathcal{F}_n) \to E(Y|\mathcal{F}_{-\infty}) \quad \text{c.s. y en } L^1. \tag{8.42}$$

Teorema 8.10.4 Teorema del escrutinio (versión general). Sean $\{\xi_j, 1 \leq j \leq n\}$ variables aleatorias i.i.d. no negativas con valores enteros, $S_k = \xi_1 + \cdots + \xi_k$ y $G = \{S_j < j \text{ para } 1 \leq j \leq n\}$.

Entonces

$$P(G|S_n) = \left(1 - \frac{S_n}{n}\right)^+. \tag{8.43}$$

Definición 8.10.2 σ-álgebra intercambiable. Sea $\Omega = \{(\omega_1, \omega_2, ...) : \omega_i \in S\}$, $\mathcal{F} = \mathcal{S} \times \mathcal{S} \times \cdots$ y $X_n(\omega) = \omega_n$. Sea $\mathcal{E}_n$ la σ-álgebra generada por los eventos que son invariantes bajo permutaciones que dejan fijos $n+1, n+2, ...$, y sea $\mathcal{E} = \cap_n \mathcal{E}_n$ la *σ-álgebra intercambiable*.

Teorema 8.10.5 Ley 0-1 de Hewitt-Savage. Si $X_1, X_2, ...$ son i.i.d. y $A \in \mathcal{E}$, entonces $P(A) \in \{0, 1\}$.

Lema 8.10.1. Suponga que $X_1, X_2, ...$ son i.i.d. y sea

$$A_n(\varphi) = \frac{1}{(n)_k} \sum_i \varphi(X_{i_1}, ..., X_{i_k}), \tag{8.44}$$

donde la suma es sobre todas las sucesiones de enteros distintos $1 \leq i_1, ..., i_k \leq n$ y $(n)_k = n(n-1)\cdots(n-k+1)$ es el número de tales sucesiones. Si φ es acotada, entonces $A_n(\varphi) \to E\varphi(X_1, ..., X_k)$ c.s.

Definición 8.10.3 Sucesión intercambiable. Una sucesión $X_1, X_2, ...$ se dice *intercambiable* si para cada n y cada permutación π de $\{1, ..., n\}$, $(X_1, ..., X_n)$ y $(X_{\pi(1)}, ..., X_{\pi(n)})$ tienen la misma distribución.

Teorema 8.10.6 Teorema de de Finetti. Si $X_1, X_2, ...$ son intercambiables, entonces condicionalmente a $\mathcal{E}$, $X_1, X_2, ...$ son independientes e idénticamente distribuidas.

Teorema 8.10.7. Si $X_1, X_2, ...$ son intercambiables y toman valores en $\{0, 1\}$, entonces existe una distribución de probabilidad F en $[0, 1]$ tal que

$$P(X_1 = 1, ..., X_k = 1, X_{k+1} = 0, ..., X_n = 0) = \int_0^1 \theta^k (1-\theta)^{n-k}\, dF(\theta). \tag{8.45}$$

8.11. Teoremas de Paro Opcional y Aplicaciones

Teorema 8.11.1. Si X_n es una submartingala uniformemente integrable, entonces para cualquier tiempo de paro N, $X_{N \wedge n}$ es uniformemente integrable.

Teorema 8.11.2. Si $E|X_N| < \infty$ y $X_n 1_{(N>n)}$ es uniformemente integrable, entonces $X_{N\wedge n}$ es uniformemente integrable y por lo tanto $EX_0 \leq EX_N$.

Teorema 8.11.3. Si X_n es una submartingala uniformemente integrable, entonces para cualquier tiempo de paro $N \leq \infty$ se tiene $EX_0 \leq EX_N \leq EX_\infty$, donde $X_\infty = \lim X_n$.

Teorema 8.11.4. Si X_n es una supermartingala no negativa y $N \leq \infty$ es un tiempo de paro, entonces $EX_0 \geq EX_N$, donde $X_\infty = \lim X_n$.

Teorema 8.11.5. Suponga que X_n es una submartingala y $E(|X_{n+1} - X_n| \,|\mathcal{F}_n) \leq B$ c.s. Si N es un tiempo de paro con $EN < \infty$, entonces $X_{N\wedge n}$ es uniformemente integrable y por lo tanto $EX_N \geq EX_0$.

Teorema 8.11.6 Ecuación de Wald. Si $\xi_1, \xi_2, ...$ son i.i.d. con $E\xi_i = \mu$, $S_n = \xi_1 + \cdots + \xi_n$ y N es un tiempo de paro con $EN < \infty$, entonces $ES_N = \mu EN$.

Teorema 8.11.7 Caminata aleatoria simétrica simple. Considere la caminata aleatoria simple simétrica, es decir, $P(\xi_i = 1) = P(\xi_i = -1) = 1/2$. Suponga que $S_0 = x$, $a < x < b$, y sea $N = \text{mín}\{n : S_n \notin (a, b)\}$. Escribiendo un subíndice para recordar el punto de partida:

(a) $P_x(S_N = a) = \dfrac{b-x}{b-a}, \qquad P_x(S_N = b) = \dfrac{x-a}{b-a}.$

(b) $E_0 N = -ab$ y por lo tanto $E_x N = (b-x)(x-a)$.

Teorema 8.11.8. Sea S_n una caminata aleatoria simétrica con $S_0 = 0$ y sea $T_1 = \text{mín}\{n : S_n = 1\}$. Entonces

$$Es^{T_1} = \frac{1 - \sqrt{1-s^2}}{s}. \tag{8.46}$$

Invirtiendo la función generadora se obtiene

$$P(T_1 = 2n-1) = \frac{1}{2n-1} \cdot \frac{(2n)!}{n!\, n!} 2^{-2n}. \tag{8.47}$$

Teorema 8.11.9 Caminata aleatoria simple asimétrica. Considere el caso en que $P(\xi_i = 1) = p$ y $P(\xi_i = -1) = q \equiv 1 - p$ con $p \neq q$.

(a) Si $\varphi(y) = \{(1-p)/p\}^y$, entonces $\varphi(S_n)$ es una martingala.

(b) Si $T_z = \text{ínf}\{n : S_n = z\}$, entonces para $a < x < b$

$$P_x(T_a < T_b) = \frac{\varphi(b) - \varphi(x)}{\varphi(b) - \varphi(a)}, \qquad P_x(T_b < T_a) = \frac{\varphi(x) - \varphi(a)}{\varphi(b) - \varphi(a)}. \tag{8.48}$$

Para las dos últimas partes suponga que $1/2 < p < 1$.

(c) Si $a < 0$, entonces $P(\text{mín}_n\, S_n \leq a) = P(T_a < \infty) = \{(1-p)/p\}^{-a}$.

(d) Si $b > 0$, entonces $P(T_b < \infty) = 1$ y $ET_b = b/(2p-1)$.

8.12. Combinatoria de la Caminata Aleatoria Simple

Proposición 8.12.1. El número de caminos de $(0,0)$ a (n,x) es

$$N_{n,x} = \binom{n}{a}, \tag{8.49}$$

donde $a = (n+x)/2$, si $-n \leq x \leq n$ y $n-x$ es par; en otro caso el número de caminos es 0.

Teorema 8.12.1 Principio de reflexión (conteo de caminos). Si $x, y > 0$, entonces el número de caminos de $(0,x)$ a (n,y) que son 0 en algún tiempo es igual al número de caminos de $(0,-x)$ a (n,y).

Teorema 8.12.2 Teorema del escrutinio (elecciones). Suponga que en una elección el candidato A obtiene α votos y el candidato B obtiene β votos, donde $\beta < \alpha$. La probabilidad de que durante todo el conteo A siempre vaya adelante de B es $(\alpha-\beta)/(\alpha+\beta)$.

Lema 8.12.1. $P(S_1 \neq 0, \ldots, S_{2n} \neq 0) = P(S_{2n} = 0)$.

Lema 8.12.2. Sea $u_{2m} = P(S_{2m} = 0)$ y $L_{2n} = \sup\{m \leq 2n : S_m = 0\}$. Entonces $P(L_{2n} = 2k) = u_{2k}u_{2n-2k}$.

Teorema 8.12.3 Ley del arcoseno para la última visita a 0. Para $0 < a < b < 1$,

$$P(a \leq L_{2n}/2n \leq b) \to \int_a^b \pi^{-1}(x(1-x))^{-1/2}\,dx. \tag{8.50}$$

Teorema 8.12.4 Ley del arcoseno para el tiempo sobre 0. Sea π_{2n} el número de segmentos $(k-1, S_{k-1}) \to (k, S_k)$ que están sobre el eje (es decir, en $\{(x,y) : y \geq 0\}$) y sea $u_m = P(S_m = 0)$. Entonces

$$P(\pi_{2n} = 2k) = u_{2k}u_{2n-2k} \tag{8.51}$$

y en consecuencia, si $0 < a < b < 1$,

$$P(a \leq \pi_{2n}/2n \leq b) \to \int_a^b \pi^{-1}(x(1-x))^{-1/2}\,dx. \tag{8.52}$$

9

Martingalas en Tiempo Continuo

9.1. Martingalas en Tiempo Continuo

Definición 9.1.1 Càdlàg. Un proceso estocástico $(X_t : t \geq 0)$ se dice continuo (respectivamente càdlàg; que es un acrónimo del francés *continu à droite, limites à gauche*) si existe $\Omega_0 \subseteq \Omega$ con $\mathbb{P}(\Omega_0) = 1$, tal que $\forall_{\omega \in \Omega_0}$, las trayectorias $t \mapsto X_t(\omega)$ son continuas (respectivamente continuas por derecha con límites por izquierda) como funciones de $[0, \infty)$ en $\mathbb{R}$.

Definición 9.1.2 Filtración en tiempo continuo. Una filtración en tiempo continuo es una colección $(\mathcal{F}_t : t \geq 0)$ de σ-álgebras de Ω tales que

$$\mathcal{F}_s \subseteq \mathcal{F}_t \subseteq \mathcal{F}, \qquad \forall\, s \leq t.$$

Definición 9.1.3 Filtración natural. La **filtración natural** de un proceso $(X_t : t \geq 0)$ es aquella para la cual $\mathcal{F}_t$ es la σ-álgebra generada por las variables aleatorias $(X_s : 0 \leq s \leq t)$.

Definición 9.1.4 ($\mathcal{F}_t$-adaptado). Dada una filtración $(\mathcal{F}_t : t \geq 0)$, un proceso estocástico $(Y_t : t \geq 0)$ se dice $(\mathcal{F}_t)$-adaptado si para cada $t \geq 0$, la variable aleatoria Y_t es $\mathcal{F}_t$-medible.

Definición 9.1.5 ($\mathcal{F}_t$**-tiempo de parada).** Considere una filtración $(\mathcal{F}_t : t \geq 0)$. Un $(\mathcal{F}_t)$-tiempo de parada es una variable aleatoria $\tau : \Omega \to [0, \infty]$ que satisface $\{\tau \leq t\} \in \mathcal{F}_t$, $\forall_{t\geq 0}$.

Definición 9.1.6 Proceso detenido. Considere una filtración $(\mathcal{F}_t : t \geq 0)$. Sea τ un $(\mathcal{F}_t)$-tiempo de parada y $Y = (Y_t : t \geq 0)$ un proceso $(\mathcal{F}_t)$-adaptado. El proceso detenido de Y por τes el proceso estocástico $Y^\tau = (Y_{\tau\wedge t} : t \geq 0)$ definido por

$$Y_{\tau\wedge t}(\omega) := Y_{\tau(\omega)\wedge t}(\omega), \qquad \forall_{\omega\in\Omega, t\geq 0}.$$

Definición 9.1.7 ($\mathcal{F}_t$**-martingala).** Un proceso estocástico $(M_t : t \geq 0)$ se dice una $(\mathcal{F}_t)$-martingala si cumple con lo siguiente

1. Cada M_t es integrable.
2. El proceso es $(\mathcal{F}_t)$-adaptado.
3. Se cumple la identidad de martingala:

$$\mathbb{E}(M_t \mid \mathcal{F}_s) = M_s, \qquad \forall_{0\leq s\leq t<\infty}.$$

Si reemplazamos "=" por "$\leq$" (respectivamente "$\geq$") se dice que $(M_t : t \geq 0)$ es una $(\mathcal{F}_t)$-supermartingala (respectivamente una $(\mathcal{F}_t)$-submartingala).

Teorema 9.1.1 Versión càdlàg de martingalas continuas. Toda martingala en tiempo continuo posee una versión càdlàg.

Requiere un nivel muy avanzado para su demostracion.

Teorema 9.1.2 Parada Opcional de Doob. Si $(M_t : t \geq 0)$ es una martingala y τ un tiempo de parada, el proceso detenido $(M_{\tau\wedge t} : t \geq 0)$ es una martingala.

Proposición 9.1.1 Preservación de la clase bajo detención. Si $(M_t : t \geq 0)$ es una submartingala (respectivamente supermartingala) y τ un tiempo de parada, entonces el proceso detenido $(M_{\tau\wedge t} : t \geq 0)$ es una submartingala (respectivamente supermartingala).

Teorema 9.1.3. Sea X_t una martingala continua por la derecha adaptada a una filtración continua por la derecha. Si T es un tiempo de paro acotado, entonces $EX_T = EX_0$.

Teorema 9.1.4 Desigualdad Maximal de Doob. Si $(M_t : t \geq 0)$ es una submartingala no-negativa que es p-integrable con $p \geq 1$, entonces $\forall_{\lambda>0,T>0}$ se tiene que

$$\lambda^p \, \mathbb{P}\left(\sup_{0\leq t\leq T} M_t \geq \lambda \right) \leq \mathbb{E}(M_T^p)\,. \tag{9.1}$$

Más aún, si $p > 1$, entonces $\forall_{T>0}$ se tiene que:

$$\mathbb{E}\left[\left(\sup_{0\le t\le T} M_t\right)^p\right] \le \left(\frac{p}{p-1}\right)^p \mathbb{E}(M_T^p)\,. \tag{9.2}$$

Teorema 9.1.5 Convergencia de Martingalas. Sea $(M_t : t \ge 0)$ una martingala que satisface $\mathbb{E}(|M_t|) \le B\ \forall_{t\ge 0}$ para cierto $B > 0$. Entonces existe una variable aleatoria M_∞ con $\mathbb{E}(|M_\infty|) \le B$ tal que

$$\mathbb{P}\Big(\lim_{t\to\infty} M_t = M_\infty\Big) = 1. \tag{9.3}$$

Si más aún se tiene que $\mathbb{E}(|M_t|^p) \le B\ \forall_{t\ge 0}$, para $p > 1$, entonces $\mathbb{E}(|M_\infty|^p) \le B$ y además

$$\lim_{t\to\infty} \mathbb{E}(|M_t - M_\infty|^p) = 0. \tag{9.4}$$

9.2. Procesos de Poisson

Definición 9.2.1 Construcción. Sean $T_1, T_2, ...$ i.i.d. con distribución exponencial de parámetro $\lambda > 0$. Defina $J_0 = 0$, $J_n = T_1 + \cdots + T_n\ \forall_{n\ge 1}$. Para cada $t \ge 0$, defina $N_t : \Omega \to \mathbb{N}$ por

$$N_t(\omega) = n \quad \text{si} \quad J_n(\omega) \le t < J_{n+1}(\omega).$$

El proceso estocástico $(N_t : t \ge 0)$ se conoce como el proceso de Poisson de parámetro $\lambda > 0$.

Proposición 9.2.1 Divergencia de los tiempos de llegada. $\mathbb{P}(\lim_{n\to\infty} J_n = \infty) = 1$.

Demostración. Por el teorema de limite central $\frac{J_n}{n}$ converge a la media de las i.i.d. en cuyo caso es $O(n)$, y por lo tanto diverge.

□

Proposición 9.2.2 Distribución de Poisson de los conteos. Para todo $t \ge 0$, N_t tiene distribución de Poisson con parámetro λt, es decir

$$\mathbb{P}(N_t = n) = \frac{e^{-\lambda t}(\lambda t)^n}{n!}. \tag{9.5}$$

Demostración. Note que la suma de exponenciales i.i.d. de parametro λ tiene distribucion $J_n \sim \text{Gamma}(n, \lambda)$, de forma que

$$\mathbb{P}(J_n \le t) = \int_0^t \frac{\lambda^n x^{n-1} e^{-\lambda x}}{(n-1)!}\, dx = \frac{\Gamma(n, \lambda t)}{\Gamma(n)}$$

donde $\Gamma(n, \lambda t)$ es la misma integral que la $\Gamma(n)$ solo que con el limite inferior en $t\lambda$ en lugar de ∞, de la cual (integrando por partes) se puede demostrar que $\Gamma(n+1, \lambda t) = n\Gamma(n, \lambda t) + (\lambda t)^n e^{-\lambda t}$, de forma que

$$\mathbb{P}(N_t = n) = \mathbb{P}(N_t \ge n) - \mathbb{P}(N_t \ge n+1) = \mathbb{P}(J_n \le t) - \mathbb{P}(J_{n+1} \le t) = \frac{\Gamma(n, \lambda t)}{\Gamma(n)} - \frac{\Gamma(n+1, \lambda t)}{\Gamma(n+1)}$$

$$= \frac{n\Gamma(n, \lambda t) + (\lambda t)^n e^{-\lambda t}}{n\Gamma(n)} - \frac{\Gamma(n, \lambda t)}{\Gamma(n)} = \frac{e^{-\lambda t}(\lambda t)^n}{n!}$$

□

Otra forma de hacerlo es

Demostración. Suponga que $n \geq 1$. De la definición se tiene que

$$\mathbb{P}(N_t = n) = \mathbb{P}(J_n \leq t < J_n + T_{n+1}) = \mathbb{P}((J_n, T_{n+1}) \in B),$$

donde $B = \{(x, y) : 0 \leq x \leq t < x + y\}$. Como $T_1, T_2, \ldots$ son i.i.d. con distribución exponencial de parámetro λ, entonces $J_n = T_1 + \cdots + T_n \sim \text{Gamma}(n, \lambda)$ y es independiente de T_{n+1}. Por tanto la densidad conjunta de (J_n, T_{n+1}) es el producto de sus densidades marginales, y

$$\mathbb{P}(N_t = n) = \frac{\lambda^{n+1}}{(n-1)!} \iint_B x^{n-1} e^{-\lambda x} e^{-\lambda y}\, dx\, dy = \frac{\lambda^{n+1}}{(n-1)!} \int_0^t x^{n-1} e^{-\lambda x} \int_{t-x}^{\infty} e^{-\lambda y}\, dy\, dx$$

$$= \frac{\lambda^{n+1}}{(n-1)!} \int_0^t x^{n-1} e^{-\lambda x} \cdot \frac{e^{-\lambda(t-x)}}{\lambda}\, dx = \frac{\lambda^n e^{-\lambda t}}{(n-1)!} \int_0^t x^{n-1}\, dx = \frac{e^{-\lambda t}(\lambda t)^n}{n!},$$

□

Lema 9.2.1 Propiedad de memoria en el proceso de Poisson. Para todo $t > 0$, $s \geq 0$, $n \in \mathbb{N}$,

$$\mathbb{P}(J_{n+1} > t + s \mid N_t = n) = \mathbb{P}(T_1 > s) = e^{-\lambda s}. \tag{9.6}$$

Demostración. Si $n = 0$, de lo anterior y la propiedad de pérdida de memoria se tiene que

$$\mathbb{P}(J_1 > t + s \mid N_t = 0) = \mathbb{P}(T_1 > t + s \mid T_1 > t) = \mathbb{P}(T_1 > s) = e^{-\lambda s}.$$

Para $n \geq 1$

$$\mathbb{P}(N_t = n, J_{n+1} > t + s) = \frac{\lambda^{n+1}}{(n-1)!} \int_0^t x^{n-1} e^{-\lambda x} \int_{t+s-x}^{\infty} e^{-\lambda y}\, dy\, dx.$$

Evaluando

$$= \frac{\lambda^n e^{-\lambda(t+s)}}{(n-1)!} \int_0^t x^{n-1}\, dx = \frac{e^{-\lambda(t+s)}(\lambda t)^n}{n!}.$$

Finalmente,

$$\mathbb{P}(J_{n+1} > t + s \mid N_t = n) = \frac{\mathbb{P}(N_t = n, J_{n+1} > t + s)}{\mathbb{P}(N_t = n)} = \frac{e^{-\lambda(t+s)}(\lambda t)^n / n!}{e^{-\lambda t}(\lambda t)^n / n!} = e^{-\lambda s}.$$

□

Lema 9.2.2 Propiedad de regeneración de los tiempos de llegada. Para todo $n \in \mathbb{N}$, $m \geq 2$, $t \geq 0$, la distribución condicional del vector aleatorio $(J_{n+1} - t,\, T_{n+2},\, \ldots,\, T_{n+m})$ dado $\{N_t = n\}$ es igual a la distribución del vector aleatorio $(T_1, T_2, \ldots, T_m)$.

Demostración. Note que por independencia

$$\mathbb{P}(J_{n+1} - t > s_1, T_{n+2} > s_2, T_{n+m} > s_m \mid N_t = n) = \frac{\mathbb{P}(J_t \leq t, J_{n+1} - t > s_1, T_{n+2} > s_2, T_{n+m} > s_m)}{\mathbb{P}(N_t = n)}$$

$$\frac{\mathbb{P}(J_t \leq t, J_{n+1} - t > s_1)\mathbb{P}(T_{n+2} > s_2, T_{n+m} > s_m)}{\mathbb{P}(N_t = n)} = \mathbb{P}(T_1 > s_1)\mathbb{P}(T_{n+2} > s_2, T_{n+m} > s_m)$$

$$= \mathbb{P}(T_1 > s_1, T_m > s_m)$$

□

Corolario 9.2.1 Propiedad de regeneración de los conteos. Para todo $n \in \mathbb{N}$, $m \geq 2$, $t, s \geq 0$,

$$\mathbb{P}(J_{n+m} \leq t+s < J_{n+m+1} \mid N_t = n) = \mathbb{P}(J_m \leq s < J_{m+1}). \tag{9.7}$$

Demostración.

$$\mathbb{P}(J_{n+m} \leq t+s < J_{n+m+1} \mid N_t = n) = \frac{\mathbb{P}(J_{n+m} \leq t+s < J_{n+m+1},\ N_t = n)}{\mathbb{P}(N_t = n)}$$

$$= \frac{\mathbb{P}(J_{n+1} - t + T_{n+2} + \cdots + T_{n+m} \leq s < J_{n+1} - t + T_{n+2} + \cdots + T_{n+m+1},\ J_n \leq t < J_{n+1})}{\mathbb{P}(N_t = n)}$$

$$= \mathbb{P}(J_{n+1} - t + T_{n+2} + \cdots + T_{n+m} \leq s < J_{n+1} - t + T_{n+2} + \cdots + T_{n+m+1} \mid N_t = n)$$

$$= \mathbb{P}(T_1 + \cdots + T_m \leq s < T_1 + \cdots + T_{m+1}) = \mathbb{P}(J_m \leq s < J_{m+1}),$$

donde el último paso usa que $J_{n+1} - t \mid \{N_t = n\} \sim \text{Exp}(\lambda)$ dado el lema anterior.

□

Definición 9.2.2 Incrementos. Sea $(X_t : t \geq 0)$ un proceso estocástico con $X_0 = 0$ c.s. Se dice que $(X_t : t \geq 0)$ tiene incrementos estacionarios si

$$\forall_{t,s \geq 0} \quad X_{t+s} - X_t \overset{d}{=} X_s. \tag{9.8}$$

$(X_t : t \geq 0)$ tiene incrementos independientes si para cada $k \in \mathbb{N}$ y cada escogencia $0 \leq t_0 < t_1 < \cdots < t_k$, las variables aleatorias $X_{t_0}, X_{t_1} - X_{t_0}, \ldots, X_{t_k} - X_{t_{k-1}}$ son independientes.

Lema 9.2.3 Incrementos estacionarios del proceso de Poisson. El proceso de Poisson $(N_t : t \geq 0)$ tiene incrementos estacionarios.

Demostración. Note que por el colorario anterior se tiene que

$$\mathbb{P}(N_t = n, N_{t+s} - N_t = m) = \mathbb{P}(N_t = n, N_{t+s} = m+n) = \mathbb{P}(N_t = n)\mathbb{P}(N_{t+s} = m+n \mid N_t = n)$$

$$\mathbb{P}(N_t = n)\mathbb{P}(J_{n+m} \leq t+s < J_{n+m+1} \mid N_t = n) = \mathbb{P}(N_t = n)\mathbb{P}(J_m \leq s < J_{m+1}) = \mathbb{P}(N_t = n)\mathbb{P}(N_s = m)$$

□

Lema 9.2.4 Incrementos independientes del proceso de Poisson. El proceso de Poisson $(N_t : t \geq 0)$ tiene incrementos independientes.

Demostración. Por el lema anterior se tiene que

$$\mathbb{P}(N_{t_0} = m_0, N_{t_1} - N_{t_0} = m_1, \ldots, N_{t_n} - N_{t_{n-1}} = m_n)$$

$$= \mathbb{P}(N_{t_0} = m_0)\mathbb{P}(N_{s_1} = m_1) \ldots \mathbb{P}(N_{s_n} = m_n)$$

$$\mathbb{P}(N_{t_0} = m_0)\mathbb{P}(N_{t_1} - N_{t_0} = m_1) \ldots \mathbb{P}(N_{t_n} - N_{t_{n-1}} = m_n)$$

□

Definición 9.2.3 Proceso de Lévy. Un proceso estocástico $(L_t : t \geq 0)$ se llama un proceso de Lévy si cumple con lo siguiente:

1. $L_0 = 0$ c.s.
2. $(L_t : t \geq 0)$ tiene incrementos estacionarios e independientes.
3. $(L_t : t \geq 0)$ es un proceso càdlàg.

Teorema 9.2.1 Caracterización del proceso de Poisson como proceso de Lévy. Todo proceso de Poisson $(N_t : t \geq 0)$ es un proceso de Lévy para el cual cada N_t tiene distribución de Poisson de parámetro λt.

Lema 9.2.5 Recíproco de la caracterización de Poisson. Sea $N = (N_t : t \geq 0)$ un proceso de Lévy tal que $N_t \sim \text{Poisson}(\lambda t)$ para algún $\lambda > 0$. Entonces N es un proceso de Poisson en el sentido ya definido, existen tiempos de llegada $J_0 = 0$, $J_n(\omega) = \text{ínf}\{t > 0 : N_t(\omega) = n\}$ con $J_n \sim \text{Gamma}(n, \lambda)$, y los interarribos $T_n = J_n - J_{n-1}$ son i.i.d. con distribución exponencial de parámetro λ.

No se demuestran

Definición 9.2.4 Proceso de saltos. Si $(X_t : t \geq 0)$ es un proceso càdlàg, para cada $t \geq 0$ definimos el salto en tiempo t como $\Delta X_t = X_t - X_{t-}$, donde $X_{t-}(\omega)$ es el límite por la izquierda de la función $s \mapsto X_s(\omega)$ en t. El proceso de saltos se define como $\Delta X = (\Delta X_t : t \geq 0)$.

Lema 9.2.6 Saltos unitarios en el proceso de Poisson. Si $(N_t : t \geq 0)$ es de Poisson, el proceso de salto $(\Delta N_t : t \geq 0)$ solamente toma los valores 0 y 1.

Voy a intentar ser mas formal xd.

Demostración. Dado que el proceso $N_t \in \mathbb{N}$ es claro que $\Delta N_t \in \mathbb{N}$. Ahora, suponga que $\Delta N_t \geq 2$ con $N_t = n$ para algún n, lo que es equivalente a decir que $J_n = J_{n+1} = t$ (si el $J_n < t$ entonces $N_{t^-} = n - 1$, lo que no cumpliría con la hipótesis) para algún n, en cuyo caso $\mathbb{P}(T_{n+1} = 0) = 0$ dado que $T_i \sim \text{Exp}(\lambda)$, entonces iterando sobre n tenemos que

$$\mathbb{P}(\Delta N_t \geq 1 \text{ para algun } t) \leq \sum_{n=1}^{\infty} \mathbb{P}(T_{n+1} = 0) = 0$$

Por lo tanto $\Delta N_t \in \{0, 1\}$ c.s. $\forall_t$.

□

Lema 9.2.7 Ausencia de saltos en tiempos fijos de Lévy. Si $L = (L_t : t \geq 0)$ es un proceso de Lévy, entonces para todo $t > 0$ se cumple que $\Delta L_t = 0$ casi seguramente.

Demostración. Note que por la continuidad en probabilidad del proceso, se tiene que

$$\lim_{s \to t} \mathbb{P}(|L_s - L_t| > \varepsilon) = 0$$

de forma que si $s \nearrow t$, se tiene que

$$\mathbb{P}(|L_{t^-} - L_t| > \varepsilon) \lim_{s \nearrow t} \mathbb{P}(|L_s - L_t| > \varepsilon) = 0, \quad \forall_\varepsilon > 0.$$

en cuyo caso $\Delta L_t 0$ c.s.

□

Teorema 9.2.2 Caracterización de procesos de Lévy con saltos unitarios. Si $(L_t : t \geq 0)$ es un proceso de Lévy que toma valores en $\mathbb{N}$, cuyas trayectorias son crecientes (c.s.), y tal que $(\Delta L_t : t \geq 0)$ solamente toma los valores 0 y 1, entonces L es un proceso de Poisson de la forma ya definida.

Demostración. Tome $T_1 = \text{ínf}\{t > 0 : L_t \geq 1\}$ y $T_{n-1} = \text{ínf}\{t > 0 : L_t - L_{T_{n-1}} \geq 1\}$, de forma que se puede ver que $f(t) := \mathbb{P}(T_1 > t) = \mathbb{P}(L_t = 0)$ por los incrementos independientes y estacionarios se tiene que

$$f(t+s) = \mathbb{P}(L_{t+s} = 0) = \mathbb{P}(L_t = 0, L_s = 0) = f(t)f(s)$$

por lo que $f(\cdot)$ satisface la ecuación de Cauchy $f(t+s) = f(t)f(s)$ donde $f(0) = \mathbb{P}(L_0 = 0) = 1$, de forma que dado que L es cadlag, es continuo en probabilidad, de forma que $f(\cdot)$ es continua y se cumple que $f(t) = e^{-\lambda t}$ para algún λ. En cuyo casi $T_1 \sim \text{Exp}(\lambda)$.

Ahora, note que T_n es un tiempo de llegada pues $\{T_n \leq t\} = \{L_t \geq n\} \in \mathcal{F}_t$. Como los incrementos de L son independientes y estacionarios, el tiempo entre dos llegadas consecutivas, $\tau_n = T_n - T_{n-1}$, tiene la misma distribución que el primer tiempo de llegada, es decir, $\tau_n \sim \text{Exp}(\lambda)$. Además, la independencia de los incrementos garantiza que las variables $\tau_1, \ldots, \tau_n$ son independientes entre sí. En consecuencia, los $\{\tau_n\}$ son i.i.d. $\text{Exp}(\lambda)$, y L es un proceso de Poisson de tasa λ.

□

Lema 9.2.8 Martingala de Lévy con media cero. Suponga que $(L_t : t \geq 0)$ es un proceso de Lévy con media 0, es decir $\mathbb{E}(L_t) = 0 \ \forall\, t > 0$, y que $(\mathcal{F}_t : t \geq 0)$ es su filtración natural. Entonces $(L_t : t \geq 0)$ es una $(\mathcal{F}_t)$-martingala.

Demostración. Tome $0 \leq s \leq t$, entonces por independencia de los procesos se sigue que

$$\mathbb{E}(L_t \mid \mathcal{F}_s) = \mathbb{E}(L_t - L_s + L_s \mid \mathcal{F}_s) = \mathbb{E}(L_t - L_s) + L_s = L_s$$

□

Corolario 9.2.2 Martingala compensada del proceso de Poisson. Suponga que $(N_t : t \geq 0)$ es de Poisson y $(\mathcal{F}_t : t \geq 0)$ su filtración natural. Entonces, el proceso compensado de Poisson $(N_t - \lambda t : t \geq 0)$ es una $(\mathcal{F}_t)$-martingala.

Demostración. Realizando la misma analogía que lo anterior se tiene que

$$\mathbb{E}(N_t - t\lambda \mid \mathcal{F}_s) = N_s - t\lambda + \mathbb{E}(N_t - N_s) = N_s - t\lambda + t\lambda - s\lambda.$$

Utilizando el hecho que la suma de Poisson es Poisson.

□

9.3. Procesos Compuestos de Poisson

Definición 9.3.1 Proceso compuesto de Poisson. Sea $(N_t : t \geq 0)$ un proceso de Poisson con parámetro $\lambda > 0$ y sean $X_1, X_2, \ldots$ i.i.d. que son independientes de $(N_t : t \geq 0)$. Sea $S_0 = 0$ y $S_n = X_1 + \cdots + X_n$ para $n \geq 1$. El proceso compuesto de Poisson es el proceso $(Y_t : t \geq 0)$ definido

por

$$Y_t(\omega) = S_{N_t(\omega)}(\omega) := \sum_{k=1}^{N_t(\omega)} X_k(\omega), \tag{9.9}$$

donde la suma se interpreta como 0 si $N_t(\omega) = 0$.

Teorema 9.3.1 Proceso compuesto de Poisson como proceso de Lévy. El proceso compuesto de Poisson $(Y_t : t \geq 0)$ es un proceso de Lévy.

Demostración. La primera propiedad es clara por definicion, sumado a ello la suma de funciones continuas es continua, en esta caso cadlag. Ahora para incrementos estacionarios sea $0 \leq t_0 < t_1$ con $B_0, B_1 \in \mathcal{B}(\mathbb{R})$, se tiene que

$$\mathbb{P}(Y_{t_0} \in B_0, Y_{t_1} - Y_{t_0} \in B_1) = \mathbb{P}(S_{N_{t_0}} \in B_0, S_{N_{t_1}} - S_{N_{t_0}} \in B_1)$$

$$= \sum_{n_0 \in \mathbb{N}} \sum_{n_1 \in \mathbb{N}} \mathbb{P}(S_{n_0} \in B_0, S_{n_1+n_0} - S_{n_0} \in B_1, N_{t_0} = n_0, N_{t_1} - N_{t_0} = n_1)$$

Por la independencia de las variables $N, X_1, \dots, X_n$ y los incrementos de N se tiene que

$$= \sum_{n_0 \in \mathbb{N}} \sum_{n_1 \in \mathbb{N}} \mathbb{P}(S_{n_0} \in B_0)\mathbb{P}(S_{n_1+n_0} - S_{n_0} \in B_1)\mathbb{P}(N_{t_0} = n_0)\mathbb{P}(N_{t_1} - N_{t_0} = n_1)$$

Por lo incrementos estacionarios y la independencia de N de los X_i se tiene que

$$= \sum_{n_0 \in \mathbb{N}} \sum_{n_1 \in \mathbb{N}} \mathbb{P}(N_{t_0} = n_0, S_{n_0} \in B_0)\mathbb{P}(N_{t_1-t_0} = n_1, S_{n_1} \in B_1)$$

$$\mathbb{P}(S_{N_{t_0}} \in B_0)\mathbb{P}(S_{N_{t_1-t_0}} \in B_1) = \mathbb{P}(Y_{t_0} \in B_0)\mathbb{P}(Y_{t_1-t_0} \in B_1)$$

Para la independencia se hace lo mismo pero sobre $n_0, \dots, n_k$.

□

Lema 9.3.1 Existencia de momentos en el proceso compuesto de Poisson. Si las variables aleatorias X_k tienen momento de orden $p \geq 1$, el proceso compuesto de Poisson $(Y_t : t \geq 0)$ tiene también momentos de orden p. Es decir, si $\mathbb{E}(|X_k|^p) < \infty$, entonces $\mathbb{E}(|Y_t|^p) < \infty \ \forall\, t \geq 0$.

Demostración. Note que

$$\mathbb{E}[|Y_t|^p] = \sum_{n=0}^{\infty} \mathbb{E}\left[\left|\sum_{k=1}^{n} X_k(\omega)\right|^p\right] \mathbb{E}[N_t = n] = \sum_{n=0}^{\infty} \mathbb{E}\left[\left|\sum_{k_1+\cdots+k_n=p} \binom{p}{k_1, \cdots, k_n} X_1^{n_1} \cdots X_k^{n_k}\right|\right] \frac{e^{-\lambda t}(\lambda t)^n}{n!}$$

$$\sum_{n=0}^{\infty} \sum_{k_1+\cdots+k_n=p} \binom{p}{k_1, \cdots, k_n} \mathbb{E}\left[X_1^{n_1}\right] \cdots \mathbb{E}\left[X_k^{n_k}\right] \frac{e^{-\lambda t}(\lambda t)^n}{n!} \leq \sum_{n=0}^{\infty} \max_{k_1+\cdots+k_n=p} (\mathbb{E}\left[X_1^{n_1}\right] \cdots \mathbb{E}\left[X_k^{n_k}\right]) \frac{e^{-\lambda t}(\lambda t)^n}{n!} n^p$$

□

Lema 9.3.2 Función característica del proceso compuesto de Poisson. Sea $\psi : \mathbb{R} \to \mathbb{C}$ la función característica común de las variables $X_1, X_2, ...$, es decir $\psi(u) = \mathbb{E}(e^{iuX_1}) \ \forall\, u \in \mathbb{R}$. Sea $(Y_t : t \geq 0)$ el proceso compuesto de Poisson. Entonces, para cada $t \geq 0$, la función característica de Y_t está dada por

$$\mathbb{E}(e^{iuY_t}) = \exp(\lambda t(\psi(u) - 1)), \qquad \forall\, u \in \mathbb{R}. \tag{9.10}$$

Demostración. Note que

$$\mathbb{E}(e^{iuY_t}) = \sum_{n=0}^{\infty} \mathbb{E}(e^{iuS_n})\,\mathbb{P}(N_t = n) = \sum_{n=0}^{\infty} (\mathbb{E}(e^{iuX_1}))^n \frac{e^{-\lambda t}(\lambda t)^n}{n!} = \sum_{n=0}^{\infty} (\psi(u))^n \frac{e^{-\lambda t}(\lambda t)^n}{n!} = e^{\lambda t(\psi(u)-1)}$$

□

9.4. El Movimiento Browniano

9.4.1. Movimiento Browniano y Procesos Gaussianos

Definición 9.4.1 Movimiento Browniano estándar. Un proceso estocástico $B = (B_t : t \geq 0)$ se llama un movimientoBrowniano estándar (también llamado proceso de Wiener) si satisface

1. $B_0 = 0$ c.s.
2. B tiene incrementos independientes.
3. $\forall\, 0 \leq s \leq t$, $B_t - B_s \overset{d}{=} \mathcal{N}(0, t-s)$, donde $\mathcal{N}(0, t-s)$ denota la distribución Gaussiana con media 0 y varianza $t-s$.
4. B tiene trayectorias continuas.

Teorema 9.4.1 Movimiento Browniano estándar como proceso de Lévy. El movimiento Browniano estándar $(B_t : t \geq 0)$ es un proceso de Lévy con función característica $\varphi(u) = \exp(-tu^2/2)$.

Demostración. Las trayectorias continuas implica que es cadlag primero que todo. La primera y segunda propiedad se cumplen, ademas note que sus trayectorias son estacionarias ya que

$$B_t - B_s \overset{d}{=} \mathcal{N}(0, t-s) \overset{d}{=} B_{t-s} - B_0 = B_{t-s}$$

y dado que $\varphi_X(t) = \exp\left(i\mu t - \frac{\sigma^2 t^2}{2}\right)$ se cumple la igualdad de la función característica.

□

Proposición 9.4.1 Martingalas y el Browniano. Si $(B_t : t \geq 0)$ es Browniano estándar y $(\mathcal{F}_t : t \geq 0)$ es su filtración natural, los siguientes procesos son una $(\mathcal{F}_t)$-martingala

1. $(B_t : t \geq 0)$.
2. $(B_t^2 - t : t \geq 0)$.
3. $\left(\exp\left(uB_t - \frac{u^2 t}{2}\right) : t \geq 0\right)$ para cada $u \in \mathbb{R}$.

Demostración. La primera es consecuencia del lema de martingalas de levy con media cero. Para el segundo note que $B_t^2 = B_s^2 + 2B_s(B_t - B_s) + (B_t - B_s)^2$, entonces se sigue (procedimiento mecánico) que

$$\mathbb{E}(B_t^2 - t \mid \mathcal{F}_s) = B_s^2 + 2B_s\mathbb{E}(B_t - B_s) + \mathbb{E}((B_t - B_s)^2) - t = B_s^2 + 2B_s \cdot 0 + (t-s) - t$$

Para la tercera note que

$$\mathbb{E}(e^{uB_t - \frac{u^2 t}{2}} \mid \mathcal{F}_s) = e^{uB_s}\mathbb{E}(e^{u(B_s - B_t)}e^{\frac{u^2 t}{2}} = e^{uB_s - \frac{u^2 s}{2}}$$

□

Definición 9.4.2 Distribución Gaussiana multivariada. Un vector aleatorio d-dimensional $V = (v_1, v_2, \dots, v_d)^T$ se dice que tiene distribución Gaussiana multivariada d-dimensional con media μ y covarianza Σ si tiene densidad conjunta

$$(2\pi)^{-d/2}(\det\Sigma)^{-1/2}\exp\left(-\tfrac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right), \qquad \forall\, x \in \mathbb{R}^d.$$

donde $\mu = (\mu_1, \mu_2, \dots, \mu_d)^T$ con $\mu_i = \mathbb{E}(v_i)$ para $i = 1, \dots, d$, y $\Sigma = (\sigma_{ij})_{i,j=1,\dots,d}$ con $\sigma_{ij} = \mathrm{Cov}(v_i, v_j) = \mathbb{E}\big[(v_i - \mu_i)(v_j - \mu_j)\big]$ para $i, j = 1, \dots, d$.

Lema 9.4.1 Independencia Gaussiana. Si $V = (v_1, v_2, \dots, v_d)^T$ es Gaussiana multivariada, las variables aleatorias $v_1, v_2, \dots, v_d$ son independientes si y sólo si Σ es una matriz diagonal.

Demostración. Si las variables son independientes, entonces la covarianza es 0 a menos que las variables sean la misma. Ahora, si la matriz en diagonal, note que entonces

$$(x-\mu)^T\Sigma^{-1}(x-\mu) = (x_1-\mu_1, x_2-\mu_2, \dots, x_d-\mu_d)\begin{pmatrix}\sigma_{11}^{-1} & 0 & \cdots & 0\\ 0 & \sigma_{22}^{-1} & \cdots & 0\\ \vdots & \vdots & \ddots & \vdots\\ 0 & 0 & \cdots & \sigma_{dd}^{-1}\end{pmatrix}\begin{pmatrix}x_1-\mu_1\\ x_2-\mu_2\\ \vdots\\ x_d-\mu_d\end{pmatrix} = \sum_{i=1}^{d}\frac{(x_i-\mu_i)^2}{\sigma_{ii}}$$

por lo tanto las distribuciones se puede factorizar, en cuyo caso, las distribuciones son independientes. □

Proposición 9.4.2 Caracterización Gaussiana. Un vector aleatorio d-dimensional V es Gaussiano multivariado si y sólo si toda combinación lineal $\theta_1 v_1 + \cdots + \theta_n v_n$ tiene distribución Gaussiana univariada.

Demostración. Si $\theta = (\theta_1, \dots, \theta_n) \in \mathbb{R}^d$, $\quad Z_\theta = \theta_1 v_1 + \cdots + \theta_n v_n$ gaussiano univariado. Entonces $\mathbb{E}(Z_\theta) = \theta^T\mu$, $\quad \mathrm{Var}(Z_\theta) = \theta^T\Sigma\theta$. En cuyo caso

$$\mathbb{E}\left(e^{i\theta^T V}\right) = \mathbb{E}(e^{iZ_\theta}) = \exp\left(i\theta^T\mu - \tfrac{1}{2}\theta^T\Sigma\theta\right),$$

de donde V tiene función característica Gaussiana multivariada.

En la otra dirección, si V es Gaussiano multivariado, dado $s \in \mathbb{R}$ y $\theta \in \mathbb{R}^d$, aplicando (3.8) al vector $s\theta$ y repitiendo los cálculos en orden inverso, se concluye que Z_θ es Gaussiano univariado con parámetros $\alpha = \theta^T\mu$, $\beta^2 = \theta^T\Sigma\theta$. □

Definición 9.4.3 Gaussiano. Un proceso estocástico $(X_t : t \geq 0)$ se dice Gaussiano si para cada escogencia $0 \leq t_1 < t_2 < \cdots < t_d$, el vector aleatorio $(X_{t_1}, X_{t_2}, \dots, X_{t_d})$ es Gaussiano multivariado. Su función de media se define por $\mu(t) = \mathbb{E}X_t$ y su función de covarianza por $\gamma(s,t) = \mathrm{Cov}(X_s, X_t)$.

Teorema 9.4.2 Caracterización del Movimiento Browniano. Un proceso estocástico $(B_t : t \geq 0)$ es un movimiento Browniano si y sólo si es un proceso Gaussiano con función de media $\mu_t = 0$ $\forall\, t \geq 0$, con función de covarianza $\gamma(s,t) = s \wedge t$ $\forall\, s, t \geq 0$, y con trayectorias continuas.

Demostración. ("⇒") Suponga que $(B_t : t \geq 0)$ es Browniano. Para probar que el proceso es Gaussiano, sean $0 \leq t_1 < t_2 < \cdots < t_d$ y $\theta = (\theta_1, \dots, \theta_d) \in \mathbb{R}^d$. Se tiene

$$\theta_1 B_{t_1} + \cdots + \theta_d B_{t_d} = \sum_{j=1}^{d}(\theta_j + \cdots + \theta_d)(B_{t_j} - B_{t_{j-1}}),$$

con $t_0 = 0$. Cada incremento es Gaussiano independiente, por lo que la combinación lineal es Gaussiana. Así, el vector $(B_{t_1}, \dots, B_{t_d})$ es Gaussiano multivariado y (B_t) es Gaussiano. Además, $\mu(t) = \mathbb{E}[B_t] = 0$ y si $0 \leq s < t$ entonces $\text{Cov}(B_s, B_t) = \mathbb{E}(B_s B_t) = \mathbb{E}(B_s^2) + \mathbb{E}(B_s(B_t - B_s)) = s + 0$ de forma que $\text{Cov}(B_s, B_t) = s \wedge t$.

("$\Leftarrow$") Note que para la primera propiedad se cumple

$$\mathbb{E}[B_0^2] = \text{Cov}(B_0, B_0) = 0.$$

Para la tercera propiedad, si $0 \leq s, t$, como el proceso es Gaussiano, por la proposición anterior se tiene que $B_{t+s} - B_s$ es Gaussiano univariado. Además,

$$\mathbb{E}[B_{t+s} - B_s] = \mathbb{E}[B_{t+s}] - \mathbb{E}[B_s] = 0,$$

$$\text{Var}(B_{t+s} - B_s) = \text{Var}(B_{t+s}) + \text{Var}(B_s) - 2\text{Cov}(B_{t+s}, B_s) = (t+s) + s - 2s = t.$$

Por tanto, $B_{t+s} - B_s \sim \mathcal{N}(0, t)$, lo que demuestra la propiedad 3. En cuanto a la segunda propiedad, corresponde a la independencia de los incrementos. Sean $0 \leq t_1 < t_2 < \cdots < t_d$. El vector de incrementos

$$(B_{t_1}, B_{t_2} - B_{t_1}, \dots, B_{t_d} - B_{t_{d-1}})$$

tiene matriz de covarianza diagonal. En efecto, si $i < j$, como $\gamma(s,t) = s \wedge t$, se cumple

$$\mathbb{E}[(B_{t_i} - B_{t_{i-1}})(B_{t_j} - B_{t_{j-1}})] = \mathbb{E}[B_{t_i} B_{t_j}] - \mathbb{E}[B_{t_i} B_{t_{j-1}}] - \mathbb{E}[B_{t_{i-1}} B_{t_j}] + \mathbb{E}[B_{t_{i-1}} B_{t_{j-1}}] = t_i - t_i - t_{i-1} + t_{i-1} = 0$$

De este modo se concluye que B tiene incrementos independientes. Finalmente, la cuarta propiedad, la continuidad de trayectorias, está incluida dentro de las suposiciones.

□

Proposición 9.4.3 Invariancias del Movimiento Browniano. Sea $B = (B_t : t \geq 0)$ el movimiento Browniano estándar. Los siguientes procesos estocásticos son un movimiento Browniano estándar

1. (Reflexión) $(-B_t : t \geq 0)$.
2. (Traslación en el tiempo) $(B_{t+a} - B_a : t \geq 0)$ para toda $a > 0$.
3. (Auto-similitud) $\left(cB_{t/c^2} : t \geq 0\right)$ para todo $c > 0$.
4. (Inversión en el tiempo) $(\widetilde{B}_t : t \geq 0)$ definido como $\widetilde{B}_0 = 0$ y $\widetilde{B}_t = tB_{1/t}$ si $t > 0$.

Demostración. La primera es inmediata. Para la segunda simplemente note que dado que es un proceso de Levy esos incrementos estacionarios son independientes con la misma distribucion que el teorema de Movimiento Browniano estandar como proceso de Levy. Para la tercera note que la primera propiedad se cumple $cB_{0/c^2} = cB_0 = 0$; para la independencia note simplemente que si $0 \leq s < t$ entonces $0 \leq s/c^2 < t/c^2$ y de ahi mismo se deriva la independencia de los incrementos; para la tercera note que $cB_{t/c^2 - cB_{s/c^2}} \overset{d}{=} \mathcal{N}(0, c^2(t/c^2 - s/c^2)) = \mathcal{N}(0, t-s)$; y por ultimo dado que la transformación es una función monotona, las trayectorias siguen siendo continuas.

Sea Ω_0 un conjunto de probabilidad 1 tal que para cada $\omega \in \Omega_0$ la trayectoria $s \mapsto B_s(\omega)$ es continua en $(0, \infty)$. Note que para $t = 0$ la continuidad se obtiene de dos hechos: primero, como $\mathbb{Q}$ es contable, la distribución de $(B_t : t \in \mathbb{Q} \cap [0, \infty))$ coincide con la de $(B_t : t \in [0, \infty))$, y por tanto para casi todo $\omega \in \Omega_0$,

$$\lim_{s \downarrow 0,\, s \in \mathbb{Q}} B_s(\omega) = 0.$$

Segundo, como $\mathbb{Q} \cap (0, \infty)$ es denso y $s \mapsto B_s(\omega)$ es continua en $(0, \infty)$, se concluye que para casi todo $\omega \in \Omega_0$,

$$0 = \lim_{s\downarrow 0,\, s\in\mathbb{Q}} B_s(\omega) = \lim_{s\downarrow 0} B_s(\omega).$$

De este modo las trayectorias de B son continuas casi seguramente. Finalmente, por el teorema anterior se concluye que B es un movimiento Browniano estándar.

□

Proposición 9.4.4 Construcción de Wiener del Browniano. Sea $a_k, k \in \mathbb{N}$, una sucesión de variables aleatorias i.i.d. con distribución normal estándar. Defina, para $t \in [0, \pi]$,

$$W_t = \frac{ta_0}{\pi} + \frac{2}{\pi}\sum_{k=1}^{\infty} \frac{a_k}{k}\sin(kt). \tag{9.11}$$

La serie converge uniformemente en $[0, \pi]$ con probabilidad 1 y el proceso $(W_t : t \in [0, \pi])$ satisface las condiciones del teorema anterior, siendo por tanto un movimiento Browniano estándar en $[0, \pi]$. Para extenderlo a $[0, \infty)$, se consideran copias independientes $W^{(n)}$ y se define B_t por concatenación en intervalos de longitud π.

Teorema 9.4.3. Sean $\Omega_o = \{\text{funciones } \omega : [0,\infty) \to \mathbb{R}\}$ y $\mathcal{F}_o$ la σ-álgebra generada por los conjuntos finito-dimensionales $\{\omega : \omega(t_i) \in A_i \text{ para } 1 \le i \le n\}$, donde $A_i \in \mathcal{R}$. Para cada $x \in \mathbb{R}$ existe una única medida de probabilidad ν_x en $(\Omega_o, \mathcal{F}_o)$ tal que $\nu_x\{\omega : \omega(0) = x\} = 1$ y, cuando $0 < t_1 < \cdots < t_n$,

$$\nu_x\{\omega : \omega(t_i) \in A_i\} = \mu_{x,t_1,\ldots,t_n}(A_1 \times \cdots \times A_n), \tag{9.12}$$

donde

$$\mu_{x,t_1,\ldots,t_n}(A_1 \times \cdots \times A_n) = \int_{A_1} dx_1 \cdots \int_{A_n} dx_n \prod_{m=1}^{n} p_{t_m - t_{m-1}}(x_{m-1}, x_m), \tag{9.13}$$

con $x_0 = x$, $t_0 = 0$ y $p_t(a,b) = (2\pi t)^{-1/2}\exp(-(b-a)^2/2t)$.

Teorema 9.4.4. Sean $T < \infty$ y $x \in \mathbb{R}$. ν_x asigna probabilidad uno a las trayectorias $\omega : Q_2 \to \mathbb{R}$ que son uniformemente continuas en $Q_2 \cap [0, T]$, donde $Q_2 = \{m2^{-n} : m, n \ge 0\}$ son los racionales diádicos.

Teorema 9.4.5 Kolmogorov. Suponga que $E|X_s - X_t|^\beta \le K|t-s|^{1+\alpha}$ donde $\alpha, \beta > 0$. Si $\gamma < \alpha/\beta$, entonces con probabilidad uno existe una constante $C(\omega)$ tal que

$$|X(q) - X(r)| \le C|q-r|^\gamma \quad \text{para todo } q, r \in Q_2 \cap [0,1]. \tag{9.14}$$

Lema 9.4.2. Sea $G_n = \{|X(i/2^n) - X((i-1)/2^n)| \le 2^{-\gamma n} \text{ para todo } 0 < i \le 2^n\}$. En $H_N = \cap_{n=N}^{\infty} G_n$ se tiene

$$|X(q) - X(r)| \le \frac{3}{1-2^{-\gamma}}|q-r|^\gamma \tag{9.15}$$

para $q, r \in Q_2 \cap [0,1]$ con $|q-r| < 2^{-N}$.

Proposición 9.4.5 Browniano en dimensión d. Un proceso estocástico en $\mathbb{R}^d$ es una colección de vectores aleatorios $(X_t : t \in T)$ con valores en $\mathbb{R}^d$. Cada X_t puede escribirse como

$$X_t = (X_t^1, \ldots, X_t^d), \tag{9.16}$$

donde X_t^k son las componentes reales. Así, $(X_t : t \in T)$ puede verse como un vector formado por d procesos reales $(X_t^k : t \in T)$, $k = 1, \dots, d$.

Definición 9.4.4 Movimiento Browniano estándar d-dimensional. Un proceso estocástico $B = (B_t : t \geq 0)$ en $\mathbb{R}^d$ se llama un movimiento Browniano estándar d-dimensional si satisface

1. $B_0 = 0$ c.s.
2. B tiene incrementos independientes.
3. $\forall\, 0 \leq s \leq t$, $B_t - B_s$ tiene distribución Gaussiana d-dimensional con vector de medias $\mu = 0$ y matriz de covarianza $\Sigma = (t-s)I_d$, donde I_d es la identidad $d \times d$.
4. B tiene trayectorias continuas.

Teorema 9.4.6 Equivalencia del Browniano Multidimensional. Sea $B = (B_t : t \geq 0)$ un proceso estocástico en $\mathbb{R}^d$ y sean $B^k = (B_t^k : t \geq 0)$ con $k = 1, \dots, d$ sus componentes. Son equivalentes

1. $B = (B_t : t \geq 0)$ es un movimiento Browniano estándar d-dimensional.
2. Para cada $k = 1, \dots, d$, $(B_t^k : t \geq 0)$ es un movimiento Browniano estándar (unidimensional) y los procesos $B^1, \dots, B^d$ son independientes.

La demostracion es casi directa usando la independencia gaussiana.

Teorema 9.4.7 Descomposición de Lévy-Itô. Suponga que $(L_t : t \geq 0)$ es un proceso de Lévy. Existen dos números $b \in \mathbb{R}$ y $\sigma > 0$, un movimiento Browniano estándar $(B_t : t \geq 0)$, una martingala cuadrado integrable $(M_t : t \geq 0)$ que es a su vez un proceso de Lévy, y un proceso compuesto de Poisson $(Y_t : t \geq 0)$, todos los anteriores procesos estocásticos independientes, tales que

$$L_t = bt + \sigma^{1/2} B_t + M_t + Y_t, \qquad \forall\, t \geq 0. \tag{9.17}$$

9.4.2. Las Trayectorias del Movimiento Browniano

Definición 9.4.5 Varianza. Sea $X = (X_t : t \geq 0)$ un proceso estocástico con trayectorias càdlàg. Sean $0 \leq a < b$ y dada una partición $\Delta_n : a = t_{n,0} < t_{n,1} < \cdots < t_{n,N(n)} = b$ de $[a, b]$

1. La variación del proceso X en la partición Δ_n se define como

$$\mathrm{Var}_{\Delta_n}(X)(\omega) = \sum_{k=1}^{N(n)} \left| X_{t_{n,k}}(\omega) - X_{t_{n,k-1}}(\omega) \right|.$$

   Se dice que X es un proceso de variación finita en $[a, b]$ si

$$\mathbb{P}\left(\sup_{\Delta_n} \mathrm{Var}_{\Delta_n}(X) < \infty \right) = 1.$$

2. Se dice que X es de variación cuadrática finita si existe un proceso estocástico $([X]_t : t \geq 0)$ tal

que para cada t y cada sucesión Δ_n de particiones de $[0,t]$ con $|\Delta_n| \to 0$

$$[X]_t(\omega) = \mathbb{P}\text{-}\lim_{|\Delta_n|\to 0} \sum_{k=1}^{N(n)} \left(X_{t_{n,k}}(\omega) - X_{t_{n,k-1}}(\omega)\right)^2.$$

Teorema 9.4.8 Variación del Movimiento Browniano. El movimiento Browniano estándar es de variación cuadrática finita y de hecho $[B]_t = t$ (convergencia en $L^2(\Omega)$). Por otro lado, las trayectorias del movimiento Browniano estándar son c.s. de variación infinita en todo subintervalo de $[0,\infty)$.

Demostración. Sea Δ_n una sucesión de particiones de $[0,t]$ tal que $|\Delta_n| \to 0$. Definimos

$$Y_n(\omega) = \sum_{k=1}^{N(n)} \left(B_{t_{n,k}}(\omega) - B_{t_{n,k-1}}(\omega)\right)^2, \quad \forall \omega \in \Omega.$$

Como el Browniano tiene incrementos independientes y gaussianos, se cumple

$$\mathbb{E}[Y_n] = \sum_{k=1}^{N(n)} \mathbb{E}[(B_{t_{n,k}} - B_{t_{n,k-1}})^2] = \sum_{k=1}^{N(n)} (t_{n,k} - t_{n,k-1}) = t.$$

Además,

$$\mathrm{Var}(Y_n) = \sum_{k=1}^{N(n)} \mathrm{Var}((B_{t_{n,k}} - B_{t_{n,k-1}})^2).$$

Como $B_{t_{n,k}} - B_{t_{n,k-1}} \sim \mathcal{N}(0,\, t_{n,k} - t_{n,k-1})$, su momento de cuarto orden es $3(t_{n,k} - t_{n,k-1})^2$, y por tanto

$$\mathrm{Var}(Y_n) \le 3t\,|\Delta_n| \quad \longrightarrow \quad 0 \quad \text{cuando } n \to \infty.$$

De este modo,

$$\lim_{n\to\infty} \mathbb{E}[|Y_n - t|^2] = 0,$$

lo que implica que $Y_n \to t$ en probabilidad. En conclusión, el Browniano es de variación cuadrática finita y se cumple

$$[B]_t = t \quad \text{c.s.}$$

Por otro lado, para probar que las trayectorias del Browniano son c.s. de variación infinita en cualquier intervalo, basta considerar $[0,t]$. Si la variación fuese finita, la continuidad de las trayectorias implicaría que

$$\sum_{k=1}^{N(n)} |B_{t_{n,k}} - B_{t_{n,k-1}}| \to 0,$$

cuando $|\Delta_n| \to 0$, lo cual contradice el hecho de que $[B]_t = t$ c.s. Por tanto, las trayectorias tienen variación infinita en todo intervalo. □

Definición 9.4.6 Hölder continuidad. Sea $f : [a,b] \to \mathbb{R}$. Se dice que f es Hölder continua de orden $0 < \alpha < 1$ si existe una constante $c > 0$ tal que

$$|f(s) - f(t)| \le c|s-t|^\alpha, \quad \forall a < s < t < b. \tag{9.18}$$

Teorema 9.4.9 Regularidad Hölder del Browniano. Para todo $0 < \alpha < 1/2$, el conjunto de todos los $\omega \in \Omega$ para los cuales la función $t \mapsto B_t(\omega)$ es Hölder continua de orden α tiene probabilidad 1.

Corolario 9.4.1 No Regularidad Hölder del Browniano. Si $\alpha > 1/2$, el conjunto de todos los $\omega \in \Omega$ para los cuales las trayectorias del Browniano estándar no son Hölder continuas de orden α para ningún intervalo tiene probabilidad 1.

Demostración. Es suficiente verificar el resultado para las trayectorias en el intervalo $[0, T]$. Procedemos por contradicción como en la última parte de la prueba del teorema anterior. Sea Δ_n una sucesión de particiones de $[0, T]$ tal que $|\Delta_n| \to 0$.

Supongamos que $|B_t(\omega) - B_s(\omega)| \leq c|t - s|^\alpha$ para todo $0 \leq s, t \leq T$ y que $\alpha > 1/2$. Por la condición de Hölder se obtiene

$$\sum_{k=1}^{N(n)} \left(B_{t_{n,k}}(\omega) - B_{t_{n,k-1}}(\omega)\right)^2 \leq c^2 T |\Delta_n|^{2\alpha - 1}.$$

El lado derecho converge a 0 cuando $n \to \infty$. Esto contradice que $[B]_t = t$ c.s.

En conclusión, las trayectorias del Browniano no pueden ser Hölder continuas de orden $\alpha > 1/2$. □

Teorema 9.4.10 Módulo de continuidad de Lévy. Para el módulo de continuidad del Browniano en $[0, 1]$

$$m(\epsilon) = \sup\{|B_s - B_t| : 0 < s < t \leq 1,\ |s - t| \leq \epsilon\}, \tag{9.19}$$

se cumple que

$$\mathbb{P}\left(\limsup_{\epsilon \to 0} \frac{m(\epsilon)}{\sqrt{2\epsilon \ln(1/\epsilon)}} = 1\right) = 1. \tag{9.20}$$

Teorema 9.4.11 Paley-Wiener-Zygmund. Con probabilidad uno, las trayectorias brownianas no son Lipschitz continuas (y por lo tanto no son diferenciables) en ningún punto.

Demostración. Consideremos las trayectorias del Browniano en el intervalo $[0, 1]$. Sea

$$G(c, \epsilon) = \{\omega \in \Omega : \exists s \in [0, 1] \text{ tal que } |B_s(\omega) - B_t(\omega)| \leq c|s - t|,\ \forall t \text{ con } |s - t| \leq \epsilon\}.$$

Sea D el conjunto de todos los $\omega \in \Omega$ para los cuales existe algún $s \in [0, 1]$ tal que la función $t \mapsto B_t(\omega)$ es diferenciable en s. Usando propiedades básicas de la diferenciación en una variable real se verifica que

$$D \subseteq \bigcup_{j=1}^{\infty} \bigcup_{k=1}^{\infty} G(j, 1/k).$$

Por el teorema anterior (caso $\alpha = 1$), cada evento $G(j, 1/k)$ tiene probabilidad cero. Como D es una unión contable de estos eventos, también tiene probabilidad cero.

En conclusión, las trayectorias del Browniano son casi seguramente no diferenciables en todo punto de $[0, 1]$. □

Teorema 9.4.12 No Monotonía del Browniano. El conjunto de todos los $\omega \in \Omega$ para los cuales la función $t \mapsto B_t(\omega)$ no es monótona en ningún intervalo tiene probabilidad 1.

Demostración. Sea $[a, b] \subseteq [0, \infty)$ y Ω_0 un conjunto de probabilidad 1 tal que para cada $\omega \in \Omega_0$ la trayectoria $s \mapsto B_s(\omega)$ es continua. Definimos

$$A[a,b] = \{\omega \in \Omega_0 : s \mapsto B_s(\omega) \text{ es creciente en } [a,b]\}.$$

Para cada $n \geq 1$, sea $t_{n,k} = a + k(b-a)/n$ y

$$A_{n,k} = \{\omega \in \Omega_0 : B_{t_{n,k-1}}(\omega) \leq B_{t_{n,k}}(\omega)\}.$$

Por continuidad se tiene

$$A[a,b] = \bigcap_{n=1}^{\infty} \bigcap_{k=1}^{n} A_{n,k}.$$

Como $B_{t_{n,k}} - B_{t_{n,k-1}} \sim \mathcal{N}(0,(b-a)/n)$, se cumple $\mathbb{P}(A_{n,k}) = 1/2$. Además, los eventos $A_{n,k}$ son independientes, por lo que

$$\mathbb{P}\Big(\bigcap_{k=1}^{n} A_{n,k}\Big) = \Big(\tfrac{1}{2}\Big)^n.$$

De aquí se deduce que $\mathbb{P}(A[a,b]) = 0$.

Finalmente, para un intervalo cualquiera $I \subseteq [0,\infty)$, el conjunto de trayectorias crecientes en I se expresa como unión de eventos $A[a,b]$ con $a,b \in \mathbb{Q} \cap I$, y por tanto también tiene probabilidad 0. De manera análoga se prueba que las trayectorias decrecientes en I tienen probabilidad 0. □

Teorema 9.4.13 Comportamiento en el largo plaza. Suponga $t_n \nearrow \infty$

$$\mathbb{P}\Big(\limsup_{n\to\infty} B_{t_n} = \infty\Big) = 1 \tag{9.21}$$

$$\mathbb{P}\Big(\liminf_{n\to\infty} B_{t_n} = -\infty\Big) = 1 \tag{9.22}$$

Teorema 9.4.14. Sea B_t un movimiento browniano unidimensional que comienza en 0. Con probabilidad 1,

$$\limsup_{t\to\infty} B_t/\sqrt{t} = \infty \qquad \text{y} \qquad \liminf_{t\to\infty} B_t/\sqrt{t} = -\infty. \tag{9.23}$$

Teorema 9.4.15 Comportamiento en el corto plazo. Sean

$$T_0^+(\omega) = \text{ínf}\{t > 0 : B_t(\omega) > 0\}, \qquad T_0^-(\omega) = \text{ínf}\{t > 0 : B_t(\omega) < 0\}. \tag{9.24}$$

Se cumple que $\mathbb{P}(T_0^+ = 0) = 1$ y $\mathbb{P}(T_0^- = 0) = 1$.

9.4.3. Movimiento Browniano y Procesos de Markov

Definición 9.4.7 Proceso de Markov. Sea $(X_t : t \geq 0)$ un proceso adaptado a la filtración $(\mathcal{F}_t : t \geq 0)$. Se dice que $(X_t : t \geq 0)$ es un proceso de Markov si $\forall\, s,t \geq 0$, $y \in \mathbb{R}$, se verifica la propiedad de Markov

$$\mathbb{P}(X_{t+s} \leq y \mid \mathcal{F}_t) = \mathbb{P}(X_{t+s} \leq y \mid X_t) \qquad \text{(c.s.)} \tag{9.25}$$

Teorema 9.4.16 Propiedad de Markov del Browniano. El movimiento Browniano estándar $B = (B_t : t \geq 0)$ es un proceso de Markov respecto a su filtración natural $(\mathcal{F}_t : t \geq 0)$.

Demostración. La idea es verificar que la generadora de momentos de B_{t+s} condicionada a $\mathcal{F}_t$ coincide con la generadora de momentos condicionada respecto a B_t. Como la generadora de momentos determina en forma única la distribución de una variable aleatoria, esto prueba la propiedad de Markov.

En efecto, para $u \in \mathbb{R}$, $s, t \geq 0$:

$$\mathbb{E}[e^{uB_{t+s}} \mid B_t] = e^{uB_t}\, \mathbb{E}[e^{u(B_{t+s}-B_t)}].$$

Usando que $B_{t+s} - B_t \sim \mathcal{N}(0, s)$, se obtiene

$$= e^{uB_t}\, \exp\Big(\tfrac{u^2 s}{2}\Big).$$

Por otro lado, de la proposición anterior sabemos que

$$\mathbb{E}[e^{uB_{t+s}} \mid \mathcal{F}_t] = \exp\Big(uB_t - \tfrac{u^2 t}{2}\Big)\, \exp\Big(\tfrac{u^2(t+s)}{2}\Big).$$

Ambas expresiones coinciden, y por lo explicado al inicio se concluye que B es un proceso de Markov respecto a su filtración natural. □

Definición 9.4.8 Función de transición. Sea $(X_t : t \geq 0)$ un proceso de Markov. Su función de transición se define como:

$$p_{s,t}(x, A) = \mathbb{P}(X_t \in A \mid X_s = x), \qquad \forall\, 0 \leq s \leq t,\ A \in \mathcal{B}(\mathbb{R}),\ x \in \mathbb{R}. \tag{9.26}$$

Las ecuaciones de Chapman-Kolmogorov son

$$p_{r,t}(x, A) = \int_{\mathbb{R}} p_{s,t}(y, A)\, p_{r,s}(x, dy), \qquad \forall\, 0 \leq r \leq s \leq t,\ A \in \mathcal{B}(\mathbb{R}),\ x \in \mathbb{R}. \tag{9.27}$$

Definición 9.4.9 Densidad de transición. Se dice que el proceso de Markov $(X_t : t \geq 0)$ tiene una densidad de transición si para cada $0 \leq s \leq t$, $x \in \mathbb{R}$, existe una función Borel-medible $y \mapsto k_{s,t}(x, y)$ tal que

$$p_{s,t}(x, A) = \int_A k_{s,t}(x, y)\, dy. \tag{9.28}$$

Si el proceso posee densidad de transición, las ecuaciones de Chapman-Kolmogorov se expresan como

$$k_{r,t}(x, z) = \int_{\mathbb{R}} k_{r,s}(x, y)\, k_{s,t}(y, z)\, dy, \qquad \forall\, 0 \leq r \leq s \leq t,\ x, z \in \mathbb{R}. \tag{9.29}$$

Definición 9.4.10 σ-álgebras $\mathcal{F}_s^o$ y $\mathcal{F}_{s+}$, operador de desplazamiento. Sean $\mathcal{F}_s^o = \sigma(B_r : r \leq s)$ y $\mathcal{F}_{s+} = \cap_{t>s} \mathcal{F}_t^o$. Sea P_x, $x \in \mathbb{R}^d$, la familia de medidas en $(C, \mathcal{C})$ tales que bajo P_x, $B_t(\omega) = \omega(t)$ es un movimiento browniano que comienza en x. Para $s \geq 0$ se define el operador de desplazamiento $\theta_s : C \to C$ por

$$(\theta_s \omega)(t) = \omega(s + t) \quad \text{para } t \geq 0. \tag{9.30}$$

Teorema 9.4.17 Propiedad de Markov (operador de desplazamiento). Si $s \geq 0$ y Y es acotada y $\mathcal{C}$-medible, entonces para todo $x \in \mathbb{R}^d$

$$E_x(Y \circ \theta_s | \mathcal{F}_{s+}) = E_{B_s} Y, \tag{9.31}$$

donde el lado derecho es la función $\varphi(x) = E_x Y$ evaluada en $x = B_s$.

Teorema 9.4.18. Si $Z \in \mathcal{C}$ es acotada, entonces para todo $s \geq 0$ y $x \in \mathbb{R}^d$,

$$E_x(Z|\mathcal{F}_{s+}) = E_x(Z|\mathcal{F}_s^o). \tag{9.32}$$

Teorema 9.4.19 Ley 0-1 de Blumenthal. Si $A \in \mathcal{F}_{0+}$, entonces para todo $x \in \mathbb{R}^d$, $P_x(A) \in \{0, 1\}$.

Teorema 9.4.20. Si $T_0 = \text{ínf}\{t > 0 : B_t = 0\}$, entonces $P_0(T_0 = 0) = 1$.

Definición 9.4.11 σ-álgebra de cola (Browniano). Sean $\mathcal{F}_t' = \sigma(B_s : s \geq t)$ el futuro al tiempo t y $\mathcal{T} = \cap_{t\geq 0}\mathcal{F}_t'$ la σ-álgebra de cola.

Teorema 9.4.21. Si $A \in \mathcal{T}$, entonces o bien $P_x(A) \equiv 0$ o bien $P_x(A) \equiv 1$.

Teorema 9.4.22. Sea B_t un movimiento browniano unidimensional y $A = \cap_n\{B_t = 0 \text{ para algún } t \geq n\}$. Entonces $P_x(A) = 1$ para todo x.

Definición 9.4.12 σ-álgebras completadas. Sean $\mathcal{N}_x = \{A : A \subset D \text{ con } P_x(D) = 0\}$, $\mathcal{F}_s^x = \sigma(\mathcal{F}_{s+} \cup \mathcal{N}_x)$ y $\mathcal{F}_s = \cap_x \mathcal{F}_s^x$.

Definición 9.4.13 Tiempo de paro (continuidad por derecha). Una variable aleatoria S con valores en $[0, \infty]$ se dice un *tiempo de paro* si para todo $t \geq 0$, $\{S < t\} \in \mathcal{F}_t$.

Teorema 9.4.23. Si G es un conjunto abierto y $T = \text{ínf}\{t \geq 0 : B_t \in G\}$, entonces T es un tiempo de paro.

Teorema 9.4.24. Si T_n es una sucesión de tiempos de paro y $T_n \downarrow T$, entonces T es un tiempo de paro.

Teorema 9.4.25. Si T_n es una sucesión de tiempos de paro y $T_n \uparrow T$, entonces T es un tiempo de paro.

Teorema 9.4.26. Si K es un conjunto cerrado y $T = \text{ínf}\{t \geq 0 : B_t \in K\}$, entonces T es un tiempo de paro.

Teorema 9.4.27. Sea S un tiempo de paro y sea $S_n = ([2^n S] + 1)/2^n$, donde $[x]$ es el mayor entero $\leq x$, es decir, $S_n = (m + 1)2^{-n}$ si $m2^{-n} \leq S < (m + 1)2^{-n}$. Entonces S_n es un tiempo de paro.

Definición 9.4.14 Desplazamiento aleatorio e información al tiempo S. Dada una variable

aleatoria no negativa $S(\omega)$, el *desplazamiento aleatorio* θ_S se define por

$$(\theta_S\omega)(t) = \begin{cases} \omega(S(\omega)+t) & \text{en } \{S<\infty\}, \\ \Delta & \text{en } \{S=\infty\}, \end{cases} \tag{9.33}$$

donde Δ es un punto extra que se agrega a C. La σ-álgebra de la información conocida al tiempo S es

$$\mathcal{F}_S = \{A : A \cap \{S \le t\} \in \mathcal{F}_t \text{ para todo } t \ge 0\}. \tag{9.34}$$

Teorema 9.4.28. Si $S \le T$ son tiempos de paro, entonces $\mathcal{F}_S \subset \mathcal{F}_T$.

Teorema 9.4.29. Si $T_n \downarrow T$ son tiempos de paro, entonces $\mathcal{F}_T = \cap \mathcal{F}(T_n)$.

Teorema 9.4.30. $B_S \in \mathcal{F}_S$, es decir, el valor de B_S es medible respecto a la información conocida al tiempo S.

Teorema 9.4.31 Propiedad fuerte de Markov (Browniano). Sea $(s,\omega) \mapsto Y_s(\omega)$ acotada y $\mathcal{R}\times\mathcal{C}$-medible. Si S es un tiempo de paro, entonces para todo $x \in \mathbb{R}^d$

$$E_x(Y_S \circ \theta_S | \mathcal{F}_S) = E_{B(S)} Y_S \quad \text{en } \{S<\infty\}, \tag{9.35}$$

donde el lado derecho es la función $\varphi(x,t) = E_x Y_t$ evaluada en $x = B(S)$, $t = S$.

Teorema 9.4.32 Principio de Reflexión. Si τ es un tiempo de parada con respecto a la filtración natural $(\mathcal{F}_t : t \ge 0)$ del Browniano estándar $B = (B_t : t \ge 0)$, entonces el proceso $\widetilde{B} = (\widetilde{B}_t : t \ge 0)$ definido por

$$\widetilde{B}_t(\omega) = \begin{cases} B_t(\omega) & \text{si } t < \tau(\omega), \\ B_{\tau(\omega)} - (B_t(\omega) - B_{\tau(\omega)}) & \text{si } t \ge \tau(\omega), \end{cases} \tag{9.36}$$

es también un movimiento Browniano estándar.

Proposición 9.4.6 Conjunto de ceros. Sea $Z(\omega) = \{t : B_t(\omega) = 0\}$. Con probabilidad uno, $Z(\omega)$ es un conjunto cerrado sin puntos aislados, no numerable y de medida de Lebesgue cero.

Teorema 9.4.33. Bajo P_0, $\{T_a, a \ge 0\}$ tiene incrementos independientes y estacionarios, donde $T_a = \text{ínf}\{t : B_t = a\}$.

Proposición 9.4.7. Para $a \ge 0$,

$$T_a \overset{d}{=} a^2 T_1. \tag{9.37}$$

Además, la transformada de Laplace $\varphi_a(\lambda) = E_0 \exp(-\lambda T_a)$ cumple $\varphi_a(\lambda) = \exp(-ac(\lambda))$ con $c(\lambda) = c(1)\sqrt{\lambda}$.

Teorema 9.4.34 Principio de reflexión (tiempo de llegada). Sean $a > 0$ y $T_a = \text{ínf}\{t : B_t = a\}$. Entonces

$$P_0(T_a < t) = 2P_0(B_t \geq a). \tag{9.38}$$

Proposición 9.4.8 Densidad de T_a.

$$P_0(T_a \leq t) = \int_0^t (2\pi s^3)^{-1/2} a \exp(-a^2/2s)\, ds. \tag{9.39}$$

Teorema 9.4.35 Ley del arcoseno de Lévy. Sea $L = \sup\{t \leq 1 : B_t = 0\}$. Entonces

$$P_0(L \leq s) = \frac{1}{\pi} \int_0^s (t(1-t))^{-1/2}\, dt = \frac{2}{\pi} \arcsin\big(\sqrt{s}\big). \tag{9.40}$$

9.4.4. Martingalas del Browniano y Martingalas Locales

Teorema 9.4.36. Si $a < x < b$, entonces $P_x(T_a < T_b) = (b-x)/(b-a)$.

Teorema 9.4.37. Sea $T = \text{ínf}\{t : B_t \notin (a,b)\}$, donde $a < 0 < b$. Entonces

$$E_0 T = -ab. \tag{9.41}$$

Teorema 9.4.38. Si $T_a = \text{ínf}\{t : B_t = a\}$, entonces

$$E_0 \exp(-\lambda T_a) = \exp\big(-a\sqrt{2\lambda}\big). \tag{9.42}$$

Teorema 9.4.39. Si $u(t,x)$ es un polinomio en t y x con

$$\frac{\partial u}{\partial t} + \frac{1}{2}\frac{\partial^2 u}{\partial x^2} = 0, \tag{9.43}$$

entonces $u(t, B_t)$ es una martingala.

Teorema 9.4.40. Si $T = \text{ínf}\{t : B_t \notin (-a,a)\}$, entonces $ET^2 = 5a^4/3$.

Definición 9.4.15 Martingala local. M_t es una *martingala local* si existe una sucesión creciente de tiempos de paro $T_n \uparrow \infty$ tal que $M(t \wedge T_n)$ es una martingala.

Lema 9.4.3. Si (i) las medidas μ_n en $[0,t]$ convergen débilmente a μ_∞, una medida finita, y (ii) g_n es una sucesión de funciones con $|g_n| \leq K$ que tiene la propiedad de que cuando $s_n \in [0,t] \to s$

entonces $g_n(s_n) \to g(s)$, entonces cuando $n \to \infty$

$$\int g_n \, d\mu_n \to \int g \, d\mu_\infty. \tag{9.44}$$

9.4.5. Teorema de Donsker y Límites Funcionales

Teorema 9.4.41 Teorema de representación de Skorokhod. Si $EX = 0$ y $EX^2 < \infty$, entonces existe un tiempo de paro T para el movimiento browniano (con $B_0 = 0$) tal que $B_T \stackrel{d}{=} X$ y $ET = EX^2$.

Teorema 9.4.42. Sean $X_1, X_2, \ldots$ i.i.d. con distribución F, que tiene media 0 y varianza 1, y sea $S_n = X_1 + \cdots + X_n$. Existe una sucesión de tiempos de paro $T_0 = 0, T_1, T_2, \ldots$ tal que $S_n \stackrel{d}{=} B(T_n)$ y $T_n - T_{n-1}$ son independientes e idénticamente distribuidos.

Teorema 9.4.43 Teorema central del límite. Bajo las hipótesis del teorema anterior, $S_n/\sqrt{n} \Rightarrow \chi$, donde χ tiene distribución normal estándar.

Definición 9.4.16 Interpolación lineal. Sea $\mathbb{N}$ el conjunto de enteros no negativos. Se define

$$S(u) = \begin{cases} S_k & \text{si } u = k \in \mathbb{N}, \\ \text{lineal en } [k, k+1] & \text{para } k \in \mathbb{N}. \end{cases} \tag{9.45}$$

Teorema 9.4.44 Teorema de Donsker. Bajo las hipótesis del teorema 8.1.2,

$$S(n\cdot)/\sqrt{n} \Rightarrow B(\cdot), \tag{9.46}$$

es decir, las medidas asociadas en $C[0,1]$ convergen débilmente.

Teorema 9.4.45. Si $\psi : C[0,1] \to \mathbb{R}$ tiene la propiedad de ser continua P_0-c.s., entonces

$$\psi(S(n\cdot)/\sqrt{n}) \Rightarrow \psi(B(\cdot)). \tag{9.47}$$

Lema 9.4.4. Sea $X_{n,m}$, $1 \le m \le n$, un arreglo triangular de variables aleatorias, $S_{n,m} = X_{n,1} + \cdots + X_{n,m}$, y suponga que $S_{n,m} = B(\tau_m^n)$. Sea

$$S_{n,(u)} = \begin{cases} S_{n,m} & \text{si } u = m \in \{0, 1, \ldots, n\}, \\ \text{lineal para } u \in [m-1, m] & \text{cuando } m \in \{1, \ldots, n\}. \end{cases} \tag{9.48}$$

Si $\tau^n_{[ns]} \to s$ en probabilidad para cada $s \in [0,1]$, entonces $\|S_{n,(n\cdot)} - B(\cdot)\| \to 0$ en probabilidad.

Lema 9.4.5. Si φ es acotada y continua, entonces $E\varphi(S_{n,(n\cdot)}) \to E\varphi(B(\cdot))$.

Definición 9.4.17 Convergencia débil en $C[0,\infty)$. Sea $C[0,\infty) = \{\omega : [0,\infty) \to \mathbb{R} \text{ continuas}\}$ con la σ-álgebra generada por los conjuntos finito-dimensionales. Dada una medida de probabilidad μ en $C[0,\infty)$, sea $\pi_M\mu = \mu \circ \psi_M^{-1}$ la medida correspondiente en $C[0,M]$ obtenida "cortando las trayectorias al tiempo M", donde $(\psi_M\omega)(t) = \omega(t)$ para $t \in [0,M]$. Se dice que una sucesión de medidas de probabilidad μ_n en $C[0,\infty)$ *converge débilmente* a μ si para todo M, $\pi_M\mu_n$ converge débilmente a $\pi_M\mu$ en $C[0,M]$.

Teorema 9.4.46. $S(n\cdot)/\sqrt{n} \Rightarrow B(\cdot)$, es decir, las medidas asociadas en $C[0,\infty)$ convergen débilmente.

Teorema 9.4.47 Strassen. Si S_n es una martingala cuadrado integrable con $S_0 = 0$ y B_t es un movimiento browniano, entonces existe una sucesión de tiempos de paro $0 = T_0 \leq T_1 \leq T_2 \leq \cdots$ para el movimiento browniano tal que

$$(S_0, S_1, \ldots, S_k) \stackrel{d}{=} (B(T_0), B(T_1), \ldots, B(T_k)) \quad \text{para todo } k \geq 0. \tag{9.49}$$

Teorema 9.4.48. Sea $\mathcal{F}_m = \sigma(S_0, S_1, \ldots, S_m)$. Entonces $\lim_{n\to\infty} S_n$ existe y es finito en $\left\{\sum_{m=1}^{\infty} E((S_m - S_{m-1})^2|\mathcal{F}_{m-1}) < \infty\right\}$.

Definición 9.4.18 Arreglo de diferencias de martingala. Se dice que $X_{n,m}, \mathcal{F}_{n,m}$, $1 \leq m \leq n$, es un *arreglo de diferencias de martingala* si $X_{n,m} \in \mathcal{F}_{n,m}$ y $E(X_{n,m}|\mathcal{F}_{n,m-1}) = 0$ para $1 \leq m \leq n$, donde $\mathcal{F}_{n,0} = \{\varnothing, \Omega\}$. Se definen $S_{n,m} = X_{n,1} + \cdots + X_{n,m}$ y

$$V_{n,k} = \sum_{1\leq m\leq k} E(X_{n,m}^2|\mathcal{F}_{n,m-1}). \tag{9.50}$$

Teorema 9.4.49 Freedman. Suponga que $\{X_{n,m}, \mathcal{F}_{n,m}\}$ es un arreglo de diferencias de martingala. Si

(i) para cada t, $V_{n,[nt]} \to t$ en probabilidad, y

(ii) $|X_{n,m}| \leq \varepsilon_n$ para todo m con $\varepsilon_n \to 0$,

entonces $S_{n,(n\cdot)} \Rightarrow B(\cdot)$.

Teorema 9.4.50 Teorema de Lindeberg-Feller para martingalas. Suponga que $X_{n,m}, \mathcal{F}_{n,m}$, $1 \leq m \leq n$, es un arreglo de diferencias de martingala. Si

(i) $V_{n,[nt]} \to t$ en probabilidad para todo $t \in [0,1]$, y

(ii) para todo $\varepsilon > 0$, $\sum_{m\leq n} E(X_{n,m}^2 1_{(|X_{n,m}|>\varepsilon)}|\mathcal{F}_{n,m-1}) \to 0$ en probabilidad,

entonces $S_{n,(n\cdot)} \Rightarrow B(\cdot)$.

Lema 9.4.6. Bajo las hipótesis del teorema anterior, sea

$$\hat{V}_n(\varepsilon) = \sum_{m=1}^{n} E(X_{n,m}^2 1_{(|X_{n,m}|>\varepsilon)}|\mathcal{F}_{n,m-1}). \tag{9.51}$$

Si $\varepsilon_n \to 0$ suficientemente despacio, entonces $\varepsilon_n^{-2}\hat{V}_n(\varepsilon_n) \to 0$ en probabilidad.

Lema 9.4.7. Sean $\hat{X}_{n,m} = X_{n,m}1_{(|X_{n,m}|>\varepsilon_n)}$, $\bar{X}_{n,m} = X_{n,m}1_{(|X_{n,m}|\leq\varepsilon_n)}$ y $\tilde{X}_{n,m} = \bar{X}_{n,m} - E(\bar{X}_{n,m}|\mathcal{F}_{n,m-1})$. Si se define $\tilde{S}_{n,(n\cdot)}$ de la manera obvia, entonces $\tilde{S}_{n,(n\cdot)} \Rightarrow B(\cdot)$.

Lema 9.4.8 Dvoretsky. Si A_n está adaptada a $\mathcal{G}_n$, entonces para cualquier $\delta \geq 0$ con $\delta \in \mathcal{G}_0$,

$$P(\cup_{m=1}^{n} A_m|\mathcal{G}_0) \leq \delta + P\left(\sum_{m=1}^{n} P(A_m|\mathcal{G}_{m-1}) > \delta \,\middle|\, \mathcal{G}_0\right). \tag{9.52}$$

Teorema 9.4.51 Teorema central del límite para martingalas. Suponga que $X_n, \mathcal{F}_n$, $n \geq 1$, es una sucesión de diferencias de martingala y sea $V_k = \sum_{1\leq n\leq k} E(X_n^2|\mathcal{F}_{n-1})$. Si

(i) $V_k/k \to \sigma^2 > 0$ en probabilidad, y

(ii) $n^{-1}\sum_{m\leq n} E(X_m^2 1_{(|X_m|>\varepsilon\sqrt{n})}) \to 0$,

entonces $S(n\cdot)/\sqrt{n} \Rightarrow \sigma B(\cdot)$.

Teorema 9.4.52 Billingsley-Ibragimov. Suponga que X_n, $n \in \mathbb{Z}$, es una sucesión estacionaria ergódica de diferencias de martingala cuadrado integrables, es decir, $\sigma^2 = EX_n^2 < \infty$ y $E(X_n|\mathcal{F}_{n-1}) = 0$, donde $\mathcal{F}_n = \sigma(X_m, m \leq n)$. Sea $S_n = X_1 + \cdots + X_n$. Entonces

$$S(n\cdot)/n^{1/2} \Rightarrow \sigma B(\cdot). \tag{9.53}$$

Teorema 9.4.53. Suponga que X_n, $n \in \mathbb{Z}$, es una sucesión estacionaria ergódica con $EX_n = 0$. Sea $\mathcal{F}_n$ una familia de σ-álgebras que satisface

(i) $n \mapsto \mathcal{F}_n$ es creciente y $X_n \in \mathcal{F}_n$,

(ii) $\theta^{-1}\mathcal{F}_m = \mathcal{F}_{m+1}$,

y

$$\sum_{n\geq 1} \|E(X_0|\mathcal{F}_{-n})\|_2 < \infty, \tag{9.54}$$

donde $\|Y\|_2 = (EY^2)^{1/2}$. Sea $S_n = X_1 + \cdots + X_n$. Entonces $S(n\cdot)/\sqrt{n} \Rightarrow \sigma B(\cdot)$, donde

$$\sigma^2 = EX_0^2 + 2\sum_{n=1}^{\infty} EX_0X_n, \tag{9.55}$$

y la serie que define a σ^2 converge absolutamente.

Definición 9.4.19 Coeficiente de dependencia α. Para σ-álgebras $\mathcal{G}$ y $\mathcal{H}$ se define

$$\alpha(\mathcal{G},\mathcal{H}) = \sup\{|P(A\cap B) - P(A)P(B)| : A\in\mathcal{G}, B\in\mathcal{H}\}. \tag{9.56}$$

Lema 9.4.9. Sean $p,q,r\in(1,\infty]$ con $1/p+1/q+1/r=1$, y suponga que $X\in\mathcal{G}$, $Y\in\mathcal{H}$ tienen $E|X|^p, E|Y|^q<\infty$. Entonces

$$|EXY - EXEY| \le 8\|X\|_p\|Y\|_q(\alpha(\mathcal{G},\mathcal{H}))^{1/r}. \tag{9.57}$$

Aquí se interpreta $x^0=1$ para $x>0$ y $0^0=0$.

Teorema 9.4.54. Suponga que X_n, $n\in\mathbb{Z}$, es una sucesión estacionaria ergódica con $EX_n=0$ y $E|X_0|^{2+\delta}<\infty$. Sea $\alpha(n)=\alpha(\mathcal{F}_{-n},\sigma(X_0))$, donde $\mathcal{F}_{-n}=\sigma(X_m : m\le -n)$, y suponga que

$$\sum_{n=1}^{\infty}\alpha(n)^{\delta/2(2+\delta)}<\infty. \tag{9.58}$$

Si $S_n=X_1+\cdots+X_n$, entonces $S(n\cdot)/\sqrt{n}\Rightarrow\sigma B(\cdot)$, donde

$$\sigma^2 = EX_0^2 + 2\sum_{n=1}^{\infty}EX_0X_n. \tag{9.59}$$

Definición 9.4.20 Distribución empírica. Sean $X_1,X_2,\ldots$ i.i.d. con distribución F. La *distribución empírica* es

$$\hat{F}_n(x) = \frac{1}{n}|\{m\le n : X_m\le x\}|. \tag{9.60}$$

Teorema 9.4.55 Teorema de Glivenko-Cantelli. Cuando $n\to\infty$,

$$\sup_x |F_n(x)-F(x)|\to 0 \quad \text{c.s.} \tag{9.61}$$

Lema 9.4.10. Sean $W_1,W_2,\ldots$ i.i.d. con $P(W_i>t)=e^{-t}$ y $Z_n=W_1+\cdots+W_n$. Si $U_1^n<U_2^n<\cdots<U_n^n$ son los estadísticos de orden de n variables i.i.d. uniformes en $(0,1)$, entonces

$$\{U_k^n : 1\le k\le n\} \overset{d}{=} \{Z_k/Z_{n+1} : 1\le k\le n\}. \tag{9.62}$$

Teorema 9.4.56. Sean $Y_1,Y_2,\ldots$ i.i.d. uniformes en $(0,1)$, $\hat{G}_n(y)=\frac{1}{n}|\{m\le n : Y_m\le y\}|$ y $D_n\equiv n^{1/2}\sup_{0<y<1}|\hat{G}_n(y)-y|$. Entonces

$$D_n \Rightarrow \max_{0\le t\le 1}|B_t - tB_1|, \tag{9.63}$$

donde B_t es un movimiento browniano que comienza en 0.

Definición 9.4.21 Puente browniano. El *puente browniano* B_t^0 es el proceso

$$\{B_t - tB_1, 0 \le t \le 1\} \stackrel{d}{=} \{B_t, 0 \le t \le 1 | B_1 = 0\}, \tag{9.64}$$

donde las distribuciones finito-dimensionales del lado derecho están dadas por

$$P(B(t_1) = x_1, \dots, B(t_n) = x_n | B(1) = 0) = \frac{1}{p_1(0,0)} \prod_{m=1}^{n+1} p_{t_m - t_{m-1}}(x_{m-1}, x_m), \tag{9.65}$$

con $0 = t_0 < t_1 < \cdots < t_n < t_{n+1} = 1$, $x_0 = 0$, $x_{n+1} = 0$ y $p_t(x,y) = (2\pi t)^{-1/2} \exp(-(y-x)^2/2t)$.

Teorema 9.4.57. La densidad de B_t en $\{T_a \wedge T_b > t\}$ es

$$P_x(T_a \wedge T_b > t, B_t = y) = \sum_{n=-\infty}^{\infty} \left[P_x(B_t = y + 2n(b-a)) - P_x(B_t = 2b - y + 2n(b-a)) \right]. \tag{9.66}$$

Proposición 9.4.9. Para el puente browniano,

$$P_0 \left(a < \min_{0 \le t \le 1} B_t^0 < \max_{0 \le t \le 1} B_t^0 < b \right) = \sum_{n=-\infty}^{\infty} \left(e^{-(2n(b-a))^2/2} - e^{-(2b+2n(b-a))^2/2} \right). \tag{9.67}$$

En particular, tomando $a = -b$,

$$P_0 \left(\max_{0 \le t \le 1} |B_t^0| < b \right) = \sum_{m=-\infty}^{\infty} (-1)^m e^{-2m^2 b^2}. \tag{9.68}$$

Teorema 9.4.58 Ley del logaritmo iterado para el movimiento browniano.

$$\limsup_{t \to \infty} B_t / (2t \log\log t)^{1/2} = 1 \quad \text{c.s.} \tag{9.69}$$

Teorema 9.4.59 Hartman-Wintner. Si $X_1, X_2, \dots$ son i.i.d. con $EX_i = 0$ y $EX_i^2 = 1$, entonces

$$\limsup_{n \to \infty} S_n / (2n \log\log n)^{1/2} = 1. \tag{9.70}$$

Teorema 9.4.60 Principio de invariancia de Strassen. Sean $X_1, X_2, \dots$ i.i.d. con $EX_i = 0$ y $EX_i^2 = 1$, sea $S_n = X_1 + \cdots + X_n$ y sea $S(n\cdot)$ la interpolación lineal usual. El conjunto límite (es decir, la colección de límites de subsucesiones convergentes) de

$$Z_n(\cdot) = (2n \log\log n)^{-1/2} S(n\cdot) \quad \text{para } n \ge 3 \tag{9.71}$$

es

$$K = \left\{ f : f(x) = \int_0^x g(y)\, dy \text{ con } \int_0^1 g(y)^2\, dy \le 1 \right\}. \tag{9.72}$$

10
Integrales estocásticas

10.1. Integral Estocástica para Integrandos Simples

Definición 10.1.1 Integrandos simples $\mathcal{S}(T)$. Sea $\mathcal{S}(T)$ la colección de todos los procesos de la forma

$$f(\omega, s) = \sum_{k=0}^{n-1} a_k(\omega)\, \mathbf{1}_{(t_k, t_{k+1}]}(s), \quad \forall \omega \in \Omega,\ s \in [0, T], \tag{10.1}$$

donde $0 = t_0 < t_1 < \cdots < t_n = T$ es una partición de $[0, T]$, y para cada k, a_k es $\mathcal{F}_{t_k}$-medible con $E(|a_k|^2) < \infty$.

Definición 10.1.2 Integral estocástica para procesos simples. Sea $f \in \mathcal{S}(T)$ de la forma anterior. Definimos la integral estocástica de f respecto a B en $[0, T]$ como la variable aleatoria

$$I(f)(\omega) = \sum_{k=0}^{n-1} a_k(\omega)(B_{t_{k+1}}(\omega) - B_{t_k}(\omega)), \quad \forall \omega \in \Omega. \tag{10.2}$$

Lema 10.1.1 Integral estocástica de la indicadora. Para todo $0 \leq a < b \leq T$,

$$\int_0^T \mathbf{1}_{[a,b]}(s)\, dB_s = B_b - B_a. \tag{10.3}$$

Demostración. Note que por definicion de función indicadora, cada $a_k = 1, \forall_k$, en cuyo caso se obtiene el resultado de forma inmediata.

□

Lema 10.1.2 Linealidad de la integral estocástica para procesos simples. Para todo $f, g \in \mathcal{S}(T)$ y $\lambda \in \mathbb{R}$,

$$I(\lambda f + g) = \lambda I(f) + I(g). \tag{10.4}$$

Demostración. Sean f y g funciones de la forma

$$f(\omega, s) = \sum_{k=0}^{n-1} a_k(\omega)\, \mathbf{1}_{(t_k, t_{k+1}]}(s), \quad g(\omega, s) = \sum_{k=0}^{m-1} b_k(\omega)\, \mathbf{1}_{(u_k, u_{k+1}]}(s).$$

Si las particiones $\{t_k\}$ y $\{u_k\}$ coinciden, el cálculo es inmediato

$$I(\lambda f + g) = \sum_k \left(\lambda a_k(\omega) + b_k(\omega)\right)\left(B_{t_{k+1}} - B_{t_k}\right) = \lambda I(f) + I(g).$$

En el caso general, las particiones que definen a f y a g pueden ser distintas. Sea Δ una partición más fina que contiene a todos los puntos de ambas particiones. Reescribimos f y g respecto a Δ, de modo que

$$f(\omega, s) = \sum_j \tilde{a}_j(\omega)\, \mathbf{1}_{(\tau_j, \tau_{j+1}]}(s), \quad g(\omega, s) = \sum_j \tilde{b}_j(\omega)\, \mathbf{1}_{(\tau_j, \tau_{j+1}]}(s).$$

Entonces

$$I(\lambda f + g) = \sum_j \left(\lambda \tilde{a}_j(\omega) + \tilde{b}_j(\omega)\right)\left(B_{\tau_{j+1}} - B_{\tau_j}\right) = \lambda I(f) + I(g).$$

□

Lema 10.1.3 Media de la integral estocástica simple. Para todo $f \in \mathcal{S}(T)$,

$$\mathbb{E}[I(f)] = 0. \tag{10.5}$$

Demostración. Basta notar que a_k es $(\mathcal{F}_{t_k})$-medible por lo que $\mathbb{E}[a_k(B_{t_{k+1}} - B_{t_k})] = \mathbb{E}[a_k]\mathbb{E}[B_{t_{k+1}} - B_{t_k}]$ al aplicar la propiedad de la torre, donde $B_{t_{k+1}} - B_{t_k} \overset{d}{=} \mathcal{N}(0, t_{k+1} - t_k)$. □

Lema 10.1.4 Isometría de Itô. Para todo $f \in \mathcal{S}(T)$,

$$\mathbb{E}[I(f)^2] = \mathbb{E}\left[\int_0^T f(s)^2\, ds\right]. \tag{10.6}$$

Demostración. Por definición se tiene

$$I(f)(\omega)^2 = \sum_{l=0}^{n-1}\sum_{k=0}^{n-1} a_l(\omega)\, a_k(\omega)\left(B_{t_{l+1}}(\omega) - B_{t_l}(\omega)\right)\left(B_{t_{k+1}}(\omega) - B_{t_k}(\omega)\right).$$

En cuyo caso dado que la esperanza de brownianos (ejercicio de la lista, igual se saca con propiedad de la torre) en intervalos distintos es 0, se tiene que

$$\mathbb{E}[I(f)(\omega)^2] = \mathbb{E}\left[\sum_{k=0}^{n-1} a_k^2 (B_{t_{k+1}} - B_{t_k})^2\right] = \sum_{k=0}^{n-1} a_k^2 (t_{k+1} - t_k).$$

Por otro lado

$$\mathbb{E}\left[\int_0^T f(s)^2\,ds\right] = \mathbb{E}\left[\int_0^T \sum_{k=0}^{n-1} a_k^2\,\mathbf{1}_{(t_k,t_{k+1}]}(s),\,ds\right] = \sum_{k=0}^{n-1} a_k^2(t_{k+1}-t_k)$$

□

Definición 10.1.3 Integral estocástica como proceso. Sea $f \in \mathcal{S}(T)$. Para cada $t \in [0,T]$, define

$$I_t(f)(\omega) = I(\mathbf{1}_{[0,t]}f)(\omega), \quad \forall \omega \in \Omega. \tag{10.7}$$

Al proceso $(I_t(f) : t \in [0,T])$ se le llama la integral estocástica de f.

Proposición 10.1.1. Sea $f \in \mathcal{S}(T)$. La integral estocástica $(I_t(f) : t \in [0,T])$ es una martingala con media cero, cuadrado integrable, con trayectorias continuas y tal que

$$\mathbb{E}[I_t(f)^2] = \mathbb{E}\left[\int_0^t f(s)^2\,ds\right] \quad \forall t \in [0,T]. \tag{10.8}$$

Demostración. Tome $0 \leq s < t \leq T$ y note que

$$\mathbb{E}\left[I_t(f) \mid \mathcal{F}_s\right] = I_s(f) + \mathbb{E}\left[I_t(f) - I_s(f) \mid \mathcal{F}_s\right],$$

si tomamos una partición lo suficientemente fina Δ donde $s = t_1 < t_{l+1} < t_j = t$, se tiene que por propiedad de la torre

$$\mathbb{E}\left[I_t(f) - I_s(f) \mid \mathcal{F}_s\right] = \mathbb{E}\left[\sum_{k=l}^{j-1} a_k\left(B_{t_{k+1}} - B_{t_k}\right)\Big|\,\mathcal{F}_s\right] = \sum_{k=l}^{j-1} \mathbb{E}\left[a_k \mid \mathcal{F}_s\right]\mathbb{E}[B_{t_{k+1}} - B_{t_k}] = 0.$$

sumado a ello por el lema de la media de la integral simple se tiene que $\mathbb{E}[I_t(f)] = 0$. Por otro lado note que

$$\mathbb{E}[I_t(f)^2] = \mathbb{E}[I(1_{[0,t]}f)] = \mathbb{E}\left(\int_0^t 1_{[0,t]}(s)\,f(s)^2\,ds\right) = \mathbb{E}\left(\int_0^t f(s)^2\,ds\right) < \infty.$$

□

10.2. Integral Estocástica para Integrandos en $H^2(T)$

Definición 10.2.1 Integrandos cuadrado integrables $H^2(T)$. Denotaremos mediante $H^2(T)$ la colección de todas las funciones $f : \Omega \times [0,T] \to \mathbb{R}$ que son $\mathcal{F}_T \otimes \mathcal{B}([0,T])$-medibles, $(\mathcal{F}_t)$-adaptadas, y tales que

$$\mathbb{E}\left[\int_0^T f(s)^2\,ds\right] < \infty. \tag{10.9}$$

Teorema 10.2.1 Densidad de procesos simples. Para cada $f \in H^2(T)$, existe una sucesión $(f_n : n \in \mathbb{N}) \subseteq \mathcal{S}(T)$ tal que

$$\lim_{n\to\infty} \mathbb{E}\left[\int_0^T |f(s) - f_n(s)|^2\,ds\right] = 0. \tag{10.10}$$

Teorema 10.2.2 Convergencia de martingalas cuadrado integrables. Considere una sucesión $(M^{(n)} : n \in \mathbb{N})$ donde cada $M^{(n)} = (M_t^{(n)} : t \in [0,T])$ es una martingala cuadrado integrable con trayectorias continuas. Si $(M^{(n)})$ es una sucesión de Cauchy uniformemente en $[0,T]$, entonces existe una martingala cuadrado integrable con trayectorias continuas $(M_t : t \in [0,T])$ tal que

$$\lim_{n\to\infty} \mathbb{E}\left[\sup_{0\le t\le T} |M_t^{(n)} - M_t|^2\right] = 0. \tag{10.11}$$

Teorema 10.2.3 Existencia y propiedades de la integral estocástica. Para cada $f \in H^2(T)$, existe una martingala con media cero, cuadrado integrable, con trayectorias continuas, denotada $(I_t(f) : t \in [0,T])$, tal que

$$\mathbb{E}[I_t(f)^2] = \mathbb{E}\left[\int_0^t f(s)^2\, ds\right], \quad \forall t \in [0,T]. \tag{10.12}$$

Demostración. Cada proceso $I_t(f_n)$ es una martingala cuadrado integrable con media cero y trayectorias continuas. Dados $m, n \ge 0$, por la desigualdad maximal de Doob y la proposición anterior

$$\lim_{m,n\to\infty} \mathbb{E}\Big[\sup_{0\le t\le T} |I_t(f_n) - I_t(f_m)|^2\Big] \le 4 \lim_{m,n\to\infty} \mathbb{E}[|I_T(f_n) - I_T(f_m)|^2].$$

Por la isometría de Itô

$$\mathbb{E}[|I_T(f_n) - I_T(f_m)|^2] = \mathbb{E}\left[\int_0^T |f_n(s) - f_m(s)|^2 ds\right].$$

Como $f_n \to f$ en $L^2(\Omega \times [0,T])$, se concluye

$$\lim_{m,n\to\infty} \mathbb{E}\left[\int_0^T |f_n(s) - f_m(s)|^2 ds\right] = 0,$$

y por tanto $I_t(f_n)$ es de Cauchy en $L^2(\Omega)$ uniformemente en t. La existencia de $I_t(f)$ y el hecho de que es una martingala cuadrado integrable con trayectorias continuas es consecuencia del. Además, no depende de la sucesión (f_n) que converge a f, por lo que es único. Para cada $t \in [0,T]$, la convergencia $I_t(f_n) \to I_t(f)$ en $L^2(\Omega)$ implica convergencia en $L^1(\Omega)$. Como $\mathbb{E}[I_t(f_n)] = 0$ entonces

$$\mathbb{E}[I_t(f)] = \lim_{n\to\infty} \mathbb{E}[I_t(f_n)] = 0.$$

Finalmente, usando la isometría de Itô y la convergencia $f_n \to f$ en $L^2(\Omega \times [0,T])$,

$$\mathbb{E}[I_t(f)^2] = \lim_{n\to\infty} \mathbb{E}[I_t(f_n)^2] = \lim_{n\to\infty} \mathbb{E}\left[\int_0^t f_n(s)^2 ds\right] = \mathbb{E}\left[\int_0^t f(s)^2 ds\right].$$

□

Definición 10.2.2 Integral estocástica en $H^2(T)$. Al proceso definido en el teorema anterior le llamaremos la integral estocástica del proceso $f \in H^2(T)$.

Proposición 10.2.1 Linealidad en $H^2(T)$. Si $f, g \in H^2(T)$ y $\lambda \in \mathbb{R}$,

$$\int_0^t (\lambda f(s) + g(s))\, dB_s = \lambda \int_0^t f(s)\, dB_s + \int_0^t g(s)\, dB_s, \quad \forall t \in [0,T]. \tag{10.13}$$

Demostración. La linealidad ya fue establecida para procesos simples. Sea ahora $f, g \in H^2(T)$ y $(f_n), (g_n)$ sucesiones de procesos simples tales que $f_n \to f,\ g_n \to g$ en $L^2(\Omega \times [0,T])$. Por la continuidad de la integral de Itô en $L^2(\Omega)$ (isometría de Itô), se tiene

$$I_t(f_n) \to I_t(f), \quad I_t(g_n) \to I_t(g), \quad \text{en } L^2(\Omega).$$

Además, para cada n $I_t(\lambda f_n + g_n) = \lambda I_t(f_n) + I_t(g_n)$.. Tomando límite en $L^2(\Omega)$ cuando $n \to \infty$, se obtiene

$$I_t(\lambda f + g) = \lambda I_t(f) + I_t(g), \quad \forall t \in [0,T].$$

□

10.3. Integral Estocástica General

Definición 10.3.1 Integrandos localmente cuadrado integrables $H^2_{\text{loc}}(T)$. Denotaremos mediante $H^2_{\text{loc}}(T)$ la colección de funciones $f : \Omega \times [0,T] \to \mathbb{R}$ que son $\mathcal{F}_T \otimes \mathcal{B}([0,T])$-medibles, $(\mathcal{F}_t)$-adaptadas, y tales que

$$P\left(\omega \in \Omega : \int_0^T f(\omega, s)^2\, ds < \infty\right) = 1. \tag{10.14}$$

Teorema 10.3.1 Existencia de la integral general. Para cada $f \in H^2_{\text{loc}}(T)$, existe un proceso estocástico $(I_t(f) : t \in [0,T])$ con trayectorias continuas que es localmente una martingala con media cero cuadrado integrable.

Demostración. Sea $f \in H^2_{\text{loc}}(T)$. Para cada $n \geq 1$ definimos

$$\tau_n(\omega) := \text{ínf}\left\{t \geq 0 : \int_0^t f(\omega, s)^2\, ds \geq n \text{ o } t \geq T\right\}.$$

Se cumple

$$\mathbb{P}\Big(\bigcup_{n=1}^{\infty} \{\tau_n = T\}\Big) = \mathbb{P}\left(\int_0^T f(s)^2\, ds < \infty\right) = 1,$$

de modo que $\lim_{n\to\infty} \tau_n = T$ c.s. Además, para cada n,

$$\mathbb{E}\left[\int_0^T f(s)^2 \mathbf{1}_{[0,\tau_n]}(s)\, ds\right] \leq n < \infty,$$

y por tanto $f\mathbf{1}_{[0,\tau_n]} \in H^2(T)$. La integral $I_t(f\mathbf{1}_{[0,\tau_n]})$ cumple las propiedades del teorema de existencia y propiedades de la integral estocastica. Tomando

$$I_t(f)(\omega) := I_t(f\mathbf{1}_{[0,\tau_n]})(\omega),$$

donde se escoge n tal que $\tau_n(\omega) \geq t$. Para cada n,

$$I_{t\wedge\tau_n}(f) = I_t(f\mathbf{1}_{[0,\tau_n]}),$$

y por tanto $I_{t\wedge\tau_n}(f)$ es una martingala cuadrado integrable con media cero. □

Definición 10.3.2 Integral estocástica general. Al proceso definido en el teorema anterior le llamaremos la integral estocástica del proceso $f \in H^2_{\text{loc}}(T)$.

Proposición 10.3.1 Linealidad en $H^2_{\text{loc}}(T)$. Si $f, g \in H^2_{\text{loc}}(T)$ y $\lambda \in \mathbb{R}$,

$$\int_0^t (\lambda f(s) + g(s))\, dB_s = \lambda \int_0^t f(s)\, dB_s + \int_0^t g(s)\, dB_s. \tag{10.15}$$

Es consecuencia de la linealidad en $H^2(T)$.

10.4. Fórmula de Itô

Proposición 10.4.1 Continuidad de la integral estocástica en $H^2(T)$. Sean $f, f_n \in H^2(T)$, $n \in \mathbb{N}$. Si

$$\mathbb{E}\left[\int_0^T |f(s) - f_n(s)|^2\, ds\right] \to 0, \tag{10.16}$$

entonces para todo $t \in [0,T]$,

$$\int_0^t f_n(s)\, dB_s \xrightarrow{L^2} \int_0^t f(s)\, dB_s. \tag{10.17}$$

La integral también es continua como operador definido para los integrandos en $H^2_{\text{loc}}(T)$.

Es consecuencia directa de la isometria de ito.

Proposición 10.4.2 Continuidad de la integral estocástica en $H^2_{\text{loc}}(T)$. Sean $f, f_n \in H^2_{\text{loc}}(T)$, $n \in \mathbb{N}$. Si

$$\int_0^T |f(s) - f_n(s)|^2\, ds \xrightarrow{\mathbb{P}} 0, \tag{10.18}$$

entonces para todo $t \in [0,T]$,

$$\int_0^t f_n(s)\, dB_s \xrightarrow{\mathbb{P}} \int_0^t f(s)\, dB_s. \tag{10.19}$$

Demostración. Definase los tiempos de parada $\tau_n(\omega) := \inf\left\{t \geq 0 : \int_0^t f(\omega, s)^2\, ds \geq n \text{ o } t \geq T\right\}$.. Entonces $f \cdot 1_{[0,\tau_n]} \in H^2(T)$. Por la continuidad en L^2 ya demostrada, se cumple

$$\int_0^t f_n(s) 1_{[0,\tau_n]}(s)\, dB_s \xrightarrow{L^2} \int_0^t f(s) 1_{[0,\tau_n]}(s)\, dB_s.$$

de forma que $\lim_{n\to\infty} \tau_n = T$ c.s. y por tanto

$$\int_0^t f_n(s)\, dB_s \xrightarrow{\mathbb{P}} \int_0^t f(s)\, dB_s, \quad \forall t \in [0,T].$$

□

Teorema 10.4.1 Representación de Riemann. Suponga que $g : \mathbb{R} \to \mathbb{R}$ es continua. Considere una sucesión de particiones $\Delta_n = \{0 = t_{n,0} < t_{n,1} < \cdots < t_{n,m_n} = T\}$ de $[0,T]$ con $|\Delta_n| = \max_{0\le k\le m_n-1} |t_{n,k+1} - t_{n,k}| \to 0$ cuando $n \to \infty$. Entonces,

$$\sum_{k=0}^{m_n-1} g(B_{t_{n,k}}) \, (B_{t_{n,k+1}} - B_{t_{n,k}}) \xrightarrow{\mathbb{P}} \int_0^T g(B_s) \, dB_s. \tag{10.20}$$

Si además se cumple que

$$\mathbb{E}\left[\int_0^T g(B_s)^2 \, ds\right] < \infty, \tag{10.21}$$

tenemos

$$\sum_{k=0}^{m_n-1} g(B_{t_{n,k}}) \, (B_{t_{n,k+1}} - B_{t_{n,k}}) \xrightarrow{L^2} \int_0^T g(B_s) \, dB_s. \tag{10.22}$$

Demostración. Para cada $n \ge 1$, se define

$$f_n(\omega, s) = \sum_{k=0}^{m_n-1} g(B_{t_{n,k}}(\omega)) \, 1_{(t_{n,k}, t_{n,k+1}]}(s).$$

Claramente, cada $f_n \in \mathcal{S}(T)$ y además

$$\int_0^T f_n(s) \, dB_s = \sum_{k=0}^{m_n-1} g(B_{t_{n,k}}) \, (B_{t_{n,k+1}} - B_{t_{n,k}}).$$

Sea $f(\omega, s) = g(B_s)(\omega)$. Como las trayectorias $s \mapsto f(\omega, s)$ son continuas, entonces son Riemann-integrables en $[0,T]$. Se tiene

$$\int_0^T |f(s) - f_n(s)|^2 \, ds \xrightarrow{c.s.} 0.$$

Por la proposición anterior concluye que

$$\sum_{k=0}^{m_n-1} g(B_{t_{n,k}}) \, (B_{t_{n,k+1}} - B_{t_{n,k}}) = \int_0^T f_n(s) \, dB_s \xrightarrow{\mathbb{P}} \int_0^T f(s) \, dB_s = \int_0^T g(B_s) \, dB_s.$$

Por otro lado, si se cumple que

$$\mathbb{E}\left[\int_0^T g(B_s)^2 \, ds\right] < \infty,$$

entonces, por el teorema de convergencia dominada, se obtiene

$$\mathbb{E}\left[\int_0^T |f(s) - f_n(s)|^2 \, ds\right] \to 0.$$

En ese caso, por la Proposición 4.24 se concluye que

$$\sum_{k=0}^{m_n-1} g(B_{t_{n,k}}) \, (B_{t_{n,k+1}} - B_{t_{n,k}}) = \int_0^T f_n(s) \, dB_s \xrightarrow{L^2} \int_0^T f(s) \, dB_s = \int_0^T g(B_s) \, dB_s.$$

□

Proposición 10.4.3 Integral estocástica con integrando determinístico. Sea $g : [0,T] \to \mathbb{R}$ una función continua. Definimos

$$X_t = \int_0^t g(s)\, dB_s, \quad \forall t \in [0,T]. \tag{10.23}$$

Entonces el proceso $(X_t : t \in [0,T])$ es Gaussiano, tiene incrementos independientes, es una martingala con función de media igual a cero y función de covarianza

$$\mathrm{Cov}(X_s, X_t) = \int_0^{s\wedge t} g(u)^2\, du. \tag{10.24}$$

Además, para cada sucesión de particiones $\Delta_n = \{0 = t_{n,0} < t_{n,1} < \cdots < t_{n,m_n} = T\}$ con

$$|\Delta_n| = \max_{0\le k\le m_n-1} |t_{n,k+1} - t_{n,k}| \to 0, \tag{10.25}$$

se cumple

$$\sum_{k=0}^{m_n-1} g(t_{n,k})\,(B_{t_{n,k+1}} - B_{t_{n,k}}) \xrightarrow{L^2} \int_0^T g(s)\, dB_s. \tag{10.26}$$

A las integrales de la forma anterior se les suele llamar integrales de Wiener.

Teorema 10.4.2 Fórmula de Itô — Caso Simple. Si $f \in C^2(\mathbb{R})$, entonces c.s. se cumple $\forall t \ge 0$,

$$f(B_t) = f(B_0) + \int_0^t f'(B_s)\, dB_s + \frac{1}{2}\int_0^t f''(B_s)\, ds. \tag{10.27}$$

Equivalente en forma diferencial estocástica

$$df(B_t) = f'(B_t)\, dB_t + \tfrac{1}{2} f''(B_t)\, dt. \tag{10.28}$$

Teorema 10.4.3 Fórmula de Itô en Espacio y Tiempo. Si $f \in C^{1,2}([0,\infty)\times\mathbb{R})$, entonces c.s. se cumple $\forall t \ge 0$,

$$f(t,B_t) = f(0,B_0) + \int_0^t \frac{\partial f}{\partial s}(s,B_s)\, ds + \int_0^t \frac{\partial f}{\partial x}(s,B_s)\, dB_s + \frac{1}{2}\int_0^t \frac{\partial^2 f}{\partial x^2}(s,B_s)\, ds. \tag{10.29}$$

Equivalente en forma diferencial estocástica:

$$df(t,B_t) = \frac{\partial f}{\partial t}(t,B_t)\, dt + \frac{\partial f}{\partial x}(t,B_t)\, dB_t + \tfrac{1}{2}\frac{\partial^2 f}{\partial x^2}(t,B_t)\, dt. \tag{10.30}$$

10.5. Procesos de Itô

Definición 10.5.1 Proceso de Itô. Un proceso estocástico $(Y_t : t \ge 0)$ se llama un proceso de Itô si es de la forma

$$Y_t = Y_0 + \int_0^t \mu(s)\, ds + \int_0^t \sigma(s)\, dB_s, \quad \forall t \ge 0, \tag{10.31}$$

donde los procesos μ y σ son $(\mathcal{F}_t)$-adaptados con condiciones de integrabilidad apropiadas.

Equivalente en forma diferencial estocástica

$$dY_t = \mu(t)\,dt + \sigma(t)\,dB_t. \tag{10.32}$$

Proposición 10.5.1 Variación cuadrática de un proceso de Itô. Si $Y = (Y_t : t \geq 0)$ es un proceso de Itô, entonces Y es un proceso de variación cuadrática finita y, más aún, su variación cuadrática está dada por

$$[Y]_t = \int_0^t \sigma(s)^2\,ds, \quad \forall t \in [0,T]. \tag{10.33}$$

Definición 10.5.2 Integral respecto a un proceso de Itô. Sea $Y = (Y_t : t \geq 0)$ un proceso de Itô y sea $X = (X_t : t \geq 0)$ un proceso medible, adaptado, tal que para todo $T > 0$ satisface

$$\int_0^T |X_s\mu(s)|\,ds < \infty \quad \wedge \quad \int_0^T |X_s\sigma(s)|^2\,ds < \infty \quad \text{c.s..} \tag{10.34}$$

Definimos la integral estocástica de X respecto a Y como

$$\int_0^t X_s\,dY_s := \int_0^t X_s\mu(s)\,ds + \int_0^t X_s\sigma(s)\,dB_s, \quad \forall t \geq 0. \tag{10.35}$$

Equivalente en forma diferencial estocástica

$$dY_t = \mu(t)\,dt + \sigma(t)\,dB_t \quad \Longrightarrow \quad X_t\,dY_t = X_t\mu(t)\,dt + X_t\sigma(t)\,dB_t. \tag{10.36}$$

Teorema 10.5.1 Fórmula de Itô para un proceso de Itô. Si $f \in C^{1,2}([0,\infty)\times\mathbb{R})$ y $Y = (Y_t : t \geq 0)$ es un proceso de Itô con diferencial estocástico

$$dY_t = \mu(t)\,dt + \sigma(t)\,dB_t, \tag{10.37}$$

entonces c.s. se cumple $\forall t \geq 0$,

$$f(t,Y_t) = f(0,Y_0) + \int_0^t \frac{\partial f}{\partial s}(s,Y_s)\,ds + \int_0^t \frac{\partial f}{\partial x}(s,Y_s)\,dY_s + \frac{1}{2}\int_0^t \frac{\partial^2 f}{\partial x^2}(s,Y_s)\,\sigma(s)^2\,ds. \tag{10.38}$$

En forma de diferencial estocástico, la expresión anterior se escribe como:

$$df(t,Y_t) = \frac{\partial f}{\partial t}(t,Y_t)\,dt + \frac{\partial f}{\partial x}(t,Y_t)\,dY_t + \frac{1}{2}\frac{\partial^2 f}{\partial x^2}(t,Y_t)\,\sigma(t)^2\,dt. \tag{10.39}$$

Teorema 10.5.2 Fórmula de Itô para dos procesos de Itô. Sean $(X_t : t \geq 0)$ y $(Y_t : t \geq 0)$ dos procesos de Itô. Si $f \in C^{2,2}(\mathbb{R}\times\mathbb{R})$, entonces c.s. se cumple $\forall t \geq 0$,

$$f(X_t,Y_t) = f(X_0,Y_0) + \int_0^t \frac{\partial f}{\partial x}\,dX_s + \int_0^t \frac{\partial f}{\partial y}\,dY_s + \frac{1}{2}\int_0^t \left(\frac{\partial^2 f}{\partial x^2}\beta^2 + 2\frac{\partial^2 f}{\partial x\partial y}\beta\sigma + \frac{\partial^2 f}{\partial y^2}\sigma^2\right)(s)\,ds. \tag{10.40}$$

En forma de diferencial estocástico, la expresión anterior se escribe como

$$df(X_t,Y_t) = \frac{\partial f}{\partial x}(X_t,Y_t)\,dX_t + \frac{\partial f}{\partial y}(X_t,Y_t)\,dY_t + \frac{1}{2}\frac{\partial^2 f}{\partial x^2}(X_t,Y_t)\,\beta(t)^2\,dt + \frac{1}{2}\frac{\partial^2 f}{\partial y^2}(X_t,Y_t)\,\sigma(t)^2\,dt + \frac{\partial^2 f}{\partial x \partial y}(X_t,Y_t)\,\beta(t)\sigma(t)\,dt. \quad (10.41)$$

Corolario 10.5.1 Regla del producto estocástica. Sean $(X_t : t \geq 0)$ y $(Y_t : t \geq 0)$ dos procesos de Itô. Entonces c.s. se cumple $\forall t \geq 0$,

$$X_t Y_t = X_0 Y_0 + \int_0^t X_s\,dY_s + \int_0^t Y_s\,dX_s + \int_0^t \beta(s)\sigma(s)\,ds. \quad (10.42)$$

La prueba es casi directa usando $f(x,y) = xy$.

10.6. Caso Multidimensional

Definición 10.6.1 Integrando matricial en $H^2(T$ y $H^2_{\text{loc}}(T))$. Para $i = 1,\dots,m$, $j = 1,\dots,d$, sea σ_{ij} un proceso $\mathcal{F}_T \otimes \mathcal{B}([0,T])$-medible y $(\mathcal{F}_t)$-adaptado. Sea $\sigma = (\sigma_{ij})_{i,j}$ el proceso con valores matriciales de tamaño $m \times d$.

1. Se dice que $\sigma \in H^2(T)$ si cada $\sigma_{ij} \in H^2(T)$.
2. Se dice que $\sigma \in H^2_{\text{loc}}(T)$ si cada $\sigma_{ij} \in H^2_{\text{loc}}(T)$.

Definición 10.6.2 Integral matricial respecto al Browniano d-dimensional. Definimos la integral del proceso matricial σ respecto al movimiento Browniano d-dimensional $B = (B_t : t \geq 0)$ como el proceso con valores en $\mathbb{R}^m$, denotado $\int_0^t \sigma(s)\,dB_s$, cuya entrada i-ésima es

$$\left(\int_0^t \sigma(s)\,dB_s\right)_i := \sum_{j=1}^{d} \int_0^t \sigma_{ij}(s)\,dB_s^j. \quad (10.43)$$

Proposición 10.6.1 Isometría de Itô en dimensión matricial. Sea $\sigma = (\sigma_{ij})_{i,j} \in H^2(T)$. Para cada $t \in [0,T]$ se cumple que

$$\mathbb{E}\left[\left\|\int_0^t \sigma(s)\,dB_s\right\|^2\right] = \mathbb{E}\left[\int_0^t \operatorname{tr}(\sigma(s)\sigma(s)^*)\,ds\right], \quad (10.44)$$

donde $\sigma(\omega,s)^*$ es la matriz adjunta de $\sigma(\omega,s)$ y $\operatorname{tr}(\sigma(\omega,s)\sigma(\omega,s)^*)$ es la traza de la matriz $\sigma(\omega,s)\sigma(\omega,s)^*$.

Definición 10.6.3 Integral de un proceso vectorial. Sea $\mu = (\mu_1,\dots,\mu_m)$ un proceso en $\mathbb{R}^m$ tal que, para cada $i = 1,\dots,m$, la aplicación $\mu_i : \Omega \times [0,\infty) \to \mathbb{R}$ es un proceso estocástico medible y adaptado.

Suponemos que para cada i se cumple

$$\int_0^T |\mu_i(s)|\, ds < \infty \quad \text{c.s.}, \quad \forall T > 0. \tag{10.45}$$

Definimos entonces, para cada $t \geq 0$, la integral

$$\int_0^t \mu(s)\, ds \tag{10.46}$$

como la variable aleatoria en $\mathbb{R}^m$ cuya entrada i-ésima está dada por

$$\left(\int_0^t \mu(\omega, s)\, ds\right)_i = \int_0^t \mu_i(\omega, s)\, ds. \tag{10.47}$$

Definición 10.6.4 Proceso de Itô en $\mathbb{R}^m$. Un proceso estocástico $(Y_t : t \geq 0)$ en $\mathbb{R}^m$ se llama un proceso de Itô si es de la forma

$$Y_t = Y_0 + \int_0^t \mu(s)\, ds + \int_0^t \sigma(s)\, dB_s, \quad \forall t \geq 0, \tag{10.48}$$

donde μ es un proceso en $\mathbb{R}^m$ y σ es un proceso con valores matriciales de tamaño $m \times d$.

Teorema 10.6.1 Fórmula de Itô multidimensional. Si $f \in C^{2,1}([0,\infty) \times \mathbb{R}^m)$ y $(Y_t : t \geq 0)$ es un proceso de Itô en $\mathbb{R}^m$ con diferencial estocástico $dY_t = \mu(t)\, dt + \sigma(t)\, dB_t$, entonces el proceso $(f(t, Y_t) : t \geq 0)$ tiene diferencial estocástico

$$df(t, Y_t) = \frac{\partial f}{\partial t}(t, Y_t)\, dt + \sum_{i=1}^m \frac{\partial f}{\partial y_i}(t, Y_t)\, dY_t^i + \frac{1}{2} \sum_{i,j=1}^m \frac{\partial^2 f}{\partial y_i \partial y_j}(t, Y_t)\, d[Y^i, Y^j]_t. \tag{10.49}$$

11

Ecuaciones diferenciales estocásticas

11.1. Definiciones Básicas

Definición 11.1.1 Solución de una EDE. Un proceso estocástico $(X_t : t \geq 0)$ se dice que es una solución de la ecuación diferencial estocástica

$$dX_t = \mu(t, X_t)\, dt + \sigma(t, X_t)\, dB_t, \tag{11.1}$$

con condición inicial x_0, si:

1. X es un proceso adaptado.
2. $X_0 = x_0$ c.s.
3. Las integrales están bien definidas: $\forall T > 0$,

$$\mathbb{P}\left(\int_0^T |\mu(t, X_t)|\, dt + \int_0^T \sigma(t, X_t)^2\, dt < \infty \right) = 1. \tag{11.2}$$

4. $\forall t \geq 0$, X cumple con la ecuación integral c.s.:

$$X_t = x_0 + \int_0^t \mu(s, X_s)\, ds + \int_0^t \sigma(s, X_s)\, dB_s. \tag{11.3}$$

Definición 11.1.2 Unicidad de solución. Se dice que la EDE con condición inicial $X_0 = x_0$ tiene una única solución si dadas dos soluciones $X = (X_t)$ e $Y = (Y_t)$ se cumple que $P(X_t = Y_t,\ \forall t \geq 0) = 1$, es decir que los procesos son indistinguibles.

11.2. Ecuaciones Diferenciales Estocásticas Lineales

Definición 11.2.1 EDE lineal. Una ecuación diferencial estocástica se dice que es lineal si tiene la forma

$$dX_t = [f(t)X_t + g(t)]\,dt + [\varphi(t)X_t + \theta(t)]\,dB_t, \tag{11.4}$$

donde f, g, φ, θ son procesos estocásticos adaptados tales que las respectivas integrales existen.

Teorema 11.2.1. Para la ecuación diferencial estocástica lineal

$$dX_t = [f(t)X_t + g(t)]\,dt + [\varphi(t)X_t + \theta(t)]\,dB_t, \quad X_0 = x_0, \tag{11.5}$$

una solución es de la forma

$$X_t = U_t \cdot V_t, \quad \forall t \geq 0, \tag{11.6}$$

donde

$$U_t = \exp\left(\int_0^t (f(s) - \tfrac{1}{2}\varphi(s)^2)\,ds + \int_0^t \varphi(s)\,dB_s\right), \tag{11.7}$$

y

$$V_t = x_0 + \int_0^t \frac{g(s) - \varphi(s)\theta(s)}{U_s}\,ds + \int_0^t \frac{\theta(s)}{U_s}\,dB_s. \tag{11.8}$$

Teorema 11.2.2 Exponencial estocástica. Sea $Y = (Y_t : t \geq 0)$ un proceso de Itô con diferencial estocástico $dY_t = \mu(t)\,dt + \sigma(t)\,dB_t$, $Y_0 = y_0$. La única solución a la ecuación diferencial estocástica

$$dU_t = U_t\,dY_t, \quad U_0 = u_0, \tag{11.9}$$

es el proceso $U = (U_t : t \geq 0)$ definido por

$$U_t = u_0 \exp\left(Y_t - y_0 - \frac{1}{2}\int_0^t \sigma(s)^2\,ds\right), \quad \forall t \geq 0. \tag{11.10}$$

Al proceso U se le llama la exponencial estocástica del proceso Y.

Demostración. Sea el proceso auxiliar $X_t = B_t e^{B_t}$. Aplicamos la fórmula de Itô para productos:

$$dX_t = B_t\,d(e^{B_t}) + e^{B_t}\,dB_t + d\langle B, e^B\rangle_t.$$

Como

$$d(e^{B_t}) = e^{B_t}\,dB_t + \tfrac{1}{2}e^{B_t}\,dt, \qquad d\langle B, e^B\rangle_t = e^{B_t}\,dt,$$

se obtiene

$$dX_t = (B_t e^{B_t} + e^{B_t})\,dB_t + \left(\tfrac{1}{2}B_t e^{B_t} + e^{B_t}\right)dt.$$

De aquí se deduce que

$$B_t e^{B_t}\,dB_t = dX_t - e^{B_t}\,dB_t - \left(\tfrac{1}{2}B_t e^{B_t} + e^{B_t}\right)dt.$$

Integrando de 0 a t:

$$\int_0^t B_r e^{B_r}\,dB_r = X_t - \int_0^t e^{B_r}\,dB_r - \frac{1}{2}\int_0^t B_r e^{B_r}\,dr - \int_0^t e^{B_r}\,dr.$$

Finalmente, como $X_t = B_t e^{B_t}$, queda

$$\int_0^t B_r e^{B_r}\,dB_r = B_t e^{B_t} - \int_0^t e^{B_r}\,dB_r - \frac{1}{2}\int_0^t B_r e^{B_r}\,dr - \int_0^t e^{B_r}\,dr.$$

Esto demuestra la identidad buscada. □

Demostración. Sea el proceso auxiliar $X_t = B_t e^{B_t}$. Aplicamos la fórmula de Itô para productos:

$$dX_t = B_t\,d(e^{B_t}) + e^{B_t}\,dB_t + d\langle B, e^B\rangle_t.$$

Como

$$d(e^{B_t}) = e^{B_t}\,dB_t + \tfrac{1}{2}e^{B_t}\,dt, \qquad d\langle B, e^B\rangle_t = e^{B_t}\,dt,$$

se obtiene

$$dX_t = (B_t e^{B_t} + e^{B_t})\,dB_t + \left(\tfrac{1}{2}B_t e^{B_t} + e^{B_t}\right)dt.$$

De aquí se deduce que

$$B_t e^{B_t}\,dB_t = dX_t - e^{B_t}\,dB_t - \left(\tfrac{1}{2}B_t e^{B_t} + e^{B_t}\right)dt.$$

Integrando de 0 a t:

$$\int_0^t B_r e^{B_r}\,dB_r = X_t - \int_0^t e^{B_r}\,dB_r - \frac{1}{2}\int_0^t B_r e^{B_r}\,dr - \int_0^t e^{B_r}\,dr.$$

Finalmente, como $X_t = B_t e^{B_t}$, queda

$$\int_0^t B_r e^{B_r}\,dB_r = B_t e^{B_t} - \int_0^t e^{B_r}\,dB_r - \frac{1}{2}\int_0^t B_r e^{B_r}\,dr - \int_0^t e^{B_r}\,dr.$$

Esto demuestra la identidad buscada. □

Teorema 11.2.3. Bajo las condiciones del teorema anterior, la única solución $X = (X_t : 0 \le t \le T)$ es un proceso de Markov respecto a su filtración natural.

11.3. Aproximaciones Numéricas

Teorema 11.3.1. Sea $X = (X_t : 0 \le t \le T)$ la única solución para la EDE donde los coeficientes son continuos en la variable temporal y satisfacen las condiciones de Lipschitz y de crecimiento espacial del teorema de existencia y unicidad. Si $(Y^{(n)}_{t_{n,k}} : k = 0, 1, \dots, n)$ está definido por $Y^{(n)}_0 = x_0$ y por el

esquema de Euler-Maruyama

$$Y^{(n)}_{t_{n,k+1}} = Y^{(n)}_{t_{n,k}} + \mu(t_{n,k}, Y^{(n)}_{t_{n,k}})(t_{n,k+1} - t_{n,k}) + \sigma(t_{n,k}, Y^{(n)}_{t_{n,k}})(B_{t_{n,k+1}} - B_{t_{n,k}}), \tag{11.11}$$

entonces se cumple que

$$\max_{k=0,1,\ldots,n} E\left|X_{t_k} - Y^{(n)}_{t_{n,k}}\right|^2 \leq \frac{\alpha}{n^{1/2}}, \tag{11.12}$$

para cierta constante $\alpha > 0$ que depende de x_0, T, μ y σ.

Parte III

12
Inferencia

Definición 12.0.1 Modelo estadístico. Un modelo estadístico es una representación matemática que nos ayuda a entender y analizar fenómenos aleatorios. Este esta formado de los siguientes elementos

1. La relación entre una variable observable X_t y una hipotéticamente observable Y_t (la variable real)
$$\underbrace{X_t}_{\text{Observable}} = \underbrace{Y_t}_{\text{Hipotética}} + \underbrace{\epsilon_t}_{\text{Error}} \tag{12.1}$$
2. Distribución conjunta de una muestra de variables observables.
3. Parámetros que se asumen desconocidos y se consideran hipotéticamente observables (desconocidos).
4. (Opcional) La especificación de la distribución de ese parámetro consiste en una identificación de variables aleatorias.

Una estimador de un parámetro θ es una variable aleatoria ya que se construye a partir de los datos. Es esencial tener en cuenta su distribución condicionada a los datos observados.

Definición 12.0.2 V.A. Hipotéticamente observable. El término hipotéticamente observable se utiliza para una variable aleatoria que requeriría recursos infinitos para ser observada, como por ejemplo el límite (cuando $n \to \infty$) de los promedios muestrales de las primeras n observaciones.

Definición 12.0.3 Distribución conjunta. Es la probabilidad conjunta que ocurra cierto evento para dos o más v.a.

Definición 12.0.4 Inferencia estadística. La inferencia estadística es un proceso que nos permite hacer afirmaciones basadas en probabilidades sobre ciertas partes o la totalidad de un modelo estadístico.

Definición 12.0.5 Datos o muestra. Una muestra o conjunto de datos se refiere a una secuencia de variables aleatorias independientes, denotadas como $X_1, \dots, X_m$. que describen un fenómeno particular. Estas variables tienen una distribución que, en muchos casos, es desconocida.

Sin esto no tenemos modelo.

Definición 12.0.6 Parámetros. Un parámetro es una característica o conjunto de características que determinan la distribución conjunta de las variables aleatorias que estamos estudiando. El conjunto total de estos parámetros se denomina espacio paramétrico, y se denota como Ω.

12.1. Tipos de inferencia

Definición 12.1.1 Predicción. Una predicción es un tipo de inferencia estadística que consiste en tratar de anticipar el comportamiento de variables aleatorias que aún no han sido observadas $X_{n+1}, \dots$ con el comportamiento de las anteriores $X_1, \dots, X_n$. Cuando lo que se desea predecir es un parámetro de una distribución, este proceso se denomina estimación.

Definición 12.1.2 Problemas de Decisión Estadística. Un problema de decisión estadística es aquel en el que, tras analizar los datos, se debe elegir una decisión dentro de una clase disponible, cuyas consecuencias dependen del valor desconocido de algún parámetro. Este tipo de inferencia está estrechamente relacionado con la prueba de hipótesis.

Este anterior es el enfoque del curso

Definición 12.1.3 Diseños Experimentales. Un diseño experimental es un tipo de inferencia estadística en el que se determina la forma en que se recolectarán los datos, incluyendo el número de unidades experimentales y las condiciones bajo las cuales se obtendrán, con el fin de garantizar un grado de confianza adecuado en los resultados.

Definición 12.1.4 Estadístico. Función que toma $X_1, \dots, X_n$. y la convierte en un real.

$$T := r(X_1, \dots, X_n) \tag{12.2}$$

12.2. Densidades previas y conjugadas

En el modelo Bayesiano el parámetro θ tiene una distribucion $\theta \sim \pi(\theta)$ y esta mismas, es llamada la distribucion previa. Antes de dar los datos, hay que tener una idea de como es la distribucion del parámetro (La historia antes de los datos).

Definición 12.2.1 Distribucion previa. La distribucion previa definida sobre ω es la distribucion del parámetro θ se denota por

$$\pi(\theta). \tag{12.3}$$

Definición 12.2.2 Análisis de Sensibilidad. El análisis de sensibilidad consiste en comparar las distribuciones posteriores que surgen de diferentes distribuciones previas, con el fin de evaluar cuánto efecto tiene la elección de la distribución previa en las respuestas a preguntas importantes.

Definición 12.2.3 Densidad impropia. Sea π una función positiva cuyo dominio esta en Ω. Si la integral de $\pi(\theta)$ sobre Ω es ∞ i.e. $\int \pi \, d\theta = \infty$, la distribucion es llamada impropia.

Definición 12.2.4 Verosimilitud. Dado $X_1, \dots, X_n$ i.i.d. se define la verosimilitud de las v.a. como

$$L(\theta \mid X) := f(X \mid \theta) = f(X_1, \dots, X_n \mid \theta) = \prod_{i=1}^{n} f(X_i \mid \theta). \tag{12.4}$$

con $X = (X_1, \dots, X_n)$

12.3. Distribucion posterior

Definición 12.3.1 Distribución Posterior. En un problema de inferencia estadística con parámetro θ y variables aleatorias $X_1, \dots, X_n$ observadas, la distribución condicional de θ dado $X_1, \dots, X_n$ se denomina distribución posterior de θ. La función de probabilidad se denota por

$$\pi(\theta \mid x_1, \dots, x_n). \tag{12.5}$$

Teorema 12.3.1 Distribucion posterior. Dado $X_1, \dots, X_n$ i.i.d. se puede definir la distribucion previa como

$$\pi(\theta \mid X) = \frac{L(\theta \mid X)\pi(\theta)}{g_n(X)} \tag{12.6}$$

donde g_n es la constante de normalización.

El teorema anterior es consecuencia del Teorema de Bayes. A los parámetros de la previa se les llama hiperparámetros.

Se va a entender como modelo a la unión de

1. El conjunto de datos $X_1, \dots, X_n$
2. La función de densidad.
3. El parámetro de la densidad θ.

Para identificar y trabajar con este modelo, lo desglosamos en las siguientes partes

1. Información previa ($\pi(\theta)$).
2. Verosimilitud.
3. Densidad posterior

$$\pi(\theta \mid X) \propto \pi(\theta) f_n(X \mid \theta) \tag{12.7}$$

4. Predicciones con datos nuevos

$$\pi(\theta \mid X_1, \dots, X_n) \propto f(X_n \mid \theta)\pi(\theta \mid X_1, \dots, X_{n-1}) \tag{12.8}$$

Bajo la suposición de independencia condicional, no hay diferencia en la posterior si los datos se obtienen secuencialmente.

$$g_n(X) = \int_\Omega f(X_n \mid \theta) = \mathbb{P}(X_n \mid X_1, \dots, X_{n-1}) \tag{12.9}$$

12.4. Distribuciones previas conjugadas

Definición 12.4.1 Familia conjugada. Si, independientemente de los datos observados, la densidad posterior pertenece a la misma familia que ψ, entonces decimos que ψ es una familia conjugada de previas.

Teorema 12.4.1 Conjugación en el modelo Bernoulli. Si $X \sim \text{Bernoulli}(\theta)$ y la previa es $\theta \sim \text{Beta}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Beta}(\alpha + x, \beta + 1 - x). \tag{12.10}$$

Demostración.

$$\pi(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}.$$

$$\Rightarrow \pi(\theta \mid x) \propto L(\theta \mid x)\,\pi(\theta) = \theta^x(1-\theta)^{1-x} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} = \theta^{\alpha+x-1}(1-\theta)^{\beta-x}$$

□

Teorema 12.4.2 Conjugación en el modelo Binomial. Si $X \sim \text{Binomial}(n, \theta)$ y la previa es $\theta \sim \text{Beta}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Beta}(\alpha + x, \beta + n - x). \tag{12.11}$$

Demostración.

$$\pi(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}.$$

$$\Rightarrow \pi(\theta \mid x) \propto L(\theta \mid x)\,\pi(\theta) = \theta^x(1-\theta)^{n-x} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} = \theta^{\alpha+x-1}(1-\theta)^{\beta-x+n+1}$$

□

Teorema 12.4.3 Conjugación en el modelo Binomial Negativa. Si $X \sim$ Binomial Negativa(r, θ) y la previa es $\theta \sim \text{Beta}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Beta}(\alpha + r, \beta + x). \tag{12.12}$$

La demostracion se deja al lector.

Teorema 12.4.4 Conjugación en el modelo Poisson. Si $X \sim \text{Poisson}(\theta)$ y la previa es $\theta \sim \text{Gamma}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Gamma}(\alpha + \sum x_i, \beta + n). \tag{12.13}$$

Demostración.

$$\pi(\theta) \propto \theta^{\alpha-1} e^{-\beta\theta}.$$

$$\Rightarrow \pi(\theta \mid x) \propto L(\theta \mid x)\,\pi(\theta) = \theta^{\sum x_i} e^{-n\theta} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} = \theta^{\sum x_i+\alpha-1} e^{-(n+\beta)\theta}$$

□

Teorema 12.4.5 Conjugación en el modelo Exponencial. Si $X \sim$ Exponencial(θ) y la previa es $\theta \sim$ Gamma(α, β), entonces la posterior es

$$\theta \mid x \sim \text{Gamma}(\alpha + n, \beta + \sum x_i). \tag{12.14}$$

Demostración.

$$\pi(\theta) \propto \theta^{\alpha-1} e^{-\beta\theta}.$$

$$\Rightarrow \pi(\theta \mid x) \propto L(\theta \mid x)\,\pi(\theta) = \theta^{n} e^{-\theta\sum x_i} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} = \theta^{n+\alpha-1} e^{-(\sum x_i+\beta)\theta}$$

□

Teorema 12.4.6 Conjugación en el modelo Normal con varianza conocida. Si $X \sim N(\theta, \sigma^2)$ con σ^2 conocida y la previa es $\theta \sim N(\mu_0, \sigma_0^2)$, entonces la posterior es

$$\theta \mid x \sim N\left(\frac{\mu_0/\sigma_0^2 + n\bar{x}/\sigma^2}{1/\sigma_0^2 + n/\sigma^2}, (1/\sigma_0^2 + n/\sigma^2)^{-1}\right). \tag{12.15}$$

Demostración.

$$\pi(\theta) \propto \exp\left(-\frac{1}{2\sigma_0^2}(\theta-\mu_0)^2\right).$$

$$\Rightarrow \pi(\theta \mid x) \propto L(\theta \mid x)\pi(\theta) = \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\theta)^2\right) \cdot \exp\left(-\frac{1}{2\sigma_0^2}(\theta-\mu_0)^2\right).$$

donde

$$\sum_{i=1}^{n}(x_i-\theta)^2 = \sum_{i=1}^{n} x_i^2 - 2\theta\sum_{i=1}^{n} x_i + n\theta^2$$

$$\Rightarrow\Rightarrow \pi(\theta \mid x) \propto \exp\left(-\frac{1}{2\sigma^2}(-2\theta\bar{x} + n\theta^2) - \frac{1}{2\sigma_0^2}(\theta^2 - 2\theta\mu_0)\right)$$

$$= \exp\left(-\frac{1}{2}\Big(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}\Big)\theta^2 + \Big(\frac{n\bar{x}}{\sigma^2} + \frac{\mu_0}{\sigma_0^2}\Big)\theta\right)$$

□

Teorema 12.4.7 Conjugación en el modelo Normal con media conocida. Si $X \sim N(\mu, \theta)$ con μ conocida y la previa es $\theta \sim$ Gamma Inversa(α, β), entonces la posterior es

$$\theta \mid x \sim \text{Gamma Inversa}\left(\alpha + \tfrac{n}{2}, \beta + \tfrac{1}{2}\sum(x_i-\mu)^2\right). \tag{12.16}$$

La demostracion se dela al lector.

Teorema 12.4.8 Posterior de la normal. Si $X_1, \ldots, X_n \sim N(\theta, \sigma^2)$ con σ^2 conocido y la previa

es $\theta \sim N(\mu_1, V_1^2)$ entonces

$$\mu_1 = \frac{\sigma^2\mu_0 + nV_0^2\bar{X}_n}{\sigma^2 + nV_0^2}, \quad V_1^2 = \frac{\sigma^2 V_0^2}{\sigma^2 + nV_0^2} \tag{12.17}$$

La demostracion se deja al lector.

Corolario 12.4.1. Si definimos

$$\mu_1 = \underbrace{\frac{\sigma^2}{\sigma^2 + nV_0^2}}_{W_1}\mu_0 + \underbrace{\frac{nV_0^2}{\sigma^2 + nV_0^2}}_{W_2}\bar{X}_n \tag{12.18}$$

Entonces

1. Si V_0^2 y σ^2 son fijos, entonces $W_1 \xrightarrow[n\to\infty]{} 0$ (la importancia de la media empírica crece conforme aumenta n).
2. Si V_0^2 y n son fijos, entonces $W_2 \xrightarrow[\sigma^2\to\infty]{} 0$ (la importancia de la media empírica decrece conforme la muestra es menos precisa).
3. Si σ^2 y n son fijos, entonces $W_2 \xrightarrow[V_0^2\to\infty]{} 1$ (la importancia de la media empírica crece conforme la previa es menos precisa).

La demostracion se deja al lector.

12.5. Estimador bayesiano y las funciones de perdida

Definición 12.5.1 Estimador. Sean $X_1, \dots, X_n$ datos observables cuyo modelo esta indexado por $\theta \in \Omega$. Un estimador de θ es cualquier estadístico de la forma $\delta(X_1, \dots, X_n)$.

Definición 12.5.2 Estimación. La estimación o estimado es

$$\delta(X_1, \dots, X_n)(\omega) = \delta(x_1, \dots, x_n) \tag{12.19}$$

Definición 12.5.3 Función de perdida. Un función de perdida es una función de dos variables talque

$$L(\theta, a), \quad \theta \in \Omega \tag{12.20}$$

con a un numero real.

Definición 12.5.4 Perdida esperada y estimador bayesiano. Suponga que θ tiene previa. La perdida esperada viene dada por

$$\mathbb{E}[L(\theta, a)] = \int_\Omega L(\theta, a)\pi(\theta)\, d\theta \tag{12.21}$$

Asuma que a se selecciona al minimizar esta esperanza, al estimador $a = \delta^*(X_1, \dots, X_n)$ se le llama

estimador bayesiano, si ponderamos los parametros con respecto a la posterior

$$\mathbb{E}[L(\theta, \delta^*) \mid X] = \min_a \mathbb{E}[L(\theta, a) \mid X] \tag{12.22}$$

Proposición 12.5.1 Perdida cuadrática. Si $L(\theta, a) = (\theta - a)^2$ entonces

$$a = \mathbb{E}[\theta \mid X]. \tag{12.23}$$

Demostración. Note que

$$\mathbb{E}[L(\theta, a)] = \int_\Omega (\theta - a)^2 \pi(\theta \mid X)\, d\theta$$
$$= \int_\Omega \theta^2 \pi(\theta \mid X)\, d\theta - 2a \int_\Omega \theta \pi(\theta \mid X)\, d\theta + \int_\Omega a^2 \pi(\theta \mid X)\, d\theta$$
$$= \mathbb{E}[\theta^2 \mid X] - 2a\mathbb{E}[\theta \mid X] + a^2$$

Darivando con respecto a la variable que queremos minimizar

$$\frac{d\mathbb{E}[L(\theta, a)]}{da} = 0 \Rightarrow -2\mathbb{E}[\theta \mid X] + 2a = 0$$

□

Proposición 12.5.2 Perdida absoluta. Si $L(\theta, a) = |\theta - a|$ entonces

$$F_{\theta|X}(a) = \frac{1}{2}. \tag{12.24}$$

Demostración. Note que

$$\mathbb{E}[L(\theta, a)] = \int_\Omega |\theta - a| \pi(\theta \mid X)\, d\theta$$
$$= \int_{-\infty}^{a} (\theta - a)\pi(\theta \mid X)\, d\theta - \int_a^{\infty} (\theta - a)\pi(\theta \mid X)\, d\theta$$

Derivando con respecto de a (aplicando Leibniz)

$$\frac{d\mathbb{E}[L(\theta, a)]}{da} = 0 \Rightarrow \int_{-\infty}^{a} \pi(\theta \mid X)\, d\theta - \int_a^{\infty} \pi(\theta \mid X)\, d\theta$$
$$= F_{\theta|X}(a) - (1 - F_{\theta|X}(a)) = 0$$

□

Proposición 12.5.3 Perdida 0-1. Si se tiene que

$$L(\theta, a) = \begin{cases} 0, & \text{si } |\theta - a| < \epsilon \\ 1, & \text{si } |\theta - a| \geq \epsilon \end{cases} \tag{12.25}$$

entonces $a = \text{máx}_\theta\, \pi(\theta \mid x)$.

12.6. Estimador de bayes para muestras grandes

12.6.1. Consistencia

Definición 12.6.1 Estimador consistente. Un estimador de $\delta(X_1, \dots, X_n)$ es consistente si

$$\delta(X_1, \dots, X_m) \xrightarrow[n\to\infty]{\mathbb{P}} \theta. \tag{12.26}$$

Teorema 12.6.1 Bayesiano consistente. Los estimadores bayesianos son consistentes.

La demostracion se deja al lector.

Definición 12.6.2 Estimador. Si $X_1, \dots, X_n$ es una muestra en un modelo indexado por θ, $\theta \in \Omega$ (k-dimensional), sea

$$h : \Omega \to H \subset \mathbb{R}^d \tag{12.27}$$

Definase $\psi = h(\theta)$. Un estimador de ψ es una función o estadístico $\delta(X_1, \dots, X_n) \in H$.

12.7. Estimadores de máxima verosimilitud y sus propiedades

Definición 12.7.1 Estimador de Máxima Verosimilitud. Un estimador de máxima verosimilitud (MLE) de θ es cualquier estadístico $\hat{\theta} = \delta(x)$ que maximice $L(X \mid \theta)$ con respecto a θ.

Definición 12.7.2 Generalización del MLE. Sea $g(\theta)$ una función arbitraria del parámetro θ, y sea G la imagen de Ω bajo g. Para cada $t \in G$, definimos

$$G_t := \{\theta \in \Omega : g(\theta) = t\}. \tag{12.28}$$

Se define además

$$L^*(t) := \max_{\theta \in G_t} \ln f_n(x \mid \theta). \tag{12.29}$$

El estimador de máxima verosimilitud de $g(\theta)$ es el valor $\hat{t}$ tal que

$$L^*(\hat{t}) := \max_{t \in G} L^*(t). \tag{12.30}$$

Teorema 12.7.1 Invarianza del MLE. Si $\hat{\theta}$ es el estimador de máxima verosimilitud de θ y g es una función biyectiva, entonces el MLE de $g(\theta)$ está dado por

$$g(\hat{\theta}). \tag{12.31}$$

Definición 12.7.3 Consistencia de un estimador. Sea $\{\delta_n(X)\}$ una sucesión de estimadores para un parámetro θ. Se dice que δ_n es consistente si

$$\delta_n(X) \xrightarrow{\mathbb{P}} \theta \quad \text{cuando } n \to \infty. \tag{12.32}$$

Teorema 12.7.2 Consistencia del MLE. Sea $\hat{\theta}_n$ el estimador de máxima verosimilitud de θ basado en una muestra de tamaño n. Bajo condiciones regulares, basta garantizar que

$$\lim_{n\to\infty} \operatorname{Var}(\hat{\theta}_n) = 0 \quad \text{y} \quad \lim_{n\to\infty} \operatorname{Bias}(\hat{\theta}_n) = 0. \tag{12.33}$$

En tal caso, se cumple que

$$\hat{\theta}_n \xrightarrow[n\to\infty]{\mathbb{P}} \theta. \tag{12.34}$$

Teorema 12.7.3 Consistencia del estimador bayesiano. Bajo condiciones generales, la sucesión de estimadores bayesianos $\{\delta_n^{Bayes}\}$ también es consistente. En particular, para una distribución previa fija y n suficientemente grande,

$$\delta_n^{Bayes} \xrightarrow{\mathbb{P}} \theta \quad \text{cuando } n \to \infty. \tag{12.35}$$

Definición 12.7.4 Método de Newton. Sea $f(\theta)$ una función real de variable real. Para resolver la ecuación

$$f(\theta) = 0, \tag{12.36}$$

se parte de una aproximación inicial θ_0. El método de Newton actualiza la aproximación mediante

$$\theta_{k+1} := \theta_k - \frac{f(\theta_k)}{f'(\theta_k)}. \tag{12.37}$$

Teorema 12.7.4 Convergencia local. Si f es dos veces diferenciable y $f'(\theta^*) \neq 0$ en la raíz θ^*, entonces para θ_0 suficientemente cercano a θ^*, la sucesión $\{\theta_k\}$ converge cuadráticamente a θ^*.

Corolario 12.7.1 Aplicación a MLE. El método de Newton puede emplearse para resolver la ecuación de primer orden de máxima verosimilitud

$$\frac{\partial}{\partial\theta}\ell(\theta \mid X) = 0, \tag{12.38}$$

donde $\ell(\theta \mid X) = \log L(\theta \mid X)$ es la log-verosimilitud.

Definición 12.7.5 Método de Momentos. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución indexada por un parámetro $\theta \in \mathbb{R}^k$, que posee al menos k momentos finitos. Para $j = 1, \dots, k$, definimos

$$\mu_j(\theta) := \mathbb{E}[X_1^j \mid \theta]. \tag{12.39}$$

Sea

$$\mu(\theta) := (\mu_1(\theta), \dots, \mu_k(\theta)), \tag{12.40}$$

y supongamos que $\mu(\theta)$ es una función biyectiva de θ. Definimos la función inversa

$$\theta = M(\mu_1(\theta), \dots, \mu_k(\theta)). \tag{12.41}$$

Los momentos muestrales se definen como

$$m_j := \frac{1}{n}\sum_{i=1}^{n} X_i^j, \quad j = 1, \dots, k. \tag{12.42}$$

El estimador por el método de momentos de θ está dado por

$$\hat{\theta}_{MoM} := M(m_1, \dots, m_k). \tag{12.43}$$

Teorema 12.7.5 Consistencia del estimador de momentos. Sea $\{\hat{\theta}_n^{MM}\}$ la sucesión de estimadores de momentos de $\theta \in \mathbb{R}^k$, basada en muestras de tamaño n. Si existen los primeros k momentos finitos y la función de momentos es continua e invertible, entonces

$$\hat{\theta}_n^{MM} \xrightarrow{\mathbb{P}} \theta \quad \text{cuando } n \to \infty. \tag{12.44}$$

12.8. Estadístico suficiente

Definición 12.8.1 Estadístico suficiente. Sea $X_1, \dots, X_n$ una muestra aleatoria con distribución dependiente de un parámetro θ. Un estadístico $T(X_1, \dots, X_n)$ se dice suficiente para θ si la distribución condicional de la muestra dado T no depende de θ.

Teorema 12.8.1 Teorema de Factorización de Neyman–Fisher. Sea $X_1, \dots, X_n$ una muestra aleatoria de función de probabilidad $f(X \mid \theta)$, donde θ es un parámetro desconocido. Un estadístico $T = r(X_1, \dots, X_n)$ es suficiente para θ si y solo si la función conjunta $L(\theta \mid X)$ puede factorizarse como

$$L(\theta \mid X) = u(x)\, v(r(x), \theta), \tag{12.45}$$

para todo $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ y todo θ en el espacio paramétrico.

Teorema 12.8.2 Caracterización bayesiana de suficiencia. T es suficiente para θ si y solo si, para cualquier distribución previa $\pi(\theta)$, la distribución posterior de θ depende de los datos únicamente a través del valor de T. Es decir

$$\pi(\theta \mid X) = \pi(\theta \mid T(X)). \tag{12.46}$$

12.9. Estimadores insesgados

Definición 12.9.1 Estimador insesgado. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución indexada por θ, y sea $\delta(X_1, \dots, X_n)$ un estimador de θ. Se dice que δ es *insesgado* para θ si

$$\mathbb{E}_\theta[\delta(X_1, \dots, X_n)] = \theta \quad \text{para todo } \theta. \tag{12.47}$$

Definición 12.9.2 Estadísticos conjuntamente suficientes. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución indexada por θ. Un conjunto de estadísticos $(T_1, \dots, T_k)$ es conjuntamente suficiente para θ si, para todo θ y todo valor posible $(t_1, \dots, t_k)$, la distribución condicional conjunta de $X_1, \dots, X_n \mid (T_1, \dots, T_k) = (t_1, \dots, t_k)$ no depende de θ.

Teorema 12.9.1 Teorema de Factorización de Neyman–Fisher para estadísticos conjuntamente suficientes. Sean $r_1, \dots, r_k$ funciones de n variables reales. Los estadísticos $T_i = r_i(X)$, $i = 1, \dots, k$, son conjuntamente suficientes para θ si y solo si

$$L(x \mid \theta) = u(x)\, v(r_1(x), \dots, r_k(x), \theta). \tag{12.48}$$

Definición 12.9.3 Ordenamientos (Order Statistics). Sea $X_1, \dots, X_n$ una muestra aleatoria. Definimos los *ordenamientos* como las variables aleatorias $Y_1, \dots, Y_n$, donde

$$Y_1 := \min\{X_1, \dots, X_n\}, \quad Y_n := \max\{X_1, \dots, X_n\}, \tag{12.49}$$

y en general Y_j es el j-ésimo menor valor de la muestra.

Para la definición anterior también se utiliza la notación $X_{(i)}$.

Teorema 12.9.2 Suficiencia de los ordenamientos. Los ordenamientos $Y_1, \dots, Y_n$ son conjuntamente suficientes para θ.

La demostración es trivial.

Definición 12.9.4 Estadístico suficiente mínimo (minimal). Un estadístico T es minimal para θ si es suficiente y además es función de todo otro estadístico suficiente.

Teorema 12.9.3 MLE y estadísticos suficientes. Sea $T = r(X_1, \dots, X_n)$ un estadístico suficiente para θ. Entonces el estimador de máxima verosimilitud $\hat{\theta}$ depende de los datos únicamente a través de T. Además, si $\hat{\theta}$ es suficiente, entonces es suficiente mínimo.

Teorema 12.9.4 Estimador bayesiano y estadísticos suficientes. Sea $T = r(X)$ un estadístico suficiente para θ. Entonces todo estimador bayesiano $\hat{\theta}$ depende de los datos únicamente a través de T. Además, si $\hat{\theta}$ es suficiente, entonces es suficiente mínimo.

Teorema 12.9.5 Varianza muestral insesgada. Sea $X_1, \dots, X_n \sim F_\theta$ con varianza finita σ^2. Entonces

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \bar{X}_n)^2 \tag{12.50}$$

es un estimador insesgado de σ^2.

Teorema 12.9.6 Cota de Cramér–Rao. Sea $X_1, \dots, X_n$ una muestra aleatoria con función de densidad (o masa) $f(x \mid \theta)$, y sea $\delta(X)$ un estimador insesgado de θ. Bajo condiciones de regularidad, la varianza de δ satisface

$$\operatorname{Var}_\theta(\delta) \geq \frac{1}{I_n(\theta)}, \tag{12.51}$$

donde $I_n(\theta) = n\, I(\theta)$ es la información de Fisher de la muestra, con

$$I(\theta) = \mathbb{E}_\theta\left[\left(\frac{\partial}{\partial \theta} \log f(X \mid \theta)\right)^2\right] = -\,\mathbb{E}_\theta\left[\frac{\partial^2}{\partial \theta^2} \log f(X \mid \theta)\right]. \tag{12.52}$$

Un estimador insesgado que alcanza esta cota se denomina *eficiente*.

Proposición 12.9.1 Distribución de Poisson estimadores insesgados. Si $X_1, \dots, X_n \sim$ Poisson(θ), entonces tanto

$$\bar{X}_n \quad \text{y} \quad s^2 \tag{12.53}$$

son estimadores insesgados de θ. Además, cualquier combinación lineal

$$T = \alpha \bar{X}_n + (1-\alpha)s^2 \tag{12.54}$$

también resulta insesgada.

Proposición 12.9.2 Distribución normal comparación de estimadores de σ^2 por MSE. Sea $X_1, \dots, X_n \sim N(\mu, \sigma^2)$. Definimos

$$T_c = c \sum_{i=1}^{n} (X_i - \bar{X}_n)^2. \tag{12.55}$$

El valor óptimo en términos de error cuadrático medio es

$$c^* = \frac{1}{n+1}, \tag{12.56}$$

de modo que

$$T_{1/(n+1)} = \frac{1}{n+1} \sum_{i=1}^{n} (X_i - \bar{X}_n)^2. \tag{12.57}$$

Sin embargo, este estimador resulta inadmisible.

Definición 12.9.5 Inadmisibilidad en términos de MSE. Un estimador δ_1 es inadmisible si existe otro estimador δ_2 tal que

$$\text{MSE}(\delta_2) \leq \text{MSE}(\delta_1) \quad \text{para todo } \theta, \tag{12.58}$$

y la desigualdad es estricta para al menos un valor de θ. En ese caso, se dice que δ_2 domina a δ_1.

Proposición 12.9.3 Conexión con Rao–Blackwell. Si $\delta(X)$ es insesgado y T es suficiente para θ, entonces

$$\delta^*(T) = \mathbb{E}[\delta(X) \mid T] \tag{12.59}$$

es también insesgado y cumple

$$\text{Var}_\theta(\delta^*) \leq \text{Var}_\theta(\delta). \tag{12.60}$$

12.10. Mejorando el estimador

Definición 12.10.1 Función de riesgo. Para un estimador $\delta(X)$ de una función $h(\theta)$, la función de riesgo bajo pérdida cuadrática se define como

$$R(\theta, \delta) := \mathbb{E}_\theta \left[\left(\delta(X) - h(\theta) \right)^2 \right] = \mathbb{E} \left[\left(\delta(X) - h(\theta) \right)^2 | \theta \right]. \tag{12.61}$$

Definición 12.10.2 Estimador de Rao–Blackwell. Sea $\delta(X)$ un estimador de θ, y sea T un estadístico suficiente para θ. Definimos el estimador mejorado como

$$\delta_0(T) := \mathbb{E}[\delta(X) \mid T]. \tag{12.62}$$

Teorema 12.10.1 Teorema de Rao–Blackwell. Sea $\delta(X)$ un estimador de θ, y sea $\delta_0(T)$ el estimador definido anteriormente a partir de un estadístico suficiente T. Entonces, para todo θ,

$$R(\theta, \delta_0) \leq R(\theta, \delta), \tag{12.63}$$

Además, si $R(\theta, \delta) < \infty$, la desigualdad es estricta salvo que $\delta(X)$ sea función de T.

Definición 12.10.3 Admisibilidad e inadmisibilidad. Sea $R(\theta, \delta)$ el riesgo de un estimador δ. Un estimador δ es inadmisible si existe otro estimador δ_0 tal que

$$R(\theta, \delta_0) \leq R(\theta, \delta) \quad \text{para todo } \theta, \tag{12.64}$$

y la desigualdad es estricta para al menos un valor de θ. En este caso, se dice que δ_0 domina a δ. Un estimador δ es admisible si no existe ningún otro estimador que lo domine.

13

Distribuciones Muestrales de Estimadores

Definición 13.0.1 Distribución χ^2. Para $m > 0$ definimos

$$\chi^2_m \sim \Gamma\left(\tfrac{m}{2}, \tfrac{1}{2}\right),$$

donde m representa los grados de libertad.

Proposición 13.0.1 Propiedades de la distribución χ^2. Si $X_i \sim \chi^2_{m_i}$ independientes, entonces

$$\sum_{i=1}^{k} X_i \sim \chi^2_{\sum m_i}.$$

Además, si $X \sim N(0,1)$, entonces $Y = X^2 \sim \chi^2_1$. Si $X_i \sim$ i.i.d. $N(0,1)$, entonces

$$\sum_{i=1}^{m} X_i^2 \sim \chi^2_m.$$

Proposición 13.0.2 Distribución muestral de la varianza. Sea $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ con μ desconocido. Si

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2,$$

entonces

$$\frac{n\hat{\sigma}^2}{\sigma^2} = \frac{\sum_{i=1}^{n}(X_i - \bar{X}_n)^2}{\sigma^2} \sim \chi^2_{n-1}.$$

Proposición 13.0.3 Independencia en muestras normales. Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, entonces $\bar{X}_n$ y s_n^2 son independientes, donde

$$s_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2.$$

Proposición 13.0.4 Matrices ortogonales. Una matriz $A_{n\times n}$ es ortogonal si $A^{-1} = A^T$ (equivalentemente $A^T A = I$). En ese caso $\det(A) = \pm 1$ y si $Y = AX$ con A ortogonal, entonces

$$\|Y\|_2^2 = \|X\|_2^2.$$

Teorema 13.0.1 Transformación ortogonal de normales. Si $X_1, \dots, X_n \sim N(0,1)$ y A es ortogonal $n \times n$, entonces para $Y = AX$ se cumple

$$Y_1, \dots, Y_n \sim N(0,1).$$

13.1. Distribución t de Student

Definición 13.1.1 Distribución t de Student. Sean $Y \sim \chi^2_m$ y $Z \sim N(0,1)$ independientes. Definimos

$$X = \frac{Z}{\sqrt{Y/m}}.$$

Entonces $X \sim t_m$, distribución t de Student con m grados de libertad.

Proposición 13.1.1 Propiedades de la distribución t.

- La media existe solo si $m > 1$, en cuyo caso es 0.
- La varianza existe si $m > 2$, y es

$$\mathrm{Var}(X) = \frac{m}{m-2}.$$

- Si $m = 1$, $X \sim$ Cauchy.
- Cuando $m \to \infty$, $t_m \to N(0,1)$.
- Es simétrica.

Proposición 13.1.2 Estadístico t en muestras normales. Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, entonces

$$\frac{n(\bar{X}_n - \mu)}{s_n} \sim t_{n-1},$$

donde

$$s_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2.$$

14

Intervalos de Confianza

Definición 14.0.1 Cuantil de orden p. Si X es una variable aleatoria continua con función de distribución acumulada F (monótona creciente), entonces

$$x = F^{-1}(p) \tag{14.1}$$

es el **cuantil de orden** p de F (p-cuantil).

Definición 14.0.2 Intervalo de confianza al $100(1-\alpha\,\%)$**.** Sea $X = (X_1, \dots, X_n)$ una muestra con parámetro θ. Sea $g(\theta)$ una característica de la distribución que genera la muestra. Sea $A < B$ dos estadísticos que cumplen, para todo θ:

$$\mathbb{P}[A < g(\theta) < B] \geq 1 - \alpha. \tag{14.2}$$

Al intervalo (A, B) se le llama **intervalo de confianza al** $100(1-\alpha)\,\%$. En el caso en que la desigualdad sea una igualdad, el intervalo es exacto.

Proposición 14.0.1 Intervalo de confianza para la media normal (σ^2 desconocida). Sea $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ con μ y σ^2 desconocidos. El estadístico pivotal es

$$U = \frac{\sqrt{n}(\bar{X}_n - \mu)}{s} \sim t_{n-1}, \tag{14.3}$$

donde $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2$. El intervalo de confianza para μ al $100(1-\alpha)\,\%$ es

$$\left[\bar{X}_n - F^{-1}_{t_{n-1}}\left(1-\tfrac{\alpha}{2}\right)\frac{s}{\sqrt{n}},\ \bar{X}_n + F^{-1}_{t_{n-1}}\left(1-\tfrac{\alpha}{2}\right)\frac{s}{\sqrt{n}}\right]. \tag{14.4}$$

A la cantidad $\dfrac{c\,s}{\sqrt{n}}$ se le llama **margen de error** (MOE).

Proposición 14.0.2 Interpretación correcta del intervalo de confianza. Una vez observados los datos, el intervalo (a, b) es un número fijo: o contiene a θ o no. El $100(1-\alpha)\,\%$ no es la probabilidad de que θ esté en ese intervalo específico, sino que el *procedimiento* produce intervalos que contienen al parámetro verdadero en el $100(1-\alpha)\,\%$ de las muestras posibles.

Definición 14.0.3 Intervalos de confianza de una cola.

- **Límite inferior de confianza:** Si A es un estadístico que cumple $\mathbb{P}[A < g(\theta)] \geq 1-\alpha$, entonces A es el **límite inferior de confianza** al $100(1-\alpha)\,\%$. El intervalo (A, ∞) es el intervalo de confianza inferior al $100(1-\alpha)\,\%$.
- **Límite superior de confianza:** De manera análoga, si B cumple $\mathbb{P}[g(\theta) < B] \geq 1-\alpha$, el intervalo $(-\infty, B)$ es el intervalo de confianza superior para $g(\theta)$ con nivel $1-\alpha$. Si se cumple la igualdad, el intervalo es exacto.

Definición 14.0.4 Cantidad pivotal. Dada una muestra $X = (X_1, \ldots, X_n)$ proveniente de una distribución F_θ, si existe una variable aleatoria $V(X, \theta)$ cuya distribución no depende de θ, entonces decimos que V es una **cantidad pivotal**.

Proposición 14.0.3 Construcción de intervalos mediante cantidad pivotal. Sea $V(X, \theta)$ una cantidad pivotal con función de distribución G. Si existe una función $r(v, x)$ tal que

$$r(V(X, \theta), X) = g(\theta), \tag{14.5}$$

y $\gamma_1 < \gamma_2$ con $\gamma_2 - \gamma_1 = 1-\alpha$, entonces los límites del intervalo de confianza al $100(1-\alpha)\,\%$ son:

$$A = r(G^{-1}(\gamma_1),\, X), \qquad B = r(G^{-1}(\gamma_2),\, X), \tag{14.6}$$

si $r(v, x)$ es creciente en v. Si $r(v, x)$ es decreciente, se intercambian A y B.
Las cantidades pivotales no siempre existen, especialmente para distribuciones discretas.

Proposición 14.0.4 Intervalo de confianza para la varianza normal. Sea $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$ con μ desconocido. La cantidad pivotal es

$$V = \frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-1}. \tag{14.7}$$

El intervalo de confianza para σ^2 al $100(1-\alpha)\,\%$ es

$$\left[\frac{\sum(X_i - \bar{X}_n)^2}{\chi^2_{n-1,\,\gamma_2}},\ \frac{\sum(X_i - \bar{X}_n)^2}{\chi^2_{n-1,\,\gamma_1}}\right], \tag{14.8}$$

donde $\gamma_1 < \gamma_2$ con $\gamma_2 - \gamma_1 = 1 - \alpha$ y $\chi^2_{n-1,\,c} = F^{-1}_{\chi^2_{n-1}}(c)$.

Proposición 14.0.5 Método Delta. Si Y_n es un estimador tal que

$$\frac{\sqrt{n}(Y_n - \theta)}{\sigma} \xrightarrow{d} N(0,1), \tag{14.9}$$

y g es una función diferenciable con $g'(\theta) \neq 0$, entonces

$$\frac{\sqrt{n}}{\sigma\, g'(\theta)}[g(Y_n) - g(\theta)] \xrightarrow{d} N(0,1). \tag{14.10}$$

En particular, si $Y_n = \bar{X}_n$ con $\mathrm{Var}(X_i) = \sigma^2$, este resultado permite derivar la distribución asintótica de cualquier función suave del estimador.

Proposición 14.0.6 Transformación estabilizadora de la varianza. Si $\sqrt{n}(\bar{X}_n - \mu)/\sigma(\mu) \xrightarrow{d} N(0,1)$ y la varianza depende del parámetro μ, se busca una transformación g tal que $g'(\mu)\,\sigma(\mu) = 1$, es decir,

$$g(\mu) = \int_a^{\mu} \frac{dx}{\sigma(x)}\, dx, \tag{14.11}$$

de modo que $\sqrt{n}[g(\bar{X}_n) - g(\theta)] \xrightarrow{d} N(0,1)$, con varianza libre del parámetro.

15
Pruebas de Hipótesis

Definición 15.0.1 Hipótesis nula y alternativa. Sea H_0 la **hipótesis nula** y H_1 la **hipótesis alternativa**. Una vez que se ha realizado una prueba de hipótesis, si se afirma $\theta \in \Omega_1$ se dice que se *rechaza* H_0. Si $\theta \in \Omega_0$, se dice que *no se rechaza* H_0.
La hipótesis nula H_0 ocupa el rol de hipótesis de referencia: se asume verdadera hasta que los datos proporcionen evidencia suficiente para rechazarla. El error que más se busca controlar es el Tipo I (rechazar H_0 cuando es verdadera).

Definición 15.0.2 Tipos de hipótesis. Sea $X_1, \dots, X_n \sim f(x|\theta)$, $\theta \in \Omega = \Omega_0 \cup \Omega_1$. Para $i = 0, 1$:

1. Si Ω_i contiene un único valor de θ, H_i es una **hipótesis simple**.
2. Si Ω_i contiene más de un valor de θ, H_i es una **hipótesis compuesta**.
3. Se tiene una **hipótesis compuesta de una cola** cuando:
   - $\Omega_0 = [\theta_0, +\infty)$: $H_0 : \theta \geq \theta_0$ y $H_1 : \theta < \theta_0$.
   - $\Omega_0 = (-\infty, \theta_0]$: $H_0 : \theta \leq \theta_0$ y $H_1 : \theta > \theta_0$.
4. Si $H_0 : \theta = \theta_0$ y $H_1 : \theta \neq \theta_0$, es una **hipótesis de dos colas**.

Definición 15.0.3 Región crítica y estadístico de prueba. Sea X una muestra aleatoria con distribución $f(x|\theta)$, $T = r(X)$ un estadístico y $R \subset \mathbb{R}$. Si se puede verificar las hipótesis afirmando "rechazamos H_0 si $T \in R$", entonces T es un **estadístico de prueba** y R es la **región de rechazo**

(o región crítica) de la prueba.
"No rechazar H_0" no equivale a "aceptar H_0": solo indica que los datos no contradicen ese supuesto al nivel de significancia elegido.

Definición 15.0.4 Función de potencia. La **función de potencia** del procedimiento δ es

$$\pi(\theta|\delta) = \mathbb{P}(X \in S_1 \mid \theta) \quad \forall\, \theta \in \Omega, \tag{15.1}$$

donde S_1 es la región crítica. Si δ se basa en un estadístico T con región de rechazo R, entonces $\pi(\theta|\delta) = \mathbb{P}(T \in R \mid \theta)$.
La función de potencia ideal satisface $\pi(\theta|\delta) = 0$ si $\theta \in \Omega_0$ y $\pi(\theta|\delta) = 1$ si $\theta \in \Omega_1$.

Definición 15.0.5 Errores de Tipo I y Tipo II.

- **Error de Tipo I** (α): se produce cuando se rechaza H_0 siendo H_0 verdadera. Si $\theta \in \Omega_0$, la probabilidad del error Tipo I es $\pi(\theta|\delta)$.
- **Error de Tipo II** (β): se produce cuando no se rechaza H_0 siendo H_0 falsa. Si $\theta \in \Omega_1$, la probabilidad del error Tipo II es $1 - \pi(\theta|\delta)$.

Reducir α generalmente aumenta β: existe un equilibrio. Por eso se fija α y se maximiza la potencia $1 - \beta$ dentro de todas las pruebas de nivel α.

Definición 15.0.6 Prueba de nivel α y tamaño de una prueba. Una prueba *de nivel o significancia* α satisface

$$\pi(\theta|\delta) \leq \alpha \quad \forall\, \theta \in \Omega_0. \tag{15.2}$$

El **tamaño** $\alpha(\delta)$ de una prueba δ se define como

$$\alpha(\delta) = \sup_{\theta \in \Omega_0} \pi(\theta|\delta). \tag{15.3}$$

Corolario 15.0.1 Caracterización del nivel de significancia. Una prueba δ es una prueba de nivel α si y solo si su tamaño es a lo sumo α, es decir, $\alpha(\delta) \leq \alpha$.

Definición 15.0.7 Valor-p. El **valor-p** es el nivel más pequeño de significancia en donde se rechazaría H_0 bajo los datos observados. Resume la evidencia en los datos en contra de la hipótesis nula.
Regla de decisión: si el valor-$p < \alpha$, los datos son poco compatibles con H_0 y hay suficiente evidencia para rechazarla; si el valor-$p \geq \alpha$, los datos son compatibles con H_0. Un valor-p grande no prueba que H_0 sea verdadera.
Un valor-p pequeño solo indica incompatibilidad con H_0; no indica el tamaño ni la importancia práctica del efecto. Con muestras grandes, diferencias mínimas pueden producir valores-p muy pequeños.

Teorema 15.0.1 Dualidad pruebas de hipótesis – regiones de confianza (I). Sea $x = (X_1, \ldots, X_n)$ una muestra con distribución F_θ y $g(\theta)$ una función tal que para cada valor g_0 existe una prueba con nivel α de $H_{0,g_0} : g(\theta) = g_0$ vs. $H_{1,g_0} : g(\theta) \neq g_0$. Defínase

$$\omega(x) = \{g_0 : \delta_{g_0} \text{ no rechaza } H_{0,g_0} \text{ si } X = x\}. \tag{15.4}$$

Entonces

$$\mathbb{P}[g(\theta_0) \in \omega(x) \mid \theta = \theta_0] \geq 1 - \alpha \quad \forall\, \theta_0 \in \Omega. \tag{15.5}$$

Teorema 15.0.2 Dualidad pruebas de hipótesis – regiones de confianza (II). Si $\omega(x)$ satisface la condición anterior para todo $\theta_0 \in \Omega$, entonces $\omega(x)$ es un **conjunto de confianza** con significancia $1-\alpha$.

Teorema 15.0.3 Dualidad pruebas de hipótesis – regiones de confianza (III). Bajo las condiciones anteriores, si $\omega(x)$ es un conjunto de confianza para g_0, entonces el procedimiento δ_{g_0}: "no rechazo H_{0,g_0} si y solo si $g_0 \in \omega(X)$", es una prueba con nivel α para H_{0,g_0}.

Definición 15.0.8 Estadístico LRT (Cociente de Verosimilitud). Para probar $H_0 : \theta \in \Omega_0$ vs. $H_1 : \theta \in \Omega_1 = \Omega_0^c$, el **estadístico de cociente de verosimilitud** se define como

$$\Lambda(x) = \frac{\sup_{\theta\in\Omega_0} f_n(x|\theta)}{\sup_{\theta\in\Omega} f_n(x|\theta)}. \tag{15.6}$$

Una prueba de cociente de verosimilitud rechaza H_0 si $\Lambda(x) \leq k$ para una constante k.

Teorema 15.0.4 Teorema de Wilks. Sea Ω un abierto en $\mathbb{R}^p$ y suponga que H_0 especifica k coordenadas de θ igualándolas a valores fijos. Asuma que H_0 es cierto y que se cumplen las condiciones de regularidad. Entonces

$$-2\ln\Lambda(x) \xrightarrow[H_0]{d} \chi^2_k. \tag{15.7}$$

16

Pruebas con Hipótesis Simples

Definición 16.0.1 Errores en hipótesis simples. En el problema de probar $H_0 : \theta = \theta_0$ vs. $H_1 : \theta = \theta_1$:

- El **error de Tipo I** es $\alpha(\delta) = \mathbb{P}[\text{Rechazo } H_0 \mid \theta = \theta_0]$.
- El **error de Tipo II** es $\beta(\delta) = \mathbb{P}[\text{No rechazo } H_0 \mid \theta = \theta_1]$.

El objetivo es minimizar simultáneamente $a\,\alpha(\delta) + b\,\beta(\delta)$, para constantes $a, b > 0$.

Teorema 16.0.1 Prueba óptima para combinación ponderada de errores. Supongamos que existe un procedimiento de prueba δ^* que rechaza H_0 si $af_0(x) < bf_1(x)$, y no rechaza H_0 si $af_0(x) > bf_1(x)$ (cuando $af_0(x) = bf_1(x)$ la decisión es indiferente). Para cualquier otro procedimiento de prueba δ,

$$a\,\alpha(\delta^*) + b\,\beta(\delta^*) \leq a\,\alpha(\delta) + b\,\beta(\delta). \tag{16.1}$$

Definición 16.0.2 Cociente de verosimilitud para hipótesis simples. El **cociente de verosimilitud** entre las densidades de las dos hipótesis es

$$\frac{f_1(x)}{f_0(x)}. \tag{16.2}$$

Su forma relacionada con la prueba LRT es

$$\Lambda(x) = \frac{f_0(x)}{\max\{f_0(x), f_1(x)\}} = \frac{\sup_{\Omega_0} f(x|\theta)}{\sup_{\Omega} f(x|\theta)}. \tag{16.3}$$

Corolario 16.0.1 Prueba óptima mediante cociente de verosimilitud. Bajo las condiciones del teorema anterior, si $a, b > 0$, la prueba δ^* que minimiza $a\,\alpha(\delta) + b\,\beta(\delta)$ rechaza H_0 si el cociente de verosimilitud $\dfrac{f_1(x)}{f_0(x)}$ es mayor que $\dfrac{a}{b}$.

Definición 16.0.3 Criterio de Neyman-Pearson. Para el problema de hipótesis simples $H_0 : \theta = \theta_0$ vs. $H_1 : \theta = \theta_1$:

1. $\alpha(\delta)$ es la probabilidad de error Tipo I; se desea $\alpha(\delta) \leq \alpha_0$.
2. $\beta(\delta)$ es la probabilidad de error Tipo II; se desea minimizar $\beta(\delta)$.

Lema 16.0.1 Lema de Neyman-Pearson. Supongamos que existe un procedimiento de prueba δ' que no rechaza H_0 si $f_1(x) < kf_0(x)$ y rechaza H_0 si $f_1(x) > kf_0(x)$. Si δ es otro procedimiento con $\alpha(\delta) \leq \alpha(\delta')$, entonces

$$\beta(\delta) \geq \beta(\delta'). \tag{16.4}$$

En consecuencia, la prueba que rechaza H_0 cuando

$$\frac{f_1(x)}{f_0(x)} > k \tag{16.5}$$

es la más potente entre todas las pruebas de nivel $\alpha(\delta')$. El valor de k se elige de modo que $\alpha(\delta') = \alpha_0$.

17

Pruebas Paramétricas Clásicas

Proposición 17.0.1 Prueba t de Student para una media. Sea $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ con μ y σ^2 desconocidos. El estadístico de prueba es

$$U = \frac{\bar{X}_n - \mu_0}{s/\sqrt{n}} \sim t_{n-1} \quad \text{bajo } H_0, \tag{17.1}$$

donde $s^2 = \dfrac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2$. Las reglas de rechazo al nivel α son:

- $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$: rechazar si $U \geq t_{n-1,\,1-\alpha}$.
- $H_0 : \mu \geq \mu_0$ vs. $H_1 : \mu < \mu_0$: rechazar si $U \leq t_{n-1,\,\alpha}$.
- $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$: rechazar si $|U| \geq t_{n-1,\,1-\alpha/2}$.

Proposición 17.0.2 Prueba t pareada. Dadas n pares de observaciones (X_i, Y_i), se define la diferencia $D_i = X_i - Y_i$. La prueba reduce el problema a una prueba de una muestra sobre $\mu_d = \mathbb{E}[D_i]$. El estadístico de prueba es

$$U = \frac{\bar{D}_n - \mu_0}{s_D/\sqrt{n}} \sim t_{n-1} \quad \text{bajo } H_0 : \mu_d = \mu_0, \tag{17.2}$$

y se rechaza H_0 si $|U| > t_{n-1,\,1-\alpha/2}$ en la prueba bilateral.
Si $\mu_0 = 0$ no pertenece al intervalo de confianza para μ_d, esto es equivalente a rechazar $H_0 : \mu_d = 0$.

Proposición 17.0.3 Prueba t para comparación de medias de dos poblaciones independientes. Sean $X_1, \dots, X_m \sim N(\mu_1, \sigma^2)$ y $Y_1, \dots, Y_n \sim N(\mu_2, \sigma^2)$ independientes con varianza común σ^2 desconocida. El estadístico de prueba es

$$U = \frac{\bar{X}_m - \bar{Y}_n}{\sqrt{\frac{1}{m} + \frac{1}{n}}\sqrt{\frac{(m-1)s_X^2 + (n-1)s_Y^2}{m+n-2}}}, \tag{17.3}$$

que bajo $H_0 : \mu_1 = \mu_2$ sigue una distribución t_{m+n-2}. Se aplican las mismas reglas de rechazo que en la prueba de una muestra, reemplazando $n-1$ por $m+n-2$.

Definición 17.0.1 Distribución F. Sean $Y \sim \chi^2_m$ y $W \sim \chi^2_n$ independientes. Se define

$$X = \frac{Y/m}{W/n}, \tag{17.4}$$

y se dice que X sigue una distribución F con m y n grados de libertad, denotada $X \sim F_{m,n}$. Su función de densidad es

$$f(x) = \begin{cases} \dfrac{\Gamma\left[\frac{1}{2}(m+n)\right] m^{m/2} n^{n/2}}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} \cdot \dfrac{x^{(m/2)-1}}{(mx+n)^{(m+n)/2}} & \text{si } x > 0, \\ 0 & \text{en otro caso.} \end{cases} \tag{17.5}$$

Proposición 17.0.4 Propiedades de la distribución F.

1. Si $X \sim F_{m,n}$, entonces $1/X \sim F_{n,m}$.
2. Si $Y \sim t_n$, entonces $Y^2 \sim F_{1,n}$.

Proposición 17.0.5 Prueba F para comparación de varianzas (una cola). Sean $X_1, \dots, X_m \sim N(\mu_1, \sigma_1^2)$ y $Y_1, \dots, Y_n \sim N(\mu_2, \sigma_2^2)$ independientes. El estadístico de prueba es

$$V = \frac{s_X^2}{s_Y^2} \sim F_{m-1,\,n-1} \quad \text{bajo } H_0 : \sigma_1^2 = \sigma_2^2. \tag{17.6}$$

Para $H_0 : \sigma_1^2 \le \sigma_2^2$ vs. $H_1 : \sigma_1^2 > \sigma_2^2$, se rechaza si $V \ge F_{m-1,\,n-1,\,1-\alpha}$. El valor-$p$ es $1 - F_{m-1,\,n-1}(V)$.

Proposición 17.0.6 Prueba F de homocedasticidad (dos colas). Para $H_0 : \sigma_1^2 = \sigma_2^2$ vs. $H_1 : \sigma_1^2 \neq \sigma_2^2$, se rechaza si $V \ge c_2$ o $V \le c_1$, donde

$$c_1 = F^{-1}_{m-1,\,n-1}\left(\frac{\alpha_0}{2}\right), \qquad c_2 = F^{-1}_{m-1,\,n-1}\left(1 - \frac{\alpha_0}{2}\right). \tag{17.7}$$

El valor-p bilateral es

$$\text{valor-}p = 2\,\text{mín}\left[1 - F_{m-1,\,n-1}(V),\ F_{m-1,\,n-1}(V)\right]. \tag{17.8}$$

La prueba F es un caso particular de la prueba de cociente de verosimilitud (LRT).

18
Bondad de Ajuste

Definición 18.0.1 Datos categóricos y distribución multinomial. Los **datos categóricos** son aquellos donde la variable puede caer en un número finito k de categorías, con probabilidades $p_1, \dots, p_k$ tales que $\sum_{i=1}^{k} p_i = 1$.
Si se recolecta una muestra de tamaño n, el vector de conteos $(N_1, \dots, N_k)$ sigue una distribución multinomial:

$$(N_1, \dots, N_k) \sim \text{Multinomial}(n,\, p_1, \dots, p_k). \tag{18.1}$$

Definición 18.0.2 Estadístico χ^2 de Pearson. Dadas probabilidades hipotéticas $p_1^0, \dots, p_k^0$ bajo H_0, el **estadístico** χ^2 se define como

$$Q = \sum_{i=1}^{k} \frac{(N_i - np_i^0)^2}{np_i^0} = \sum_{i=1}^{k} \frac{(\text{observado}_i - \text{esperado}_i)^2}{\text{esperado}_i}. \tag{18.2}$$

Bajo H_0, cuando n es grande y k es pequeño relativo a n,

$$Q \underset{H_0}{\longrightarrow} \chi^2_{k-1}. \tag{18.3}$$

Se rechaza H_0 si $Q \geq F^{-1}_{\chi^2_{k-1}}(1-\alpha)$.
La aproximación es adecuada si $np_i^0 \geq 5$ para todas las categorías. Con $np_i^0 \geq 1{,}5$ la aproximación es aceptable.

Definición 18.0.3 Prueba χ^2 con hipótesis parametrizadas. Si cada probabilidad depende de un parámetro $\theta = (\theta_1, \dots, \theta_s)$ con $s < k-1$, es decir, $p_i = \pi_i(\theta)$, el estadístico de prueba es

$$Q = \sum_{i=1}^{k} \frac{[N_i - n\pi_i(\hat{\theta})]^2}{n\pi_i(\hat{\theta})}, \tag{18.4}$$

donde $\hat{\theta}$ es el estimador de máxima verosimilitud de θ.

Teorema 18.0.1 Distribución asintótica con hipótesis parametrizadas. Bajo la hipótesis nula, cuando $n \to \infty$, la distribución de Q tiende a una χ^2 con $k-1-s$ grados de libertad:

$$Q \xrightarrow[H_0]{d} \chi^2_{k-1-s}. \tag{18.5}$$

Teorema 18.0.2 Prueba χ^2 con MLE basado en datos individuales. Sea $X_1, \dots, X_n \sim F_\theta$ con θ p-dimensional y $\hat{\theta}_n$ el MLE de θ. Tomando una partición de $\mathbb{R}$ en k intervalos disjuntos $(I_1, \dots, I_k)$, con N_i observaciones en I_i y $\pi_i(\theta) = \mathbb{P}_\theta[X \in I_i]$, el estadístico

$$Q' = \sum_{i=1}^{k} \frac{[N_i - n\pi_i(\hat{\theta}_n)]^2}{n\pi_i(\hat{\theta}_n)} \tag{18.6}$$

tiene, bajo condiciones de regularidad del MLE y H_0 verdadero, una función de distribución acumulada acotada entre χ^2_{k-p-1} y χ^2_{k-1} conforme $n \to \infty$.

19

Tablas de Contingencia

Definición 19.0.1 Tabla de contingencia. Un arreglo bidimensional en el que cada observación se puede clasificar de dos o más formas, generalmente a lo largo de filas y columnas.
Se usa la siguiente notación:

- R: número de filas; C: número de columnas.
- N_{ij}: número de individuos en la fila i y columna j.
- $N_{i+} = \sum_{j=1}^{C} N_{ij}$: total de la fila i.
- $N_{+j} = \sum_{i=1}^{R} N_{ij}$: total de la columna j.
- $n = \sum_{i,j} N_{ij}$: total de observaciones.
- p_{ij}: probabilidad de que un individuo pertenezca a la celda (i, j).
- $p_{i+} = \sum_{j=1}^{C} p_{ij}$, $p_{+j} = \sum_{i=1}^{R} p_{ij}$: probabilidades marginales.

Proposición 19.0.1 Prueba de independencia. La hipótesis nula de independencia es

$$H_0 : p_{ij} = p_{i+} \cdot p_{+j}, \quad i = 1, \dots, R;\ j = 1, \dots, C. \tag{19.1}$$

Los estimadores de máxima verosimilitud bajo H_0 son

$$\hat{p}_{i+} = \frac{N_{i+}}{n}, \qquad \hat{p}_{+j} = \frac{N_{+j}}{n}, \tag{19.2}$$

y la frecuencia esperada en la celda (i, j) es

$$\hat{E}_{ij} = n\,\hat{p}_{i+}\,\hat{p}_{+j} = \frac{N_{i+}\,N_{+j}}{n}. \tag{19.3}$$

El estadístico de prueba es

$$Q = \sum_{i=1}^{R}\sum_{j=1}^{C} \frac{(N_{ij} - \hat{E}_{ij})^2}{\hat{E}_{ij}} \underset{n \text{ grande},\, H_0}{\sim} \chi^2_{(R-1)(C-1)}. \tag{19.4}$$

Se rechaza H_0 si $Q > \chi^2_{(R-1)(C-1),\,1-\alpha}$. Los grados de libertad se obtienen como $k - s - 1 = RC - (R + C - 2) - 1 = (R-1)(C-1)$.

Proposición 19.0.2 Prueba de homogeneidad. Se tienen R poblaciones independientes y se observa una variable discreta con C categorías. La hipótesis nula es

$$H_0 : p_{1j} = p_{2j} = \cdots = p_{Rj}, \quad j = 1, \ldots, C. \tag{19.5}$$

El estadístico de prueba es el mismo que el de la prueba de independencia:

$$Q = \sum_{i=1}^{R}\sum_{j=1}^{C} \frac{(N_{ij} - \hat{E}_{ij})^2}{\hat{E}_{ij}} \sim \chi^2_{(R-1)(C-1)}, \tag{19.6}$$

con $\hat{E}_{ij} = N_{i+}N_{+j}/n$ y $(R-1)(C-1)$ grados de libertad.
Desde el punto de vista computacional, las pruebas de independencia y homogeneidad son idénticas; difieren en su interpretación: la primera analiza la relación entre dos variables en una única población, la segunda compara la distribución de una variable entre varias poblaciones.

Proposición 19.0.3 Comparación de proporciones en R grupos. Para comparar la proporción de una categoría entre R grupos se usa la prueba de homogeneidad con $C = 2$ columnas. El estadístico es

$$Q = \sum_{i=1}^{R}\sum_{j=1}^{2} \frac{(N_{ij} - \hat{E}_{ij})^2}{\hat{E}_{ij}} \underset{H_0}{\sim} \chi^2_{R-1}. \tag{19.7}$$

Definición 19.0.2 V de Cramer. La **V de Cramer** es una medida de la fuerza de asociación entre dos variables nominales, definida como

$$V = \sqrt{\frac{\chi^2/n}{\min(R-1,\, C-1)}}, \tag{19.8}$$

donde χ^2 es el estadístico de Pearson, n el total de observaciones, R el número de filas y C el número de columnas. Su valor varía entre 0 (ninguna asociación) y 1 (asociación perfecta).

Proposición 19.0.4 Paradoja de Simpson. La **Paradoja de Simpson** es un fenómeno en el que una tendencia observable en datos agregados desaparece o se invierte al desagregar los datos por una variable oculta (confusora). Formalmente, es posible tener simultáneamente

$$\mathbb{P}[\text{Mejora} \mid A \cap B] > \mathbb{P}[\text{Mejora} \mid A \cap B^c], \tag{19.9}$$

$$\mathbb{P}[\text{Mejora} \mid A^c \cap B] > \mathbb{P}[\text{Mejora} \mid A^c \cap B^c], \tag{19.10}$$

y sin embargo

$$\mathbb{P}[\text{Mejora} \mid B] < \mathbb{P}[\text{Mejora} \mid B^c]. \tag{19.11}$$

La paradoja se evita si se cumple que $\mathbb{P}[A \mid B] = \mathbb{P}[A \mid B^c]$, es decir, si la variable confusora es independiente del tratamiento. A este proceso de separar los datos por la variable oculta se le denomina **desagregación**.

20

Pruebas de Kolmogorov-Smirnov

Definición 20.0.1 Función de distribución empírica. Dados los valores observados $x_1, \dots, x_n$ de la muestra $X_1, \dots, X_n$, para cada x se define $F_n(x)$ como la proporción de valores observados menores o iguales a x:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}_{\{x_i \leq x\}}. \tag{20.1}$$

Es una función escalonada con saltos de magnitud $\frac{1}{n}$ en cada x_i. Por la ley de los grandes números, $F_n(x) \xrightarrow{\mathbb{P}} F(x)$ cuando $n \to \infty$, por lo que es un estimador consistente de F.

Lema 20.0.1 Lema de Glivenko-Cantelli. Sea $F_n(x)$ la función de distribución empírica de una muestra $X_1, \dots, X_n$ proveniente de la distribución F. Defínase

$$D_n = \sup_{-\infty < x < \infty} |F_n(x) - F(x)|. \tag{20.2}$$

Entonces

$$D_n \xrightarrow{\mathbb{P}} 0. \tag{20.3}$$

Es decir, si F_n proviene realmente de F, la diferencia suprema entre ambas converge en probabilidad a cero conforme $n \to \infty$.

Definición 20.0.2 Estadístico de Kolmogorov-Smirnov para una muestra. Para probar $H_0 : F = F^\star$ vs. $H_1 : F \neq F^\star$, el estadístico de prueba es

$$D_n^\star = \sup_{-\infty<x<\infty} |F_n(x) - F^\star(x)|. \tag{20.4}$$

Bajo H_0, la distribución de $D_n^\star$ no depende de $F^\star$. Se rechaza H_0 si $n^{1/2}D_n^\star \geq c$ para un valor crítico c.
En la práctica, $D_n^\star$ se calcula como

$$D_n^\star = \text{máx}\{D_n^+,\ D_n^-\}, \tag{20.5}$$

donde

$$D_n^+ = \sup_{1\leq i\leq n}\left\{\frac{i}{n} - F^\star(X_{(i)})\right\}, \qquad D_n^- = \sup_{1\leq i\leq n}\left\{F^\star(X_{(i)}) - \frac{i-1}{n}\right\}. \tag{20.6}$$

Teorema 20.0.1 Teorema de Kolmogorov-Smirnov (1930). Si H_0 es cierto, para $t > 0$,

$$\lim_{n\to\infty} \mathbb{P}\big(n^{1/2}D_n^\star \leq t\big) = 1 - 2\sum_{i=1}^{\infty}(-1)^{i-1}e^{-2i^2t^2} = H(t). \tag{20.7}$$

Para un nivel de significancia α_0, se rechaza H_0 si $n^{1/2}D_n^\star \geq H^{-1}(1-\alpha_0)$. Los cuantiles más comunes son:

- $\alpha = 0{,}01$: $H^{-1}(0{,}99) = 1{,}63$.
- $\alpha = 0{,}05$: $H^{-1}(0{,}95) = 1{,}36$.
- $\alpha = 0{,}10$: $H^{-1}(0{,}90) = 1{,}22$.

Definición 20.0.3 Estadístico de Kolmogorov-Smirnov para dos muestras. Sean $X_1, \ldots, X_m \sim F$ y $Y_1, \ldots, Y_n \sim G$ continuas e independientes. Para probar $H_0 : F = G$ vs. $H_1 : F \neq G$, el estadístico es

$$D_{mn}^\star = \sup_{-\infty<x<\infty} |F_m(x) - G_n(x)|, \tag{20.8}$$

donde F_m y G_n son las distribuciones empíricas de cada muestra. Se calcula como

$$D_{mn}^\star = \text{máx}\{D_{mn}^+,\ D_{mn}^-\}, \tag{20.9}$$

con

$$D_{mn}^+ = \sup_{1\leq i\leq n}\left\{F_m(X_{(i)}) - G_n(X_{(i)})\right\}, \qquad D_{mn}^- = \sup_{1\leq i\leq n}\left\{G_n(X_{(i)}) - F_m(X_{(i-1)})\right\}. \tag{20.10}$$

Teorema 20.0.2 Distribución límite para dos muestras. Si $H(t)$ es la distribución límite del caso de una muestra, entonces para $t > 0$,

$$\lim_{m,n\to\infty} \mathbb{P}\left(\left(\frac{mn}{m+n}\right)^{1/2} D_{mn}^\star \leq t\right) = H(t). \tag{20.11}$$

Se rechaza H_0 si $\left(\frac{mn}{m+n}\right)^{1/2} D_{mn}^\star \geq c(\alpha)$, donde

$$c(\alpha) = \sqrt{-\ln\Big(\frac{\alpha}{2}\Big)\frac{1}{2}}. \tag{20.12}$$

21

Pruebas No Paramétricas: Signo y Rango

Definición 21.0.1 Mediana poblacional. Sea X una variable aleatoria continua. La **mediana** μ es el valor que satisface

$$\mathbb{P}(X \leq \mu) = 0{,}5. \tag{21.1}$$

Toda distribución continua tiene mediana definida, incluso cuando no existe la media (como en la distribución de Cauchy). En este capítulo, μ denota la mediana, no la media.

Definición 21.0.2 Prueba de signo. Sean $X_1, \ldots, X_n$ una muestra de una distribución continua con mediana μ. Para las hipótesis

$$H_0 : \mu \leq \mu_0 \quad \text{vs.} \quad H_1 : \mu > \mu_0, \tag{21.2}$$

se definen $Y_i = \mathbf{1}_{\{X_i \leq \mu_0\}}$ y $W = \sum_{i=1}^{n} Y_i$. Bajo H_0, $p = \mathbb{P}(Y_i = 1) \geq 0{,}5$, de modo que

$$W \sim \text{Binomial}(n,\, p). \tag{21.3}$$

Se rechaza H_0 si $W \leq c$, donde c se elige tal que

$$\sum_{w=0}^{c} \binom{n}{w} \left(\frac{1}{2}\right)^{n} \leq \alpha_0 < \sum_{w=0}^{c+1} \binom{n}{w} \left(\frac{1}{2}\right)^{n}. \tag{21.4}$$

La prueba se llama **prueba de signo** porque está basada en el número de veces que $X_i - \mu_0$ es negativo.
Para la prueba bilateral $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$, se rechaza si $W \leq c$ o $W \geq n - c$, con c tal que

$$\sum_{w=0}^{c} \binom{n}{w} \left(\frac{1}{2}\right)^n \leq \frac{\alpha_0}{2}. \tag{21.5}$$

La función de potencia es

$$\pi(p) = \mathbb{P}(W \leq c) = \sum_{w=0}^{c} \binom{n}{w} (1-p)^{n-w} p^w. \tag{21.6}$$

Definición 21.0.3 Estadístico de rangos de Wilcoxon-Mann-Whitney. Sean $X_1, \dots, X_m \overset{\text{i.i.d.}}{\sim} F$ y $Y_1, \dots, Y_n \overset{\text{i.i.d.}}{\sim} G$ continuas, independientes entre sí. Para probar $H_0 : F = G$ vs. $H_1 : F \neq G$, se combinan ambas muestras en $(W_1, \dots, W_{m+n})$ y se ordenan. Se define S como la suma de los rangos de las X_i en la muestra combinada.

Proposición 21.0.1 Distribución del estadístico S bajo H_0. Bajo $H_0 : F = G$, los índices de posición de los X_i en la muestra combinada están uniformemente distribuidos sobre $\{1, \dots, m+n\}$. En consecuencia:

$$\mathbb{E}[S] = m\left(\frac{m+n+1}{2}\right), \qquad \operatorname{Var}(S) = mn\left(\frac{m+n+1}{12}\right). \tag{21.7}$$

Para m, n grandes (resultado de Mann y Whitney, 1947):

$$S \underset{H_0}{\sim} N\left(\frac{m(m+n+1)}{2},\ \frac{mn(m+n+1)}{12}\right). \tag{21.8}$$

Se rechaza H_0 si S se desvía significativamente de su media; la regla de rechazo bilateral es

$$\left|S - \frac{m(m+n+1)}{2}\right| \geq \sqrt{\operatorname{Var}(S)}\ \Phi^{-1}\left(1 - \frac{\alpha}{2}\right). \tag{21.9}$$

22

Anexo

22.1. Distribuciones de probabilidad discretas

22.1.1. Distribución de Bernoulli

Definición 22.1.1 Distribución Bernoulli. La notación $X \sim \text{Bernoulli}(p)$ indica que la variable aleatoria X tiene distribución Bernoulli con parámetro p, donde $0 < p < 1$. Esta distribución modela un experimento con dos posibles resultados éxito ($x = 1$) y fracaso ($x = 0$).

Teorema 22.1.1 Propiedades de la distribución Bernoulli. La función de masa de probabilidad de X es

$$f_X(x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}. \tag{22.1}$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1-p & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases} \tag{22.2}$$

La función de supervivencia de X es

$$S_X(x) = \begin{cases} 1 & x \leq 0 \\ p & 0 < x \leq 1 \\ 0 & x > 1 \end{cases} \tag{22.3}$$

La función de riesgo de X es

$$h_X(x) = \begin{cases} 1-p & x = 0 \\ 1 & x = 1 \end{cases} \tag{22.4}$$

La función de riesgo acumulada de X es

$$H_X(x) = \begin{cases} 0 & x \leq 0 \\ -\ln p & 0 < x \leq 1 \end{cases} \tag{22.5}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \begin{cases} 0 & 0 < u < 1-p \\ 1 & 1-p \leq u < 1 \end{cases} \tag{22.6}$$

La función generadora de momentos de X es

$$\phi_X(t) = (1-p) + pe^t, \quad t \in \mathbb{R}. \tag{22.7}$$

La función característica de X es

$$\varphi_X(t) = (1-p) + pe^{it}, \quad t \in \mathbb{R}. \tag{22.8}$$

La esperanza de X es

$$\mathbb{E}[X] = p. \tag{22.9}$$

La varianza de X es

$$\text{Var}(X) = p(1-p). \tag{22.10}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{1-2p}{\sqrt{p(1-p)}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3p^2-3p+1}{p(1-p)}. \tag{22.11}$$

La demostracion queda al lector.

22.1.2. Distribución binomial

Definición 22.1.2 Distribución Binomial. La notación $X \sim \text{Binomial}(n,p)$ indica que la variable aleatoria X tiene distribución Binomial con parámetro entero positivo n y parámetro real p, donde $0 < p < 1$. Esta distribución modela el número de éxitos en n ensayos de Bernoulli mutuamente independientes, cada uno con probabilidad de éxito p.

Teorema 22.1.2 Propiedades de la distribución Binomial. La función de masa de probabilidad de X es

$$f_X(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x \in \{0,1,\dots,n\}. \tag{22.12}$$

La función de distribución acumulada de X es

$$F_X(x) = \sum_{k=0}^{x} \binom{n}{k} p^k (1-p)^{n-k}, \quad x \in \{0,1,\dots,n\}. \tag{22.13}$$

La función de supervivencia de X es

$$S_X(x) = \sum_{k=x}^{n} \binom{n}{k} p^k (1-p)^{n-k}, \quad x \in \{0,1,\dots,n\}. \tag{22.14}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \min\{x \in \{0,1,\dots,n\} : F_X(x) \geq u\}, \quad 0 < u < 1. \tag{22.15}$$

La función generadora de momentos de X es

$$\phi_X(t) = \left((1-p) + pe^t\right)^n, \quad t \in \mathbb{R}. \tag{22.16}$$

La función característica de X es

$$\varphi_X(t) = \left((1-p) + pe^{it}\right)^n, \quad t \in \mathbb{R}. \tag{22.17}$$

La esperanza de X es

$$\mathbb{E}[X] = np. \tag{22.18}$$

La varianza de X es

$$\text{Var}(X) = np(1-p). \tag{22.19}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{1-2p}{\sqrt{np(1-p)}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3+1-6p(1-p)}{np(1-p)}. \tag{22.20}$$

La demostracion queda al lector.

22.1.3. Distribución Geométrica

Definición 22.1.3 Distribución geométrica. La notación $X \sim \text{Geometric}(p)$ indica que la variable aleatoria X tiene distribución Geométrica con parámetro real p, donde $0 < p < 1$. Esta distribución modela el número de fracasos antes del primer éxito en ensayos de Bernoulli repetidos e independientes, cada uno con probabilidad de éxito p.

Teorema 22.1.3 Propiedades de la distribución Geométrica. La función de masa de probabilidad de X es

$$f_X(x) = p(1-p)^x, \quad x \in \{0, 1, 2, \dots\}. \tag{22.21}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - (1-p)^{x+1}, \quad x \in \{0, 1, 2, \dots\}. \tag{22.22}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{\ln(1-u)}{\ln(1-p)}, \quad 0 < u < 1. \tag{22.23}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{p}{1-(1-p)e^t}, \quad t < -\ln(1-p). \tag{22.24}$$

La función característica de X es

$$\varphi_X(t) = \frac{p}{1-(1-p)e^{it}}, \quad t \in \mathbb{R}. \tag{22.25}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{1-p}{p}. \tag{22.26}$$

La varianza de X es

$$\text{Var}(X) = \frac{1-p}{p^2}. \tag{22.27}$$

La función de supervivencia de X es

$$S_X(x) = (1-p)^x, \quad x \in \{0, 1, 2, \dots\}. \tag{22.28}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = p, \quad x \in \{0, 1, 2, \dots\}. \tag{22.29}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln(S_X(x)) = -\ln((1-p)^x), \quad x \in \{0, 1, 2, \dots\}. \tag{22.30}$$

El sesgo poblacional de X es

$$\text{Skewness}(X) = \frac{2-p}{\sqrt{1-p}}. \tag{22.31}$$

La curtosis poblacional de X es

$$\text{Kurtosis}(X) = \frac{9+p^2}{1-p}. \tag{22.32}$$

La demostracion queda al lector.

22.1.4. Distribución de Poisson

Definición 22.1.4 Distribución Poisson. La notación $X \sim \text{Poisson}(\lambda)$ indica que la variable aleatoria X tiene distribución Poisson con parámetro positivo λ. Esta distribución modela el número de eventos que ocurren en un intervalo de tiempo o espacio, bajo un proceso aleatorio con tasa constante λ.

Teorema 22.1.4 Propiedades de la distribución Poisson. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x \in \{0, 1, 2, \dots\}. \tag{22.33}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\Gamma(x+1, \lambda)}{\Gamma(x+1)}, \quad x \in \{0, 1, 2, \dots\}. \tag{22.34}$$

La función de supervivencia de X es

$$S_X(x) = \Gamma(x+1) - x\Gamma(x, \lambda), \quad x \in \{0, 1, 2, \dots\}. \tag{22.35}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\lambda^x e^{-\lambda}}{\Gamma(x+1) - x\Gamma(x, \lambda)}, \quad x \in \{0, 1, 2, \dots\}. \tag{22.36}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln(S_X(x)) = -\ln\left(\Gamma(x+1) - x\Gamma(x, \lambda)\right), \quad x \in \{0, 1, 2, \dots\}. \tag{22.37}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \min\{x \in \mathbb{N}_0 : F_X(x) \geq u\}, \quad 0 < u < 1. \tag{22.38}$$

La función generadora de momentos de X es

$$\phi_X(t) = e^{\lambda(e^t - 1)}, \quad t \in \mathbb{R}. \tag{22.39}$$

La función característica de X es

$$\varphi_X(t) = e^{\lambda(e^{it} - 1)}, \quad t \in \mathbb{R}. \tag{22.40}$$

La esperanza de X es

$$\mathbb{E}[X] = \lambda. \tag{22.41}$$

La varianza de X es

$$\text{Var}(X) = \lambda. \tag{22.42}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \lambda^{-1/2}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3 + \lambda^{-1}. \tag{22.43}$$

La demostracion queda al lector.

22.1.5. Distribución hipergeométrica

Definición 22.1.5 Distribución Hipergeométrica. La notación $X \sim \text{Hypergeometric}(n_1, n_2, n_3)$ indica que la variable aleatoria X tiene distribución Hipergeométrica con parámetros enteros no negativos n_1, n_2, n_3, donde $n_1, n_2 \in \{0, 1, 2, \dots, n_3\}$. Esta distribución modela el número de elementos con una característica específica (por ejemplo, defectuosos) en una muestra de tamaño n_2, extraída sin reemplazo de una población finita de n_3 elementos que contiene n_1 elementos con dicha característica.

Teorema 22.1.5 Propiedades de la distribución Hipergeométrica. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\binom{n_1}{x}\binom{n_3-n_1}{n_2-x}}{\binom{n_3}{n_2}}, \quad x \in \{\text{máx}(0, n_1+n_2-n_3), \dots, \text{mín}(n_1, n_2)\}. \tag{22.44}$$

La función de distribución acumulada de X es

$$F_X(x) = \sum_{k=0}^{x} \frac{\binom{n_1}{k}\binom{n_3-n_1}{n_2-k}}{\binom{n_3}{n_2}}, \quad x \in \{\text{máx}(0, n_1+n_2-n_3), \dots, \text{mín}(n_1, n_2)\}. \tag{22.45}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \text{mín}\{x \in \mathbb{N}_0 : F_X(x) \geq u\}, \quad 0 < u < 1. \tag{22.46}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{\binom{n_3-n_1}{n_2}}{\binom{n_3}{n_2}} \cdot {}_2F_1(-n_2, -n_1, n_3-n_1-n_2+1, e^t), \tag{22.47}$$

donde ${}_2F_1(a, b, c, z)$ es la función hipergeométrica de Gauss.
La esperanza de X es

$$\mathbb{E}[X] = \frac{n_1 n_2}{n_3}. \tag{22.48}$$

La varianza de X es

$$\text{Var}(X) = \frac{n_2 n_1 (n_3-n_1)(n_3-n_2)}{n_3^2(n_3-1)}. \tag{22.49}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{(n_3-2n_1)(n_3-1)^{1/2}(n_3-2n_2)}{[n_2 n_1 (n_3-n_1)(n_3-n_2)]^{1/2}(n_3-2)}. \tag{22.50}$$

La demostracion queda al lector.

22.1.6. Distribución de Pascal

Definición 22.1.6 Distribución Pascal. La notación $X \sim \text{Pascal}(n, p)$ indica que la variable aleatoria X tiene distribución Pascal con parámetro entero positivo n y parámetro real p, donde $0 < p < 1$. Esta distribución modela el número de fracasos antes del n-ésimo éxito en ensayos de Bernoulli repetidos e independientes, cada uno con probabilidad de éxito p.

Teorema 22.1.6 Propiedades de la distribución Pascal. La función de masa de probabilidad de X es

$$f_X(x) = \binom{n-1+x}{x} p^n (1-p)^x, \quad x \in \{0, 1, 2, \dots\}. \tag{22.51}$$

La función generadora de momentos de X es

$$\phi_X(t) = \left(\frac{p}{1-(1-p)e^t}\right)^n, \quad t < -\ln(1-p). \tag{22.52}$$

La función característica de X es

$$\varphi_X(t) = \left(\frac{p}{1-(1-p)e^{it}}\right)^n, \quad t \in \mathbb{R}. \tag{22.53}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n(1-p)}{p}. \tag{22.54}$$

La varianza de X es

$$\operatorname{Var}(X) = \frac{n(1-p)}{p^2}. \tag{22.55}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2-p}{\sqrt{np(1-p)}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{p^2-6p-3np+3n+6}{n(1-p)}. \tag{22.56}$$

La demostracion queda al lector.

22.1.7. Distribución uniforme discreta

Definición 22.1.7 Distribución Uniforme Discreta. La notación $X \sim \text{Uniforme Discreta}(a, b)$ indica que la variable aleatoria X tiene distribución uniforme discreta con parámetros enteros a y b, donde $a < b$. Esta distribución modela una selección aleatoria equiprobable entre los valores enteros $a, a+1, \dots, b$.

Teorema 22.1.7 Propiedades de la distribución Uniforme Discreta. La función de masa de probabilidad de X es

$$f_X(x) = \frac{1}{b-a+1}, \quad x \in \{a, a+1, \dots, b\}. \tag{22.57}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{x-a+1}{b-a+1}, \quad x \in \{a, a+1, \dots, b\}. \tag{22.58}$$

La función de supervivencia de X es

$$S_X(x) = \frac{b-x+1}{b-a+1}, \quad x \in \{a, a+1, \dots, b\}. \tag{22.59}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{b-x+1}, \quad x \in \{a, a+1, \dots, b\}. \tag{22.60}$$

La función inversa de distribución de X es

$$F^{-1}(u) = a + \lfloor u(b-a+1) \rfloor, \quad 0 < u < 1. \tag{22.61}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{e^{at} - e^{(b+1)t}}{(b-a+1)(1-e^t)}, \quad t \in \mathbb{R}. \tag{22.62}$$

La función característica de X es

$$\varphi_X(t) = \frac{e^{ait} - e^{(b+1)it}}{(b-a+1)(1-e^{it})}, \quad t \in \mathbb{R}. \tag{22.63}$$

La mediana de X es

$$\text{Mediana}(X) = \frac{a+b}{2}. \tag{22.64}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{a+b}{2}. \tag{22.65}$$

La varianza de X es

$$\text{Var}(X) = \frac{(b-a+1)^2 - 1}{12}. \tag{22.66}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{6[(b-a+1)^2+1]}{5[(b-a+1)^2-1]}. \tag{22.67}$$

La demostracion queda al lector.

22.1.8. Distribución zeta

Definición 22.1.8 Distribución Zeta. La notación $X \sim \text{Zeta}(\alpha)$ indica que la variable aleatoria X tiene distribución Zeta con parámetro $\alpha > 1$. Esta distribución modela fenómenos discretos con comportamiento de cola pesada, y está definida sobre los enteros positivos.

Teorema 22.1.8 Propiedades de la distribución Zeta. La función de masa de probabilidad de X es

$$f_X(x) = \frac{1}{x^\alpha \zeta(\alpha)}, \quad x \in \{1, 2, 3, \dots\}. \tag{22.68}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{\zeta(\alpha)} \sum_{i=1}^{x} \frac{1}{i^\alpha}, \quad x \in \{1, 2, 3, \dots\}. \tag{22.69}$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{\zeta(\alpha)} \sum_{i=x}^{\infty} \frac{1}{i^\alpha}, \quad x \in \{1, 2, 3, \dots\}. \tag{22.70}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{x^\alpha \sum_{i=x}^{\infty} \frac{1}{i^\alpha}}, \quad x \in \{1, 2, 3, \dots\}. \tag{22.71}$$

La función de riesgo acumulada de X es

$$H_X(x) = \ln(\zeta(\alpha)) - \ln\left(\sum_{i=x}^{\infty} \frac{1}{i^\alpha}\right), \quad x \in \{1, 2, 3, \dots\}. \tag{22.72}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{1}{\zeta(\alpha)} \sum_{x=1}^{\infty} \frac{e^{tx}}{x^\alpha}, \quad t \in \mathbb{R}. \tag{22.73}$$

La función característica de X es

$$\varphi_X(t) = \frac{1}{\zeta(\alpha)} \sum_{x=1}^{\infty} \frac{e^{itx}}{x^\alpha}, \quad t \in \mathbb{R}. \tag{22.74}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\zeta(\alpha - 1)}{\zeta(\alpha)}, \quad \alpha > 2. \tag{22.75}$$

La varianza de X es

$$\mathrm{Var}(X) = \frac{\zeta(\alpha)\zeta(\alpha - 2) - \zeta(\alpha - 1)^2}{\zeta(\alpha)^2}, \quad \alpha > 3. \tag{22.76}$$

La demostracion queda al lector.

22.1.9. Distribución zipf

Definición 22.1.9 Distribución Zipf. La notación $X \sim \mathrm{Zipf}(\alpha, n)$ indica que la variable aleatoria X tiene distribución Zipf con parámetros $\alpha \geq 0$ y $n \in \mathbb{N}^+$. Esta distribución modela fenómenos donde unos pocos elementos tienen alta frecuencia o popularidad, mientras que la mayoría son poco frecuentes.

Teorema 22.1.9 Propiedades de la distribución Zipf. La función de masa de probabilidad de X es

$$f_X(x) = \frac{1}{x^\alpha H_{n,\alpha}}, \quad x \in \{1, 2, \dots, n\}, \tag{22.77}$$

donde $H_{n,\alpha} = \sum_{i=1}^{n} \frac{1}{i^\alpha}$.
La función de distribución acumulada de X es

$$F_X(x) = \frac{H_{x,\alpha}}{H_{n,\alpha}}, \quad x \in \{1, 2, \dots, n\}. \tag{22.78}$$

La función de supervivencia de X es

$$S_X(x) = \frac{x^\alpha H_{n,\alpha} - x^\alpha H_{x+1,\alpha}}{x^\alpha H_{n,\alpha}}, \quad x \in \{1, 2, \dots, n\}. \tag{22.79}$$

La función de riesgo de X es

$$h_X(x) = \frac{1}{x^\alpha H_{n,\alpha} - x^\alpha H_{x+1,\alpha}}, \quad x \in \{1, 2, \dots, n\}. \tag{22.80}$$

La función de riesgo acumulada de X es

$$H_X(x) = \ln\big(x^\alpha H_{n,\alpha}\big) - \ln\big(x^\alpha H_{n,\alpha} - x^\alpha H_{x+1,\alpha}\big), \quad x \in \{1, 2, \dots, n\}. \tag{22.81}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{1}{H_{n,\alpha}} \sum_{j=1}^{n} \frac{e^{tj}}{j^\alpha}, \quad t \in \mathbb{R}. \tag{22.82}$$

La función característica de X es

$$\varphi_X(t) = \frac{1}{H_{n,\alpha}} \sum_{j=1}^{n} \frac{e^{itj}}{j^\alpha}, \quad t \in \mathbb{R}. \tag{22.83}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{H_{n,\alpha-1}}{H_{n,\alpha}}. \tag{22.84}$$

La varianza de X es

$$\operatorname{Var}(X) = \frac{H_{n,\alpha} H_{n,\alpha-2} - H_{n,\alpha-1}^2}{H_{n,\alpha}^2}. \tag{22.85}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{H_{n,\alpha-3} H_{n,\alpha} - 3H_{n,\alpha-1} H_{n,\alpha-2} + 2H_{n,\alpha-1}^3}{\left(H_{n,\alpha} H_{n,\alpha-2} - H_{n,\alpha-1}^2\right)^{3/2}} \tag{22.86}$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{H_{n,\alpha} H_{n,\alpha-4} - 4H_{n,\alpha-1} H_{n,\alpha-3} + 6H_{n,\alpha-1}^2 H_{n,\alpha-2} - 3H_{n,\alpha-1}^4}{\left(H_{n,\alpha} H_{n,\alpha-2} - H_{n,\alpha-1}^2\right)^2}. \tag{22.87}$$

La demostracion queda al lector.

22.1.10. Distribución beta-binomial

Definición 22.1.10 Distribución Beta-Binomial. La notación $X \sim \text{BetaBinomial}(a, b, n)$ indica que la variable aleatoria X tiene distribución Beta-Binomial con parámetros $a > 0$, $b > 0$ y $n \in \mathbb{N}^+$. Esta distribución modela el número de éxitos en n ensayos de Bernoulli donde la probabilidad de éxito p sigue una distribución Beta con parámetros a y b.

Teorema 22.1.10 Propiedades de la distribución Beta-Binomial. La función de masa de

probabilidad de X es

$$f_X(x) = \frac{\Gamma(x+a)\Gamma(n-x+b)\Gamma(a+b)\Gamma(n+2)}{(n+1)\Gamma(a+b+n)\Gamma(a)\Gamma(b)\Gamma(x+1)\Gamma(n-x+1)}, \quad x \in \{0,1,\dots,n\}. \tag{22.88}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{na}{a+b}. \tag{22.89}$$

La varianza de X es

$$\operatorname{Var}(X) = \frac{nab(a+b+n)}{(a+b)^2(a+b+1)}. \tag{22.90}$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{(a+b+2n)(b-a)\sqrt{1+a+b}}{(a+b+2)(a+b)^2(a+b+1)\sqrt{nab(n+a+b)}}. \tag{22.91}$$

La demostracion queda al lector.

22.1.11. Distribución hipergeométrica negativa

Definición 22.1.11 Distribución Hipergeométrica Negativa. La notación $X \sim \text{NegHypergeometric}(n_1, n_2, n_3)$ indica que la variable aleatoria X tiene distribución Hipergeométrica Negativa con parámetros $n_1, n_2, n_3 \in \mathbb{N}^+$, donde $n_1 \leq n_2$. Esta distribución modela el número de éxitos obtenidos antes de observar n_1 fracasos en un muestreo sin reemplazo de una población finita de n_3 elementos, de los cuales n_2 son exitosos.

Teorema 22.1.11 Propiedades de la distribución Hipergeométrica Negativa. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\binom{n_1+x-1}{x}\binom{n_3-n_1+n_2-x-1}{n_2-x}}{\binom{n_3+n_2-1}{n_2}}, \quad x \in \{0,1,\dots,n_2\}. \tag{22.92}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n_1 n_2}{n_3}. \tag{22.93}$$

La varianza de X es

$$\operatorname{Var}(X) = \frac{n_1 n_2 (n_3+n_2)(n_3-n_1)}{n_3^2(n_3+1)}. \tag{22.94}$$

La demostracion queda al lector.

22.1.12. Distribución de Polya

Definición 22.1.12 Distribución Polya. La notación $X \sim \text{Polya}(n, p, \beta)$ indica que la variable aleatoria X tiene distribución Polya con parámetros $n \in \mathbb{N}^+$, $0 < p < 1$, y $\beta > 0$. Esta distribución modela el número de éxitos en n ensayos de Bernoulli con probabilidad de éxito variable, influenciada por los parámetros p y β.

Teorema 22.1.12 Propiedades de la distribución Polya. La función de masa de probabilidad de X es

$$f_X(x) = \binom{n}{x} \cdot \frac{\prod_{j=0}^{x-1}(p+j\beta)\cdot\prod_{k=0}^{n-x-1}(1-p+k\beta)}{\prod_{i=0}^{n-1}(1+i\beta)}, \quad x \in \{0,1,\dots,n\}. \tag{22.95}$$

La esperanza de X es

$$\mathbb{E}[X] = -\frac{\sin\left(\frac{\pi(-1+\beta+p)}{\beta}\right)\cdot pn\cdot\sin\left(\frac{\pi(n\beta+1)}{\beta}\right)}{\sin\left(\frac{\pi}{\beta}\right)\cdot\sin\left(\frac{\pi(n\beta-\beta-p+1)}{\beta}\right)}. \tag{22.96}$$

La demostracion queda al lector.

22.1.13. Distribución logarítmica

Definición 22.1.13 Distribución Logarítmica. La notación $X \sim \text{Logarithm}(c)$ indica que la variable aleatoria X tiene distribución logarítmica con parámetro $0 < c < 1$. Esta distribución discreta se utiliza para modelar fenómenos con alta probabilidad de valores pequeños y decaimiento exponencial.

Teorema 22.1.13 Propiedades de la distribución Logarítmica. La función de masa de probabilidad de X es

$$f_X(x) = -\frac{(1-c)^x}{x\ln c}, \quad x \in \{1,2,3,\dots\}. \tag{22.97}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{\ln(1-e^t+ce^t)}{\ln c}, \quad t \in \mathbb{R}. \tag{22.98}$$

La función característica de X es

$$\varphi_X(t) = \frac{\ln(1-e^{it}+ce^{it})}{\ln c}, \quad t \in \mathbb{R}. \tag{22.99}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{-c}{(1-c)\ln c}. \tag{22.100}$$

La varianza de X es

$$\text{Var}(X) = \frac{(c-1)(\ln c+1-c)}{(\ln c)^2 c^2}. \tag{22.101}$$

La demostracion queda al lector.

22.1.14. Distribución gamma-poisson

Definición 22.1.14 Distribución Gamma–Poisson. La notación $X \sim \text{Gamma–Poisson}(\alpha,\beta)$ indica que la variable aleatoria X tiene distribución Gamma–Poisson con parámetros positivos α y β. Esta distribución modela una variable Poisson con parámetro aleatorio $\mu \sim \text{Gamma}(\alpha,\beta)$, y se utiliza para representar conteos con sobredispersión.

Teorema 22.1.14 Propiedades de la distribución Gamma–Poisson. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\Gamma(x+\beta)\cdot\alpha^x}{\Gamma(\beta)\cdot(1+\alpha)^{\beta+x}\cdot x!}, \quad x \in \{0,1,2,\dots\}. \tag{22.102}$$

La función de distribución acumulada de X es

$$F_X(x) = \sum_{w=0}^{x} \frac{\Gamma(w+\beta)\cdot\alpha^w}{\Gamma(\beta)\cdot(1+\alpha)^{\beta+w}\cdot w!}, \quad x \in \{0,1,2,\dots\}. \tag{22.103}$$

La función generadora de momentos de X es

$$\phi_X(t) = (1+\alpha-\alpha e^t)^{-\beta}, \quad t \in \mathbb{R}. \tag{22.104}$$

La función característica de X es

$$\varphi_X(t) = (1+\alpha-\alpha e^{it})^{-\beta}, \quad t \in \mathbb{R}. \tag{22.105}$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha\beta. \tag{22.106}$$

La varianza de X es

$$\operatorname{Var}(X) = \alpha\beta + \alpha^2\beta. \tag{22.107}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{1+2\alpha}{\sqrt{\alpha\beta(1+\alpha)}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3\alpha^2\beta+6\alpha^2+3\alpha\beta+6\alpha+1}{\alpha\beta(1+\alpha)}. \tag{22.108}$$

La demostracion queda al lector.

22.1.15. Distribución beta-pascal

Definición 22.1.15 Distribución Beta–Pascal. La notación $X \sim \text{BetaPascal}(n,a,b)$ indica que la variable aleatoria X tiene distribución Beta–Pascal con parámetros $n \in \mathbb{N}^+$, $a > 0$, y $b > 0$. Esta distribución modela el número de fracasos antes del n-ésimo éxito en ensayos de Bernoulli, donde la probabilidad de éxito p sigue una distribución Beta con parámetros a y b.

Teorema 22.1.15 Propiedades de la distribución Beta–Pascal. La función de masa de probabilidad de X es

$$f_X(x) = \binom{n-1+x}{x} \cdot \frac{B(n+a,b+x)}{B(a,b)}, \quad x \in \{0,1,2,\dots\}. \tag{22.109}$$

La función de distribución acumulada de X es

$$F_X(x) = \sum_{w=0}^{x} \binom{n-1+w}{w} \cdot \frac{B(n+a,b+w)}{B(a,b)}, \quad x \in \{0,1,2,\dots\}. \tag{22.110}$$

La función de supervivencia de X es

$$S_X(x) = \sum_{w=x}^{\infty} \binom{n-1+w}{w} \cdot \frac{B(n+a, b+w)}{B(a,b)}, \quad x \in \{0,1,2,\dots\}. \tag{22.111}$$

La demostracion queda al lector.

22.1.16. Distribución power series

Definición 22.1.16 Distribución Power Series. Una variable aleatoria X tiene distribución Power Series si su función de masa de probabilidad depende de una secuencia $a_x > 0$, un parámetro $c > 0$, y una función generadora de la serie $A(c) = \sum_{x=0}^{\infty} a_x c^x$. Esta familia incluye distribuciones como binomial, Poisson, y negativa binomial como casos especiales.

Teorema 22.1.16 Propiedades de la distribución Power Series. La función de masa de probabilidad de X es

$$f_X(x) = \frac{a_x c^x}{A(c)}, \quad x \in \{0,1,2,\dots\}. \tag{22.112}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{A(c)} \sum_{w=0}^{x} a_w c^w. \tag{22.113}$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{A(c)} \sum_{w=x}^{\infty} a_w c^w. \tag{22.114}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{a_x c^x}{\sum_{w=x}^{\infty} a_w c^w}. \tag{22.115}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{A(ce^t)}{A(c)}, \quad t > 0. \tag{22.116}$$

La esperanza de X es

$$\mathbb{E}[X] = c \cdot \frac{d}{dc} \left[\ln A(c)\right]. \tag{22.117}$$

La demostracion queda al lector.

22.1.17. Distribución Weibull discreta

Definición 22.1.17 Distribución Weibull Discreta. La notación $X \sim$ Weibull Discreta(p, β) indica que la variable aleatoria X tiene distribución Weibull Discreta con parámetro de escala $0 < p < 1$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza para modelar tiempos discretos de falla o eventos con comportamiento de cola pesada.

Teorema 22.1.17 Propiedades de la distribución Weibull Discreta. La función de masa de probabilidad de X es

$$f_X(x) = (1-p)^{x^\beta} - (1-p)^{(x+1)^\beta}, \quad x \in \{0, 1, 2, \dots\}. \tag{22.118}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - (1-p)^{(x+1)^\beta}. \tag{22.119}$$

La función de supervivencia de X es

$$S_X(x) = (1-p)^{x^\beta}. \tag{22.120}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = 1 - (1-p)^{(x+1)^\beta - x^\beta}. \tag{22.121}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = -x^\beta \ln(1-p). \tag{22.122}$$

La función generadora de momentos de X es

$$\phi_X(t) = \sum_{x=0}^{\infty} \left[(1-p)^{x^\beta} - (1-p)^{(x+1)^\beta}\right] e^{tx}. \tag{22.123}$$

La esperanza de X es

$$\mathbb{E}[X] = \sum_{x=0}^{\infty} \left[(1-p)^{x^\beta} - (1-p)^{(x+1)^\beta}\right] x. \tag{22.124}$$

La demostracion queda al lector.

22.1.18. Distribución rectangular discreta

Definición 22.1.18 Distribución Rectangular Discreta. La notación $X \sim \text{Rectangular}(n)$ indica que la variable aleatoria X tiene distribución rectangular discreta con parámetro entero positivo n. Esta distribución asigna igual probabilidad a cada uno de los valores enteros $x \in \{0, 1, \dots, n\}$.

Teorema 22.1.18 Propiedades de la distribución Rectangular Discreta. La función de masa de probabilidad de X es

$$f_X(x) = \frac{1}{n+1}, \quad x \in \{0, 1, \dots, n\}. \tag{22.125}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{x+1}{n+1}, \quad x \in \{0, 1, \dots, n\}. \tag{22.126}$$

La función de supervivencia de X es

$$S_X(x) = \frac{n+1-x}{n+1}, \quad x \in \{0, 1, \dots, n\}. \tag{22.127}$$

La función de riesgo de X es

$$h_X(x) = \frac{1}{n+1-x}, \quad x \in \{0, 1, \dots, n\}. \tag{22.128}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln\left(\frac{n+1-x}{n+1}\right), \quad x \in \{0, 1, \dots, n\}. \tag{22.129}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \lfloor (n+1)u \rfloor, \quad 0 < u < 1. \tag{22.130}$$

La mediana de X es

$$\text{Mediana}(X) = \frac{n-1}{2}, \quad \text{si } n \text{ es par.} \tag{22.131}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{e^{t(n+1)} - 1}{(e^t - 1)(n+1)}, \quad t \in \mathbb{R}. \tag{22.132}$$

La función característica de X es

$$\varphi_X(t) = \frac{e^{it(n+1)} - 1}{(e^{it} - 1)(n+1)}, \quad t \in \mathbb{R}. \tag{22.133}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n}{2}. \tag{22.134}$$

La varianza de X es

$$\text{Var}(X) = \frac{n(n+2)}{12}. \tag{22.135}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3}{5} \cdot \frac{3n^2 + 6n - 4}{n(n+2)}. \tag{22.136}$$

La demostracion queda al lector.

22.1.19. Distribución Benford

Definición 22.1.19 Distribución Benford. La notación $X \sim$ Benford indica que la variable aleatoria X tiene distribución Benford. Esta distribución modela la probabilidad de aparición de los dígitos iniciales en datos reales, y es útil en auditorías, detección de fraudes y análisis de datos empíricos.

Teorema 22.1.19 Propiedades de la distribución Benford. La función de masa de probabilidad de X es

$$f_X(x) = \log_{10}\left(1 + \frac{1}{x}\right), \quad x \in \{1, 2, \dots, 9\}. \tag{22.137}$$

La función de distribución acumulada de X es

$$F_X(x) = \log_{10}(1+x), \quad x \in \{1,2,\dots,9\}. \tag{22.138}$$

La función de supervivencia de X es

$$S_X(x) = 1 - \log_{10}(x), \quad x \in \{1,2,\dots,9\}. \tag{22.139}$$

La función de riesgo de X es

$$h_X(x) = \frac{\log_{10}\left(1+\frac{1}{x}\right)}{1-\log_{10}(x)}, \quad x \in \{1,2,\dots,9\}. \tag{22.140}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln\Big(1-\log_{10}(x)\Big), \quad x \in \{1,2,\dots,9\}. \tag{22.141}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \lfloor 10^u \rfloor, \quad 0 < u < 1. \tag{22.142}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{2\ln(2) - 4\ln(3) + 8\ln(5) - \ln(7)}{\ln(2)+\ln(5)}. \tag{22.143}$$

La varianza de X es

$$\mathrm{Var}(X) \approx 6{,}0565. \tag{22.144}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] \approx 0{,}7956, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] \approx 2{,}4518. \tag{22.145}$$

La demostracion queda al lector.

22.2. Distribuciones de probabilidad continuas

22.2.1. Distribución normal

Definición 22.2.1 Distribución Normal. La notación $X \sim \mathcal{N}(\mu, \sigma^2)$ indica que la variable aleatoria X tiene distribución normal con media $\mu \in \mathbb{R}$ y varianza $\sigma^2 > 0$. Esta distribución es fundamental en estadística y modela fenómenos naturales como alturas, pesos, errores de medición y resultados agregados por el teorema central del límite.

Teorema 22.2.1 Propiedades de la distribución Normal. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}. \tag{22.146}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2}\left[1 + \mathrm{erf}\left(\frac{x-\mu}{\sqrt{2}\sigma}\right)\right], \quad x \in \mathbb{R}. \tag{22.147}$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{2}\left[1 - \operatorname{erf}\left(\frac{x-\mu}{\sqrt{2}\sigma}\right)\right], \quad x \in \mathbb{R}. \tag{22.148}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{\sigma\sqrt{2\pi}} \cdot \frac{\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)}{1 - \operatorname{erf}\left(\frac{x-\mu}{\sqrt{2}\sigma}\right)}, \quad x \in \mathbb{R}. \tag{22.149}$$

La función de riesgo acumulada de X es matemáticamente intractable.
La función inversa de distribución de X es

$$F^{-1}(u) = \mu + \sigma\sqrt{2} \cdot \operatorname{erf}^{-1}(2u-1), \quad 0 < u < 1. \tag{22.150}$$

La mediana de X es

$$\text{Mediana}(X) = \mu. \tag{22.151}$$

La función generadora de momentos de X es

$$\phi_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right), \quad t \in \mathbb{R}. \tag{22.152}$$

La función característica de X es

$$\varphi_X(t) = \exp\left(i\mu t - \frac{\sigma^2 t^2}{2}\right), \quad t \in \mathbb{R}. \tag{22.153}$$

La esperanza de X es

$$\mathbb{E}[X] = \mu. \tag{22.154}$$

La varianza de X es

$$\operatorname{Var}(X) = \sigma^2. \tag{22.155}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3. \tag{22.156}$$

La demostracion queda al lector.

22.2.2. Distribución exponencial

Definición 22.2.2 Distribución Exponencial. La notación $X \sim \text{Exponencial}(\alpha)$ indica que la variable aleatoria X tiene distribución exponencial con parámetro de escala $\alpha > 0$. Alternativamente, puede parametrizarse por su tasa $\lambda = 1/\alpha$. Esta distribución modela tiempos entre eventos en procesos de Poisson, y es la única distribución continua con la propiedad de falta de memoria.

Teorema 22.2.2 Propiedades de la distribución Exponencial. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\alpha} e^{-x/\alpha}, \quad x > 0. \tag{22.157}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-x/\alpha}, \quad x > 0. \tag{22.158}$$

La función de supervivencia de X es

$$S_X(x) = e^{-x/\alpha}, \quad x > 0. \tag{22.159}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{\alpha}, \quad x > 0. \tag{22.160}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \frac{x}{\alpha}, \quad x > 0. \tag{22.161}$$

La función inversa de distribución de X es

$$F^{-1}(u) = -\alpha \ln(1-u), \quad 0 < u < 1. \tag{22.162}$$

La mediana de X es

$$\text{Mediana}(X) = \alpha \ln 2. \tag{22.163}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{1}{1-\alpha t}, \quad t < \frac{1}{\alpha}. \tag{22.164}$$

La función característica de X es

$$\varphi_X(t) = \frac{1}{1-\alpha i t}, \quad t \in \mathbb{R}. \tag{22.165}$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha. \tag{22.166}$$

La varianza de X es

$$\text{Var}(X) = \alpha^2. \tag{22.167}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 2, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 9. \tag{22.168}$$

La demostracion queda al lector.

22.2.3. Distribución uniforme continua

Definición 22.2.3 Distribución Uniforme Continua. La notación $X \sim \mathcal{U}(a,b)$ indica que la variable aleatoria X tiene distribución uniforme continua con parámetros $a < b$, donde $a, b \in \mathbb{R}$. Esta distribución modela una variable que tiene igual probabilidad de tomar cualquier valor dentro del intervalo (a,b).

Teorema 22.2.3 Propiedades de la distribución Uniforme Continua. La función de densidad

de probabilidad de X es

$$f_X(x) = \frac{1}{b-a}, \quad a < x < b. \tag{22.169}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{x-a}{b-a}, \quad a < x < b. \tag{22.170}$$

La función de supervivencia de X es

$$S_X(x) = \frac{b-x}{b-a}, \quad a < x < b. \tag{22.171}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{b-x}, \quad a < x < b. \tag{22.172}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(b-a) - \ln(b-x), \quad a < x < b. \tag{22.173}$$

La función inversa de distribución de X es

$$F^{-1}(u) = a + u(b-a), \quad 0 < u < 1. \tag{22.174}$$

La mediana de X es

$$\text{Mediana}(X) = \frac{a+b}{2}. \tag{22.175}$$

La función generadora de momentos de X es

$$\phi_X(t) = \begin{cases} \frac{e^{bt}-e^{at}}{t(b-a)}, & t \neq 0 \\ 1, & t = 0 \end{cases} \tag{22.176}$$

La función característica de X es

$$\varphi_X(t) = \begin{cases} \frac{e^{ibt}-e^{iat}}{it(b-a)}, & t \neq 0 \\ 1, & t = 0 \end{cases} \tag{22.177}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{a+b}{2}. \tag{22.178}$$

La varianza de X es

$$\text{Var}(X) = \frac{(b-a)^2}{12}. \tag{22.179}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{9}{5}. \tag{22.180}$$

22.2.4. Distribución gamma

Definición 22.2.4 Distribución Gamma. La notación $X \sim \text{Gamma}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución Gamma con parámetro de escala $\beta > 0$ y parámetro de forma $\alpha > 0$. Esta distribución se utiliza para modelar tiempos de servicio, tiempos de vida útil y procesos de reparación, y posee una cola derecha exponencial.

Teorema 22.2.4 Propiedades de la distribución Gamma. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)}, \quad x > 0. \tag{22.181}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\Gamma(\alpha, \beta x)}{\Gamma(\alpha)}, \quad x > 0, \tag{22.182}$$

donde $\Gamma(\alpha, \beta x)$ es la función gamma incompleta superior.
La función de supervivencia de X es

$$S_X(x) = 1 - \frac{\Gamma(\alpha, \beta x)}{\Gamma(\alpha)}, \quad x > 0. \tag{22.183}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{x^{\alpha-1} e^{-\beta x} \beta^\alpha}{\Gamma(\alpha) - \Gamma(\alpha, \beta x)}, \quad x > 0. \tag{22.184}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = -\ln\left(1 - \frac{\Gamma(\alpha, \beta x)}{\Gamma(\alpha)}\right), \quad x > 0. \tag{22.185}$$

La función inversa de distribución de X no tiene forma cerrada.
La función generadora de momentos de X es

$$\phi_X(t) = \left(1 - \frac{t}{\beta}\right)^{-\alpha}, \quad t < \beta. \tag{22.186}$$

La función característica de X es

$$\varphi_X(t) = \left(1 - \frac{it}{\beta}\right)^{-\alpha}, \quad t \in \mathbb{R}. \tag{22.187}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\alpha}{\beta}. \tag{22.188}$$

La varianza de X es

$$\text{Var}(X) = \frac{\alpha}{\beta^2}. \tag{22.189}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2}{\sqrt{\alpha}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3 + \frac{6}{\alpha}. \tag{22.190}$$

La demostracion queda al lector.

22.2.5. Distribución beta

Definición 22.2.5 Distribución Beta. La notación $X \sim \text{Beta}(\beta, \gamma)$ indica que la variable aleatoria X tiene distribución Beta con parámetros de forma positivos $\beta > 0$ y $\gamma > 0$. Esta distribución se utiliza para modelar proporciones, tasas de éxito, y como distribución a priori en inferencia bayesiana.

Teorema 22.2.5 Propiedades de la distribución Beta/. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\Gamma(\beta+\gamma)}{\Gamma(\beta)\Gamma(\gamma)} x^{\beta-1}(1-x)^{\gamma-1}, \quad 0 < x < 1. \tag{22.191}$$

La función de distribución acumulada de X es

$$F_X(x) = I_x(\beta, \gamma) = \frac{B_x(\beta, \gamma)}{B(\beta, \gamma)}, \quad 0 < x < 1, \tag{22.192}$$

donde $B_x(\beta, \gamma) = \int_0^x t^{\beta-1}(1-t)^{\gamma-1}dt$ es la función beta incompleta y $B(\beta, \gamma) = \frac{\Gamma(\beta)\Gamma(\gamma)}{\Gamma(\beta+\gamma)}$ es la función beta completa.
La función de supervivencia de X es

$$S_X(x) = 1 - I_x(\beta, \gamma), \quad 0 < x < 1. \tag{22.193}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\Gamma(\beta+\gamma)}{\Gamma(\beta)\Gamma(\gamma)} \cdot \frac{x^{\beta-1}(1-x)^{\gamma-1}}{1 - I_x(\beta, \gamma)}, \quad 0 < x < 1. \tag{22.194}$$

La mediana de X es el valor $m \in (0, 1)$ tal que $I_m(\beta, \gamma) = 0{,}5$.
La esperanza de X es

$$\mathbb{E}[X] = \frac{\beta}{\beta+\gamma}. \tag{22.195}$$

La varianza de X es

$$\text{Var}(X) = \frac{\beta\gamma}{(\beta+\gamma)^2(\beta+\gamma+1)}. \tag{22.196}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2(\gamma-\beta)\sqrt{1+\beta+\gamma}}{\sqrt{\beta\gamma(\beta+\gamma+2)}} \tag{22.197}$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3(\beta^2\gamma + \beta\gamma^2 - 2\beta\gamma + 2\beta^2 + 2\gamma^2)(1+\beta+\gamma)}{\beta\gamma(\beta+\gamma+2)(\beta+\gamma+3)}. \tag{22.198}$$

La demostracion queda al lector.

22.2.6. Distribución chi-cuadrado

Definición 22.2.6 Distribución Chi-cuadrado. La notación $X \sim \chi^2(n)$ indica que la variable aleatoria X tiene distribución chi-cuadrado con $n > 0$ grados de libertad. Esta distribución surge como la suma de los cuadrados de n variables normales estándar independientes, y se utiliza ampliamente en pruebas de hipótesis, análisis de varianza y teoría de confiabilidad.

Teorema 22.2.6 Propiedades de la distribución Chi-cuadrado. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{x^{n/2-1}e^{-x/2}}{2^{n/2}\Gamma(n/2)}, \quad x > 0. \tag{22.199}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\Gamma(n/2, x/2)}{\Gamma(n/2)}, \quad x > 0, \tag{22.200}$$

donde $\Gamma(s, x)$ es la función gamma incompleta superior.
La función de supervivencia de X es

$$S_X(x) = 1 - \frac{\Gamma(n/2, x/2)}{\Gamma(n/2)}, \quad x > 0. \tag{22.201}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)}, \quad x > 0. \tag{22.202}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x), \quad x > 0. \tag{22.203}$$

La moda de X es

$$\text{Moda}(X) = \text{máx}\{n-2, 0\}. \tag{22.204}$$

La función generadora de momentos de X es

$$\phi_X(t) = (1-2t)^{-n/2}, \quad t < \frac{1}{2}. \tag{22.205}$$

La función característica de X es

$$\varphi_X(t) = (1-2it)^{-n/2}, \quad t \in \mathbb{R}. \tag{22.206}$$

La esperanza de X es

$$\mathbb{E}[X] = n. \tag{22.207}$$

La varianza de X es

$$\text{Var}(X) = 2n. \tag{22.208}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \sqrt{\frac{8}{n}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3 + \frac{12}{n}. \tag{22.209}$$

La demostracion queda al lector.

22.2.7. Distribución t de student

Definición 22.2.7 Distribución t de Student. La notación $X \sim t(n)$ indica que la variable aleatoria X tiene distribución t de Student con $n > 0$ grados de libertad. Esta distribución surge en pruebas de hipótesis sobre medias, especialmente cuando la varianza poblacional es desconocida y el tamaño de muestra es pequeño.

Teorema 22.2.7 Propiedades de la distribución t de Student. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\,\Gamma\left(\frac{n}{2}\right)}\left(1+\frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad x \in \mathbb{R}. \tag{22.210}$$

La función de distribución acumulada de X es

$$F_X(x) = \int_{-\infty}^{x} \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\,\Gamma\left(\frac{n}{2}\right)}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}} dt. \tag{22.211}$$

La función de supervivencia de X es

$$S_X(x) = \int_{x}^{\infty} \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\,\Gamma\left(\frac{n}{2}\right)}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}} dt. \tag{22.212}$$

La mediana de X es

$$\text{Mediana}(X) = 0. \tag{22.213}$$

La esperanza de X es

$$\mathbb{E}[X] = 0, \quad \text{si } n > 1. \tag{22.214}$$

La varianza de X es

$$\text{Var}(X) = \frac{n}{n-2}, \quad \text{si } n > 2. \tag{22.215}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \text{si } n > 3, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3(n-2)}{n-4}, \quad \text{si } n > 4. \tag{22.216}$$

La demostracion queda al lector.

22.2.8. Distribución F de Fisher-Snedecor

Definición 22.2.8 Distribución F de Fisher–Snedecor. La notación $X \sim F(n_1, n_2)$ indica que la variable aleatoria X tiene distribución F con $n_1 > 0$ y $n_2 > 0$ grados de libertad en el numerador y denominador, respectivamente. Esta distribución se utiliza para comparar varianzas entre dos poblaciones normales o tasas entre poblaciones exponenciales.

Teorema 22.2.8 Propiedades de la distribución F. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)}\left(\frac{n_1}{n_2}\right)^{n_1/2} \cdot \frac{x^{n_1/2-1}}{\left(1+\frac{n_1}{n_2}x\right)^{(n_1+n_2)/2}}, \quad x > 0. \tag{22.217}$$

La moda de X es

$$\text{Moda}(X) = \frac{n_2(n_1-2)}{n_1(n_2+2)}, \quad \text{si } n_1 > 2. \tag{22.218}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n_2}{n_2-2}, \quad \text{si } n_2 > 2. \tag{22.219}$$

La varianza de X es

$$\text{Var}(X) = \frac{2n_2^2(n_1+n_2-2)}{n_1(n_2-2)^2(n_2-4)}, \quad \text{si } n_2 > 4. \tag{22.220}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{(2n_1+n_2-2)\sqrt{8(n_2-4)}}{(n_2-6)\sqrt{n_1(n_1+n_2-2)}}, \quad \text{si } n_2 > 6, \tag{22.221}$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3(n_2-4)}{n_2-8} \cdot \frac{10n_2^2+1n_2-20n_1+8n_1n_2+n_1n_2^2+16-16n_2+4n_2^2}{n_1(n_1+n_2-2)(n_2-6)(n_2-8)}, \quad \text{si } n_2 > 8. \tag{22.222}$$

La demostracion queda al lector.

22.2.9. Distribución Log-normal

Definición 22.2.9 Distribución Log-normal. La notación $X \sim \text{Lognormal}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución log-normal con parámetros $\alpha > 0$ y $\beta > 0$. Esta distribución modela variables positivas cuyo logaritmo sigue una distribución normal, y es útil para representar tiempos de vida, ingresos, tamaños biológicos y productos de variables independientes.

Teorema 22.2.9 Propiedades de la distribución Log-normal. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{x\beta\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{\ln(x/\alpha)}{\beta}\right)^2\right), \quad x > 0. \tag{22.223}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2} + \frac{1}{2}\operatorname{erf}\left(\frac{\ln(x)-\alpha}{\sqrt{2}\beta}\right), \quad x > 0. \tag{22.224}$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{2} - \frac{1}{2}\operatorname{erf}\left(\frac{\ln(x)-\alpha}{\sqrt{2}\beta}\right), \quad x > 0. \tag{22.225}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{x\beta\sqrt{2\pi}} \exp\left(-\frac{(\ln(x)-\alpha)^2}{2\beta^2}\right) \left[\frac{1}{1-\operatorname{erf}\left(\frac{\ln(x)-\alpha}{\sqrt{2}\beta}\right)}\right], \quad x > 0. \tag{22.226}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(2) + i\pi - \ln\left(1 - \operatorname{erf}\left(\frac{\ln(x)-\alpha}{\sqrt{2}\beta}\right)\right), \quad x > 0. \tag{22.227}$$

La mediana de X es

$$\text{Mediana}(X) = \alpha. \tag{22.228}$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha e^{\beta^2/2}. \tag{22.229}$$

La varianza de X es

$$\text{Var}(X) = \alpha^2 e^{\beta^2}(e^{\beta^2} - 1). \tag{22.230}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = (e^{\beta^2}+2)\sqrt{e^{\beta^2}-1}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = e^{4\beta^2}+2e^{3\beta^2}+3e^{2\beta^2}-3. \tag{22.231}$$

La demostracion queda al lector.

22.2.10. Distribución Weibull

Definición 22.2.10 Distribución Weibull. La notación $X \sim \text{Weibull}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución Weibull con parámetro de escala $\alpha > 0$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza ampliamente en análisis de supervivencia y confiabilidad para modelar tiempos de vida, fallas y servicios.

Teorema 22.2.10 Propiedades de la distribución Weibull. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\beta}{\alpha}x^{\beta-1}e^{-(x/\alpha)^\beta}, \quad x > 0. \tag{22.232}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-(x/\alpha)^\beta}, \quad x > 0. \tag{22.233}$$

La función de supervivencia de X es

$$S_X(x) = e^{-(x/\alpha)^\beta}, \quad x > 0. \tag{22.234}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\beta}{\alpha}x^{\beta-1}, \quad x > 0. \tag{22.235}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \left(\frac{x}{\alpha}\right)^\beta, \quad x > 0. \tag{22.236}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \alpha\left[-\ln(1-u)\right]^{1/\beta}, \quad 0 < u < 1. \tag{22.237}$$

La mediana de X es

$$\text{Mediana}(X) = \alpha(\ln 2)^{1/\beta}. \tag{22.238}$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha\,\Gamma\left(1+\frac{1}{\beta}\right). \tag{22.239}$$

La varianza de X es

$$\text{Var}(X) = \alpha^2\left[\Gamma\left(1+\frac{2}{\beta}\right) - \left(\Gamma\left(1+\frac{1}{\beta}\right)\right)^2\right]. \tag{22.240}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{\Gamma\left(1+\frac{3}{\beta}\right) - 3\Gamma\left(1+\frac{1}{\beta}\right)\Gamma\left(1+\frac{2}{\beta}\right) + 2\left(\Gamma\left(1+\frac{1}{\beta}\right)\right)^3}{\left[\Gamma\left(1+\frac{2}{\beta}\right) - \left(\Gamma\left(1+\frac{1}{\beta}\right)\right)^2\right]^{3/2}}, \tag{22.241}$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{\Gamma\left(1+\frac{4}{\beta}\right) - 4\Gamma\left(1+\frac{1}{\beta}\right)\Gamma\left(1+\frac{3}{\beta}\right) + 6\left(\Gamma\left(1+\frac{1}{\beta}\right)\right)^2\Gamma\left(1+\frac{2}{\beta}\right) - 3\left(\Gamma\left(1+\frac{1}{\beta}\right)\right)^4}{\left[\Gamma\left(1+\frac{2}{\beta}\right) - \left(\Gamma\left(1+\frac{1}{\beta}\right)\right)^2\right]^2}. \tag{22.242}$$

La demostracion queda al lector.

22.2.11. Distribución Laplace Asimétrica

Definición 22.2.11 Distribución Laplace Asimétrica. La notación $X \sim \text{Laplace}(\alpha_1, \alpha_2)$ indica que la variable aleatoria X tiene distribución Laplace con parámetros de escala positivos $\alpha_1 > 0$ (lado izquierdo) y $\alpha_2 > 0$ (lado derecho). Esta distribución es una alternativa a la normal, con colas más pesadas, útil en modelado de errores, tiempos de servicio y fenómenos con discontinuidad en la pendiente.

Teorema 22.2.11 Propiedades de la distribución Laplace Asimétrica. La función de densidad de probabilidad de X es

$$f_X(x) = \begin{cases} \frac{1}{\alpha_1+\alpha_2}\exp\left(\frac{x}{\alpha_1}\right), & x < 0 \\ \frac{1}{\alpha_1+\alpha_2}\exp\left(-\frac{x}{\alpha_2}\right), & x \geq 0 \end{cases} \tag{22.243}$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} \frac{\alpha_1}{\alpha_1+\alpha_2}\exp\left(\frac{x}{\alpha_1}\right), & x < 0 \\ 1 - \frac{\alpha_2}{\alpha_1+\alpha_2}\exp\left(-\frac{x}{\alpha_2}\right), & x \geq 0 \end{cases} \tag{22.244}$$

La función de supervivencia de X es

$$S_X(x) = \begin{cases} 1 - \frac{\alpha_1}{\alpha_1+\alpha_2}\exp\left(\frac{x}{\alpha_1}\right), & x < 0 \\ \frac{\alpha_2}{\alpha_1+\alpha_2}\exp\left(-\frac{x}{\alpha_2}\right), & x \geq 0 \end{cases} \tag{22.245}$$

La función de riesgo de X es

$$h_X(x) = \begin{cases} \frac{\exp(x/\alpha_1)}{\alpha_1+\alpha_2+\alpha_1\exp(x/\alpha_1)}, & x < 0 \\ \frac{1}{\alpha_2}, & x \geq 0 \end{cases} \tag{22.246}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \begin{cases} -\alpha_1\left[-\ln(\alpha_1+\alpha_2) + \ln(\alpha_1) - \ln(u)\right], & 0 < u < \frac{\alpha_1}{\alpha_1+\alpha_2} \\ -\alpha_2\left[\ln(\alpha_1+\alpha_2) - \ln(\alpha_2) + \ln(1-u)\right], & \frac{\alpha_1}{\alpha_1+\alpha_2} \leq u < 1 \end{cases} \tag{22.247}$$

La mediana de X es

$$\text{Mediana}(X) = 0. \tag{22.248}$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha_2 - \alpha_1. \tag{22.249}$$

La varianza de X es

$$\mathrm{Var}(X) = \frac{\alpha_1^2 + \alpha_2^2}{1}. \tag{22.250}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{-2(\alpha_1^3 - \alpha_2^3)}{(\alpha_1^2 + \alpha_2^2)^{3/2}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3(3\alpha_1^4 + 2\alpha_1^2\alpha_2^2 + 3\alpha_2^4)}{(\alpha_1^2 + \alpha_2^2)^2}. \tag{22.251}$$

La demostracion queda al lector.

22.2.12. Distribución logística generalizada

Definición 22.2.12 Distribución Logística Generalizada. La notación $X \sim \text{Logistic}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución logística con parámetro de escala $\lambda > 0$ y parámetro de forma $\kappa > 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento sigmoidal, colas pesadas y saturación, como tiempos de adopción, respuestas biológicas y modelos de supervivencia.

Teorema 22.2.12 Propiedades de la distribución Logística Generalizada. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\lambda\kappa^\kappa e^{\kappa x}}{(1 + (\lambda e^x)^\kappa)^2}, \quad x \in \mathbb{R}. \tag{22.252}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\lambda\kappa e^{\kappa x}}{1 + \lambda\kappa e^x}, \quad x \in \mathbb{R}. \tag{22.253}$$

La función de supervivencia de X es

$$S_X(x) = \frac{1 + \lambda\kappa e^x - \lambda\kappa e^{\kappa x}}{1 + \lambda\kappa e^x}, \quad x \in \mathbb{R}. \tag{22.254}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\kappa e^{\kappa x}(\lambda\kappa + \lambda^2\kappa e^x)}{(1 + (\lambda e^x)^\kappa)^2 (1 + \lambda\kappa e^x - \lambda\kappa e^{\kappa x})}, \quad x \in \mathbb{R}. \tag{22.255}$$

La función inversa de distribución de X es

$$F^{-1}(u) = -\frac{1}{\kappa}\ln\left(\frac{u}{1-u}\right) - \ln\lambda, \quad 0 < u < 1. \tag{22.256}$$

La función generadora de momentos de X es

$$\phi_X(t) = \int_{-\infty}^{\infty} \frac{\lambda\kappa^\kappa e^{x(t+\kappa)}}{(1 + (\lambda e^x)^\kappa)^2} dx. \tag{22.257}$$

La función característica de X es

$$\varphi_X(t) = \int_{-\infty}^{\infty} \frac{\lambda\kappa^\kappa e^{x(it+\kappa)}}{\left(1+(\lambda e^x)^\kappa\right)^2} dx. \tag{22.258}$$

La esperanza de X es

$$\mathbb{E}[X] = -\ln\lambda. \tag{22.259}$$

La varianza de X es

$$\mathrm{Var}(X) = \frac{\pi^2}{3\kappa^2}. \tag{22.260}$$

El sesgo y la curtosis poblacional de X son expresiones más complejas y no se presentan en forma cerrada.

La demostracion queda al lector.

22.2.13. Distribución Rayleigh

Definición 22.2.13 Distribución Rayleigh. La notación $X \sim \text{Rayleigh}(\alpha)$ indica que la variable aleatoria X tiene distribución Rayleigh con parámetro de escala $\alpha > 0$. Esta distribución se utiliza para modelar tiempos de vida, tiempos de servicio y magnitudes de vectores bidimensionales con componentes normales independientes.

Teorema 22.2.13 Propiedades de la distribución Rayleigh. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{2x}{\alpha} e^{-x^2/\alpha}, \quad x > 0. \tag{22.261}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-x^2/\alpha}, \quad x > 0. \tag{22.262}$$

La función de supervivencia de X es

$$S_X(x) = e^{-x^2/\alpha}, \quad x > 0. \tag{22.263}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{2x}{\alpha}, \quad x > 0. \tag{22.264}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \frac{x^2}{\alpha}, \quad x > 0. \tag{22.265}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \sqrt{-\alpha \ln(1-u)}, \quad 0 < u < 1. \tag{22.266}$$

La mediana de X es

$$\text{Mediana}(X) = \sqrt{\alpha \ln 2}. \tag{22.267}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\alpha\pi^{1/2}}{2}. \tag{22.268}$$

La varianza de X es

$$\text{Var}(X) = \alpha\left(1 - \frac{\pi}{4}\right). \tag{22.269}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2\sqrt{\pi(\pi-3)}}{(4-\pi)^{3/2}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{6\pi(4-\pi)-16}{(4-\pi)^2}. \tag{22.270}$$

La demostracion queda al lector.

22.2.14. Distribución gaussiana inversa

Definición 22.2.14 Distribución Gaussiana Inversa. La notación $X \sim \text{InverseGaussian}(\lambda, \mu)$ indica que la variable aleatoria X tiene distribución gaussiana inversa con parámetros $\lambda > 0$ (precisión) y $\mu > 0$ (media). Esta distribución se utiliza para modelar tiempos de vida, trayectorias de partículas en movimiento browniano y procesos de decisión estocásticos.

Teorema 22.2.14 Propiedades de la distribución Gaussiana Inversa. La función de densidad de probabilidad de X es

$$f_X(x) = \sqrt{\frac{\lambda}{2\pi x^3}} \exp\left(-\frac{\lambda(x-\mu)^2}{2x\mu^2}\right), \quad x > 0. \tag{22.271}$$

La función generadora de momentos de X es

$$\phi_X(t) = \exp\left(\frac{\lambda}{\mu}\left[1 - \sqrt{1 - \frac{2\mu^2 t}{\lambda}}\right]\right), \quad t < \frac{\lambda}{2\mu^2}. \tag{22.272}$$

La función característica de X es

$$\varphi_X(t) = \exp\left(\frac{\lambda}{\mu}\left[1 - \sqrt{1 - \frac{2\mu^2 it}{\lambda}}\right]\right), \quad t \in \mathbb{R}. \tag{22.273}$$

La esperanza de X es

$$\mathbb{E}[X] = \mu. \tag{22.274}$$

La varianza de X es

$$\text{Var}(X) = \frac{\mu^3}{\lambda}. \tag{22.275}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 3\sqrt{\frac{\mu}{\lambda}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3 + \frac{15\mu}{\lambda}. \tag{22.276}$$

La demostracion queda al lector.

22.2.15. Distribución Pareto

Definición 22.2.15 Distribución Pareto. La notación $X \sim \text{Pareto}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución Pareto con parámetros $\lambda > 0$ (mínimo) y $\kappa > 0$ (forma). Esta distribución se utiliza para modelar ingresos, duraciones mínimas, tiempos de vida con garantía, y fenómenos con comportamiento de cola pesada.

Teorema 22.2.15 Propiedades de la distribución Pareto. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\kappa \lambda^\kappa}{x^{\kappa+1}}, \quad x > \lambda. \tag{22.277}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \left(\frac{\lambda}{x}\right)^\kappa, \quad x > \lambda. \tag{22.278}$$

La función de supervivencia de X es

$$S_X(x) = \left(\frac{\lambda}{x}\right)^\kappa, \quad x > \lambda. \tag{22.279}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\kappa}{x}, \quad x > \lambda. \tag{22.280}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = -\kappa(\ln \lambda - \ln x), \quad x > \lambda. \tag{22.281}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \lambda(1-u)^{-1/\kappa}, \quad 0 < u < 1. \tag{22.282}$$

La mediana de X es

$$\text{Mediana}(X) = \lambda \cdot 2^{1/\kappa}. \tag{22.283}$$

La función generadora de momentos de X es

$$\phi_X(t) = \kappa(-\lambda t)^\kappa \Gamma(-\kappa, -\lambda t), \quad t < 0. \tag{22.284}$$

La función característica de X es

$$\varphi_X(t) = \kappa(-\lambda i t)^\kappa \Gamma(-\kappa, -\lambda i t), \quad t \in \mathbb{R}. \tag{22.285}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\kappa \lambda}{\kappa - 1}, \quad \text{si } \kappa > 1. \tag{22.286}$$

La varianza de X es

$$\text{Var}(X) = \frac{\kappa \lambda^2}{(\kappa-1)^2(\kappa-2)}, \quad \text{si } \kappa > 2. \tag{22.287}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2\kappa+1}{\kappa-3}, \quad \text{si } \kappa > 3, \tag{22.288}$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3(\kappa-2)(3\kappa^3+\kappa+2)}{\kappa(\kappa-3)(\kappa-4)}, \quad \text{si } \kappa > 4. \tag{22.289}$$

La demostracion queda al lector.

22.2.16. Distribución Cauchy

Definición 22.2.16 Distribución Cauchy. La notación $X \sim \text{Cauchy}(a, \alpha)$ indica que la variable aleatoria X tiene distribución Cauchy con parámetro de localización $a \in \mathbb{R}$ y parámetro de escala $\alpha > 0$. Esta distribución es conocida por sus colas pesadas y por el hecho de que no tiene momentos definidos.

Teorema 22.2.16 Propiedades de la distribución Cauchy. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\alpha\pi\left[1+\left(\frac{x-a}{\alpha}\right)^2\right]}, \quad x \in \mathbb{R}. \tag{22.290}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2\pi}\left[\pi - 2\arctan\left(\frac{a-x}{\alpha}\right)\right], \quad x \in \mathbb{R}. \tag{22.291}$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{2\pi}\left[\pi + 2\arctan\left(\frac{a-x}{\alpha}\right)\right], \quad x \in \mathbb{R}. \tag{22.292}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{2\alpha(\alpha^2 - 2xa + a^2 + x^2 - 1)}{\pi + 2\arctan\left(\frac{a-x}{\alpha}\right)}, \quad x \in \mathbb{R}. \tag{22.293}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(2\pi) - \ln\left[\pi + 2\arctan\left(\frac{a-x}{\alpha}\right)\right], \quad x \in \mathbb{R}. \tag{22.294}$$

La función inversa de distribución de X es

$$F^{-1}(u) = a - \alpha\cot(\pi u), \quad 0 < u < 1. \tag{22.295}$$

La mediana de X es

$$\text{Mediana}(X) = a. \tag{22.296}$$

La demostracion queda al lector.

22.2.17. Distribución Gompertz

Definición 22.2.17 Distribución Gompertz. La notación $X \sim \text{Gompertz}(\delta, \kappa)$ indica que la variable aleatoria X tiene distribución Gompertz con parámetros de forma $\delta > 0$ y $\kappa > 1$. Esta distribución se utiliza en análisis actuarial para modelar tiempos de vida de adultos y en estudios de supervivencia con tasas de riesgo crecientes.

Teorema 22.2.17 Propiedades de la distribución Gompertz. La función de densidad de probabilidad de X es

$$f_X(x) = \delta\kappa^x \exp\left(-\frac{\delta(\kappa^x - 1)}{\ln \kappa}\right), \quad x > 0. \tag{22.297}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \exp\left(-\frac{\delta(\kappa^x - 1)}{\ln \kappa}\right), \quad x > 0. \tag{22.298}$$

La función de supervivencia de X es

$$S_X(x) = \exp\left(-\frac{\delta(\kappa^x - 1)}{\ln \kappa}\right), \quad x > 0. \tag{22.299}$$

La función de riesgo de X es

$$h_X(x) = \delta\kappa^x, \quad x > 0. \tag{22.300}$$

La función de riesgo acumulada de X es

$$H_X(x) = \frac{\delta(\kappa^x - 1)}{\ln \kappa}, \quad x > 0. \tag{22.301}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{-\ln \delta - \ln(\delta - \ln(1-u)\ln \kappa)}{\ln \kappa}, \quad 0 < u < 1. \tag{22.302}$$

La mediana de X es

$$\text{Mediana}(X) = \frac{-\ln \delta - \ln(\delta + \ln 2 \cdot \ln \kappa)}{\ln \kappa}. \tag{22.303}$$

La demostracion queda al lector.

22.2.18. Distribución valor extremo

Definición 22.2.18 Distribución de Valor Extremo. La notación $X \sim \text{ExtremeValue}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución de valor extremo con parámetro de escala $\alpha > 0$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza para modelar fenómenos extremos como niveles de inundación, magnitudes sísmicas y máximos de muestras.

Teorema 22.2.18 Propiedades de la distribución de Valor Extremo. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\beta}{\alpha} e^{\beta x - e^{\beta x}/\alpha}, \quad x \in \mathbb{R}. \tag{22.304}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \exp\left(-\frac{e^{\beta x}}{\alpha}\right), \quad x \in \mathbb{R}. \tag{22.305}$$

La función de supervivencia de X es

$$S_X(x) = \exp\left(-\frac{e^{\beta x}}{\alpha}\right), \quad x \in \mathbb{R}. \tag{22.306}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \beta e^{\beta x}, \quad x \in \mathbb{R}. \tag{22.307}$$

La función de riesgo acumulada de X es

$$H_X(x) = \frac{e^{\beta x}}{\alpha}, \quad x \in \mathbb{R}. \tag{22.308}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{\ln\left(-\alpha \ln(1-u)\right)}{\beta}, \quad 0 < u < 1. \tag{22.309}$$

La demostracion queda al lector.

22.2.19. Distribución gamma generalizada

Definición 22.2.19 Distribución Gamma Generalizada. La notación $X \sim \text{GammaGeneralizada}(\alpha, \beta, \gamma)$ indica que la variable aleatoria X tiene distribución gamma generalizada con parámetros positivos: escala $\alpha > 0$, forma $\beta > 0$, y potencia $\gamma > 0$. Esta distribución incluye como casos especiales la gamma, la Weibull y la exponencial, y se utiliza para modelar tiempos de vida, servicios y fenómenos con flexibilidad en la forma de la cola.

Teorema 22.2.19 Propiedades de la distribución Gamma Generalizada. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\gamma x^{\gamma\beta - 1} \exp\left(-\left(\frac{x}{\alpha}\right)^{\gamma}\right)}{\alpha^{\gamma\beta}\Gamma(\beta)}, \quad x > 0. \tag{22.310}$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha \cdot \frac{\Gamma\left(\beta + \frac{1}{\gamma}\right)}{\Gamma(\beta)}. \tag{22.311}$$

La varianza de X es

$$\text{Var}(X) = \alpha^2 \left[\frac{\Gamma\left(\beta + \frac{2}{\gamma}\right)}{\Gamma(\beta)} - \left(\frac{\Gamma\left(\beta + \frac{1}{\gamma}\right)}{\Gamma(\beta)}\right)^2\right]. \tag{22.312}$$

22.2.20. Distribución Pareto generalizada

Definición 22.2.20 Distribución Pareto Generalizada. La notación $X \sim \text{ParetoGeneralizada}(\delta, \kappa, \gamma)$ indica que la variable aleatoria X tiene distribución Pareto generalizada con parámetros de forma $\delta > 0$, $\gamma \geq 0$, y $\kappa \geq -\delta\gamma$. Esta distribución se utiliza para modelar fenómenos con colas pesadas y tasas de riesgo variables, como ingresos extremos, tiempos de espera prolongados y duraciones de eventos raros.

Teorema 22.2.20 Propiedades de la distribución Pareto Generalizada. La función de den-

sidad de probabilidad de X es

$$f_X(x) = \frac{\gamma + \frac{\kappa}{x+\delta}}{(1+\frac{x}{\delta})^{\kappa}} e^{-\gamma x}, \quad x > 0. \tag{22.313}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-\gamma x}\left(1+\frac{x}{\delta}\right)^{-\kappa}, \quad x > 0. \tag{22.314}$$

La función de supervivencia de X es

$$S_X(x) = e^{-\gamma x}\left(1+\frac{x}{\delta}\right)^{-\kappa}, \quad x > 0. \tag{22.315}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \gamma + \frac{\kappa}{x+\delta}, \quad x > 0. \tag{22.316}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \gamma x + \kappa \ln\left(1+\frac{x}{\delta}\right), \quad x > 0. \tag{22.317}$$

La demostracion queda al lector.

22.2.21. Distribución t no central

Definición 22.2.21 Distribución t No Central. La notación $X \sim \mathrm{t}_{\text{no central}}(n, \delta)$ indica que la variable aleatoria X tiene distribución t no central con $n \in \mathbb{N}^+$ grados de libertad y parámetro de no centralidad $\delta \in \mathbb{R}$. Esta distribución surge en pruebas de hipótesis cuando la media poblacional no es cero, y se utiliza en inferencia estadística bajo desviaciones sistemáticas.

Teorema 22.2.21 Propiedades de la distribución t No Central. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\sqrt{n}^{n/2} e^{-\delta^2/2}}{\pi\Gamma(n/2)(n+x^2)^{(n+1)/2}} \cdot \sum_{i=0}^{\infty} \frac{\Gamma\left(\frac{n+i+1}{2}\right)}{i!}\left(\frac{x\delta\sqrt{2}}{\sqrt{n+x^2}}\right)^i, \quad x \in \mathbb{R}. \tag{22.318}$$

La esperanza de X es

$$\mathbb{E}[X] = \delta \cdot \sqrt{\frac{n}{2}} \cdot \frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)}, \quad \text{si } n > 1. \tag{22.319}$$

La varianza de X es

$$\mathrm{Var}(X) = \left[\frac{n(1+\delta^2)}{n-2} - \delta^2 \cdot \frac{n}{2}\left(\frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)}\right)^2\right], \quad \text{si } n > 2. \tag{22.320}$$

22.2.22. Distribución F no central

Definición 22.2.22 Distribución F No Central. La notación $X \sim \mathrm{F}_{\text{no central}}(n_1, n_2, \delta)$ indica que la variable aleatoria X tiene distribución F no central con parámetros $n_1, n_2 \in \mathbb{N}^+$ y parámetro de no centralidad $\delta > 0$. Esta distribución surge en pruebas de hipótesis sobre varianzas cuando hay un efecto sistemático presente, como en análisis de varianza con medias desplazadas.

Teorema 22.2.22 Propiedades de la distribución F No Central. La función de densidad de probabilidad de X es

$$f_X(x) = \sum_{i=0}^{\infty} \frac{e^{-\delta/2}\left(\frac{\delta}{2}\right)^i}{i!} \cdot \frac{\Gamma\left(\frac{2i+n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_2}{2}\right)\Gamma\left(\frac{2i+n_1}{2}\right)} \cdot \left(\frac{n_1}{n_2}\right)^{(2i+n_1)/2} \cdot \frac{x^{(2i+n_1-2)/2}}{\left(1+\frac{n_1}{n_2}x\right)^{(2i+n_1+n_2)/2}}, \quad x > 0. \tag{22.321}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n_2(n_1+\delta)}{n_1(n_2-2)}, \quad \text{si } n_2 > 2. \tag{22.322}$$

La varianza de X es

$$\mathrm{Var}(X) = \frac{2\left[(n_1+\delta)^2 + (n_1+2\delta)(n_2-2)\right]}{n_1^2(n_2-2)^2(n_2-4)}, \quad \text{si } n_2 > 4. \tag{22.323}$$

La demostracion queda al lector.

22.2.23. Distribución chicuadrado no central

Definición 22.2.23 Distribución Chi-cuadrado No Central. La notación $X \sim \chi^2_{\text{no central}}(\delta, n)$ indica que la variable aleatoria X tiene distribución chi-cuadrado no central con $n \in \mathbb{N}^+$ grados de libertad y parámetro de no centralidad $\delta \geq 0$. Esta distribución surge cuando se suman los cuadrados de variables normales independientes con medias distintas de cero, y se utiliza en pruebas de hipótesis bajo desviaciones sistemáticas.

Teorema 22.2.23 Propiedades de la distribución Chi-cuadrado No Central. La función de densidad de probabilidad de X es

$$f_X(x) = e^{-(\delta+x)/2} \sum_{k=0}^{\infty} \frac{(\delta/2)^k}{k!} \cdot \frac{x^{(n+2k)/2-1}}{2^{(n+2k)/2}\Gamma\left(\frac{n+2k}{2}\right)}, \quad x > 0. \tag{22.324}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{e^{\delta t/(1-2t)}}{(1-2t)^{n/2}}, \quad t < \frac{1}{2}. \tag{22.325}$$

La función característica de X es

$$\varphi_X(t) = \frac{e^{\delta it/(1-2it)}}{(1-2it)^{n/2}}, \quad t \in \mathbb{R}. \tag{22.326}$$

La esperanza de X es

$$\mathbb{E}[X] = n + \delta. \tag{22.327}$$

La varianza de X es

$$\text{Var}(X) = 2(n + 2\delta). \tag{22.328}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2^{3/2}(n+3\delta)}{(n+2\delta)^{3/2}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3 + \frac{12(n+4\delta)}{(n+2\delta)^2}. \tag{22.329}$$

La demostracion queda al lector.

22.2.24. Distribución beta no central

Definición 22.2.24 Distribución Beta No Central. La notación $X \sim \text{Beta}_{\text{no central}}(\beta, \gamma, \delta)$ indica que la variable aleatoria X tiene distribución beta no central con parámetros positivos $\beta > 0$, $\gamma > 0$, y parámetro de no centralidad $\delta > 0$. Esta distribución surge en pruebas de hipótesis relacionadas con proporciones bajo desviaciones sistemáticas, y en modelos de razón de varianzas con efectos fijos.

Teorema 22.2.24 Propiedades de la distribución Beta No Central. La función de densidad de probabilidad de X es

$$f_X(x) = e^{-\delta/2} \sum_{i=0}^{\infty} \frac{1}{i!} \left(\frac{\delta}{2}\right)^i \cdot \frac{\Gamma(i+\beta+\gamma)}{\Gamma(\gamma)\Gamma(i+\beta)} \cdot x^{i+\beta-1}(1-x)^{\gamma-1}, \quad 0 < x < 1. \tag{22.330}$$

La demostracion queda al lector.

22.2.25. Distribución F doble no central

Definición 22.2.25 Distribución F Doble No Central. La notación $X \sim F''(n_1, n_2, \delta, \gamma)$ indica que la variable aleatoria X tiene distribución F doblemente no central con parámetros $n_1, n_2 \in \mathbb{N}^+$ y parámetros de no centralidad $\delta > 0$, $\gamma > 0$. Esta distribución surge en pruebas de hipótesis sobre varianzas cuando tanto el numerador como el denominador están desplazados por efectos sistemáticos.

Teorema 22.2.25 Propiedades de la distribución F Doble No Central. La función de densidad de probabilidad de X es

$$f_X(x) = \sum_{j=0}^{\infty} \sum_{k=0}^{\infty} \frac{e^{-\delta/2}(\delta/2)^j}{j!} \cdot \frac{e^{-\gamma/2}(\gamma/2)^k}{k!} \cdot \frac{n_1^{n_1/2+j} \cdot n_2^{n_2/2+k}}{B\left(\frac{n_1}{2}+j, \frac{n_2}{2}+k\right)} \cdot \frac{x^{n_1/2+j-1}}{(n_2+n_1 x)^{(n_1+n_2-j-k)/2}}, \quad x > 0. \tag{22.331}$$

La demostracion queda al lector.

22.2.26. Distribución log-gamma

Definición 22.2.26 Distribución Log-gamma. La notación $X \sim \text{LogGamma}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución log-gamma con parámetro de escala $\alpha > 0$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento exponencial modulado por una transformación logarítmica, como tiempos de espera, procesos de servicio y datos

con asimetría extrema.

Teorema 22.2.26 Propiedades de la distribución Log-gamma. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{e^{\beta x} \cdot e^{-e^x/\alpha}}{\alpha^\beta \Gamma(\beta)}, \quad x \in \mathbb{R}. \tag{22.332}$$

La demostracion queda al lector.

22.2.27. Distribución log-logística

Definición 22.2.27 Distribución Log-logística. La notación $X \sim \text{LogLogística}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución log-logística con parámetro de escala $\lambda > 0$ y parámetro de forma $\kappa > 0$. Esta distribución se utiliza para modelar tiempos de vida, duraciones de servicio y fenómenos con tasas de riesgo no monótonas.

Teorema 22.2.27 Propiedades de la distribución Log-logística. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\lambda\kappa(\lambda x)^{\kappa-1}}{(1+(\lambda x)^\kappa)^2}, \quad x > 0. \tag{22.333}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{(\lambda x)^\kappa}{1+(\lambda x)^\kappa}, \quad x > 0. \tag{22.334}$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{1+(\lambda x)^\kappa}, \quad x > 0. \tag{22.335}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\lambda\kappa(\lambda x)^{\kappa-1}}{1+(\lambda x)^\kappa}, \quad x > 0. \tag{22.336}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln\left[1+(\lambda x)^\kappa\right], \quad x > 0. \tag{22.337}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{1}{\lambda}\left(\frac{u}{1-u}\right)^{1/\kappa}, \quad 0 < u < 1. \tag{22.338}$$

La mediana de X es

$$\text{Mediana}(X) = \frac{1}{\lambda}. \tag{22.339}$$

La función generadora de momentos de X es

$$\phi_X(t) = \int_0^\infty e^{tx} \cdot \frac{\lambda\kappa(\lambda x)^{\kappa-1}}{(1+(\lambda x)^\kappa)^2}\, dx, \quad t > 0. \tag{22.340}$$

La función característica de X es

$$\varphi_X(t) = \int_0^\infty e^{itx} \cdot \frac{\lambda\kappa(\lambda x)^{\kappa-1}}{(1+(\lambda x)^\kappa)^2}\, dx, \quad t \in \mathbb{R}. \tag{22.341}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\pi}{\lambda\kappa \sin\left(\frac{\pi}{\kappa}\right)}, \quad \text{si } \kappa > 1. \tag{22.342}$$

La varianza de X es

$$\mathrm{Var}(X) = \left[\frac{\pi^2}{\kappa^2}\left(\frac{1-\cos\left(\frac{\pi}{\kappa}\right)}{2} + \frac{\sin\left(\frac{\pi(\kappa+2)}{\kappa}\right)}{\sin\left(\frac{\pi(\kappa+2)}{\kappa}\right)\cos\left(\frac{\pi}{\kappa}\right)} - 1\right)\right] \cdot \frac{1}{(\lambda\kappa)^2}, \quad \text{si } \kappa > 2. \tag{22.343}$$

La demostracion queda al lector.

22.2.28. Distribución hiperexponencial

Definición 22.2.28 Distribución Hiperexponencial. La notación $X \sim \text{Hiperexponencial}(\alpha, p)$ indica que la variable aleatoria X tiene distribución hiperexponencial con parámetros de escala $\alpha = (\alpha_1, \alpha_2, \ldots, \alpha_n)$ y probabilidades $p = (p_1, p_2, \ldots, p_n)$, donde $\alpha_i > 0$, $p_i > 0$, y $\sum_{i=1}^n p_i = 1$. Esta distribución modela tiempos de espera con múltiples fases exponenciales y es útil en teoría de colas y confiabilidad.

Teorema 22.2.28 Propiedades de la distribución Hiperexponencial. La función de densidad de probabilidad de X es

$$f_X(x) = \sum_{i=1}^n \frac{p_i}{\alpha_i} e^{-x/\alpha_i}, \quad x > 0. \tag{22.344}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \sum_{i=1}^n p_i e^{-x/\alpha_i}, \quad x > 0. \tag{22.345}$$

La función de supervivencia de X es

$$S_X(x) = \sum_{i=1}^n p_i e^{-x/\alpha_i}, \quad x > 0. \tag{22.346}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\sum_{i=1}^n \frac{p_i}{\alpha_i} e^{-x/\alpha_i}}{\sum_{i=1}^n p_i e^{-x/\alpha_i}}, \quad x > 0. \tag{22.347}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = -\ln\left(\sum_{i=1}^n p_i e^{-x/\alpha_i}\right), \quad x > 0. \tag{22.348}$$

La función generadora de momentos de X es

$$M_X(t) = \sum_{i=1}^{n} \frac{p_i}{1-\alpha_i t}, \quad |t| < \frac{1}{\max_j \alpha_j}. \tag{22.349}$$

La esperanza de X es

$$\mathbb{E}[X] = \sum_{i=1}^{n} p_i \alpha_i. \tag{22.350}$$

La demostracion queda al lector.

22.2.29. Distribución hipoexponencial

Definición 22.2.29 Distribución Hipoexponencial. La notación $X \sim \text{Hipoexponencial}(\alpha)$ indica que la variable aleatoria X tiene distribución hipoexponencial con vector de parámetros positivos $\alpha = (\alpha_1, \alpha_2, \ldots, \alpha_n)$, donde $\alpha_i \neq \alpha_j$ para $i \neq j$. Esta distribución representa la suma de n variables exponenciales independientes con tasas distintas, y se utiliza en teoría de colas y análisis de confiabilidad.

Teorema 22.2.29 Propiedades de la distribución Hipoexponencial. La función de densidad de probabilidad de X es

$$f_X(x) = \sum_{i=1}^{n} \left(\frac{1}{\alpha_i} e^{-x/\alpha_i} \prod_{\substack{j=1 \\ j \neq i}}^{n} \frac{\alpha_i}{\alpha_i - \alpha_j} \right), \quad x > 0. \tag{22.351}$$

Para el caso $n = 2$, la función de distribución acumulada es

$$F_X(x) = 1 - \frac{1}{\alpha_1 - \alpha_2} \left(\alpha_2 e^{-x/\alpha_2} - \alpha_1 e^{-x/\alpha_1} \right), \quad x > 0. \tag{22.352}$$

La esperanza de X es

$$\mathbb{E}[X] = \sum_{i=1}^{n} \alpha_i. \tag{22.353}$$

La varianza de X es

$$\text{Var}(X) = \sum_{i=1}^{n} \alpha_i^2. \tag{22.354}$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma} \right)^3 \right] = \frac{2 \sum_{i=1}^{n} \alpha_i^3}{\left(\sum_{i=1}^{n} \alpha_i^2 \right)^{3/2}}. \tag{22.355}$$

La demostracion queda al lector.

22.2.30. Distribución Makeham

Definición 22.2.30 Distribución Makeham. La notación $X \sim \text{Makeham}(\delta, \kappa, \gamma)$ indica que la variable aleatoria X tiene distribución Makeham con parámetros $\delta > 0$, $\kappa > 1$, y $\gamma > 0$. Esta distribución se utiliza principalmente en estudios actuariales para modelar la duración de la vida

adulta, incorporando tanto un componente exponencial como uno de crecimiento Gompertziano.

Teorema 22.2.30 Propiedades de la distribución Makeham. La función de densidad de probabilidad de X es

$$f_X(x) = (\gamma + \delta\kappa x) \cdot e^{-\gamma x - \delta(\kappa x - 1)/\ln(\kappa)}, \quad x > 0. \tag{22.356}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-(\gamma x \ln(\kappa) + \delta\kappa x - \delta)/\ln(\kappa)}, \quad x > 0. \tag{22.357}$$

La función de supervivencia de X es

$$S_X(x) = e^{-(\gamma x \ln(\kappa) + \delta\kappa x - \delta)/\ln(\kappa)}, \quad x > 0. \tag{22.358}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \gamma + \delta\kappa x, \quad x > 0. \tag{22.359}$$

La función de riesgo acumulada de X es

$$H_X(x) = \frac{\gamma x \ln(\kappa) + \delta\kappa x - \delta}{\ln(\kappa)}, \quad x > 0. \tag{22.360}$$

La demostracion queda al lector.

22.2.31. Distribución lomax

Definición 22.2.31 Distribución Lomax. La notación $X \sim \text{Lomax}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución Lomax con parámetro de escala $\lambda > 0$ y parámetro de forma $\kappa > 0$. Esta distribución es una versión desplazada de la Pareto tipo II y se utiliza para modelar datos con colas pesadas, como ingresos, tiempos de espera y fallas en sistemas.

Teorema 22.2.31 Propiedades de la distribución Lomax. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\lambda\kappa}{(1 + \lambda x)^{\kappa+1}}, \quad x > 0. \tag{22.361}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - (1 + \lambda x)^{-\kappa}, \quad x > 0. \tag{22.362}$$

La función de supervivencia de X es

$$S_X(x) = (1 + \lambda x)^{-\kappa}, \quad x > 0. \tag{22.363}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\lambda\kappa}{1 + \lambda x}, \quad x > 0. \tag{22.364}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \kappa \ln(1+\lambda x), \quad x > 0. \tag{22.365}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{(1-u)^{-1/\kappa} - 1}{\lambda}, \quad 0 < u < 1. \tag{22.366}$$

La mediana de X es

$$\text{Mediana}(X) = \frac{2^{1/\kappa} - 1}{\lambda}. \tag{22.367}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\lambda}{\kappa - 1}, \quad \text{si } \kappa > 1. \tag{22.368}$$

La demostracion queda al lector.

22.2.32. Distribución Muth

Definición 22.2.32 Distribución Muth. La notación $X \sim \text{Muth}(\kappa)$ indica que la variable aleatoria X tiene distribución Muth con parámetro $\kappa \in (0, 1]$. Esta distribución se utiliza para modelar tiempos de vida con tasas de riesgo crecientes y se ha aplicado en estudios actuariales y confiabilidad.

Teorema 22.2.32 Propiedades de la distribución Muth. La función de densidad de probabilidad de X es

$$f_X(x) = (e^{\kappa x} - \kappa) \cdot \exp\left[-\left(\frac{e^{\kappa x}}{\kappa} + \frac{\kappa x + 1}{\kappa}\right)\right], \quad x > 0. \tag{22.369}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \exp\left[-\left(\frac{e^{\kappa x}}{\kappa} + \frac{\kappa x + 1}{\kappa}\right)\right], \quad x > 0. \tag{22.370}$$

La función de supervivencia de X es

$$S_X(x) = \exp\left[-\left(\frac{e^{\kappa x}}{\kappa} + \frac{\kappa x + 1}{\kappa}\right)\right], \quad x > 0. \tag{22.371}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = e^{\kappa x} - \kappa, \quad x > 0. \tag{22.372}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \frac{e^{\kappa x}}{\kappa} - \frac{\kappa x + 1}{\kappa}, \quad x > 0. \tag{22.373}$$

La esperanza de X es

$$\mathbb{E}[X] = 1. \tag{22.374}$$

La demostracion queda al lector.

22.2.33. Distribución Von Mises

Definición 22.2.33 Distribución Von Mises. La notación $X \sim$ Von Mises(κ, μ) indica que la variable aleatoria X tiene distribución von Mises con parámetro de forma $\kappa \in \mathbb{R}$ y parámetro de localización $\mu \in (0, 2\pi)$. Esta distribución se utiliza para modelar datos angulares o direccionales, como orientaciones, fases o direcciones en estadística circular.

Teorema 22.2.33 Propiedades de la distribución Von Mises. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{e^{\kappa \cos(x-\mu)}}{2\pi I_0(\kappa)}, \quad 0 < x < 2\pi, \tag{22.375}$$

donde $I_0(\kappa)$ es la función de Bessel modificada de primera especie y orden cero:

$$I_0(\kappa) = \sum_{i=0}^{\infty} \frac{(\kappa^2)^i}{(2^{2i})(i!)^2}. \tag{22.376}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2\pi I_0(\kappa)} \int_0^x e^{\kappa \cos(t-\mu)}\, dt, \quad 0 < x < 2\pi. \tag{22.377}$$

La esperanza de X es

$$\mathbb{E}[X] = \mu. \tag{22.378}$$

La demostracion queda al lector.

22.2.34. Distribución arcsin

Definición 22.2.34 Distribución Arcsin. La notación $X \sim$ Arcsin indica que la variable aleatoria X tiene distribución arcsin sobre el intervalo $(0, 1)$. Esta distribución se utiliza en estadística bayesiana, teoría de probabilidad y análisis de proporciones, especialmente cuando se requiere una forma simétrica con densidad infinita en los extremos.

Teorema 22.2.34 Propiedades de la distribución Arcsin. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\pi\sqrt{x(1-x)}}, \quad 0 < x < 1. \tag{22.379}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\pi + 2\arcsin(2x-1)}{2\pi}, \quad 0 < x < 1. \tag{22.380}$$

La función de supervivencia de X es

$$S_X(x) = \frac{\pi - 2\arcsin(2x-1)}{2\pi}, \quad 0 < x < 1. \tag{22.381}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{\sqrt{x(1-x)} \cdot (\pi - 2\arcsin(2x-1))}, \quad 0 < x < 1. \tag{22.382}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{1}{2} - \frac{1}{2}\cos(\pi u), \quad 0 < u < 1. \tag{22.383}$$

La esperanza de X es

$$\mathbb{E}[X] = 1. \tag{22.384}$$

La varianza de X es

$$\operatorname{Var}(X) = 1. \tag{22.385}$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3}{2}. \tag{22.386}$$

La demostracion queda al lector.

22.2.35. Distribución arctangent

Definición 22.2.35 Distribución Arctangent. La notación $X \sim \text{Arctangent}(\lambda, \varphi)$ indica que la variable aleatoria X tiene distribución arctangent con parámetro de localización $\lambda > 0$ y parámetro de fase $\varphi \in \mathbb{R}$. Esta distribución se utiliza para modelar fenómenos con colas pesadas y simetría desplazada, como en análisis de señales y modelos de dispersión.

Teorema 22.2.35 Propiedades de la distribución Arctangent. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\lambda}{\left(\arctan(\lambda\varphi) + \frac{1}{2}\pi\right)\left(1 + \lambda^2(x-\varphi)^2\right)}, \quad x \geq 0. \tag{22.387}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{2\arctan(\lambda\varphi) - \arctan(-\lambda x + \lambda\varphi)}{2\arctan(\lambda\varphi) + \pi}, \quad x \geq 0. \tag{22.388}$$

La función de supervivencia de X es

$$S_X(x) = \frac{\pi + 2\arctan(-\lambda x + \lambda\varphi)}{2\arctan(\lambda\varphi) + \pi}, \quad x \geq 0. \tag{22.389}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{2\lambda}{(1 + \lambda^2x^2 - 2\lambda^2\varphi x + \lambda^2\varphi^2)(\pi + 2\arctan(-\lambda x + \lambda\varphi))}, \quad x \geq 0. \tag{22.390}$$

La función de riesgo acumulada de X es

$$H_X(x) = \ln\left(2\arctan(\lambda\varphi) + \pi\right) - \ln\left(\pi + 2\arctan(\lambda(-x+\varphi))\right), \quad x \geq 0. \tag{22.391}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{\lambda\varphi + \tan\left(-\arctan(\lambda\varphi) + u\arctan(\lambda\varphi) + \frac{1}{2}u\pi\right)}{\lambda}, \quad 0 < u < 1. \tag{22.392}$$

La demostracion queda al lector.

22.2.36. Distribución power

Definición 22.2.36 Distribución Power. La notación $X \sim \text{Power}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución power con parámetro de escala $\alpha > 0$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento polinomial dentro de un intervalo finito, como tiempos de falla, proporciones y datos normalizados.

Teorema 22.2.36 Propiedades de la distribución Power. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\beta x^{\beta-1}}{\alpha^\beta}, \quad 0 < x < \alpha. \tag{22.393}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{x^\beta}{\alpha^\beta}, \quad 0 < x < \alpha. \tag{22.394}$$

La función de supervivencia de X es

$$S_X(x) = 1 - \frac{x^\beta}{\alpha^\beta}, \quad 0 < x < \alpha. \tag{22.395}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\beta x^{\beta-1}\alpha^{-\beta}}{1 - x^\beta \alpha^{-\beta}}, \quad 0 < x < \alpha. \tag{22.396}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln\left(1 - \left(\frac{x}{\alpha}\right)^\beta\right), \quad 0 < x < \alpha. \tag{22.397}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \alpha u^{1/\beta}, \quad 0 < u < 1. \tag{22.398}$$

La mediana de X es

$$\text{Mediana}(X) = \alpha\left(\frac{1}{2}\right)^{1/\beta}. \tag{22.399}$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{-\beta\Gamma(\beta, -t\alpha) - \Gamma(1+\beta)}{(-t)^\beta \alpha^\beta}, \quad -\infty < t < \infty. \tag{22.400}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\alpha\beta}{1+\beta}. \tag{22.401}$$

La varianza de X es

$$\text{Var}(X) = \frac{\alpha^2\beta}{(2+\beta)(1+\beta)^2}. \tag{22.402}$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2(\beta-1)}{(2+\beta)(3+\beta)}\sqrt{\frac{(3+\beta)}{\beta}}. \tag{22.403}$$

La curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3(2-\beta+3\beta^2)}{\beta(2+\beta)(3+\beta)(4+\beta)}. \tag{22.404}$$

22.2.37. Distribución power estándar

Definición 22.2.37 Distribución Power estándar. La notación $X \sim \text{Power}(1,\beta)$ indica que la variable aleatoria X tiene distribución power estándar con parámetro de forma $\beta > 0$. Esta distribución se define sobre el intervalo $(0,1)$ y se utiliza para modelar proporciones, tiempos normalizados y fenómenos con crecimiento polinomial.

Teorema 22.2.37 Propiedades de la distribución Power estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \beta x^{\beta-1}, \quad 0 < x < 1. \tag{22.405}$$

La función de distribución acumulada de X es

$$F_X(x) = x^\beta, \quad 0 < x < 1. \tag{22.406}$$

La función de supervivencia de X es

$$S_X(x) = 1 - x^\beta, \quad 0 < x < 1. \tag{22.407}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\beta x^{\beta-1}}{1-x^\beta}, \quad 0 < x < 1. \tag{22.408}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln(1-x^\beta), \quad 0 < x < 1. \tag{22.409}$$

La función inversa de distribución de X es

$$F^{-1}(u) = u^{1/\beta}, \quad 0 < u < 1. \tag{22.410}$$

La mediana de X es

$$\text{Mediana}(X) = \left(\frac{1}{2}\right)^{1/\beta}. \tag{22.411}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\beta}{\beta+1}. \tag{22.412}$$

La varianza de X es

$$\text{Var}(X) = \frac{\beta}{(\beta+2)(\beta+1)^2}. \tag{22.413}$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2(1-\beta)}{(\beta+2)(\beta+3)}\sqrt{\beta}. \tag{22.414}$$

La curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3(3\beta^2-\beta+2)}{\beta(\beta+2)(\beta+3)(\beta+4)}. \tag{22.415}$$

La demostracion queda al lector.

22.2.38. Distribución normal estándar

Definición 22.2.38 Distribución Normal Estándar. La notación $X \sim \mathcal{N}(0,1)$ indica que la variable aleatoria X tiene distribución normal estándar con media $\mu = 0$ y varianza $\sigma^2 = 1$. Esta distribución surge al estandarizar una variable normal cualquiera mediante la transformación $Z = \frac{X-\mu}{\sigma}$, y se utiliza ampliamente en estadística, probabilidad y teoría de errores.

Teorema 22.2.38 Propiedades de la distribución Normal Estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{e^{-x^2/2}}{\sqrt{2\pi}}, \quad x \in \mathbb{R}. \tag{22.416}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2} + \frac{1}{2}\operatorname{erf}\left(\frac{x}{\sqrt{2}}\right), \quad x \in \mathbb{R}, \tag{22.417}$$

donde la función error es $\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}}\int_0^x e^{-t^2}dt.$. La función de supervivencia de X es

$$S_X(x) = \frac{1}{2} - \frac{1}{2}\operatorname{erf}\left(\frac{x}{\sqrt{2}}\right), \quad x \in \mathbb{R}. \tag{22.418}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{-e^{-x^2/2}}{\sqrt{2\pi}\left(-1+\operatorname{erf}\left(\frac{x}{\sqrt{2}}\right)\right)}, \quad x \in \mathbb{R}. \tag{22.419}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(2) - \ln\left(1-\operatorname{erf}\left(\frac{x}{\sqrt{2}}\right)\right), \quad x \in \mathbb{R}. \tag{22.420}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \sqrt{2}\cdot\operatorname{erf}^{-1}(2u-1), \quad 0 < u < 1. \tag{22.421}$$

La mediana y la moda de X son

$$\text{Mediana}(X) = \text{Moda}(X) = 0. \tag{22.422}$$

La función característica de X es

$$\varphi_X(t) = e^{-t^2/2}, \quad t \in \mathbb{R}. \tag{22.423}$$

La esperanza de X es

$$\mathbb{E}[X] = 0. \tag{22.424}$$

La varianza de X es

$$\mathrm{Var}(X) = 1. \tag{22.425}$$

El sesgo y la curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0. \tag{22.426}$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3. \tag{22.427}$$

22.2.39. Distribución Cauchy estándar

Definición 22.2.39 Distribución Cauchy estándar. La notación $X \sim \mathrm{Cauchy}(1, 0)$ indica que la variable aleatoria X tiene distribución Cauchy estándar con parámetro de escala $\gamma = 1$ y parámetro de localización $x_0 = 0$. Esta distribución se caracteriza por colas pesadas y se utiliza en estadística robusta, física y teoría de señales.

Teorema 22.2.39 Propiedades de la distribución Cauchy estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}. \tag{22.428}$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\pi + 2\arctan(x)}{2\pi}, \quad x \in \mathbb{R}. \tag{22.429}$$

La función de supervivencia de X es

$$S_X(x) = \frac{\pi - 2\arctan(x)}{2\pi}, \quad x \in \mathbb{R}. \tag{22.430}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{2}{(1+x^2)(\pi - 2\arctan(x))}, \quad x \in \mathbb{R}. \tag{22.431}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(2) + \ln(\pi) - \ln(\pi - 2\arctan(x)), \quad x \in \mathbb{R}. \tag{22.432}$$

La función inversa de distribución de X es

$$F^{-1}(u) = -\cot(\pi u), \quad 0 < u < 1. \tag{22.433}$$

La mediana de X es

$$\mathrm{Mediana}(X) = 0. \tag{22.434}$$

La función característica de X es

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = e^{-|t|}, \quad t \in \mathbb{R}. \tag{22.435}$$

La demostracion queda al lector.

22.2.40. Distribución triangular estándar

Definición 22.2.40 Distribución Triangular estándar. La notación $X \sim \text{Triangular}(-1, 0, 1)$ indica que la variable aleatoria X tiene distribución triangular estándar con mínimo $a = -1$, modo $c = 0$, y máximo $b = 1$. Esta distribución se utiliza para modelar incertidumbre cuando se conocen los valores extremos y el valor más probable.

Teorema 22.2.40 Propiedades de la distribución Triangular estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \begin{cases} x+1, & -1 < x < 0, \\ 1-x, & 0 \leq x < 1, \end{cases} \tag{22.436}$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} \frac{1}{2}(2x^2 + x + 1), & -1 < x < 0, \\ \frac{1}{2}(2x^2 - x + 1), & 0 \leq x < 1, \end{cases} \tag{22.437}$$

La función de riesgo de X es

$$h_X(x) = \begin{cases} \frac{x+1}{\frac{1}{2}(2x^2-x+1)}, & -1 < x < 0, \\ \frac{1-x}{\frac{1}{2}(2x^2+x+1)}, & 0 \leq x < 1, \end{cases} \tag{22.438}$$

La función de riesgo acumulada de X es

$$H_X(x) = \begin{cases} -\ln\left(\frac{1}{2}(2x^2 - x + 1)\right), & -1 < x < 0, \\ -\ln\left(\frac{1}{2}(2x^2 + x + 1)\right), & 0 \leq x < 1, \end{cases} \tag{22.439}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \begin{cases} -1 + \sqrt{2u}, & 0 < u < \frac{1}{2}, \\ 1 - \sqrt{2(1-u)}, & \frac{1}{2} \leq u < 1, \end{cases} \tag{22.440}$$

La mediana, la moda y la esperanza de X son

$$\text{Mediana}(X) = \text{Moda}(X) = \mathbb{E}[X] = 0. \tag{22.441}$$

La función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{tX}] = \frac{e^{-t} - 2 + e^t}{t^2}, \quad t \in \mathbb{R}. \tag{22.442}$$

La varianza de X es

$$\text{Var}(X) = \frac{1}{6}. \tag{22.443}$$

El sesgo y la curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0. \tag{22.444}$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{12}{5}. \tag{22.445}$$

La demostracion queda al lector.

22.2.41. Distribución Wald estándar

Definición 22.2.41 Distribución Wald estándar. La notación $X \sim \text{standardWald}(\lambda)$ indica que la variable aleatoria X tiene distribución Wald estándar con parámetro $\lambda > 0$. Esta distribución también es conocida como distribución inversa gaussiana estándar y se utiliza en modelos de tiempo de decisión, procesos estocásticos y análisis de supervivencia.

Teorema 22.2.41 Propiedades de la distribución Wald estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \sqrt{\frac{\lambda}{2\pi x^3}} \cdot \exp\left(-\frac{\lambda(x-1)^2}{2x}\right), \quad x > 0. \tag{22.446}$$

La función de distribución acumulada de X es

$$F_X(x) = \int_0^x \sqrt{\frac{\lambda}{2\pi t^3}} \cdot \exp\left(-\frac{\lambda(t-1)^2}{2t}\right) dt, \quad x > 0. \tag{22.447}$$

La función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{tX}] = \exp\left(\lambda\left(1 - \sqrt{1 - \frac{2t}{\lambda}}\right)\right), \quad t < \frac{\lambda}{2}. \tag{22.448}$$

La función característica de X es

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \exp\left(\lambda\left(1 - \sqrt{1 - \frac{2it}{\lambda}}\right)\right), \quad t \in \mathbb{R}. \tag{22.449}$$

La esperanza de X es

$$\mathbb{E}[X] = 1. \tag{22.450}$$

La varianza de X es

$$\text{Var}(X) = \frac{1}{\lambda}. \tag{22.451}$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{3}{\sqrt{\lambda}}. \tag{22.452}$$

La curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3 + \frac{15}{\lambda}. \tag{22.453}$$

La demostracion queda al lector.

22.2.42. Distribución minimax

Definición 22.2.42 Distribución Minimax. La notación $X \sim \text{Minimax}(\beta, \gamma)$ indica que la variable aleatoria X tiene distribución minimax con parámetros de forma positivos $\beta > 0$ y $\gamma > 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento polinomial y decaimiento controlado en el intervalo unitario.

Teorema 22.2.42 Propiedades de la distribución Minimax. La función de densidad de probabilidad de X es

$$f_X(x) = \beta\gamma x^{\beta-1}(1-x^\beta)^{\gamma-1}, \quad 0 < x < 1. \tag{22.454}$$

La función de distribución acumulada de X es

$$F_X(x) = 1-(1-x^\beta)^\gamma, \quad 0 < x < 1. \tag{22.455}$$

La función de supervivencia de X es

$$S_X(x) = (1-x^\beta)^\gamma, \quad 0 < x < 1. \tag{22.456}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\beta\gamma x^{\beta-1}}{1-x^\beta}, \quad 0 < x < 1. \tag{22.457}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \left[1-(1-u)^{1/\gamma}\right]^{1/\beta}, \quad 0 < u < 1. \tag{22.458}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\Gamma(\gamma+1)\cdot\Gamma\left(\frac{\beta+1}{\beta}\right)}{\Gamma\left(\frac{\beta\gamma+\beta+1}{\beta}\right)}. \tag{22.459}$$

La demostracion queda al lector.

22.2.43. Distribución IDB

Definición 22.2.43 Distribución IDB. La notación $X \sim \text{IDB}(\delta, \kappa, \gamma)$ indica que la variable aleatoria X tiene distribución IDB con parámetros $\delta > 0$, $\kappa > 0$, y $\gamma \geq 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento polinomial y decaimiento exponencial, y aparece en contextos de confiabilidad y procesos estocásticos.

Teorema 22.2.43 Propiedades de la distribución IDB. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{((1+\kappa x)^{\delta x+\gamma})\cdot\exp\left(-\frac{1}{2\delta x^2}\right)}{(1+\kappa x)^{\gamma/\kappa+1}}, \quad x > 0. \tag{22.460}$$

La demostracion queda al lector.

22.2.44. Distribución error

Definición 22.2.44 Distribución Error. La notación $X \sim \text{Error}(a, b, c)$ indica que la variable aleatoria X tiene distribución error con parámetro de localización $a \in \mathbb{R}$, parámetro de escala $b > 0$, y parámetro de forma $c > 0$. Esta distribución generaliza la forma de la normal y la Laplace, y se utiliza para modelar errores de medición y fenómenos con simetría central.

Teorema 22.2.44 Propiedades de la distribución Error. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\exp\left(-\frac{1}{2}\left(\frac{|x-a|}{b}\right)^{2/c}\right)}{b \cdot 2^{c/2+1} \cdot \Gamma(c/2+1)}, \quad x \in \mathbb{R}. \tag{22.461}$$

La función de distribución acumulada de X es

$$F_X(x) = \int_{-\infty}^{x} \frac{\exp\left(-\frac{1}{2}\left(\frac{|t-a|}{b}\right)^{2/c}\right)}{b \cdot 2^{c/2+1} \cdot \Gamma(c/2+1)}\, dt, \quad x \in \mathbb{R}. \tag{22.462}$$

La mediana y la moda de X son

$$\text{Mediana}(X) = \text{Moda}(X) = a. \tag{22.463}$$

La esperanza de X es

$$\mathbb{E}[X] = a. \tag{22.464}$$

La varianza de X es

$$\text{Var}(X) = \frac{2cb^2\Gamma(3c/2)}{\Gamma(c/2)}. \tag{22.465}$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0. \tag{22.466}$$

La curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{\Gamma(5c/2)\cdot\Gamma(c/2)}{(\Gamma(3c/2))^2}. \tag{22.467}$$

La demostracion queda al lector.

22.2.45. Distribución exponential power

Definición 22.2.45 Distribución Exponential Power. La notación $X \sim \text{ExponentialPower}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución exponential power con parámetro de escala $\lambda > 0$ y parámetro de forma $\kappa > 0$. Esta distribución es notable por su capacidad de modelar funciones de riesgo con forma de bañera, lo que la hace útil en análisis de confiabilidad y supervivencia.

Teorema 22.2.45 Propiedades de la distribución Exponential Power. La función de densidad de probabilidad de X es

$$f_X(x) = e^{1-e^{\lambda x^\kappa}} \cdot e^{\lambda x^\kappa} \cdot \lambda\kappa x^{\kappa-1}, \quad x > 0. \tag{22.468}$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{1-e^{\lambda x^\kappa}}, \quad x > 0. \tag{22.469}$$

La función de supervivencia de X es

$$S_X(x) = e^{1-e^{\lambda x^\kappa}}, \quad x > 0. \tag{22.470}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = e^{\lambda x^\kappa} \cdot \lambda \kappa x^{\kappa-1}, \quad x > 0. \tag{22.471}$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = e^{\lambda x^\kappa} - 1, \quad x > 0. \tag{22.472}$$

La función inversa de distribución de X es

$$F^{-1}(u) = \left[\frac{1}{\lambda} \ln\left(1 - \ln(1-u)\right)\right]^{1/\kappa}, \quad 0 < u < 1. \tag{22.473}$$

La mediana de X es

$$\text{Mediana}(X) = \left[\lambda \cdot \ln\left(1 - \ln\left(\frac{1}{2}\right)\right)\right]^{-1/\kappa}. \tag{22.474}$$

La función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{tX}] = \int_0^\infty e^{tx} \cdot f_X(x)\, dx. \tag{22.475}$$

La función característica de X es

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \int_0^\infty e^{itx} \cdot f_X(x)\, dx. \tag{22.476}$$

Nota: La esperanza, varianza, sesgo y curtosis de X son matemáticamente intractables.

La demostracion queda al lector.

22.2.46. Distribución triangular

Definición 22.2.46 Distribución Triangular. La notación $X \sim \text{Triangular}(a, m, b)$ indica que la variable aleatoria X tiene distribución triangular con mínimo a, modo m, y máximo b, donde $a < m < b$. Esta distribución se utiliza como modelo aproximado cuando no hay datos disponibles, pero se conocen los valores extremos y el valor más probable.

Teorema 22.2.46 Propiedades de la distribución Triangular. La función de densidad de probabilidad de X es

$$f_X(x) = \begin{cases} \frac{2(x-a)}{(b-a)(m-a)}, & a < x < m, \\ \frac{2(b-x)}{(b-a)(b-m)}, & m \le x < b, \end{cases} \tag{22.477}$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} \frac{(x-a)^2}{(b-a)(m-a)}, & a < x < m, \\ 1 - \frac{(b-x)^2}{(b-a)(b-m)}, & m \le x < b, \end{cases} \tag{22.478}$$

La función de supervivencia de X es

$$S_X(x) = \begin{cases} 1 - \frac{(x-a)^2}{(b-a)(m-a)}, & a < x < m, \\ \frac{(b-x)^2}{(b-a)(b-m)}, & m \le x < b, \end{cases} \tag{22.479}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)}, \quad \text{con expresiones específicas según el intervalo.} \tag{22.480}$$

La función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{tX}] = \frac{-2(-me^{ta} + be^{ta} + be^{tm} + ae^{tm} - ae^{tb} + me^{tb})}{(a-m)(a-b)(m-b)t^2}, \quad t > 0. \tag{22.481}$$

La función característica de X es

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \frac{2(-me^{ita} + be^{ita} + be^{itm} + ae^{itm} - ae^{itb} + me^{itb})}{(a-m)(a-b)(m-b)t^2}, \quad t \in \mathbb{R}. \tag{22.482}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{a+m+b}{3}. \tag{22.483}$$

La varianza de X es

$$\operatorname{Var}(X) = \frac{a^2+m^2+b^2-ab-am-mb}{18}. \tag{22.484}$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{2(a+b-2m)(2a-b-m)(a-2b+m)}{5(a^2+b^2+m^2-ab-am-bm)^{3/2}}. \tag{22.485}$$

La curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{12}{5}. \tag{22.486}$$

La demostracion queda al lector.

22.2.47. Distribución TSP

Definición 22.2.47 Distribución TSP. La notación $X \sim \text{TSP}(a, b, m, n)$ indica que la variable aleatoria X tiene distribución TSP con parámetros $a < m < b$ y $n > 0$. Esta distribución generaliza la triangular mediante polinomios segmentados, y se utiliza en modelado cuando se desea controlar la forma de la densidad en cada tramo.

Teorema 22.2.47 Propiedades de la distribución TSP. La función de densidad de probabilidad de X es

$$f_X(x) = \begin{cases} \dfrac{n(x-a)^{n-1}}{(b-a)(m-a)^{n-1}}, & a < x < m, \\ \dfrac{n(b-x)^{n-1}}{(b-a)(b-m)^{n-1}}, & m \le x < b, \end{cases} \tag{22.487}$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} \dfrac{(x-a)^n}{(b-a)(m-a)^{n-1}}, & a < x < m, \\ 1 - \dfrac{(b-x)^n}{(b-a)(b-m)^{n-1}}, & m \le x < b, \end{cases} \tag{22.488}$$

La función de supervivencia de X es

$$S_X(x) = \begin{cases} 1 - \dfrac{(x-a)^n}{(b-a)(m-a)^{n-1}}, & a < x < m, \\ \dfrac{(b-x)^n}{(b-a)(b-m)^{n-1}}, & m \leq x < b, \end{cases} \tag{22.489}$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)}, \quad \text{con expresiones específicas según el intervalo.} \tag{22.490}$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{b - m + mn + a}{n+1}. \tag{22.491}$$

La varianza de X es

$$\operatorname{Var}(X) = \frac{-2mnb + 2m^2n + a^2n + b^2n - 2mna + 2bm - 2ba + 2am - 2m^2}{(n+1)^2(n+2)}. \tag{22.492}$$

La demostracion queda al lector.

22.3. Transformadas

Definición 22.3.1 Transformada de Laplace. Sea $f(t)$ definida para $t \geq 0$. La transformada de Laplace $\mathcal{L}\{f(t)\}(s)$ se define como

$$\mathcal{L}\{f(t)\}(s) = \int_0^\infty f(t)e^{-st} \mid s \in \mathbb{C}. \tag{22.493}$$

Definición 22.3.2 Transformada de Fourier. Sea $f(t)$ definida en $\mathbb{R}$. La transformada de Fourier $\mathcal{F}\{f(t)\}(\omega)$ se define como

$$\mathcal{F}\{f(t)\}(\omega) = \int_{-\infty}^\infty f(t)e^{-i\omega t}\,dt \mid \omega \in \mathbb{R}. \tag{22.494}$$

Definición 22.3.3 Transformada de Mellin. Sea $f(t)$ definida para $t > 0$. La transformada de Mellin $\mathcal{M}\{f(t)\}(s)$ se define como

$$\mathcal{M}\{f(t)\}(s) = \int_0^\infty t^{s-1}f(t)\,dt \mid s \in \mathbb{C}. \tag{22.495}$$

Definición 22.3.4 Transformada de Hilbert. Sea $f(t)$ definida en $\mathbb{R}$. La transformada de Hilbert $\mathcal{H}\{f(t)\}(t)$ se define como

$$\mathcal{H}\{f(t)\}(t) = \frac{1}{\pi}\,\mathrm{PV}\left\{\int_{-\infty}^\infty \frac{f(\tau)}{t-\tau}\,d\tau\right\} \mid t \in \mathbb{R}. \tag{22.496}$$

Definición 22.3.5 Transformada de Abel. Sea $f(r)$ definida para $r \geq 0$. La transformada de Abel $F(p)$ se define como

$$F(p) = \int_p^\infty \frac{f(r)}{\sqrt{r^2 - p^2}}\, dr \mid p \geq 0. \tag{22.497}$$

Definición 22.3.6 Transformada de Stieltjes. Sea $f(t)$ definida para $t \geq 0$. La transformada de Stieltjes $S\{f(t)\}(s)$ se define como

$$S\{f(t)\}(s) = \int_0^\infty \frac{f(t)}{t+s}\, dt \mid s \in \mathbb{C},\ \mathrm{Re}(s) > 0. \tag{22.498}$$

Definición 22.3.7 Transformada de Weierstrass (Gauss-Weierstrass). Sea $f(t)$ definida en $\mathbb{R}$. La transformada de Weierstrass $\mathcal{W}\{f(t)\}(\tau)$ se define como

$$\mathcal{W}\{f(t)\}(\tau) = \frac{1}{\sqrt{4\pi\tau}} \int_{-\infty}^\infty f(t)\, e^{-\frac{(t-\tau)^2}{4\tau}}\, dt \mid \tau > 0. \tag{22.499}$$

Lema 22.3.1 Linealidad. Sean $\mathcal{T}$ cualquiera de las transformadas definidas anteriormente, f, g funciones en el dominio correspondiente y $\alpha, \beta \in \mathbb{C}$. Entonces

$$\mathcal{T}\{\alpha f + \beta g\} = \alpha\, \mathcal{T}\{f\} + \beta\, \mathcal{T}\{g\}. \tag{22.500}$$

La demostración se deja al lector.

Teorema 22.3.1 Transformada de Laplace de la derivada. Sea f diferenciable con transformada de Laplace existente. Entonces

$$\mathcal{L}\{f^{(n)}(t)\}(s) = s^n \mathcal{L}\{f(t)\}(s) - s^{n-1} f(0) - s^{n-2} f'(0) - \cdots - f^{(n-1)}(0). \tag{22.501}$$

Demostración. Basta probar el caso $n = 1$ e iterar. Integrando por partes,

$$\mathcal{L}\{f'(t)\}(s) = \int_0^\infty f'(t) e^{-st}\, dt = [f(t)e^{-st}]_0^\infty + s \int_0^\infty f(t) e^{-st}\, dt = -f(0) + s\mathcal{L}\{f(t)\}(s),$$

donde el término de frontera se anula pues $f(t)e^{-st} \to 0$ cuando $t \to \infty$ para $\mathrm{Re}(s)$ suficientemente grande. Aplicando este resultado iteradamente se obtiene la fórmula general.

□

Lema 22.3.2 Transformada de Laplace de la integral. Sea f con transformada de Laplace existente. Entonces

$$\mathcal{L}\left\{\int_0^t f(\tau)\, d\tau\right\}(s) = \frac{\mathcal{L}\{f(t)\}(s)}{s}. \tag{22.502}$$

Demostración. Sea $g(t) = \int_0^t f(\tau)\, d\tau$, de modo que $g'(t) = f(t)$ y $g(0) = 0$. Aplicando el teorema anterior con $n = 1$,

$$\mathcal{L}\{f(t)\}(s) = \mathcal{L}\{g'(t)\}(s) = s\mathcal{L}\{g(t)\}(s) - g(0) = s\mathcal{L}\{g(t)\}(s),$$

de donde se despeja $\mathcal{L}\{g(t)\}(s) = \mathcal{L}\{f(t)\}(s)/s$.

□

Teorema 22.3.2 Convolución de Laplace. Sean f y g con transformadas de Laplace existentes. Entonces

$$\mathcal{L}\{(f*g)(t)\}(s) = \mathcal{L}\{f(t)\}(s)\cdot\mathcal{L}\{g(t)\}(s), \tag{22.503}$$

donde $(f*g)(t) = \int_0^t f(\tau)g(t-\tau)\,d\tau$.

Demostración. Escribimos el producto de transformadas e intercambiamos el orden de integración usando Fubini

$$\mathcal{L}\{f\}(s)\cdot\mathcal{L}\{g\}(s) = \int_0^\infty f(\tau)e^{-s\tau}\,d\tau\int_0^\infty g(\sigma)e^{-s\sigma}\,d\sigma = \int_0^\infty\int_0^\infty f(\tau)g(\sigma)e^{-s(\tau+\sigma)}\,d\tau\,d\sigma.$$

Haciendo el cambio de variable $t=\tau+\sigma$ y reordenando la región de integración a $0\le\tau\le t<\infty$,

$$= \int_0^\infty\left(\int_0^t f(\tau)g(t-\tau)\,d\tau\right)e^{-st}\,dt = \mathcal{L}\{(f*g)(t)\}(s).$$

□

Teorema 22.3.3 Valor inicial y final de Laplace. Sea f con transformada de Laplace $F(s)$. Entonces

$$\lim_{t\to0^+} f(t) = \lim_{s\to\infty} sF(s), \qquad \lim_{t\to\infty} f(t) = \lim_{s\to0^+} sF(s), \tag{22.504}$$

siempre que los límites existan.

Demostración. Del teorema de la derivada con $n=1$,

$$\mathcal{L}\{f'(t)\}(s) = sF(s) - f(0).$$

Tomando $s\to\infty$ y usando que $\mathcal{L}\{f'\}(s)\to0$, se obtiene $\lim_{s\to\infty} sF(s) = f(0) = \lim_{t\to0^+} f(t)$. Tomando $s\to0^+$ y usando que $\mathcal{L}\{f'\}(s)\to\int_0^\infty f'(t)\,dt = \lim_{t\to\infty} f(t) - f(0)$, se obtiene $\lim_{s\to0^+} sF(s) = \lim_{t\to\infty} f(t)$. □

Teorema 22.3.4 Inversión de Laplace (fórmula de Bromwich). Si $F(s) = \mathcal{L}\{f(t)\}(s)$, entonces

$$f(t) = \frac{1}{2\pi i}\int_{\gamma-i\infty}^{\gamma+i\infty} F(s)\,e^{st}\,ds, \tag{22.505}$$

donde γ es mayor que la parte real de todas las singularidades de F.

La demostración se deja al lector.

Teorema 22.3.5 Transformada de Fourier de la derivada. Sea f diferenciable con $f\in L^1(\mathbb{R})$. Entonces

$$\mathcal{F}\{f^{(n)}(t)\}(\omega) = (i\omega)^n\,\mathcal{F}\{f(t)\}(\omega). \tag{22.506}$$

Demostración. Para $n=1$, integrando por partes y usando que $f\in L^1(\mathbb{R})$ implica $f(t)\to0$ cuando $|t|\to\infty$,

$$\mathcal{F}\{f'(t)\}(\omega) = \int_{-\infty}^{\infty} f'(t)e^{-i\omega t}\,dt = \big[f(t)e^{-i\omega t}\big]_{-\infty}^{\infty} + i\omega\int_{-\infty}^{\infty} f(t)e^{-i\omega t}\,dt = i\omega\,\mathcal{F}\{f(t)\}(\omega).$$

Iterando se obtiene el caso general.

□

Teorema 22.3.6 Convolución de Fourier. Sean $f, g \in L^1(\mathbb{R})$. Entonces

$$\mathcal{F}\{(f*g)(t)\}(\omega) = \mathcal{F}\{f(t)\}(\omega)\cdot\mathcal{F}\{g(t)\}(\omega), \tag{22.507}$$

donde $(f*g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t-\tau)\,d\tau$.

Demostración. Por Fubini, ya que $f, g \in L^1(\mathbb{R})$,

$$\mathcal{F}\{f*g\}(\omega) = \int_{-\infty}^{\infty}\left(\int_{-\infty}^{\infty} f(\tau)g(t-\tau)\,d\tau\right)e^{-i\omega t}\,dt = \int_{-\infty}^{\infty} f(\tau)\left(\int_{-\infty}^{\infty} g(t-\tau)e^{-i\omega t}\,dt\right)d\tau = \int_{-\infty}^{\infty} f(\tau)e^{-i\omega\tau}\,\mathcal{F}\{g\}(\omega)\,d\tau = \mathcal{F}\{$$

donde en el penúltimo paso se usó el cambio de variable $u = t-\tau$.

□

Teorema 22.3.7 Identidad de Parseval-Plancherel. Sea $f \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$. Entonces

$$\int_{-\infty}^{\infty} |f(t)|^2\,dt = \frac{1}{2\pi}\int_{-\infty}^{\infty} |\mathcal{F}\{f\}(\omega)|^2\,d\omega. \tag{22.508}$$

La demostración se deja al lector.

Teorema 22.3.8 Inversión de Fourier. Si $f \in L^1(\mathbb{R})$ y $\mathcal{F}\{f\} \in L^1(\mathbb{R})$, entonces

$$f(t) = \frac{1}{2\pi}\int_{-\infty}^{\infty} \mathcal{F}\{f\}(\omega)\,e^{i\omega t}\,d\omega \quad \text{c.s.} \tag{22.509}$$

La demostración se deja al lector.

Teorema 22.3.9 Principio de incertidumbre de Heisenberg. Sea $f \in L^2(\mathbb{R})$ con $\|f\|_2 = 1$. Entonces

$$\left(\int_{\mathbb{R}} t^2|f(t)|^2\,dt\right)\left(\int_{\mathbb{R}} \omega^2|\mathcal{F}\{f\}(\omega)|^2\,d\omega\right) \geq \frac{1}{4}. \tag{22.510}$$

Demostración. Por la identidad de Parseval y la desigualdad de Cauchy-Schwarz,

$$\frac{1}{2} = \left|\int_{\mathbb{R}} f(t)\overline{f(t)}\,dt\right| = \left|\int_{\mathbb{R}} tf(t)\cdot\frac{\overline{f(t)}}{t}\,dt\right| \leq \|tf(t)\|_2\cdot\left\|\frac{f(t)}{t}\right\|_2.$$

Combinando con Parseval-Plancherel para relacionar $\|tf(t)\|_2$ con $\|\omega\mathcal{F}\{f\}(\omega)\|_2$ se obtiene la desigualdad.

□

Lema 22.3.3 Relación entre Mellin y Fourier. Sea f definida para $t > 0$. Entonces

$$\mathcal{M}\{f(t)\}(\sigma+i\tau) = \mathcal{F}\{f(e^u)e^{\sigma u}\}(\tau), \tag{22.511}$$

donde el cambio de variable es $t = e^u$.

Demostración. Haciendo $t = e^u$, $dt = e^u\,du$,

$$\mathcal{M}\{f\}(\sigma+i\tau) = \int_0^{\infty} t^{\sigma+i\tau-1}f(t)\,dt = \int_{-\infty}^{\infty} e^{(\sigma+i\tau-1)u}f(e^u)e^u\,du = \int_{-\infty}^{\infty} f(e^u)e^{\sigma u}e^{-i(-\tau)u}\,du = \mathcal{F}\{f(e^u)e^{\sigma u}\}(\tau).$$

□

Teorema 22.3.10 Inversión de Mellin. Si $\mathcal{M}\{f(t)\}(s) = \phi(s)$, entonces

$$f(t) = \frac{1}{2\pi i}\int_{c-i\infty}^{c+i\infty} \phi(s)\, t^{-s}\, ds, \tag{22.512}$$

para c en la franja de analiticidad de ϕ.

La demostración se deja al lector.

Teorema 22.3.11 Acotación de la transformada de Hilbert en L^p. Sea $1 < p < \infty$ y $f \in L^p(\mathbb{R})$. Entonces $\mathcal{H}\{f\} \in L^p(\mathbb{R})$ y existe una constante $C_p > 0$ tal que

$$\|\mathcal{H}\{f\}\|_p \leq C_p \|f\|_p. \tag{22.513}$$

La demostración se deja al lector.

Teorema 22.3.12 Involución de la transformada de Hilbert. Si $f \in L^p(\mathbb{R})$ con $1 < p < \infty$, entonces

$$\mathcal{H}\{\mathcal{H}\{f\}\}(t) = -f(t) \quad \text{c.s.} \tag{22.514}$$

Demostración. Usando la relación con Fourier del lema siguiente,

$$\mathcal{F}\{\mathcal{H}\{\mathcal{H}\{f\}\}\}(\omega) = (-i\,\mathrm{sgn}(\omega))^2 \mathcal{F}\{f\}(\omega) = -\mathcal{F}\{f\}(\omega),$$

y aplicando la inversión de Fourier se concluye $\mathcal{H}\{\mathcal{H}\{f\}\} = -f$ c.s.

□

Lema 22.3.4 Relación de Hilbert con Fourier. Sea $f \in L^2(\mathbb{R})$. Entonces

$$\mathcal{F}\{\mathcal{H}\{f\}\}(\omega) = -i\,\mathrm{sgn}(\omega)\,\mathcal{F}\{f\}(\omega). \tag{22.515}$$

La demostración se deja al lector.

Lema 22.3.5 Relación entre Laplace y Stieltjes. Sea f con transformada de Laplace F. Entonces

$$S\{f(t)\}(s) = \mathcal{L}\{F(t)\}(s) = \int_0^\infty F(t)\, e^{-st}\, dt. \tag{22.516}$$

La demostración se deja al lector.

Lema 22.3.6 Relación entre Abel y Fourier. Sea f radialmente simétrica e integrable. La transformada de Abel satisface

$$\mathcal{F}_{\mathbb{R}^2}\{f\}(\rho) = 2\pi\, \mathcal{F}_{\mathbb{R}}\{F(p)\}(\rho), \tag{22.517}$$

donde $F(p)$ es la transformada de Abel de f y $\mathcal{F}_{\mathbb{R}^2}$ denota la transformada de Fourier bidimensional en coordenadas polares.

La demostración se deja al lector.

Teorema 22.3.13 Transformada de Weierstrass como solución del calor. La función $u(x,t) = \mathcal{W}\{f\}(x,t)$ es solución de la ecuación del calor

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2}, \qquad u(x,0) = f(x). \tag{22.518}$$

Demostración. Diferenciando bajo el signo integral,

$$\frac{\partial u}{\partial t} = \frac{\partial}{\partial t}\left(\frac{1}{\sqrt{4\pi t}} \int_{-\infty}^{\infty} f(s) e^{-(x-s)^2/4t}\, ds \right),$$

y análogamente para $\partial^2 u/\partial x^2$. Un cálculo directo muestra que el núcleo gaussiano $K(x,t) = (4\pi t)^{-1/2} e^{-x^2/4t}$ satisface $\partial_t K = \partial_{xx} K$, luego por linealidad u también lo satisface. La condición inicial $u(x,0) = f(x)$ se sigue de que $K(\cdot,t) \to \delta_0$ cuando $t \to 0^+$.

□

Lema 22.3.7 Relación entre Weierstrass y Fourier. Sea $f \in L^2(\mathbb{R})$. Entonces

$$\mathcal{F}\{\mathcal{W}\{f\}(\,\cdot\,,\tau)\}(\omega) = e^{-\tau\omega^2}\, \mathcal{F}\{f\}(\omega). \tag{22.519}$$

Demostración. Como $\mathcal{W}\{f\}(x,\tau) = (K_\tau * f)(x)$ con $K_\tau(x) = (4\pi\tau)^{-1/2} e^{-x^2/4\tau}$, por el teorema de convolución de Fourier

$$\mathcal{F}\{\mathcal{W}\{f\}(\cdot,\tau)\}(\omega) = \mathcal{F}\{K_\tau\}(\omega) \cdot \mathcal{F}\{f\}(\omega).$$

Un cálculo directo da $\mathcal{F}\{K_\tau\}(\omega) = e^{-\tau\omega^2}$, de donde se obtiene el resultado.

□

A

Índice de definiciones y teoremas

1.1.1 Proposición El principio básico de conteo . . . 3
1.2.1 Proposición Conteo de permutaciones . . . 4
1.2.1 Teorema Teorema del coeficiente multinomial . . . 4
1.2.2 Proposición Permutaciones sin repetición . . . 4
1.2.3 Proposición Permutaciones con repetición . . . 5
1.3.1 Teorema Teorema de las estrellas y barras . . . 5
1.3.1 Proposición Principio del producto . . . 5
1.3.2 Teorema Soluciones de una ecuación lineal . . . 5
1.3.2 Proposición Principio multiplicativo para selecciones independientes . . . 6
1.3.3 Proposición selección no consecutiva. . . . 6
1.4.1 Teorema Teorema multinomial . . . 6

2.1.1 Definición Anillos conjuntivos . . . 8
2.1.1 Proposición Intersección y unión de anillos . . . 8
2.1.2 Proposición Intersección de σ-anillos . . . 9
2.1.2 Definición Recta real extendida . . . 9
2.1.3 Definición Unión disjunta . . . 9

2.1.4 Definición Función aditiva . . . 10
2.1.1 Teorema Aditividad . . . 10
2.1.1 Corolario Separación de la suma de una función contable aditiva . . . 11
2.1.1 Lema Monotonía . . . 11
2.1.5 Definición Medida . . . 11
2.1.6 Definición Espacio medible . . . 11
2.1.7 Definición σ-finidad . . . 11
2.2.1 Definición Espacio muestral . . . 12
2.2.2 Definición Experimento . . . 12
2.2.3 Definición Finito, cantable o no . . . 12
2.2.4 Definición Álgebra conjuntiva . . . 12
2.2.1 Proposición Relación entre anillos y álgebras . . . 12
2.2.2 Proposición Union, intersección y diferencia de álgebras . . . 12
2.2.3 Proposición Intersección de σ-álgebras . . . 13
2.2.1 Corolario La más pequeña σ-álgebra $\sigma(\cdot)$ . . . 13
2.2.5 Definición Probabilidad . . . 13
2.2.6 Definición Espacio de probabilidad . . . 13
2.2.1 Teorema Propiedades . . . 13
2.2.2 Corolario Union de probabilidades . . . 14
2.2.7 Definición Semialgebra . . . 15
2.2.1 Lema Álgebra de semialgebra . . . 15
2.2.8 Definición π-sistema . . . 15
2.2.9 Definición λ-sistema . . . 15
2.2.2 Teorema Teorema $\pi - \lambda$ de Dynkin . . . 15
2.3.1 Teorema Teorema de unicidad de medidas . . . 16
2.3.1 Lema σ-aditividad heredada . . . 16
2.3.1 Definición Medida exterior de Carathéodory . . . 17
2.3.2 Definición Medida exterior . . . 17
2.3.3 Definición Criterio de medibilidad de Carathéodory . . . 17
2.3.2 Lema Coherencia con la medida original . . . 17
2.3.2 Teorema Teorema de Carathéodory . . . 18
2.3.3 Teorema Teorema de la extensión de Carathodory . . . 19
2.3.4 Teorema Teorema de Hahn-Kolmogorov . . . 19
2.3.4 Definición Medida de Stieltjes . . . 20
2.3.5 Definición Función indicadora y medida de Dirac . . . 20
2.3.6 Definición Función simple . . . 20
2.3.7 Definición Integral de una función simple . . . 20
2.3.3 Lema Propiedades básicas de la integral para funciones simples . . . 20
2.3.8 Definición Definición de la integral de Lebesgue vía funciones simples . . . 21
2.3.4 Lema propiedades elementales de la integral de Lebesgue para funciones acotadas de soporte de medida finita . . . 22
2.3.9 Definición Integral de f sobre el conjunto E . . . 22
2.3.10 Definición Integral de Lebesgue para funciones medibles no negativas . . . 22
2.3.5 Lema Aproximación por truncamiento . . . 22
2.3.6 Lema Propiedades elementales de la integral de Lebesgue. . . . 23
2.3.11 Definición Extensión de la integral de Lebesgue a funciones medibles de signo arbitrario . 23
2.3.7 Lema Linealidad para la diferencia . . . 23
2.3.5 Teorema Teorema de las propiedades fundamentales de la integral de Lebesgue . . . 23
2.3.6 Teorema Desigualdad de Jensen . . . 24
2.3.7 Teorema Teorema de convergencia acotada . . . 24
2.3.8 Lema Lema de Fatou . . . 25
2.3.8 Teorema Teorema de convergencia monotona . . . 26
2.3.9 Teorema Teorema de convergencia dominada . . . 26
2.3.10 Teorema Teorema Riemann-Lebesgue . . . 26

2.3.12 Definición Espacio de medida producto . . . 27
2.3.13 Definición Medida producto . . . 27
2.3.11 Teorema Teorema de la medida producto . . . 27
2.3.9 Lema Lema de las secciones medibles . . . 28
2.3.10 Lema Lema de Tonelli para funciones indicadoras . . . 28
2.3.12 Teorema Teorema de Fubini-Tonelli . . . 29
2.4.1 Definición Espacio $L^p(\mu)$ . . . 29
2.4.2 Definición Exponente conjugado . . . 30
2.4.1 Teorema Desigualdad de Hölder . . . 30
2.4.2 Teorema Desigualdad de Minkowski . . . 30
2.4.3 Teorema Relación entre espacios L^p en medida finita . . . 31
2.4.3 Definición Espacio métrico completo . . . 31
2.4.4 Definición Espacio de Banach . . . 31
2.4.4 Teorema Riesz-Fischer . . . 31
2.4.5 Definición Conjunto denso . . . 31
2.4.5 Teorema Densidad de funciones simples en L^p . . . 32
2.4.6 Teorema Densidad de C_c en L^p . . . 32
2.4.6 Definición Producto interno en L^2 . . . 32
2.4.7 Definición Espacio de Hilbert . . . 32
2.4.7 Teorema $L^2(\mu)$ es un espacio de Hilbert . . . 32
2.4.8 Teorema Identidad de Parseval . . . 32
2.4.9 Teorema Proyección ortogonal . . . 32
2.4.8 Definición Funcional lineal acotado y dual . . . 33
2.4.10 Teorema Dualidad de L^p . . . 33
2.4.11 Teorema Dualidad de L^1 . . . 33
2.4.12 Teorema Convergencia en L^p implica convergencia en medida . . . 33
2.4.13 Teorema Criterio de uniformemente integrabilidad en L^1 . . . 33
2.4.9 Definición Medida signada . . . 33
2.4.10 Definición Conjuntos positivos y negativos respecto de una medida signada . . . 34
2.4.1 Lema Herencia y unión contable de conjuntos positivos . . . 34
2.4.2 Lema Existencia de un subconjunto negativo . . . 34
2.4.14 Teorema Descomposicion de Hahn . . . 34
2.4.11 Definición Medidas mutuamente singulares . . . 35
2.4.15 Teorema Descomposicion de Jordan . . . 35
2.4.12 Definición Absoluta continuidad . . . 35
2.4.16 Teorema Descomposición de Lebesgue . . . 35
2.4.13 Definición Completitud de la medida . . . 36
2.4.3 Lema Extensión de la σ–álgebra . . . 36
2.4.17 Teorema Completitud de la extensión . . . 37
2.4.18 Teorema Radon-Nikodym . . . 37
2.5.1 Definición Distribución de probabilidad en un espacio contable . . . 37
2.5.2 Definición Probabilidad geométrica . . . 37
2.5.3 Definición Probabilidad de Laplace . . . 38
2.6.1 Definición Probabilidad condicional . . . 38
2.6.1 Teorema Teorema fundamental de la probabilidad condicional . . . 38
2.6.2 Teorema Teorema de probabilidad total . . . 39
2.6.3 Teorema Teorema de Bayes . . . 39
2.7.1 Definición Independencia de eventos . . . 39
2.7.2 Definición Familias independientes . . . 39

3.1.1 Definición Función medible . . . 41
3.1.1 Teorema Teorema de la medibilidad por generador . . . 41
3.1.2 Teorema Teorema de la composición de funciones medibles . . . 41
3.1.2 Definición σ-álgebra de Borel . . . 42

3.1.3 Teorema Caracterización de la σ-álgebra de Borel . . . 42
3.2.1 Definición Variable aleatoria . . . 42
3.2.1 Proposición Equivalente de variable aleatoria . . . 42
3.2.1 Teorema Operaciones algebraicas con variables aleatorias . . . 43
3.2.2 Teorema Máximo y mínimo de variables aleatorias . . . 44
3.2.3 Teorema Composición de variables aleatorias . . . 44
3.2.2 Definición σ-álgebra generada por una variable aleatoria . . . 44
3.3.1 Definición Distribución inducida por una variable aleatoria . . . 45
3.3.1 Proposición La distribución inducida por una variable aleatoria es una medida de probabilidad . . . 45
3.3.2 Definición Función de distribución acumulada . . . 45
3.3.1 Teorema Propiedades de la función de distribución acumulada . . . 45
3.3.1 Corolario Cálculo de probabilidades mediante la función de distribución acumulada . . . 46
3.3.3 Definición Salto de la función de distribución acumulada . . . 47
3.3.4 Definición Función de Stieltjes . . . 47
3.3.2 Teorema Teorema de Stieltjes . . . 47
3.3.5 Definición Función de distribución en $\mathbb{R}^d$ . . . 48
3.3.3 Teorema Teorema de Stieltjes en $\mathbb{R}^d$ . . . 48
3.3.4 Teorema Correspondencia biyectiva entre funciones de distribución y medidas de probabilidad en $\mathbb{R}$ . . . 48
3.4.1 Definición Variable aleatoria continua . . . 49
3.4.2 Definición Igualdad en distribución . . . 49
3.4.3 Definición Variable aleatoria absolutamente continua . . . 49
3.4.1 Teorema Variable aleatoria absolutamente continua . . . 49
3.4.2 Teorema Transformación de densidades . . . 49
3.4.4 Definición Variable aleatoria discreta . . . 50
3.5.1 Definición Esperanza . . . 50
3.5.1 Lema Esperanza en $\mathbb{R}$ . . . 50
3.5.3 Lema Fórmula de Fubini para la esperanza . . . 51
3.5.1 Teorema LOTUS para la esperanza . . . 51
3.5.2 Definición Momento de orden r . . . 52
3.5.1 Proposición Linealidad de la esperanza . . . 52
3.5.2 Proposición Desigualdad de Hölder para esperanzas . . . 53
3.5.3 Proposición Desigualdad de Markov . . . 53
3.6.1 Definición Media, varianza y momentos . . . 53
3.6.1 Proposición Relación entre momentos centrados y momentos ordinarios . . . 53
3.6.1 Corolario Fórmula de la varianza . . . 54
3.6.2 Corolario Propiedades fundamentales de la varianza . . . 54
3.7.1 Definición Función generadora de momentos . . . 54
3.7.1 Teorema Teorema fundamental de la función generadora de momentos . . . 54
3.7.2 Teorema Colas exponenciales de la función generadora de momentos . . . 55
3.7.3 Teorema Teorema de unicidad de la función generadora de momentos . . . 55
3.8.1 Definición Función característica . . . 56
3.8.1 Proposición Propiedades básicas de la función característica . . . 56
3.8.1 Teorema Fórmula de inversión de Lévy . . . 56
3.8.1 Corolario Unicidad de la función característica . . . 58
3.8.2 Teorema Diferenciación de la función característica . . . 58
3.8.3 Teorema Fórmula de inversión de Fourier para la densidad . . . 59

4.0.1 Definición Variable aleatoria en varias variables . . . 60
4.0.2 Definición Función de distribución conjunta . . . 60
4.0.1 Teorema Propiedades básicas de la función de distribución conjunta . . . 60
4.0.3 Definición Función de distribución marginal . . . 61
4.0.2 Teorema Teorema de las marginales . . . 61

4.0.1 Proposición Función de masa de probabilidad conjunta . . . 62
4.0.3 Teorema Distribución inducida . . . 62
4.0.4 Definición Función de densidad conjunta . . . 62
4.0.2 Proposición LOTUS multivariable . . . 63
4.1.1 Definición Esperanza de un vector aleatorio . . . 63
4.1.1 Teorema LOTUS para esperanza multivariable . . . 63
4.1.2 Teorema Teorema del Jacobiano . . . 64
4.1.3 Teorema Teorema del cambio de variable . . . 64
4.2.1 Definición Covarianza . . . 65
4.2.1 Proposición Propiedades fundamentales de la covarianza . . . 65
4.2.2 Definición Correlación . . . 65
4.2.1 Teorema Propiedades fundamentales del coeficiente de correlación lineal . . . 65
4.2.2 Proposición Fórmula de la varianza de una suma . . . 66
4.2.3 Definición Matriz de covarianza . . . 66
4.3.1 Definición Independencia de vectores aleatorios . . . 66
4.3.1 Teorema Independencia mediante la función de distribución conjunta . . . 66
4.3.1 Proposición Independencia mediante factorización de la distribución conjunta . . . 67
4.3.2 Teorema Preservación de independencia por funciones medibles . . . 67
4.3.3 Teorema Factorización de la esperanza bajo independencia . . . 67
4.3.1 Corolario Independencia implica incorrelación . . . 67
4.3.2 Corolario Varianza aditiva bajo independencia . . . 67
4.3.2 Definición Función generadora de momentos multivariable . . . 67
4.3.4 Teorema Factorización de la función generadora de momentos bajo independencia . . . 68
4.3.3 Definición Función características multivariable . . . 68
4.3.5 Teorema Factorización de la función característica bajo independencia . . . 68
4.3.4 Definición Distribución acumulada condicional . . . 68
4.3.2 Proposición Densidad condicional . . . 68
4.3.3 Proposición Función de masa condicional . . . 68
4.3.6 Teorema Regla de Bayes para mezclas discreto–continuas . . . 69
4.4.1 Definición Esperanza condicional . . . 69
4.4.2 Definición Distribución condicional regular . . . 70
4.4.1 Lema Unicidad casi segura . . . 70
4.4.1 Teorema Existencia de la esperanza condicional . . . 70
4.4.2 Teorema Propiedades de la esperanza condicional . . . 70
4.4.3 Teorema Contracción en L^p y proyección ortogonal en L^2 . . . 71
4.4.4 Teorema LOTUS condicional . . . 71
4.4.1 Proposición Varianza condicional . . . 71
4.4.2 Proposición Ley de la varianza total . . . 71
4.4.5 Teorema Factorización condicional bajo independencia y extracción funciones . . . 71
4.4.6 Teorema Fórmula de convolución . . . 71
4.4.7 Teorema Convolución de densidades . . . 72
4.5.1 Definición Convergencia casi segura . . . 72
4.5.1 Proposición Caracterización probabilística de la convergencia casi segura . . . 72
4.5.2 Definición Convergencia en L^p . . . 73
4.5.3 Definición Convergencia en distribución . . . 73
4.5.4 Definición Convergencia en probabilidad . . . 73
4.5.1 Teorema Cadena de implicaciones de convergencia . . . 73
4.5.2 Teorema Convergencia dominada . . . 74
4.5.3 Teorema Convergencia monótona . . . 74
4.5.4 Teorema Teorema de Helly-Bray . . . 74
4.5.5 Teorema Continuidad de Lévy y Cramér . . . 75
4.5.6 Teorema Desigualdad de Chebyshev . . . 75

5.0.1 Definición Variables no correlacionadas . . . 77

5.0.1 Teorema Varianza no correlacionada . . . 77
5.0.1 Lema Convergencia en probabilidad vía momentos . . . 77
5.0.2 Teorema Ley débil en L^2 . . . 78
5.0.3 Teorema Ley débil por control de varianza . . . 78
5.0.2 Definición Variable indicadora de ciclos en la descomposición . . . 78
5.0.2 Lema Esperanza del conteo de ciclos vía indicadores . . . 78
5.0.3 Definición Truncamiento . . . 79
5.0.4 Teorema Teorema de Bienaymé–Chebyshev, versión débil tipo Lindeberg . . . 79
5.0.3 Lema Fórmula de integración por partes para momentos . . . 80
5.0.5 Teorema Ley de los Grandes Números con truncamiento para colas ligeras . . . 80
5.1.1 Teorema Primer lema de Borel-Cantelli . . . 81
5.1.2 Teorema Caracterización de convergencia en probabilidad . . . 81
5.1.3 Teorema Criterio secuencial de convergencia . . . 83
5.1.4 Teorema Ley débil de los grandes números . . . 83
5.1.5 Teorema Teorema de continuidad de la convergencia en probabilidad . . . 84
5.1.6 Teorema Ley Fuerte de los Grandes Números con cuarto momento finito . . . 84
5.1.1 Lema Segundo lema de Borel-Cantelli . . . 85
5.1.7 Teorema Divergencia del promedio para medias infinitas . . . 85
5.1.8 Teorema Convergencia casi segura de sucesiones no convergentes . . . 85
5.1.9 Teorema Ley de los récords . . . 85
5.1.2 Lema Lema de Kochen-Stone . . . 86
5.1.3 Lema Truncación para la Ley Fuerte de los Grandes Números . . . 86
5.1.4 Lema Cota de varianza tipo Kolmogórov para variables truncadas . . . 86
5.1.5 Lema Desigualdad elemental para series tipo p–serie . . . 86
5.1.10 Teorema Ley Fuerte de los Grandes Números para medias unilaterales infinitas . . . 86
5.1.11 Teorema Ley Fuerte de los Tiempos de Espera . . . 86
5.1.12 Teorema Teorema de Glivenko-Cantelli . . . 86
5.1.13 Teorema Desigualdad máxima de Kolmogorov . . . 87
5.1.14 Teorema Convergencia casi segura de series independientes . . . 87
5.1.15 Teorema Teorema de las tres series de Kolmogorov . . . 87
5.1.16 Teorema Lema de Kronecker . . . 87
5.1.17 Teorema Ley fuerte de los grandes números . . . 88
5.1.18 Teorema Ley del Límite Superior . . . 88
5.1.19 Teorema Ley Fuerte de los Grandes Números para momentos fraccionarios . . . 88
5.1.20 Teorema Teorema de Kolmogórov para sumas de variables i.i.d. con media infinita . . . 88
5.2.1 Teorema Ley Fuerte de los Tiempos de Renovación . . . 88
5.2.2 Teorema Ecuación de Wald . . . 89
5.2.3 Teorema Ley Fuerte de los Tiempos de Renovación es el nombre estándar . . . 89
5.2.4 Teorema Teorema de renovación de Blackwell . . . 89
5.2.5 Teorema Teorema de existencia y unicidad de la ecuación de renovación . . . 89
5.2.6 Teorema Teorema de renovación . . . 89
5.2.1 Lema Integrabilidad directa para funciones decrecientes no negativas . . . 89
5.3.1 Lema Subaditividad de Cramér para grandes desviaciones . . . 90
5.3.2 Lema Lema de Cramér sobre crecimiento exponencial de la función generadora de momentos 90
5.3.1 Teorema Teorema de grandes desviaciones de Cramér . . . 90
5.3.3 Lema Lema de cambio de medida exponencial . . . 90
5.3.2 Teorema Teorema de límite de la razón de momentos . . . 90
5.3.3 Teorema Teorema de cola pesada límite lineal . . . 91

6.0.1 Teorema Teorema de De Moivre-Laplace . . . 92
6.0.1 Lema Lema de límite exponencial . . . 92
6.0.2 Teorema Teorema de aproximación de De Moivre–Laplace . . . 92
6.0.3 Teorema El otro Teorema de De Moivre-Laplace . . . 93
6.1.1 Teorema Teorema de convergencia de medidas por convergencia puntual de densidades . . 93

6.1.1 Lema Lemma sobre la densidad de V_{n+1} . . . 93
6.1.2 Teorema Teorema de Skorokhod . . . 93
6.1.3 Teorema Teorema de la convergencia débil . . . 94
6.1.4 Teorema Teorema del mapeo continuo . . . 94
6.1.5 Teorema Teorema de Portmanteau . . . 94
6.1.6 Teorema Teorema de selección de Helly . . . 94
6.1.7 Teorema Teorema de Tightness para sucesiones de distribuciones . . . 94
6.1.8 Teorema Criterio de Prokhorov para tightness . . . 94
6.1.9 Teorema Teorema de subsecuencias límites para convergencia en distribución . . . 95
6.1.10 Teorema Teorema de continuidad . . . 95
6.1.2 Lema Aproximación de la exponencial compleja mediante su serie de Taylor . . . 95
6.1.11 Teorema Diferenciabilidad de la función característica . . . 95
6.1.12 Teorema Desarrollo de Taylor de la función característica . . . 95
6.1.13 Teorema Condición de concavidad limitada para la función característica . . . 95
6.1.14 Teorema Criterio de Pólya . . . 96
6.1.15 Teorema Unicidad en el problema de momentos . . . 96
6.1.16 Teorema Teorema de continuidad de momentos . . . 96
6.1.17 Teorema Teorema de Lindeberg-Lévy . . . 96
6.1.18 Teorema Teorema de límite exponencial . . . 96
6.1.3 Lema Diferencias de productos . . . 96
6.1.4 Lema Aproximación exponencial . . . 97
6.1.19 Teorema Teorema de Lindeberg-Feller . . . 97
6.1.20 Teorema Teorema de Gnedenko-Kolmogorov . . . 97
6.1.5 Lema Lemma de selección diagona . . . 97
6.1.21 Teorema Teorema central de Erdős-Kac . . . 97
6.1.22 Teorema Teorema de Berry-Esseen . . . 98
6.1.6 Lema Lema de Esseen . . . 98
6.1.7 Lema Lema de Fourier de Lévy . . . 98
6.2.1 Teorema Teorema central del límite . . . 98
6.2.2 Teorema Teorema de Lévy sobre la estructura de la función característica . . . 98
6.2.3 Teorema Teorema Local del Límite Central . . . 99
6.2.4 Teorema Teorema Puntual del Límite Central . . . 99
6.3.1 Teorema Teorema de Poisson límite . . . 99
6.3.1 Lema Lema de convergencia en variación . . . 99
6.3.2 Lema Lema de subaditividad de la norma de variación total para medidas producto . . . 99
6.3.3 Lema Lema de contracción de la convolución en variación total . . . 99
6.3.4 Lema Lema de Poisson-Binomial para una sola variable . . . 100
6.3.2 Teorema Teorema de Poisson en el problema de las cajas y bolas . . . 100
6.3.3 Teorema Teorema de Poisson extendido . . . 100
6.3.4 Teorema Teorema de Poisson para procesos de cuenta . . . 100
6.4.1 Lema Lema de la diagonal de Cantor . . . 100
6.4.1 Teorema Teorema de Gnedenko-Kolmogorov sobre la convergencia a distribuciones estables 101
6.4.2 Lema Lema de Potter . . . 101
6.4.2 Teorema Teorema de Gnedenko . . . 101
6.4.3 Teorema Teorema de convergencia de tipos . . . 101
6.5.1 Teorema Teorema de Lévy sobre la divisibilidad infinita . . . 102
6.5.2 Teorema Teorema de Lévy-Khinchin . . . 102
6.5.3 Teorema Teorema de Kolmogórov . . . 102
6.6.1 Teorema Teorema limite en $\mathbb{R}$ . . . 103
6.6.2 Teorema Teorema de Prokhorov en dimensión d . . . 103
6.6.3 Teorema Teorema de Prokhorov . . . 103
6.6.4 Teorema Fórmula de inversión . . . 103
6.6.5 Teorema Teorema de continuidad de las funciones características . . . 103
6.6.6 Teorema Dispositivo de Cramér-Wold . . . 103

6.6.7 Teorema Teorema central del límite en $\mathbb{R}^d$ . . . 104

7.1.1 Definición Proceso estocástico . . . 106
7.1.2 Definición Trayectoria . . . 106
7.1.3 Definición Proceso estocástico en $\mathbb{R}^d$ . . . 106
7.1.4 Definición Caminata aleatoria simple . . . 107
7.1.5 Definición Caminata aleatoria generalizada . . . 107
7.1.1 Proposición Propiedad de Markov . . . 107
7.2.1 Definición Cadena de Markov . . . 107
7.2.2 Definición Probabilidades de transición . . . 107
7.2.3 Definición Distribución inicial de la cadena . . . 108
7.2.1 Lema Factorización con Markov . . . 108
7.2.4 Definición Función de transición de m-pasos . . . 108
7.2.2 Lema Expansionan de una cadena de Markov . . . 108
7.2.1 Corolario Equivalencia de transición de n+m pasos . . . 108
7.2.1 Teorema Chapman-Kolmogorov . . . 108
7.2.5 Definición Función de transición . . . 109
7.2.2 Corolario Matriz de m-pasos de transición . . . 109
7.2.3 Lema No se como llamarlo . . . 109
7.3.1 Definición Probabilidad de transición y cadena de Markov . . . 109
7.3.2 Definición Operadores de desplazamiento . . . 109
7.3.2 Teorema Teorema de la clase monótona . . . 110
7.3.3 Teorema Propiedad de Markov (operador de desplazamiento) . . . 110
7.3.3 Definición σ-álgebra $\mathcal{F}_N$ y desplazamiento aleatorio . . . 110
7.3.4 Teorema Propiedad fuerte de Markov (operador de desplazamiento) . . . 110
7.4.1 Definición Comunicación de una cadena . . . 110
7.4.2 Definición No comunicación . . . 110
7.4.3 Definición Intercomunicación . . . 111
7.4.4 Definición Cadena irreducible . . . 111
7.4.1 Lema Condición para comunicación . . . 111
7.4.2 Lema Relación de equivalencia . . . 111
7.4.5 Definición Notación de comunicación . . . 111
7.4.6 Definición Recurrente y transitorio . . . 111
7.4.7 Definición Visita exacta . . . 111
7.4.8 Definición Estado absorbente . . . 111
7.4.1 Proposición Recurrencia en estados no absorbentes . . . 111
7.4.3 Lema Comunicación y visita . . . 112
7.4.4 Lema Primera visita . . . 112
7.4.2 Proposición Absorción casi segura desde transitorios . . . 112
7.4.9 Definición Tiempos de retorno . . . 112
7.4.10 Definición Numero esperado de visitas . . . 112
7.4.5 Lema Transiciones y Numero de visitas . . . 113
7.4.6 Lema Series de potencia de visitas . . . 113
7.4.2 Teorema Consecuencias de recurrencia y transición . . . 114
7.4.3 Teorema Caracterización de la recurrencia . . . 114
7.4.3 Proposición Transitorios se visitan finitas veces . . . 114
7.4.11 Definición Tiempo medio de recurrencia . . . 114
7.4.4 Proposición Convergencia cesariana de las transiciones . . . 115
7.4.7 Lema Equivalencia de nulorecurente . . . 115
7.4.12 Definición Estado periódico . . . 115
7.4.5 Teorema Equivalencia entre estados . . . 115
7.4.8 Lema Recurrencia y equivalencia . . . 116
7.4.13 Definición Conjunto cerrado e irreducible . . . 116
7.4.6 Teorema Equivalencia de cerrado . . . 116

7.4.9 Lema Recurrencia en conjunto cerrado . . . 116
7.4.7 Teorema Recurrencia positiva en conjuntos finitos cerrados . . . 117
7.4.1 Corolario Recurrencia positiva en cadenas finitas irreducibles . . . 117
7.4.8 Teorema Descomposición del espacio de estados . . . 117
7.4.10 Lema Existencia de descenso estricto . . . 118
7.4.5 Proposición Probabilidad de absorción con función harmónica monótona . . . 118
7.4.11 Lema Conjunto de máximo es cerrado . . . 118
7.5.1 Definición Cadena de nacimiento y muerte . . . 118
7.6.1 Teorema Principio de reflexión (caminatas simétricas) . . . 119
7.6.1 Definición Valor recurrente y valor posible . . . 119
7.6.2 Definición Caminata aleatoria recurrente y transitoria . . . 119
7.6.6 Teorema Teorema de Chung-Fuchs . . . 120
7.6.3 Lema Relación de Parseval . . . 120
7.6.3 Definición Caminata aleatoria verdaderamente tridimensional . . . 120
7.7.1 Definición Medida estacionaria . . . 121
7.7.1 Lema Invariante para probabilidades n-pasos . . . 121
7.7.2 Definición Probabilidad de transición doblemente estocástica . . . 121
7.7.3 Definición Balance detallado y medida reversible . . . 121
7.7.2 Teorema Condición del ciclo de Kolmogorov . . . 121
7.7.5 Teorema Equivalencia entre recurrencia positiva e invariancia . . . 122
7.7.1 Corolario Existencia y unicidad en cadenas finitas irreducibles . . . 122
7.7.2 Lema Soporte de la distribución estacionaria . . . 122
7.7.7 Teorema Clasificación de distribuciones estacionarias . . . 123
7.8.1 Corolario Ergódico de medias temporales . . . 123
7.8.1 Definición Descomposición cíclica . . . 124
7.8.1 Teorema Ergódico de convergencia . . . 124
7.9.1 Definición σ-álgebra de cola . . . 125
7.10.1 Definición Cadena de Harris . . . 125
7.10.2 Definición Cadena extendida $\bar{X}_n$ . . . 125
7.10.3 Definición Recurrencia y transitoriedad para cadenas de Harris . . . 126
7.10.4 Definición Cadena de Harris aperiódica . . . 126
7.11.1 Definición Sucesión estacionaria . . . 127
7.11.2 Definición Transformación que preserva la medida . . . 127
7.11.3 Definición Evento invariante y transformación ergódica . . . 127
7.11.1 Lema Lema ergódico maximal . . . 127
7.11.1 Teorema Teorema ergódico . . . 127
7.11.5 Teorema Kac . . . 128
7.11.6 Teorema Teorema ergódico subaditivo . . . 128

8.1.1 Definición Distribución condicional regular . . . 129
8.2.1 Definición martingala en tiempo discreto . . . 130
8.2.2 Definición Filtración . . . 130
8.2.3 Definición Filtración natural . . . 130
8.2.4 Definición $(\mathcal{F}_n)$-adaptado . . . 130
8.2.5 Definición $(\mathcal{F}_n)$-martingala . . . 131
8.2.2 Teorema Consecuencias para submartingalas y supermartingalas . . . 131
8.2.6 Definición $(\mathcal{F}_n)$-predecible . . . 132
8.2.3 Teorema Descomposición de Doob . . . 132
8.2.7 Definición Transformada de martingala . . . 132
8.2.8 Definición Ganancias del sistema H . . . 132
8.3.1 Definición $(\mathcal{F}_n)$-tiempo de parada . . . 133
8.3.2 Definición Variable detenida . . . 133
8.4.1 Definición Proceso detenido . . . 133
8.4.1 Teorema Parada Opcional de Doob . . . 133

8.5.1 Teorema Desigualdad Maximal de Doob . . . 134
8.5.2 Teorema Desigualdad de Doob . . . 134
8.5.3 Teorema Desigualdad en L^p de Doob . . . 134
8.6.1 Definición Cruces ascendentes . . . 135
8.6.1 Teorema Desigualdad de cruces ascendentes . . . 135
8.6.2 Teorema Convergencia de Martingalas . . . 135
8.6.3 Teorema Convergencia de submartingalas . . . 137
8.6.4 Teorema Convergencia de supermartingalas no negativas . . . 137
8.7.2 Teorema Segundo lema de Borel-Cantelli, II . . . 138
8.7.4 Teorema Dicotomía de Kakutani . . . 138
8.7.1 Definición Proceso de Galton-Watson . . . 138
8.7.8 Teorema Kesten-Stigum . . . 139
8.8.1 Teorema Ortogonalidad de los incrementos de una martingala . . . 139
8.8.2 Teorema Fórmula de la varianza condicional . . . 139
8.8.1 Definición Proceso creciente asociado . . . 139
8.8.6 Teorema Segundo lema de Borel-Cantelli, III . . . 140
8.9.1 Definición Integrabilidad uniforme . . . 140
8.9.7 Teorema Ley 0-1 de Lévy . . . 141
8.9.8 Teorema Teorema de convergencia dominada para esperanzas condicionales . . . 141
8.10.1 Definición Martingala hacia atrás . . . 141
8.10.4 Teorema Teorema del escrutinio (versión general) . . . 141
8.10.2 Definición σ-álgebra intercambiable . . . 142
8.10.5 Teorema Ley 0-1 de Hewitt-Savage . . . 142
8.10.3 Definición Sucesión intercambiable . . . 142
8.10.6 Teorema Teorema de de Finetti . . . 142
8.11.6 Teorema Ecuación de Wald . . . 143
8.11.7 Teorema Caminata aleatoria simétrica simple . . . 143
8.11.9 Teorema Caminata aleatoria simple asimétrica . . . 143
8.12.1 Teorema Principio de reflexión (conteo de caminos) . . . 144
8.12.2 Teorema Teorema del escrutinio (elecciones) . . . 144
8.12.3 Teorema Ley del arcoseno para la última visita a 0 . . . 144
8.12.4 Teorema Ley del arcoseno para el tiempo sobre 0 . . . 144

9.1.1 Definición Càdlàg . . . 145
9.1.2 Definición Filtración en tiempo continuo . . . 145
9.1.3 Definición Filtración natural . . . 145
9.1.4 Definición $(\mathcal{F}_t)$-adaptado . . . 145
9.1.5 Definición $(\mathcal{F}_t)$-tiempo de parada . . . 146
9.1.6 Definición Proceso detenido . . . 146
9.1.7 Definición $(\mathcal{F}_t)$-martingala . . . 146
9.1.1 Teorema Versión càdlàg de martingalas continuas . . . 146
9.1.2 Teorema Parada Opcional de Doob . . . 146
9.1.1 Proposición Preservación de la clase bajo detención . . . 146
9.1.4 Teorema Desigualdad Maximal de Doob . . . 146
9.1.5 Teorema Convergencia de Martingalas . . . 147
9.2.1 Definición Construcción . . . 147
9.2.1 Proposición Divergencia de los tiempos de llegada . . . 147
9.2.2 Proposición Distribución de Poisson de los conteos . . . 147
9.2.1 Lema Propiedad de memoria en el proceso de Poisson . . . 148
9.2.2 Lema Propiedad de regeneración de los tiempos de llegada . . . 148
9.2.1 Corolario Propiedad de regeneración de los conteos . . . 149
9.2.2 Definición Incrementos . . . 149
9.2.3 Lema Incrementos estacionarios del proceso de Poisson . . . 149
9.2.4 Lema Incrementos independientes del proceso de Poisson . . . 149

9.2.3 Definición Proceso de Lévy . . . 150
9.2.1 Teorema Caracterización del proceso de Poisson como proceso de Lévy . . . 150
9.2.5 Lema Recíproco de la caracterización de Poisson . . . 150
9.2.4 Definición Proceso de saltos . . . 150
9.2.6 Lema Saltos unitarios en el proceso de Poisson . . . 150
9.2.7 Lema Ausencia de saltos en tiempos fijos de Lévy . . . 150
9.2.2 Teorema Caracterización de procesos de Lévy con saltos unitarios . . . 151
9.2.8 Lema Martingala de Lévy con media cero . . . 151
9.2.2 Corolario Martingala compensada del proceso de Poisson . . . 151
9.3.1 Definición Proceso compuesto de Poisson . . . 151
9.3.1 Teorema Proceso compuesto de Poisson como proceso de Lévy . . . 152
9.3.1 Lema Existencia de momentos en el proceso compuesto de Poisson . . . 152
9.3.2 Lema Función característica del proceso compuesto de Poisson . . . 152
9.4.1 Definición Movimiento Browniano estándar . . . 153
9.4.1 Teorema Movimiento Browniano estándar como proceso de Lévy . . . 153
9.4.1 Proposición Martingalas y el Browniano . . . 153
9.4.2 Definición Distribución Gaussiana multivariada . . . 154
9.4.1 Lema Independencia Gaussiana . . . 154
9.4.2 Proposición Caracterización Gaussiana . . . 154
9.4.3 Definición Gaussiano . . . 154
9.4.2 Teorema Caracterización del Movimiento Browniano . . . 154
9.4.3 Proposición Invariancias del Movimiento Browniano . . . 155
9.4.4 Proposición Construcción de Wiener del Browniano . . . 156
9.4.5 Teorema Kolmogorov . . . 156
9.4.5 Proposición Browniano en dimensión d . . . 156
9.4.4 Definición Movimiento Browniano estándar d-dimensional . . . 157
9.4.6 Teorema Equivalencia del Browniano Multidimensional . . . 157
9.4.7 Teorema Descomposición de Lévy-Itô . . . 157
9.4.5 Definición Varianza . . . 157
9.4.8 Teorema Variación del Movimiento Browniano . . . 158
9.4.6 Definición Hölder continuidad . . . 158
9.4.9 Teorema Regularidad Hölder del Browniano . . . 159
9.4.1 Corolario No Regularidad Hölder del Browniano . . . 159
9.4.10 Teorema Módulo de continuidad de Lévy . . . 159
9.4.11 Teorema Paley-Wiener-Zygmund . . . 159
9.4.12 Teorema No Monotonía del Browniano . . . 159
9.4.13 Teorema Comportamiento en el largo plaza . . . 160
9.4.15 Teorema Comportamiento en el corto plazo . . . 160
9.4.7 Definición Proceso de Markov . . . 160
9.4.16 Teorema Propiedad de Markov del Browniano . . . 160
9.4.8 Definición Función de transición . . . 161
9.4.9 Definición Densidad de transición . . . 161
9.4.10 Definición σ-álgebras $\mathcal{F}_s^o$ y $\mathcal{F}_{s+}$, operador de desplazamiento . . . 161
9.4.17 Teorema Propiedad de Markov (operador de desplazamiento) . . . 161
9.4.19 Teorema Ley 0-1 de Blumenthal . . . 162
9.4.11 Definición σ-álgebra de cola (Browniano) . . . 162
9.4.12 Definición σ-álgebras completadas . . . 162
9.4.13 Definición Tiempo de paro (continuidad por derecha) . . . 162
9.4.14 Definición Desplazamiento aleatorio e información al tiempo S . . . 162
9.4.31 Teorema Propiedad fuerte de Markov (Browniano) . . . 163
9.4.32 Teorema Principio de Reflexión . . . 163
9.4.6 Proposición Conjunto de ceros . . . 163
9.4.34 Teorema Principio de reflexión (tiempo de llegada) . . . 164
9.4.8 Proposición Densidad de T_a . . . 164

9.4.35 Teorema Ley del arcoseno de Lévy . . . 164
9.4.15 Definición Martingala local . . . 164
9.4.41 Teorema Teorema de representación de Skorokhod . . . 165
9.4.43 Teorema Teorema central del límite . . . 165
9.4.16 Definición Interpolación lineal . . . 165
9.4.44 Teorema Teorema de Donsker . . . 165
9.4.17 Definición Convergencia débil en $C[0,\infty)$ . . . 166
9.4.47 Teorema Strassen . . . 166
9.4.18 Definición Arreglo de diferencias de martingala . . . 166
9.4.49 Teorema Freedman . . . 166
9.4.50 Teorema Teorema de Lindeberg-Feller para martingalas . . . 166
9.4.8 Lema Dvoretsky . . . 167
9.4.51 Teorema Teorema central del límite para martingalas . . . 167
9.4.52 Teorema Billingsley-Ibragimov . . . 167
9.4.19 Definición Coeficiente de dependencia α . . . 168
9.4.20 Definición Distribución empírica . . . 168
9.4.55 Teorema Teorema de Glivenko-Cantelli . . . 168
9.4.21 Definición Puente browniano . . . 169
9.4.58 Teorema Ley del logaritmo iterado para el movimiento browniano . . . 169
9.4.59 Teorema Hartman-Wintner . . . 169
9.4.60 Teorema Principio de invariancia de Strassen . . . 169

10.1.1 Definición Integrandos simples $\mathcal{S}(T)$ . . . 170
10.1.2 Definición Integral estocástica para procesos simples . . . 170
10.1.1 Lema Integral estocástica de la indicadora . . . 170
10.1.2 Lema Linealidad de la integral estocástica para procesos simples . . . 171
10.1.3 Lema Media de la integral estocástica simple . . . 171
10.1.4 Lema Isometría de Itô . . . 171
10.1.3 Definición Integral estocástica como proceso . . . 172
10.2.1 Definición Integrandos cuadrado integrables $H^2(T)$ . . . 172
10.2.1 Teorema Densidad de procesos simples . . . 172
10.2.2 Teorema Convergencia de martingalas cuadrado integrables . . . 173
10.2.3 Teorema Existencia y propiedades de la integral estocástica . . . 173
10.2.2 Definición Integral estocástica en $H^2(T)$ . . . 173
10.2.1 Proposición Linealidad en $H^2(T)$ . . . 174
10.3.1 Definición Integrandos localmente cuadrado integrables $H^2_{\text{loc}}(T)$ . . . 174
10.3.1 Teorema Existencia de la integral general . . . 174
10.3.2 Definición Integral estocástica general . . . 175
10.3.1 Proposición Linealidad en $H^2_{\text{loc}}(T)$ . . . 175
10.4.1 Proposición Continuidad de la integral estocástica en $H^2(T)$ . . . 175
10.4.2 Proposición Continuidad de la integral estocástica en $H^2_{\text{loc}}(T)$ . . . 175
10.4.1 Teorema Representación de Riemann . . . 176
10.4.3 Proposición Integral estocástica con integrando determinístico . . . 177
10.4.2 Teorema Fórmula de Itô — Caso Simple . . . 177
10.4.3 Teorema Fórmula de Itô en Espacio y Tiempo . . . 177
10.5.1 Definición Proceso de Itô . . . 177
10.5.1 Proposición Variación cuadrática de un proceso de Itô . . . 178
10.5.2 Definición Integral respecto a un proceso de Itô . . . 178
10.5.1 Teorema Fórmula de Itô para un proceso de Itô . . . 178
10.5.2 Teorema Fórmula de Itô para dos procesos de Itô . . . 178
10.5.1 Corolario Regla del producto estocástica . . . 179
10.6.1 Definición Integrando matricial en $H^2(T)$ y $H^2_{\text{loc}}(T)$ . . . 179
10.6.2 Definición Integral matricial respecto al Browniano d-dimensional . . . 179
10.6.1 Proposición Isometría de Itô en dimensión matricial . . . 179

10.6.3 Definición Integral de un proceso vectorial . . . 179
10.6.4 Definición Proceso de Itô en $\mathbb{R}^m$ . . . 180
10.6.1 Teorema Fórmula de Itô multidimensional . . . 180

11.1.1 Definición Solución de una EDE . . . 181
11.1.2 Definición Unicidad de solución . . . 182
11.2.1 Definición EDE lineal . . . 182
11.2.2 Teorema Exponencial estocástica . . . 182

12.0.1 Definición Modelo estadístico . . . 186
12.0.2 Definición V.A. Hipotéticamente observable . . . 186
12.0.3 Definición Distribución conjunta . . . 187
12.0.4 Definición Inferencia estadística . . . 187
12.0.5 Definición Datos o muestra . . . 187
12.0.6 Definición Parámetros . . . 187
12.1.1 Definición Predicción . . . 187
12.1.2 Definición Problemas de Decisión Estadística . . . 187
12.1.3 Definición Diseños Experimentales . . . 187
12.1.4 Definición Estadístico . . . 187
12.2.1 Definición Distribucion previa . . . 188
12.2.2 Definición Análisis de Sensibilidad . . . 188
12.2.3 Definición Densidad impropia . . . 188
12.2.4 Definición Verosimilitud . . . 188
12.3.1 Definición Distribución Posterior . . . 188
12.3.1 Teorema Distribucion posterior . . . 188
12.4.1 Definición Familia conjugada . . . 189
12.4.1 Teorema Conjugación en el modelo Bernoulli . . . 189
12.4.2 Teorema Conjugación en el modelo Binomial . . . 189
12.4.3 Teorema Conjugación en el modelo Binomial Negativa . . . 189
12.4.4 Teorema Conjugación en el modelo Poisson . . . 189
12.4.5 Teorema Conjugación en el modelo Exponencial . . . 190
12.4.6 Teorema Conjugación en el modelo Normal con varianza conocida . . . 190
12.4.7 Teorema Conjugación en el modelo Normal con media conocida . . . 190
12.4.8 Teorema Posterior de la normal . . . 190
12.5.1 Definición Estimador . . . 191
12.5.2 Definición Estimación . . . 191
12.5.3 Definición Función de perdida . . . 191
12.5.4 Definición Perdida esperada y estimador bayesiano . . . 191
12.5.1 Proposición Perdida cuadrática . . . 192
12.5.2 Proposición Perdida absoluta . . . 192
12.5.3 Proposición Perdida 0-1 . . . 192
12.6.1 Definición Estimador consistente . . . 193
12.6.1 Teorema Bayesiano consistente . . . 193
12.6.2 Definición Estimador . . . 193
12.7.1 Definición Estimador de Máxima Verosimilitud . . . 193
12.7.2 Definición Generalización del MLE . . . 193
12.7.1 Teorema Invarianza del MLE . . . 193
12.7.3 Definición Consistencia de un estimador . . . 193
12.7.2 Teorema Consistencia del MLE . . . 194
12.7.3 Teorema Consistencia del estimador bayesiano . . . 194
12.7.4 Definición Método de Newton . . . 194
12.7.4 Teorema Convergencia local . . . 194
12.7.1 Corolario Aplicación a MLE . . . 194
12.7.5 Definición Método de Momentos . . . 194

12.7.5 Teorema Consistencia del estimador de momentos . . . 195
12.8.1 Definición Estadístico suficiente . . . 195
12.8.1 Teorema Teorema de Factorización de Neyman–Fisher . . . 195
12.8.2 Teorema Caracterización bayesiana de suficiencia . . . 195
12.9.1 Definición Estimador insesgado . . . 195
12.9.2 Definición Estadísticos conjuntamente suficientes . . . 195
12.9.1 Teorema Teorema de Factorización de Neyman–Fisher para estadísticos conjuntamente suficientes . . . 196
12.9.3 Definición Ordenamientos (Order Statistics) . . . 196
12.9.2 Teorema Suficiencia de los ordenamientos . . . 196
12.9.4 Definición Estadístico suficiente mínimo (minimal) . . . 196
12.9.3 Teorema MLE y estadísticos suficientes . . . 196
12.9.4 Teorema Estimador bayesiano y estadísticos suficientes . . . 196
12.9.5 Teorema Varianza muestral insesgada . . . 196
12.9.6 Teorema Cota de Cramér–Rao . . . 196
12.9.1 Proposición Distribución de Poisson estimadores insesgados . . . 197
12.9.2 Proposición Distribución normal comparación de estimadores de σ^2 por MSE . . . 197
12.9.5 Definición Inadmisibilidad en términos de MSE . . . 197
12.9.3 Proposición Conexión con Rao–Blackwell . . . 197
12.10.1 Definición Función de riesgo . . . 197
12.10.2 Definición Estimador de Rao–Blackwell . . . 198
12.10.1 Teorema Teorema de Rao–Blackwell . . . 198
12.10.3 Definición Admisibilidad e inadmisibilidad . . . 198

13.0.1 Definición Distribución χ^2 . . . 199
13.0.1 Proposición Propiedades de la distribución χ^2 . . . 199
13.0.2 Proposición Distribución muestral de la varianza . . . 199
13.0.3 Proposición Independencia en muestras normales . . . 200
13.0.4 Proposición Matrices ortogonales . . . 200
13.0.1 Teorema Transformación ortogonal de normales . . . 200
13.1.1 Definición Distribución t de Student . . . 200
13.1.1 Proposición Propiedades de la distribución t . . . 200
13.1.2 Proposición Estadístico t en muestras normales . . . 200

14.0.1 Definición Cuantil de orden p . . . 202
14.0.2 Definición Intervalo de confianza al $100(1-\alpha)\,\%$ . . . 202
14.0.1 Proposición Intervalo de confianza para la media normal (σ^2 desconocida) . . . 202
14.0.2 Proposición Interpretación correcta del intervalo de confianza . . . 203
14.0.3 Definición Intervalos de confianza de una cola . . . 203
14.0.4 Definición Cantidad pivotal . . . 203
14.0.3 Proposición Construcción de intervalos mediante cantidad pivotal . . . 203
14.0.4 Proposición Intervalo de confianza para la varianza normal . . . 203
14.0.5 Proposición Método Delta . . . 204
14.0.6 Proposición Transformación estabilizadora de la varianza . . . 204

15.0.1 Definición Hipótesis nula y alternativa . . . 205
15.0.2 Definición Tipos de hipótesis . . . 205
15.0.3 Definición Región crítica y estadístico de prueba . . . 205
15.0.4 Definición Función de potencia . . . 206
15.0.5 Definición Errores de Tipo I y Tipo II . . . 206
15.0.6 Definición Prueba de nivel α y tamaño de una prueba . . . 206
15.0.1 Corolario Caracterización del nivel de significancia . . . 206
15.0.7 Definición Valor-p . . . 206
15.0.1 Teorema Dualidad pruebas de hipótesis – regiones de confianza (I) . . . 206

15.0.2 Teorema Dualidad pruebas de hipótesis – regiones de confianza (II) . . . 207
15.0.3 Teorema Dualidad pruebas de hipótesis – regiones de confianza (III) . . . 207
15.0.8 Definición Estadístico LRT (Cociente de Verosimilitud) . . . 207
15.0.4 Teorema Teorema de Wilks . . . 207

16.0.1 Definición Errores en hipótesis simples . . . 208
16.0.1 Teorema Prueba óptima para combinación ponderada de errores . . . 208
16.0.2 Definición Cociente de verosimilitud para hipótesis simples . . . 208
16.0.1 Corolario Prueba óptima mediante cociente de verosimilitud . . . 209
16.0.3 Definición Criterio de Neyman-Pearson . . . 209
16.0.1 Lema Lema de Neyman-Pearson . . . 209

17.0.1 Proposición Prueba t de Student para una media . . . 210
17.0.2 Proposición Prueba t pareada . . . 210
17.0.3 Proposición Prueba t para comparación de medias de dos poblaciones independientes . . . 211
17.0.1 Definición Distribución F . . . 211
17.0.4 Proposición Propiedades de la distribución F . . . 211
17.0.5 Proposición Prueba F para comparación de varianzas (una cola) . . . 211
17.0.6 Proposición Prueba F de homocedasticidad (dos colas) . . . 211

18.0.1 Definición Datos categóricos y distribución multinomial . . . 212
18.0.2 Definición Estadístico χ^2 de Pearson . . . 212
18.0.3 Definición Prueba χ^2 con hipótesis parametrizadas . . . 213
18.0.1 Teorema Distribución asintótica con hipótesis parametrizadas . . . 213
18.0.2 Teorema Prueba χ^2 con MLE basado en datos individuales . . . 213

19.0.1 Definición Tabla de contingencia . . . 214
19.0.1 Proposición Prueba de independencia . . . 214
19.0.2 Proposición Prueba de homogeneidad . . . 215
19.0.3 Proposición Comparación de proporciones en R grupos . . . 215
19.0.2 Definición V de Cramer . . . 215
19.0.4 Proposición Paradoja de Simpson . . . 215

20.0.1 Definición Función de distribución empírica . . . 217
20.0.1 Lema Lema de Glivenko-Cantelli . . . 217
20.0.2 Definición Estadístico de Kolmogorov-Smirnov para una muestra . . . 218
20.0.1 Teorema Teorema de Kolmogorov-Smirnov (1930) . . . 218
20.0.3 Definición Estadístico de Kolmogorov-Smirnov para dos muestras . . . 218
20.0.2 Teorema Distribución límite para dos muestras . . . 218

21.0.1 Definición Mediana poblacional . . . 219
21.0.2 Definición Prueba de signo . . . 219
21.0.3 Definición Estadístico de rangos de Wilcoxon-Mann-Whitney . . . 220
21.0.1 Proposición Distribución del estadístico S bajo H_0 . . . 220

22.1.1 Definición Distribución Bernoulli . . . 222
22.1.1 Teorema Propiedades de la distribución Bernoulli . . . 222
22.1.2 Definición Distribución Binomial . . . 223
22.1.2 Teorema Propiedades de la distribución Binomial . . . 223
22.1.3 Definición Distribución geométrica . . . 224
22.1.3 Teorema Propiedades de la distribución Geométrica . . . 224
22.1.4 Definición Distribución Poisson . . . 225
22.1.4 Teorema Propiedades de la distribución Poisson . . . 225
22.1.5 Definición Distribución Hipergeométrica . . . 226
22.1.5 Teorema Propiedades de la distribución Hipergeométrica . . . 226

22.1.6 Definición Distribución Pascal . . . 226
22.1.6 Teorema Propiedades de la distribución Pascal . . . 227
22.1.7 Definición Distribución Uniforme Discreta . . . 227
22.1.7 Teorema Propiedades de la distribución Uniforme Discreta . . . 227
22.1.8 Definición Distribución Zeta . . . 228
22.1.8 Teorema Propiedades de la distribución Zeta . . . 228
22.1.9 Definición Distribución Zipf . . . 229
22.1.9 Teorema Propiedades de la distribución Zipf . . . 229
22.1.10 Definición Distribución Beta-Binomial . . . 230
22.1.10 Teorema Propiedades de la distribución Beta-Binomial . . . 230
22.1.11 Definición Distribución Hipergeométrica Negativa . . . 231
22.1.11 Teorema Propiedades de la distribución Hipergeométrica Negativa . . . 231
22.1.12 Definición Distribución Polya . . . 231
22.1.12 Teorema Propiedades de la distribución Polya . . . 232
22.1.13 Definición Distribución Logarítmica . . . 232
22.1.13 Teorema Propiedades de la distribución Logarítmica . . . 232
22.1.14 Definición Distribución Gamma–Poisson . . . 232
22.1.14 Teorema Propiedades de la distribución Gamma–Poisson . . . 233
22.1.15 Definición Distribución Beta–Pascal . . . 233
22.1.15 Teorema Propiedades de la distribución Beta–Pascal . . . 233
22.1.16 Definición Distribución Power Series . . . 234
22.1.16 Teorema Propiedades de la distribución Power Series . . . 234
22.1.17 Definición Distribución Weibull Discreta . . . 234
22.1.17 Teorema Propiedades de la distribución Weibull Discreta . . . 235
22.1.18 Definición Distribución Rectangular Discreta . . . 235
22.1.18 Teorema Propiedades de la distribución Rectangular Discreta . . . 235
22.1.19 Definición Distribución Benford . . . 236
22.1.19 Teorema Propiedades de la distribución Benford . . . 236
22.2.1 Definición Distribución Normal . . . 237
22.2.1 Teorema Propiedades de la distribución Normal . . . 237
22.2.2 Definición Distribución Exponencial . . . 238
22.2.2 Teorema Propiedades de la distribución Exponencial . . . 238
22.2.3 Definición Distribución Uniforme Continua . . . 239
22.2.3 Teorema Propiedades de la distribución Uniforme Continua . . . 239
22.2.4 Definición Distribución Gamma . . . 241
22.2.4 Teorema Propiedades de la distribución Gamma . . . 241
22.2.5 Definición Distribución Beta . . . 242
22.2.5 Teorema Propiedades de la distribución Beta/ . . . 242
22.2.6 Definición Distribución Chi-cuadrado . . . 242
22.2.6 Teorema Propiedades de la distribución Chi-cuadrado . . . 243
22.2.7 Definición Distribución t de Student . . . 243
22.2.7 Teorema Propiedades de la distribución t de Student . . . 244
22.2.8 Definición Distribución F de Fisher–Snedecor . . . 244
22.2.8 Teorema Propiedades de la distribución F . . . 244
22.2.9 Definición Distribución Log-normal . . . 245
22.2.9 Teorema Propiedades de la distribución Log-normal . . . 245
22.2.10 Definición Distribución Weibull . . . 246
22.2.10 Teorema Propiedades de la distribución Weibull . . . 246
22.2.11 Definición Distribución Laplace Asimétrica . . . 247
22.2.11 Teorema Propiedades de la distribución Laplace Asimétrica . . . 247
22.2.12 Definición Distribución Logística Generalizada . . . 248
22.2.12 Teorema Propiedades de la distribución Logística Generalizada . . . 248
22.2.13 Definición Distribución Rayleigh . . . 249
22.2.13 Teorema Propiedades de la distribución Rayleigh . . . 249

22.2.14 Definición Distribución Gaussiana Inversa . . . 250
22.2.14 Teorema Propiedades de la distribución Gaussiana Inversa . . . 250
22.2.15 Definición Distribución Pareto . . . 251
22.2.15 Teorema Propiedades de la distribución Pareto . . . 251
22.2.16 Definición Distribución Cauchy . . . 252
22.2.16 Teorema Propiedades de la distribución Cauchy . . . 252
22.2.17 Definición Distribución Gompertz . . . 252
22.2.17 Teorema Propiedades de la distribución Gompertz . . . 253
22.2.18 Definición Distribución de Valor Extremo . . . 253
22.2.18 Teorema Propiedades de la distribución de Valor Extremo . . . 253
22.2.19 Definición Distribución Gamma Generalizada . . . 254
22.2.19 Teorema Propiedades de la distribución Gamma Generalizada . . . 254
22.2.20 Definición Distribución Pareto Generalizada . . . 254
22.2.20 Teorema Propiedades de la distribución Pareto Generalizada . . . 254
22.2.21 Definición Distribución t No Central . . . 255
22.2.21 Teorema Propiedades de la distribución t No Central . . . 255
22.2.22 Definición Distribución F No Central . . . 256
22.2.22 Teorema Propiedades de la distribución F No Central . . . 256
22.2.23 Definición Distribución Chi-cuadrado No Central . . . 256
22.2.23 Teorema Propiedades de la distribución Chi-cuadrado No Central . . . 256
22.2.24 Definición Distribución Beta No Central . . . 257
22.2.24 Teorema Propiedades de la distribución Beta No Central . . . 257
22.2.25 Definición Distribución F Doble No Central . . . 257
22.2.25 Teorema Propiedades de la distribución F Doble No Central . . . 257
22.2.26 Definición Distribución Log-gamma . . . 257
22.2.26 Teorema Propiedades de la distribución Log-gamma . . . 258
22.2.27 Definición Distribución Log-logística . . . 258
22.2.27 Teorema Propiedades de la distribución Log-logística . . . 258
22.2.28 Definición Distribución Hiperexponencial . . . 259
22.2.28 Teorema Propiedades de la distribución Hiperexponencial . . . 259
22.2.29 Definición Distribución Hipoexponencial . . . 260
22.2.29 Teorema Propiedades de la distribución Hipoexponencial . . . 260
22.2.30 Definición Distribución Makeham . . . 260
22.2.30 Teorema Propiedades de la distribución Makeham . . . 261
22.2.31 Definición Distribución Lomax . . . 261
22.2.31 Teorema Propiedades de la distribución Lomax . . . 261
22.2.32 Definición Distribución Muth . . . 262
22.2.32 Teorema Propiedades de la distribución Muth . . . 262
22.2.33 Definición Distribución Von Mises . . . 263
22.2.33 Teorema Propiedades de la distribución Von Mises . . . 263
22.2.34 Definición Distribución Arcsin . . . 263
22.2.34 Teorema Propiedades de la distribución Arcsin . . . 263
22.2.35 Definición Distribución Arctangent . . . 264
22.2.35 Teorema Propiedades de la distribución Arctangent . . . 264
22.2.36 Definición Distribución Power . . . 265
22.2.36 Teorema Propiedades de la distribución Power . . . 265
22.2.37 Definición Distribución Power estándar . . . 266
22.2.37 Teorema Propiedades de la distribución Power estándar . . . 266
22.2.38 Definición Distribución Normal Estándar . . . 267
22.2.38 Teorema Propiedades de la distribución Normal Estándar . . . 267
22.2.39 Definición Distribución Cauchy estándar . . . 268
22.2.39 Teorema Propiedades de la distribución Cauchy estándar . . . 268
22.2.40 Definición Distribución Triangular estándar . . . 269
22.2.40 Teorema Propiedades de la distribución Triangular estándar . . . 269

22.2.41 Definición Distribución Wald estándar . . . 270
22.2.41 Teorema Propiedades de la distribución Wald estándar . . . 270
22.2.42 Definición Distribución Minimax . . . 270
22.2.42 Teorema Propiedades de la distribución Minimax . . . 271
22.2.43 Definición Distribución IDB . . . 271
22.2.43 Teorema Propiedades de la distribución IDB . . . 271
22.2.44 Definición Distribución Error . . . 271
22.2.44 Teorema Propiedades de la distribución Error . . . 272
22.2.45 Definición Distribución Exponential Power . . . 272
22.2.45 Teorema Propiedades de la distribución Exponential Power . . . 272
22.2.46 Definición Distribución Triangular . . . 273
22.2.46 Teorema Propiedades de la distribución Triangular . . . 273
22.2.47 Definición Distribución TSP . . . 274
22.2.47 Teorema Propiedades de la distribución TSP . . . 274
22.3.1 Definición Transformada de Laplace . . . 275
22.3.2 Definición Transformada de Fourier . . . 275
22.3.3 Definición Transformada de Mellin . . . 275
22.3.4 Definición Transformada de Hilbert . . . 275
22.3.5 Definición Transformada de Abel . . . 276
22.3.6 Definición Transformada de Stieltjes . . . 276
22.3.7 Definición Transformada de Weierstrass (Gauss-Weierstrass) . . . 276
22.3.1 Lema Linealidad . . . 276
22.3.1 Teorema Transformada de Laplace de la derivada . . . 276
22.3.2 Lema Transformada de Laplace de la integral . . . 276
22.3.2 Teorema Convolución de Laplace . . . 277
22.3.3 Teorema Valor inicial y final de Laplace . . . 277
22.3.4 Teorema Inversión de Laplace (fórmula de Bromwich) . . . 277
22.3.5 Teorema Transformada de Fourier de la derivada . . . 277
22.3.6 Teorema Convolución de Fourier . . . 278
22.3.7 Teorema Identidad de Parseval-Plancherel . . . 278
22.3.8 Teorema Inversión de Fourier . . . 278
22.3.9 Teorema Principio de incertidumbre de Heisenberg . . . 278
22.3.3 Lema Relación entre Mellin y Fourier . . . 278
22.3.10 Teorema Inversión de Mellin . . . 279
22.3.11 Teorema Acotación de la transformada de Hilbert en L^p . . . 279
22.3.12 Teorema Involución de la transformada de Hilbert . . . 279
22.3.4 Lema Relación de Hilbert con Fourier . . . 279
22.3.5 Lema Relación entre Laplace y Stieltjes . . . 279
22.3.6 Lema Relación entre Abel y Fourier . . . 279
22.3.13 Teorema Transformada de Weierstrass como solución del calor . . . 280
22.3.7 Lema Relación entre Weierstrass y Fourier . . . 280