

Resumen Probabilidad y Estadística

Anthony Flores Rojas

Buenos días Costa Rica. No se
complique, viva feliz. Vivan la vida como
una lombriz.

Contenido

Prefacio	1
1 Un poco de combinatoria enumerativa	4
1.1 El principio básico de conteo	4
1.2 Permutaciones básicas	5
1.3 Combinaciones y selecciones	6
1.4 Teorema multinomial	7
2 Teoría de la medida y probabilidad.	9
2.1 Anillos y funciones en anillos	9
2.1.1 Funciones en anillos	10
2.1.2 Medidas	12
2.2 Álgebras y medidas de probabilidad	12
2.2.1 Álgebra	13
2.2.2 Medidas de probabilidad	14
2.2.3 Semialgebra y sistemas	15
2.3 Más sobre la medida	16
2.3.1 Medida exterior	17
2.3.2 Medida de Stieltjes	20
2.3.3 Integración de funciones simples	20
2.3.4 Integración para funciones acotadas	21
2.3.5 Integración para funciones no negativas	22
2.3.6 Integración para funciones medibles	23
2.3.7 Sucesiones de funciones	24
2.3.8 Teorema Riemann-Lebesgue	26
2.3.9 Medida del producto	26
2.3.10 Teorema de Fubini-Tonelli	28
2.4 L^p	29
2.4.1 Desigualda de Hölder y Minkowski	29
2.4.2 Propiedades de L^p	30
2.4.3 Medida signada	32
2.4.4 Descomposición de Hahn y Jordan	33
2.4.5 Radon-Nikodym	36
2.5 Probabilidades curiosas	36
2.6 Probabilidades condicionales	37
2.7 Eventos independientes	38
3 Variables aleatorias	39
3.1 Funciones medibles	39
3.2 Propiedades de la variables aleatorias	40
3.3 Distribución de probabilidad	42
3.3.1 Distribucion acumulada	43
3.3.2 Función de Stieltjes	44
3.4 V.A. continua y absolutamente continua	46
3.5 Esperanza	47
3.5.1 Propiedades de la esperanza	47
3.6 Media, varianza y momentos	50
3.7 Función generadora de momentos	51

3.7.1	Propiedades de la función generadora de momentos	51
3.8	Función característica	53
4	Vectores aleatorios	56
4.0.1	Distribucion de vectores aleatorios	56
4.1	Esperanza de vectores aleatorios	59
4.2	Varianza, covarianza y correlación	60
4.3	Independencia de vectores aleatorios	62
4.3.1	Esperanza independiente	63
4.3.2	Propiedades de la distribucion condicional	64
4.4	Esperanza condicional	65
4.4.1	Propiedades de la esperanza regular	66
4.5	Convergencia de variables aleatorias	68
4.5.1	Convergencia casi segura	68
4.5.2	Convergencia en L^p	68
4.5.3	Convergencia en distribucion	69
4.5.4	Convergencia en probabilidad	69
4.5.5	Teorema de convergencia	69
4.5.6	Desigualdad de Chebyshev	71
5	Ley de los grandes números.	72
5.0.1	Variables no correlacionadas	72
5.0.2	Ley debil en L^2	73
5.0.3	Ley de los Grandes Números con truncamiento para colas ligeras	75
5.1	Lema de Borel-Cantelli	76
5.1.1	Ley débil de los grandes números	77
5.1.2	Segundo lema de Borel-Cantelli	79
5.1.3	Ley fuerte de los grandes números	81
5.2	Teoria de Renovación	82
5.3	Desviación grande	83
6	Teorema del limite central	85
6.1	Convergencia débil	86
6.2	Teorema de limite local	91
6.3	Convergencia de Poisson	92
6.4	Ley estable	93
6.5	Distribuciones infinitamente divisibles	94
6.6	Teorema limite en $\mathbb{R}$	95
7	Cadenas de Markov	99
7.1	Cadenas de Markov	99
7.2	Clasificación de Estados	102
7.3	Distribucion estacionaria	109
8	Martingales	112
8.1	Definición y Propiedades Básicas	112
8.2	Tiempos de Parada	115
8.3	Parada Opcional	115
8.4	Desigualdades para Submartingalas	116
8.5	Convergencia de Martingalas	117
9	Martingalas en Tiempo Continuo	120
9.1	Procesos de Poisson	122
9.2	Procesos Compuestos de Poisson	126
9.3	El Movimiento Browniano	127
9.3.1	Movimiento Browniano y Procesos Gaussianos	127
9.3.2	Las Trayectorias del Movimiento Browniano	131
9.3.3	Movimiento Browniano y Procesos de Markov	134

10 Inferencia	138
10.1 Tipos de inferencia	139
10.2 Densidades previas y conjugadas	139
10.3 Distribucion posterior	140
10.4 Distribuciones previas conjugadas	141
10.5 Estimador bayesiano y las funciones de perdida	143
10.6 Estimador de bayes para muestras grandes	144
10.6.1 Consistencia	144
10.7 Estimadores de máxima verosimilitud y sus propiedades	145
10.8 Estadístico suficiente	146
10.9 Estimadores insesgados	147
10.10 Mejorando el estimador	149
11 Distribuciones Muestrales de Estimadores	150
11.1 Distribución t de Student	151
12 Anexo	153
12.1 Distribuciones de probabilidad discretas	154
12.1.1 Distribución de Bernoulli	154
12.1.2 Distribución binomial	155
12.1.3 Distribución Geométrica	156
12.1.4 Distribución de Poisson	157
12.1.5 Distribución hipergeométrica	158
12.1.6 Distribución de Pascal	159
12.1.7 Distribución uniforme discreta	160
12.1.8 Distribución zeta	161
12.1.9 Distribución zipf	162
12.1.10 Distribución beta-binomial	163
12.1.11 Distribución hipergeométrica negativa	163
12.1.12 Distribución de Polya	164
12.1.13 Distribución logarítmica	164
12.1.14 Distribución gamma-poisson	165
12.1.15 Distribución beta-pascal	165
12.1.16 Distribución power series	167
12.1.17 Distribución Weibull discreta	168
12.1.18 Distribución rectangular discreta	169
12.1.19 Distribución Benford	170
12.2 Distribuciones de probabilidad continuas	171
12.2.1 Distribución normal	171
12.2.2 Distribución exponencial	172
12.2.3 Distribución uniforme continua	173
12.2.4 Distribución gamma	174
12.2.5 Distribución beta	175
12.2.6 Distribución chi-cuadrado	176
12.2.7 Distribución t de student	177
12.2.8 Distribución F de Fisher-Snedecor	178
12.2.9 Distribución Log-normal	179
12.2.10 Distribución Weibull	180
12.2.11 Distribución Laplace Asimétrica	181
12.2.12 Distribución logística generalizada	182
12.2.13 Distribución Rayleigh	183
12.2.14 Distribución gaussiana inversa	184
12.2.15 Distribución Pareto	185
12.2.16 Distribución Cauchy	187
12.2.17 Distribución Gompertz	188
12.2.18 Distribución valor extremo	189
12.2.19 Distribución gamma generalizada	190
12.2.20 Distribución Pareto generalizada	190

12.2.21	Distribución t no central	191
12.2.22	Distribución F no central	192
12.2.23	Distribución χ^2 no central	193
12.2.24	Distribución beta no central	194
12.2.25	Distribución F doble no central	194
12.2.26	Distribución log-gamma	194
12.2.27	Distribución log-logística	195
12.2.28	Distribución hiperexponencial	196
12.2.29	Distribución hipoexponencial	197
12.2.30	Distribución Makeham	198
12.2.31	Distribución lomax	199
12.2.32	Distribución Muth	200
12.2.33	Distribución Von Mises	201
12.2.34	Distribución arcsin	202
12.2.35	Distribución arctangent	203
12.2.36	Distribución power	204
12.2.37	Distribución power estándar	206
12.2.38	Distribución normal estándar	207
12.2.39	Distribución Cauchy estándar	208
12.2.40	Distribución triangular estándar	209
12.2.41	Distribución Wald estándar	210
12.2.42	Distribución minimax	211
12.2.43	Distribución IDB	211
12.2.44	Distribución error	212
12.2.45	Distribución exponential power	213
12.2.46	Distribución triangular	214
12.2.47	Distribución TSP	215
12.3	Transformadas	216

Prefacio

Este documento no solo toma como referencia las notas del curso tomadas por mi persona, se le suma el documento de el libro *Probability: Theory and Examples by Rick Durrett*, *Introducción a la Probabilidad de Jose David Cambos*, el libro *A First Course in Probability by Sheldon Ross*, *Combinatoria enumerativa de Eduardo Piza* y demás apuntes tomados de diferentes libros o artículos. Cabe aclarar que no todas las demostraciones son propias, sumado a ello se requieren conocimientos en calculo en varias variables y análisis real.

Parte I

1

Un poco de combinatoria enumerativa

1.1 El principio básico de conteo

Para empezar, primero se vera conceptos básicos de combinatoria como una introducción a la probabilidad, ya que la combinatoria nos permite conocer la cantidad de variaciones que podemos obtener poniendo ciertas condiciones a un conjunto de elementos.

Proposición 1.1.1. El principio básico de conteo. Suponga que un experimento a puede tener cualquiera de n posible resultados, y un experimento b puede tener cualquiera de m posibles resultados, en consecuencia, hay mn posibilidades resultados al realizar los dos experimentos a la vez.

Demostración. Note que para cada posible resultado del experimento a , existen m posible resultados del experimento b , donde podemos enumerar entonces todos los resultados de ambos elementos de la siguiente forma

$$\begin{array}{cccc} (1,1) & (1,2) & \cdots & (1,n) \\ (2,1) & 2,2 & \cdots & (2,n) \\ \vdots & \vdots & \ddots & \vdots \\ (m,1) & (m,2) & \cdots & (m,n) \end{array} \quad (1.1)$$

Donde cada (i,j) son los posibles resultados de los dos experimentos a la vez, en cuyo caso, tenemos que hay nm posibles resultados.

□

1.2 Permutaciones básicas

El siguiente resultado es uno de los mas utilizados e importantes es cuanto a permutaciones.

Proposición 1.2.1. Conteo de permutaciones. Si tenemos n objetos distintos entre si, entonces el numero de permutaciones tomando n de los mismo, es $n!$.

Demostración. Note que para la primera concrecencia tenemos n posibles elecciones, para la siguiente tenemos todos excepto ese mismo o lo que es igual a $n - 1$ elecciones, para la siguiente tendremos $n - 2$ posibles elecciones, así hasta que nos quedemos con el ultimo y restante objetos que elegir; utilizando la Proposición del principio básico de conteo, tenemos que el total de los posibles resultados del experimento es la multiplicación de los posibles resultados individuales, en consecuencia el numero de permutaciones totales es $n(n - 1)(n - 2) \cdots 1 =: n!$. □

Ahora, si tenemos en cuenta que alguno o varios de los objetos se pueden repetir, claramente esto nos disminuiría la cantidad de objetos que podemos elegir para las permutaciones, mejor dicho, nos quita la cantidad de permutaciones que involucran a ese objeto.

Teorema 1.2.1. Teorema del coeficiente multinomial. Suponga que tenemos n objetos, y hay m diferentes tipos de objetos entre si con n_i la cantidad de cada distinción, entonces la cantidad de permutaciones totales es

$$\binom{n}{n_1, n_2, \dots, n_{m-1}} := \frac{n!}{n_1! n_2! \cdots n_m!}. \quad (1.2)$$

Con $n_1 + n_2 + \cdots + n_m = n$.

Demostración. Note que si tenemos que n_1 objetos se repiten, entonces estos se puede permutar de $n_1!$ formas, en cuyo caso tenemos que el numero que posibles permutaciones sin que ningún objeto n_1 permute es $n!/n_1!$, si repetimos esto con cada grupo distinguible tenemos que el numero total de permutaciones sin que ninguno de ellos se repita es

$$\frac{n!}{n_1! n_2! \cdots n_m!}.$$

□

Ahora, tomemos el primer caso de las permutaciones, si solo tomamos m objetos de los n con cuantos nos quedaríamos

Proposición 1.2.2. Permutaciones sin repetición. El numero de permutaciones de n objetos distintos entre si, solo tomando $m \leq n$ de ellos es

$$[n]_m := \frac{n!}{(n - m)!}. \quad (1.3)$$

Demostración. Note que solo estamos tomando m de estos objetos, entonces estamos eliminando $n - m$ de estos utilizando la Proposición de conteo de permutaciones podríamos asumir que estos objetos que no tenemos tan solo están repetidos, con esto concluiría la demostración □

Note que si no nos interesa el orden de los mismo, solo habría que eliminar las m permutaciones de los m objetos seleccionados.

Para el siguiente caso se va a ver el numero de permutaciones eligiendo de un conjunto de n objetos con la posibilidad de repetición.

Proposición 1.2.3. Permutaciones con repetición. Si tomamos m objetos de un conjunto de n objetos permitiendo la repetición de los mismo, la cantidad de posibles permutaciones es n^m .

Demostración. Note que para cada elecciones independiente tenemos que hay n posibles objetos a elegir, utilizando el principio básico de conteo, tenemos m experimentos realizados a la vez, en cuyo caso el numero total de permutaciones sera

$$\underbrace{n \cdots n}_m = n^m. \quad (1.4)$$

□

1.3 Combinaciones y selecciones

Teorema 1.3.1. Teorema de las estrellas y barras. Suponga que tenemos m objetos distintos entre si, y tenemos n cajas ordenadas, entonces la cantidad de posibles distribuciones ordenadas de los mismo es

$$[n]^m := \frac{(n + m - 1)!}{(n - 1)!}. \quad (1.5)$$

Demostración. Note que podemos tomar la separación de cada caja como un objeto mas, ya que nos define el momento en el que se dio un cambio en el orden de los objetos

$$\underbrace{i_1 \cdots i_k}_{\text{caja 1}} \mid \underbrace{i_{k+1} \cdots i_{j+k}}_{\text{caja 2}} \mid \cdots \mid \underbrace{i_m}_{\text{caja n}}. \quad (1.6)$$

□

Utilizando la Proposición de las permutaciones sin reposición, podemos ver que cada caja se puede tomar como un objeto del tipo raya $|$, que son todos iguales entre si, teniendo $n - 1$ de ellos en las permutaciones; mientras que los m objetos son distintos entre si, entonces tenemos $m + n - 1$ objetos con $n - 1$ iguales entre si, en consecuencia hay $[n]^m$ posibles permutaciones.

Proposición 1.3.1. Principio del producto. Suponga que tenemos m objetos distintos entre si, y tenemos n cajas ordenadas, entonces la cantidad de posibles distribuciones sin importar el orden de los mismo es n^m .

La demostración queda como ejercicio para el lector.

Teorema 1.3.2. Soluciones de una ecuación lineal. El numero de soluciones en $\mathbb{N}_0$ de la ecuación lineal $x_1 + x_2 + \cdots + x_n = m$ es

$$\frac{[n]^m}{m!}.$$

Demostración. Tome cada elemento x_i como una caja, y note que análogamente al Teorema de estrellas y barras tenemos $[n]^m$ posibles maneras de distribuir 1 (Donde si distribuimos $j \leq m$ de los objetos 1 en x_i , entonces $x_i = j$) en cada una de las cajas. Dado que cada objeto 1 es igual entre si, tenemos que eliminar las posible m permutaciones de los mismo.

□

Una consecuencia de esto es que si uno de los $x_i \geq k$ entonces $x_i - k \geq 0$ y podemos escribir en su lugar $x_1 + \cdots + (x_i - k) + \cdots + x_n = m - k$.

Proposición 1.3.2. Principio multiplicativo para selecciones independientes. Suponga que tenemos N objetos divididos en r grupos conteniendo cada uno N_r objetos, entonces si tomamos n objetos de los N iniciales, el total de diferentes selecciones sin importar el orden de los objetos es

$$\binom{N_1}{n_1} \binom{N_2}{n_2} \cdots \binom{N_r}{n_r}. \quad (1.7)$$

Donde $n_i \leq N_i$ es la cantidad de objetos tomados de N_i .

La demostración queda como ejercicio para el lector. Note simplemente que cada caso de selección es independiente y el orden de la misma no importa.

Proposición 1.3.3. selección no consecutiva. Si tenemos n objetos en línea recta, y seleccionamos m de ellos de manera no consecutiva, el número de posibles selecciones es.

$$\binom{n-m+1}{m}.$$

Demostración. Utilizando la ilustración de las cajas y el Teorema de estrellas y barras, tenemos que de los n objetos $m-1$ no los podemos seleccionar (Son los objetos que separan a los que vamos a seleccionar), entonces en realidad tendremos $n-m+1$ objetos a seleccionar, de los cuales seleccionaremos como m de ellos, entonces tenemos $[n-m+1]_m$ posibles selecciones, pero tenemos que recordar que los elementos m pueden permutar entre sí a la hora de la selección, en consecuencia tendremos que eliminar estas permutaciones de las selecciones, entonces tenemos que el número de posibles selecciones es

$$\frac{[n-m+1]_m}{m!} = \binom{n-m+1}{m}. \quad (1.8)$$

□

1.4 Teorema multinomial

Teorema 1.4.1. Teorema multinomial. Sea $x_i \in \mathbb{C}, \forall_{i \leq k}$, entonces

$$(x_1 + x_2 + \cdots + x_k)^n = \sum_{n_1 + \cdots + n_k = n} \binom{n}{n_1, \dots, n_k} x_1^{n_1} \cdots x_k^{n_k}. \quad (1.9)$$

Demostración. Note que para $k=1$ es el teorema del binomio de Newton, cuya demostración se deja al lector.

Suponga entonces que se cumple para k , entonces podemos tomar

$$(x_1 + \cdots + x_k + x_{k+1})^n (y + x_{k+1})^n \mid y = x_1 + \cdots + x_k.$$

Lo ponemos tomar como

$$\begin{aligned} (y + x_{k+1})^n &= \sum_{l=0}^n \frac{n!}{l!(n-l)!} y^l x_{k+1}^{n-l} = \sum_{l=0}^n \frac{n!}{l!(n-l)!} \left(\sum_{n_1 + \cdots + n_k = l} \binom{l}{n_1, \dots, n_k} x_1^{n_1} \cdots x_k^{n_k} \right) x_{k+1}^{n-l} \\ &= \sum_{l=0}^n \sum_{n_1 + \cdots + n_k = l} \frac{n!}{l!(n-l)!} \binom{l}{n_1, \dots, n_k} x_1^{n_1} \cdots x_k^{n_k} x_{k+1}^{n-l} \\ &= \sum_{l=0}^n \sum_{n_1 + \cdots + n_k = l} \frac{n!}{l!(n-l)!} \frac{l!}{n_1! \cdots n_k!} x_1^{n_1} \cdots x_k^{n_k} x_{k+1}^{n-l} \end{aligned}$$

$$= \sum_{n_1 + \dots + n_k + n_{k+1} = n} \binom{n}{n_1, \dots, n_{k+1}} x_1^{n_1} \dots x_{k+1}^{n_{k+1}}.$$

□

2

Teoría de la medida y probabilidad.

2.1 Anillos y funciones en anillos

Definición 2.1.1. Anillos conjuntivos. Un anillo es una familia $\mathcal{R}$ de conjuntos si para $A, B \in \mathcal{R}$ entonces

$$A \cup B \in \mathcal{R}, \quad (2.1)$$

$$A \setminus B \in \mathcal{R}. \quad (2.2)$$

Más aun, si $A_n \in \mathcal{R}, \forall_{n \in \mathbb{N}}$ es llamado un σ -anillo si

$$\bigcup_{n=1}^{\infty} A_n \in \mathcal{R}. \quad (2.3)$$

Proposición 2.1.1. Intersección y unión de anillos. Sea $\mathcal{R}$ un anillo con $A_i \in \mathcal{R}, \forall_{i \in \mathbb{N}_{\leq n}}$ entonces

$$\bigcup_{i=1}^n A_i \in \mathcal{R}, \quad (2.4)$$

$$\bigcap_{i=1}^n A_i \in \mathcal{R}, \quad (2.5)$$

Demostración. Sean $A_i \in \mathcal{R}$ con $1 \leq i \leq n$. Utilizando la propiedad de la unión del anillo se tiene que

$$\left(((A_1 \in \mathcal{R} \wedge A_2 \in \mathcal{R} \Rightarrow A_1 \cup A_2 \in \mathcal{R}) \wedge A_3 \in \mathcal{R} \Rightarrow \dots) \Rightarrow \bigcup_{i=1}^{n-1} A_i \in \mathcal{R} \right) \wedge A_n \in \mathcal{R} \Rightarrow \bigcup_{i=1}^n A_i \in \mathcal{R}.$$

Para la segunda propiedad, utilizando lo anteriormente demostrado y la definición de anillo, se tiene que

$$\mathcal{R} \ni \bigcap_{i=1}^n A_i = A_1 \setminus \bigcup_{i=1}^n (A_1 \setminus A_n).$$

□

Proposición 2.1.2. Intersección de σ -anillos. Sea $\mathcal{R}$ un σ -anillo, entonces $\mathcal{R}$ es un anillo. Sumado a ello si tenemos que $A_n \in \mathcal{R}, \forall n \in \mathbb{N}$, entonces

$$\bigcap_{n=1}^{\infty} A_n \in \mathcal{R}. \quad (2.6)$$

Sea $\mathcal{A}$ otro σ -anillo, si $\mathcal{R} \cap \mathcal{A} \neq \emptyset$, entonces

$$\mathcal{R} \cap \mathcal{A} \text{ es un } \sigma\text{-anillo}. \quad (2.7)$$

Demostración. Tome $B_i := \{B_1 = A_1, B_2 = A_2, A_{i>2} = \emptyset\}$ entonces es claro que $A_1 \cup A_2 \in \mathcal{R}$. Ahora note que utilizando la proposición anterior podemos ver como

$$\mathcal{A} \ni \bigcap_{i=1}^{\infty} A_i = A_1 \setminus \bigcup_{i=1}^{\infty} (A_1 \setminus A_n).$$

Para la intersección de anillos se puede ver que si

$$A, B \in \mathcal{R} \cap \mathcal{A} \Rightarrow A \cup B \in \mathcal{R} \wedge A \cup B \in \mathcal{A} \Rightarrow A \cup B \in \mathcal{R} \cap \mathcal{A},$$

$$A, B \in \mathcal{R} \cap \mathcal{A} \Rightarrow A \setminus B \in \mathcal{R} \wedge A \setminus B \in \mathcal{A} \Rightarrow A \setminus B \in \mathcal{R} \cap \mathcal{A},$$

$$\bigcup_{n=1}^{\infty} A_n \in \mathcal{R} \cap \mathcal{A} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{R} \wedge \bigcup_{n=1}^{\infty} A_n \in \mathcal{A} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{R} \cap \mathcal{A},$$

por lo tanto $\mathcal{R} \cap \mathcal{A}$ es una σ -anillo.

□

2.1.1 Funciones en anillos

Definición 2.1.2. Recta real extendida.

$$\overline{\mathbb{R}} := \mathbb{R} \cup \{\infty\}. \quad (2.8)$$

Definición 2.1.3. Unión disjunta.

$$\bigsqcup_{n=1}^{\infty} A_n \quad (2.9)$$

denota la unión de conjuntos disjuntos, es decir, $A_i \cap A_j = \emptyset$ si $i \neq j$.

Definición 2.1.4. Función aditiva. La función $\phi : \mathcal{R} \rightarrow \overline{\mathbb{R}}$ es aditiva si para $A, B \in \mathcal{R}$ disjuntos, tenemos que

$$\phi(A \cup B) = \phi(A) + \phi(B) \quad (2.10)$$

Se le llama aditiva contable si

$$\phi\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \phi(A_n) \quad (2.11)$$

Teorema 2.1.1. Aditividad. Sea ϕ contable aditiva sobre un anillo $\mathcal{R}$ si $A_n \in \mathcal{R}, \forall n \in \mathbb{N}$, entonces

$$\phi(\emptyset) = 0, \quad (2.12)$$

$$\text{Si } \phi \text{ es aditiva contable entonces es aditiva,} \quad (2.13)$$

$$\text{Si } A_1 \subset A_2 \text{ y } \forall i \in \mathbb{N} (\phi(A_i) \geq 0) \text{ entonces } \phi(A_1) \leq \phi(A_2), \quad (2.14)$$

$$\text{Si } |\phi(A_1)| < \infty \text{ entonces } \phi(A_2 \setminus A_1) = \phi(A_2) - \phi(A_1), \quad (2.15)$$

$$\phi(A_1 \cup A_2) = \phi(A_1) + \phi(A_2) - \phi(A_1 \cap A_2). \quad (2.16)$$

Si A_n es una sucesión creciente (o decreciente) y $\lim_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} A_n$ o $\left(\lim_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} A_n \right)$ entonces

$$\phi\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} \phi(A_n). \quad (2.17)$$

Demostración. Para la primera propiedad note que por la definicion de contabilidad aditiva tenemos que

$$\phi(A_1) = \phi(A_1 \cup \emptyset \cup \emptyset \cup \emptyset \dots) = \phi(A_1) + \sum_{k=1}^{\infty} \phi(\emptyset) \Rightarrow \phi(\emptyset) = 0.$$

Continuando con la segunda propiedad, dado que $A_1 \cap A_2 = \emptyset$ y utilizando la definicion de contable aditiva se puede ver que

$$\phi(A_1 \cup A_2 \cup \emptyset \cup \emptyset \dots) = \phi(A_1) + \phi(A_2) + \sum_{k=1}^{\infty} \phi(\emptyset) = \phi(A_1) + \phi(A_2).$$

Para las siguientes dos podemos ver que $A_2 = A_1 \cup (A_2 \setminus A_1)$, donde $(A_2 \setminus A_1) \cap A_1 = \emptyset$, entonces

$$\phi(A_2) = \phi(A_1) + \phi(A_2 \setminus A_1),$$

$$\Rightarrow \phi(A_2) - \phi(A_1) = \phi(A_2 \setminus A_1) \quad \wedge \quad \phi(A_1) \leq \phi(A_1) + \phi(A_2 \setminus A_1) = \phi(A_2).$$

Al igual que en la demostración anterior, podemos tomar uniones disjuntas tales que

$$A_1 = A_1 \setminus A_2 \cup (A_1 \cap A_2) \quad \wedge \quad A_1 \cup A_2 = A_2 \setminus A_2 \cup A_2 \setminus A_1 \cup (A_1 \cap A_2),$$

entonces

$$\phi(A_1 \cup A_2) = \phi(A_1 \setminus A_2) + \phi(A_2 \setminus A_1) + \phi(A_1 \cap A_2) = \phi(A_1) + \phi(A_2) - \phi(A_1 \cap A_2).$$

Para la ultima, si la sucesión es creciente tenemos que $A_n \subset A_{n+1}$, entonces podemos tomar $B_n := A_n - A_{n-1}$ con $B_1 := A_1$, entonces $B_n \cap B_{n+1} = \emptyset$ y $\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n = A_n$, en consecuencia

$$\phi\left(\lim_{n \rightarrow \infty} A_n\right) = \phi\left(\bigcup_{n=1}^{\infty} A_n\right) = \phi\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \phi(B_n) = \sum_{n=1}^{\infty} \phi(A_n) - \phi(A_{n-1}) = \lim_{n \rightarrow \infty} \phi(A_n).$$

Para el otro caso tome $A_i \setminus A_n$ de forma que $\exists_{i \in \mathbb{N}} |\phi(A_i)| < \infty$ (note que es sucesión decreciente convergente a $A_i \setminus A$), entonces $\phi(A_i \setminus A_n)$ converge a $\phi(A_i \setminus A)$ y dado que $A \subset A_i$ tenemos que

$$\phi(A_n) = \phi(A_i \setminus A_n) + \phi(A_i) \xrightarrow{n \rightarrow \infty} \phi(A_i \setminus A) + \phi(A_i) = \phi(A).$$

□

Corolario 2.1.1. Separación de la suma de una función contable aditiva. Sea ϕ contable aditiva sobre $\mathcal{R}$ si $A_n \in \mathcal{R}, \forall n \in \mathbb{N}$, entonces

$$\phi\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \phi(A_i). \quad (2.18)$$

Sumado a ello

$$\phi\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} \phi(A_i). \quad (2.19)$$

La demostración queda al lector.

Lema 2.1.1. Monotonía. Si $\phi : \mathcal{R} \rightarrow \overline{\mathbb{R}}$ es contablemente aditiva y no negativa, y $A \subseteq B$ con $A, B \in \mathcal{R}$, entonces

$$\phi(A) \leq \phi(B). \quad (2.20)$$

La demostración queda al lector.

2.1.2 Medidas

Definición 2.1.5. Medida. Una medida es una función $\mu : \mathcal{R} \rightarrow \overline{\mathbb{R}}$ contable aditiva no negativa.

La anterior definición tiene ciertos equivalentes, como cambiar el hecho de no negativa con $\mu(\emptyset) = 0$ y demás.

Definición 2.1.6. Espacio medible. Se dice que $(X, \mathcal{R})$ es un espacio medible si existe un σ -anillo $\mathcal{R}$ de los subconjuntos de X y μ es una medida sobre $\mathcal{R}$. Sumado a ello si $X \in \mathcal{R}$, $(X, \mathcal{R}, \mu)$ se dice ser un espacio de medida.

Definición 2.1.7. σ -finidad. Se dice que μ es σ -finita si existe una sucesión $B_n \in \mathcal{R}$ tal que $\mu(B_n) < \infty$ y $\bigcup_n B_n = A$. Si $\mu(A) < \infty$ entonces μ es llamada finita.

2.2 Álgebras y medidas de probabilidad

Definición 2.2.1. Espacio muestral. El conjunto de todos los posibles resultados de un experimento es llamado *espacio muestral* lo denotamos por Ω , a los elementos $\omega \in \Omega$ se les llama resultado o evento elemental.

Definición 2.2.2. Experimento. Un experimento es aleatorio si todos sus posibles resultados son conocidos, pero no se puede determinar el resultado hasta que ocurre.

Definición 2.2.3. Finito, contable o no. Se dice que el espacio muestral Ω es finito, discreto o continuo, cuando es un conjunto finito, contable o no contable.

2.2.1 Álgebra

Definición 2.2.4. Álgebra conjuntiva. La colección $\mathcal{A}$ de subconjuntos de Ω es llamada un campo o (álgebra) si

$$\mathcal{A} \text{ es no vacío,} \quad (2.21)$$

$$\text{si } A \in \mathcal{A} \text{ entonces } A^c \in \mathcal{A}, \quad (2.22)$$

$$\text{si } A, B \in \mathcal{A} \text{ entonces } A \cup B \in \mathcal{A}. \quad (2.23)$$

Ademas es llamado un σ -campo o (σ -álgebra o espacio de eventos) si

$$A_i \in \mathcal{A}, \forall_{i \in \mathbb{R}} \text{ entonces } \bigcup_{i \in \mathbb{R}} A_i \in \mathcal{A}. \quad (2.24)$$

Proposición 2.2.1. Relación entre anillos y álgebras. Todo álgebra de conjuntos es un anillo, pero no todo anillo es un álgebra.

La demostración queda al lector.

Proposición 2.2.2. Union, intersección y diferencia de álgebras. Sea $\mathcal{A}$ una álgebra con $A_n \in \mathcal{A}, \forall_{i \in \mathbb{N}_{\leq n}}$ entonces

$$\bigcup_{i=1}^n A_i \in \mathcal{A}, \quad (2.25)$$

$$\bigcap_{i=1}^n A_i \in \mathcal{A}, \quad (2.26)$$

$$A_1 \setminus A_2 \in \mathcal{A}. \quad (2.27)$$

Demostración. Para la primera propiedad observe que son propiedades hereditarias de los anillos.

Para la segunda utilizando lo anteriormente demostrado y la anterior se tiene que

$$\forall_{i \leq n} (A_i^c \in \mathcal{A}) \Rightarrow \bigcup_{i=1}^n A_i^c \in \mathcal{A} \Rightarrow \left(\bigcup_{i=1}^n A_i^c \right)^c \in \mathcal{A} \Rightarrow \bigcap_{i=1}^n A_i \in \mathcal{A}.$$

Y por ultimo simplemente note que

$$(A_1 \setminus A_2) \in \mathcal{A} \Rightarrow A_1^c \in \mathcal{A} \Rightarrow A_1^c \cup A_2 \in \mathcal{A} \Rightarrow A_1 \cap A_2^c = A_1 \setminus A_2 \in \mathcal{A} \in \mathcal{A}.$$

□

Proposición 2.2.3. Intersección de σ -álgebras Sea $\mathcal{A}$ una σ -álgebra entonces $\mathcal{A}$ es una álgebra, y con $A_n \in \mathcal{A}, \forall_{n \in \mathbb{N}}$ tenemos que

$$\bigcap_{n=1}^{\infty} A_n \in \mathcal{A}. \quad (2.28)$$

Si $\mathcal{F}$ es otra σ -álgebra, entonces

$$\mathcal{A} \cap \mathcal{F}. \quad (2.29)$$

es una σ -álgebra.

Al igual que la unión, la condición suficiente es que la sucesión sea contable. La demostración de la propiedad anterior es hereditaria de los anillos.

Corolario 2.2.1. La más pequeña σ -álgebra $\sigma(\cdot)$. Sea $\mathcal{F}$ una familia de conjuntos de Ω , entonces existe una única σ -álgebra sobre Ω , la cual es la más pequeña y $\mathcal{F}$ esta en ella. Usualmente es llamada $\sigma(\mathcal{F})$ o sigma álgebra de Borel .

La demostración queda al lector.

2.2.2 Medidas de probabilidad

Definición 2.2.5. Probabilidad. Si $(\Omega, \mathcal{F})$ es un espacio medible y $\mathbb{P}$ (también llamado μ) es una medida sobre $\mathcal{F}$ talque $\mathbb{P}(\Omega) = 1$ entonces, $\mathbb{P}$ es llamada una medida de probabilidad sobre $(\Omega, \mathcal{F})$

Definición 2.2.6. Espacio de probabilidad. Un espacio de probabilidad es la tripleta $(\Omega, \mathcal{F}, \mathbb{P})$ de los objetos tales que

$$\Omega \text{ es no vacío,} \quad (2.30)$$

$$\mathcal{F} \text{ es un espacio de eventos de } \Omega, \quad (2.31)$$

$$\mathbb{P} \text{ es una medida de probabilidad sobre } (\Omega, \mathcal{F}). \quad (2.32)$$

Teorema 2.2.1. Propiedades. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad con $A_1, A_2 \in \mathcal{F}$, entonces

$$\mathbb{P}(\emptyset) = 0, \quad (2.33)$$

$$\text{Si } A_1 \cap A_2 = \emptyset, \text{ entonces } \mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2), \quad (2.34)$$

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c), \forall A \in \mathcal{F}, \quad (2.35)$$

$$\text{Si } A_1 \subset A_2 \text{ entonces } \mathbb{P}(A_1) \leq \mathbb{P}(A_2), \mathbb{P}(A_2 \setminus A_1) = \mathbb{P}(A_2) - \mathbb{P}(A_1) \text{ y } \mathbb{P}(A) \leq 1 \forall A \in \mathcal{F}, \quad (2.36)$$

$$\mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2). \quad (2.37)$$

Si $(A_n)_n$ es una sucesión creciente o decreciente de conjuntos sobre $\mathcal{F}$, entonces

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n) \quad (2.38)$$

Demostración. Con lo demostrado anteriormente y con la definicion de medida podemos obtener que

$$\mathbb{P}(\Omega) = 1 = \mathbb{P}(A) + \mathbb{P}(A^c) \Rightarrow \mathbb{P}(A) = 1 - \mathbb{P}(A^c).$$

Las otras propiedades ya están demostradas. □

Corolario 2.2.2. Union de probabilidades. Sean $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad con $A_1, \dots, A_n \in \mathcal{F}$, entonces

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < \dots < i_k \leq n} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}). \quad (2.39)$$

Demostración. Caso $n = 1$ es trivial, suponga que se cumple para n , entonces note que

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i) - \sum_{1 \leq i_1 < i_2 \leq n} \mathbb{P}(A_{i_1} \cap A_{i_2}) + \sum_{1 \leq i_1 < i_2 < i_3 \leq n} \mathbb{P}(A_{i_1} \cap A_{i_2} \cap A_{i_3}) - \dots + \dots$$

$$+(-1)^{n-1}\mathbb{P}\left(\bigcap_{i=1}^n A_i\right).$$

En cuyo caso

$$\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) = \mathbb{P}\left(A_{n+1} \cup \bigcup_{i=1}^n A_i\right) = \mathbb{P}\left(\bigcup_{i=1}^n A_i\right) + \mathbb{P}(A_{n+1}) - \mathbb{P}\left(\bigcup_{i=1}^n A_i \cap A_{n+1}\right).$$

Donde

$$\begin{aligned} \mathbb{P}\left(\bigcup_{i=1}^n A_i \cap A_{n+1}\right) &= \sum_{i=1}^n \mathbb{P}(A_i \cap A_{n+1}) - \sum_{1 \leq i_1 < i_2 \leq n} \mathbb{P}(A_{i_1} \cap A_{i_2} \cap A_{n+1}) + \sum_{1 \leq i_1 < i_2 < i_3 \leq n} \mathbb{P}(A_{i_1} \cap A_{i_2} \cap A_{i_3} \cap A_{n+1}) - \\ &\quad \dots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^n A_i \cap A_{n+1}\right). \end{aligned}$$

Entonces se tiene que

$$\begin{aligned} \mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) &= \sum_{i=1}^{n+1} \mathbb{P}(A_i) - \sum_{1 \leq i_1 < i_2 \leq n+1} \mathbb{P}(A_{i_1} \cap A_{i_2}) + \sum_{1 \leq i_1 < i_2 < i_3 \leq n+1} \mathbb{P}(A_{i_1} \cap A_{i_2} \cap A_{i_3}) - \dots + \dots \\ &\quad + (-1)^n \mathbb{P}\left(\bigcap_{i=1}^{n+1} A_i\right). \\ \mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) &= \sum_{k=1}^{n+1} (-1)^{k+1} \sum_{1 \leq i_1 < \dots < i_k \leq n+1} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}). \end{aligned}$$

□

La siguiente parte se puede saltar hasta el (*), ya que la siguiente sección es solo una pincelada de algunos resultados de teoría de la medida.

2.2.3 Semialgebra y sistemas

Definición 2.2.7. Semialgebra. Una colección de conjuntos $\mathcal{S}$ es llamada una semialgebra si

$$A_1, A_2 \in \mathcal{S} \text{ entonces } A_1 \cap A_2 \in \mathcal{S}, \quad (2.40)$$

$$\text{Si } A \in \mathcal{S} \text{ entonces } A^c = \bigsqcup_i^n A_i, \text{ con } A_i \in \mathcal{S}. \quad (2.41)$$

Para dejar más claro lo anterior, A^c tiene que ser la unión finita de conjuntos disjuntos de $\mathcal{S}$.

Lema 2.2.1. Álgebra de semialgebra. Si $\mathcal{S}$ es una semialgebra, entonces

$$\overline{\mathcal{S}} := \left\{ \bigsqcup_{i=1}^n A_n : A_i \in \mathcal{S} \right\} \text{ es un álgebra.} \quad (2.42)$$

Demostración. Sean $A, B \in \overline{\mathcal{S}}$, de modo que $A = \bigsqcup_{i=1}^n A_i$ y $B = \bigsqcup_{j=1}^m B_j$ con $A_i, B_j \in \mathcal{S}$. Como $\mathcal{S}$ es semialgebra, $A_i \cap B_j \in \mathcal{S}, \forall_{i,j}$. Entonces

$$A \cap B = \bigsqcup_{i=1}^n \bigsqcup_{j=1}^m (A_i \cap B_j) \in \overline{\mathcal{S}},$$

Para el complemento, dado $A = \bigsqcup_{i=1}^n A_i$ se tiene $A^c = \bigcap_{i=1}^n A_i^c$. Como $\mathcal{S}$ es semialgebra, cada $A_i^c = \bigsqcup_k C_{i,k}$ con $C_{i,k} \in \mathcal{S}$, luego $A_i^c \in \overline{\mathcal{S}}$. Por lo anterior, la intersección finita $A^c = \bigcap_{i=1}^n A_i^c$ pertenece

a $\overline{\mathcal{P}}$. Las demás propiedades son triviales. □

Definición 2.2.8. π -sistema. Si $\mathcal{P}$ es una colección de conjunto cerrada ante intersección finita, entonces es llamado un π -sistema.

Definición 2.2.9. λ -sistema. Se le llama λ -sistema a la colección de conjuntos $\mathcal{L}$ si

$$A, B \in \mathcal{L} \text{ y } A \subset B \text{ entonces } B - A \in \mathcal{L}, \quad (2.43)$$

$$\text{si } A_n \in \mathcal{L}, \forall_{n \in \mathbb{N}} \text{ y } A_1 \subset A_2 \subset \dots \mid A_n \rightarrow A, \text{ entonces } A \in \mathcal{L}. \quad (2.44)$$

Teorema 2.2.2. Teorema $\pi - \lambda$ de Dynkin . Si $\mathcal{P}$ es un π -sistema y $\mathcal{L}$ es un λ -sistema que contiene a $\mathcal{P}$, entonces $\sigma(\mathcal{P}) \subset \mathcal{L}$.

Demostración. Sea $\ell(\mathcal{P})$ el λ -sistema más pequeño que contiene a $\mathcal{P}$. Para cada $A \in \ell(\mathcal{P})$ se define

$$\mathcal{G}_A := \{B \in \ell(\mathcal{P}) : A \cap B \in \ell(\mathcal{P})\}.$$

$\Omega \in \mathcal{G}_A$ pues $A \cap \Omega = A$; si $C \subseteq B$ están en $\mathcal{G}_A$, entonces $A \cap (B \setminus C) = (A \cap B) \setminus (A \cap C) \in \ell(\mathcal{P})$; y si $B_n \nearrow B$ en $\mathcal{G}_A$, entonces $A \cap B_n \nearrow A \cap B \in \ell(\mathcal{P})$.

Si $A \in \mathcal{P}$, la propiedad de π permite que $A \cap B \in \mathcal{P} \subseteq \ell(\mathcal{P})$ para todo $B \in \mathcal{P}$, así que $\mathcal{P} \subseteq \mathcal{G}_A$ y por minimalidad $\mathcal{G}_A = \ell(\mathcal{P})$. Luego para todo $A \in \mathcal{P}$ y $B \in \ell(\mathcal{P})$ se tiene $A \cap B \in \ell(\mathcal{P})$.

Esto muestra que $\mathcal{P} \subseteq \mathcal{G}_B$, y por minimalidad $\mathcal{G}_B = \ell(\mathcal{P})$. Por tanto $\ell(\mathcal{P})$ es cerrado bajo intersecciones finitas.

Se sigue que los complementos pertenecen por definición de λ -sistema, ya que $A \subset \Omega$; y las uniones countables generales se reducen al caso disjunto tomando $A'_n = A_n - \bigcup_{k < n} A_k \in \ell(\mathcal{P})$. Por minimalidad $\sigma(\mathcal{P}) \subseteq \ell(\mathcal{P}) \subseteq \mathcal{L}$. □

2.3 Más sobre la medida

Teorema 2.3.1. Teorema de unicidad de medidas. Sea $\mathcal{P}$ un π -sistema. Si ν_1, ν_2 son medidas respectivamente sobre $\mathcal{F}_1, \mathcal{F}_2$ que coinciden sobre $\mathcal{P}$ y además existe una sucesión creciente sobre Ω con $\nu_1(A_n), \nu_2(A_n) < \infty$, entonces ν_1 y ν_2 coinciden sobre $\sigma(\mathcal{P})$.

Demostración. Supongamos que $\nu_1(\Omega) = \nu_2(\Omega) < \infty$. Fijese $A \in \mathcal{P}$ y definase

$$\mathcal{L} := \{B \in \sigma(\mathcal{P}) : \nu_1(A \cap B) = \nu_2(A \cap B)\}.$$

Como ν_1 y ν_2 coinciden en $\mathcal{P}$, se tiene $\nu_1(A \cap \Omega) = \nu_1(A) = \nu_2(A) = \nu_2(A \cap \Omega)$, luego $\Omega \in \mathcal{L}$. Si $B, C \in \mathcal{L}$ con $C \subseteq B$, como $\nu_1(\Omega) < \infty$ en particular $\nu_1(A \cap B) < \infty$, y entonces

$$\nu_1(A \cap (B \setminus C)) = \nu_1(A \cap B) - \nu_1(A \cap C) = \nu_2(A \cap B) - \nu_2(A \cap C) = \nu_2(A \cap (B \setminus C)),$$

entonces $B \setminus C \in \mathcal{L}$. Si $(B_n)_{n \geq 1} \subseteq \mathcal{L}$ es creciente con $B_n \nearrow B$, entonces $A \cap B_n \nearrow A \cap B$, y por continuidad de las medidas desde abajo,

$$\nu_1(A \cap B) = \lim_{n \rightarrow \infty} \nu_1(A \cap B_n) = \lim_{n \rightarrow \infty} \nu_2(A \cap B_n) = \nu_2(A \cap B),$$

luego $B \in \mathcal{L}$. Por tanto $\mathcal{L}$ es un λ -sistema que contiene a $\mathcal{P}$, y por el teorema de Dynkin $\sigma(\mathcal{P}) \subseteq \mathcal{L}$, es decir $\nu_1(A \cap B) = \nu_2(A \cap B)$ para todo $B \in \sigma(\mathcal{P})$ y todo $A \in \mathcal{P}$. Tomando $A = \Omega$ se concluye $\nu_1 = \nu_2$ sobre $\sigma(\mathcal{P})$ en el caso finito.

Para el caso general, sea $(A_n)_{n \geq 1} \subseteq \mathcal{P}$ creciente con $A_n \nearrow \Omega$ y $\nu_1(A_n), \nu_2(A_n) < \infty$ para todo n . Fijemos $B \in \sigma(\mathcal{P})$. Las medidas $\nu_i(\cdot \cap A_n)$ son finitas y coinciden en $\mathcal{P}$, luego por el caso anterior $\nu_1(B \cap A_n) = \nu_2(B \cap A_n)$ para todo n . Como $B \cap A_n \nearrow B$, la continuidad desde abajo da

$$\nu_1(B) = \lim_{n \rightarrow \infty} \nu_1(B \cap A_n) = \lim_{n \rightarrow \infty} \nu_2(B \cap A_n) = \nu_2(B).$$

□

Lema 2.3.1. σ -aditividad heredada. Suponga que μ es una medida sobre $\mathcal{S}$ y que $\bar{\mu}$ medida de $\bar{\mathcal{S}}$ es una extensión de μ , entonces

$$\text{Si } A = \bigcup_{i=1}^n B_i \mid A, B_i \in \bar{\mathcal{S}}, \text{ entonces } \bar{\mu}(A) = \sum_{i=1}^n \bar{\mu}(B_i). \quad (2.45)$$

$$\text{Si } A \subset \bigcup_{i=1}^n B_i \mid A, B_i \in \bar{\mathcal{S}}, \text{ entonces } \bar{\mu}(A) \leq \sum_{i=1}^n \bar{\mu}(B_i). \quad (2.46)$$

Demostración. Como $B_i \in \bar{\mathcal{S}}$, existe una descomposición $B_i = \bigsqcup_j S_{i,j}$ con $S_{i,j} \in \mathcal{S}$ unión finita disjunta. Si $A = \bigsqcup_{i=1}^n B_i$, entonces $A = \bigsqcup_{i,j} S_{i,j}$ es también una unión finita disjunta de elementos de $\mathcal{S}$, luego por definición de $\bar{\mu}$ y porque $\bar{\mu}$ extiende a μ ,

$$\bar{\mu}(A) = \sum_{i,j} \mu(S_{i,j}) = \sum_{i=1}^n \sum_j \mu(S_{i,j}) = \sum_{i=1}^n \bar{\mu}(B_i).$$

Para la segunda afirmación, definamos $C_1 = B_1$ y $C_i = B_i \setminus (B_1 \cup \dots \cup B_{i-1})$ para $i \geq 2$. Entonces $C_i \subseteq B_i$, los C_i son disjuntos, $\bigsqcup_{i=1}^n C_i = \bigsqcup_{i=1}^n B_i$, y $A = \bigsqcup_{i=1}^n (A \cap C_i)$. Por la primera parte y la monotonía de $\bar{\mu}$,

$$\bar{\mu}(A) = \sum_{i=1}^n \bar{\mu}(A \cap C_i) \leq \sum_{i=1}^n \bar{\mu}(C_i) \leq \sum_{i=1}^n \bar{\mu}(B_i).$$

□

2.3.1 Medida exterior

Definición 2.3.1. Medida exterior de Carathéodory. Sea μ una medida en una álgebra $\mathcal{F}$, si $E \subset \Omega$ y $\{A_i\}$ un recubrimiento sobre E , entonces se define

$$\mu^*(E) := \inf \sum_{n=1}^{\infty} \mu(A_n). \quad (2.47)$$

Definición 2.3.2. Medida exterior. Una función $\mu^* : \mathcal{F} \rightarrow \bar{\mathbb{R}}$ se le dice medida exterior si

$$\mu^*(\emptyset) = 0 \quad (2.48)$$

$$\text{Si } E \subset F, \text{ entonces } \mu^*(E) \leq \mu^*(F) \quad (2.49)$$

$$\text{Si } E \subset \bigcup_i F_i, \text{ entonces } \mu^*(E) \leq \sum_i \mu^*(F_i) \quad (2.50)$$

Definición 2.3.3. Criterio de medibilidad de Carathéodory. Sea μ^* una medida exterior sobre $\mathcal{F}$. Un conjunto $E \subset \Omega$ se dice medible si para todo conjunto $F \subset \Omega$ se cumple

$$\mu^*(F) = \mu^*(F \cap E) + \mu^*(F \cap E^c). \quad (2.51)$$

Lema 2.3.2. Coherencia con la medida original. Si $A \in \mathcal{A}$ entonces $\mu^*(A) = \mu(A)$ y A es medible.

Demostración. Es claro que si $A \subset \bigcup_i A_i$ entonces

$$\mu(A) \leq \sum_i \mu(A_i),$$

Entonces $\mu(A) \leq \mu^*(A)$, dado que $A \subset A$ entonces $\mu^*(A) \leq \mu(A)$. Ahora si $\mu^*(F) = \infty$ la condición de medible es trivial; entonces tome $\mu^*(F) < \infty$ y $E = A$ por propiedades del ínfimo si $F \subset \bigcup_i B_i$ si $\varepsilon > 0$ tenemos que

$$\sum_i \mu(B_i) \leq \mu^*(F) + \varepsilon.$$

Dado que $\mu = \mu^*$, entonces

$$\mu^*(F \cap A) + \mu^*(F \cap A^c) \leq \sum_i \mu^*(B_i \cap A) + \mu^*(B_i \cap A^c) = \sum_i \mu(B_i) \leq \mu^*(F) + \varepsilon.$$

Para la otra desigualdad tan solo note que por definicion

$$\mu^*(F \cap A) + \mu^*(F \cap A^c) \geq \mu^*(F).$$

□

Teorema 2.3.2. Teorema de Carathéodory. La clase $\mathcal{A}^*$ de conjuntos medibles de una σ -álgebra y la restricción μ^* sobre $\mathcal{A}^*$ es una medida.

Demostración. Primero note que el hecho de que $E^c \mid E \in \mathcal{A}^*$ es trivial.

Ahora, note que si $E_1, E_2 \in \mathcal{A}^*$ tenemos que

$$\begin{aligned} & \mu^*(F \cap (E_1 \cup E_2)) + \mu^*(F \cap (E_1^c \cap E_2^c)) \\ & \leq \mu^*(F \cap E_1) + \mu^*(F \cap E_1^c \cap E_2) + \mu^*(F \cap (E_1^c \cap E_2^c)) = \mu^*(F \cap E_1) + \mu^*(F \cap E_1^c) = \mu^*(F) \end{aligned}$$

En cuyo caso $E_1 \cup E_2$ es medible. Para $E_1 \cap E_2$ bastan notar que $(E_1^c \cup E_2^c)^c$, entonces $E_1 \cap E_2$ es medible.

Ahora si $E_1, \dots, E_n \in \mathcal{A}^*$ conjuntos disjuntos medibles, si tomamos $C_m = \bigsqcup_{i \leq m} E_i$. Dado que $F_n \supset E_n$, y $F_{n-1} \cap E_n = \emptyset$, se tiene

$$\mu^*(G \cap F_n) = \mu^*(G \cap F_n \cap E_n) + \mu^*(G \cap F_n \cap E_n^c) = \mu^*(G \cap E_n) + \mu^*(G \cap F_{n-1}).$$

Por inducción sobre n , se sigue que

$$\mu^* \left(G \cap \bigsqcup_{i=1}^n E_i \right) = \sum_{i=1}^n \mu^*(G \cap E_i).$$

Para probar que si $E_i \in \mathcal{A}^*$, entonces $E = \bigcup_{i=1}^{\infty} E_i \in \mathcal{A}^*$, defina $E_i' = E_i \cap \bigcap_{j < i} E_j^c$. Por lo anterior, $E_i' \in \mathcal{A}^*$, por lo que podemos asumir sin pérdida de generalidad que los E_i' son disjuntos dos a dos. Sea $F_n = \bigcup_{i=1}^n E_i'$. Por lo anterior, $F_n \in \mathcal{A}^*$. Utilizando lo anteriormente demostrados y dado que $E^c \subset F_n^c$ tenemos

$$\mu^*(G) = \mu^*(G \cap F_n) + \mu^*(G \cap F_n^c) \geq \sum_{i=1}^n \mu^*(G \cap E_i') + \mu^*(G \cap E^c).$$

Dejando $n \rightarrow \infty$ se sigue que

$$\mu^*(G) \geq \sum_{i=1}^{\infty} \mu^*(G \cap E_i') + \mu^*(G \cap E^c) \geq \mu^*(G \cap E) + \mu^*(G \cap E^c),$$

Demostrando que E es medible.

Finalmente, si $E = \bigcup_i E_i$ con $E_1, E_2, \dots \in \mathcal{A}^*$ disjuntos, sea $F_n = \bigsqcup_{i=1}^n E_i$. Entonces se sigue que $\mu^*(E) \geq \mu^*(F_n) = \sum_{i=1}^n \mu^*(E_i)$, tomando el límite cuando $n \rightarrow \infty$ tenemos que

$$\mu^*(E) \leq \sum_{i=1}^{\infty} \mu^*(E_i).$$

Dado que la desigualdad opuesta de la definición de μ^* , concluimos que $\mu^*(E) = \sum_{i=1}^{\infty} \mu^*(E_i)$. $\square$

Teorema 2.3.3. Teorema de la extensión de Carathodory . Sea μ σ -finita sobre una álgebra $\mathcal{A}$, entonces μ tiene una única extensión ν para $\sigma(\mathcal{A})$.

Demostración. La unicidad ya está probada por el teorema de coincidencia de π -sistemas. Y la existencia el lema anterior la prueba. $\square$

Teorema 2.3.4. Teorema de Hahn-Kolmogorov. Sea $\mathcal{S}$ una semialgebra y μ una medida exterior sobre $\mathcal{S}$, entonces si $A \in \mathcal{S}$ es una colección finita de conjuntos disjuntos de $A_i \in \mathcal{S}$ se tiene que

$$\mu(A) = \sum_i \mu(A_i). \quad (2.52)$$

Y si $A = \bigcap_{i \leq n} A_i$ se sigue que

$$\mu(A) \leq \sum_i \mu(A_i). \quad (2.53)$$

Sumado a ello, μ tiene una única extensión $\bar{\mu}$ que es una medida sobre $\mathcal{S}^*$. Si la extensión es σ -finita, entonces existe una única extensión ν que es una medida sobre $\sigma(\mathcal{S})$.

Demostración. Definimos $\bar{\mu}$ sobre $\mathcal{S}^*$ como

$$\bar{\mu}(A) = \sum_i \mu(S_i) \quad \text{si } A = \bigsqcup_i S_i \mid S_i \in \mathcal{S}.$$

Para verificar que $\bar{\mu}$ está bien definida, supongamos que $A = \bigsqcup_j T_j$ con $T_j \in \mathcal{S}$. Entonces se sigue que $S_i = \bigsqcup_j (S_i \cap T_j)$ y $T_j = \bigsqcup_i (S_i \cap T_j)$, por la aditividad finita se tiene que

$$\sum_i \mu(S_i) = \sum_{i,j} \mu(S_i \cap T_j) = \sum_j \mu(T_j),$$

lo que prueba que $\bar{\mu}$ no depende de la representación.

Para extender la aditividad a uniones disjuntas numerables $A = \bigsqcup_{i \geq 1} B_i$, con $B_i \in \bar{\mathcal{S}}$, observamos que cada $B_i = \bigsqcup_j S_{i,j}$ con $S_{i,j} \in \mathcal{S}$, y entonces:

$$\sum_{i \geq 1} \bar{\mu}(B_i) = \sum_{i \geq 1, j} \mu(S_{i,j}).$$

Reemplazando los B_i por los $S_{i,j}$, podemos suponer que $B_i \in \mathcal{S}$. Dado que $A \in \bar{\mathcal{S}}$, existe una unión finita disjunta $A = \bigsqcup_j T_j$ con $T_j \in \mathcal{S}$, y cada $T_j = \bigcup_{i \geq 1} (T_j \cap B_i)$. Por la subaditividad

$$\mu(T_j) \leq \sum_{i=1}^{\infty} \mu(T_j \cap B_i).$$

Sumando sobre j

$$\bar{\mu}(A) = \sum_j \mu(T_j) \leq \sum_{i=1}^{\infty} \sum_j \mu(T_j \cap B_i) = \sum_{i=1}^{\infty} \mu(B_i).$$

Para la desigualdad opuesta, definimos $A_n = \bigsqcup_{i=1}^n B_i$ y $C_n = A \cap A_n^c$. Como $\bar{S}$ es un álgebra, $C_n \in \bar{S}$, y por aditividad finita

$$\bar{\mu}(A) = \bar{\mu}(A_n) + \bar{\mu}(C_n) \geq \sum_{i=1}^n \bar{\mu}(B_i).$$

Tomando el límite cuando $n \rightarrow \infty$, se concluye

$$\bar{\mu}(A) \geq \sum_{i \geq 1} \bar{\mu}(B_i).$$

Por tanto, $\bar{\mu}$ es aditiva contable sobre $\bar{S}$, y define una medida.

Ahora para la primera parte la unicidad es clara por el teorema de coincidencia de en π -sistemas. Y si es σ -finita por el Teorema de la extensión de Carathodory. La extensión es única sobre $\sigma(\mathcal{S})$. $\square$

2.3.2 Medida de Stieltjes

Definición 2.3.4. Medida de Stieltjes. Las medidas sobre $(\mathbb{R}, \mathcal{B}(E))$ se definen a partir de una función de medida de Stieltjes $F : \mathcal{B}(E) \rightarrow \mathbb{R}$ que satisface las siguientes propiedades

$$F \text{ es no decreciente, es decir, si } x \leq y \text{ entonces } F(x) \leq F(y). \quad (2.54)$$

$$F \text{ es continua por la derecha, es decir } \lim_{y \rightarrow x^+} F(y) = F(x), \text{ para todo } x \in \mathbb{R}. \quad (2.55)$$

2.3.3 Integración de funciones simples

Definición 2.3.5. Función indicadora y medida de Dirac. Sea $(\Omega, \mathcal{F})$ un espacio medible. La función indicadora de un conjunto $A \in \mathcal{F}$ y la medida de Dirac en un punto $x_0 \in \Omega$ se definen respectivamente como

$$\mathbf{1}_A(x) := \begin{cases} 1 & \text{si } x \in A, \\ 0 & \text{si } x \notin A, \end{cases} \quad \delta_{x_0}(A) := \mathbf{1}_A(x_0), \quad (2.56)$$

también denotada $\mathbb{1}_{\{x \in A\}}$. La medida de Dirac satisface $\int f d\delta_{x_0} = f(x_0)$ para toda función medible f .

Definición 2.3.6. Función simple. Sea $(\Omega, \mathcal{F}, \mu)$ un espacio de medida. Se dice que una función $\varphi : \Omega \rightarrow \mathbb{R}$ es simple si existe una colección finita de conjuntos disjuntos $A_1, A_2, \dots, A_n \in \mathcal{F}$ con $\mu(A_i) < \infty$ para cada i , y constantes reales $a_1, a_2, \dots, a_n$, tales que

$$\varphi(\omega) = \sum_{i=1}^n a_i \mathbf{1}_{A_i}(\omega). \quad (2.57)$$

Definición 2.3.7. Integral de una función simple. Sea μ una medida sobre un espacio medible $(\Omega, \mathcal{F})$. La integral de una función simple se define como

$$\int \varphi d\mu := \sum_{i=1}^n a_i \mu(A_i). \quad (2.58)$$

Lema 2.3.3. Propiedades básicas de la integral para funciones simples. Sean φ y ψ funciones simples. Entonces se cumple:

$$\varphi \geq 0 \text{ en casi todas partes} \Rightarrow \int \varphi d\mu \geq 0. \quad (2.59)$$

$$a \in \mathbb{R} \Rightarrow \int a\varphi d\mu = a \int \varphi d\mu. \quad (2.60)$$

$$\int (\varphi + \psi) d\mu = \int \varphi d\mu + \int \psi d\mu. \quad (2.61)$$

$$\varphi \leq \psi \text{ en casi todas partes} \Rightarrow \int \varphi d\mu \leq \int \psi d\mu. \quad (2.62)$$

$$\varphi = \psi \text{ en casi todas partes} \Rightarrow \int \varphi d\mu = \int \psi d\mu. \quad (2.63)$$

$$\left| \int \varphi d\mu \right| \leq \int |\varphi| d\mu. \quad (2.64)$$

Demostración. Las dos primeras demostraciones son triviales. Para demostrar la segunda suponga que

$$\varphi = \sum_{i=1}^m a_i \mathbf{1}_{A_i}, \quad \psi = \sum_{j=1}^n b_j \mathbf{1}_{B_j}.$$

Para unificar los dominios de las funciones simples φ y ψ , definimos los conjuntos complementarios residuales $A_0 := \left(\bigcup_j B_j\right) - \left(\bigcup_i A_i\right)$, $B_0 := \left(\bigcup_i A_i\right) - \left(\bigcup_j B_j\right)$ y tomamos $a_0 = b_0 = 0$. Entonces se tiene

$$\varphi + \psi = \sum_{i=0}^m \sum_{j=0}^n (a_i + b_j) \mathbf{1}_{A_i \cap B_j},$$

donde $A_i = \bigsqcup_j (A_i \cap B_j)$ y $B_j = \bigsqcup_i (A_i \cap B_j)$. Por tanto

$$\begin{aligned} \int (\varphi + \psi) d\mu &= \sum_{i=0}^m \sum_{j=0}^n (a_i + b_j) \mu(A_i \cap B_j) = \sum_{i=0}^m \sum_{j=0}^n a_i \mu(A_i \cap B_j) + \sum_{j=0}^n \sum_{i=0}^m b_j \mu(A_i \cap B_j) \\ &= \sum_{i=0}^m a_i \mu(A_i) + \sum_{j=0}^n b_j \mu(B_j) = \int \varphi d\mu + \int \psi d\mu. \end{aligned}$$

Por la aditividad, se tiene $\int \psi d\mu = \int \varphi d\mu + \int (\psi - \varphi) d\mu$, y como $\psi - \varphi \geq 0$ la desigualdad se cumple por la primera demostración. Si $\varphi = \psi$ casi en todas partes, entonces simultáneamente $\varphi \leq \psi$ y $\psi \leq \varphi$ casi en todas partes. Aplicando la desigualdad anterior en ambas direcciones se concluye que las integrales son iguales. Como $\varphi \leq |\varphi|$ y también $-\varphi \leq |\varphi|$, se obtiene que la integral de φ es menor o igual que la de $|\varphi|$, y que la integral de $-\varphi$ también lo es. Esto implica que el valor absoluto de la integral de φ está acotado por la integral de $|\varphi|$, lo que concluye la demostración. $\square$

2.3.4 Integración para funciones acotadas

Definición 2.3.8. Definición de la integral de Lebesgue vía funciones simples. Sea $E \subset \Omega$ con $\mu(E) < \infty$, y sea f una función acotada que se anula fuera de E . Para definir $\int f d\mu$, observamos que si φ y ψ son funciones simples tales que $\varphi \leq f \leq \psi$, entonces definimos

$$\int f d\mu := \sup_{\varphi \leq f} \int \varphi d\mu = \inf_{\psi \geq f} \int \psi d\mu. \quad (2.65)$$

Lema 2.3.4. propiedades elementales de la integral de Lebesgue para funciones acotadas de soporte de medida finita. Sea $E \subset \Omega$ con $\mu(E) < \infty$. Si f y g son funciones acotadas que se anulan fuera de E , entonces:

$$f \geq 0 \text{ en casi todas partes} \Rightarrow \int f d\mu \geq 0. \quad (2.66)$$

$$a \in \mathbb{R} \Rightarrow \int a f d\mu = a \int f d\mu. \quad (2.67)$$

$$\int (f + g) d\mu = \int f d\mu + \int g d\mu. \quad (2.68)$$

$$g \leq f \text{ en casi todas partes} \Rightarrow \int g d\mu \leq \int f d\mu. \quad (2.69)$$

$$g = f \text{ en casi todas partes} \Rightarrow \int g d\mu = \int f d\mu. \quad (2.70)$$

$$\left| \int f d\mu \right| \leq \int |f| d\mu. \quad (2.71)$$

La demostración se deja al lector.

Definición 2.3.9. Integral de f sobre el conjunto E Definimos la integral de f sobre el conjunto E como

$$\int_E f d\mu := \int f \cdot \mathbf{1}_E d\mu. \quad (2.72)$$

2.3.5 Integración para funciones no negativas

Definición 2.3.10. Integral de Lebesgue para funciones medibles no negativas. Si $f \geq 0$, definimos

$$\int f d\mu := \sup \left\{ \int h d\mu : 0 \leq h \leq f, h \leq M \mid M \in \mathbb{R}, \mu(\{x : h(x) > 0\}) < \infty \right\}. \quad (2.73)$$

Lema 2.3.5. Aproximación por truncamiento. Sea $E_n \rightarrow \Omega \mid E_{n-1} \subset E_n$ con $\mu(E_n) < \infty$. Entonces

$$\int_{E_n} \min\{f, n\} d\mu \rightarrow \int f d\mu \text{ creciente, cuando } n \rightarrow \infty. \quad (2.74)$$

Demostración. Sea h tal que $0 \leq h \leq f$, $h \leq M$, y $\mu(\{x : h(x) > 0\}) < \infty$. Para $n \geq M$, se tiene

$$\int_{E_n} \min\{f, n\} d\mu \geq \int_{E_n} h d\mu = \int h d\mu - \int_{E_n^c} h d\mu.$$

Como $0 \leq \int_{E_n^c} h d\mu \leq M$, $\mu(E_n^c \cap \{x : h(x) > 0\}) \rightarrow 0$ cuando $n \rightarrow \infty$, se concluye que

$$\liminf_{n \rightarrow \infty} \int_{E_n} \min\{f, n\} d\mu \geq \int h d\mu,$$

y como h es arbitraria, se obtiene el resultado. □

Lema 2.3.6. Propiedades elementales de la integral de Lebesgue. Supóngase que $f, g \geq 0$. Entonces:

$$\int f d\mu \geq 0. \quad (2.75)$$

$$a > 0 \Rightarrow \int af d\mu = a \int f d\mu. \quad (2.76)$$

$$\int (f + g) d\mu = \int f d\mu + \int g d\mu. \quad (2.77)$$

$$0 \leq g \leq f \text{ en casi todas partes} \Rightarrow \int g d\mu \leq \int f d\mu. \quad (2.78)$$

$$0 \leq g = f \text{ en casi todas partes} \Rightarrow \int g d\mu = \int f d\mu. \quad (2.79)$$

La demostración queda al lector, solo cabe recalcar que para la suma de integral hay que utilizar el lema anterior.

2.3.6 Integración para funciones medibles

Definición 2.3.11. Extensión de la integral de Lebesgue a funciones medibles de signo arbitrario. Se dice que una función cualquiera f es integrable si $\int |f| d\mu < \infty$. Definimos

$$f^+(x) := \max\{f(x), 0\}, \quad f^-(x) := \min\{f(x), 0\} \quad (2.80)$$

Entonces se tiene $f(x) = f^+(x) - f^-(x)$, $|f(x)| = f^+(x) + f^-(x)$. Definimos la integral de f como

$$\int f d\mu := \int f^+ d\mu - \int f^- d\mu. \quad (2.81)$$

Lema 2.3.7. Linealidad para la diferencia. Si $f = f_1 - f_2$ con $f_1, f_2 \geq 0$ y $\int f_i d\mu < \infty$, entonces

$$\int f d\mu = \int f_1 d\mu - \int f_2 d\mu. \quad (2.82)$$

La demostración queda al lector.

Teorema 2.3.5. Teorema de las propiedades fundamentales de la integral de Lebesgue. Supóngase que f y g son integrables. Entonces

$$f \geq 0 \text{ en casi todas partes} \Rightarrow \int f d\mu \geq 0. \quad (2.83)$$

$$a \in \mathbb{R} \Rightarrow \int af d\mu = a \int f d\mu. \quad (2.84)$$

$$\int (f + g) d\mu = \int f d\mu + \int g d\mu. \quad (2.85)$$

$$g \leq f \text{ en casi todas partes} \Rightarrow \int g d\mu \leq \int f d\mu. \quad (2.86)$$

$$g = f \text{ en casi todas partes} \Rightarrow \int g d\mu = \int f d\mu. \quad (2.87)$$

$$\left| \int f d\mu \right| \leq \int |f| d\mu. \quad (2.88)$$

La demostración se deja al lector.

Teorema 2.3.6. Desigualdad de Jensen. Sea $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ una función convexa, es decir, para todo $\lambda \in (0, 1)$ y $x, y \in \mathbb{R}$ se cumple

$$\lambda\varphi(x) + (1 - \lambda)\varphi(y) \geq \varphi(\lambda x + (1 - \lambda)y). \quad (2.89)$$

Sea μ una medida de probabilidad sobre $(\Omega, \mathcal{A})$, y sea $f : \Omega \rightarrow \mathbb{R}$ tal que f y $\varphi \circ f$ son integrables. Entonces

$$\varphi\left(\int f d\mu\right) \leq \int \varphi(f) d\mu. \quad (2.90)$$

Demostración. Sea $c := \int f d\mu$. Por la convexidad de φ , existe una función lineal $\ell(x) = ax + b$ tal que $\ell(c) = \varphi(c)$ y $\varphi(x) \geq \ell(x)$ para todo $x \in \mathbb{R}$. Para ver que tal función existe, se considera que la convexidad implica

$$\lim_{h \rightarrow 0^+} \frac{\varphi(c) - \varphi(c - h)}{h} \leq \lim_{h \rightarrow 0^+} \frac{\varphi(c + h) - \varphi(c)}{h}.$$

Si se toma cualquier a entre ambos límites y se define $\ell(x) := a(x - c) + \varphi(c)$. Dado que $\varphi(f) \geq \ell(f)$, se tiene que

$$\int \varphi(f) d\mu \geq \int \ell(f) d\mu = \int (af + b) d\mu = a \int f d\mu + b = \ell\left(\int f d\mu\right) = \varphi(c).$$

□

2.3.7 Sucesiones de funciones

Teorema 2.3.7. Teorema de convergencia acotada. Sea $E \subset \Omega$ con $\mu(E) < \infty$. Supóngase que f_n es una sucesión de funciones medibles tales que $f_n = 0$ en E^c , $|f_n(x)| \leq M$ para todo $x \in E$, y que $f_n \rightarrow f$ en medida. Entonces

$$\int f d\mu = \lim_{n \rightarrow \infty} \int f_n d\mu. \quad (2.91)$$

Demostración. Sea $\varepsilon > 0$ fijo. Definimos $G_n := \{x \in E : |f_n(x) - f(x)| < \varepsilon\}$ y $B_n := E \setminus G_n$, se tiene que

$$\left| \int f d\mu - \int f_n d\mu \right| = \left| \int (f - f_n) d\mu \right| \leq \int |f - f_n| d\mu.$$

Separando la integral sobre G_n y B_n , se obtiene

$$\int |f - f_n| d\mu = \int_{G_n} |f - f_n| d\mu + \int_{B_n} |f - f_n| d\mu.$$

En G_n , se cumple $|f - f_n| < \varepsilon$, por lo que

$$\int_{G_n} |f - f_n| d\mu \leq \varepsilon \mu(E).$$

En B_n , como $|f_n(x)| \leq M$ y $|f(x)| \leq M$ casi en todas partes, se tiene $|f(x) - f_n(x)| \leq 2M$, y por tanto

$$\int_{B_n} |f - f_n| d\mu \leq 2M \mu(B_n).$$

Combinando ambas estimaciones

$$\left| \int f d\mu - \int f_n d\mu \right| \leq \varepsilon \mu(E) + 2M \mu(B_n).$$

Como $f_n \rightarrow f$ en medida, se tiene $\mu(B_n) \rightarrow 0$ cuando $n \rightarrow \infty$. Dado que $\varepsilon > 0$ es arbitrario y

$\mu(E) < \infty$, se concluye que

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu.$$

□

Lema 2.3.8. Lema de Fatou. Sea $\{f_n\}$ una sucesión de funciones medibles no negativas. Entonces

$$\liminf_{n \rightarrow \infty} \int f_n d\mu \geq \int \liminf_{n \rightarrow \infty} f_n d\mu. \quad (2.92)$$

Demostración. Sea $g_n(x) := \inf_{m \geq n} f_m(x)$. Entonces $f_n(x) \geq g_n(x)$ se tiene

$$\liminf_{n \rightarrow \infty} \int f_n d\mu \geq \liminf_{n \rightarrow \infty} \int g_n d\mu.$$

Por tanto, basta probar que $\liminf_{n \rightarrow \infty} \int g_n d\mu \geq \int g d\mu$. Sea $E_m \rightarrow \Omega$ una sucesión de conjuntos medibles creciente con $\mu(E_m) < \infty$. Como $g_n \geq 0$, y para cada m fijo se tiene que $\min\{g_n, m\} \mathbf{1}_{E_m} \rightarrow \min\{g, m\} \mathbf{1}_{E_m}$ casi en todas partes, el teorema de convergencia acotada implica

$$\lim_{n \rightarrow \infty} \int_{E_m} \min\{g_n, m\} d\mu = \int_{E_m} \min\{g, m\} d\mu.$$

Como $g_n \geq g_n \wedge m$, se tiene

$$\liminf_{n \rightarrow \infty} \int g_n d\mu \geq \int_{E_m} \min\{g, m\} d\mu.$$

Tomando el supremo sobre m se concluye que

$$\liminf_{n \rightarrow \infty} \int f_n d\mu \geq \int g d\mu = \int \liminf_{n \rightarrow \infty} f_n d\mu.$$

□

Teorema 2.3.8. Teorema de convergencia monotona. Sea $\{f_n\}$ una sucesión de funciones medibles no negativas tal que $f_n \rightarrow f$ crecientes. Entonces

$$\int f_n d\mu \rightarrow \int f d\mu. \quad (2.93)$$

Demostración. Por el Lema de Fatou, se tiene

$$\liminf_{n \rightarrow \infty} \int f_n d\mu \geq \int f d\mu.$$

Como $f_n \leq f$, también se tiene

$$\limsup_{n \rightarrow \infty} \int f_n d\mu \leq \int f d\mu.$$

Por tanto

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu.$$

□

Teorema 2.3.9. Teorema de convergencia dominada. Sea $\{f_n\}$ una sucesión de funciones medibles tal que $f_n \rightarrow f$ casi en todas partes, $|f_n| \leq g$ para todo n , y g integrable. Entonces

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu. \quad (2.94)$$

Demostración. Como $f_n + g \geq 0$, el Lema de Fatou implica

$$\liminf_{n \rightarrow \infty} \int (f_n + g) d\mu \geq \int (f + g) d\mu.$$

Restando $\int g d\mu$ en ambos lados se obtiene

$$\liminf_{n \rightarrow \infty} \int f_n d\mu \geq \int f d\mu.$$

Aplicando el mismo argumento a $-f_n$, se obtiene

$$\limsup_{n \rightarrow \infty} \int f_n d\mu \leq \int f d\mu.$$

Por tanto,

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu.$$

Esto concluye la demostración. □

2.3.8 Teorema Riemann-Lebesgue

Teorema 2.3.10. Teorema Riemann-Lebesgue. Sea $f : [a, b] \rightarrow \mathbb{R}$ una función acotada y Riemann-integrable. Entonces f es medible y Lebesgue-integrable, y se cumple

$$\int_{[a,b]} f(x) dx = \int_{[a,b]} f(x) d\mu(x). \quad (2.95)$$

La demostración queda al lector. Nada mas note las sumas inferiores y superiores puede acotar la integral, en cuyo caso como es Riemann integrable todas las sumas de Riemann convergen entre si.

Definición 2.3.12. Espacio de medida producto. Sean $(X, \mathcal{A}, \mu_1)$ y $(Y, \mathcal{B}, \mu_2)$ dos espacios de medida σ -finitos. Definimos el espacio producto como

$$\Omega = X \times Y = \{(x, y) : x \in X, y \in Y\}.$$

La colección de rectángulos como

$$\mathcal{S} = \{A \times B : A \in \mathcal{A}, B \in \mathcal{B}\}.$$

2.3.9 Medida del producto

Definición 2.3.13. Medida producto. La σ -álgebra generada por $\mathcal{S}$ se denota $\mathcal{F} = \sigma(\mathcal{S})$. La medida μ en $\mathcal{F}$ tal que

$$\mu(A \times B) = \mu_1(A)\mu_2(B) \quad (2.96)$$

se denota comúnmente como $\mu_1 \times \mu_2$.

Teorema 2.3.11. Teorema de la medida producto. Existe una única medida μ en $\mathcal{F}$ tal que

$$\mu(A \times B) = \mu_1(A)\mu_2(B). \quad (2.97)$$

Demostración. Para probar la unicidad, consideremos que si $A \times B = \bigsqcup_i (A_i \times B_i)$ contable, entonces

$$\mu(A \times B) = \sum_i \mu(A_i \times B_i).$$

Para cada $x \in A$, definimos $I(x) = \{i : x \in A_i\}$. Entonces $B = \bigcup_{i \in I(x)} B_i$, por lo que

$$1_A(x)\mu_2(B) = \sum_i 1_{A_i}(x)\mu_2(B_i).$$

Integrando con respecto a μ_1 , se obtiene

$$\mu_1(A)\mu_2(B) = \sum_i \mu_1(A_i)\mu_2(B_i),$$

□

Usando este teorema y el principio de inducción, se deduce que si $(\Omega_i, \mathcal{F}_i, \mu_i)$, $i = 1, \dots, n$, son espacios de medida σ -finitos y $\Omega = \Omega_1 \times \dots \times \Omega_n$, existe una única medida μ en la σ -álgebra $\mathcal{F}$ generada por conjuntos de la forma $A_1 \times \dots \times A_n$, $A_i \in \mathcal{F}_i$, tal que

$$\mu(A_1 \times \dots \times A_n) = \prod_{m=1}^n \mu_m(A_m). \quad (2.98)$$

Cuando $(\Omega_i, \mathcal{F}_i, \mu_i) = (\mathbb{R}, \mathcal{B}, \lambda)$ para todo i , el resultado es la medida de Lebesgue en los subconjuntos de Borel del espacio euclídeo n -dimensional $\mathbb{R}^n$.

Lema 2.3.9. Lema de las secciones medibles. Sea $E_x = \{y : (x, y) \in E\}$ la sección transversal en x . Si $E \in \mathcal{F}$, entonces $E_x \in \mathcal{B}$.

Demostración. Dado que $(E^c)_x = (E_x)^c$ y $(\bigcup_i E_i)_x = \bigcup_i (E_i)_x$, como $\mathcal{E}$ contiene rectángulos $\in \mathcal{B}$, la colección $\mathcal{E} = \{E : E_x \in \mathcal{B}\}$ es una σ -álgebra.

□

Lema 2.3.10. Lema de Tonelli para funciones indicadoras. Si $E \in \mathcal{F}$, entonces $g(x) \equiv \mu_2(E_x)$ es $\mathcal{A}$ -medible y

$$\int_X g d\mu_1 = \mu(E).$$

Demostración. Sea $\mathcal{L}$ la colección de conjuntos $E \in \mathcal{F}$ tales que $x \mapsto \mu_2(E_x)$ es $\mathcal{A}$ -medible y $\int_X \mu_2(E_x) d\mu_1 = \mu(E)$.

Si $E = A \times B$ con $A \in \mathcal{A}$, $B \in \mathcal{B}$, entonces $E_x = B$ si $x \in A$ y $E_x = \emptyset$ si $x \notin A$, luego $\mu_2(E_x) = \mu_2(B) \mathbf{1}_A(x)$, que es $\mathcal{A}$ -medible, y

$$\int_X \mu_2(E_x) d\mu_1 = \mu_2(B) \mu_1(A) = \mu(A \times B).$$

Por tanto los rectángulos medibles pertenecen a $\mathcal{L}$, y forman un π -sistema que genera $\mathcal{F}$.

Verificamos que $\mathcal{L}$ es un λ -sistema en el caso $\mu_1(X), \mu_2(Y) < \infty$. El total $\Omega = X \times Y$ pertenece a $\mathcal{L}$ pues $\mu_2(\Omega_x) = \mu_2(Y)$ es constante y $\int_X \mu_2(Y) d\mu_1 = \mu_2(Y) \mu_1(X) = \mu(\Omega)$. Si $A \subseteq B$ con $A, B \in \mathcal{L}$, entonces $\mu_2((B \setminus A)_x) = \mu_2(B_x) - \mu_2(A_x)$, diferencia de funciones $\mathcal{A}$ -medibles, luego también $\mathcal{A}$ -medible.

Como $\mu_1(X) < \infty$ y $\mu_2(Y) < \infty$ las integrales son finitas y

$$\int_X \mu_2((B \setminus A)_x) d\mu_1 = \int_X \mu_2(B_x) d\mu_1 - \int_X \mu_2(A_x) d\mu_1 = \mu(B) - \mu(A) = \mu(B \setminus A),$$

luego $B \setminus A \in \mathcal{L}$. Si $(E_n)_x \subseteq \mathcal{L}$ es creciente con $E_n \nearrow E$, entonces $(E_n)_x \nearrow E_x$ y por continuidad de μ_2 desde abajo $\mu_2((E_n)_x) \nearrow \mu_2(E_x)$, que es $\mathcal{A}$ -medible por ser límite puntual de funciones medibles. Por el teorema de convergencia monótona,

$$\int_X \mu_2(E_x) d\mu_1 = \lim_{n \rightarrow \infty} \int_X \mu_2((E_n)_x) d\mu_1 = \lim_{n \rightarrow \infty} \mu(E_n) = \mu(E),$$

luego $E \in \mathcal{L}$. Por tanto $\mathcal{L}$ es un λ -sistema que contiene al π -sistema de rectángulos, y por el teorema de Dynkin $\mathcal{F} = \sigma(\text{rectángulos}) \subseteq \mathcal{L}$, es decir $\mathcal{L} = \mathcal{F}$.

Para el caso σ -finito, sea $\Omega_n = X_n \times Y_n \nearrow \Omega$ con $\mu_1(X_n), \mu_2(Y_n) < \infty$. Dado $E \in \mathcal{F}$, el caso finito da $\mu_2((E \cap \Omega_n)_x) = \mu_2(E_x \cap Y_n)$ medible e $\int_{X_n} \mu_2(E_x \cap Y_n) d\mu_1 = \mu(E \cap \Omega_n)$. Como $E_x \cap Y_n \nearrow E_x$, el teorema de convergencia monótona aplicado dos veces da

$$\int_X \mu_2(E_x) d\mu_1 = \lim_{n \rightarrow \infty} \int_{X_n} \mu_2(E_x \cap Y_n) d\mu_1 = \lim_{n \rightarrow \infty} \mu(E \cap \Omega_n) = \mu(E).$$

□

2.3.10 Teorema de Fubini-Tonelli

Teorema 2.3.12. Teorema de Fubini-Tonelli. Sean $(X, \mathcal{A}, \mu_1)$ y $(Y, \mathcal{B}, \mu_2)$ dos espacios de medida σ -finitos, con $\Omega = X \times Y$, $\mathcal{S} = \{A \times B : A \in \mathcal{A}, B \in \mathcal{B}\}$ y $\mathcal{F} = \sigma(\mathcal{S})$. Si $f \geq 0$ o $\int |f| d\mu < \infty$, entonces

$$\int_X \left(\int_Y f(x, y) \mu_2(dy) \right) \mu_1(dx) = \int_{X \times Y} f d\mu = \int_Y \left(\int_X f(x, y) \mu_1(dx) \right) \mu_2(dy). \quad (2.99)$$

Demostración. El lema de Tonelli para indicadoras garantiza que para todo $E \in \mathcal{F}$, la función $y \mapsto \mathbf{1}_{E_x}(y)$ es $\mathcal{B}$ -medible, $x \mapsto \mu_2(E_x)$ es $\mathcal{A}$ -medible, y

$$\int_X \mu_2(E_x) d\mu_1 = \mu(E),$$

lo que establece el resultado para $f = \mathbf{1}_E$. Por linealidad de la integral, el resultado se extiende a funciones simples no negativas.

Si $f \geq 0$, definamos

$$f_n = \min \left(\frac{\lfloor 2^n f \rfloor}{2^n}, n \right).$$

Las f_n son funciones simples no negativas, forman una sucesión creciente y $f_n \nearrow f$ puntualmente. Por el caso anterior,

$$\int_X \left(\int_Y f_n(x, y) \mu_2(dy) \right) \mu_1(dx) = \int_{X \times Y} f_n d\mu = \int_Y \left(\int_X f_n(x, y) \mu_1(dx) \right) \mu_2(dy).$$

Las integrales interiores $\int_Y f_n(x, y) \mu_2(dy)$ crecen puntualmente en x hacia $\int_Y f(x, y) \mu_2(dy)$, y análogamente en y . Aplicando el teorema de convergencia monótona a cada una de las tres integrales,

$$\int_X \left(\int_Y f(x, y) \mu_2(dy) \right) \mu_1(dx) = \int_{X \times Y} f d\mu = \int_Y \left(\int_X f(x, y) \mu_1(dx) \right) \mu_2(dy).$$

Para el caso general, escribimos $f = f^+ - f^-$. Como $\int |f| d\mu < \infty$, se tiene $\int f^+ d\mu < \infty$ y $\int f^- d\mu < \infty$. Aplicando el caso no negativo a f^+ y f^- por separado y restando, la linealidad de la

integral permite concluir

$$\int_X \left(\int_Y f(x, y) \mu_2(dy) \right) \mu_1(dx) = \int_{X \times Y} f d\mu = \int_Y \left(\int_X f(x, y) \mu_1(dx) \right) \mu_2(dy).$$

□

2.4 L^p

Definición 2.4.1. Espacio $L^p(\mu)$. Sea $(\Omega, \mathcal{F}, \mu)$ un espacio de medida y $1 \leq p < \infty$. Definimos

$$L^p(\mu) = \left\{ f : \Omega \rightarrow \mathbb{R} \text{ medible} : \int_{\Omega} |f|^p d\mu < \infty \right\} / \sim, \quad (2.100)$$

donde $f \sim g$ si $f = g$ μ -casi en todas partes. La norma en este espacio se define como

$$\|f\|_p = \left(\int_{\Omega} |f|^p d\mu \right)^{1/p}. \quad (2.101)$$

Para $p = \infty$ definimos $L^\infty(\mu)$ como el espacio de funciones medibles esencialmente acotadas, con norma

$$\|f\|_\infty = \inf\{M \geq 0 : |f| \leq M \text{ } \mu\text{-c.s.}\}. \quad (2.102)$$

Definición 2.4.2. Exponente conjugado. Dado $1 \leq p \leq \infty$, se llama exponente conjugado de p al valor q determinado por

$$\frac{1}{p} + \frac{1}{q} = 1, \quad (2.103)$$

con las convenciones $q = \infty$ si $p = 1$ y $q = 1$ si $p = \infty$.

2.4.1 Desigualda de Hölder y Minkowski

Teorema 2.4.1. Desigualdad de Hölder. Sean $1 \leq p \leq \infty$ y q su exponente conjugado. Si $f \in L^p(\mu)$ y $g \in L^q(\mu)$, entonces $fg \in L^1(\mu)$ y

$$\int_{\Omega} |fg| d\mu \leq \|f\|_p \|g\|_q. \quad (2.104)$$

Demostración. Si $\|f\|_p = 0$ o $\|g\|_q = 0$, entonces $|fg| = 0$ casi en todas partes, y la desigualdad es trivial. Por tanto, basta probar el resultado cuando $\|f\|_p = \|g\|_q = 1$, ya que el caso general se obtiene dividiendo ambos lados por $\|f\|_p \|g\|_q$. Definase

$$\varphi(x) := \frac{x^p}{p} + \frac{y^q}{q} - xy \quad \text{para } x \geq 0.$$

Entonces $\varphi'(x) = x^{p-1} - y$, $\varphi''(x) = (p-1)x^{p-2}$, por lo que φ tiene un mínimo en $x_0 = y^{1/(p-1)}$, como $q = \frac{p}{p-1}$, se tiene $x_0^p = y^q$, y por tanto

$$\varphi(x_0) = \frac{y^q}{p} + \frac{y^q}{q} - y^{1/(p-1)}y = y^q \left(\frac{1}{p} + \frac{1}{q} \right) - y^{1/(p-1)}y = y^q - y^q = 0.$$

Como x_0 es el mínimo, se concluye que

$$xy \leq \frac{x^p}{p} + \frac{y^q}{q}.$$

Tomando $x = |f|$, $y = |g|$, e integrando, se obtiene

$$\int |fg| d\mu \leq \int \frac{|f|^p}{p} d\mu + \int \frac{|g|^q}{q} d\mu = \frac{1}{p} + \frac{1}{q} = 1.$$

El caso general se deduce multiplicando por $\|f\|_p \|g\|_q$.

□

Teorema 2.4.2. Desigualdad de Minkowski. Sean $1 \leq p \leq \infty$ y $f, g \in L^p(\mu)$. Entonces $f + g \in L^p(\mu)$ y

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p. \quad (2.105)$$

La demostración se deja al lector.

2.4.2 Propiedades de L^p

Teorema 2.4.3. Relación entre espacios L^p en medida finita. Si $\mu(\Omega) < \infty$ y $1 \leq p \leq r \leq \infty$, entonces $L^r(\mu) \subseteq L^p(\mu)$ y

$$\|f\|_p \leq \mu(\Omega)^{1/p-1/r} \|f\|_r. \quad (2.106)$$

Definición 2.4.3. Espacio métrico completo. Un espacio métrico (X, d) se dice completo si toda sucesión de Cauchy en X converge a un elemento de X , es decir, si para toda sucesión $(x_n)_{n \geq 1}$ en X tal que

$$\lim_{n, m \rightarrow \infty} d(x_n, x_m) = 0, \quad (2.107)$$

existe $x \in X$ tal que $x_n \rightarrow x$.

Definición 2.4.4. Espacio de Banach. Un espacio vectorial normado $(X, \|\cdot\|)$ se dice un espacio de Banach si es completo respecto a la métrica inducida por su norma, es decir, si toda sucesión de Cauchy $(x_n)_{n \geq 1}$ en X con

$$\lim_{n, m \rightarrow \infty} \|x_n - x_m\| = 0 \quad (2.108)$$

converge a algún $x \in X$ con $\|x_n - x\| \rightarrow 0$.

Teorema 2.4.4. Riesz-Fischer. Para $1 \leq p \leq \infty$, el espacio $L^p(\mu)$ es completo, es decir, toda sucesión de Cauchy en $L^p(\mu)$ converge en $L^p(\mu)$. En particular, $L^p(\mu)$ es un espacio de Banach.

Definición 2.4.5. Conjunto denso. Sea (X, d) un espacio métrico y $A, B \subseteq X$. Se dice que A es denso en B si para todo $x \in B$ y todo $\varepsilon > 0$ existe $a \in A$ tal que

$$d(a, x) < \varepsilon, \quad (2.109)$$

o equivalentemente si $\bar{A} \supseteq B$, donde $\bar{A}$ denota la clausura de A en X .

Teorema 2.4.5. Densidad de funciones simples en L^p . Sea $1 \leq p < \infty$. El conjunto de funciones simples es denso en $L^p(\mu)$, es decir, para todo $f \in L^p(\mu)$ y todo $\varepsilon > 0$ existe una función simple φ tal que

$$\|f - \varphi\|_p < \varepsilon. \quad (2.110)$$

Teorema 2.4.6. Densidad de C_c en L^p . Sea $1 \leq p < \infty$ y μ la medida de Lebesgue en $\mathbb{R}^n$. El espacio de funciones continuas con soporte compacto $C_c(\mathbb{R}^n)$ es denso en $L^p(\mu)$.

Definición 2.4.6. Producto interno en L^2 . En el espacio $L^2(\mu)$ se define el producto interno

$$\langle f, g \rangle = \int_{\Omega} f g d\mu, \quad (2.111)$$

el cual induce la norma $\|f\|_2 = \langle f, f \rangle^{1/2}$.

Definición 2.4.7. Espacio de Hilbert. Un espacio vectorial H sobre $\mathbb{R}$ o $\mathbb{C}$ se dice un espacio de Hilbert si está dotado de un producto interno $\langle \cdot, \cdot \rangle : H \times H \rightarrow \mathbb{R}$ que satisface para todo $x, y, z \in H$ y $\alpha \in \mathbb{R}$:

$$\langle \alpha x + y, z \rangle = \alpha \langle x, z \rangle + \langle y, z \rangle, \quad (2.112)$$

$$\langle x, y \rangle = \langle y, x \rangle, \quad (2.113)$$

$$\langle x, x \rangle \geq 0, \quad \text{con } \langle x, x \rangle = 0 \text{ si y solo si } x = 0; \quad (2.114)$$

y además es completo respecto a la norma inducida

$$\|x\| = \sqrt{\langle x, x \rangle}. \quad (2.115)$$

En particular, todo espacio de Hilbert es un espacio de Banach.

Teorema 2.4.7. $L^2(\mu)$ es un espacio de Hilbert. El espacio $L^2(\mu)$ dotado del producto interno anterior es un espacio de Hilbert, es decir, es completo respecto a la norma inducida por dicho producto interno.

Teorema 2.4.8. Identidad de Parseval. Sea $\{e_n\}_{n \geq 1}$ una base ortonormal de $L^2(\mu)$. Entonces para todo $f \in L^2(\mu)$,

$$\|f\|_2^2 = \sum_{n=1}^{\infty} |\langle f, e_n \rangle|^2, \quad (2.116)$$

y además $f = \sum_{n=1}^{\infty} \langle f, e_n \rangle e_n$ con convergencia en $L^2(\mu)$.

Teorema 2.4.9. Proyección ortogonal. Sea H un subespacio cerrado de $L^2(\mu)$. Para todo $f \in L^2(\mu)$ existe un único $g \in H$ tal que

$$\|f - g\|_2 = \inf_{h \in H} \|f - h\|_2, \quad (2.117)$$

y se tiene la descomposición ortogonal $f = g + (f - g)$ con $f - g \perp H$.

Definición 2.4.8. Funcional lineal acotado y dual. Un funcional lineal $\Lambda : L^p(\mu) \rightarrow \mathbb{R}$ se dice acotado si existe $C > 0$ tal que $|\Lambda(f)| \leq C \|f\|_p$ para todo $f \in L^p(\mu)$. El espacio dual $(L^p(\mu))^*$ es el espacio de todos los funcionales lineales acotados sobre $L^p(\mu)$.

Teorema 2.4.10. Dualidad de L^p . Sean $1 < p < \infty$ y q su exponente conjugado. Para todo funcional lineal acotado $\Lambda \in (L^p(\mu))^*$ existe un único $g \in L^q(\mu)$ tal que

$$\Lambda(f) = \int_{\Omega} fg d\mu \quad \forall f \in L^p(\mu), \quad (2.118)$$

y además $\|\Lambda\| = \|g\|_q$. En consecuencia $(L^p(\mu))^* \cong L^q(\mu)$.

Teorema 2.4.11. Dualidad de L^1 . El dual de $L^1(\mu)$ es isométricamente isomorfo a $L^\infty(\mu)$: para todo $\Lambda \in (L^1(\mu))^*$ existe un único $g \in L^\infty(\mu)$ tal que

$$\Lambda(f) = \int_{\Omega} fg d\mu \quad \forall f \in L^1(\mu), \quad (2.119)$$

con $\|\Lambda\| = \|g\|_\infty$.

Teorema 2.4.12. Convergencia en L^p implica convergencia en medida. Si $f_n \rightarrow f$ en $L^p(\mu)$ con $1 \leq p < \infty$, entonces $f_n \rightarrow f$ en medida. Si además $\mu(\Omega) < \infty$, existe una subsucesión que converge μ -casi en todas partes.

Teorema 2.4.13. Criterio de uniformemente integrabilidad en L^1 . Una sucesión $\{f_n\} \subset L^1(\mu)$ con $\mu(\Omega) < \infty$ satisface $f_n \rightarrow f$ en $L^1(\mu)$ si y solo si $f_n \rightarrow f$ en medida y la sucesión es uniformemente integrable, es decir,

$$\lim_{M \rightarrow \infty} \sup_n \int_{\{|f_n| > M\}} |f_n| d\mu = 0. \quad (2.120)$$

2.4.3 Medida signada

Definición 2.4.9. Medida signada. Sea $(\Omega, \mathcal{F})$ un espacio medible. Una función $\alpha: \mathcal{F} \rightarrow (-\infty, \infty]$ se llama una medida signada si

$$\alpha(\emptyset) = 0. \quad (2.121)$$

$$\text{Si } E = \bigsqcup_i E_i \text{ es una unión disjunta, entonces } \alpha(E) = \sum_i \alpha(E_i). \quad (2.122)$$

con las siguientes condiciones

$$\text{Si } \alpha(E) < \infty, \sum_i |\alpha(E_i)| \leq \infty \text{ y } \sum_i \alpha(E_i) = \alpha(E).$$

$$\text{Si } \alpha(E) = \infty, \text{ entonces } \sum_i \alpha(E_i)^- < \infty \text{ y } \sum_i \alpha(E_i)^+ = \infty.$$

Definición 2.4.10. Conjuntos positivos y negativos respecto de una medida signada. Un conjunto $A \in \mathcal{F}$ es positivo si

$$\forall B \subset A (\alpha(B) \geq 0). \quad (2.123)$$

Es negativo si

$$\forall B \subset A (\alpha(B) \leq 0). \quad (2.124)$$

Lema 2.4.1. Herencia y unión contable de conjuntos positivos. Todo subconjunto medible de un conjunto positivo es positivo y si A_n son conjuntos positivos, entonces $A = \bigcup_n A_n$ también es positivo.

Demostración. Lo primero es trivial. Para lo segundo defina $B_n = A_n \cap \bigcap_{m=1}^{n-1} A_m^c$, que son disjuntos y positivos. Sea $E \subset A$ medible, entonces $E = \bigcup_n E \cap B_n = \bigcup_n E_n$. Como cada B_n es positivo, se tiene $\alpha(E_n) \geq 0$, y por definición de medida signada

$$\alpha(E) = \sum_n \alpha(E_n) \geq 0.$$

□

Lema 2.4.2. Existencia de un subconjunto negativo. Si $\alpha(E) < 0$, entonces existe $F \subset E$ tal que:

$$F \text{ es negativo y } \alpha(F) < 0. \quad (2.125)$$

Demostración. Si E es negativo, ya está hecho. Si no, construimos una sucesión de subconjuntos $E_k \subset E$ tal que $\alpha(E_k) \geq 1/n_k$. Definimos $F_k = E - \bigcup_{j=1}^{k-1} E_j$. Si alguno F_k es negativo, terminamos. Si no, seguimos indefinidamente y definimos

$$F = E - \bigcup_k E_k = \bigcap_k F_k \Rightarrow \alpha(E) = \alpha(F) + \sum_k \alpha(E_k)$$

Como $\alpha(E) < 0$ y $\alpha(E_k) \geq 0$, se concluye que $\alpha(F) < 0$. Además, ningún subconjunto de F puede tener medida positiva, pues eso contradice la construcción.

□

2.4.4 Descomposición de Hahn y Jordan

Teorema 2.4.14. Descomposicion de Hahn. Sea α una medida signada. Entonces existen conjuntos $A, B \in \mathcal{F}$ tales que A es positivo, B es negativo, $\Omega = A \cup B$ y $A \cap B = \emptyset$.

Demostración. Sea $c = \inf\{\alpha(B) : \alpha(B) \leq 0, \forall A \subset B\} \leq 0$. Consideramos una sucesión $\{B_i\}$ de conjuntos negativos tal que $\alpha(B_i) \rightarrow c^+$, y definimos $B = \bigcup_i B_i$, es claro que $\alpha(B) \geq c$; para demostrar que $\alpha(B) \leq c$, observe que $\alpha(B) = \alpha(B_i) + \alpha(B - B_i) \leq \alpha(B_i)$, ya que B es negativo y $B - B_i \subset B$. Al tomar el límite cuando $i \rightarrow \infty$, obtenemos $\alpha(B) \leq c$, y por lo tanto $\alpha(B) = c$.

Ahora definimos $A = B^c$, y queremos probar que A es positivo. Supongamos que existe un conjunto medible $E \subset A$ tal que $\alpha(E) < 0$. Entonces, por el anterior, existe un subconjunto $F \subset E$ tal que F es negativo y $\alpha(F) < 0$. En ese caso, $B \cup F$ sería un conjunto negativo, y se tendría $\alpha(B \cup F) = \alpha(B) + \alpha(F) < c$, lo cual contradice la definición de c como ínfimo. Por lo tanto, tal conjunto E no puede existir, y se concluye que A es positivo. Así, hemos construido una partición $\Omega = A \cup B$ con A positivo y B negativo, y $A \cap B = \emptyset$.

□

Definición 2.4.11. Medidas mutuamente singulares. Sean μ_1 y μ_2 dos medidas sobre un espacio medible $(\Omega, \mathcal{F})$. Se dice que son *mutuamente singulares* si existe un conjunto $A \in \mathcal{F}$ tal que $\mu_1(A) = 0$ y $\mu_2(A^c) = 0$. En este caso, también se dice que μ_1 es singular con respecto a μ_2 , y se denota por $\mu_1 \perp \mu_2$.

Teorema 2.4.15. Descomposicion de Jordan. Sea α una medida signada. Entonces existen medidas α^+, α^- mutuamente singulares tales que

$$\alpha = \alpha^+ - \alpha^-. \quad (2.126)$$

Demostración. Sea $c = \inf\{\alpha(B) : B \text{ es negativo}\} \leq 0$. Consideramos una sucesión $\{B_i\}$ de conjuntos negativos tal que $\alpha(B_i) \rightarrow c^+$, y definimos $B = \bigcup_i B_i$. Dado que B es negativo, y por construcción se tiene que $\alpha(B) \geq c$. Para demostrar que $\alpha(B) \leq c$, observamos que $\alpha(B) = \alpha(B_i) + \alpha(B - B_i) \leq \alpha(B_i)$, ya que $B - B_i \subset B$ y B es negativo. Al tomar el límite cuando $i \rightarrow \infty$, obtenemos $\alpha(B) \leq c$, y por lo tanto $\alpha(B) = c$.

Definimos ahora $A = B^c$, y queremos probar que A es positivo. Supongamos que existe un conjunto medible $E \subset A$ tal que $\alpha(E) < 0$. Entonces, por el lema anterior, existe un subconjunto $F \subset E$ tal que F es negativo y $\alpha(F) < 0$. En ese caso, $B \cup F$ sería un conjunto negativo, y se tendría $\alpha(B \cup F) = \alpha(B) + \alpha(F) < c$, lo cual contradice la definición de c como ínfimo. Por lo tanto, tal conjunto E no puede existir, y se concluye que A es positivo. Así, hemos construido una partición $\Omega = A \cup B$ con A positivo y B negativo, y $A \cap B = \emptyset$.

A partir de esta descomposición de Hahn, definimos las medidas α^+ y α^- como sigue

$$\alpha^+(E) = \alpha(E \cap A), \quad \alpha^-(E) = -\alpha(E \cap B).$$

Como A es positivo y B es negativo, se tiene que α^+ y α^- son medidas no negativas. Además, $\alpha^+(B) = 0$ y $\alpha^-(A) = 0$, por lo que son mutuamente singulares. Se verifica que $\alpha = \alpha^+ - \alpha^-$ por construcción.

Para probar la unicidad de esta descomposición, supongamos que existe otra pareja de medidas ν_1, ν_2 tales que $\alpha = \nu_1 - \nu_2$, y que existe un conjunto $D \in \mathcal{F}$ tal que $\nu_1(D) = 0$ y $\nu_2(D^c) = 0$. Definimos $C = D^c$, de modo que $\Omega = C \cup D$ es otra descomposición de Hahn. Por la elección de D , se tiene

$$\nu_1(E) = \alpha(E \cap C), \quad \nu_2(E) = -\alpha(E \cap D).$$

La unicidad de la descomposición de Hahn implica que las intersecciones $A \cap D$ y $B \cap C$ son conjuntos nulos, es decir, tienen medida cero. Por lo tanto

$$\alpha(E \cap C) = \alpha(E \cap (A \cup C)) = \alpha(E \cap A),$$

lo que implica que $\nu_1 = \alpha^+$. De manera análoga, se concluye que $\nu_2 = \alpha^-$, lo que demuestra la unicidad de la descomposición de Jordan. □

Definición 2.4.12. Absoluta continuidad. Se dice que ν es absolutamente continua con respecto de μ $\nu \ll \mu$ si

$$\mu(A) = 0 \Rightarrow \nu(A) = 0. \quad (2.127)$$

Teorema 2.4.16. Descomposición de Lebesgue. Sean μ y ν medidas σ -finitas sobre un espacio medible $(\Omega, \mathcal{F})$. Entonces existe una descomposición única $\nu = \nu_r + \nu_s$ donde $\nu_r \ll \mu$, $\nu_s \perp \mu$, y existe una función $g \geq 0$ medible tal que

$$\nu_r(E) = \int_E g d\mu \quad \text{para todo } E \in \mathcal{F}. \quad (2.128)$$

Demostración. Supongamos primero que μ y ν son finitas. Sea

$$\mathcal{G} = \left\{ g \geq 0 \text{ medible} : \int_E g d\mu \leq \nu(E) \quad \forall E \in \mathcal{F} \right\}$$

y $\kappa = \sup\{\int g d\mu : g \in \mathcal{G}\} \leq \nu(\Omega) < \infty$. Si $g, h \in \mathcal{G}$ y $A = \{g > h\}$, entonces

$$\int_E (g \vee h) d\mu = \int_{E \cap A} g d\mu + \int_{E \cap A^c} h d\mu \leq \nu(E \cap A) + \nu(E \cap A^c) = \nu(E),$$

luego $g \vee h \in \mathcal{G}$. Tomemos $g_n \in \mathcal{G}$ con $\int g_n d\mu > \kappa - 1/n$ y definamos $h_n = g_1 \vee \dots \vee g_n$. Entonces $h_n \in \mathcal{G}$,

$h_n \nearrow h$, y por convergencia monótona

$$\int h \, d\mu = \lim_{n \rightarrow \infty} \int h_n \, d\mu \geq \lim_{n \rightarrow \infty} \int g_n \, d\mu = \kappa.$$

Como $h \in \mathcal{G}$ también $\int h \, d\mu \leq \kappa$, luego $\int h \, d\mu = \kappa$. Definimos

$$\nu_r(E) = \int_E h \, d\mu, \quad \nu_s(E) = \nu(E) - \nu_r(E).$$

Como $h \in \mathcal{G}$ se tiene $\nu_r(E) \leq \nu(E)$ para todo E , luego $\nu_s \geq 0$ y $\nu_r \ll \mu$ por definición.

Probamos que $\nu_s \perp \mu$. Para cada $\varepsilon > 0$, la medida signada $\nu_s - \varepsilon\mu$ es finita, y por la descomposición de Hahn existe $A_\varepsilon \in \mathcal{F}$ positivo para $\nu_s - \varepsilon\mu$, con $B_\varepsilon = A_\varepsilon^c$ negativo. Si $\mu(A_\varepsilon) > 0$, entonces para todo $E \in \mathcal{F}$,

$$\int_E (h + \varepsilon \mathbf{1}_{A_\varepsilon}) \, d\mu = \nu_r(E) + \varepsilon\mu(E \cap A_\varepsilon) \leq \nu_r(E) + \nu_s(E \cap A_\varepsilon) \leq \nu(E),$$

donde en la primera desigualdad usamos que A_ε es positivo para $\nu_s - \varepsilon\mu$. Entonces $h + \varepsilon \mathbf{1}_{A_\varepsilon} \in \mathcal{G}$ y $\int (h + \varepsilon \mathbf{1}_{A_\varepsilon}) \, d\mu = \kappa + \varepsilon\mu(A_\varepsilon) > \kappa$, contradiciendo la definición de κ . Luego $\mu(A_\varepsilon) = 0$.

Sea $A = \bigcup_{n=1}^{\infty} A_{1/n}$, de modo que $\mu(A) = 0$. Para todo $E \subseteq A^c$ y todo $n \geq 1$, como $A^c \subseteq B_{1/n}$ es negativo para $\nu_s - \frac{1}{n}\mu$,

$$\nu_s(E) \leq \frac{1}{n}\mu(E).$$

Tomando $n \rightarrow \infty$ se obtiene $\nu_s(E) = 0$ para todo $E \subseteq A^c$, luego $\nu_s(A^c) = 0$ y por tanto $\nu_s \perp \mu$.

Para la unicidad, supongamos $\nu = \nu_r + \nu_s = \nu'_r + \nu'_s$ con $\nu_r, \nu'_r \ll \mu$ y $\nu_s, \nu'_s \perp \mu$. Entonces $\nu_r - \nu'_r = \nu'_s - \nu_s$. El lado izquierdo es absolutamente continuo respecto a μ y el derecho es singular respecto a μ , luego ambos son cero, es decir $\nu_r = \nu'_r$ y $\nu_s = \nu'_s$.

El caso σ -finito se reduce al finito tomando una partición $\Omega = \bigsqcup_n \Omega_n$ con $\mu(\Omega_n), \nu(\Omega_n) < \infty$, aplicando el resultado en cada Ω_n y definiendo $g = \sum_n g_n \mathbf{1}_{\Omega_n}$, $\nu_s = \sum_n \nu_s^{(n)}$.

□

Definición 2.4.13. Completitud de la medida. Sea $(\Omega, \mathcal{F}, \mu)$ un espacio de medida. Decimos que la medida μ es *completa* si para todo conjunto $A \in \mathcal{F}$ con $\mu(A) = 0$, se cumple que cualquier subconjunto $B \subseteq A$ también pertenece a $\mathcal{F}$ y satisface $\mu(B) = 0$.

Lema 2.4.3. Extensión de la σ -álgebra. Dado un espacio de medida $(\Omega, \mathcal{F}, \mu)$ no necesariamente completo, existe una extensión $\overline{\mathcal{F}}$ de la σ -álgebra $\mathcal{F}$ definida como

$$\overline{\mathcal{F}} := \{E \cup N : E \in \mathcal{F}, N \subseteq A \text{ con } A \in \mathcal{F}, \mu(A) = 0\}.$$

La medida extendida $\overline{\mu}$ sobre $\overline{\mathcal{F}}$ se define por

$$\overline{\mu}(E \cup N) := \mu(E).$$

Se prueba después.

Teorema 2.4.17. Completitud de la extensión. La extensión $(\Omega, \overline{\mathcal{F}}, \overline{\mu})$ es un espacio de medida completo, y $\overline{\mu}$ coincide con μ sobre $\mathcal{F}$.

Se prueba después.

2.4.5 Radon-Nikodym

Teorema 2.4.18. Radon-Nikodym. Sean μ, ν medidas σ -finitas con $\nu \ll \mu$. Entonces existe una función $g \geq 0$ tal que:

$$\nu(E) = \int_E g d\mu \quad \forall E \in \mathcal{F} \quad (2.129)$$

Además, si h también satisface esta propiedad, entonces:

$$g = h \quad \mu \text{ en casi todas partes.} \quad (2.130)$$

Demostración. Por el teorema de descomposición de Lebesgue existe $\nu = \nu_r + \nu_s$ con $\nu_r \ll \mu$, $\nu_s \perp \mu$ y $\nu_r(E) = \int_E g d\mu$ para cierta $g \geq 0$ medible. Sea $A \in \mathcal{F}$ tal que $\mu(A) = 0$ y $\nu_s(A^c) = 0$. Como $\nu \ll \mu$, se tiene $\nu(A) = 0$, luego $\nu_s(A) \leq \nu(A) = 0$. Junto con $\nu_s(A^c) = 0$ se concluye $\nu_s \equiv 0$, de modo que $\nu = \nu_r$ y

$$\nu(E) = \int_E g d\mu \quad \forall E \in \mathcal{F}.$$

Para la unicidad, supongamos que $h \geq 0$ satisface también $\nu(E) = \int_E h d\mu$ para todo $E \in \mathcal{F}$. Entonces $\int_E (g - h) d\mu = 0$ para todo E . Para cada $n \in \mathbb{N}$ tomemos $E_n = \{g > h, g \leq n\}$. En E_n se tiene $g - h > 0$ y la integral es cero, luego $\mu(E_n) = 0$. Como $\{g > h\} = \bigcup_n E_n$, se obtiene $\mu(\{g > h\}) = 0$. Análogamente $\mu(\{h > g\}) = 0$, luego $g = h$ μ c.s. □

* Cabe recalcar que esta anterior parte tiene diferentes errores que futuramente serán corregidos.

2.5 Probabilidades curiosas

Definición 2.5.1. Distribución de probabilidad en un espacio contable. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, con $\Omega = \{\omega_1, \omega_2, \dots\}$ contable o finito y $\mathcal{F} = \mathcal{P}(\Omega)$, si $A \subset \Omega$ y $A \neq \emptyset$ se define

$$\mathbb{P}(A) = \sum_{\omega_i \in A} p_i. \quad (2.131)$$

Con $p_i := \mathbb{P}(\omega_i)$, al vector $p := (p_1, p_2, \dots)$ se le llama vector de probabilidad

Definición 2.5.2. Probabilidad geométrica. Si $(\Omega, \mathcal{F})$ es un espacio de medible. Con m una medida geométrica sobre $\mathcal{F}$ con $m(\Omega) < \infty$, entonces la probabilidad geométrica se define por

$$\mathbb{P}(A) = \frac{m(A)}{m(\Omega)}. \quad (2.132)$$

Con $A \in \mathcal{F}$

Definición 2.5.3. Probabilidad de Laplace. Un espacio de probabilidad de Laplace, es un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ que cumple que

$$|\Omega| < \infty, \quad (2.133)$$

$$\mathcal{F} = \mathcal{P}(\Omega), \quad (2.134)$$

$$\mathbb{P}(\omega) = \frac{1}{|\Omega|}, \forall \omega \in \Omega. \quad (2.135)$$

A esta medida se le llama distribución clásica o uniforme.

2.6 Probabilidades condicionales

Definición 2.6.1. Probabilidad condicional. Si $A, B \in \mathcal{F}$ en un espacio de probabilidad y $\mathbb{P}(B) > 0$, entonces la probabilidad condicional de A condicionada a B se denota y define por

$$\mathbb{P}(A|B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (2.136)$$

Teorema 2.6.1. Teorema fundamental de la probabilidad condicional. Si $A, B \in \mathcal{F}$ en un espacio de probabilidad y $\mathbb{P}(B) > 0$, entonces

$$\mathbb{D}(A) := \mathbb{P}(A|B) \text{ es una medida de probabilidad,} \quad (2.137)$$

$$\mathbb{P}(A \cap C|B) = \mathbb{P}(A|B \cap C)\mathbb{P}(C|B) \text{ si } \mathbb{P}(B \cap C) > 0. \quad (2.138)$$

Sumado a ello si $A_1, \dots, A_n \in \mathcal{F}$ con $\mathbb{P}(A_1 \cap \dots \cap A_i) > 0, \forall_{i \leq n-1}$ entonces

$$\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1)\mathbb{P}(A_2|A_1)\mathbb{P}(A_3|A_1 \cap A_2) \dots \mathbb{P}(A_n|A_1 \cap \dots \cap A_{n-1}) \quad (2.139)$$

Demostración. Note que

$$\mathbb{D}(\Omega) = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1.$$

Sumado a ello es trivial demostrar que $\mathbb{D} \geq 0$. Ahora note que

$$\mathbb{D}\left(\bigcup_{i=1}^{\infty} A_i\right) = \frac{\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i \cap B\right)}{\mathbb{P}(B)} = \sum_{i=1}^{\infty} \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \sum_{i=1}^{\infty} \mathbb{D}(A_i).$$

Para el segundo caso, note simplemente que

$$\mathbb{P}(A \cap C|B) = \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A \cap B \cap C)\mathbb{P}(B \cap C)}{\mathbb{P}(B \cap C)\mathbb{P}(B)} = \mathbb{P}(A|B \cap C)\mathbb{P}(C|B).$$

Y por ultimo es simplemente tomar lo anterior por inducción. □

Teorema 2.6.2. Teorema de probabilidad total. Si $\{B_1, B_2, \dots\}$ es una partición de Ω (Donde $B_i \cap B_j = \emptyset$ si $i \neq j$ y $\bigcup B_i = \Omega$) con $\mathbb{P}(B_i) > 0, \forall_{B_i \in \mathcal{F}}$, entonces

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A|B_i)\mathbb{P}(B_i). \quad (2.140)$$

Con $A \in \mathcal{F}$.

Demostración. Note que

$$\mathbb{P}(A) = \mathbb{P}(A \cap \Omega) = \mathbb{P}\left(\bigcup_i B_i \cap A\right) = \sum_i \mathbb{P}(B_i \cap A) = \sum_i \mathbb{P}(A|B_i)\mathbb{P}(B_i)$$

□

Teorema 2.6.3. Teorema de Bayes. Sea $\{B_1, B_2, \dots\}$ una partición de Ω con $\mathbb{P}(B_i) > 0, \forall_{B_i \in \mathcal{F}}$, entonces para cualquier evento $\mathbb{P}(A) > 0$ tenemos que

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_i \mathbb{P}(A|B_i)\mathbb{P}(B_i)}. \quad (2.141)$$

Demostración. Note que por definición de probabilidad condicional y el teorema anterior

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_i \mathbb{P}(A|B_i)\mathbb{P}(B_i)}.$$

□

2.7 Eventos independientes

Definición 2.7.1. Independencia de eventos. Eventos A y B sobre un mismo espacio de probabilidad son llamados independientes si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B). \quad (2.142)$$

Si no se cumple la condición se les llama dependientes.

Cabe recalcar que dos eventos sean independientes no esta conectado directamente con que sea mutuamente excluyentes (Dos eventos son mutuamente excluyentes si $A \cap B = \emptyset$).

Definición 2.7.2. Familias independientes. Las familias $\mathcal{A}_i \subset \mathcal{F}$ se dicen ser independientes si

$$\mathbb{P}\left(\bigcap_i A_i\right) = \prod_i \mathbb{P}(A_i), \forall_{(i \leq n \wedge A_i \in \mathcal{A}_i)}. \quad (2.143)$$

Mas aun, se que las familias de eventos $(A_k)_{k \in I}$ son independientes si

$$\mathbb{P}\left(\bigcap_k A_k\right) = \prod_k \mathbb{P}(A_k), \forall_{(k \in J \wedge (A_k)_{k \in J})}. \quad (2.144)$$

Con $J \subset I$ finito no vacío (Estos eventos son llamados mutuamente independientes). Por ultimo, son independientes 2 a 2 o en pares si

$$\mathbb{P}(A_i \cap A_j) = \mathbb{P}(A_i)\mathbb{P}(A_j), \forall_{i \neq j} \quad (2.145)$$

3

Variables aleatorias

3.1 Funciones medibles

Definición 3.1.1. Función medible. Una función $X : \Omega \rightarrow S$ se dice que es una función medible de $(\Omega, \mathcal{F})$ a $(S, \mathcal{S})$ si

$$X^{-1}(A) \equiv \{\omega \in \Omega : X(\omega) \in A\} \in \mathcal{F} \quad \text{para todo } A \in \mathcal{S}. \quad (3.1)$$

Teorema 3.1.1. Teorema de la medibilidad por generador. Sea $X : \Omega \rightarrow S$ una función entre espacios medibles. Si $\{\omega : X(\omega) \in A\} \in \mathcal{F}$ para todo $A \in \mathcal{A}$, y $\mathcal{A}$ genera $\mathcal{S}$ (es decir, $\mathcal{S}$ es la σ -álgebra más pequeña que contiene a $\mathcal{A}$), entonces X es medible.

Demostración. Note que

$$\{X \in \bigcup_i B_i\} = \bigcup_i \{X \in B_i\}, \quad \{X \in B^c\} = (\{X \in B\})^c.$$

Esto muestra que la clase de conjuntos $\mathcal{B} = \{B : \{X \in B\} \in \mathcal{F}\}$ es una σ -álgebra. Como $\mathcal{B} \supset \mathcal{A}$ y $\mathcal{A}$ genera $\mathcal{S}$, se concluye que $\mathcal{B} \supset \mathcal{S}$. Por lo tanto, X es medible. □

Teorema 3.1.2. Teorema de la composición de funciones medibles. Sea $X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S})$ y $f : (S, \mathcal{S}) \rightarrow (T, \mathcal{T})$ aplicaciones medibles. Entonces $f(X)$ es una aplicación medible de $(\Omega, \mathcal{F})$ a $(T, \mathcal{T})$.

Demostración. Sea $B \in \mathcal{T}$. Entonces

$$\{\omega \in \Omega : f(X(\omega)) \in B\} = \{\omega \in \Omega : X(\omega) \in f^{-1}(B)\}$$

Como f es medible, se tiene que $f^{-1}(B) \in \mathcal{S}$, y como X es medible, se concluye que $\{\omega : X(\omega) \in f^{-1}(B)\} \in \mathcal{F}$. Por lo tanto, $f(X)$ es medible. $\square$

Definición 3.1.2. σ -álgebra de Borel. Sea $\Omega = \mathbb{R}^d$ con $d \in \mathbb{N}$, entonces la menor *sigma*-álgebra sobre $\mathbb{R}^d$ que contiene todos los abiertos $A \subset \mathbb{R}^d$ se denota por $\mathcal{B}(\mathbb{R}^d)$ y es llamada σ -álgebra de Borel.

Teorema 3.1.3. Caracterización de la σ -álgebra de Borel. Sea $\mathcal{B}(\mathbb{R})$ la σ -álgebra de Borel, entonces

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(a, b] \mid -\infty \leq a < b < \infty\}) = \sigma(\{(-\infty, b] \mid b \in \mathbb{R}\}). \quad (3.2)$$

De forma general

$$\mathcal{B}(\mathbb{R}^d) = \sigma\left(\left\{\bigtimes_{i=1}^d (a_i, b_i] \mid -\infty \leq a_i < b_i < \infty, \forall_{i \leq d}\right\}\right) \quad (3.3)$$

Demostración. Tome $A \in \mathcal{B}(\mathbb{R})$, dado que todo abierto es la unión de abiertos de la forma $(c, d) \mid c < d \wedge c, d \in \mathbb{R}$, se va a demostrar que todo abierto de la forma $(c, d) \in \sigma(\cdot)$. Note que.

$$(c, d) = (-\infty, c]^c \cap \bigcup_{n \geq 1} (-\infty, d - 1/n] \Rightarrow \sigma(\{(a, b] \mid -\infty \leq a < b < \infty\}) \subset \mathcal{B}(\mathbb{R}) = \sigma(\{(-\infty, b] \mid b \in \mathbb{R}\})$$

Ahora tome $(-\infty, d]$ y note que.

$$(-\infty, d] = (d, \infty)^c \Rightarrow \sigma(\{(a, b] \mid -\infty \leq a < b < \infty\}) = \mathcal{B}(\mathbb{R}) \subset \sigma(\{(-\infty, b] \mid b \in \mathbb{R}\}) \Rightarrow \mathcal{B}(\mathbb{R}) = \sigma(\cdot)$$

La segunda parte del ejercicio es consecuencia directa de lo anteriormente demostrado. $\square$

3.2 Propiedades de la variables aleatorias

Definición 3.2.1. Variable aleatoria. Sea $(\Omega, \mathcal{F})$ un espacio medible. Una función $X : \Omega \rightarrow \mathbb{R}$ es llamado una variable aleatoria si para todo $A \in \mathcal{B}(\mathbb{R})$

$$X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\} \in \mathcal{F}. \quad (3.4)$$

Donde $X^{-1}(A) \in \mathcal{F}$

Usualmente se utiliza la notación $X^{-1}(A) = \{X \in A\}$ para referirse a los subconjuntos de $\mathcal{F}$.

Proposición 3.2.1. Equivalente de variable aleatoria. Sea $X : \Omega \rightarrow \mathbb{R}$, entonces es equivalente

$$X \text{ es una variable aleatoria,} \quad (3.5)$$

$$\{X \leq y\} := X^{-1}((-\infty, y]) \in \mathcal{F} \text{ o } \{X < y\} := X^{-1}((-\infty, y)) \in \mathcal{F} \quad (3.6)$$

$$\{a < X \leq b\} := X^{-1}((a, b]) \mid -\infty \leq a < b < \infty \quad (3.7)$$

La demostración es consecuencia directa de la σ -álgebra de Borel y la definición anterior.

Normalmente los libros dividen la siguiente sección en variables aleatorias discretas y continuas, pero es casi lo mismo entonces solo se va a ver generalizado.

Teorema 3.2.1. Operaciones algebraicas con variables aleatorias. Si X, Y dos variables aleatorias, entonces

$$X + Y \text{ es variable aleatoria,} \quad (3.8)$$

$$k \cdot X \text{ es variable aleatoria con } k \in \mathbb{R}, \quad (3.9)$$

$$X \cdot Y \text{ es variable aleatoria.} \quad (3.10)$$

Más aun, si $\{Y = 0\} \neq \emptyset$, entonces

$$\frac{X}{Y} \text{ es variable aleatoria.} \quad (3.11)$$

Demostración. Para el primer caso note que si definimos

$$A := \bigcup_{r \in \mathbb{Q}} (\{X < r\} \cap \{Y < z - r\}).$$

Entonces $A \in \mathcal{F}$ ya que es una unión contable de elementos de $\mathcal{F}$. Dado que

$$\{X < r\} \cap \{Y < z - r\} = \{\omega \in \Omega \mid X(\omega) \in (-\infty, r)\} \cap \{\omega \in \Omega \mid Y(\omega) \in (-\infty, z - r)\}.$$

Se puede inferir que

$$\bigcup_{r \in \mathbb{Q}} (\{\omega \in \Omega \mid X(\omega) \in (-\infty, r)\} \cap \{\omega \in \Omega \mid Y(\omega) \in (-\infty, z - r)\}) \subset (X + Y)^{-1}((-\infty, z)).$$

Donde

$$(X + Y)^{-1}((-\infty, z)) = \{\omega \in \Omega \mid X(\omega) + Y(\omega) \in (-\infty, z)\}.$$

Ahora note que si $\omega \in \{A + Y < z\}$ entonces $X(\omega) < z - Y(\omega)$, en cuyo caso, por densidad de $\mathbb{Q}$ en $\mathbb{R}$ tenemos que $\exists l \in \mathbb{Q} \mid X(\omega) < l < z - Y(\omega)$, entonces se sigue que $\{X + Y < z\} \subset A$, en consecuencia $A = \{X + Y < z\}$.

Siguiendo con la demostración simplemente note que si $k = 0$ tenemos que si $z < 0$ se sigue que $\{kX \leq z\} = \emptyset$ ya que no hay $z \in \mathbb{R} \mid z < 0 < z$, caso contrario si $z \geq 0$ entonces $\{kX \leq z\} = \Omega$ claramente, y en consecuencia kX cumple con la definición de variable aleatoria. Ahora si $k > 0$ entonces $\{kX \leq z\} = \{X \leq \frac{z}{k}\}$, caso similar si $k < 0$ se sigue que $\{kX \leq z\} = \{X \geq \frac{z}{k}\}$ entonces kX es una variable aleatoria.

Para (3.11) primero note que X^2 es una variable aleatoria, ya que si $z < 0$ entonces $\{X^2 \leq z\} = \emptyset$, y si $z \geq 0$ entonces $\{X^2 \leq z\} = \{-\sqrt{z} \leq X \leq \sqrt{z}\} = \{X \leq \sqrt{z}\} \cap \{X \geq -\sqrt{z}\} \in \mathcal{F}$, entonces simplemente note que

$$X \cdot Y = \frac{(X + Y)^2 - (X - Y)^2}{4}.$$

En consecuencia $X \cdot Y$ es una variable aleatoria.

Y por ultimo para (3.12) note que

$$\begin{aligned} \left\{ \frac{X}{Y} \leq z \right\} &= \left(\left\{ \frac{X}{Y} \leq z \right\} \cap \{Y < 0\} \right) \cup \left(\left\{ \frac{X}{Y} \leq z \right\} \cap \{Y > 0\} \right) \\ &= (\{X - zY \geq 0\} \cap \{Y < 0\}) \cup (\{X - zY \leq 0\} \cap \{Y > 0\}). \end{aligned}$$

Lo cual es la unión de los eventos de la suma de dos σ -álgebras X, Y , por (3.9) esto es una variable aleatoria. □

Teorema 3.2.2. Máximo y mínimo de variables aleatorias. Sean $X_1, \dots, X_n$ variables aleatorias, entonces $\max_{1 \leq k \leq n} X_k$ y $\min_{1 \leq k \leq n} X_k$ son variables aleatorias.

Demostración. Tome $y \in \mathbb{R}$, entonces note que

$$\{\max_{1 \leq k \leq n} X_k \leq y\} = \left(\bigcup_{k=1}^n \{X_k > y\} \right)^c = \bigcap_{k=1}^n \{X_k \leq y\} \in \mathcal{F}.$$

Ya para que $\max_{1 \leq k \leq n} X_k \leq y$ todos los $X_k \leq y$, si alguno de los $X_k > y$ entonces $\max_{1 \leq k \leq n} X_k > y$, en cuyo caso sería el evento complemento. De forma similar podemos llegar a que

$$\{\min_{1 \leq k \leq n} X_k \leq y\} = \bigcup_{k=1}^n \{X_k \leq y\} \in \mathcal{F}.$$

□

Teorema 3.2.3. Composición de variables aleatorias. Si $X_1, \dots, X_n$ son variables aleatorias y $f : (\mathbb{R}^n, \mathcal{R}^n) \rightarrow (\mathbb{R}, \mathcal{R})$ es una función medible, entonces $f(X_1, \dots, X_n)$ es una variable aleatoria.

Demostración. Note que si $A_1, \dots, A_n$ son conjuntos de Borel, entonces

$$\{(X_1, \dots, X_n) \in A_1 \times \dots \times A_n\} = \bigcap_{i=1}^n \{X_i \in A_i\} \in \mathcal{F}$$

Dado que los conjuntos de la forma $A_1 \times \dots \times A_n$ generan la σ -álgebra de Borel en $\mathbb{R}^n$, entonces $f(X)$ es una variable aleatoria.

□

Definición 3.2.2. σ -álgebra generada por una variable aleatoria La *sigma*-álgebra generada por la variable aleatoria X es la colección

$$\sigma(X) := \{X^{-1}(A) \mid A \in \mathcal{B}(\mathbb{R})\} \quad (3.12)$$

Donde $\sigma(X)$ es toda la información generada por X (Toda la información conocida por definición).

3.3 Distribución de probabilidad

Definición 3.3.1. Distribución inducida por una variable aleatoria. Si $\mathbb{P}$ es una medida de probabilidad sobre $(\Omega, \mathcal{F})$, se le llama distribución de probabilidad de X a $\mathbb{P}_X$ definida sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ y esta definida por

$$\mathbb{P}_X(A) := \mathbb{P}(\{X \in A\}), \forall A \in \mathcal{B}(\mathbb{R}). \quad (3.13)$$

Proposición 3.3.1. La distribución inducida por una variable aleatoria es una medida de probabilidad. $\mathbb{P}_X$ es una medida de probabilidad sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Demostración. Primero note que

$$\mathbb{P}_X(\mathbb{R}) = \mathbb{P}(\{X \in \mathbb{R}\}) = \mathbb{P}(X^{-1}(\mathbb{R})).$$

Y dado que $\forall \omega \in \Omega (X(\omega) \in \mathbb{R})$, entonces $\mathbb{P}(X^{-1}(\mathbb{R})) = \mathbb{P}(\Omega) = 1$. Ahora para la segunda propiedad tome $(A_i)_i$ una sucesión disjunta de subconjuntos de $\mathbb{R}$, entonces note que

$$\mathbb{P}_X\left(\bigcup_{i=1}^{\infty} A_i\right) = \mathbb{P}\left(\left\{X \in \bigcup_{i=1}^{\infty} A_i\right\}\right) = \mathbb{P}\left(\bigcup_{i=1}^{\infty} X^{-1}(A_i)\right).$$

Dado que $A_i \cap A_j = \emptyset \iff i \neq j$, entonces por el hecho de pertenencia de cada uno de estos

conjuntos, tenemos que $X^{-1}(A_i) \neq X^{-1}(A_j) \iff i \neq j$, entonces

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} X^{-1}(A_i)\right) = \sum_{i=1}^{\infty} \mathbb{P}(X^{-1}(A_i)) = \sum_{i=1}^{\infty} \mathbb{P}_X(A_i).$$

□

3.3.1 Distribucion acumulada

Definición 3.3.2. Función de distribución acumulada. Se le llama función de distribución a la función $F_X : \mathbb{R} \rightarrow [0, 1]$, con X variable aleatoria sobre $(\Omega, \mathcal{F}, \mathbb{P})$, y se define como

$$F_X(y) := \mathbb{P}(X \leq y), \forall y \in \mathbb{R}. \quad (3.14)$$

Teorema 3.3.1. Propiedades de la función de distribución acumulada Sea F_X una función de distribución de una variable aleatoria sobre $(\Omega, \mathcal{F}, \mathbb{P})$, entonces

$$x < y \Rightarrow F_X(x) \leq F_X(y), \quad (3.15)$$

$$F_X(y^+) := \lim_{h \rightarrow 0^+} F_X(y + h) = F_X(y), \forall y \in \mathbb{R}, \quad (3.16)$$

$$F_X(y^-) := \lim_{h \rightarrow 0^-} F_X(y + h) = \mathbb{P}(X < y), \forall y \in \mathbb{R}, \quad (3.17)$$

$$\lim_{y \rightarrow \infty} F_X(y) = 1, \quad (3.18)$$

$$\lim_{y \rightarrow -\infty} F_X(y) = 0. \quad (3.19)$$

Demostración. Primero note simplemente que si $x < y$ entonces $\{X \leq x\} \subset \{X \leq y\}$ entonces $F_X(x) \leq F_X(y)$.

Para la segunda tome

$$A_n = \left\{ X \leq y + \frac{1}{n} \right\}.$$

Y note que $\{X \leq y\} = \bigcap_{n=i}^{\infty} A_n$ con $i \in \mathbb{N}$, entonces

$$F_X(y^+) = \lim_{h \rightarrow 0^+} F_X(y + h) = \lim_{n \rightarrow \infty} \mathbb{P}\left(\left\{X \leq y + \frac{1}{n}\right\}\right) = \mathbb{P}\left(\bigcap_{n=i}^{\infty} A_n\right) = \mathbb{P}(\{X \leq y\}) = F_X(y).$$

Ahora para tercera podemos tomar

$$A_n = \left\{ X \leq y - \frac{1}{n} \right\}.$$

Entonces $\{X < y\} = \bigcup_{n=i}^{\infty} A_n$ con $i \in \mathbb{N}$, entonces

$$F_X(y^-) = \lim_{h \rightarrow 0^-} F_X(y + h) = \lim_{n \rightarrow \infty} \mathbb{P}\left(\left\{X \leq y - \frac{1}{n}\right\}\right) = \mathbb{P}\left(\bigcup_{n=i}^{\infty} A_n\right) = \mathbb{P}(\{X < y\}) = \mathbb{P}(X < y).$$

Continuando, es claro que $\{X \leq n\} \subset \{X \leq n+1\}$, entonces $\bigcup_{n=i}^{\infty} \{X \leq n\} = \Omega$. De igual forma note

que $\{X \leq -n\} \supset \{X \leq -(n+1)\}$, entonces $\bigcap_{n=i}^{\infty} \{X \leq -n\} = \emptyset$, en consecuencia.

$$\mathbb{P}\left(\bigcup_{n=i}^{\infty} \{X \leq n\}\right) = \mathbb{P}(\Omega) = 1$$

$$\mathbb{P}\left(\bigcap_{n=i}^{\infty} \{X \leq -n\}\right) = \mathbb{P}(\emptyset) = 0.$$

□

Corolario 3.3.1. Cálculo de probabilidades mediante la función de distribución acumulada Sea F_X una función de distribución de una variable aleatoria sobre $(\Omega, \mathcal{F}, \mathbb{P})$, entonces

$$\mathbb{P}(a \leq X \leq b) = F_X(b) - F_X(a^-) \quad (3.20)$$

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a) \quad (3.21)$$

$$\mathbb{P}(a \leq X < b) = F_X(b^-) - F_X(a^-) \quad (3.22)$$

$$\mathbb{P}(a < X < b) = F_X(b^-) - F_X(a) \quad (3.23)$$

$$\mathbb{P}(X = a) = F_X(a) - F_X(a^-) \quad (3.24)$$

La demostración queda al lector.

Definición 3.3.3. Salto de la función de distribución acumulada. Si $a \in \mathbb{R}$ y $\Delta F_X(a) := F_X(a) - F_X(a^-) \neq 0$ entonces se dice que F_X tiene un salto en a .

3.3.2 Función de Stieltjes

Definición 3.3.4. Función de Stieltjes. Una función $F: \mathbb{R} \rightarrow \mathbb{R}$ se denomina función de medida de Stieltjes si cumple las $x \leq y \Rightarrow F(x) \leq F(y)$ y $\forall x \in \mathbb{R} \lim_{y \rightarrow x^-} F(y) = F(x)$.

Teorema 3.3.2. Teorema de Stieltjes. Asociada a cada función de medida de Stieltjes F (o también llamada función de distribución), existe una medida única μ sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ tal que

$$\mu((a, b]) = F(b) - F(a) \quad (3.25)$$

Cuando $F(x) = x$, la medida resultante se denomina (λ) medida de Lebesgue.

Demostración. Sea S la semiálgebra de intervalos semiabiertos $(a, b]$ con $-\infty \leq a < b \leq \infty$. Para definir μ sobre S , comenzamos observando que

$$F(\infty) = \lim_{x \rightarrow \infty^-} F(x) \quad \text{y} \quad F(-\infty) = \lim_{x \rightarrow -\infty^+} F(x)$$

existen, y que $\mu((a, b]) = F(b) - F(a)$ tiene sentido para todo $-\infty \leq a < b \leq \infty$, dado que $F(\infty) > -\infty$ y $F(-\infty) < \infty$. Si $(a, b] = \bigcup_{i=1}^n (a_i, b_i]$, entonces, tras reordenar los intervalos, se debe tener $a_1 = a$, $b_n = b$, y $a_i = b_{i-1}$ para $2 \leq i \leq n$, entonces la primera condición de *Teorema 2.2.5.*

Para la segunda condición, supongamos primero que $-\infty < a < b < \infty$, y que $(a, b] \subset \bigcup_{i \geq 1} (a_i, b_i]$, donde $-\infty < a_i < b_i < \infty$. Sea $\delta > 0$ tal que $F(a + \delta) < F(a) + \varepsilon$, y elijamos $\eta_i > 0$ tal que

$$F(b_i + \eta_i) < F(b_i) + \varepsilon 2^{-i}.$$

Los intervalos abiertos $(a_i, b_i + \eta_i)$ cubren $[a + \delta, b]$, por lo que existe un subcubrimiento finito (α_j, β_j) , $1 \leq j \leq J$. Como $(a + \delta, b] \subset \bigcup_{j=1}^J (\alpha_j, \beta_j]$, se sigue entonces que

$$F(b) - F(a + \delta) \leq \sum_{j=1}^J F(\beta_j) - F(\alpha_j) \leq \sum_{i=1}^{\infty} (F(b_i + \eta_i) - F(a_i)).$$

Por la elección de δ y η_i ,

$$F(b) - F(a) \leq 2\varepsilon + \sum_{i=1}^{\infty} (F(b_i) - F(a_i)),$$

y como ε es arbitrario, se ha demostrado el resultado en el caso $-\infty < a < b < \infty$.

Ahora si $-\infty \leq a < b \leq \infty$, observemos que si $(a, b] \subset \bigcup_i (a_i, b_i]$ y $(A, B] \subset (a, b]$ con $-\infty < A < B < \infty$, entonces

$$F(B) - F(A) \leq \sum_{i=1}^{\infty} (F(b_i) - F(a_i)).$$

Como este resultado es válido para cualquier intervalo finito $(A, B] \subset (a, b]$, se concluye el resultado deseado. $\square$

El resultado anterior se puede generalizar para $\mathbb{R}^d$.

Definición 3.3.5. Función de distribución en $\mathbb{R}^d$. Una función $F : \mathbb{R}^d \rightarrow [0, 1]$ se dice una función de distribución en $\mathbb{R}^d$ si satisface

F es no decreciente, es decir, si $x \leq y$ coordenada a coordenada entonces $F(x) \leq F(y)$. (3.26)

F es continua por derecha, es decir, $\lim_{y \downarrow x} F(y) = F(x)$. (3.27)

Si $x_n \downarrow -\infty$ coordenada a coordenada entonces

$$F(x_n) \downarrow 0 \quad (3.28)$$

y si $x_n \uparrow \infty$ coordenada a coordenada entonces.

$$F(x_n) \uparrow 1. \quad (3.29)$$

Para todo rectángulo finito $A = (a_1, b_1] \times \cdots \times (a_d, b_d]$ con vértices $V = \{a_1, b_1\} \times \cdots \times \{a_d, b_d\}$, se cumple

$$\Delta_A F := \sum_{v \in V} \text{sgn}(v) F(v) \geq 0, \quad (3.30)$$

donde $\text{sgn}(v) = (-1)^{|\{i \in \{1, \dots, d\} : v_i = a_i\}|}$.

Teorema 3.3.3. Teorema de Stieltjes en $\mathbb{R}^d$. Suponga que $F : \mathbb{R}^d \rightarrow [0, 1]$ satisface las condiciones anteriores. Entonces existe una única medida de probabilidad μ sobre $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ tal que

$$\mu(A) = \Delta_A F \quad (3.31)$$

para todo rectángulo finito $A = (a_1, b_1] \times \cdots \times (a_d, b_d]$. En particular, para $d = 1$ se recupera el teorema de Stieltjes clásico

$$\mu((a, b]) = F(b) - F(a), \quad (3.32)$$

y cuando $F(x_1, \dots, x_d) = x_1 \cdots x_d$ la medida resultante es la medida de Lebesgue λ^d en $\mathbb{R}^d$.

La demostración se deja al lector.

Teorema 3.3.4. Correspondencia biyectiva entre funciones de distribución y medidas de probabilidad en $\mathbb{R}$. Dada una función de distribución $F : \mathbb{R} \rightarrow \mathbb{R}$, existe una única medida de probabilidad μ sobre el espacio medible $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ tal que

$$F(y) = \mu((-\infty, y]) \quad \text{para todo } y \in \mathbb{R}. \quad (3.33)$$

En particular, si X es la variable aleatoria sobre el espacio de probabilidad $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mu)$ definida por $X(\omega) = \omega$, entonces F es la función de distribución de X , es decir

$$F(y) = \mathbb{P}(X \leq y) = \mu((-\infty, y]). \quad (3.34)$$

La demostración es directa del teorema anterior.

3.4 V.A. continua y absolutamente continua

Definición 3.4.1. Variable aleatoria continua. Una variable aleatoria X se dice continua si su función de distribución F_X es continua.

Definición 3.4.2. Igualdad en distribución. Cuando X y Y tienen la misma distribución, escribimos $X \stackrel{d}{=} Y$. Por razones tipográficas, también se utiliza la notación $X =_d Y$.

Definición 3.4.3. Variable aleatoria absolutamente continua. Una variable aleatoria X se dice absolutamente continua si su medida inducida $\mathbb{P} \circ X^{-1}$ es absolutamente continua respecto a la medida de Lebesgue λ , es decir

$$\lambda(B) = 0 \implies \mathbb{P}(X \in B) = 0 \quad \forall B \in \mathcal{B}(\mathbb{R}). \quad (3.35)$$

Teorema 3.4.1. Variable aleatoria absolutamente continua. Una variable aleatoria X es absolutamente continua si existe una función $f_X \geq 0$ medible tal que

$$F_X(x) := \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(t) dt, \quad (3.36)$$

a f_X se le llama la función de densidad de X .

La demostración se deja al lector.

Teorema 3.4.2. Transformación de densidades. Sea X una variable aleatoria absolutamente continua con función de densidad f_X . Sea $g : \mathbb{R} \rightarrow \mathbb{R}$ una función estrictamente monótona y diferenciable. Entonces la variable aleatoria $Y = g(X)$ es también absolutamente continua y su función de densidad f_Y está dada por

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|, & \text{si } y \in \text{Ran}(g) \\ 0, & \text{en otro caso} \end{cases} \quad (3.37)$$

Demostración. Note que si g es creciente, por el teorema de la función y derivada inversa tenemos que g^{-1} es estrictamente creciente. Sea $y \in \text{Ran}(g)$, entonces existe $x \in \mathbb{R}$ tal que $g(x) = y$. Por definición de función de distribución de Y , se tiene

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq g^{-1}(y)) = F_X(g^{-1}(y))$$

Aplicando la regla de la cadena

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{d}{dy} F_X(g^{-1}(y)) = f_X(g^{-1}(y)) \cdot \frac{d}{dy} g^{-1}(y)$$

Por otro lado, si $y \notin \text{Ran}(g)$, entonces $F_Y(y) = 0$ o $F_Y(y) = 1$, y por tanto

$$f_Y(y) = \frac{d}{dy} F_Y(y) = 0$$

Por el teorema fundamental del cálculo, f_Y es la función densidad de Y , lo que implica que Y es absolutamente continua. □

Definición 3.4.4. Variable aleatoria discreta. Se dice que X es discreta si existe un conjunto contable $\{y_i\}_{i \in J} \subseteq \mathbb{R}$ tal que

$$\mathbb{P}(X \in \{y_i\}_{i \in J}) = \sum_{i \in J} \mathbb{P}(X = y_i) = 1. \quad (3.38)$$

sumado a ellos se define $p(y_i) := \mathbb{P}(X = y_i)$ como la función de masa de probabilidad.

Proposición 3.4.1. Sea X una variable aleatoria discreta con valores $\{y_i\}_{i \in J}$. Entonces

$$\mathbb{P} \circ X^{-1} = \sum_{i \in J} p_X(y_i) \delta_{y_i}, \quad (3.39)$$

donde δ_{y_i} es la medida de Dirac en y_i y $p_X(y_i) = \mathbb{P}(X = y_i)$, y la función de distribución se expresa como

$$F_X(y) = \mathbb{P}(X \leq y) = \int \mathbf{1}_{(-\infty, y]}(x) d(\mathbb{P} \circ X^{-1})(x) = \sum_{y_i \leq y} p_X(y_i). \quad (3.40)$$

La demostración se deja al lector.

3.5 Esperanza

Definición 3.5.1. Esperanza. Sea X una variable aleatoria sobre $(\Omega, \mathcal{F}, \mathbb{P})$. Diremos que la esperanza de X existe si

$$\int_{\Omega} |X| d\mathbb{P} < \infty, \quad (3.41)$$

en tal caso la esperanza de X se define como

$$\mathbb{E}(X) := \int_{\Omega} X d\mathbb{P} \quad (3.42)$$

3.5.1 Propiedades de la esperanza

Lema 3.5.1. Esperanza en $\mathbb{R}$. Sea X una variable aleatoria con esperanza finita. Entonces

$$\int_{\Omega} X d\mathbb{P} = \int_{\mathbb{R}} x d(\mathbb{P} \circ X^{-1})(x) = \int_{\mathbb{R}} x dF_X(x) = \int_{\mathbb{R}} x f_X(x) dx, \quad (3.43)$$

donde la última igualdad aplica cuando X es absolutamente continua con densidad f_X .

La demostración es trivial.

Lema 3.5.2. Sea X una variable aleatoria discreta con valores $\{y_i\}_{i \in J}$ y esperanza finita. Entonces

$$\mathbb{E}(X) = \int_{\Omega} X d\mathbb{P} = \int_{\mathbb{R}} x d(\mathbb{P} \circ X^{-1})(x) = \sum_{i \in J} y_i p_X(y_i). \quad (3.44)$$

La demostración se deja al lector.

Lema 3.5.3. Fórmula de Fubini para la esperanza. Sea X una variable aleatoria absolutamente continua tal que $\mathbb{E}(X)$ existe. Entonces

$$\mathbb{E}(X) = \int_{\mathbb{R}^+} \mathbb{P}(X > y) dy - \int_{\mathbb{R}^-} \mathbb{P}(X \leq y) dy = \int_{\mathbb{R}^+} [1 - F_X(y)] dy - \int_{\mathbb{R}^+} F_X(-y) dy. \quad (3.45)$$

Demostración. Por definición de esperanza

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f_X(x) dx = \int_0^{\infty} x f_X(x) dx + \int_{-\infty}^0 x f_X(x) dx.$$

Entonces

$$\begin{aligned} \int_0^{\infty} x f_X(x) dx &= \int_0^{\infty} \left(\int_0^x dy \right) f_X(x) dx = \int_0^{\infty} \left(\int_y^{\infty} f_X(x) dx \right) dy = \int_0^{\infty} \mathbb{P}(X > y) dy. \\ \int_{-\infty}^0 x f_X(x) dx &= - \int_{-\infty}^0 \left(\int_x^0 dy \right) f_X(x) dx = - \int_{-\infty}^0 \left(\int_{-\infty}^y f_X(x) dx \right) dy = - \int_{-\infty}^0 \mathbb{P}(X \leq y) dy. \end{aligned}$$

Por tanto

$$\mathbb{E}(X) = \int_0^{\infty} \mathbb{P}(X > y) dy - \int_{-\infty}^0 \mathbb{P}(X \leq y) dy = \int_0^{\infty} [1 - F_X(y)] dy - \int_0^{\infty} F_X(-y) dy.$$

□

Teorema 3.5.1. LOTUS para la esperanza. Sea X una variable aleatoria absolutamente continua con función de densidad f_X y sea g una función medible tal que $\mathbb{E}(|g(X)|) \leq \infty$, entonces $g(X)$ es integrable y se cumple

$$\mathbb{E}(g(X)) = \int_{\mathbb{R}} g(y) f_X(y) dy. \quad (3.46)$$

Demostración. Por el teorema de cambio de variable,

$$\mathbb{E}(g(X)) = \int_{\Omega} g(X) d\mathbb{P} = \int_{\mathbb{R}} g(y) d(\mathbb{P} \circ X^{-1})(y).$$

Como X es absolutamente continua, $\mathbb{P} \circ X^{-1} \ll \lambda$ con derivada de Radon-Nikodym f_X , luego

$$\int_{\mathbb{R}} g(y) d(\mathbb{P} \circ X^{-1})(y) = \int_{\mathbb{R}} g(y) f_X(y) dy.$$

□

Para demostrarlo sin el uso de Radon-Nikodym.

Demostración. Primero se va a probar para funciones indicadoras. Sea $B \in \mathcal{B}(\mathbb{R})$ y sea $g = \mathbf{1}_B$. Entonces

$$\mathbb{E}(\mathbf{1}_B(X)) = \mathbb{P}(X \in B) = \mu_X(B) = \int_{\mathbb{R}} \mathbf{1}_B(y) f_X(y) dy.$$

Ahora con funciones simples. Sea $g(y) = \sum_{m=1}^n c_m \mathbf{1}_{B_m}(y)$, con $c_m \in \mathbb{R}$, $B_m \in \mathcal{B}(\mathbb{R})$. Por linealidad de la esperanza, el resultado del caso 1 y la linealidad de la integral, se tiene

$$\mathbb{E}(g(X)) = \sum_{m=1}^n c_m \mathbb{E}(\mathbf{1}_{B_m}(X)) = \sum_{m=1}^n c_m \int_{\mathbb{R}} \mathbf{1}_{B_m}(y) f_X(y) dy = \int_{\mathbb{R}} g(y) f_X(y) dy.$$

Funciones no negativas. Sea $g \geq 0$ y definamos

$$g_n(y) := \min \left\{ \frac{\lfloor 2^n g(y) \rfloor}{2^n}, n \right\}.$$

Entonces g_n es simple y $g_n \rightarrow g$ de forma creciente. Por el resultado del caso 2 y el Teorema de convergencia monótona, se tiene

$$\mathbb{E}(g(X)) = \lim_{n \rightarrow \infty} \mathbb{E}(g_n(X)) = \lim_{n \rightarrow \infty} \int_{\mathbb{R}} g_n(y) f_X(y) dy = \int_{\mathbb{R}} g(y) f_X(y) dy.$$

Para funciones integrables. Sea g medible tal que $\mathbb{E}(|g(X)|) < \infty$. Escribimos

$$g(y) = g^+(y) - g^-(y), \quad |g(y)| = g^+(y) + g^-(y).$$

Como $\mathbb{E}(|g(X)|) < \infty$, se tiene que $\mathbb{E}(g^+(X))$ y $\mathbb{E}(g^-(X))$ son finitas. Por el caso 3 y la linealidad de la esperanza e integración, se concluye que

$$\mathbb{E}(g(X)) = \mathbb{E}(g^+(X)) - \mathbb{E}(g^-(X)) = \int_{\mathbb{R}} g^+(y) f_X(y) dy - \int_{\mathbb{R}} g^-(y) f_X(y) dy = \int_{\mathbb{R}} g(y) f_X(y) dy.$$

□

Definición 3.5.2. Momento de orden r . Si $\mathbb{E}(|X|^r) < \infty$, diremos que X es r -integrable, si

$$\mathbb{E}(X^r) \tag{3.47}$$

existe y se denomina el momento de orden r de X alrededor de 0. En particular si $r = 1$, diremos que X es integrable; si $r = 2$, diremos que X es cuadrado integrable.

Proposición 3.5.1. Linealidad de la esperanza. Sean X y Y dos variables aleatorias integrables. Entonces

$$\mathbb{E}(aX + bY) = a\mathbb{E}(X) + b\mathbb{E}(Y), \tag{3.48}$$

$$\text{Si } \mathbb{P}(X \leq Y) = 1, \text{ entonces } \mathbb{E}(X) \leq \mathbb{E}(Y), \tag{3.49}$$

$$\text{Si } X \stackrel{d}{=} Y, \text{ entonces } \mathbb{E}(X) = \mathbb{E}(Y). \tag{3.50}$$

Demostración. Como X e Y son integrables, se tiene

$$\int_{\Omega} |aX + bY| d\mathbb{P} \leq |a| \int_{\Omega} |X| d\mathbb{P} + |b| \int_{\Omega} |Y| d\mathbb{P} < \infty,$$

luego $aX + bY$ es integrable y por linealidad de la integral de Lebesgue

$$\mathbb{E}(aX + bY) = \int_{\Omega} (aX + bY) d\mathbb{P} = a \int_{\Omega} X d\mathbb{P} + b \int_{\Omega} Y d\mathbb{P} = a\mathbb{E}(X) + b\mathbb{E}(Y).$$

Para la monotonía, si $\mathbb{P}(X \leq Y) = 1$ entonces $Y - X \geq 0$ c.s., luego

$$\mathbb{E}(Y) - \mathbb{E}(X) = \mathbb{E}(Y - X) = \int_{\Omega} (Y - X) d\mathbb{P} \geq 0.$$

Para la última es trivial. □

Proposición 3.5.2. Desigualdad de Hölder para esperanzas. Si X y Y son variables aleatorias cuadrado integrables, entonces

$$\mathbb{E}(|XY|) \leq \|\mathbb{E}(X^p)\|_p \|\mathbb{E}(Y^q)\|_q. \quad (3.51)$$

La demostración es consecuencia de la desigualdad de Hölder.

Proposición 3.5.3. Desigualdad de Markow. Sea X una variable aleatoria r -integrable. Entonces, para todo $\varepsilon > 0$

$$\mathbb{P}(|X| \geq \varepsilon) \leq \frac{\mathbb{E}(|X|^r)}{\varepsilon^r}. \quad (3.52)$$

Demostración. Sea $\varepsilon > 0$. Consideramos el conjunto $A := \{\omega \in \Omega : |X(\omega)| \geq \varepsilon\}$. Entonces, por definición de esperanza y usando que $|X|^r \geq \varepsilon^r$ en A , se tiene

$$\mathbb{E}(|X|^r) = \int_{\Omega} |X(\omega)|^r d\mathbb{P}(\omega) \geq \int_A |X(\omega)|^r d\mathbb{P}(\omega) \geq \int_A \varepsilon^r d\mathbb{P}(\omega) = \varepsilon^r \mathbb{P}(A).$$

□

3.6 Media, varianza y momentos

Definición 3.6.1. Media, varianza y momentos. Sea X una variable aleatoria integrable. Se define la media como

$$\mu := \mathbb{E}(X) \quad (3.53)$$

Para $r \geq 2$, si $\mathbb{E}(|X - \mu|^r) < \infty$, entonces el momento centrado de orden r se define como

$$\mu_r := \mathbb{E}((X - \mu)^r) \quad (3.54)$$

El momento ordinario de orden r se define como

$$m_r := \mathbb{E}(X^r) \quad (3.55)$$

En particular, la varianza de X es

$$\text{Var}(X) := \mathbb{E}((X - \mu)^2) \text{ y } \sigma := \sqrt{\text{Var}(X)} \text{ se llama desviación estándar.} \quad (3.56)$$

Proposición 3.6.1. Relación entre momentos centrados y momentos ordinarios. Sea X una variable aleatoria r -integrable con $r \geq 2$. Entonces, para todo $s \in \mathbb{N}$, se cumple

$$\mathbb{E}((X - \mu)^s) = \sum_{k=0}^s \binom{s}{k} (-\mu)^{s-k} m_k. \quad (3.57)$$

Demostración. Por la fórmula del binomio y la linealidad de la esperanza, tenemos

$$\mathbb{E}((X - \mu)^s) = \mathbb{E}\left(\sum_{k=0}^s \binom{s}{k} X^k (-\mu)^{s-k}\right) = \sum_{k=0}^s \binom{s}{k} \mathbb{E}(X^k) (-\mu)^{s-k} = \sum_{k=0}^s \binom{s}{k} m_k (-\mu)^{s-k}.$$

□

Corolario 3.6.1. Fórmula de la varianza. Si X es cuadrado integrable, entonces

$$\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2. \quad (3.58)$$

La demostración es trivial.

Corolario 3.6.2. Propiedades fundamentales de la varianza. Si X es cuadrado integrable y $a, b \in \mathbb{R}$, entonces

$$\text{Var}(X) \geq 0. \quad (3.59)$$

$$\text{Var}(aX) = a^2 \text{Var}(X). \quad (3.60)$$

$$\text{Var}(X + b) = \text{Var}(X). \quad (3.61)$$

$$\text{Var}(X) = 0 \quad \text{si y solo si} \quad \mathbb{P}(X = \mathbb{E}(X)) = 1. \quad (3.62)$$

La demostración se deja al lector.

3.7 Función generadora de momentos

Definición 3.7.1. Función generadora de momentos. Sea X una variable aleatoria tal que existe $\alpha > 0$ tal que $\mathbb{E}(e^{tX}) < \infty$ para todo $t \in (-\alpha, \alpha)$. Entonces se define la función generadora de momentos de X , denotada por ϕ_X , como

$$\phi_X(t) := \mathbb{E}(e^{tX}) \text{ para todo } t \in (-\alpha, \alpha). \quad (3.63)$$

3.7.1 Propiedades de la función generadora de momentos

Teorema 3.7.1. Teorema fundamental de la función generadora de momentos. Sea X una variable aleatoria tal que su función generadora de momentos $\phi_X(t) = \mathbb{E}(e^{tX})$ existe en un vecindario de $t = 0$. Entonces, para todo $r \in \mathbb{N}$, el momento de orden r de X está dado por

$$\mathbb{E}(X^r) = \left. \frac{d^r \phi_X(t)}{dt^r} \right|_{t=0}. \quad (3.64)$$

Demostración. Note que si existe $a > 0$ tal que $\phi_X(t) < \infty$ para todo $t \in (-a, a)$. Tenemos que $\mathbb{E}(e^{aX}) < \infty$ y $\mathbb{E}(e^{-aX}) < \infty$, de donde

$$\mathbb{E}(e^{c|X|}) \leq \mathbb{E}(e^{cX}) + \mathbb{E}(e^{-cX}) < \infty \quad \text{para todo } c \in (0, a).$$

Note que por desarrollos de Taylor la siguiente desigualdad es cierta si $r \in \mathbb{N}$

$$|x|^r \leq \frac{r!}{c^r} e^{c|x|}.$$

Ahora fijado $t \in (-a/2, a/2)$ y tomando $c \in (0, a - |t|)$, se obtiene

$$|X|^r e^{tX} \leq |X|^r e^{t|X|} \leq \frac{r!}{c^r} e^{(c+|t|)|X|} \leq \frac{r!}{c^r} e^{a|X|}.$$

Considere primero $r = 1$. Para $h \rightarrow 0$

$$\frac{e^{(t+h)X} - e^{tX}}{h} = X e^{tX} \cdot \frac{e^{hX} - 1}{hX},$$

donde $\frac{e^{hX}-1}{hX} \rightarrow 1$ puntualmente cuando $h \rightarrow 0$. Además

$$\left| \frac{e^{(t+h)X} - e^{tX}}{h} \right| \leq |X| e^{(t+h)_+ |X|} \leq \frac{1!}{c^1} e^{a|X|},$$

para $|t|, |h|$ suficientemente pequeños y algún $c \in (0, a - |t| - |h|)$. Por convergencia dominada

$$\phi'_X(t) = \lim_{h \rightarrow 0} \mathbb{E} \left(\frac{e^{(t+h)X} - e^{tX}}{h} \right) = \mathbb{E}(X e^{tX}).$$

Procediendo por inducción, si $\phi_X^{(k)}(t) = \mathbb{E}(X^k e^{tX})$ para cierto k , entonces para $h \rightarrow 0$

$$\frac{\phi_X^{(k)}(t+h) - \phi_X^{(k)}(t)}{h} = \mathbb{E} \left(X^k e^{tX} \cdot \frac{e^{hX} - 1}{h} \right) \rightarrow \mathbb{E}(X^{k+1} e^{tX}),$$

y el numerador $|X|^{k+1} e^{tX}$ es integrable por la cota $|X|^{k+1} \leq \frac{(k+1)!}{c^{k+1}} e^{c|X|}$ y el mismo argumento de arriba. Por convergencia dominada se concluye

$$\phi_X^{(k+1)}(t) = \mathbb{E}(X^{k+1} e^{tX}) \quad \text{para } t \in (-a/2, a/2).$$

□

Teorema 3.7.2. Colas exponenciales de la función generadora de momentos. Sea X una variable aleatoria. La función generadora de momentos $m_X(t) = \mathbb{E}(e^{tX})$ es finita en un intervalo abierto (a, b) que contiene a 0 si y solo si las colas de la función de distribución F_X están exponencialmente acotadas, es decir

$$\mathbb{P}(X > x) \leq C e^{-t_0 x} \quad \text{para algunos } C > 0, t_0 > 0. \quad (3.65)$$

La demostración se deja al lector. Es consecuencia directa de los desarrollos de Taylor.

Teorema 3.7.3. Teorema de unicidad de la función generadora de momentos. Sean X y Y dos variables aleatorias tales que sus funciones generadoras de momentos ϕ_X y ϕ_Y existen. Si

$$\phi_X(t) = \phi_Y(t) \quad \text{para todo } t \in (-\varepsilon, \varepsilon), \quad (3.66)$$

para algún $\varepsilon > 0$, entonces

$$X \stackrel{d}{=} Y. \quad (3.67)$$

Demostración. Sea $\phi_X(t) := \mathbb{E}(e^{tX})$ y $\phi_Y(t) := \mathbb{E}(e^{tY})$ las funciones generadoras de momentos de X y Y , respectivamente. Por hipótesis, existe $\varepsilon > 0$ tal que

$$\phi_X(t) = \phi_Y(t) \quad \text{para todo } t \in (-\varepsilon, \varepsilon).$$

Como ϕ_X y ϕ_Y son finitas en un intervalo abierto que contiene al cero, admiten desarrollo en serie de potencias alrededor de $t = 0$

$$\phi_X(t) = \sum_{n=0}^{\infty} \frac{\mathbb{E}(X^n)}{n!} t^n, \quad \phi_Y(t) = \sum_{n=0}^{\infty} \frac{\mathbb{E}(Y^n)}{n!} t^n,$$

con radio de convergencia al menos ε . La igualdad $\phi_X(t) = \phi_Y(t)$ para todo $t \in (-\varepsilon, \varepsilon)$ implica la igualdad de coeficientes en las series de potencias, por unicidad del desarrollo de Taylor

$$\mathbb{E}(X^n) = \mathbb{E}(Y^n) \quad \text{para todo } n \geq 0.$$

Por lo tanto, la igualdad de todos los momentos implica $X \stackrel{d}{=} Y$.

□

3.8 Función característica

Definición 3.8.1. Función característica. Sea X una variable aleatoria sobre $(\Omega, \mathcal{F}, \mathbb{P})$. Se define la función característica de X como la función $\varphi_X: \mathbb{R} \rightarrow \mathbb{C}$ dada por

$$\varphi_X(t) := \mathbb{E}(e^{itX}) = \mathbb{E}(\cos(tX)) + i\mathbb{E}(\sin(tX)). \quad (3.68)$$

Proposición 3.8.1. Propiedades básicas de la función característica Para todo $t \in \mathbb{R}$, se cumple

$$\varphi_X(0) = 1. \quad (3.69)$$

$$\varphi_X(-t) = \overline{\varphi_X(t)}. \quad (3.70)$$

$$|\varphi_X(t)| \leq 1. \quad (3.71)$$

$$|\varphi_X(t+h) - \varphi_X(t)| \leq \mathbb{E}(|e^{ihX} - 1|). \quad (3.72)$$

$$\varphi_{aX+b}(t) = e^{itb} \varphi_X(at). \quad (3.73)$$

La demostración es trivial.

Teorema 3.8.1. Fórmula de inversión de Lévy. Si X es una variable aleatoria y $a < b$, entonces

$$\mathbb{P}(a < X < b) + \mathbb{P}(X = a)/2 + \mathbb{P}(X = b)/2 = \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt. \quad (3.74)$$

Demostración. El resultado anterior se puede obtener mediante transformada de Fourier con la función de compuerta y el teorema de Fubini. Utilizando los mismos resultados de la transformada pero sin utilizarla se tiene que si

$$\varphi_X(t) = \int_{\mathbb{R}} e^{itx} dP_X(x)$$

Se sigue que

$$\frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) = \int_{\mathbb{R}} \frac{e^{-it(x-a)} - e^{-it(x-b)}}{it} dP_X(x)$$

Ahora note que

$$\left| \frac{e^{it(x-a)} - e^{it(x-b)}}{it} \right| \leq |e^{-ita}| \left| \frac{1 - e^{it(b-a)}}{it} \right| \leq \frac{|2 \sin(\frac{t(b-a)}{2})|}{|t|}$$

Entonces

$$\int_{-T}^T \frac{|2 \sin(\frac{t(b-a)}{2})|}{|t|} \int_{\mathbb{R}} dP_X(x) \leq 1|b-a|\pi$$

En cuyo caso podemos utilizar el teorema de Fubini para

$$\int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt = \int_{\mathbb{R}} \int_{-T}^T \frac{e^{-it(x-a)} - e^{-it(x-b)}}{it} dt dP_X(x).$$

Nota que

$$\int_{x-a}^{x-b} e^{ity} dy = \left[\frac{e^{ity}}{it} \right]_{x-a}^{x-b} = \frac{e^{it(x-b)} - e^{it(x-a)}}{it}.$$

Entonces

$$\int_{-T}^T \frac{e^{it(x-a)} - e^{it(x-b)}}{it} dt = \int_{x-b}^{x-a} \int_{-T}^T e^{ity} dt dy.$$

Evaluamos la integral interna en t

$$\int_{-T}^T e^{ity} dt = \frac{e^{iTy} - e^{-iTy}}{iy} = \frac{2 \sin(Ty)}{y}.$$

Por lo tanto

$$\frac{1}{2\pi} \int_{x-b}^{x-a} \frac{2 \sin(Ty)}{y} dy = \frac{1}{\pi} \int_{x-b}^{x-a} \frac{\sin(Ty)}{y} dy.$$

Realizamos el cambio de variable $u = Ty$, $du = T dy$, $dy = \frac{du}{T}$ la integral doble queda como

$$\int_{-\infty}^{\infty} \left(\frac{1}{\pi} \int_{T(x-b)}^{T(x-a)} \frac{\sin(u)}{u} du \right) dF_X(x).$$

Note que el comportamiento de la integral interna cuando $T \rightarrow \infty$ depende de x , por lo tanto tenemos tres casos

Caso 1, para $x \in (a, b)$ tenemos que $x - b < 0$ y $x - a > 0$, así que $T(x - b) \rightarrow -\infty$, $T(x - a) \rightarrow \infty$. Entonces

$$\frac{1}{\pi} \int_{T(x-b)}^{T(x-a)} \frac{\sin(u)}{u} du \rightarrow \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{\sin(u)}{u} du = 1,$$

Caso 2, para $x = a$ tenemos que $T(a - b) \rightarrow -\infty$, $T(a - a) = 0$. Entonces

$$\frac{1}{\pi} \int_{T(a-b)}^0 \frac{\sin(u)}{u} du \rightarrow \frac{1}{\pi} \int_{-\infty}^0 \frac{\sin(u)}{u} du = \frac{1}{2},$$

Caso 3, para $x = b$ tenemos que $T(b - b) = 0$, $T(b - a) \rightarrow \infty$. Entonces

$$\frac{1}{\pi} \int_0^{T(b-a)} \frac{\sin(u)}{u} du \rightarrow \frac{1}{\pi} \int_0^{\infty} \frac{\sin(u)}{u} du = \frac{1}{2}.$$

Caso 4, para $x < a$ o $x > b$ tenemos que los límites $T(x - b)$ y $T(x - a)$ tienden ambos a $-\infty$ o ∞ , y la integral interna tiende a 0.

Con estos casos tenemos que

$$g(x) = \lim_{T \rightarrow \infty} \frac{1}{\pi} \int_{T(x-b)}^{T(x-a)} \frac{\sin(u)}{u} du = \begin{cases} 1 & \text{si } x \in (a, b), \\ \frac{1}{2} & \text{si } x = a \text{ o } x = b, \\ 0 & \text{si } x < a \text{ o } x > b. \end{cases}$$

Entonces tenemos que

$$\int_{\mathbb{R}} \left(\lim_{T \rightarrow \infty} \frac{1}{\pi} \int_{T(x-b)}^{T(x-a)} \frac{\sin(u)}{u} du \right) dF_X(x) = \int_{\mathbb{R}} g(x) dF_X(x),$$

donde

$$g(x) = \begin{cases} 1 & \text{si } x \in (a, b), \\ \frac{1}{2} & \text{si } x = a \text{ o } x = b, \\ 0 & \text{si } x < a \text{ o } x > b. \end{cases}$$

Descomponemos la integral

$$\int_{\mathbb{R}} g(x) dF_X(x) = \int_{(a,b)} 1 dF_X(x) + \frac{1}{2} \mathbb{P}(X = a) + \frac{1}{2} \mathbb{P}(X = b)$$

En cuyo caso

$$\mathbb{P}(a < X < b) + \mathbb{P}(X = a)/2 + \mathbb{P}(X = b)/2 = \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt.$$

□

Corolario 3.8.1. Unicidad de la función característica. Si $\varphi_X(t) = \varphi_Y(t)$ para todo $t \in \mathbb{R}$, entonces

$$X \stackrel{d}{=} Y. \quad (3.75)$$

La demostración es consecuencia de la igualdad en funciones generadas de momentos.

Teorema 3.8.2. Diferenciación de la función característica. Suponga que X es r -integrable. Entonces

$$\varphi_X^{(r)}(t) = \mathbb{E}((iX)^r e^{itX}). \quad (3.76)$$

En particular

$$\varphi_X^{(r)}(0) = i^r \mathbb{E}(X^r). \quad (3.77)$$

Además, el desarrollo de Taylor alrededor de $t = 0$ está dado por

$$\varphi_X(t) = \sum_{k=0}^r \frac{(it)^k}{k!} \mathbb{E}(X^k) + o(t^r). \quad (3.78)$$

Demostración. Utilizando el resultado para la función generadora de momentos tenemos que

$$\frac{\varphi_X^{(k)}(t+h) - \varphi_X^{(k)}(t)}{h} = \mathbb{E} \left((iX)^k e^{itX} \cdot \frac{e^{ihX} - 1}{h} \right) \xrightarrow{h \rightarrow 0} \mathbb{E}((iX)^{k+1} e^{itX}),$$

□

Teorema 3.8.3. Fórmula de inversión de Fourier para la densidad. Si

$$\int_{\mathbb{R}} |\varphi_X(t)| dt < \infty, \quad (3.79)$$

entonces X es absolutamente continua con densidad dada por

$$f_X(y) = \frac{1}{2\pi} \int_{\mathbb{R}} e^{-ity} \varphi_X(t) dt. \quad (3.80)$$

Demostración. Este ejercicio igual se puede obtener por transformada de Fourier. Pero de igual forma note que utilizando el hecho de que X es absolutamente continua tenemos que

$$\left(\frac{F_X(b) + F_X(b^-)}{2} - \frac{F_X(a) + F_X(a^-)}{2} \right) = F_X(b) - F_X(a) = \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \varphi_X(t) dt.$$

Ahora tomado $b = x$ y $a \rightarrow \infty$ se tiene que

$$F_X(x) - 1 = \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itx}}{it} \varphi_X(t) dt.$$

Derivando con respecto de x tenemos que

$$F'_X(x) = f(x) = \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T e^{-itx} \varphi_X(t) dt.$$

□

4

Vectores aleatorias

Definición 4.0.1. Variable aleatoria en varias variables. Una variable aleatoria en $\mathbb{R}^n$ sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ es una función $X: \Omega \rightarrow \mathbb{R}^n$ que es medible para todo $A \in \mathcal{B}(\mathbb{R}^n)$, es decir

$$X^{-1}(A) \in \mathcal{F}. \quad (4.1)$$

4.0.1 Distribucion de vectores aleatorios

Definición 4.0.2. Función de distribución conjunta. Sea $X = (X_1, X_2, \dots, X_n)$ un vector aleatorio. La función de distribución conjunta de X es la función $F_X: \mathbb{R}^n \rightarrow [0, 1]$ dada por

$$F_X(x_1, \dots, x_n) := \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n). \quad (4.2)$$

Teorema 4.0.1. Propiedades básicas de la función de distribución conjunta. Sea $X = (X_1, X_2, \dots, X_n)$ un vector aleatorio en $\mathbb{R}^n$ con función de distribución conjunta $F_X(x_1, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n)$. Entonces se verifican las siguientes propiedades

$$F_X(a_1, \dots, a_n) \leq F_X(b_1, \dots, b_n) \text{ si } \forall_{i \in \{1, \dots, n\}} (a_i \leq b_i) \quad (4.3)$$

$$\lim_{x_i \rightarrow a_i^+} F_X(x_1, \dots, x_i, \dots, x_n) = F_X(x_1, \dots, x_i, \dots, a_i, \dots, x_n), \forall_{i \in \{1, \dots, n\}} \quad (4.4)$$

$$\lim_{x_i \rightarrow -\infty} F_X(x_1, \dots, x_i, \dots, x_n) = 0, \forall_{i \in \{1, \dots, n\}} \quad (4.5)$$

$$\lim_{(x_1, \dots, x_n) \rightarrow \infty} F_X(x_1, \dots, x_n) = 1 \quad (4.6)$$

Demostración. Primero si $a_i \leq b_i$ para todo i , entonces el evento $\{X_i \leq a_i\} \subseteq \{X_i \leq b_i\}$, por lo tanto

$$\bigcap_{i=1}^d \{X_i \leq a_i\} \subseteq \bigcap_{i=1}^d \{X_i \leq b_i\}$$

y se sigue que $F_X(a_1, \dots, a_d) \leq F_X(b_1, \dots, b_d)$. Ahora sea $\{x_i^m\}_m \rightarrow a_i^+$ para algún i , entonces

$$\begin{aligned} \lim_{x_i \rightarrow a_i^+} F_X(x_1, \dots, x_i, \dots, x_n) &= \mathbb{P}_X \left(\bigcap_{n=1}^{\infty} \{X_1 \leq x_1, \dots, X_i \leq x_i^m, \dots, X_n \leq x_n\} \right) \\ &= \mathbb{P}_X (X_1 \leq x_1, \dots, X_i \leq a_i, \dots, X_n \leq x_n) = F_X(x_1, \dots, x_i, \dots, a_i, \dots, x_n) \end{aligned}$$

Como tercero si $\{x_i^m\}_m \rightarrow -\infty$ para algún i , se sigue que

$$\bigcap_{m=1}^{\infty} \{X_1 \leq x_1, \dots, X_i \leq x_i^m, \dots, X_n \leq x_n\} = \emptyset \Rightarrow F_X(x_1, \dots, x_i^m, \dots, x_n) \rightarrow \mathbb{P}(\emptyset) = 0$$

Y la ultima se sigue que si $x_i^{(n)} \rightarrow +\infty$ para todo i , entonces

$$\bigcap_{i=1}^d \{X_i \leq x_i^{(n)}\} \rightarrow \Omega \Rightarrow F_X(x_1^{(n)}, \dots, x_d^{(n)}) \rightarrow \mathbb{P}(\Omega) = 1.$$

□

Definición 4.0.3. Función de distribución marginal. Si $X = (X_1, X_2, \dots, X_n)$ es un vector aleatorio, a la función de distribución F_{X_k} de X_k (para todo $k = 1, 2, \dots, n$) se le llama función de distribución marginal de la variable X_k

$$F_{X_k}(x_k) := \mathbb{P}(X_k \leq x_k) \quad (4.7)$$

Teorema 4.0.2. Teorema de las marginales. Sea $X = (X_1, X_2, \dots, X_n)$ un vector aleatorio en $\mathbb{R}^n$ con función de distribución conjunta

$$F_X(x_1, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n). \quad (4.8)$$

Entonces, para cada $k \in \{1, \dots, n\}$, la función de distribución marginal de X_k se obtiene como

$$F_{X_k}(x_k) = \lim_{x_i \rightarrow +\infty, \forall i \neq k} F_X(x_1, \dots, x_n). \quad (4.9)$$

Demostración. Considere sucesiones $\{x_i^{(m)}\}_m \rightarrow +\infty$ para cada $i \neq k$, entonces

$$\bigcap_{i=1}^d \{X_i \leq x_i^{(n)}\} \rightarrow \Omega \Rightarrow \bigcap_{\substack{i=1 \\ i \neq k}}^d \{X_i \leq x_i^{(n)}\} \cap \{X_k \leq x_k\} \rightarrow \Omega \cap \{X_k \leq x_k\}$$

Entonces se sigue que

$$\lim_{\substack{x_i \rightarrow +\infty \\ i \neq k}} \mathbb{P} \left(\bigcap_{\substack{i=1 \\ i \neq k}}^d \{X_i \leq x_i^{(n)}\} \cap \{X_k \leq x_k\} \right) = F_X(\Omega \cap \{X_k \leq x_k\}) = F_{X_k}(x_k).$$

□

Aquí cabe recalcar que no siempre de las funciones de distribución marginal podemos obtener la función de distribución conjunta.

Proposición 4.0.1. Función de masa de probabilidad conjunta. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio discreto. Entonces la medida inducida $\mathbb{P} \circ X^{-1}$ sobre $\mathbb{R}^n$ admite la representación

$$\mathbb{P} \circ X^{-1} = \sum_{(x_1, \dots, x_n)} p_{X_1, \dots, X_n}(x_1, \dots, x_n) \delta_{(x_1, \dots, x_n)}, \quad (4.10)$$

donde la suma recorre $\text{Ran}(X)$ y

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = (\mathbb{P} \circ X^{-1})(\{(x_1, \dots, x_n)\}), \quad (4.11)$$

con $p_{X_1, \dots, X_n}(x_1, \dots, x_n) = 0$ para $(x_1, \dots, x_n) \notin \text{Ran}(X)$.

Teorema 4.0.3. Distribución inducida. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio discreto con $\text{Ran}(X) \subset A$, y sean $g_1, \dots, g_k : A \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ campos escalares. Para cada $j \in \{1, \dots, k\}$ sea $Y_j = g_j(X_1, \dots, X_n)$. Entonces $Y = (Y_1, \dots, Y_k)$ es un vector aleatorio discreto con distribución conjunta

$$\mathbb{P}(Y_1 = y_1, \dots, Y_k = y_k) = \sum_{\substack{(x_1, \dots, x_n) \in \text{Ran}(X) \\ g_j(x_1, \dots, x_n) = y_j \quad \forall j}} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n). \quad (4.12)$$

Demostración. Note que para cada $j = 1 \dots k$, se tiene

$$\{\omega : g_j(X(\omega)) = y_j\} = \bigcup_{\substack{(x_1, \dots, x_n) \in \mathbb{R}^n \\ g_j(x_1, \dots, x_n) = y_j}} \{\omega : X(\omega) = (x_1, \dots, x_n)\}$$

Por lo tanto, la intersección de esos eventos es

$$\bigcap_{j=1}^k \{\omega : g_j(X(\omega)) = y_j\} = \bigcup_{\substack{(x_1, \dots, x_n) \in \mathbb{R}^n \\ g_j(x_1, \dots, x_n) = y_j, \forall j}} \{\omega : X(\omega) = (x_1, \dots, x_n)\}$$

Y entonces

$$\mathbb{P}(Y_1 = y_1, \dots, Y_k = y_k) = \sum_{\substack{(x_1, \dots, x_n) \in \mathbb{R}^n \\ g_j(x_1, \dots, x_n) = y_j, \forall j}} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$$

□

Definición 4.0.4. Función de densidad conjunta. Un vector aleatorio $X = (X_1, \dots, X_n)$ se dice absolutamente continuo si su medida inducida $\mathbb{P} \circ X^{-1} \ll \lambda^n$, donde λ^n es la medida de Lebesgue en $\mathbb{R}^n$. Por Radon-Nikodym existe $f_{X_1, \dots, X_n} \geq 0$ medible tal que

$$\mathbb{P}(X \in B) = \int_B f_{X_1, \dots, X_n} d\lambda^n \quad \forall B \in \mathcal{B}(\mathbb{R}^n), \quad (4.13)$$

a $f_{X_1, \dots, X_n}$ se le llama la densidad conjunta de X , y corresponde a la derivada de Radon-Nikodym $f_{X_1, \dots, X_n} = d(\mathbb{P} \circ X^{-1})/d\lambda^n$.

Proposición 4.0.2. LOTUS multivariable. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio absolutamente continuo con densidad conjunta $f_{X_1, \dots, X_n}$. Entonces para cada $k \in \{1, \dots, n\}$ la medida inducida de X_k satisface $\mathbb{P} \circ X_k^{-1} \ll \lambda$ con densidad marginal

$$f_{X_k}(y) = \frac{d(\mathbb{P} \circ X_k^{-1})}{d\lambda}(y) = \int_{\mathbb{R}^{n-1}} f_{X_1, \dots, X_n}(t_1, \dots, t_{k-1}, y, t_{k+1}, \dots, t_n) d\lambda^{n-1}(t), \quad (4.14)$$

resultado que se obtiene aplicando el teorema de Fubini a la medida $\mathbb{P} \circ X^{-1}$.

La demostración es consecuencia directa del teorema de Fubini y la fórmula de Leibniz.

4.1 Esperanza de vectores aleatorios

Definición 4.1.1. Esperanza de un vector aleatorio. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio sobre $(\Omega, \mathcal{F}, \mathbb{P})$. La esperanza de X se define componente a componente como

$$\mathbb{E}[X] := (\mathbb{E}[X_1], \dots, \mathbb{E}[X_n]), \quad (4.15)$$

siempre que cada $\mathbb{E}[|X_k|] < \infty$.

Teorema 4.1.1. LOTUS para esperanza multivariable Si $(X_1, \dots, X_n)$ es un vector aleatorio y $g: \mathbb{R}^n \rightarrow \mathbb{R}$ es integrable, entonces

$$\mathbb{E}[g(X_1, \dots, X_n)] = \int_{\mathbb{R}^n} g(t_1, \dots, t_n) f_{X_1, \dots, X_n}(t_1, \dots, t_n) dt_1 \dots dt_n \quad (4.16)$$

Demostración. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio definido sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, y sea $g: \mathbb{R}^n \rightarrow \mathbb{R}$ una función medible tal que $g(X)$ es integrable, es decir, $\mathbb{E}[|g(X)|] < \infty$.

El vector aleatorio X induce una medida de probabilidad μ sobre $\mathbb{R}^n$, definida por

$$\mu(B) = \mathbb{P}(X \in B), \quad \text{para todo } B \in \mathcal{B}(\mathbb{R}^n),$$

donde $\mathcal{B}(\mathbb{R}^n)$ es la σ -álgebra de Borel.

La esperanza de $g(X)$ se puede expresar como una integral respecto a esta medida

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}^n} g(x) d\mu(x).$$

Si X tiene una densidad conjunta $f_{X_1, \dots, X_n}: \mathbb{R}^n \rightarrow \mathbb{R}^+$, entonces la medida μ es absolutamente continua respecto a la medida de Lebesgue, y por el teorema de Radon-Nikodym, existe una función f tal que $d\mu(x) = f(x) dx$, por lo tanto, la esperanza se puede escribir como

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}^n} g(x) f(x) dx,$$

lo que en coordenadas se expresa como

$$\mathbb{E}(g(X_1, \dots, X_n)) = \int_{\mathbb{R}^n} g(t_1, \dots, t_n) f_{X_1, \dots, X_n}(t_1, \dots, t_n) dt_1 \dots dt_n.$$

□

Teorema 4.1.2. Teorema del Jacobiano. Sea $R = [a_1 b_1] \times [a_2 b_2] \times \dots \times [a_n b_n]$ un rectángulo n -dimensional y $u = (u_1(x_1, \dots, x_n), \dots, u_n(x_1, \dots, x_n))$ un campo vectorial de clase C^1 en un vecindario del rectángulo R , que tiene inversa $x = (x_1(u_1, \dots, u_n), \dots, x_n(u_1, \dots, u_n))$. Suponga que el jacobiano $\frac{\partial(x_1, \dots, x_n)}{\partial(u_1, \dots, u_n)} \neq 0$ sobre $u(R)$. Entonces, si f es un campo escalar integrable sobre R , se tiene

$$\int_R f(x_1, \dots, x_n) dx_1 \dots dx_n = \int_{u(R)} f(x) \times \left| \frac{\partial(x_1, \dots, x_n)}{\partial(u_1, \dots, u_n)} \right| du_1 \dots du_n. \quad (4.17)$$

Demostración. Sea $(u_1, \dots, u_n) \in u(R) \subset \mathbb{R}^n$, y considere

$$R = \{(x_1, \dots, x_n) \in \mathbb{R}^n : u(x_1, \dots, x_n) \in u(R)\} = u^{-1}(u(R)),$$

donde $u : R \rightarrow u(R)$ es biyectiva con de clase C^1 con inversa $x = (x_1(u_1, \dots, u_n), \dots, x_n(u_1, \dots, u_n))$ igual de clase C^1 , y el jacobiano $\frac{\partial(x_1, \dots, x_n)}{\partial(u_1, \dots, u_n)} \neq 0$ en $u(R)$.

Tenemos que

$$\int_R f(x_1, \dots, x_n) dx_1 \dots dx_n,$$

donde $f : R \rightarrow \mathbb{R}$ es integrable, debe transformarse bajo el cambio de coordenadas $x = x(u)$.

Por el teorema del cambio de variables para integrales múltiples, obtenemos que

$$\int_R f(x_1, \dots, x_n) dx_1 \dots dx_n = \int_{u(R)} f(x_1(u_1, \dots, u_n), \dots, x_n(u_1, \dots, u_n)) \left| \frac{\partial(x_1, \dots, x_n)}{\partial(u_1, \dots, u_n)} \right| du_1 \dots du_n.$$

□

Teorema 4.1.3. Teorema del cambio de variable. Suponga que $X = (X_1, \dots, X_n)$ tiene distribución absolutamente continua conjunta y $U = (U_1, \dots, U_n)$, donde $U_k = u_k(X_1, \dots, X_n)$ para cada $k = 1, \dots, n$. Suponga que $X_k = x_k(U_1, \dots, U_n)$ para cada $k = 1, \dots, n$. Entonces $U_1, \dots, U_n$ tiene distribución absolutamente continua conjunta dada por

$$f_{U_1, \dots, U_n}(u_1, \dots, u_n) = f_{X_1, \dots, X_n}(x_1(u_1, \dots, u_n), \dots, x_n(u_1, \dots, u_n)) \left| \frac{\partial(x_1, \dots, x_n)}{\partial(u_1, \dots, u_n)} \right|. \quad (4.18)$$

Demostración. Sea $(y_1, \dots, y_n) \in \mathbb{R}^n$, y considere

$$R = \{(x_1, \dots, x_n) : u(x_1, \dots, x_n) \leq (y_1, \dots, y_n)\} = u^{-1}([-\infty, y_1] \times \dots \times [-\infty, y_n]).$$

Tenemos que

$$\begin{aligned} F_{U_1, \dots, U_n}(y_1, \dots, y_n) &= \mathbb{P}(U_1 \leq y_1, \dots, U_n \leq y_n) \\ &= \mathbb{P}((X_1, \dots, X_n) \in R) \\ &= \int_R f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_n. \end{aligned}$$

De donde obtenemos

$$F_{U_1, \dots, U_n}(y_1, \dots, y_n) = \int_{-\infty}^{y_1} \dots \int_{-\infty}^{y_n} f_{X_1, \dots, X_n}(x_1(u_1, \dots, u_n), \dots, x_n(u_1, \dots, u_n)) \left| \frac{\partial(x_1, \dots, x_n)}{\partial(u_1, \dots, u_n)} \right| du_1 \dots du_n.$$

□

4.2 Varianza, covarianza y correlación

Definición 4.2.1. Covarianza. Si X, Y son variables aleatorias tales que $\mathbb{E}[X^2] < \infty$ y $\mathbb{E}[Y^2] < \infty$, la covarianza de X y Y se define como

$$\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]. \quad (4.19)$$

Proposición 4.2.1. Propiedades fundamentales de la covarianza. Si $\mathbb{E}(X^2) < \infty$ y $\mathbb{E}(Y^2) < \infty$, entonces

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y] \quad (4.20)$$

$$\text{Cov}(X, Y) = \text{Cov}(Y, X) \quad (4.21)$$

$$\text{Var}(X) = \text{Cov}(X, X) \quad (4.22)$$

$$\text{Cov}(aX + bY, Zc) = ac \cdot \text{Cov}(X, Z) + bc \cdot \text{Cov}(Y, Z) \quad \text{para todo } a, b, c \in \mathbb{R} \quad (4.23)$$

La demostración queda al lector.

Definición 4.2.2. Correlación El coeficiente de correlación de X y Y se define como

$$\rho(X, Y) := \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \cdot \sqrt{\text{Var}(Y)}} \quad (4.24)$$

siempre y cuando el denominador esté bien definido.

Teorema 4.2.1. Propiedades fundamentales del coeficiente de correlación lineal. Si está definido, entonces $-1 \leq \rho(X, Y) \leq 1$. Además

$$\rho(X, Y) = 1 \quad \text{si y sólo si existe } \lambda > 0 \text{ tal que } Y - \mathbb{E}[Y] = \lambda(X - \mathbb{E}[X]) \quad (4.25)$$

$$\rho(X, Y) = -1 \quad \text{si y sólo si existe } \lambda < 0 \text{ tal que } Y - \mathbb{E}[Y] = \lambda(X - \mathbb{E}[X]) \quad (4.26)$$

Demostración. Usando la desigualdad de Cauchy-Schwartz tenemos

$$[\mathbb{E}((X - \mathbb{E}[X])(Y - \mathbb{E}[Y]))]^2 \leq \mathbb{E}[(X - \mathbb{E}[X])^2] \cdot \mathbb{E}[(Y - \mathbb{E}[Y])^2].$$

Esto implica que

$$-1 \leq \rho(X, Y) \leq 1.$$

Para demostrar las igualdades, se utiliza el hecho de que la igualdad en la desigualdad de Cauchy-Schwartz se obtiene si y sólo si existe un $t \in \mathbb{R}$ tal que

$$Y - \mathbb{E}[Y] = t(X - \mathbb{E}[X])$$

□

Proposición 4.2.2. Fórmula de la varianza de una suma. Sean $X_1, \dots, X_n$ variables aleatorias tales que $\mathbb{E}[X_k^2] < \infty$ para todo $k = 1, \dots, n$. Entonces

$$\text{Var} \left(\sum_{k=1}^n X_k \right) = \sum_{k=1}^n \text{Var}(X_k) + 2 \sum_{i < j} \text{Cov}(X_i, X_j) \quad (4.27)$$

La demostración queda al lector.

Definición 4.2.3. Matriz de covarianza. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio tal que $\mathbb{E}(X_k^2) < \infty$ para todo $k = 1, \dots, n$. La matriz de covarianza de X , denotada por Σ , se define como

$$\Sigma := \begin{pmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \dots & \text{Cov}(X_n, X_n) \end{pmatrix} \quad (4.28)$$

Y la matriz de correlación de X , denotada por R , se define como

$$R := \begin{pmatrix} \rho(X_1, X_1) & \rho(X_1, X_2) & \dots & \rho(X_1, X_n) \\ \rho(X_2, X_1) & \rho(X_2, X_2) & \dots & \rho(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \rho(X_n, X_1) & \rho(X_n, X_2) & \dots & \rho(X_n, X_n) \end{pmatrix} \quad (4.29)$$

4.3 Independencia de vectores aleatorios

Definición 4.3.1. Independencia de vectores aleatorios. Sean $X_1, \dots, X_n$ variables aleatorias. Decimos que estas variables son independientes si para cada escogencia de números reales $a_k < b_k$, los eventos

$$a_1 < X_1 < b_1, \quad a_2 < X_2 < b_2, \quad \dots, \quad a_n < X_n < b_n \quad (4.30)$$

son independientes. En particular, para todo $m \leq n$ se cumple que

$$\mathbb{P} \left(\bigcap_{k=1}^m \{a_k < X_k < b_k\} \right) = \prod_{k=1}^m \mathbb{P}(a_k < X_k < b_k). \quad (4.31)$$

En realidad todo esto y lo anterior se puede generalizar tomando variables aleatorias no a $\mathbb{R}$ sino a cualquier conjunto o espacio métrico para mejor manejo.

Teorema 4.3.1. Independencia mediante la función de distribución conjunta. Sean $X_1, \dots, X_n$ variables aleatorias. Una condición necesaria y suficiente para que las variables sean independientes es que

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = F_{X_1}(x_1) F_{X_2}(x_2) \dots F_{X_n}(x_n). \quad (4.32)$$

para todo $(x_1, \dots, x_n) \in \mathbb{R}^n$.

La demostración queda al lector.

Proposición 4.3.1. Independencia mediante factorización de la distribución conjunta. Sean $X_1, \dots, X_n$ variables aleatorias. Entonces, si todas son discretas, son independientes si y sólo si

$$\mathbb{P} \left(\bigcap_{k=1}^n \{X_k = x_k\} \right) = \prod_{k=1}^n p(x_k). \quad (4.33)$$

para todo $x_k \in \text{Ran}(X_k)$, $k = 1, \dots, n$. Si todas son absolutamente continuas, entonces son independientes si y sólo si

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = f_{X_1}(x_1) \dots f_{X_n}(x_n). \quad (4.34)$$

para todo $x_k \in \mathbb{R}$, $k = 1, \dots, n$.

La demostración queda al lector.

Teorema 4.3.2. Preservación de independencia por funciones medibles. Si $X_1, \dots, X_n$ son variables aleatorias independientes, y $f_1, \dots, f_n$ son funciones Borel-medible, entonces $f_1(X_1), \dots, f_n(X_n)$ también son variables aleatorias independientes.

La demostración queda al lector.

4.3.1 Esperanza independiente

Teorema 4.3.3. Factorización de la esperanza bajo independencia. Si $X_1, \dots, X_n$ son variables aleatorias independientes, y si $\mathbb{E}[X_k] < \infty$ para todo $k = 1, \dots, n$, entonces se cumple que

$$\mathbb{E}[X_1 \dots X_n] = \mathbb{E}[X_1] \dots \mathbb{E}[X_n]. \quad (4.35)$$

La demostración queda al lector.

Corolario 4.3.1. Independencia implica incorrelación. Si X y Y son independientes, entonces

$$\text{Cov}(X, Y) = 0. \quad (4.36)$$

La demostración queda al lector.

Corolario 4.3.2. Varianza aditiva bajo independencia. Si $X_1, \dots, X_n$ son independientes y $\mathbb{E}[X_k^2] < \infty$ para todo $k = 1, \dots, n$, entonces

$$\text{Var} \left(\sum_{k=1}^n X_k \right) = \sum_{k=1}^n \text{Var}(X_k). \quad (4.37)$$

La demostración queda al lector.

Definición 4.3.2. Función generadora de momentos multivariable. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio. Suponga que existe un $M > 0$ tal que $\mathbb{E}[e^{X \cdot t}] < \infty$ para todo $t = (t_1, \dots, t_n) \in \mathbb{R}^n$ tal que $\|t\| < M$. Entonces, la función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{X \cdot t}]. \quad (4.38)$$

Teorema 4.3.4. Factorización de la función generadora de momentos bajo independencia. Si $X = (X_1, \dots, X_n)$, entonces m_X existe si y sólo si ϕ_{X_k} existe para todo $k = 1, \dots, n$. Más aún, si $X_1, \dots, X_n$ son independientes, entonces

$$\phi_X(t) = \phi_{X_1}(t_1) \dots \phi_{X_n}(t_n). \quad (4.39)$$

La demostración queda al lector.

Definición 4.3.3. Función características multivariable. Sea $X = (X_1, \dots, X_n)$ un vector aleatorio. La función característica de X se define como

$$\varphi_X(t) = \mathbb{E}[e^{iX \cdot t}] \quad (4.40)$$

para todo $t = (t_1, \dots, t_n) \in \mathbb{R}^n$.

Teorema 4.3.5. Factorización de la función característica bajo independencia. Si $X = (X_1, \dots, X_n)$ es un vector aleatorio, este queda determinado en forma única por φ_X . Más aún, si $X_1, \dots, X_n$ son independientes, entonces

$$\varphi_X(t) = \varphi_{X_1}(t_1) \dots \varphi_{X_n}(t_n). \quad (4.41)$$

La demostración se deja al lector.

Distribución condicional

Definición 4.3.4. Distribución acumulada condicional. La distribución condicional de X dado $Y = y$ se define como

$$F_{X|Y}(x | y) := \mathbb{P}(X \leq x | Y = y). \quad (4.42)$$

para todo $x \in \mathbb{R}$, siempre y cuando la probabilidad condicional esté bien definida.

4.3.2 Propiedades de la distribución condicional

Proposición 4.3.2. Densidad condicional. Sean X, Y variables aleatorias absolutamente continuas con densidad conjunta $f_{X,Y}$ y densidad marginal f_Y . Entonces para todo y con $f_Y(y) > 0$, la medida condicional $\mu_{X|Y=y} \ll \lambda$ con derivada de Radon-Nikodym

$$f_{X|Y}(x | y) = \frac{d\mu_{X|Y=y}}{d\lambda}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad (4.43)$$

y en consecuencia

$$F_{X|Y}(x | y) = \int_{-\infty}^x f_{X|Y}(t | y) dt. \quad (4.44)$$

La demostración se deja al lector.

Proposición 4.3.3. Función de masa condicional. Sean X, Y variables aleatorias discretas con función de masa conjunta $p_{X,Y}$ y función de masa marginal p_Y . Entonces para todo y con $p_Y(y) > 0$, la medida condicional $\mu_{X|Y=y} \ll \mu_c$ con derivada de Radon-Nikodym respecto a la medida de conteo μ_c

$$p_{X|Y}(x | y) = \frac{d\mu_{X|Y=y}}{d\mu_c}(x) = \frac{p_{X,Y}(x, y)}{p_Y(y)}, \quad (4.45)$$

y en consecuencia

$$F_{X|Y}(x | y) = \sum_{t \leq x} p_{X|Y}(t | y). \quad (4.46)$$

La demostración se deja al lector.

Teorema 4.3.6. Regla de Bayes para mezclas discreto-continuas. Suponga que Z es absolutamente continua y que N es discreta. Entonces

$$\frac{d}{dz} F_{Z|N}(z | n) = \lim_{h \rightarrow 0} \frac{\mathbb{P}(z < Z \leq z + h | N = n)}{h} \quad (4.47)$$

$$= \lim_{h \rightarrow 0} \frac{\mathbb{P}(N = n | z < Z \leq z + h)}{p(N = n)} \cdot \frac{\mathbb{P}(z < Z \leq z + h)}{h} \quad (4.48)$$

$$= \mathbb{P}(N = n | Z = z) \cdot \frac{f_Z(z)}{p(N = n)} \quad (4.49)$$

Por lo tanto, se tiene que

$$f_{Z|N}(z | n) = \mathbb{P}(N = n | Z = z) \cdot \frac{f_Z(z)}{p(N = n)} \quad (4.50)$$

Si $f_Z(z) > 0$, de lo anterior es razonable definir

$$F_{N|Z}(n | z) := \frac{f_{Z|N}(z | n)}{f_Z(z)} p(N = n) \quad (4.51)$$

En particular, se puede comprobar que

$$p(N = n) = \int_{\mathbb{R}} \mathbb{P}(N = n | Z = z) f_Z(z) dz \quad (4.52)$$

Demostración. Para

$$\frac{d}{dz} F_{Z|N}(z | n) = \lim_{h \rightarrow 0} \frac{\mathbb{P}(z < Z \leq z + h, N = n)}{h},$$

se deriva del teorema fundamental del calculo y la definición de distribución condicional. Las igualdades se derivan trivialmente de el argumento anterior. Y para la ultima simplemente integre sobre $\mathbb{R}$ con respecto a z . $\square$

4.4 Esperanza condicional

Definición 4.4.1. Esperanza condicional. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, $\mathcal{G} \subseteq \mathcal{F}_0$ una σ -álgebra, y X una variable aleatoria con $\mathbb{E}[|X|] < \infty$. Se dice que Y es una versión de $\mathbb{E}[X | \mathcal{G}]$ si

$$Y \in \mathcal{G}, \quad \text{y} \quad \int_A X d\mathbb{P} = \int_A Y d\mathbb{P} \quad \forall A \in \mathcal{G}. \quad (4.53)$$

Si Y es una variable aleatoria, definimos $\mathbb{E}[X | Y] := \mathbb{E}[X | \sigma(Y)]$, donde $\sigma(Y)$ es la σ -álgebra generada por Y .

Definición 4.4.2. Distribución condicional regular. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, $X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S})$ una función medible y $\mathcal{G} \subseteq \mathcal{F}$ una σ -álgebra. Una función $\mu : \Omega \times \mathcal{S} \rightarrow [0, 1]$ se dice una distribución condicional regular de X dado $\mathcal{G}$ si

$$\text{para cada } A \in \mathcal{S}, \quad \omega \mapsto \mu(\omega, A) \text{ es una versión de } \mathbb{P}(X \in A | \mathcal{G}), \quad (4.54)$$

$$\text{para c.t.p. } \omega, \quad A \mapsto \mu(\omega, A) \text{ es una medida de probabilidad sobre } (S, \mathcal{S}). \quad (4.55)$$

Cuando $S = \Omega$ y X es la identidad, μ se llama una probabilidad condicional regular.

4.4.1 Propiedades de la esperanza regular

Lema 4.4.1. Unicidad casi segura. Si Y_1 e Y_2 son dos versiones de $\mathbb{E}[X \mid \mathcal{G}]$, entonces $\mathbb{P}(Y_1 = Y_2) = 1$.

Demostración. Sea $Z = Y_1 - Y_2$. Como ambas satisfacen la definición, $\int_A Z d\mathbb{P} = 0$ para todo $A \in \mathcal{G}$. Tomando $A^+ = \{Z > 0\}$ y $A^- = \{Z < 0\}$, que pertenecen a $\mathcal{G}$, se tiene $\int_{A^+} Z d\mathbb{P} = 0$ con $Z > 0$ en A^+ , luego $\mathbb{P}(A^+) = 0$, y análogamente $\mathbb{P}(A^-) = 0$. Por tanto $\mathbb{P}(Z \neq 0) \leq \mathbb{P}(A^+) + \mathbb{P}(A^-) = 0$. $\square$

Teorema 4.4.1. Existencia de la esperanza condicional. Si $\mathbb{E}[|X|] < \infty$, entonces $\mathbb{E}[X \mid \mathcal{G}]$ existe.

Demostración. Escribimos $X = X^+ - X^-$ con $X^+, X^- \geq 0$ e integrables. Para $Y \geq 0$ con $Y \in L^1(\mathcal{F}_0)$, la medida $\nu(A) = \int_A Y d\mathbb{P}$ sobre $\mathcal{G}$ satisface $\nu \ll \mathbb{P}|_{\mathcal{G}}$. Por Radon-Nikodym existe $Z \in \mathcal{G}$, $Z \geq 0$, tal que $\nu(A) = \int_A Z d\mathbb{P}$ para todo $A \in \mathcal{G}$. Aplicando esto a X^+ y X^- se obtienen $Y^+, Y^- \in \mathcal{G}$ no negativos con $\int_A X^\pm d\mathbb{P} = \int_A Y^\pm d\mathbb{P}$. Entonces $Y = Y^+ - Y^-$ satisface la definición. $\square$

Teorema 4.4.2. Propiedades de la esperanza condicional. Sean X, Y variables aleatorias integrables, $a, b \in \mathbb{R}$, $\mathcal{G}_1 \subseteq \mathcal{G}_2 \subseteq \mathcal{F}_0$ σ -álgebras y φ convexa. Entonces:

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]] = \mathbb{E}[X]. \quad (4.56)$$

$$X \geq 0 \implies \mathbb{E}[X \mid \mathcal{G}] \geq 0 \quad \wedge \quad X \leq Y \implies \mathbb{E}[X \mid \mathcal{G}] \leq \mathbb{E}[Y \mid \mathcal{G}]. \quad (4.57)$$

$$\mathbb{E}[aX + bY \mid \mathcal{G}] = a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}]. \quad (4.58)$$

$$\text{Si } \sigma(X) \perp \mathcal{G}, \text{ entonces } \mathbb{E}[X \mid \mathcal{G}] = \mathbb{E}[X]. \quad (4.59)$$

$$\text{Si } Y \in \mathcal{G}, \text{ entonces } \mathbb{E}[XY \mid \mathcal{G}] = Y\mathbb{E}[X \mid \mathcal{G}]. \quad (4.60)$$

$$\mathbb{E}[\varphi(X) \mid \mathcal{G}] \geq \varphi(\mathbb{E}[X \mid \mathcal{G}]). \quad (4.61)$$

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}_2] \mid \mathcal{G}_1] = \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}_1] \mid \mathcal{G}_2] = \mathbb{E}[X \mid \mathcal{G}_1]. \quad (4.62)$$

$$X_n \uparrow X, X_n \geq 0, \mathbb{E}[X] < \infty \implies \mathbb{E}[X_n \mid \mathcal{G}] \uparrow \mathbb{E}[X \mid \mathcal{G}]. \quad (4.63)$$

La demostración se deja al lector.

Teorema 4.4.3. Contracción en L^p y proyección ortogonal en L^2 . Para $p \geq 1$, la esperanza condicional es una contracción en L^p :

$$\|\mathbb{E}[X \mid \mathcal{G}]\|_p \leq \|X\|_p. \quad (4.64)$$

En particular para $p = 2$, $\mathbb{E}[X \mid \mathcal{G}]$ es la única variable $Y \in \mathcal{G}$ que minimiza

$$\mathbb{E}[(X - Y)^2], \quad (4.65)$$

es decir, es la proyección ortogonal de X sobre $L^2(\mathcal{G})$.

La demostración se deja al lector.

Teorema 4.4.4. LOTUS condicional. Sea $\mu(\omega, \cdot)$ una distribución condicional regular de X dado $\mathcal{G}$, y sea g medible con $\mathbb{E}[|g(X)|] < \infty$. Entonces

$$\mathbb{E}[g(X) | \mathcal{G}](\omega) = \int \mu(\omega, dx) g(x) \quad \text{c.s.} \quad (4.66)$$

En los casos particulares, si Y es discreta o absolutamente continua

$$\mathbb{E}[g(X) | Y = y] = \sum_x g(x) p_{X|Y}(x | y) \quad \text{o} \quad \mathbb{E}[g(X) | Y = y] = \int_{-\infty}^{\infty} g(x) f_{X|Y}(x | y) dx. \quad (4.67)$$

La demostración se deja al lector.

Proposición 4.4.1. Varianza condicional. Sea X una variable aleatoria con $\mathbb{E}[X^2] < \infty$. La varianza condicional de X dado Y es la variable aleatoria

$$\text{Var}(X | Y) := \mathbb{E}[(X - \mathbb{E}[X | Y])^2 | Y] = \mathbb{E}[X^2 | Y] - (\mathbb{E}[X | Y])^2, \quad (4.68)$$

La demostración se deja al lector.

Proposición 4.4.2. Ley de la varianza total. Se cumple que

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X | Y)] + \text{Var}(\mathbb{E}[X | Y]) \quad (4.69)$$

La demostración se deja al lector.

Teorema 4.4.5. Factorización condicional bajo independencia y extracción funciones.

$$\text{Si } X \text{ y } Y \text{ son independientes, entonces } \mathbb{E}[X | Y] = \mathbb{E}[X] \quad (4.70)$$

$$\mathbb{E}[X \cdot g(Y) | Y] = g(Y) \cdot \mathbb{E}[X | Y] \quad (4.71)$$

La primera es trivial, y la segunda es simplemente por que Y está fijo para un conjunto.

Teorema 4.4.6. Fórmula de convolución. Sean X y Y variables aleatorias independientes con funciones de distribución acumulada $F(x) = \mathbb{P}(X \leq x)$ y $G(y) = \mathbb{P}(Y \leq y)$, respectivamente. Entonces, para todo $z \in \mathbb{R}$, se cumple

$$\mathbb{P}(X + Y \leq z) = \int_{-\infty}^{\infty} F(z - y) dG(y). \quad (4.72)$$

Demostración. Dado que son independientes se cumple que $\mathbb{P}(X \leq x, Y \leq y) = F(x)G(y)$ y dado que

$$\mathbb{P}(X \leq z - Y | Y) = \mathbb{P}(X \leq z - Y) = F(z - Y).$$

Ahora por el teorema de probabilidad total

$$\mathbb{P}(X + Y \leq z) = \mathbb{E}(\mathbb{P}(X + Y \leq z | Y)) = \mathbb{E}(\mathbb{P}(X \leq z - Y | Y)).$$

Entonces por definición de esperanza de una variable aleatoria continua

$$\mathbb{P}(X + Y \leq z) = \mathbb{E}[F(z - Y)] = \int_{-\infty}^{\infty} F(z - y) dG(y).$$

□

Teorema 4.4.7. Convolución de densidades. Sean X y Y variables aleatorias independientes, donde X tiene densidad f y Y tiene función de distribución acumulada $G(y) = \mathbb{P}(Y \leq y)$. Entonces, la variable aleatoria $X + Y$ tiene densidad h dada por

$$h(x) = \int_{-\infty}^{\infty} f(x-y) dG(y). \quad (4.73)$$

Si además Y tiene densidad g , entonces

$$h(x) = \int_{-\infty}^{\infty} f(x-y) g(y) dy. \quad (4.74)$$

El teorema anterior es consecuencia directa del teorema de Leibniz para integración parcial y el teorema anterior.

4.5 Convergencia de variables aleatorias

4.5.1 Convergencia casi segura

Definición 4.5.1. Convergencia casi segura. La sucesión X_n , $n = 1, 2, 3, \dots$, converge casi seguramente a una variable aleatoria X si

$$\mathbb{P}\left(\left\{\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right\}\right) = 1 \quad (4.75)$$

Se denota $X_n \xrightarrow{\text{c.s.}} X$ o $\lim_{n \rightarrow \infty} X_n = X$ c.s.

Proposición 4.5.1. Caracterización probabilística de la convergencia casi segura. Se tiene que $X_n \xrightarrow{\text{c.s.}} X$ si y sólo si para todo $\varepsilon > 0$ se cumple

$$\lim_{m \rightarrow \infty} \mathbb{P}\left(\sup_{n \geq m} |X_n - X| \geq \varepsilon\right) = 0 \quad (4.76)$$

Demostración. Suponga por contradicción que $X_n \xrightarrow{\text{c.s.}} X$ pero no

$$\lim_{m \rightarrow \infty} \mathbb{P}\left(\sup_{n \geq m} |X_n - X| \geq \varepsilon\right) = 0.$$

En cuyo caso eso implica que $\exists_{\omega \in \Omega} \mid \exists_{\varepsilon > 0} \forall_{m \in \mathbb{N}} (\sup_{n \geq m} |X_n - X| \geq \varepsilon)$ (Osea, hay un $\omega \mid \mathbb{P}(\omega) > 0$). Entonces se sigue que de igual forma $\exists_{\omega} \mid \lim_{n \rightarrow \infty} X_n(\omega) \neq X(\omega)$, consecuentemente, ya que se esta bajo la misma función de probabilidad esto implica que

$$\mathbb{P}\left(\left\{\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right\}\right) + \mathbb{P}\left(\left\{\omega : \lim_{n \rightarrow \infty} X_n(\omega) \neq X(\omega)\right\}^c\right) = \mathbb{P}(\omega) > 1,$$

lo cual es una contradicción. La otra dirección es básicamente los mismo. □

4.5.2 Convergencia en L^p

Definición 4.5.2. Convergencia en L^p . Sea $p \geq 1$ entero. Suponga que $\mathbb{E}[|X|^p] < \infty$ y $\mathbb{E}[|X_n|^p] < \infty$ para todo $n \in \mathbb{N}$. Diremos que X_n converge en L^p a X si

$$\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X|^p] = 0 \quad (4.77)$$

Denotamos $X_n \xrightarrow{L^p} X$ o $\lim_{n \rightarrow \infty} X_n = X$ en L^p .

4.5.3 Convergencia en distribución

Definición 4.5.3. Convergencia en distribución. Sean $X_1, X_2, X_3, \dots$ variables aleatorias cuyas funciones de distribución están dadas por $F_1, F_2, F_3, \dots$ respectivamente. Se dice que X_n converge en distribución a X si

$$\lim_{n \rightarrow \infty} F_n(x) = F(x) \quad (4.78)$$

para todo punto de continuidad de F , donde F representa la función de distribución de X . Se denota $X_n \xrightarrow{d} X$.

4.5.4 Convergencia en probabilidad

Definición 4.5.4. Convergencia en probabilidad. Sean $(X_n)_{n \in \mathbb{N}}$ y X variables aleatorias definidas sobre el mismo espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$. Decimos que X_n converge en probabilidad a X si, para todo $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \varepsilon) = 0. \quad (4.79)$$

Se denota $X_n \xrightarrow{\mathbb{P}} X$ o $X_n \rightarrow X$ en probabilidad.

4.5.5 Teorema de convergencia

Teorema 4.5.1. Cadena de implicaciones de convergencia. Si $X_n \xrightarrow{\text{c.s.}} X$, entonces $X_n \xrightarrow{\mathbb{P}} X$. Si $X_n \xrightarrow{\mathbb{P}} X$, entonces $X_n \xrightarrow{d} X$. Si $c \in \mathbb{R}$ y $X_n \xrightarrow{d} c$, entonces $X_n \xrightarrow{\mathbb{P}} c$.

La primera es por pura definición. La segunda se hace por contradicción. Y la tercera se hace tomando epsilons y el valor real de la variable aleatoria.

Teorema 4.5.2. Convergencia dominada. Suponga que $X_n \xrightarrow{\text{c.s.}} X$ y que existe una variable aleatoria Y tal que $\mathbb{E}(Y) < \infty$ y $|X_n| \leq Y$ para todo $n \in \mathbb{N}$. Entonces

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}[X] \quad (4.80)$$

Demostración. Suponga que $\mathbb{E}(X) < \infty$. Ahora tome $Z_n = |X_n - X|$ y note que $Z_n \xrightarrow{\text{c.s.}} 0$, entonces $\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|) = 0$. En cuyo caso se sigue que por la desigualdad de Jensen se tiene $\lim_{n \rightarrow \infty} \mathbb{E}(X_n) = \mathbb{E}(X)$. El caso $\mathbb{E}(X) = \infty$ es trivial. □

Teorema 4.5.3. Convergencia monótona. Suponga que $0 \leq X_n \uparrow X$ y que $X_n \xrightarrow{\text{c.s.}} X$. Entonces

$$\lim_{n \rightarrow \infty} \mathbb{E}(X_n) = \mathbb{E}(X) \quad (4.81)$$

Demostración. Dada la convergencia monótona creciente positiva, se tiene que $|X_n| = X_n \leq X$. Ahora suponga que $\mathbb{E}(X) = \infty$, entonces se sigue que

$$\lim_{m \rightarrow \infty} \mathbb{P} \left(\sup_{n \geq m} |X_n - X| \geq \varepsilon \right) > 0,$$

Lo que contradice en teorema trasanterior. Entonces lo demás se sigue del teorema anterior. □

Teorema 4.5.4. Teorema de Helly-Bray. Sean F_n funciones de distribución acumulada y F una función de distribución acumulada tal que $X_n \xrightarrow{d} X$. Sea $h : \mathbb{R} \rightarrow \mathbb{R}$ una función continua y acotada. Entonces

$$\int_{-\infty}^{\infty} h(x) dF_n(x) \rightarrow \int_{-\infty}^{\infty} h(x) dF(x). \quad (4.82)$$

Demostración. Como h es continua y acotada en $\mathbb{R}$, existe una constante $M > 0$ tal que $|h(x)| \leq M, \forall x \in \mathbb{R}$. Sea $\varepsilon > 0$. Dado que h es continua y acotada, existe una función escalonada de la forma

$$\varphi(x) = \sum_{k=1}^m c_k \mathbf{1}_{(-\infty, d_k]}(x),$$

donde $d_1 < d_2 < \dots < d_m$ independientes del n , tal que $\sup_{x \in \mathbb{R}} |h(x) - \varphi(x)| < \varepsilon$. Por linealidad de la integral de Stieltjes

$$\begin{aligned} & \int h(x) dF_n(x) - \int h(x) dF(x) \\ &= \int (h - \varphi) dF_n(x) + \int \varphi(x) dF_n(x) - \int \varphi(x) dF(x) + \int (\varphi - h) dF(x). \end{aligned}$$

Ahora note

$$\int \varphi(x) dF_n(x) = \sum_{k=1}^m c_k F_n(d_k) \quad \wedge \quad \int \varphi(x) dF(x) = \sum_{k=1}^m c_k F(d_k).$$

Elegimos los puntos d_k como puntos de continuidad de F . Por convergencia en distribución

$$\sum_{k=1}^m c_k F_n(d_k) \rightarrow \sum_{k=1}^m c_k F(d_k).$$

De forma que

$$\limsup_{n \rightarrow \infty} \left| \int h dF_n - \int h dF \right| \leq M\varepsilon.$$

Entonces

$$\left| \int_{-\infty}^{\infty} h(x) dF_n(x) - \int_{-\infty}^{\infty} h(x) dF(x) \right| < \varepsilon(M + 1).$$

□

Teorema 4.5.5. Continuidad de Lévy y Cramér. Sean $X_1, X_2, X_3, \dots$ variables aleatorias con funciones características $\varphi_1, \varphi_2, \varphi_3, \dots$ respectivamente. Sea X otra variable aleatoria con función característica φ . Entonces $X_n \xrightarrow{d} X$ si y sólo si

$$\lim_{n \rightarrow \infty} \varphi_n(t) = \varphi(t) \quad \text{para todo } t \in \mathbb{R} \quad (4.83)$$

Demostración. La parte izquierda derecha se deja al lector.

Para la otra parte note que por el teorema de Helly, toda sucesión de $\{F_n\}$ tiene una subsucesión $\{F_{n_k}\}$ que converge en todos los puntos de continuidad del límite a alguna función de distribución G . Sea entonces $\{F_{n_k}\}$ una subsucesión cualquiera tal que $F_{n_k} \rightarrow G$, cuya función característica denotaremos ψ ; sea $h(x) = e^{itx}$. Por Helly-Bray aplicado a la subsucesión

$$\varphi_{n_k}(t) = \int e^{itx} dF_{n_k}(x) \rightarrow \int e^{itx} dG(x) = \psi(t).$$

Pero por hipótesis, $\varphi_{n_k}(t) \rightarrow \varphi(t)$. Por unicidad del límite, $\psi(t) = \varphi(t)$ para todo $t \in \mathbb{R}$. Es bien conocido (y se prueba usando inversión de Fourier o el teorema de Stone-Weierstrass en intervalos) que

dos variables aleatorias con la misma función característica tienen la misma distribución. En particular $G = F$.

Supongamos por contradicción que no $X_n \xrightarrow{d} X$. Entonces existe $\varepsilon > 0$, un punto de continuidad x de F , y una subsucesión n_j tal que

$$|F_{n_j}(x) - F(x)| \geq \varepsilon, \quad \forall j.$$

Pero $\{F_{n_j}\}$ tiene una subsucesión convergente $F_{n_{j_k}} \Rightarrow H$ para alguna f.d. H . Por el teorema de Helly y lo anterior $H = F$, así que $F_{n_{j_k}}(x) \rightarrow F(x)$, contradicción.

Por tanto, $F_n(x) \rightarrow F(x)$ en todo punto de continuidad de F , es decir, $X_n \xrightarrow{d} X$.

□

4.5.6 Desigualdad de Chebyshev

Teorema 4.5.6. Desigualdad de Chebyshev. Sea X una variable aleatoria con $\mathbb{E}[|X|] < \infty$ y $\text{Var}(X) < \infty$. Entonces, para todo $\varepsilon > 0$,

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}. \quad (4.84)$$

Demostración. Definamos $Y = X - \mathbb{E}[X]$. Entonces

$$\mathbb{E}[Y] = 0, \quad \text{Var}(Y) = \text{Var}(X).$$

Por definición de varianza

$$\text{Var}(Y) = \mathbb{E}[Y^2].$$

Ahora, descomponemos la esperanza usando el evento $\{|Y| \geq \varepsilon\}$

$$\mathbb{E}[Y^2] = \mathbb{E}[Y^2 \cdot 1_{\{|Y| \geq \varepsilon\}}] + \mathbb{E}[Y^2 \cdot 1_{\{|Y| < \varepsilon\}}].$$

El segundo término es no negativo

$$\mathbb{E}[Y^2 \cdot 1_{\{|Y| < \varepsilon\}}] \geq 0.$$

En el primer término, como $|Y| \geq \varepsilon$ en el soporte del indicador

$$Y^2 \cdot 1_{\{|Y| \geq \varepsilon\}} \geq \varepsilon^2 \cdot 1_{\{|Y| \geq \varepsilon\}}.$$

Tomando esperanza

$$\mathbb{E}[Y^2 \cdot 1_{\{|Y| \geq \varepsilon\}}] \geq \varepsilon^2 \cdot \mathbb{E}[1_{\{|Y| \geq \varepsilon\}}] = \varepsilon^2 \cdot \mathbb{P}(|Y| \geq \varepsilon).$$

□

5

Ley de los grandes números.

5.0.1 Variables no correlacionadas

Definición 5.0.1. Variables no correlacionadas. Sea $\{X_i\}_{i \in I}$ una familia de variables aleatorias tales que $\mathbb{E}[X_i^2] < \infty$ para todo $i \in I$. Decimos que dicha familia es no correlacionada si, para todo par $i \neq j$, se cumple

$$\mathbb{E}[X_i X_j] = \mathbb{E}[X_i] \cdot \mathbb{E}[X_j]. \quad (5.1)$$

Teorema 5.0.1. Varianza no correlacionada. Sean $X_1, \dots, X_n$ variables aleatorias no correlacionadas tales que $\mathbb{E}[X_i^2] < \infty$ para todo $i = 1, \dots, n$. Entonces, la varianza de la suma es igual a la suma de las varianzas

$$\text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n), \quad (5.2)$$

donde $\text{Var}(Y)$ denota la varianza de la variable aleatoria Y .

La demostración queda al lector. Aplique el binomio de newton y ya.

Lema 5.0.1. Convergencia en probabilidad vía momentos. Sea $\{Z_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias y sea $p > 0$. Si

$$\lim_{n \rightarrow \infty} \mathbb{E}(|Z_n|^p) = 0, \quad (5.3)$$

entonces

$$Z_n \xrightarrow{\mathbb{P}} 0, \quad (5.4)$$

es decir, Z_n converge a cero en probabilidad.

La demostración queda al lector. Aplique la desigualdad de chebyshev.

5.0.2 Ley debil en L^2

Teorema 5.0.2. Ley débil en L^2 . Suponga que $X_1, X_2, X_3, \dots$ son variables aleatorias no correlacionadas con $\mathbb{E}[X_n] = \mu$ y $\text{Var}(X_n) < \infty$ para todo $n \in \mathbb{N}$. Si $S_n := X_1 + X_2 + \dots + X_n$, entonces

$$\frac{S_n}{n} \xrightarrow{L^2} \mu \quad (5.5)$$

y por lo tanto

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu \quad (5.6)$$

La demostración queda al lector. Aplique el Teorema del promedio de Cesàro.

Teorema 5.0.3. Ley débil por control de varianza. Sea S_n una sucesión de variables aleatorias con esperanza $\mu_n := \mathbb{E}[S_n]$ y varianza $\sigma_n^2 := \text{Var}(S_n)$. Suponga que existe una sucesión de escalares positivos $b_n > 0$ tal que

$$\frac{\sigma_n^2}{b_n^2} \rightarrow 0, \quad (5.7)$$

entonces

$$\frac{S_n - \mu_n}{b_n} \xrightarrow{\mathbb{P}} 0. \quad (5.8)$$

Demostración. Note que

$$\mathbb{P}(|S_n - \mu_n| \geq \varepsilon b_n) \leq \frac{\text{Var}(S_n)}{(\varepsilon b_n)^2} = \frac{\sigma_n^2}{\varepsilon^2 b_n^2}.$$

Entonces se sigue que

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{S_n - \mu_n}{b_n}\right| \geq \varepsilon\right) \leq \lim_{n \rightarrow \infty} \frac{\sigma_n^2}{\varepsilon^2 b_n^2} = 0.$$

□

Definición 5.0.2. Variable indicadora de ciclos en la descomposición. Para cada $n \in \mathbb{N}$, se define la variable indicadora $X_{n,k}$ como aquella que toma el valor 1 si un paréntesis derecho aparece después del k -ésimo número en la descomposición correspondiente, y 0 en caso contrario. La suma total $S_n := X_{n,1} + X_{n,2} + \dots + X_{n,n}$ representa el número total de ciclos en dicha descomposición.

Lema 5.0.2. Esperanza del conteo de ciclos vía indicadores. Sean $X_{n,1}, \dots, X_{n,n}$ variables aleatorias independientes tales que

$$\mathbb{P}(X_{n,j} = 1) = \frac{1}{n - j + 1}. \quad (5.9)$$

Entonces, la suma $S_n = X_{n,1} + X_{n,2} + \dots + X_{n,n}$ satisface

$$\mathbb{E}[S_n] = \sum_{j=1}^n \frac{1}{n - j + 1} = H_n, \quad (5.10)$$

donde H_n es el n -ésimo número armónico.

La demostración es casi trivial.

Definición 5.0.3. Truncamiento. Sea X una variable aleatoria y sea $M > 0$. El truncamiento de X en el nivel M se define como

$$\bar{X} := X \cdot \mathbf{1}_{\{|X| \leq M\}} = \begin{cases} X, & \text{si } |X| \leq M, \\ 0, & \text{si } |X| > M. \end{cases} \quad (5.11)$$

Teorema 5.0.4. Teorema de Bienaymé–Chebyshev, versión débil tipo Lindeberg. Para cada $n \in \mathbb{N}$, sean $X_{n,k}$, con $1 \leq k \leq n$, variables aleatorias independientes. Sea $b_n > 0$ tal que $b_n \rightarrow \infty$; y suponga que, cuando $n \rightarrow \infty$, se cumplen las siguientes condiciones

$$\sum_{k=1}^n \mathbb{P}(|X_{n,k}| > b_n) \rightarrow 0, \quad (5.12)$$

$$\frac{1}{b_n^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] \rightarrow 0. \quad (5.13)$$

Si definimos $S_n := X_{n,1} + \dots + X_{n,n}$ y $a_n := \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}]$, entonces

$$\frac{S_n - a_n}{b_n} \xrightarrow{\mathbb{P}} 0. \quad (5.14)$$

Demostración. Note que los $\bar{X}_{n,k}$ son independientes y $|\bar{X}_{n,k}| \leq b_n$.

Tome

$$S_n = \sum_{k=1}^n \bar{X}_{n,k} + \sum_{k=1}^n X_{n,k} \mathbf{1}_{\{|X_{n,k}| > b_n\}} = \bar{S}_n + \hat{S}_n$$

Entonces

$$\mathbb{P}\left(\left|\frac{\hat{S}_n}{b_n}\right| > 0\right) \leq \mathbb{P}\left(\bigcup_k \{|X_{n,k}| > b_n\}\right) \leq \sum_{k=1}^n \mathbb{P}(|X_{n,k}| > b_n) \rightarrow 0.$$

Ahora, por independencia note que

$$\mathbb{E}\left[\frac{\bar{X}_{n,k} - \mathbb{E}[\bar{X}_{n,k}]}{b_n}\right] = 0 \quad \wedge \quad \text{Var}\left(\frac{\bar{X}_{n,k} - \mathbb{E}[\bar{X}_{n,k}]}{b_n}\right) = \frac{\mathbb{E}[\bar{X}_{n,k}^2]}{b_n^2}.$$

Por lo tanto

$$\text{Var}\left(\sum_{k=1}^n \frac{\bar{X}_{n,k} - \mathbb{E}[\bar{X}_{n,k}]}{b_n}\right) = \frac{1}{b_n^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] \rightarrow 0.$$

Sumado a ello

$$\sum_{k=1}^n \frac{\bar{X}_{n,k} - \mathbb{E}[\bar{X}_{n,k}]}{b_n} = \frac{\hat{S}_n - a_n}{b_n}.$$

Aplicando directamente el Teorema de ley débil por control de varianza

$$\frac{\hat{S}_n - a_n}{b_n} \xrightarrow{\mathbb{P}} 0.$$

□

Lema 5.0.3. Fórmula de integración por partes para momentos. Sea Y una variable aleatoria tal que $Y \geq 0$ casi seguramente, y sea $p > 0$. Entonces, el momento p -ésimo de Y se puede expresar como

$$\mathbb{E}[Y^p] = \int_0^\infty p y^{p-1} \mathbb{P}(Y > y) dy. \quad (5.15)$$

La demostración se deja al lector.

5.0.3 Ley de los Grandes Números con truncamiento para colas ligeras

Teorema 5.0.5. Ley de los Grandes Números con truncamiento para colas ligeras. Sea $X_1, X_2, X_3, \dots$ una sucesión de variables aleatorias i.i.d. tales que

$$x \cdot \mathbb{P}(|X_1| > x) \rightarrow 0 \quad \text{cuando } x \rightarrow \infty. \quad (5.16)$$

Defina $S_n := X_1 + X_2 + \dots + X_n$ y $\mu_n := \mathbb{E}[X_1 \cdot \mathbf{1}_{\{|X_1| \leq n\}}]$. Entonces, se tiene la siguiente convergencia en probabilidad

$$\frac{S_n}{n} - \mu_n \xrightarrow{\mathbb{P}} 0. \quad (5.17)$$

Demostración. Aplicamos directamente el teorema anterior tomando $X_{n,k} := X_k$ para $k = 1, \dots, n$ y $b_n := n$. Podemos ver que

$$\sum_{k=1}^n \mathbb{P}(|X_{n,k}| > n) = n \cdot \mathbb{P}(|X_1| > n) = n \cdot \mathbb{P}(|X_1| > b_n) \rightarrow 0.$$

Sumando a ello si $\bar{X}_{n,k} := X_k \mathbf{1}_{\{|X_k| \leq n\}}$, entonces

$$\frac{1}{b_n^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] = \frac{1}{n^2} \cdot n \cdot \mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}] = \frac{1}{n} \mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}] = \frac{2}{n} \int_0^n t \mathbb{P}(|X_1| > t) dt..$$

Y dado que $x \cdot \mathbb{P}(|X_1| > x) \rightarrow 0$, se tiene que para todo $\varepsilon > 0$ existe t_0 talque si $t \geq t_0$, entonces

$$\left| 2 \int_0^n t \mathbb{P}(|X_1| > t) dt \right| \leq 2t_0 + 2n\varepsilon$$

De forma que

$$\left| \frac{1}{b_n^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] \right| \leq 2 \frac{t_0}{n} + 2\varepsilon$$

De forma que cuando $n \rightarrow \infty$ entonces $\frac{1}{b_n^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] \rightarrow 0$. Además

$$a_n = \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}] = n \cdot \mathbb{E}[X_1 \mathbf{1}_{\{|X_1| \leq n\}}] = n\mu_n.$$

Entonces por el teorema anterior

$$\frac{S_n - a_n}{b_n} = \frac{S_n - n\mu_n}{n} = \frac{S_n}{n} - \mu_n \xrightarrow{\mathbb{P}} 0.$$

□

5.1 Lema de Borel-Cantelli

Teorema 5.1.1. Primer lema de Borel-Cantelli. Sea $\{A_n\}_{n \in \mathbb{N}}$ una sucesión de eventos en un espacio de probabilidad. Si

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty, \quad (5.18)$$

entonces

$$\mathbb{P}(A_n \text{ i.o.}) = 0, \quad (5.19)$$

donde A_n i.o. denota el evento de que ocurren infinitos A_n , es decir

$$A_n \text{ i.o.} := \limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k. \quad (5.20)$$

Demostración. Note que $m \in \mathbb{N}$. Entonces

$$\mathbb{P}\left(\bigcup_{k=m}^{\infty} A_k\right) \leq \sum_{k=m}^{\infty} \mathbb{P}(A_k)$$

Como la serie $\sum \mathbb{P}(A_k)$ converge entonces

$$\mathbb{P}\left(\bigcup_{k=m}^{\infty} A_k\right) \rightarrow 0 \quad m \rightarrow \infty.$$

Ahora, como

$$A_n \text{ i.o.} = \bigcap_{m=1}^{\infty} \bigcup_{k=m}^{\infty} A_k \subset \bigcup_{k=m}^{\infty} A_k, \quad \forall m$$

tenemos

$$\mathbb{P}(A_n \text{ i.o.}) \leq \mathbb{P}\left(\bigcup_{k=m}^{\infty} A_k\right), \quad \forall m.$$

Tomando el límite superior cuando $m \rightarrow \infty$,

$$\mathbb{P}(A_n \text{ i.o.}) \leq \lim_{m \rightarrow \infty} \mathbb{P}\left(\bigcup_{k=m}^{\infty} A_k\right) = 0.$$

□

Teorema 5.1.2. Caracterización de convergencia en probabilidad. Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias y sea X una variable aleatoria. Entonces

$$X_n \xrightarrow{\mathbb{P}} X \quad (5.21)$$

si y solo si para toda subsucesión $\{X_{n_m}\}_{m \in \mathbb{N}}$ existe una subsucesión adicional $\{X_{n_{m_k}}\}_{k \in \mathbb{N}}$ tal que

$$X_{n_{m_k}} \xrightarrow{\text{c.s.}} X. \quad (5.22)$$

Demostración. $(\Rightarrow)$ Suponga que $X_n \xrightarrow{\mathbb{P}} X$. Sea $\{X_{n_m}\}_m$ cualquier subsucesión. Para cada $k \in \mathbb{N}$ definimos el evento

$$A_k := \{|X_{n_m} - X| > \frac{1}{k} \text{ para infinitos } m\} = (|X_{n_m} - X| > \frac{1}{k}) \text{ i.o.}$$

Como $X_n \xrightarrow{\mathbb{P}} X$, se tiene que

$$\mathbb{P}\left(|X_{n_m} - X| > \frac{1}{k}\right) = \mathbb{P}\left(|X_n - X| > \frac{1}{k}\right) \rightarrow 0 \quad n \rightarrow \infty,$$

entonces $\mathbb{P}\left(|X_{n_m} - X| > \frac{1}{k}\right) \rightarrow 0$ cuando $m \rightarrow \infty$. Por el primer lema de Borel-Cantelli

$$\sum_m \mathbb{P}\left(|X_{n_m} - X| > \frac{1}{k}\right) < \infty \Rightarrow \mathbb{P}(A_k) = 0.$$

Así

$$\mathbb{P}\left(\bigcup_{k=1}^{\infty} A_k\right) \leq \sum_{k=1}^{\infty} \mathbb{P}(A_k) = 0.$$

Pero

$$\bigcup_{k=1}^{\infty} A_k = \{|X_{n_m} - X| \not\rightarrow 0\}.$$

Por lo tanto

$$\mathbb{P}(X_{n_m} \not\rightarrow X \text{ c.s.}) = 0 \Rightarrow \mathbb{P}(X_{n_m} \xrightarrow{\text{c.s.}} X) = 1.$$

Como esto vale para toda subsucesión $\{n_m\}$, basta tomar una subsucesión conveniente para concluir la implicación.

($\Leftarrow$) Supongamos que toda subsucesión tiene una subsucesión que converge c.s. a X . Si $X_n \xrightarrow{\mathbb{P}} X$, existen $\varepsilon > 0$ y $\delta > 0$ tales que

$$\mathbb{P}(|X_n - X| > \varepsilon) \geq \delta \quad \text{para infinitos } n.$$

Sea $\{n_m\}$ la subsucesión de esos índices

$$\mathbb{P}(|X_{n_m} - X| > \varepsilon) \geq \delta > 0 \quad \forall m.$$

Por hipótesis, esta subsucesión $\{X_{n_m}\}$ admite una subsucesión $\{X_{n_{m_k}}\}$ tal que

$$X_{n_{m_k}} \xrightarrow{\text{c.s.}} X.$$

Pero la convergencia casi segura implica convergencia en probabilidad, luego

$$\mathbb{P}(|X_{n_{m_k}} - X| > \varepsilon) \rightarrow 0,$$

lo cual contradice que $\mathbb{P}(|X_{n_m} - X| > \varepsilon) \geq \delta$ para todo m (y en particular para la subsucesión). Contradicción. Por tanto $X_n \xrightarrow{\mathbb{P}} X$.

□

Teorema 5.1.3. Criterio secuencial de convergencia. Sea $\{y_n\}_{n \in \mathbb{N}}$ una sucesión de elementos de un espacio topológico. Si toda subsucesión $\{y_{n_m}\}_{m \in \mathbb{N}}$ admite una subsucesión adicional $\{y_{n_{m_k}}\}_{k \in \mathbb{N}}$ que converge a y , entonces se tiene

$$y_n \rightarrow y. \quad (5.23)$$

La demostración se deja al lector.

5.1.1 Ley débil de los grandes números

Teorema 5.1.4. Ley débil de los grandes números. Suponga que $X_1, X_2, X_3, \dots$ son variables aleatorias i.i.d. con media μ , y sea $S_n := X_1 + X_2 + \dots + X_n$. Entonces

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu \quad (5.24)$$

Demostración. Como $\mathbb{E}|X_1| < \infty$, por el teorema de Feller (o directamente) sabemos que

$$n\mathbb{P}(|X_1| > n) \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

Tomando $\varepsilon > 0$ y definimos la truncación

$$\bar{X}_{n,k} := X_k \mathbf{1}_{\{|X_k| \leq n\}}, \quad k = 1, \dots, n.$$

Las $\bar{X}_{n,k}$ son i.i.d., con

$$\mathbb{E}[\bar{X}_{n,k}] = \mathbb{E}[X_1 \mathbf{1}_{\{|X_1| \leq n\}}] =: \mu_n, \quad \text{Var}(\bar{X}_{n,k}) \leq \mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}].$$

Sea $\bar{S}_n := \sum_{k=1}^n \bar{X}_{n,k}$. Por desigualdad de Chebyshev

$$\mathbb{P}\left(\left|\frac{\bar{S}_n}{n} - \mu_n\right| > \varepsilon\right) \leq \frac{\text{Var}(\bar{S}_n/n)}{\varepsilon^2} = \frac{1}{n^2 \varepsilon^2} \sum_{k=1}^n \mathbb{E}[\bar{X}_{n,k}^2] = \frac{\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}]}{n \varepsilon^2}.$$

Ahora

$$\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}] = 2 \int_0^n t \mathbb{P}(|X_1| > t) dt \leq 2 \frac{t_0}{n} + 2\varepsilon$$

porque $t\mathbb{P}(|X_1| > t) \rightarrow 0$. Por lo tanto

$$\frac{\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}]}{n \varepsilon^2} \rightarrow 0,$$

entonces

$$\frac{\bar{S}_n}{n} \xrightarrow{\mathbb{P}} \mu_n.$$

Dado que

$$\left| \frac{S_n}{n} - \frac{\bar{S}_n}{n} \right| \leq \frac{1}{n} \sum_{k=1}^n |X_k| \mathbf{1}_{\{|X_k| > n\}},$$

y

$$\mathbb{P}\left(\frac{1}{n} \sum_{k=1}^n |X_k| \mathbf{1}_{\{|X_k| > n\}} > 0\right) \leq n \mathbb{P}(|X_1| > n) \rightarrow 0.$$

Por tanto, $S_n/n - \bar{S}_n/n \xrightarrow{\mathbb{P}} 0$. Finalmente, como $\mathbb{E}|X_1| < \infty$ implica (por dominación o teorema de la convergencia monótona)

$$\mu_n = \mathbb{E}[X_1 \mathbf{1}_{\{|X_1| \leq n\}}] \rightarrow \mathbb{E}[X_1] = \mu,$$

entonces

$$\frac{\tilde{S}_n}{n} \xrightarrow{\mathbb{P}} \mu_n \quad \wedge \quad \frac{S_n - \tilde{S}_n}{n} \xrightarrow{\mathbb{P}} 0 \quad \wedge \quad \mu_n \rightarrow \mu$$

□

Todo lo demás se demuestra después.

Teorema 5.1.5. Teorema de continuidad de la convergencia en probabilidad. Sea f una función continua y sea $X_n \xrightarrow{\mathbb{P}} X$. Entonces

$$f(X_n) \xrightarrow{\mathbb{P}} f(X). \quad (5.25)$$

Si además f es acotada, entonces

$$\mathbb{E}[f(X_n)] \rightarrow \mathbb{E}[f(X)]. \quad (5.26)$$

La demostración se deja al lector.

Teorema 5.1.6. Ley Fuerte de los Grandes Números con cuarto momento finito. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $\mathbb{E}[X_i] = \mu$ y $\mathbb{E}[X_i^4] < \infty$. Si definimos $S_n := X_1 + \dots + X_n$, entonces

$$\frac{S_n}{n} \xrightarrow{\text{c.s.}} \mu. \quad (5.27)$$

La demostración se deja al lector.

5.1.2 Segundo lema de Borel-Cantelli

Lema 5.1.1. Segundo lema de Borel-Cantelli. Sean $\{A_n\}_{n \in \mathbb{N}}$ eventos independientes. Si

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty, \quad (5.28)$$

entonces

$$\mathbb{P}(A_n \text{ i.o.}) = 1. \quad (5.29)$$

La demostración se deja al lector.

Teorema 5.1.7. Divergencia del promedio para medias infinitas. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $\mathbb{E}[|X_i|] = \infty$. Entonces

$$\mathbb{P}(|X_n| \geq n \text{ i.o.}) = 1, \quad (5.30)$$

y por lo tanto, si $S_n := X_1 + \dots + X_n$, se tiene

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \frac{S_n}{n} \in (-\infty, \infty)\right) = 0. \quad (5.31)$$

La demostración se deja al lector.

Teorema 5.1.8. Convergencia casi segura de sucesiones no convergentes. Sean $\{A_n\}_{n \in \mathbb{N}}$ eventos independientes por pares tales que

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty. \quad (5.32)$$

Entonces, cuando $n \rightarrow \infty$

$$\frac{1}{\sum_{m=1}^n \mathbb{P}(A_m)} \sum_{m=1}^n \mathbf{1}_{A_m} \rightarrow 1 \quad \text{c.s.} \quad (5.33)$$

La demostración se deja al lector.

Teorema 5.1.9. Ley de los récords. Sea $R_n := \sum_{m=1}^n \mathbf{1}_{A_m}$ el número de récords en el tiempo n . Entonces, cuando $n \rightarrow \infty$

$$\frac{R_n}{\ln(n)} \rightarrow 1 \quad \text{c.s.} \quad (5.34)$$

La demostración se deja al lector.

Lema 5.1.2. Lema de Kochen-Stone. Suponga que $\sum_{k=1}^{\infty} \mathbb{P}(A_k) = \infty$. Si

$$\limsup_{n \rightarrow \infty} \frac{\left(\sum_{k=1}^n \mathbb{P}(A_k)\right)^2}{\sum_{1 \leq j, k \leq n} \mathbb{P}(A_j \cap A_k)} = \alpha > 0, \quad (5.35)$$

entonces

$$\mathbb{P}(A_n \text{ i.o.}) \geq \alpha. \quad (5.36)$$

La demostracion se deja al lector.

Lema 5.1.3. Truncación para la Ley Fuerte de los Grandes Números. Sea $Y_k := X_k \cdot \mathbf{1}(|X_k| \leq k)$ y defina $T_n := Y_1 + \dots + Y_n$. Es suficiente demostrar que

$$\frac{T_n}{n} \xrightarrow{\text{c.s.}} \mu. \quad (5.37)$$

Lema 5.1.4. Cota de varianza tipo Kolmogórov para variables truncadas. Se cumple que

$$\sum_{k=1}^{\infty} \frac{\text{Var}(Y_k)}{k^2} \leq 4 \mathbb{E}[|X_1|] < \infty. \quad (5.38)$$

La demostracion se deja al lector.

Lema 5.1.5. Desigualdad elemental para series tipo p-serie. Si $y \geq 0$, entonces

$$2y \sum_{k>y} \frac{1}{k^2} \leq 4. \quad (5.39)$$

Teorema 5.1.10. Ley Fuerte de los Grandes Números para medias unilaterales infinitas. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. tales que $\mathbb{E}[X_i^+] = \infty$ y $\mathbb{E}[X_i^-] < \infty$. Si $S_n := X_1 + \dots + X_n$, entonces

$$\frac{S_n}{n} \xrightarrow{\text{c.s.}} \infty. \quad (5.40)$$

La demostracion se deja al lector.

Teorema 5.1.11. Ley Fuerte de los Tiempos de Espera. Suponga que $\mathbb{E}[X_1] = \mu \leq \infty$. Entonces, cuando $t \rightarrow \infty$

$$\frac{N_t}{t} \xrightarrow{\text{c.s.}} \frac{1}{\mu}, \quad (5.41)$$

donde se interpreta $1/\infty := 0$.

La demostracion se deja al lector.

Teorema 5.1.12. Teorema de Glivenko-Cantelli. Sea $F_n(x)$ la función de distribución empírica asociada a una muestra i.i.d. con función de distribución $F(x)$. Entonces, cuando $n \rightarrow \infty$,

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \xrightarrow{\text{c.s.}} 0. \quad (5.42)$$

La demostracion se deja al lector.

Teorema 5.1.13. Desigualdad máxima de Kolmogorov. Sean $X_1, \dots, X_n$ variables aleatorias independientes con $\mathbb{E}[X_i] = 0$ y $\text{Var}(X_i) < \infty$ para todo i . Si definimos $S_k := X_1 + \dots + X_k$, entonces para todo $x > 0$,

$$\mathbb{P}\left(\max_{1 \leq k \leq n} |S_k| \geq x\right) \leq \frac{\text{Var}(S_n)}{x^2}. \quad (5.43)$$

La demostración se deja al lector.

Teorema 5.1.14. Convergencia casi segura de series independientes. Sean $X_1, X_2, \dots$ variables aleatorias independientes con $\mathbb{E}[X_n] = 0$ para todo n , y suponga que

$$\sum_{n=1}^{\infty} \text{Var}(X_n) < \infty. \quad (5.44)$$

Entonces, con probabilidad uno, la serie

$$\sum_{n=1}^{\infty} X_n(\omega) \quad (5.45)$$

converge.

La demostración se deja al lector.

Teorema 5.1.15. Teorema de las tres series de Kolmogorov. Sean $X_1, X_2, \dots$ variables aleatorias independientes y sea $A > 0$. Defina $Y_n := X_n \cdot \mathbf{1}(|X_n| \leq A)$. Entonces, la serie $\sum_{n=1}^{\infty} X_n$ converge casi seguramente si y solo si se cumplen las tres condiciones siguientes:

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > A) < \infty, \quad (5.46)$$

$$\sum_{n=1}^{\infty} \mathbb{E}[Y_n] \text{ converge}, \quad (5.47)$$

$$\sum_{n=1}^{\infty} \text{Var}(Y_n) < \infty. \quad (5.48)$$

La demostración se deja al lector.

Teorema 5.1.16. Lema de Kronecker Sea $\{a_n\}_{n \in \mathbb{N}}$ una sucesión creciente tal que $a_n \rightarrow \infty$, y sea $\{x_n\}_{n \in \mathbb{N}}$ una sucesión tal que

$$\sum_{n=1}^{\infty} \frac{x_n}{a_n} \text{ converge}. \quad (5.49)$$

Entonces,

$$\frac{1}{a_n} \sum_{m=1}^n x_m \rightarrow 0. \quad (5.50)$$

La demostración se deja al lector.

5.1.3 Ley fuerte de los grandes números

Teorema 5.1.17. Ley fuerte de los grandes números. Sean $X_1, X_2, X_3, \dots$ variables aleatorias independientes en pares e idénticamente distribuidas con media μ . Defina $S_n := X_1 + X_2 + \dots + X_n$. Entonces

$$\frac{S_n}{n} \xrightarrow{\text{c.s.}} \mu \quad (5.51)$$

La demostracion se deja al lector.

Teorema 5.1.18. Ley del Límite Superior. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $\mathbb{E}[X_i] = 0$ y $\mathbb{E}[X_i^2] = \sigma^2 < \infty$. Defina $S_n := X_1 + \dots + X_n$. Entonces, para todo $\varepsilon > 0$

$$\frac{S_n}{\sqrt{n} \cdot (\log n)^{1/2+\varepsilon}} \xrightarrow{\text{c.s.}} 0. \quad (5.52)$$

La demostracion se deja al lector.

Teorema 5.1.19. Ley Fuerte de los Grandes Números para momentos fraccionarios. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $\mathbb{E}[X_1] = 0$ y $\mathbb{E}[|X_1|^p] < \infty$ para algún $1 < p < 2$. Si $S_n := X_1 + \dots + X_n$, entonces

$$\frac{S_n}{n^{1/p}} \xrightarrow{\text{c.s.}} 0. \quad (5.53)$$

La demostracion se deja al lector.

Teorema 5.1.20. Teorema de Kolmogórov para sumas de variables i.i.d. con media infinita. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $\mathbb{E}[|X_1|] = \infty$, y sea $S_n := X_1 + \dots + X_n$. Sea $\{a_n\}_{n \in \mathbb{N}}$ una sucesión de números positivos tal que a_n/n es creciente. Entonces,

$$\limsup_{n \rightarrow \infty} \frac{|S_n|}{a_n} = \begin{cases} 0, & \text{si } \sum_{n=1}^{\infty} \mathbb{P}(|X_1| \geq a_n) < \infty, \\ \infty, & \text{si } \sum_{n=1}^{\infty} \mathbb{P}(|X_1| \geq a_n) = \infty. \end{cases} \quad (5.54)$$

La demostracion se deja al lector.

5.2 Teoria de Renovación

Teorema 5.2.1. Ley Fuerte de los Tiempos de Renovación. Sea $\{\xi_i\}_{i \in \mathbb{N}}$ una sucesión de variables aleatorias positivas con $\mathbb{P}(\xi_i > 0) = 1$ y esperanza $\mu := \mathbb{E}[\xi_i] \in (0, \infty]$. Defina $T_0 := 0$ y $T_k := T_{k-1} + \xi_k$ para $k \geq 1$, y sea $N_t := \inf\{k : T_k > t\}$. Entonces

$$\frac{N_t}{t} \xrightarrow{\text{c.s.}} \frac{1}{\mu}, \quad \text{donde } \frac{1}{\infty} := 0. \quad (5.55)$$

La demostracion se deja al lector.

Teorema 5.2.2. Ecuación de Wald. Sean $X_1, X_2, \dots$ variables aleatorias con $\mathbb{E}[|X_1|] < \infty$, y sea N una variable aleatoria que representa un tiempo de parada con $\mathbb{E}[N] < \infty$. Entonces

$$\mathbb{E}[S_N] = \mathbb{E}[X_1] \cdot \mathbb{E}[N], \quad (5.56)$$

donde $S_N := X_1 + \dots + X_N$.

La demostracion se deja al lector.

Teorema 5.2.3. Ley Fuerte de los Tiempos de Renovación es el nombre estándar. Sea $U(t) := \mathbb{E}[N_t]$, donde N_t es el número de renovaciones en $[0, t]$. Entonces

$$\frac{U(t)}{t} \rightarrow \frac{1}{\mu} \quad \text{cuando } t \rightarrow \infty. \quad (5.57)$$

La demostracion se deja al lector.

Teorema 5.2.4. Teorema de renovación de Blackwell. Suponga que la distribución F de las variables ξ_i es no aritmética y que $\mu := \mathbb{E}[\xi_i] < \infty$. Entonces, para todo $h > 0$

$$U([t, t+h]) \rightarrow \frac{h}{\mu} \quad \text{cuando } t \rightarrow \infty, \quad (5.58)$$

donde $U([t, t+h]) := \sum_{n=0}^{\infty} \mathbb{P}(T_n \in [t, t+h])$ es la medida de renovación en el intervalo $[t, t+h]$.

La demostración se deja al lector.

Teorema 5.2.5. Teorema de existencia y unicidad de la ecuación de renovación. Sea h una función acotada. Entonces la función

$$H(t) = \int_0^t h(t-s) dU(s) \quad (5.59)$$

es la única solución de la ecuación de renovación $H = h + H * F$ que es acotada en intervalos acotados.

La demostración se deja al lector.

Teorema 5.2.6. Teorema de renovación. Si F es no aritmética y h es directamente integrable en el sentido de Riemann, entonces

$$\lim_{t \rightarrow \infty} H(t) = \frac{1}{\mu} \int_0^{\infty} h(s) ds. \quad (5.60)$$

La demostración se deja al lector.

Lema 5.2.1. Integrabilidad directa para funciones decrecientes no negativas. Si $h(x) \geq 0$ es decreciente, $h(0) < \infty$ y $\int_0^{\infty} h(x) dx < \infty$, entonces h es directamente integrable en el sentido de Riemann.

La demostración se deja al lector.

5.3 Desviación grande

Lema 5.3.1. Subaditividad de Cramér para grandes desviaciones. Sea $\{X_i\}_{i \in \mathbb{N}}$ una sucesión de variables aleatorias i.i.d. con $\mu := \mathbb{E}[X_i]$, y defina $S_n := X_1 + \dots + X_n$. Sea $a > \mu$ y defina $\pi_n := \mathbb{P}(S_n \geq na)$, así como $\gamma_n := \log \pi_n$. Si se cumple que

$$\gamma_{m+n} \geq \gamma_m + \gamma_n, \quad (5.61)$$

entonces

$$\lim_{n \rightarrow \infty} \frac{\gamma_n}{n} = \sup_{m \in \mathbb{N}} \frac{\gamma_m}{m}. \quad (5.62)$$

La demostración se deja al lector.

Lema 5.3.2. Lema de Cramér sobre crecimiento exponencial de la función generadora de momentos. Sea $X_1, X_2, \dots$ una sucesión de variables aleatorias i.i.d. con $\mu := \mathbb{E}[X_1]$, y sea $a > \mu$. Suponga que la función generadora de momentos $\varphi(\theta) := \mathbb{E}[e^{\theta X_1}]$ es finita para $\theta > 0$, y defina $\kappa(\theta) := \log \varphi(\theta)$. Entonces, para $\theta > 0$ suficientemente pequeño,

$$a\theta - \kappa(\theta) > 0. \quad (5.63)$$

La demostracion se deja al lector.

Teorema 5.3.1. Teorema de grandes desviaciones de Cramér. Suponga que se cumplen las condiciones

$$\varphi(\theta) := \mathbb{E}(e^{\theta X_1}) < \infty \quad \text{para algún } \theta > 0, \quad (\text{H1})$$

$$\text{existe } \theta_a \in (0, \theta_+) \text{ tal que } a = \frac{\varphi'(\theta_a)}{\varphi(\theta_a)}, \quad (\text{H2})$$

donde $\varphi(\theta)$ es la función generadora de momentos de las variables aleatorias i.i.d. $X_1, X_2, \dots$ y $S_n := X_1 + \dots + X_n$. Entonces, cuando $n \rightarrow \infty$,

$$\frac{1}{n} \log \mathbb{P}(S_n \geq na) \longrightarrow -a\theta_a + \log \varphi(\theta_a). \quad (5.64)$$

La demostracion se deja al lector.

Lema 5.3.3. Lema de cambio de medida exponencial. Sea $X_1, X_2, \dots, X_n$ una sucesión de variables aleatorias i.i.d. con función generadora de momentos $\varphi(\lambda) := \mathbb{E}[e^{\lambda X_1}]$. Sea F_n la distribución de la suma $S_n := X_1 + \dots + X_n$. Entonces, la derivada de F_n respecto a la medida exponencial de parámetro $\lambda > 0$ está dada por:

$$\frac{dF_n}{dF_n^\lambda}(x) = e^{-\lambda x} \varphi(\lambda)^n, \quad (5.65)$$

donde F_n^λ denota la medida de probabilidad sesgada por $e^{\lambda S_n}$.

La demostracion se deja al lector.

Teorema 5.3.2. Teorema de límite de la razón de momentos. Suponga que $x_0 := \sup\{x : F(x) < 1\} < \infty$ y que F no es una masa puntual en x_0 . Si $\varphi(\theta) := \mathbb{E}[e^{\theta X_1}] < \infty$ para todo $\theta > 0$, entonces

$$\frac{\varphi'(\theta)}{\varphi(\theta)} \longrightarrow x_0 \quad \text{cuando } \theta \uparrow \infty. \quad (5.66)$$

La demostracion se deja al lector.

Teorema 5.3.3. Teorema de cola pesada límite lineal. Suponga que $x_0 = \infty$, que $\theta_+ < \infty$, y que $\frac{\varphi'(\theta)}{\varphi(\theta)}$ es creciente y converge a un límite finito a_0 cuando $\theta \uparrow \theta_+$. Si $a_0 \leq a < \infty$, entonces

$$\frac{1}{n} \log \mathbb{P}(S_n \geq na) \longrightarrow -a\theta_+ + \log \varphi(\theta_+), \quad (5.67)$$

es decir, $\gamma(a)$ es lineal para $a \geq a_0$.

La demostracion se deja al lector.

6

Teorema del limite central

Teorema 6.0.1. Teorema de De Moivre-Laplace. Sea $X_1, X_2, \dots$ una sucesión de variables aleatorias i.i.d. con $\mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = -1) = \frac{1}{2}$, y defina $S_n := X_1 + \dots + X_n$. Entonces, para enteros n y k

$$\mathbb{P}(S_{2n} = 2k) = \binom{2n}{n+k} \cdot 2^{-2n}, \quad (6.1)$$

ya que $S_{2n} = 2k$ si y solo si hay $n+k$ resultados de $+1$ y $n-k$ resultados de -1 entre los primeros $2n$ lanzamientos.

La demostracion se deja al lector.

Lema 6.0.1. Lema de límite exponencial. Sea $\{c_j\}_{j \in \mathbb{N}}$ una sucesión tal que $c_j \rightarrow 0$, y sea $\{a_j\}_{j \in \mathbb{N}}$ una sucesión tal que $a_j \rightarrow \infty$ y $a_j c_j \rightarrow \lambda$. Entonces

$$(1 + c_j)^{a_j} \longrightarrow e^\lambda. \quad (6.2)$$

La demostracion se deja al lector.

Teorema 6.0.2. Teorema de aproximación de De Moivre–Laplace. Sea $X_1, X_2, \dots$ una sucesión de variables aleatorias i.i.d. con $\mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = -1) = \frac{1}{2}$, y defina $S_n := X_1 + \dots + X_n$. Si $x \in \mathbb{R}$ y $k = k(n)$ es tal que

$$\frac{2k}{\sqrt{2n}} \rightarrow x \quad \text{cuando } n \rightarrow \infty, \quad (6.3)$$

entonces

$$\mathbb{P}(S_{2n} = 2k) \sim \frac{1}{\sqrt{\pi n}} e^{-x^2/2}. \quad (6.4)$$

La demostración se deja al lector.

Teorema 6.0.3. El otro Teorema de De Moivre–Laplace. Sea $X_1, X_2, \dots$ una sucesión de variables aleatorias i.i.d. con $\mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = -1) = \frac{1}{2}$, y defina $S_m := X_1 + \dots + X_m$. Si $a < b$, entonces cuando $m \rightarrow \infty$,

$$\mathbb{P}\left(a \leq \frac{S_m}{\sqrt{m}} \leq b\right) \rightarrow \int_a^b \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx. \quad (6.5)$$

La demostración se deja al lector.

6.1 Convergencia débil

Teorema 6.1.1. Teorema de convergencia de medidas por convergencia puntual de densidades. Suponga que $\{f_n\}_{n \in \mathbb{N}}$ son densidades de probabilidad tales que $f_n \rightarrow f_\infty$ puntualmente cuando $n \rightarrow \infty$. Entonces, para todo conjunto de Borel B

$$\left| \int_B f_n(x) dx - \int_B f_\infty(x) dx \right| \leq \int_B |f_n(x) - f_\infty(x)| dx, \quad (6.6)$$

y si además

$$\int_{\mathbb{R}} (f_\infty(x) - f_n(x))^+ dx \rightarrow 0, \quad (6.7)$$

entonces $\int_B f_n(x) dx \rightarrow \int_B f_\infty(x) dx$.

La demostración se deja al lector.

Lema 6.1.1. Lemma sobre la densidad de V_{n+1} La variable aleatoria V_{n+1} tiene función de densidad dada por

$$f_{V_{n+1}}(x) = (2n+1) \binom{2n}{n} x^n (1-x)^n. \quad (6.8)$$

La demostración se deja al lector.

Teorema 6.1.2. Teorema de Skorokhod. Si $F_n \Rightarrow F_\infty$, entonces existen variables aleatorias Y_n , $1 \leq n \leq \infty$, con distribución F_n , tales que $Y_n \rightarrow Y_\infty$ casi seguramente.

La demostración se deja al lector.

Teorema 6.1.3. Teorema de la convergencia débil. Se tiene $X_n \Rightarrow X_\infty$ si y solo si para toda función continua acotada g

$$\mathbb{E}[g(X_n)] \rightarrow \mathbb{E}[g(X_\infty)]. \quad (6.9)$$

La demostración se deja al lector.

Teorema 6.1.4. Teorema del mapeo continuo. Sea g una función medible y sea $D_g := \{x : g \text{ es discontinua en } x\}$. Si $X_n \Rightarrow X_\infty$ y $\mathbb{P}(X_\infty \in D_g) = 0$, entonces $g(X_n) \Rightarrow g(X_\infty)$. Si además g es acotada, entonces

$$\mathbb{E}[g(X_n)] \rightarrow \mathbb{E}[g(X_\infty)]. \quad (6.10)$$

La demostración se deja al lector.

Teorema 6.1.5. Teorema de Portmanteau. Las siguientes afirmaciones son equivalentes

$$X_n \Rightarrow X_\infty, \quad (6.11)$$

$$\text{Para todo conjunto abierto } G, \quad \liminf_{n \rightarrow \infty} \mathbb{P}(X_n \in G) \geq \mathbb{P}(X_\infty \in G), \quad (6.12)$$

$$\text{Para todo conjunto cerrado } K, \quad \limsup_{n \rightarrow \infty} \mathbb{P}(X_n \in K) \leq \mathbb{P}(X_\infty \in K), \quad (6.13)$$

Para todo conjunto de Borel A tal que $\mathbb{P}(X_\infty \in \partial A) = 0$, se tiene

$$\mathbb{P}(X_n \in A) \rightarrow \mathbb{P}(X_\infty \in A). \quad (6.14)$$

La demostración se deja al lector.

Teorema 6.1.6. Teorema de selección de Helly. Para toda sucesión $\{F_n\}$ de funciones de distribución, existe una subsucesión $\{F_{n(k)}\}$ y una función F no decreciente y continua por la derecha tal que

$$\lim_{k \rightarrow \infty} F_{n(k)}(y) = F(y) \quad (6.15)$$

en todos los puntos de continuidad de F .

La demostración se deja al lector.

Teorema 6.1.7. Teorema de Tightness para sucesiones de distribuciones. Toda subsucesión límite es función de distribución de una medida de probabilidad si y solo si la sucesión $\{F_n\}$ es ajustada, es decir, para todo $\varepsilon > 0$ existe $M_\varepsilon > 0$ tal que

$$\limsup_{n \rightarrow \infty} [1 - F_n(M_\varepsilon) + F_n(-M_\varepsilon)] \leq \varepsilon. \quad (6.16)$$

La demostración se deja al lector.

Teorema 6.1.8. Criterio de Prokhorov para tightness. Si existe una función $\varphi \geq 0$ tal que $\varphi(x) \rightarrow \infty$ cuando $|x| \rightarrow \infty$, y

$$\sup_n \int \varphi(x) dF_n(x) < \infty, \quad (6.17)$$

entonces la sucesión $\{F_n\}$ es ajustada.

La demostración se deja al lector.

Teorema 6.1.9. Teorema de subsecuencias límites para convergencia en distribución. Si toda subsecución de $\{X_n\}$ tiene una subsecución adicional que converge en distribución a X , entonces $X_n \Rightarrow X$.

La demostración se deja al lector.

Teorema 6.1.10. Teorema de continuidad. Sean μ_n , $1 \leq n \leq \infty$, medidas de probabilidad con funciones características φ_n . Entonces

$$\text{Si } \mu_n \Rightarrow \mu_\infty, \text{ entonces } \varphi_n(t) \rightarrow \varphi_\infty(t) \text{ para todo } t \in \mathbb{R}. \quad (6.18)$$

Si $\{\varphi_n(t)\}_{n \in \mathbb{N}}$ converge puntualmente a una función $\varphi(t)$ que es continua en $t = 0$, entonces $\{\mu_n\}$ es ajustada y

$$\mu_n \Rightarrow \mu, \quad (6.19)$$

donde μ es la única medida de probabilidad con función característica φ .

La demostración se deja al lector.

Lema 6.1.2. Aproximación de la exponencial compleja mediante su serie de Taylor. Para todo $n \in \mathbb{N}$, se cumple

$$\left| e^{ix} - \sum_{m=0}^n \frac{(ix)^m}{m!} \right| \leq \min \left\{ \frac{|x|^{n+1}}{(n+1)!}, \frac{2|x|^n}{n!} \right\}. \quad (6.20)$$

La demostración se deja al lector.

Teorema 6.1.11. Diferenciabilidad de la función característica Si $\int |x|^n \mu(dx) < \infty$, entonces la función característica $\varphi(t)$ de μ tiene derivada continua de orden n dada por

$$\varphi^{(n)}(t) = \int (ix)^n e^{itx} \mu(dx). \quad (6.21)$$

La demostración se deja al lector.

Teorema 6.1.12. Desarrollo de Taylor de la función característica Si $\mathbb{E}(|X|^2) < \infty$, entonces la función característica $\varphi(t)$ de X satisface

$$\varphi(t) = 1 + it \mathbb{E}(X) - \frac{t^2}{2} \mathbb{E}(X^2) + o(t^2). \quad (6.22)$$

La demostración se deja al lector.

Teorema 6.1.13. Condición de concavidad limitada para la función característica. Si

$$\limsup_{h \downarrow 0} \frac{\varphi(h) - 2\varphi(0) + \varphi(-h)}{h^2} > -\infty, \quad (6.23)$$

entonces $\mathbb{E}(|X|^2) < \infty$.

La demostración se deja al lector.

Teorema 6.1.14. Criterio de Pólya. Sea $\varphi(t)$ una función real, no negativa, tal que $\varphi(0) = 1$, $\varphi(t) = \varphi(-t)$, y φ es decreciente y convexa en $(0, \infty)$, con

$$\lim_{t \downarrow 0} \varphi(t) = 1, \quad \lim_{t \uparrow \infty} \varphi(t) = 0. \quad (6.24)$$

Entonces existe una medida de probabilidad ν sobre $(0, \infty)$ tal que

$$\varphi(t) = \int_0^\infty \left(1 - \frac{t}{s}\right)^+ \nu(ds), \quad (6.25)$$

y por lo tanto φ es una función característica.

La demostración se deja al lector.

Teorema 6.1.15. Unicidad en el problema de momentos. Si

$$\limsup_{k \rightarrow \infty} \frac{\mu_{2k}^{1/2k}}{2k} = r < \infty, \quad (6.26)$$

entonces existe a lo sumo una función de distribución F tal que $\mu_k = \int x^k dF(x)$ para todo $k \in \mathbb{N}$.

La demostración se deja al lector.

Teorema 6.1.16. Teorema de continuidad de momentos. Suponga que $\int x^k dF_n(x) \rightarrow \mu_k$ para cada $k \in \mathbb{N}$, y que

$$\limsup_{k \rightarrow \infty} \frac{\mu_{2k}^{1/2k}}{2k} < \infty. \quad (6.27)$$

Entonces F_n converge débilmente a la única distribución con momentos $\{\mu_k\}$.

La demostración se deja al lector.

Teorema 6.1.17. Teorema de Lindeberg-Lévy. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $\mathbb{E}(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2 \in (0, \infty)$. Si $S_n := X_1 + \dots + X_n$, entonces

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \Rightarrow \chi, \quad (6.28)$$

donde χ tiene distribución normal estándar.

La demostración se deja al lector.

Teorema 6.1.18. Teorema de límite exponencial. Si $c_n \rightarrow c \in \mathbb{C}$, entonces

$$\left(1 + \frac{c_n}{n}\right)^n \rightarrow e^c. \quad (6.29)$$

La demostración se deja al lector.

Lema 6.1.3. Diferencias de productos Sean $z_1, \dots, z_n$ y $w_1, \dots, w_n$ números complejos de módulo menor o igual que θ . Entonces

$$\left| \prod_{m=1}^n z_m - \prod_{m=1}^n w_m \right| \leq \theta^{n-1} \sum_{m=1}^n |z_m - w_m|. \quad (6.30)$$

La demostración se deja al lector.

Lema 6.1.4. Aproximación exponencial. Si b es un número complejo con $|b| \leq 1$, entonces

$$|e^b - (1 + b)| \leq |b|^2. \quad (6.31)$$

La demostración se deja al lector.

Teorema 6.1.19. Teorema de Lindeberg-Feller. Para cada n , sean $X_{n,1}, \dots, X_{n,n}$ variables aleatorias independientes con $\mathbb{E}(X_{n,m}) = 0$. Suponga que:

$$\sum_{m=1}^n \mathbb{E}(X_{n,m}^2) \rightarrow \sigma^2 > 0, \quad (6.32)$$

y que para todo $\varepsilon > 0$,

$$\sum_{m=1}^n \mathbb{E}(X_{n,m}^2; |X_{n,m}| > \varepsilon) \rightarrow 0. \quad (6.33)$$

Entonces, si $S_n := X_{n,1} + \dots + X_{n,n}$, se tiene

$$\frac{S_n}{\sigma} \Rightarrow \chi. \quad (6.34)$$

La demostración se deja al lector.

Teorema 6.1.20. Teorema de Gnedenko-Kolmogorov. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. y $S_n := X_1 + \dots + X_n$. Existen constantes a_n y $b_n > 0$ tales que

$$\frac{S_n - a_n}{b_n} \Rightarrow \chi \quad (6.35)$$

si y solo si

$$\frac{y^2 \mathbb{P}(|X_1| > y)}{\mathbb{E}(X_1^2; |X_1| \leq y)} \rightarrow 0. \quad (6.36)$$

La demostración se deja al lector.

Lema 6.1.5. Lemma de selección diagonal Sea $h_n(\varepsilon)$ una función tal que $h_n(\varepsilon) \rightarrow 0$ para cada $\varepsilon > 0$. Entonces existe una sucesión $\varepsilon_n \rightarrow 0$ tal que $h_n(\varepsilon_n) \rightarrow 0$.

La demostración se deja al lector.

Teorema 6.1.21. Teorema central de Erdős-Kac. Cuando $n \rightarrow \infty$,

$$\mathbb{P} \left(\frac{g(m) - \log \log n}{\sqrt{\log \log n}} \leq x \right) \rightarrow \mathbb{P}(\chi \leq x), \quad (6.37)$$

donde $g(m)$ denota el número de factores primos distintos de m .

La demostración se deja al lector.

Teorema 6.1.22. Teorema de Berry-Esseen. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $\mathbb{E}(X_i) = 0$, $\mathbb{E}(X_i^2) = \sigma^2$, y $\mathbb{E}(|X_i|^3) = \rho < \infty$. Si $F_n(x)$ es la función de distribución de $(X_1 + \dots + X_n)/(\sigma\sqrt{n})$ y $N(x)$ es la distribución normal estándar, entonces

$$|F_n(x) - N(x)| \leq \frac{3\rho}{\sigma^3\sqrt{n}}. \quad (6.38)$$

La demostración se deja al lector.

Lema 6.1.6. Lema de Esseen. Sean F y G funciones de distribución con $G'(x) \leq \lambda < \infty$. Sea $\Delta(x) := F(x) - G(x)$, $\eta := \sup |\Delta(x)|$, $\Delta_L := \Delta * H_L$, y $\eta_L := \sup |\Delta_L(x)|$. Entonces

$$\eta_L \geq \frac{\eta}{2} - \frac{12\lambda}{\pi L}, \quad \text{o bien} \quad \eta \leq 2\eta_L + \frac{24\lambda}{\pi L}. \quad (6.39)$$

La demostración se deja al lector.

Lema 6.1.7. Lema de Fourier de Lévy. Sean K_1 y K_2 funciones de distribución con media cero, cuyas funciones características κ_i son integrables. Entonces

$$K_1(x) - K_2(x) = \frac{1}{2\pi} \int \frac{e^{-itx}(\kappa_1(t) - \kappa_2(t))}{it} dt. \quad (6.40)$$

La demostración se deja al lector.

6.2 Teorema de límite local

Teorema 6.2.1. Teorema central del límite. Sean $X_1, X_2, X_3, \dots$ variables aleatorias i.i.d. con media μ y varianza σ^2 . Defina $S_n := X_1 + X_2 + \dots + X_n$. Entonces

$$\frac{S_n - n\mu}{\sqrt{n}\sigma} \xrightarrow{d} Z \quad (6.41)$$

donde Z es una variable aleatoria normal estándar.

La demostración se deja al lector.

Teorema 6.2.2. Teorema de Lévy sobre la estructura de la función característica. Sea $\varphi(t) := \mathbb{E}(e^{itX})$ la función característica de una variable aleatoria X . Entonces, solo hay tres posibilidades

$$|\varphi(t)| < 1 \quad \text{para todo } t \neq 0,$$

Existe $\lambda > 0$ tal que $|\varphi(\lambda)| = 1$ y $|\varphi(t)| < 1$ para todo $0 < t < \lambda$; en este caso X es reticular con paso máximo $2\pi/\lambda$.

$$|\varphi(t)| = 1 \quad \text{para todo } t \in \mathbb{R}. \quad \text{En este caso, } X = b \text{ casi seguramente para algún } b \in \mathbb{R}.$$

La demostración se deja al lector.

Teorema 6.2.3. Teorema Local del Límite Central. Bajo las hipótesis anteriores, cuando $n \rightarrow \infty$,

$$\sup_{x \in L_n} \sqrt{n} |p_n(x) - \mathbf{n}(x)| \rightarrow 0, \quad (6.42)$$

donde L_n es el soporte de la distribución de S_n , $p_n(x)$ es la función de masa de probabilidad de S_n , y $\mathbf{n}(x)$ es la densidad de la normal estándar.

Teorema 6.2.4. Teorema Puntual del Límite Central. Bajo las hipótesis anteriores, si $x_n/\sqrt{n} \rightarrow x$, entonces

$$\sqrt{n} p_n(x_n) \rightarrow \mathbf{n}(x), \quad (6.43)$$

donde $\mathbf{n}(x)$ es la densidad de la normal estándar evaluada en x .

La demostración se deja al lector.

6.3 Convergencia de Poisson

Teorema 6.3.1. Teorema de Poisson límite. Para cada n , sean $X_{n,1}, \dots, X_{n,n}$ variables aleatorias independientes con $\mathbb{P}(X_{n,m} = 1) = p_{n,m}$ y $\mathbb{P}(X_{n,m} = 0) = 1 - p_{n,m}$. Suponga que

$$\sum_{m=1}^n p_{n,m} \rightarrow \lambda \in (0, \infty), \quad \max_{1 \leq m \leq n} p_{n,m} \rightarrow 0. \quad (6.44)$$

Si $S_n := X_{n,1} + \dots + X_{n,n}$, entonces

$$S_n \Rightarrow Z, \quad (6.45)$$

donde Z tiene distribución de Poisson con media λ .

La demostración se deja al lector.

Lema 6.3.1. Lema de convergencia en variación. La distancia $d(\mu, \nu) := \|\mu - \nu\|$ define una métrica sobre las medidas de probabilidad en $\mathbb{Z}$. Se tiene $\|\mu_n - \mu\| \rightarrow 0$ si y solo si $\mu_n(x) \rightarrow \mu(x)$ para todo $x \in \mathbb{Z}$, lo cual es equivalente a $\mu_n \Rightarrow \mu$.

La demostración se deja al lector.

Lema 6.3.2. Lema de subaditividad de la norma de variación total para medidas producto. Si $\mu_1 \times \mu_2$ denota la medida producto sobre $\mathbb{Z} \times \mathbb{Z}$ definida por $(\mu_1 \times \mu_2)(x, y) = \mu_1(x)\mu_2(y)$, entonces

$$\|\mu_1 \times \mu_2 - \nu_1 \times \nu_2\| \leq \|\mu_1 - \nu_1\| + \|\mu_2 - \nu_2\|. \quad (6.46)$$

La demostración se deja al lector.

Lema 6.3.3. Lema de contracción de la convolución en variación total. Si $\mu_1 * \mu_2$ denota la convolución de μ_1 y μ_2 , definida por

$$(\mu_1 * \mu_2)(x) := \sum_{y \in \mathbb{Z}} \mu_1(x - y)\mu_2(y), \quad (6.47)$$

entonces

$$\|\mu_1 * \mu_2 - \nu_1 * \nu_2\| \leq \|\mu_1 \times \mu_2 - \nu_1 \times \nu_2\|. \quad (6.48)$$

La demostración se deja al lector.

Lema 6.3.4. Lema de Poisson-Binomial para una sola variable. Sea μ la medida con $\mu(1) = p$ y $\mu(0) = 1 - p$, y sea ν la distribución de Poisson con media p . Entonces

$$\|\mu - \nu\| \leq p^2. \quad (6.49)$$

La demostración se deja al lector.

Teorema 6.3.2. Teorema de Poisson en el problema de las cajas y bolas. Si $ne^{-r/n} \rightarrow \lambda \in [0, \infty)$, entonces el número de cajas vacías converge en distribución a una variable de Poisson con media λ .

La demostración se deja al lector.

Teorema 6.3.3. Teorema de Poisson extendido. Sean $X_{n,1}, \dots, X_{n,n}$ variables aleatorias independientes con valores enteros no negativos, tales que:

$$\mathbb{P}(X_{n,m} = 1) = p_{n,m}, \quad \mathbb{P}(X_{n,m} \geq 2) = \varepsilon_{n,m}, \quad (6.50)$$

y suponga que

$$\sum_{m=1}^n p_{n,m} \rightarrow \lambda \in (0, \infty), \quad \max_{1 \leq m \leq n} p_{n,m} \rightarrow 0, \quad \sum_{m=1}^n \varepsilon_{n,m} \rightarrow 0. \quad (6.51)$$

Entonces, si $S_n := X_{n,1} + \dots + X_{n,n}$, se tiene

$$S_n \Rightarrow Z, \quad (6.52)$$

donde Z tiene distribución de Poisson con media λ .

La demostración se deja al lector.

Teorema 6.3.4. Teorema de Poisson para procesos de cuenta. Si la primera y última condición se cumplen, entonces $N(0, t)$ tiene distribución de Poisson con media λt .

La demostración se deja al lector.

6.4 Ley estable

Lema 6.4.1. Lema de la diagonal de Cantor. Si $h_n(\varepsilon) \rightarrow g(\varepsilon)$ para cada $\varepsilon > 0$ y $g(\varepsilon) \rightarrow g(0)$ cuando $\varepsilon \rightarrow 0$, entonces existe una sucesión $\varepsilon_n \rightarrow 0$ tal que

$$h_n(\varepsilon_n) \rightarrow g(0). \quad (6.53)$$

La demostración se deja al lector.

Teorema 6.4.1. Teorema de Gnedenko-Kolmogorov sobre la convergencia a distribuciones estables. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con una distribución que satisface:

$$\lim_{x \rightarrow \infty} \frac{\mathbb{P}(X_1 > x)}{\mathbb{P}(|X_1| > x)} = \theta \in [0, 1], \quad (6.54)$$

y

$$\mathbb{P}(|X_1| > x) = x^{-\alpha} L(x), \quad (6.55)$$

donde $\alpha < 2$ y $L(x)$ es lentamente variable. Sea $S_n := X_1 + \dots + X_n$, defina

$$a_n := \inf\{x : \mathbb{P}(|X_1| > x) \leq n^{-1}\}, \quad b_n := n \cdot \mathbb{E}(X_1 \cdot \mathbf{1}(|X_1| \leq a_n)). \quad (6.56)$$

Entonces,

$$\frac{S_n - b_n}{a_n} \Rightarrow Y, \quad (6.57)$$

donde Y tiene una distribución no degenerada.

La demostración se deja al lector.

Lema 6.4.2. Lema de Potter. Para todo $\delta > 0$, existe una constante $C > 0$ tal que para todo $t \geq t_0$ y $y \leq 1$,

$$\frac{\mathbb{P}(|X_1| > yt)}{\mathbb{P}(|X_1| > t)} \leq C y^{-\alpha-\delta}. \quad (6.58)$$

La demostracion se deja al lector.

Teorema 6.4.2. Teorema de Gnedenko Una variable aleatoria Y es el límite de

$$\frac{X_1 + \cdots + X_k - b_k}{a_k} \quad (6.59)$$

para alguna sucesión i.i.d. $\{X_i\}$ si y solo si Y tiene una ley estable.

La demostracion se deja al lector.

Teorema 6.4.3. Teorema de convergencia de tipos. Suponga que $W_n \Rightarrow W$ y que existen constantes $\alpha_n > 0$, $\beta_n \in \mathbb{R}$ tales que

$$W'_n := \alpha_n W_n + \beta_n \Rightarrow W', \quad (6.60)$$

donde W y W' son distribuciones no degeneradas. Entonces existen constantes α y β tales que

$$\alpha_n \rightarrow \alpha, \quad \beta_n \rightarrow \beta. \quad (6.61)$$

La demostracion se deja al lector.

6.5 Distribuciones infinitamente divisibles

Teorema 6.5.1. Teorema de Lévy sobre la divisibilidad infinita. Una variable aleatoria Z es el límite de sumas del tipo

$$Z_n := X_1^{(n)} + \cdots + X_n^{(n)}, \quad (6.62)$$

donde los $X_i^{(n)}$ son independientes y apropiadamente normalizados, si y solo si Z tiene una distribución infinitamente divisible.

La demostracion se deja al lector.

Teorema 6.5.2. Teorema de Lévy-Khinchin. Una variable aleatoria Z tiene una distribución infinitamente divisible si y solo si su función característica $\varphi(t) := \mathbb{E}(e^{itZ})$ satisface

$$\log \varphi(t) = ict - \frac{\sigma^2 t^2}{2} + \int_{\mathbb{R}} \left(e^{itx} - 1 - itx \cdot \mathbf{1}_{\{|x| \leq 1\}} \right) \mu(dx), \quad (6.63)$$

donde $c \in \mathbb{R}$, $\sigma^2 \geq 0$, y μ es una medida de Lévy tal que $\mu(\{0\}) = 0$ y

$$\int_{\mathbb{R}} \frac{x^2}{1+x^2} \mu(dx) < \infty. \quad (6.64)$$

La demostracion se deja al lector.

Teorema 6.5.3. Teorema de Kolmogórov. Una variable aleatoria Z tiene una distribución infinitamente divisible con media cero y varianza finita si y solo si su función característica $\varphi(t)$ satisface

$$\log \varphi(t) = \int_{\mathbb{R}} (e^{itx} - 1 - itx) x^{-2} \nu(dx), \quad (6.65)$$

donde ν es la medida canónica asociada a Z , y se cumple

$$\text{Var}(Z) = \nu(\mathbb{R}). \quad (6.66)$$

La demostracion se deja al lector.

6.6 Teorema limite en $\mathbb{R}$

Teorema 6.6.1. Teorema limite en $\mathbb{R}$. Las siguientes afirmaciones son equivalentes

$$\mathbb{E}(f(X_n)) \rightarrow \mathbb{E}(f(X_\infty)) \text{ para toda función continua y acotada } f.$$

$$\mathbb{E}(f(X_n)) \rightarrow \mathbb{E}(f(X_\infty)) \text{ para toda función acotada y Lipschitz-continua } f.$$

$$\text{Para todo conjunto cerrado } K, \limsup_{n \rightarrow \infty} \mathbb{P}(X_n \in K) \leq \mathbb{P}(X_\infty \in K).$$

$$\text{Para todo conjunto abierto } G, \liminf_{n \rightarrow \infty} \mathbb{P}(X_n \in G) \geq \mathbb{P}(X_\infty \in G).$$

$$\text{Para todo conjunto de Borel } A \text{ tal que } \mathbb{P}(X_\infty \in \partial A) = 0, \mathbb{P}(X_n \in A) \rightarrow \mathbb{P}(X_\infty \in A).$$

$$\text{Para toda función acotada } f \text{ cuyo conjunto de discontinuidades } D_f \text{ verifica } \mathbb{P}(X_\infty \in D_f) = 0, \\ \mathbb{E}(f(X_n)) \rightarrow \mathbb{E}(f(X_\infty)).$$

La demostracion se deja al lector.

Teorema 6.6.2. Teorema de Prokhorov en dimensión d . En $\mathbb{R}^d$, la convergencia débil definida en términos de convergencia de funciones de distribución $F_n \Rightarrow F$ es equivalente a la noción de convergencia débil definida para espacios métricos generales.

La demostracion se deja al lector.

Teorema 6.6.3. Teorema de Prokhorov. Si la sucesión de medidas μ_n es ajustada, entonces existe una subsucesión que converge débilmente.

La demostracion se deja al lector.

Teorema 6.6.4. Fórmula de inversión. Sea $A = [a_1, b_1] \times \cdots \times [a_d, b_d]$ tal que $\mu(\partial A) = 0$. Entonces,

$$\mu(A) = \lim_{T \rightarrow \infty} \frac{1}{(2\pi)^d} \int_{[-T, T]^d} \prod_{j=1}^d \psi_j(s_j) \varphi(s) ds, \quad (6.67)$$

donde $\psi_j(s) := \frac{e^{-isa_j} - e^{-isb_j}}{is}$ y $\varphi(s)$ es la función característica de μ .

La demostracion se deja al lector.

Teorema 6.6.5. Teorema de continuidad de las funciones características. Sean X_n , $1 \leq n \leq \infty$, vectores aleatorios con funciones características φ_n . Una condición necesaria y suficiente para que $X_n \Rightarrow X_\infty$ es que

$$\varphi_n(t) \rightarrow \varphi_\infty(t) \text{ para todo } t \in \mathbb{R}^d. \quad (6.68)$$

La demostracion se deja al lector.

Teorema 6.6.6. Dispositivo de Cramér-Wold. Una condición suficiente para que $X_n \Rightarrow X_\infty$ en $\mathbb{R}^d$ es que

$$\theta \cdot X_n \Rightarrow \theta \cdot X_\infty \text{ para todo } \theta \in \mathbb{R}^d. \quad (6.69)$$

La demostracion se deja al lector.

Teorema 6.6.7. Teorema central del límite en $\mathbb{R}^d$. Sean $X_1, X_2, \dots$ vectores aleatorios i.i.d. con $\mathbb{E}(X_n) = \mu$ y covarianzas finitas

$$\Gamma_{ij} := \mathbb{E}[(X_{n,i} - \mu_i)(X_{n,j} - \mu_j)]. \quad (6.70)$$

Si $S_n := X_1 + \dots + X_n$, entonces

$$\frac{S_n - n\mu}{\sqrt{n}} \Rightarrow \chi, \quad (6.71)$$

donde χ tiene distribución normal multivariada con media cero y matriz de covarianza Γ , es decir,

$$\mathbb{E}[e^{i\theta \cdot \chi}] = \exp\left(-\frac{1}{2} \sum_{i,j} \theta_i \theta_j \Gamma_{ij}\right). \quad (6.72)$$

La demostracion se deja al lector.

Esta sin terminar.

Parte II

Cadenas de Markov

7.1 Cadenas de Markov

Definición 7.1.1. Proceso estocástico. Un proceso estocástico es una familia de variables aleatorias $\{X_t : t \in T\}$ con $T \neq \emptyset$. Las distribuciones de probabilidad finito-dimensionales del proceso se definen como

$$\mathbb{P}(X_{t_1} = s_1, X_{t_2} = s_2, \dots, X_{t_n} = s_n) \quad (7.1)$$

para $n \in \mathbb{N}_{>0}$, $s_i \in S$ y $t_i < t_{i+1}$.

Cuando $T \subset \mathbb{N}$ se llama de proceso de tiempo discreto y cuando $T \subset \mathbb{R}^+$ se llama de proceso de tiempo continuo.

Definición 7.1.2. Trayectoria. Se llama trayectoria del proceso estocástico al mapeo $t \mapsto X_t(\omega)$.

Definición 7.1.3. Proceso estocástico en $\mathbb{R}^d$. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Un proceso estocástico en $\mathbb{R}^d$ es una familia de variables aleatorias $\{X_t : t \in T\}$ con $X_t = (X_t^1, X_t^2, \dots, X_t^d)$, tales que cada coordenada X_t^i es medible de $\mathcal{F}$ en los borelianos $\mathcal{B}(\mathbb{R})$, para $i = 1, \dots, d$.

En este caso, cada proceso coordenada $\{X_t^i : t \in T\}$ es un proceso estocástico en $\mathbb{R}$. Cuando el conjunto de índices T se toma como un subconjunto de $\mathbb{R}^d$, con $d \geq 1$, la familia de variables aleatorias $\{X_t : t \in T\}$ recibe el nombre de campo aleatorio (random field).

Definición 7.1.4. Caminata aleatoria simple. Un proceso estocástico $\{S_n : n \in \mathbb{N}\}$ con

$$S_n = X_1 + \dots + X_n \quad (7.2)$$

donde X_i son pasos independientes, es llamado caminata aleatoria simple.

Definición 7.1.5. Caminata aleatoria generalizada. Sean $X_1, X_2, \dots$ variables aleatorias i.i.d., tales que $\mathbb{P}(X_i = k) = a_k \in [0, 1], \forall k \in \mathbb{Z}$ con $\sum_{k \in \mathbb{Z}} a_k = 1$. Sea S_0 una variable aleatoria con valores en $\mathbb{Z}$, independiente de X_i . Se define

$$S_n = S_0 + X_1 + \dots + X_n, \quad \forall n \in \mathbb{N}, \quad (7.3)$$

el proceso $\{S_n : n \in \mathbb{N}\}$ se denomina caminata aleatoria generalizada con valores en $\mathbb{Z}$.

Proposición 7.1.1. Propiedad de Markov. Sea $\{S_n : n \in \mathbb{N}\}$ una caminata aleatoria generalizada en $\mathbb{Z}$ talque $S_i = k_i, \forall k_i \in \mathbb{Z}$. Entonces

$$\mathbb{P}(S_n = k_n \mid S_0 = k_0, S_1 = k_1, \dots, S_{n-1} = k_{n-1}) = \mathbb{P}(X_n = k_n - k_{n-1}). \quad (7.4)$$

$$\mathbb{P}(S_n = k_n \mid S_{n-1} = k_{n-1}) = \mathbb{P}(X_n = k_n - k_{n-1}). \quad (7.5)$$

En particular

$$\mathbb{P}(S_n = k_n \mid S_0 = k_0, S_1 = k_1, \dots, S_{n-1} = k_{n-1}) = \mathbb{P}(S_n = k_n \mid S_{n-1} = k_{n-1}), \quad (7.6)$$

lo cual muestra que $(S_n)_n$ es un proceso de Markov (el futuro depende únicamente del estado presente y no de la historia pasada) en $\mathbb{Z}$.

La demostración se deja al lector.

Definición 7.1.6. Cadena de Markov. Un proceso estocástico se llama una cadena de Markov si satisface la propiedad de Markov

$$\mathbb{P}(X_n = x_n \mid X_0 = x_0, X_1 = x_1, \dots, X_{n-1} = x_{n-1}) = \mathbb{P}(X_n = x_n \mid X_{n-1} = x_{n-1}) \quad (7.7)$$

Definición 7.1.7. Probabilidades de transición. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov con espacio de estados S . Entonces

$$\mathbb{P}(X_{n+1} = y \mid X_n = x) \quad (7.8)$$

es llamado las probabilidades de transición de un paso de la cadena. Si suponemos que son estacionarias, osea

$$\mathbb{P}(X_{n+1} = y \mid X_n = x) = \mathbb{P}(X_1 = y \mid X_0 = x), \quad \forall x, y \in S, n \in \mathbb{N}, \quad (7.9)$$

entonces la función de transición de un paso se define como

$$p(x, y) := \mathbb{P}(X_{n+1} = y \mid X_n = x), \quad \forall x, y \in S. \quad (7.10)$$

Definición 7.1.8. Distribución inicial de la cadena. La distribución de probabilidad de una cadena de Markov que también es llamada distribución inicial de la cadena, viene dada por

$$\Pi_0(x) := \mathbb{P}(X_0 = x). \quad (7.11)$$

Lema 7.1.1. Factorización con Markov. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov con espacio de estados S . Sumado a ello $\forall n, m \in \mathbb{N}, x_i \in S$ se tiene que

$$\mathbb{P}(X_0 = x_0, \dots, X_n = x_n) = \Pi_0(x_0)p(x_0, x_1) \cdots p(x_{n-1}, x_n), \quad (7.12)$$

$$\mathbb{P}(X_{n+m} = x_{n+m} \mid X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_{n+m} = x_{n+m} \mid X_n = x_n). \quad (7.13)$$

La demostración es trivial. La última propiedad anterior se le llama propiedad fuerte de Markov.

Definición 7.1.9. Función de transición de m -pasos. Para $m \geq 1$, la función de transición de m -pasos se define como

$$p^m(x, y) := \mathbb{P}(X_m = y \mid X_0 = x), \quad \forall x, y \in S. \quad (7.14)$$

Además, se define

$$p^0(x, y) := \begin{cases} 1 & \text{si } x = y, \\ 0 & \text{en otro caso.} \end{cases} \quad (7.15)$$

Lema 7.1.2. Expansionan de una cadena de Markov. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov. Para todo $m \geq 1$ y $x, y \in S$, se cumple que

$$p^m(x, y) = \sum_{y_1 \in S} \sum_{y_2 \in S} \cdots \sum_{y_{m-1} \in S} p(x, y_1) p(y_1, y_2) \cdots p(y_{m-2}, y_{m-1}) p(y_{m-1}, y). \quad (7.16)$$

La demostración se deja al lector. Para este caso basta con recordar la probabilidad de eventos disjuntos y la factorización del lema anterior. De ahora en adelante, se asumirá que toda cadena de Markov es homogénea o estacionaria.

Corolario 7.1.1. Equivalencia de transición de $n+m$ pasos. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov. Entonces $\forall n \in \mathbb{N}, m \geq 1$ y $x, y \in S$, se cumple que

$$p^m(x, y) = \mathbb{P}(X_{n+m} = y \mid X_n = x). \quad (7.17)$$

La demostración es trivial.

Teorema 7.1.1. Chapman-Kolmogorov. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov. Entonces $\forall n, m \geq 0$ y $x, y \in S$, se cumple que

$$p^{m+n}(x, y) = \sum_{z \in S} p^n(x, z) p^m(z, y). \quad (7.18)$$

A lo anterior se le conoce como las ecuaciones de Chapman-Kolmogorov. Para su demostración aplique el corolario anterior y la propiedad de Markov.

Definición 7.1.10. Función de transición La función de transición de m -pasos se define como una matriz (posiblemente de dimensión infinita)

$$P^m := (p^m(x_i, x_j))_{i,j \geq 0} = \begin{pmatrix} p^m(x_0, x_0) & p^m(x_0, x_1) & p^m(x_0, x_2) & \cdots \\ p^m(x_1, x_0) & p^m(x_1, x_1) & p^m(x_1, x_2) & \cdots \\ p^m(x_2, x_0) & p^m(x_2, x_1) & p^m(x_2, x_2) & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}. \quad (7.19)$$

Corolario 7.1.2. Matriz de m -pasos de transición. La matriz de transición de m -pasos P^m es el producto m -veces de la matriz de transición de un paso P .

Utilice el teorema de Chapman-Kolmogorov para la demostración.

Lema 7.1.3. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov. Se cumple que $\forall m \in \mathbb{N}$ y $y \in S$

$$\mathbb{P}(X_m = y) = \sum_{x \in S} \Pi_0(x) p^m(x, y). \quad (7.20)$$

La demostración es trivial.

7.2 Clasificación de Estados

Definición 7.2.1. Comunicación de una cadena. Se dice que un estado $x \in S$ se comunica con un estado $y \in S$ cuando

$$\mathbb{P}(X_n = y \text{ para algún } n \geq 1 \mid X_0 = x) > 0, \quad (7.21)$$

en cuyo caso se utiliza la notación $x \rightarrow y$.

Definición 7.2.2. No comunicación. Se afirma que un estado $x \in S$ no se comunica con un estado $y \in S$ cuando

$$\mathbb{P}(X_n = y \text{ para algún } n \geq 1 \mid X_0 = x) = 0, \quad (7.22)$$

en cuyo caso se escribe $x \nrightarrow y$.

Definición 7.2.3. Intercomunicación. Dos estados $x, y \in S$ se consideran intercomunicados cuando se cumple simultáneamente que $x \rightarrow y$ y $y \rightarrow x$. La notación empleada es

$$x \leftrightarrow y. \quad (7.23)$$

Definición 7.2.4. Cadena irreducible. Una cadena de Markov se denomina irreducible cuando todos los estados del espacio S se intercomunican entre sí, es decir, para todo par $x, y \in S$ se cumple

$$x \leftrightarrow y. \quad (7.24)$$

Lema 7.2.1. Condición para comunicación. Sean $x, y \in S$ con $x \neq y$. Entonces, se cumple que $x \rightarrow y$ si y sólo si

$$\exists_{m \geq 1} \mid p^m(x, y) > 0 \quad (7.25)$$

La demostración es trivial.

Lema 7.2.2. Relación de equivalencia. La relación de intercomunicación es una relación de equivalencia, en consecuencia

$$x \leftrightarrow x \text{ (reflexiva)} \quad (7.26)$$

$$x \leftrightarrow y \Rightarrow y \leftrightarrow x \text{ (simétrica)} \quad (7.27)$$

$$x \leftrightarrow y \text{ y } y \leftrightarrow z \Rightarrow x \leftrightarrow z \text{ (transitiva)} \quad (7.28)$$

La demostración se deja al lector.

Definición 7.2.5. Notación de comunicación. Sean $x, y \in S$.

$$F_{xy} := \mathbb{P}(X_n = y \text{ para algún } n \geq 1 \mid X_0 = x). \quad (7.29)$$

Definición 7.2.6. Recurrente y transitorio. Un estado $y \in S$ se denomina *recurrente* si

$$F_{yy} = 1. \quad (7.30)$$

En caso contrario, transitorio si

$$F_{yy} < 1, \quad (7.31)$$

Definición 7.2.7. Visita exacta. $\forall x, y \in S$ y $n \geq 1$

$$f^n(x, y) := \mathbb{P}(X_n = y, X_{k < n} \neq y \mid X_0 = x) = \mathbb{P}(\inf\{m \geq 1 : X_m = y\} = n \mid X_0 = x). \quad (7.32)$$

Definición 7.2.8. Estado absorbente. Un estado $x \in S$ se denomina absorbente si

$$\mathbb{P}(X_{n+1} = x \mid X_n = x) = 1. \quad (7.33)$$

Proposición 7.2.1. Recurrencia en estados no absorbentes. Sea $x \in S$ no absorbente, entonces

$$\exists y \in S - \{x\} \mid p(x, y) > 0 \quad (7.34)$$

La demostración es trivial.

Lema 7.2.3. Comunicación y visita. $\forall x, y \in S$ se cumple que

$$F_{xy} = \sum_{n=1}^{\infty} f^n(x, y). \quad (7.35)$$

La demostración se deja al lector.

Lema 7.2.4. Primera visita. $\forall n \geq 1$ y $x, y \in S$ se cumple que

$$p^n(x, y) = \sum_{k=1}^n f^k(x, y) p^{n-k}(y, y). \quad (7.36)$$

Demostración. Note que

$$f^k(x, y) p^{n-k}(y, y) = \mathbb{P}(X_k = y, X_{i < k} \neq y \mid X_0 = x) \mathbb{P}(X_{n-k} = y \mid X_0 = y)$$

Por transición se tiene que

$$f^k(x, y) p^{n-k}(y, y) = \mathbb{P}(X_k = y, X_{i < k} \neq y \mid X_0 = x) \mathbb{P}(X_n = y \mid X_k = y)$$

Dado que $\mathbb{P}(A \mid B) = \mathbb{P}(A \mid B, C)$, se tiene que

$$f^k(x, y) p^{n-k}(y, y) = \mathbb{P}(X_n = y \mid X_k = y, X_{i < k} \neq y) \mathbb{P}(X_k = y, X_{i < k} \neq y \mid X_0 = x)$$

Aplicando el teorema Chapman-Kolmogorov, se tiene que la suma de estas probabilidades es igual a $p^n(x, y)$. $\square$

Proposición 7.2.2. Absorción casi segura desde transitorios. Sea $A \subset S$ un conjunto de estados absorbentes y $T = S \setminus A$. Si $\forall x \in T \exists a \in A \mid p^n(a, x) > 0$, entonces

$$\forall x \in T \quad \mathbb{P}(T_A < \infty \mid X_0 = x) = 1, \quad T_A := \inf\{n \geq 1 : X_n \in A\} \quad (7.37)$$

La demostración se deja al lector.

Definición 7.2.9. Numero esperado de visitas. $\forall x, y \in S$, se denota mediante $P_{x,y}$ el número esperado de visitas de la cadena al estado y partiendo del estado x

$$P_{x,y} := \mathbb{E} \left[\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=y\}} \middle| X_0 = x \right], \quad (7.38)$$

donde la variable aleatoria

$$\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=y\}} \quad (7.39)$$

contabiliza el número de veces que la cadena ha visitado el estado y .

Lema 7.2.5. Transiciones y Numero de visitas. $\forall x, y \in S$ se cumple

$$P_{x,y} = \sum_{n=0}^{\infty} p^n(x, y). \quad (7.40)$$

Demostración. Dado que son la suma de variables aleatorias, por linealidad se tiene que

$$\mathbb{E} \left[\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=y\}} \middle| X_0 = x \right] = \sum_{n=0}^{\infty} \mathbb{E} \left[\mathbb{1}_{\{X_n=y\}} \middle| X_0 = x \right]$$

Donde claramente $\mathbb{1}_{\{X_n=y\}}$ nos limita a fijar el valor de la variable aleatoria, de forma que

$$\mathbb{E} \left[\mathbb{1}_{\{X_n=y\}} \middle| X_0 = x \right] = \mathbb{P}(X_n = y \mid X_0 = x).$$

□

Lema 7.2.6. Series de potencia de visitas. $\forall x, y \in S$, las series de potencias

$$P_{x,y}(t) = \sum_{n=0}^{\infty} p^n(x, y)t^n \quad (7.41)$$

$$F_{x,y}(t) = \sum_{n=1}^{\infty} f^n(x, y)t^n, \quad (7.42)$$

son absolutamente convergentes para $|t| < 1$. Además

$$P_{x,y}(t) = \delta_{x,y} + F_{x,y}(t)P_{y,y}(t), \quad (7.43)$$

donde

$$\delta_{x,y} = \begin{cases} 1 & \text{si } x = y, \\ 0 & \text{si } x \neq y. \end{cases} \quad (7.44)$$

Más aún

$$\lim_{t \uparrow 1} P_{x,y}(t) = P_{x,y}, \quad \lim_{t \uparrow 1} F_{x,y}(t) = F_{x,y}. \quad (7.45)$$

Demostración. La parte de la convergencia es trivial. Para la formula, ahora note que

$$P_{x,y}(t) - \delta_{x,y} = \sum_{n=1}^{\infty} p^n(x, y)t^n$$

Como $p^n(x, y) = \sum_{k=1}^n f^k(x, y)p^{n-k}(y, y)$, entonces por el Teorema de Tonelli

$$P_{x,y}(t) - \delta_{x,y} = \sum_{n=1}^{\infty} \left(\sum_{k=1}^n f^k(x, y)p^{n-k}(y, y)t^n \right) = \sum_{k=1}^{\infty} f^k(x, y) \sum_{n=k}^{\infty} p^{n-k}(y, y)t^n$$

De forma que

$$P_{x,y}(t) - \delta_{x,y} = \sum_{k=1}^{\infty} f^k(x,y)t^k \sum_{n=0}^{\infty} p^n(y,y)t^n = F_{x,y}(t)P_{y,y}(t)$$

La demostración de los límites es trivial. □

Teorema 7.2.1. Consecuencias de recurrencia y transición. Un estado $x \in S$ es recurrente si y sólo si

$$\sum_{n=0}^{\infty} p^n(x,x) = \infty. \quad (7.46)$$

Un estado $x \in S$ es transitorio si y sólo si

$$\sum_{n=0}^{\infty} p^n(x,x) < \infty. \quad (7.47)$$

Si $y \in S$ es transitorio, entonces para todo $x \in S$ se cumple

$$\sum_{n=0}^{\infty} p^n(x,y) < \infty. \quad (7.48)$$

La demostración se deja al lector.

Teorema 7.2.2. Caracterización de la recurrencia. Un estado $x \in S$ es recurrente si y sólo si

$$\mathbb{P}(X_n = x \text{ para infinitamente muchos } n \mid X_0 = x) = 1. \quad (7.49)$$

La demostración es consecuencia directa del lema de Borel-Cantelli.

Proposición 7.2.3. Transitorios se visitan finitas veces. Sea $x \in s$ transitorio. Entonces

$$\mathbb{P}(X_n \in T \text{ para infinitamente muchos } n \mid X_0 = x) = 0 \quad (7.50)$$

La demostración se deja al lector.

Definición 7.2.10. Tiempo medio de recurrencia. Sea $x \in S$ un estado recurrente.

$$m_y := \sum_{n=1}^{\infty} n f^n(x,y) \quad (7.51)$$

se denomina el tiempo medio de recurrencia de x . Se dice que

$$x \text{ es nulo-recurrente si } m_x = \infty, \quad (7.52)$$

$$x \text{ es positivo-recurrente si } m_x < \infty. \quad (7.53)$$

Lema 7.2.7. Convergencia de un estado recurrente. Sean $x, y \in S$. Supóngase que y es un estado recurrente y que $x \rightarrow y$. Entonces

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{m=1}^n p^m(x,y) = \frac{1}{m_y}. \quad (7.54)$$

Demostración. Sea $m_y := \mathbb{E}[\xi_k]$ donde $\xi_k = T_k - T_{k-1}$ son los tiempos entre retornos i.i.d. a y . Por el

teorema de renovación,

$$\frac{N_t}{t} \xrightarrow{c.s.} \frac{1}{m_y}, \quad N_t := \inf\{k : T_k > t\}.$$

Como $x \rightarrow y$ e y es recurrente, por el Lema anterior $\mathbb{P}_x(\tau < \infty) = 1$, donde $\tau := \inf\{m \geq 1 : X_m = y\}$. Por la propiedad fuerte de Markov, las visitas a y tras τ forman el proceso de renovación $\{T_k\}$, por lo que $V_y(n) = N_n - 1$ c.s. para $n \geq \tau$, y entonces

$$\frac{V_y(n)}{n} \xrightarrow{c.s.} \frac{1}{m_y}.$$

Finalmente, como $\frac{1}{n} \sum_{m=1}^n p^m(x, y) = \mathbb{E}_x \left[\frac{V_y(n)}{n} \right]$ y la convergencia es dominada,

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{m=1}^n p^m(x, y) = \frac{1}{m_y}.$$

□

Lema 7.2.8. Equivalencia de nulorecurrente. Un estado recurrente $x \in S$ es nulo-recurrente si y sólo si

$$p^n(x, x) \rightarrow 0 \text{ cuando } n \rightarrow \infty. \quad (7.55)$$

La demostración se deja al lector. Bastan con utilizar el primer teorema de Cauchy para sumas aritméticas y el lema anterior.

Definición 7.2.11. Estado periódico. Sea $x \in S$. Se define el periodo de un estado como

$$d(x) := \text{mcd}\{n \geq 1 : p^n(x, x) > 0\}, \quad (7.56)$$

donde *mcd* denota el máximo común divisor.

$$x \text{ es un estado periódico si } d(x) \geq 2. \quad (7.57)$$

$$x \text{ es un estado aperiódico si } d(x) = 1. \quad (7.58)$$

$$x \text{ es un estado ergódico si es positivo-recurrente y aperiódico.} \quad (7.59)$$

Teorema 7.2.3. Equivalencia entre estados. Sean $x, y \in S$ y supóngase que $x \leftrightarrow y$. Entonces

$$x \text{ es transitorio si y sólo si } y \text{ lo es.} \quad (7.60)$$

$$x \text{ es recurrente si y sólo si } y \text{ lo es.} \quad (7.61)$$

$$x \text{ es nulo-recurrente si y sólo si } y \text{ lo es.} \quad (7.62)$$

$$x \text{ es positivo-recurrente si y sólo si } y \text{ lo es.} \quad (7.63)$$

$$x \text{ es periódico si y sólo si } y \text{ lo es. En ese caso } d(x) = d(y). \quad (7.64)$$

$$x \text{ es aperiódico si y sólo si } y \text{ lo es.} \quad (7.65)$$

$$x \text{ es ergódico si y sólo si } y \text{ lo es.} \quad (7.66)$$

La demostración se deja al lector.

Lema 7.2.9. Recurrencia y equivalencia. Si x es recurrente y sumado a ello $x \rightarrow y$, entonces

$$y \rightarrow x. \quad (7.67)$$

$$y \text{ es recurrente.} \quad (7.68)$$

Demostración. Suponga por contradicción que $y \nrightarrow x$, dado que $p^n(x, y) > 0$ para algún n , si $T_x := \{m : X_m = x\}$ tiene que

$$\begin{aligned} \mathbb{P}(T_x = \infty \mid X_0 = x) &\geq \mathbb{P}(T_x = \infty, X_n = y \mid X_0 = x) \\ &= \mathbb{P}(T_x = \infty \mid X_n = y, X_0 = x) \mathbb{P}(X_n = y \mid X_0 = x) > \mathbb{P}(X_n = y \mid X_0 = x) > 0 \end{aligned}$$

Pero $F_{xx} = 1$, lo que implica que $\mathbb{P}(T_x = \infty \mid X_0 = x) = 0$. Por consecuencia, $y \rightarrow x$. La parte de la recurrencia es consecuencia del teorema anterior, y de paso es trivial. $\square$

Definición 7.2.12. Conjunto cerrado e irreducible. Un subconjunto $C \subset S$ se dice cerrado si, una vez que la cadena entra en C , nunca abandona C . Formalmente

$$\mathbb{P}(X_k \in S \setminus C \text{ para algún } k \mid X_0 = x) = 0, \forall x \in C. \quad (7.69)$$

Un subconjunto $C \subset S$ se dice irreducible si

$$\forall x, y \in C, x \leftrightarrow y. \quad (7.70)$$

Teorema 7.2.4. Equivalencia de cerrado. Sea $C \subset S$. C es cerrado si y sólo si

$$p(x, y) = 0, \forall x \in C, y \in S \setminus C. \quad (7.71)$$

La demostración es trivial. Utiliza inducción en izquierda derecha, y sume con respecto a $S \setminus C$ y k para la otra dirección.

Lema 7.2.10. Recurrencia en conjunto cerrado. Si $C \subset S$ es un subconjunto finito y cerrado, entonces existe al menos un $x \in C$ que es recurrente.

Demostración. Suponga que $\sum_{n=1}^{\infty} p^n(x, z) < \infty$, note que por distribución de probabilidad y dado que C es finito

$$\sum_{z \in C} p^n(x, z) = 1 \quad \wedge \quad \sum_{z \in C} \sum_{n=1}^{\infty} p^n(x, z) < \infty$$

pero note que (dado que son sumas finitas)

$$\sum_{n=1}^{\infty} \sum_{z \in C} p^n(x, z) = \sum_{n=1}^{\infty} 1 = \infty$$

$\square$

Teorema 7.2.5. Recurrencia positiva en conjuntos finitos cerrados. Si $C \subset S$ es un subconjunto finito, cerrado e irreducible, entonces

$$\forall x \in C, x \text{ es positivo-recurrente.} \quad (7.72)$$

Demostración. Note que por lemas anteriores todos los estados de C ahora son recurrentes. Entonces

$$\sum_{z \in C} p^n(x, z) = 1, \forall n \geq 1.$$

Sumando y dividiendo por N se tiene que

$$\sum_{z \in C} \frac{1}{N} \sum_{n=1}^N p^n(x, z) = 1.$$

Por el teorema de convergencia de estado recurrente, para cada $z \in C$ recurrente el límite cesariano existe y satisface

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N p^n(x, z) = \frac{1}{m_z}$$

Tomando $N \rightarrow \infty$ e intercambiando límite

$$\sum_{z \in C} \frac{1}{m_z} = 1.$$

Como la suma es finita, debe existir al menos un $y \in C$ con $m_y < \infty$. Como C es irreducible, todos los estados se pueden acotar entre si mismos, entonces $m_z < \infty$ para todo $z \in C$, es decir todo $x \in C$ es positivo-recurrente. □

Corolario 7.2.1. Recurrencia positiva en cadenas finitas irreducibles. Si una cadena de Markov es irreducible y tiene un número finito de estados, entonces

todos sus estados son positivo-recurrentes. (7.73)

La demostracion es inmediata del teorema anterior.

Teorema 7.2.6. Descomposición del espacio de estados. El espacio de estados S de una cadena de Markov tiene la siguiente descomposición como unión disjunta

$$S = T \cup \bigsqcup_{j=0}^N C_j, \tag{7.74}$$

donde T es el subconjunto de todos los estados transitorios, cada C_j es un subconjunto cerrado e irreducible de estados recurrentes, y $N \in \mathbb{N} \cup \{\infty\}$.

Demostración. Sea T el conjunto de estados transitorios y $R = S \setminus T$ el conjunto de estados recurrentes. Entonces $S = T \cup R$, siendo esta unión disjunta. Dentro de R , dos estados $i, j \in R$ se comunican si $i \leftrightarrow j$, esta relación es de equivalencia, por lo que R se particiona en clases de comunicación $\{C_j\}$ cerradas.

Si existiera un camino hacia afuera, hacia algún $y \notin C_j$, entonces habría un $z \in C_j$ con $\mathbb{P}(z, y) > 0$. Pero si z es recurrente, la cadena debe regresar a y con probabilidad 1, lo que implicaría que y comunica de regreso con z , contradiciendo $y \notin C_j$. Por tanto, ninguna clase recurrente tiene salida. Además, cada C_j es irreducible.

Los estados que no pertenecen a ninguna clase C_j son necesariamente transitorios, pues si fueran recurrentes estarían en alguna clase. Así, T absorbe exactamente los estados fuera de las clases recurrentes. □

Lema 7.2.11. Existencia de descenso estricto. Sea $\{X_n\}$ una cadena de Markov con $S \subset \mathbb{Z}$ finito y $f : S \rightarrow \mathbb{R}$ tal que $\sum_{y \in S} f(y) p(x, y) = f(x)$ para todo $x \in S$. Si $x \in S$ no es absorbente, entonces

$$\exists y_1, y_2 \in S \mid p(x, y_1) > 0 \wedge p(x, y_2) > 0 \wedge f(y_1) < f(x) < f(y_2) \tag{7.75}$$

La demostracion se deja al lector.

Proposición 7.2.4. Probabilidad de absorción con función armónica monótona. Sea $\{X_n\}$ una cadena de Markov con $S = \{0, 1, \dots, d\}$ y $f : S \rightarrow \mathbb{R}$ estrictamente monótona tal que

$$\sum_{y \in S} f(y) p(x, y) = f(x) \quad \forall x \in S \quad (7.76)$$

Entonces para todo $x \in \{1, \dots, d-1\}$

$$\mathbb{P}(\text{absorción en } f^{-1}(\max f) \mid X_0 = x) = \frac{f(x) - f(0)}{f(d) - f(0)} \quad (7.77)$$

La demostración se deja al lector.

Lema 7.2.12. Conjunto de máximo es cerrado. Sea $f : S \rightarrow \mathbb{R}$ tal que $\sum_{y \in S} f(y) p(x, y) = f(x)$ para todo $x \in S$. Sean $M = \max_{x \in S} f(x)$ y $C = \{x \in S : f(x) = M\}$. Entonces C es cerrado

$$p(x, y) = 0 \quad \forall x \in C, y \notin C \quad (7.78)$$

La demostración se deja al lector.

7.3 Distribución estacionaria

Definición 7.3.1. Distribución estacionaria. Una distribución de probabilidad $\pi = \{\pi(x) : x \in S\}$ sobre S se dice estacionaria o invariante para la cadena $\{X_n : n \in \mathbb{N}\}$ si

$$\pi(y) = \sum_{x \in S} \pi(x) p(x, y), \quad \forall y \in S. \quad (7.79)$$

Lema 7.3.1. Invariante para probabilidades n-pasos. Supóngase que π es una distribución estacionaria. Entonces

$$\pi(y) = \sum_{x \in S} \pi(x) p_n(x, y), \quad \forall y \in S, n \geq 1. \quad (7.80)$$

La demostración de deja al lector, se demuestra por inducción.

Teorema 7.3.1. Equivalencia entre recurrencia positiva e invariancia. Supóngase que la cadena $\{X_n : n \in \mathbb{N}\}$ es irreducible. Las siguientes afirmaciones son equivalentes:

$$\text{Todo estado de la cadena es positivo-recurrente.} \quad (7.81)$$

$$\text{La cadena posee una distribución estacionaria } \pi. \quad (7.82)$$

Más aún, en ambos casos se concluye que existe una única distribución estacionaria, la cual satisface

$$\pi(y) = \frac{1}{m_y}, \quad \forall y \in S. \quad (7.83)$$

Demostración. (i) $\Rightarrow$ (ii): Defínase la medida de ocupación de ciclo

$$\gamma(x) := \mathbb{E}_y \left[\sum_{n=0}^{T_y-1} \mathbf{1}_{\{X_n=x\}} \right],$$

que satisface $\gamma(y) = 1$ y la ecuación de balance $\gamma(x) = \sum_z \gamma(z) p(z, x)$. Como

$$\sum_{x \in S} \gamma(x) = \mathbb{E}_y[T_y] = m_y < \infty,$$

donde $T_y = \inf\{n \geq 1 : X_n = y\}$, la medida $\pi(x) := \gamma(x)/m_y$ es una distribución estacionaria.

(ii) $\Rightarrow$ (i): Si y fuera nulo-recurrente, por el teorema de convergencia de recurrencia

$$\frac{1}{n} \sum_{m=1}^n p^m(x, y) \rightarrow \frac{1}{m_y} = 0 \quad \forall x.$$

Pero $\pi(y) = \sum_x \pi(x) p^n(x, y)$ para todo n , y por Convergencia Dominada $\pi(y) = \sum_x \pi(x) \cdot 0 = 0$, contradiciendo $\sum_y \pi(y) = 1$. Luego todo estado es positivo-recurrente. La unicidad se sigue de que toda distribución estacionaria μ satisface $\mu(y) = 1/m_y = \pi(y)$. □

Corolario 7.3.1. Existencia y unicidad en cadenas finitas irreducibles. Si una cadena de Markov es irreducible y tiene un número finito de estados, entonces posee una única distribución estacionaria π . Más aún, π satisface la relación anterior.

Demostrado anteriormente.

Corolario 7.3.2. Ergódico de medias temporales. Supóngase que la cadena $\{X_n : n \in \mathbb{N}\}$ es irreducible y que todos sus estados son positivo-recurrentes. Sea π su única distribución estacionaria. Entonces

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{m=1}^n p^m(x, y) = \pi(y), \quad \forall x, y \in S. \quad (7.84)$$

La demostración queda al lector.

Teorema 7.3.2. Ergódico de convergencia. Supóngase que la cadena $\{X_n : n \in \mathbb{N}\}$ es irreducible y que todos sus estados son positivo-recurrentes. Sea π su única distribución estacionaria y sea d el período común de todos los estados de la cadena.

$$\text{Si } d(x) = 1 \text{ (aperiódicos), } \lim_{n \rightarrow \infty} p^n(x, y) = \pi(y), \quad \forall x, y \in S. \quad (7.85)$$

$$\text{Si } d \geq 2 \text{ (periódicos), entonces } \forall x, y \in S \exists 0 \leq r < d \wedge r \neq n - dm \mid p^n(x, y) = 0, \quad (7.86)$$

y además

$$\lim_{m \rightarrow \infty} p^{dm+r}(x, y) = d\pi(y). \quad (7.87)$$

Demostración. Caso aperiódico ($d = 1$): Por el Lema de Primera visita,

$$p^n(x, y) = \sum_{k=1}^n f^k(x, y) p^{n-k}(y, y).$$

Como y es positivo-recurrente, por el teorema ergódico el promedio cesariano satisface

$$\frac{1}{N} \sum_{n=1}^N p^n(x, y) \rightarrow \pi(y).$$

Para obtener convergencia puntual, nótese que $p^n(x, y)$ es una convolución con una distribución de probabilidad $\{f^k(x, y)\}$ de media finita. Por el teorema de Blackwell-Stone para sumas de Cesàro de convoluciones, si el límite cesariano existe y la distribución es aperiódica, entonces el límite puntual existe e igual al cesariano:

$$p^n(x, y) \xrightarrow{n \rightarrow \infty} \pi(y).$$

Caso periódico ($d \geq 2$): Todos los estados comparten período d . Fijado y , las clases cíclicas

$$C_r := \{z \in S : p^{nd+r}(y, z) > 0 \text{ para algún } n\}, \quad r = 0, \dots, d-1,$$

particionan S , y la cadena pasa de C_r a $C_{r+1 \bmod d}$ con probabilidad 1. Para $x \in C_i$, $y \in C_j$ con $r = j - i \bmod d$, se tiene $p^n(x, y) = 0$ salvo cuando $n = dm + r$.

La cadena $Y_m := X_{dm}$ restringida a C_j es irreducible y aperiódica, con tiempo medio de retorno $m_y^{(d)} = m_y/d$. Aplicando el caso aperiódico,

$$p^{dm+r}(x, y) \xrightarrow{m \rightarrow \infty} \frac{1}{m_y^{(d)}} = \frac{d}{m_y} = d \pi(y).$$

□

Lema 7.3.2. Soporte de la distribución estacionaria. Si la cadena $\{X_n : n \in \mathbb{N}\}$ posee una distribución estacionaria π , entonces

$$\pi(x) = 0 \quad \text{para todo estado } x \in S \text{ que sea transitorio o nulo-recurrente.} \quad (7.88)$$

La demostración queda al lector.

Teorema 7.3.3. Clasificación de distribuciones estacionarias. Denótese mediante S_p el conjunto de los estados positivo-recurrentes de la cadena $\{X_n : n \in \mathbb{N}\}$.

$$\text{Si } S_p = \emptyset, \text{ la cadena no posee distribución estacionaria.} \quad (7.89)$$

$$\text{Si } S_p \neq \emptyset \text{ y } S_p \text{ es irreducible, la cadena tiene una única distribución estacionaria.} \quad (7.90)$$

$$\text{Si } S_p \neq \emptyset \text{ y } S_p \text{ no es irreducible, la cadena posee un número infinito de distribuciones estacionarias.} \quad (7.91)$$

Demostración. Caso $S_p = \emptyset$. Todos los estados son transitorios o nulo-recurrentes. Si existiera una distribución estacionaria π , el Lema de Soporte de la distribución estacionaria daría $\pi(x) = 0$ para todo $x \in S$, lo que contradice $\sum_{x \in S} \pi(x) = 1$. Luego no existe distribución estacionaria.

Caso $S_p \neq \emptyset$, S_p irreducible. Por el Teorema de Equivalencia de cerrado y el Lema de Recurrencia y equivalencia, S_p es un subconjunto cerrado: si existiera $x \in S_p$ e $y \notin S_p$ con $p(x, y) > 0$, entonces por irreducibilidad de S_p la cadena debería retornar a x desde y , lo que forzaría a y a ser positivo-recurrente, contradiciendo $y \notin S_p$. Como S_p es cerrado e irreducible, la cadena restringida a S_p satisface las hipótesis del Teorema de Equivalencia entre recurrencia positiva e invariancia, que garantiza la existencia de una única distribución estacionaria π sobre S_p . Extendiendo con $\pi(x) = 0$ para $x \notin S_p$, lo cual es consistente con el Lema de Soporte, se obtiene la única distribución estacionaria sobre S .

Caso $S_p \neq \emptyset$, S_p no irreducible. Por el Teorema de Descomposición del espacio de estados, S_p contiene al menos dos clases cerradas irreducibles distintas $C_1, C_2 \subset S_p$. Aplicando el caso anterior a cada C_i , se obtienen distribuciones estacionarias π_1 y π_2 soportadas respectivamente en C_1 y C_2 . Dado que la ecuación de estacionariedad es lineal, para todo $\alpha \in [0, 1]$ la mezcla convexa

$$\pi_\alpha := \alpha \pi_1 + (1 - \alpha) \pi_2$$

es también una distribución estacionaria. Como la familia $\{\pi_\alpha : \alpha \in [0, 1]\}$ es no contable, existen infinitas distribuciones estacionarias.

□

8

Martingales

8.1 Definición y Propiedades Básicas

Definición 8.1.1. martingala en tiempo discreto. Un proceso estocástico en tiempo discreto y de variables aleatorias reales $(M_n : n \geq 1)$ se dice ser una martingala en tiempo discreto con respecto a una sucesión de variables aleatorias $(X_n : n \geq 1)$, siempre que se cumpla con lo siguiente

1. Cada M_n es integrable.
2. Cada M_n es medible con respecto a la sucesión finita $X_1, \dots, X_n$, es decir, $\forall n \geq 1$ existe una función $f_n : \mathbb{R}^n \rightarrow \mathbb{R}$ que es (Borel) medible tal que $M_n = f_n(X_1, \dots, X_n)$.
3. Se cumple la identidad de martingala

$$\mathbb{E}(M_{n+1} \mid X_1, \dots, X_n) = M_n, \quad \forall n \geq 1. \quad (8.1)$$

Definición 8.1.2. Filtración. Una sucesión de σ -álgebras $(\mathcal{F}_n : n \geq 1)$ de Ω tal que

$$\mathcal{F}_1 \subseteq \mathcal{F}_2 \subseteq \dots \subseteq \mathcal{F}_n \subseteq \dots \subseteq \mathcal{F},$$

se llama una filtración.

Definición 8.1.3. Filtración natural. Sea $(X_n : n \geq 1)$ una sucesión de variables aleatorias definidas sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$. Para cada $n \in \mathbb{N}$ se define

$$\mathcal{F}_n = \sigma(X_1, X_2, \dots, X_n), \quad (8.2)$$

es decir, la menor σ -álgebra que contiene todos los eventos de la forma

$$\{X_k \in B_k\}, \quad B_k \in \mathcal{B}(\mathbb{R}), \quad k = 1, \dots, n. \quad (8.3)$$

La sucesión $(\mathcal{F}_n : n \geq 1)$ constituye una filtración, llamada la filtración natural asociada a (X_n) .

Proposición 8.1.1. Sea $(\mathcal{F}_n : n \geq 1)$ la filtración natural de (X_n) . Un evento $A \in \mathcal{F}$ pertenece a $\mathcal{F}_n$ si y sólo si su función indicadora 1_A puede escribirse como

$$1_A = f(X_1, \dots, X_n), \quad (8.4)$$

para alguna función medible $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

Para otro día.

Definición 8.1.4. $(\mathcal{F}_n)$ -adaptado. Un proceso $(M_n : n \geq 1)$ se dice $(\mathcal{F}_n)$ -adaptado si para todo $n \geq 1$, la variable aleatoria M_n es $\mathcal{F}_n$ -medible, es decir, si $\{M_n \in B\} \in \mathcal{F}_n \forall B \in \mathcal{B}(\mathbb{R})$.

Definición 8.1.5. $(\mathcal{F}_n)$ -martingala. Un proceso estocástico $(M_n : n \geq 1)$ es una $(\mathcal{F}_n)$ -martingala siempre que se cumpla lo siguiente

1. Cada M_n es integrable.
2. El proceso es $(\mathcal{F}_n)$ -adaptado.
3. Se cumple la identidad de martingala

$$\mathbb{E}(M_{n+1} \mid \mathcal{F}_n) = M_n, \quad \forall n \geq 1. \quad (8.5)$$

Si reemplazamos “=” por “ $\leq$ ” (respectivamente “ $\geq$ ”) se dice que $(M_n : n \geq 1)$ es una $(\mathcal{F}_n)$ -supermartingala (respectivamente una $(\mathcal{F}_n)$ -submartingala).

En lo que resta de esta sección, y salvo indicación contraria, se trabajara con una filtración $(\mathcal{F}_n : n \geq 1)$ respecto de la cual todas nuestras martingalas son $(\mathcal{F}_n)$ -adaptadas; por ello se utilizara simplemente el término martingala, y de igual forma supermartingala y submartingala.

Lema 8.1.1. Si $(M_n : n \geq 1)$ es una martingala, se tiene que

$$\mathbb{E}(M_1) = \mathbb{E}(M_2) = \dots = \mathbb{E}(M_n) = \dots$$

La demostración es consecuencia de la propiedad de la torre.

Lema 8.1.2. Si $(M_n : n \geq 1)$ es una supermartingala (respectivamente una submartingala) entonces para $n > m$, $\mathbb{E}(M_n \mid \mathcal{F}_m) \leq M_m$ (respectivamente $\mathbb{E}(M_n \mid \mathcal{F}_m) \geq M_m$).

Demostración. Si suponemos que por inducción se cumple para n (ya que para $n = m + 1$ se cumple por definición), entonces para $m + k + 1 = n + 1$ por propiedad de la torre

$$\mathbb{E}[M_{m+k+1} \mid \mathcal{F}_m] = \mathbb{E}[\mathbb{E}[M_{m+k+1} \mid \mathcal{F}_{m+k}] \mid \mathcal{F}_m] \leq \mathbb{E}[M_{m+k} \mid \mathcal{F}_m] \leq M_m$$

Para el segundo caso es lo mismo.

□

Lema 8.1.3. Si $(M_n : n \geq 1)$ es una martingala entonces para $n > m$, $\mathbb{E}(M_n | \mathcal{F}_m) = M_m$.

Se aplica lo mismo anterior.

Teorema 8.1.1. Si $(M_n : n \geq 1)$ es una martingala (respectivamente una submartingala) y φ es una función convexa (respectivamente convexa y creciente) para la cual se satisface que $\mathbb{E}|\varphi(M_n)| < \infty \forall_{n \geq 1}$, entonces el proceso $(\varphi(M_n) : n \geq 1)$ es una submartingala. En particular, si para $p \geq 1$ se cumple $\mathbb{E}|M_n|^p < \infty$, entonces $(|M_n|^p : n \geq 1)$ es una submartingala.

Note que esto pasa ya que $\mathbb{E}[\varphi(X) | \mathcal{G}] \geq \varphi(\mathbb{E}[X | \mathcal{G}])$. Desigualdad de Jensen.

Definición 8.1.6. $(\mathcal{F}_n)$ -predecible. Un proceso $(A_n : n \geq 1)$ se dice que es $(\mathcal{F}_n)$ -predecible si $\forall_{n \geq 1}$, A_n es $\mathcal{F}_{n-1}$ -medible, con la convención $\mathcal{F}_0 = \{\emptyset, \Omega\}$.

Teorema 8.1.2. Descomposición de Doob Una submartingala $(N_n : n \geq 1)$ se puede escribir en forma única como $N_n = M_n + A_n \forall_{n \geq 1}$, donde $(M_n : n \geq 1)$ es una martingala y $(A_n : n \geq 1)$ es un proceso predecible creciente.

Demostración. Tome $\Delta A_{n+1} = \mathbb{E}[N_{n+1} - N_n | \mathcal{F}_n]$, y en consecuencia tome

$$A_n = \sum_{k=1}^n \Delta A_k \quad M_n = N_n - A_n$$

por definicion de A_n dado que los valores anteriores ya están determinados, por el ultimo incremento Δ entonces es $\mathcal{F}_{n-1}$ -medible, en cuyo caso es predecible y creciente. Ahora, note que

$$\mathbb{E}[M_n | \mathcal{F}_{n-1}] = \mathbb{E}[N_n - A_n | \mathcal{F}_{n-1}] = \mathbb{E}[N_n | \mathcal{F}_{n-1}] - A_n = N_{n-1} + \Delta A_n - \sum_{k=1}^n \Delta A_k = M_{n-1}$$

Para la unicidad suponga otros M' y A' y se llegan a que son iguales a los ya encontrados.

□

Definición 8.1.7. Transformada de martingala. Suponga que tenemos un proceso predecible $(A_n : n \geq 1)$ y una martingala $(M_n : n \geq 1)$. Defina el proceso $(\tilde{M}_n : n \geq 1)$ como

$$\tilde{M}_n = \sum_{i=1}^{n-1} A_{i+1}(M_{i+1} - M_i), \quad \forall n \geq 1.$$

A $(\tilde{M}_n : n \geq 1)$ se le llama la transformada de martingala de (M_n) mediante (A_n) .

Teorema 8.1.3. Sean $(A_n : n \geq 1)$, $(M_n : n \geq 1)$ y $(\tilde{M}_n : n \geq 1)$ como la definicion anterior. Suponga que cada A_n es una variable aleatoria acotada. Entonces la transformada de martingala $(\tilde{M}_n : n \geq 1)$ es una martingala.

Demostración. Simplemente note que $\mathbb{E}[|\tilde{M}_n|] < \infty$, sumado a ello tanto A_i y M_i son $\mathcal{F}_n$ -medibles por la definicion de filtración. Por ultimo

$$\mathbb{E}[\tilde{M}_n | \mathcal{F}_{n-1}] = \sum_{i=1}^{n-2} A_{i+1}(M_{i+1} - M_i) + A_n \mathbb{E}[M_n | \mathcal{F}_{n-1}] - A_n M_{n-1} = \sum_{i=1}^{n-2} A_{i+1}(M_{i+1} - M_i) = \tilde{M}_{n-1}$$

□

8.2 Tiempos de Parada

Definición 8.2.1. $(\mathcal{F}_n)$ -tiempo de parada. Considere una filtración $(\mathcal{F}_n : n \geq 1)$. Una variable aleatoria τ con valores en $\mathbb{N} \cup \{\infty\}$ se llama un $(\mathcal{F}_n)$ -tiempo de parada si para cada $n \geq 1$ se cumple que $\{\tau \leq n\} \in \mathcal{F}_n$.

Definición 8.2.2. Variable detenida. Si $(Y_n : n \geq 0)$ es un proceso estocástico $(\mathcal{F}_n)$ -adaptado y si τ es un $(\mathcal{F}_n)$ -tiempo de parada tal que $\mathbb{P}(\tau < \infty) = 1$, definiremos la variable detenida Y_τ como la variable aleatoria dada por:

$$Y_\tau(\omega) := \sum_{k=1}^{\infty} \mathbf{1}_{\{\tau=k\}}(\omega) Y_k(\omega), \quad \forall \omega \in \Omega. \quad (8.6)$$

8.3 Parada Opcional

Definición 8.3.1. Proceso detenido. Sea $(Y_n : n \geq 0)$ un proceso estocástico $(\mathcal{F}_n)$ -adaptado y τ un $(\mathcal{F}_n)$ -tiempo de parada tal que

$$\mathbb{P}(\tau < \infty) = 1. \quad (8.7)$$

Si τ está acotado, es decir, si existe $M > 0$ tal que

$$\mathbb{P}(\tau \leq M) = 1, \quad (8.8)$$

la suma en la definición de variable detenida involucra un número finito de términos. Para cada $n \in \mathbb{N}$ se define el $(\mathcal{F}_n)$ -tiempo de parada

$$\tau \wedge n = \min\{\tau, n\}, \quad (8.9)$$

el cual está acotado por n . El proceso detenido $(Y_{\tau \wedge n} : n \geq 1)$ se define como

$$Y_{\tau \wedge n}(\omega) = \begin{cases} Y_\tau(\omega), & \text{si } \tau(\omega) < n, \\ Y_n(\omega), & \text{si } \tau(\omega) \geq n. \end{cases} \quad (8.10)$$

Teorema 8.3.1. Parada Opcional de Doob Si $(M_n : n \geq 1)$ es una martingala y τ un tiempo de parada tal que $\mathbb{P}(\tau < \infty) = 1$, el proceso detenido $(M_{\tau \wedge n} : n \geq 1)$ es una martingala.

Demostración. Tome $A_n(\omega) = \mathbf{1}_{\{\tau \geq n\}}(\omega) = 1 - \mathbf{1}_{\{\tau < n\}}(\omega)$ es un proceso predecible tal que $\{\tau \leq n-1\} \in \mathcal{F}_{n-1}$ por lo que A_n es $\mathcal{F}_{n-1}$ -medible. Ahora note que

$$M_1 + \sum_{k=1}^{n-1} A_{k+1}(M_{k+1} - M_k) = M_\tau \mathbf{1}_{\{\tau < n\}}(\omega) + M_n \mathbf{1}_{\{\tau \geq n\}}(\omega) = M_{\tau \wedge n}$$

es una martingala. □

8.4 Desigualdades para Submartingalas

Teorema 8.4.1. Desigualdad Maximal de Doob Si $(M_n : n \geq 1)$ es una $(\mathcal{F}_n)$ -submartingala no-negativa que es p -integrable con $p \geq 1$, entonces $\forall_{\lambda > 0, n \geq 1}$ se tiene que

$$\lambda^p \mathbb{P}\left(\max_{1 \leq m \leq n} M_m \geq \lambda\right) \leq \mathbb{E}\left(M_n^p \mathbf{1}_{\{\max_{1 \leq m \leq n} M_m \geq \lambda\}}\right) \leq \mathbb{E}(M_n^p). \quad (8.11)$$

Demostración. Como x^p es convexa y creciente en $x \geq 0$, el proceso $(M_n^p : n \geq 1)$ es una submartingala no-negativa p -integrable. Por tanto, basta probar la desigualdad para $p = 1$ y aplicarla a (M_n^p) con umbral λ^p . Entonces tome $\tau(\omega) = \min\{1 \leq m \leq n : M_m(\omega) \geq \lambda\}$ con la convención $\tau = n$ si el conjunto es vacío. Observe que τ es el primer tiempo de llegada al conjunto $[\lambda, \infty)$, y que se cumple la igualdad de eventos

$$\left\{\max_{1 \leq m \leq n} M_m \geq \lambda\right\} = \{\tau \leq n\}.$$

Ahora note que en el evento $\{\tau \leq n\}$ se tiene por definición que $M_\tau \geq \lambda$, de donde

$$\lambda \mathbf{1}_{\{\tau \leq n\}} \leq M_\tau \mathbf{1}_{\{\tau \leq n\}} = \sum_{m=1}^n M_m \mathbf{1}_{\{\tau=m\}}.$$

Tomando esperanza a ambos lados y usando que (M_n) es submartingala, es decir $\mathbb{E}(M_n | \mathcal{F}_m) \geq M_m$ para $m \leq n$, se obtiene

$$\lambda \mathbb{P}(\tau \leq n) \leq \sum_{m=1}^n \mathbb{E}(M_m \mathbf{1}_{\{\tau=m\}}) \leq \sum_{m=1}^n \mathbb{E}(M_n \mathbf{1}_{\{\tau=m\}}) = \mathbb{E}(M_n \mathbf{1}_{\{\tau \leq n\}}) \leq \mathbb{E}(M_n).$$

Usando la igualdad de eventos $\{\tau \leq n\} = \{\max_{1 \leq m \leq n} M_m \geq \lambda\}$ se concluye el caso $p = 1$.

Para $p \geq 1$ basta aplicar lo anterior al proceso (M_n^p) con umbral λ^p , y usar que $\max_{1 \leq m \leq n} M_m^p \geq \lambda^p \iff \max_{1 \leq m \leq n} M_m \geq \lambda$ dado que x^p es creciente en $x \geq 0$, lo que da directamente

$$\lambda^p \mathbb{P}\left(\max_{1 \leq m \leq n} M_m \geq \lambda\right) \leq \mathbb{E}\left(M_n^p \mathbf{1}_{\{\max_{1 \leq m \leq n} M_m \geq \lambda\}}\right) \leq \mathbb{E}(M_n^p).$$

□

Teorema 8.4.2. Desigualdad en L^p de Doob Si $(M_n : n \geq 1)$ es una $(\mathcal{F}_n)$ -submartingala no-negativa que es p -integrable con $p \geq 2$, entonces $\forall_{n \geq 1}$ se tiene que

$$\mathbb{E}\left(\max_{1 \leq m \leq n} M_m^p\right) \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}(M_n^p). \quad (8.12)$$

Demostración. Sea $M_n^* = \max_{1 \leq m \leq n} M_m$. Por la fórmula de la esperanza mediante la función de distribución y la Desigualdad Maximal de Doob se tiene

$$\mathbb{E}((M_n^*)^p) = p \int_0^\infty \lambda^{p-1} \mathbb{P}(M_n^* \geq \lambda) d\lambda \leq p \int_0^\infty \lambda^{p-1} \frac{\mathbb{E}(M_n \mathbf{1}_{\{M_n^* \geq \lambda\}})}{\lambda} d\lambda = p \int_0^\infty \lambda^{p-2} \mathbb{E}(M_n \mathbf{1}_{\{M_n^* \geq \lambda\}}) d\lambda.$$

Intercambiando esperanza e integral mediante el Teorema de Fubini

$$\mathbb{E}((M_n^*)^p) \leq p \mathbb{E}\left(M_n \int_0^{M_n^*} \lambda^{p-2} d\lambda\right) = \frac{p}{p-1} \mathbb{E}(M_n (M_n^*)^{p-1}).$$

Aplicando la desigualdad de Hölder con exponentes p y $\frac{p}{p-1}$ al lado derecho,

$$\mathbb{E}(M_n (M_n^*)^{p-1}) \leq \mathbb{E}(M_n^p)^{1/p} \mathbb{E}((M_n^*)^p)^{(p-1)/p}.$$

Sustituyendo y dividiendo ambos lados por $\mathbb{E}((M_n^*)^p)^{(p-1)/p}$ (que es finito y positivo),

$$\mathbb{E}((M_n^*)^p)^{1/p} \leq \frac{p}{p-1} \mathbb{E}(M_n^p)^{1/p},$$

y elevando a la potencia p se concluye

$$\mathbb{E}\left(\max_{1 \leq m \leq n} M_m^p\right) \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}(M_n^p).$$

□

8.5 Convergencia de Martingalas

Teorema 8.5.1. Convergencia de Martingalas. Sea $(M_n : n \geq 1)$ una martingala que satisface $\mathbb{E}(|M_n|) \leq B \forall n \geq 1$ para cierto $B > 0$. Entonces existe una variable aleatoria M_∞ con $\mathbb{E}(|M_\infty|) \leq B$ tal que

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} M_n = M_\infty\right) = 1, \quad (8.13)$$

es decir $M_n \xrightarrow{\text{c.s.}} M_\infty$.

Si más aún se tiene que $\mathbb{E}(|M_n|^p) \leq B \forall n \geq 1$, para $p > 1$, entonces $\mathbb{E}(|M_\infty|^p) \leq B$ y además

$$\lim_{n \rightarrow \infty} \mathbb{E}(|M_n - M_\infty|^p) = 0, \quad (8.14)$$

es decir $M_n \xrightarrow{L^p} M_\infty$.

Demostración. Convergencia casi segura. Sean $a < b$ racionales. Definase

$$\sigma_1 = \min\{k \geq 1 : M_k \leq a\}, \quad \tau_i = \min\{k > \sigma_i : M_k \geq b\}, \quad \sigma_{i+1} = \min\{k > \tau_i : M_k \leq a\},$$

y sea $U_n[a, b] = \max\{j : \tau_j \leq n\}$ el número de upcrossings del intervalo $[a, b]$ hasta el tiempo n . El proceso

$$H_k = \sum_{j \geq 1} \mathbf{1}_{\{\sigma_j < k \leq \tau_j\}}$$

es predecible pues $\{\sigma_j < k \leq \tau_j\} \in \mathcal{F}_{k-1}$, y por la transformada de martingalas

$$\tilde{H}_n = \sum_{i=1}^{n-1} H_{i+1}(M_{i+1} - M_i)$$

es una martingala con $\mathbb{E}(\tilde{H}_n) = 0$. Dado que cada upcrossing completo contribuye al menos $b - a$ a $\tilde{H}_n$, y los incrementos fuera de los upcrossings satisfacen $(M_n - a)^+ \geq \tilde{H}_n - U_n[a, b](b - a) + (M_n - a)^+$, se obtiene la desigualdad de upcrossings de Doob:

$$(b - a) \mathbb{E}(U_n[a, b]) \leq \mathbb{E}((M_n - a)^+) \leq \mathbb{E}(|M_n|) + |a| \leq B + |a| < \infty.$$

Por monotonía $U_n[a, b] \nearrow U_\infty[a, b]$, y por el Teorema de Convergencia Monótona

$$\mathbb{E}(U_\infty[a, b]) \leq \frac{B + |a|}{b - a} < \infty,$$

luego $U_\infty[a, b] < \infty$ c.s. Tomando unión sobre todos los pares $a < b$ racionales,

$$\mathbb{P}\left(\liminf_{n \rightarrow \infty} M_n < \limsup_{n \rightarrow \infty} M_n\right) = \mathbb{P}\left(\bigcup_{\substack{a, b \in \mathbb{Q} \\ a < b}} \{U_\infty[a, b] = \infty\}\right) = 0,$$

por lo que $\lim_{n \rightarrow \infty} M_n = M_\infty$ existe c.s. La cota $\mathbb{E}(|M_\infty|) \leq B$ se obtiene aplicando el Lema de Fatou

$$\mathbb{E}(|M_\infty|) = \mathbb{E}\left(\lim_{n \rightarrow \infty} |M_n|\right) \leq \liminf_{n \rightarrow \infty} \mathbb{E}(|M_n|) \leq B.$$

Convergencia en L^p . Si $\mathbb{E}(|M_n|^p) \leq B$ para todo $n \geq 1$ con $p > 1$, la cota $\mathbb{E}(|M_\infty|^p) \leq B$ se obtiene igualmente por el Lema de Fatou. Para la convergencia L^p , note que la sucesión $(|M_n|^p)$ está acotada en L^1 con $p > 1$, lo que implica que la familia $\{M_n\}$ es uniformemente integrable. Junto con la convergencia c.s. ya probada, esto da

$$\lim_{n \rightarrow \infty} \mathbb{E}(|M_n - M_\infty|^p) = 0.$$

□

Otra demostración por si acaso

Demostración. Sean $d_k = M_k - M_{k-1}$ con $M_0 = 0$ las diferencias de la martingala. Como $\mathbb{E}(d_k d_j) = 0$ para $k \neq j$, se tiene

$$\mathbb{E}(M_n^2) = \mathbb{E}\left(\sum_{k=1}^n d_k\right)^2 = \sum_{k=1}^n \mathbb{E}(|d_k|^2),$$

y de la cota $\mathbb{E}(|M_n|^2) \leq B$ se concluye que $\sum_{k=1}^\infty \mathbb{E}(|d_k|^2) \leq B < \infty$.

Para probar la convergencia c.s., note que para $\epsilon > 0$ fijo, la Desigualdad Maximal de Doob aplicada a la martingala $(M_{k+m} - M_m : k \geq 1)$ da

$$\mathbb{P}\left(\sup_{k > m} |M_k - M_m| \geq \epsilon\right) \leq \frac{1}{\epsilon^2} \sum_{k=m+1}^\infty \mathbb{E}(|d_k|^2) \rightarrow 0, \quad m \rightarrow \infty,$$

pues la cola de una serie convergente tiende a cero. Esto implica que (M_n) es de Cauchy en probabilidad, y por el criterio de convergencia c.s. se concluye que

$$\mathbb{P}\left(\liminf_{n \rightarrow \infty} M_n = \limsup_{n \rightarrow \infty} M_n\right) = 1.$$

Definimos entonces $M_\infty(\omega) = \lim_{n \rightarrow \infty} M_n(\omega)$ en el conjunto de probabilidad 1 donde el límite existe, y $M_\infty(\omega) = 0$ en el complemento, de modo que $M_n \xrightarrow{\text{c.s.}} M_\infty$.

Para la convergencia en L^2 , observe que $M_\infty - M_n = \sum_{k=n+1}^\infty d_k$, y por ortogonalidad de las diferencias

$$\mathbb{E}(|M_\infty - M_n|^2) = \sum_{k=n+1}^\infty \mathbb{E}(|d_k|^2) \rightarrow 0, \quad n \rightarrow \infty.$$

□

Teorema 8.5.2. No se que poner xd. Si $(M_n : n \geq 1)$ es una submartingala que satisface $\mathbb{E}(\max\{M_n, 0\}) \leq B \ \forall_{n \geq 1}$, entonces $M_n \xrightarrow{\text{c.s.}} M_\infty$ con $\mathbb{E}(|M_\infty|) < \infty$.

Demostración. Por la Descomposición de Doob existe una martingala (N_n) y un proceso predecible creciente (A_n) con $A_1 = 0$ tal que $M_n = N_n + A_n$. Como (A_n) es creciente y

$$\mathbb{E}(A_n) = \mathbb{E}(M_n) - \mathbb{E}(N_n) = \mathbb{E}(M_n) - \mathbb{E}(M_1) \leq \mathbb{E}(\max\{M_n, 0\}) \leq B,$$

se tiene que $A_n \nearrow A_\infty$ c.s. con $\mathbb{E}(A_\infty) \leq B$. Por otra parte,

$$\mathbb{E}(|N_n|) \leq \mathbb{E}(|M_n|) + \mathbb{E}(A_n) \leq 2B + |\mathbb{E}(M_1)| < \infty,$$

luego (N_n) satisface la hipótesis del Teorema de Convergencia de Martingalas, de donde $N_n \xrightarrow{\text{c.s.}} N_\infty$ con $\mathbb{E}(|N_\infty|) < \infty$. Entonces

$$M_n = N_n + A_n \xrightarrow{\text{c.s.}} N_\infty + A_\infty =: M_\infty,$$

y $\mathbb{E}(|M_\infty|) \leq \mathbb{E}(|N_\infty|) + \mathbb{E}(A_\infty) < \infty$.

□

Teorema 8.5.3. No se que poner xd. Si $(M_n : n \geq 1)$ es una supermartingala que satisface $M_n \geq 0 \ \forall_{n \geq 1}$, entonces $M_n \xrightarrow{\text{c.s.}} M_\infty$ con $\mathbb{E}(M_\infty) \leq \mathbb{E}(M_1)$.

Note que $(-M_n)$ es una submartingala.

9

Martingalas en Tiempo Continuo

Definición 9.0.1. Càdlàg. Un proceso estocástico $(X_t : t \geq 0)$ se dice continuo (respectivamente càdlàg; que es un acrónimo del francés *continu à droite, limites à gauche*) si existe $\Omega_0 \subseteq \Omega$ con $\mathbb{P}(\Omega_0) = 1$, tal que $\forall_{\omega \in \Omega_0}$, las trayectorias $t \mapsto X_t(\omega)$ son continuas (respectivamente continuas por derecha con límites por izquierda) como funciones de $[0, \infty)$ en $\mathbb{R}$.

Definición 9.0.2. Filtración en tiempo continuo. Una filtración en tiempo continuo es una colección $(\mathcal{F}_t : t \geq 0)$ de σ -álgebras de Ω tales que

$$\mathcal{F}_s \subseteq \mathcal{F}_t \subseteq \mathcal{F}, \quad \forall s \leq t.$$

Definición 9.0.3. Filtración natural. La **filtración natural** de un proceso $(X_t : t \geq 0)$ es aquella para la cual $\mathcal{F}_t$ es la σ -álgebra generada por las variables aleatorias $(X_s : 0 \leq s \leq t)$.

Definición 9.0.4. $(\mathcal{F}_t)$ -adaptado Dada una filtración $(\mathcal{F}_t : t \geq 0)$, un proceso estocástico $(Y_t : t \geq 0)$ se dice $(\mathcal{F}_t)$ -adaptado si para cada $t \geq 0$, la variable aleatoria Y_t es $\mathcal{F}_t$ -medible.

Definición 9.0.5. $(\mathcal{F}_t)$ -tiempo de parada. Considere una filtración $(\mathcal{F}_t : t \geq 0)$. Un $(\mathcal{F}_t)$ -tiempo de parada es una variable aleatoria $\tau : \Omega \rightarrow [0, \infty]$ que satisface $\{\tau \leq t\} \in \mathcal{F}_t, \forall t \geq 0$.

Definición 9.0.6. Proceso detenido. Considere una filtración $(\mathcal{F}_t : t \geq 0)$. Sea τ un $(\mathcal{F}_t)$ -tiempo de parada y $Y = (Y_t : t \geq 0)$ un proceso $(\mathcal{F}_t)$ -adaptado. El proceso detenido de Y por τ es el proceso estocástico $Y^\tau = (Y_{\tau \wedge t} : t \geq 0)$ definido por

$$Y_{\tau \wedge t}(\omega) := Y_{\tau(\omega) \wedge t}(\omega), \quad \forall \omega \in \Omega, t \geq 0.$$

Definición 9.0.7. $(\mathcal{F}_t)$ -martingala. Un proceso estocástico $(M_t : t \geq 0)$ se dice una $(\mathcal{F}_t)$ -martingala si cumple con lo siguiente

1. Cada M_t es integrable.
2. El proceso es $(\mathcal{F}_t)$ -adaptado.
3. Se cumple la identidad de martingala:

$$\mathbb{E}(M_t \mid \mathcal{F}_s) = M_s, \quad \forall 0 \leq s \leq t < \infty.$$

Si reemplazamos “=” por “ $\leq$ ” (respectivamente “ $\geq$ ”) se dice que $(M_t : t \geq 0)$ es una $(\mathcal{F}_t)$ -supermartingala (respectivamente una $(\mathcal{F}_t)$ -submartingala).

Teorema 9.0.1. Versión càdlàg de martingalas continuas . Toda martingala en tiempo continuo posee una versión càdlàg.

Requiere un nivel muy avanzado para su demostracion.

Teorema 9.0.2. Parada Opcional de Doob. Si $(M_t : t \geq 0)$ es una martingala y τ un tiempo de parada, el proceso detenido $(M_{\tau \wedge t} : t \geq 0)$ es una martingala.

Proposición 9.0.1. Preservación de la clase bajo detención. Si $(M_t : t \geq 0)$ es una submartingala (respectivamente supermartingala) y τ un tiempo de parada, entonces el proceso detenido $(M_{\tau \wedge t} : t \geq 0)$ es una submartingala (respectivamente supermartingala).

Teorema 9.0.3. Desigualdad Maximal de Doob. Si $(M_t : t \geq 0)$ es una submartingala no-negativa que es p -integrable con $p \geq 1$, entonces $\forall \lambda > 0, T > 0$ se tiene que

$$\lambda^p \mathbb{P}\left(\sup_{0 \leq t \leq T} M_t \geq \lambda\right) \leq \mathbb{E}(M_T^p). \quad (9.1)$$

Más aún, si $p > 1$, entonces $\forall T > 0$ se tiene que:

$$\mathbb{E}\left[\left(\sup_{0 \leq t \leq T} M_t\right)^p\right] \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}(M_T^p). \quad (9.2)$$

Teorema 9.0.4. Convergencia de Martingalas. Sea $(M_t : t \geq 0)$ una martingala que satisface $\mathbb{E}(|M_t|) \leq B \forall t \geq 0$ para cierto $B > 0$. Entonces existe una variable aleatoria M_∞ con $\mathbb{E}(|M_\infty|) \leq B$ tal que

$$\mathbb{P}\left(\lim_{t \rightarrow \infty} M_t = M_\infty\right) = 1. \quad (9.3)$$

Si más aún se tiene que $\mathbb{E}(|M_t|^p) \leq B \forall t \geq 0$, para $p > 1$, entonces $\mathbb{E}(|M_\infty|^p) \leq B$ y además

$$\lim_{t \rightarrow \infty} \mathbb{E}(|M_t - M_\infty|^p) = 0. \quad (9.4)$$

9.1 Procesos de Poisson

Definición 9.1.1. Construcción. Sean $T_1, T_2, \dots$ i.i.d. con distribución exponencial de parámetro $\lambda > 0$. Defina $J_0 = 0$, $J_n = T_1 + \dots + T_n \forall n \geq 1$. Para cada $t \geq 0$, defina $N_t : \Omega \rightarrow \mathbb{N}$ por

$$N_t(\omega) = n \quad \text{si} \quad J_n(\omega) \leq t < J_{n+1}(\omega).$$

El proceso estocástico $(N_t : t \geq 0)$ se conoce como el proceso de Poisson de parámetro $\lambda > 0$.

Proposición 9.1.1. Divergencia de los tiempos de llegada. $\mathbb{P}(\lim_{n \rightarrow \infty} J_n = \infty) = 1$.

Demostración. Por el teorema de limite central $\frac{J_n}{n}$ converge a la media de las i.i.d. en cuyo caso es $O(n)$, y por lo tanto diverge. □

Proposición 9.1.2. Distribución de Poisson de los conteos. Para todo $t \geq 0$, N_t tiene distribución de Poisson con parámetro λt , es decir

$$\mathbb{P}(N_t = n) = \frac{e^{-\lambda t} (\lambda t)^n}{n!}. \quad (9.5)$$

Demostración. Note que la suma de exponenciales i.i.d. de parametro λ tiene distribucion $J_n \sim \text{Gamma}(n, \lambda)$, de forma que

$$\mathbb{P}(J_n \leq t) = \int_0^t \frac{\lambda^n x^{n-1} e^{-\lambda x}}{(n-1)!} dx = \frac{\Gamma(n, \lambda t)}{\Gamma(n)}$$

donde $\Gamma(n, \lambda t)$ es la misma integral que la $\Gamma(n)$ solo que con el limite inferior en $t\lambda$ en lugar de ∞ , de la cual (integrando por partes) se puede demostrar que $\Gamma(n+1, \lambda t) = n\Gamma(n, \lambda t) + (\lambda t)^n e^{-\lambda t}$, de forma que

$$\begin{aligned} \mathbb{P}(N_t = n) &= \mathbb{P}(N_t \geq n) - \mathbb{P}(N_t \geq n+1) = \mathbb{P}(J_n \leq t) - \mathbb{P}(J_{n+1} \leq t) = \frac{\Gamma(n, \lambda t)}{\Gamma(n)} - \frac{\Gamma(n+1, \lambda t)}{\Gamma(n+1)} \\ &= \frac{n\Gamma(n, \lambda t) + (\lambda t)^n e^{-\lambda t}}{n\Gamma(n)} - \frac{\Gamma(n, \lambda t)}{\Gamma(n)} = \frac{e^{-\lambda t} (\lambda t)^n}{n!} \end{aligned}$$

□

Otra forma de hacerlo es

Demostración. Suponga que $n \geq 1$. De la definición se tiene que

$$\mathbb{P}(N_t = n) = \mathbb{P}(J_n \leq t < J_{n+1}) = \mathbb{P}((J_n, T_{n+1}) \in B),$$

donde $B = \{(x, y) : 0 \leq x \leq t < x + y\}$. Como $T_1, T_2, \dots$ son i.i.d. con distribución exponencial de parámetro λ , entonces $J_n = T_1 + \dots + T_n \sim \text{Gamma}(n, \lambda)$ y es independiente de T_{n+1} . Por tanto la densidad conjunta de (J_n, T_{n+1}) es el producto de sus densidades marginales, y

$$\begin{aligned} \mathbb{P}(N_t = n) &= \frac{\lambda^{n+1}}{(n-1)!} \iint_B x^{n-1} e^{-\lambda x} e^{-\lambda y} dx dy = \frac{\lambda^{n+1}}{(n-1)!} \int_0^t x^{n-1} e^{-\lambda x} \int_{t-x}^{\infty} e^{-\lambda y} dy dx \\ &= \frac{\lambda^{n+1}}{(n-1)!} \int_0^t x^{n-1} e^{-\lambda x} \cdot \frac{e^{-\lambda(t-x)}}{\lambda} dx = \frac{\lambda^n e^{-\lambda t}}{(n-1)!} \int_0^t x^{n-1} dx = \frac{e^{-\lambda t} (\lambda t)^n}{n!}, \end{aligned}$$

□

Lema 9.1.1. Propiedad de memoria en el proceso de Poisson. Para todo $t > 0$, $s \geq 0$, $n \in \mathbb{N}$,

$$\mathbb{P}(J_{n+1} > t + s \mid N_t = n) = \mathbb{P}(T_1 > s) = e^{-\lambda s}. \quad (9.6)$$

Demostración. Si $n = 0$, de lo anterior y la propiedad de pérdida de memoria se tiene que

$$\mathbb{P}(J_1 > t + s \mid N_t = 0) = \mathbb{P}(T_1 > t + s \mid T_1 > t) = \mathbb{P}(T_1 > s) = e^{-\lambda s}.$$

Para $n \geq 1$

$$\mathbb{P}(N_t = n, J_{n+1} > t + s) = \frac{\lambda^{n+1}}{(n-1)!} \int_0^t x^{n-1} e^{-\lambda x} \int_{t+s-x}^\infty e^{-\lambda y} dy dx.$$

Evaluando

$$= \frac{\lambda^n e^{-\lambda(t+s)}}{(n-1)!} \int_0^t x^{n-1} dx = \frac{e^{-\lambda(t+s)} (\lambda t)^n}{n!}.$$

Finalmente,

$$\mathbb{P}(J_{n+1} > t + s \mid N_t = n) = \frac{\mathbb{P}(N_t = n, J_{n+1} > t + s)}{\mathbb{P}(N_t = n)} = \frac{e^{-\lambda(t+s)} (\lambda t)^n / n!}{e^{-\lambda t} (\lambda t)^n / n!} = e^{-\lambda s}.$$

□

Lema 9.1.2. Propiedad de regeneración de los tiempos de llegada. Para todo $n \in \mathbb{N}$, $m \geq 2$, $t \geq 0$, la distribución condicional del vector aleatorio $(J_{n+1} - t, T_{n+2}, \dots, T_{n+m})$ dado $\{N_t = n\}$ es igual a la distribución del vector aleatorio $(T_1, T_2, \dots, T_m)$.

Demostración. Note que por independencia

$$\begin{aligned} \mathbb{P}(J_{n+1} - t > s_1, T_{n+2} > s_2, T_{n+m} > s_m \mid N_t = n) &= \frac{\mathbb{P}(J_t \leq t, J_{n+1} - t > s_1, T_{n+2} > s_2, T_{n+m} > s_m)}{\mathbb{P}(N_t = n)} \\ &= \frac{\mathbb{P}(J_t \leq t, J_{n+1} - t > s_1) \mathbb{P}(T_{n+2} > s_2, T_{n+m} > s_m)}{\mathbb{P}(N_t = n)} = \mathbb{P}(T_1 > s_1) \mathbb{P}(T_{n+2} > s_2, T_{n+m} > s_m) \\ &= \mathbb{P}(T_1 > s_1, T_m > s_m) \end{aligned}$$

□

Corolario 9.1.1. Propiedad de regeneración de los conteos. Para todo $n \in \mathbb{N}$, $m \geq 2$, $t, s \geq 0$,

$$\mathbb{P}(J_{n+m} \leq t + s < J_{n+m+1} \mid N_t = n) = \mathbb{P}(J_m \leq s < J_{m+1}). \quad (9.7)$$

Demostración.

$$\begin{aligned} \mathbb{P}(J_{n+m} \leq t + s < J_{n+m+1} \mid N_t = n) &= \frac{\mathbb{P}(J_{n+m} \leq t + s < J_{n+m+1}, N_t = n)}{\mathbb{P}(N_t = n)} \\ &= \frac{\mathbb{P}(J_{n+1} - t + T_{n+2} + \dots + T_{n+m} \leq s < J_{n+1} - t + T_{n+2} + \dots + T_{n+m+1}, J_n \leq t < J_{n+1})}{\mathbb{P}(N_t = n)} \\ &= \mathbb{P}(J_{n+1} - t + T_{n+2} + \dots + T_{n+m} \leq s < J_{n+1} - t + T_{n+2} + \dots + T_{n+m+1} \mid N_t = n) \\ &= \mathbb{P}(T_1 + \dots + T_m \leq s < T_1 + \dots + T_{m+1}) = \mathbb{P}(J_m \leq s < J_{m+1}), \end{aligned}$$

donde el último paso usa que $J_{n+1} - t \mid \{N_t = n\} \sim \text{Exp}(\lambda)$ dado el lema anterior.

□

Definición 9.1.2. Incrementos. Sea $(X_t : t \geq 0)$ un proceso estocástico con $X_0 = 0$ c.s. Se dice que $(X_t : t \geq 0)$ tiene incrementos estacionarios si

$$\forall_{t,s \geq 0} \quad X_{t+s} - X_t \stackrel{d}{=} X_s. \quad (9.8)$$

$(X_t : t \geq 0)$ tiene incrementos independientes si para cada $k \in \mathbb{N}$ y cada escogencia $0 \leq t_0 < t_1 < \dots < t_k$, las variables aleatorias $X_{t_0}, X_{t_1} - X_{t_0}, \dots, X_{t_k} - X_{t_{k-1}}$ son independientes.

Lema 9.1.3. Incrementos estacionarios del proceso de Poisson. El proceso de Poisson $(N_t : t \geq 0)$ tiene incrementos estacionarios.

Demostración. Note que por el colorario anterior se tiene que

$$\begin{aligned} \mathbb{P}(N_t = n, N_{t+s} - N_t = m) &= \mathbb{P}(N_t = n, N_{t+s} = m + n) = \mathbb{P}(N_t = n) \mathbb{P}(N_{t+s} = m + n \mid N_t = n) \\ \mathbb{P}(N_t = n) \mathbb{P}(J_{n+m} \leq t + s < J_{n+m+1} \mid N_t = n) &= \mathbb{P}(N_t = n) \mathbb{P}(J_m \leq s < J_{m+1}) = \mathbb{P}(N_t = n) \mathbb{P}(N_s = m) \end{aligned}$$

□

Lema 9.1.4. Incrementos independientes del proceso de Poisson. El proceso de Poisson $(N_t : t \geq 0)$ tiene incrementos independientes.

Demostración. Por el lema anterior se tiene que

$$\begin{aligned} \mathbb{P}(N_{t_0} = m_0, N_{t_1} - N_{t_0} = m_1, \dots, N_{t_n} - N_{t_{n-1}} = m_n) \\ = \mathbb{P}(N_{t_0} = m_0) \mathbb{P}(N_{s_1} = m_1) \dots \mathbb{P}(N_{s_n} = m_n) \\ \mathbb{P}(N_{t_0} = m_0) \mathbb{P}(N_{t_1} - N_{t_0} = m_1) \dots \mathbb{P}(N_{t_n} - N_{t_{n-1}} = m_n) \end{aligned}$$

□

Definición 9.1.3. Proceso de Lévy. Un proceso estocástico $(L_t : t \geq 0)$ se llama un proceso de Lévy si cumple con lo siguiente:

1. $L_0 = 0$ c.s.
2. $(L_t : t \geq 0)$ tiene incrementos estacionarios e independientes.
3. $(L_t : t \geq 0)$ es un proceso càdlàg.

Teorema 9.1.1. Caracterización del proceso de Poisson como proceso de Lévy. Todo proceso de Poisson $(N_t : t \geq 0)$ es un proceso de Lévy para el cual cada N_t tiene distribución de Poisson de parámetro λt .

Lema 9.1.5. Recíproco de la caracterización de Poisson. Sea $N = (N_t : t \geq 0)$ un proceso de Lévy tal que $N_t \sim \text{Poisson}(\lambda t)$ para algún $\lambda > 0$. Entonces N es un proceso de Poisson en el sentido ya definido, existen tiempos de llegada $J_0 = 0$, $J_n(\omega) = \inf\{t > 0 : N_t(\omega) = n\}$ con $J_n \sim \text{Gamma}(n, \lambda)$, y los interarribos $T_n = J_n - J_{n-1}$ son i.i.d. con distribución exponencial de parámetro λ .

No se demuestran

Definición 9.1.4. Proceso de saltos. Si $(X_t : t \geq 0)$ es un proceso càdlàg, para cada $t \geq 0$ definimos el salto en tiempo t como $\Delta X_t = X_t - X_{t-}$, donde $X_{t-}(\omega)$ es el límite por la izquierda de la función $s \mapsto X_s(\omega)$ en t . El proceso de saltos se define como $\Delta X = (\Delta X_t : t \geq 0)$.

Lema 9.1.6. Saltos unitarios en el proceso de Poisson. Si $(N_t : t \geq 0)$ es de Poisson, el proceso de salto $(\Delta N_t : t \geq 0)$ solamente toma los valores 0 y 1.

Voy a intentar ser mas formal xd.

Demostración. Dado que el proceso $N_t \in \mathbb{N}$ es claro que $\Delta N_t \in \mathbb{N}$. Ahora, suponga que $\Delta N_t \geq 2$ con $N_t = n$ para algún n , lo que es equivalente a decir que $J_n = J_{n+1} = t$ (si el $J_n < t$ entonces $N_{t-} = n - 1$, lo que no cumpliría con la hipótesis) para algún n , en cuyo caso $\mathbb{P}(T_{n+1} = 0) = 0$ dado que $T_i \sim \text{Exp}(\lambda)$, entonces iterando sobre n tenemos que

$$\mathbb{P}(\Delta N_t \geq 1 \text{ para algun } t) \leq \sum_{n=1}^{\infty} \mathbb{P}(T_{n+1} = 0) = 0$$

Por lo tanto $\Delta N_t \in \{0, 1\}$ c.s. $\forall t$.

□

Teorema 9.1.2. Caracterización de procesos de Lévy con saltos unitarios. Si $(L_t : t \geq 0)$ es un proceso de Lévy que toma valores en $\mathbb{N}$, cuyas trayectorias son crecientes (c.s.), y tal que $(\Delta L_t : t \geq 0)$ solamente toma los valores 0 y 1, entonces L es un proceso de Poisson de la forma ya definida.

Demostración. Tome $T_1 = \inf\{t > 0 : L_t \geq 1\}$ y $T_{n-1} = \inf\{t > 0 : L_t - L_{T_{n-1}} \geq 1\}$, de forma que se puede ver que $f(t) := \mathbb{P}(T_1 > t) = \mathbb{P}(L_t = 0)$ por los incrementos independientes y estacionarios se tiene que

$$f(t+s) = \mathbb{P}(L_{t+s} = 0) = \mathbb{P}(L_t = 0, L_s = 0) = f(t)f(s)$$

por lo que $f(\cdot)$ satisface la ecuación de Cauchy $f(t+s) = f(t)f(s)$ donde $f(0) = \mathbb{P}(L_0 = 0) = 1$, de forma que dado que L es cadlag, es continuo en probabilidad, de forma que $f(\cdot)$ es continua y se cumple que $f(t) = e^{-\lambda t}$ para algún λ . En cuyo caso $T_1 \sim \text{Exp}(\lambda)$.

Ahora, note que T_n es un tiempo de llegada pues $\{T_n \leq t\} = \{L_t \geq n\} \in \mathcal{F}_t$. Como los incrementos de L son independientes y estacionarios, el tiempo entre dos llegadas consecutivas, $\tau_n = T_n - T_{n-1}$, tiene la misma distribución que el primer tiempo de llegada, es decir, $\tau_n \sim \text{Exp}(\lambda)$. Además, la independencia de los incrementos garantiza que las variables $\tau_1, \dots, \tau_n$ son independientes entre sí. En consecuencia, los $\{\tau_n\}$ son i.i.d. $\text{Exp}(\lambda)$, y L es un proceso de Poisson de tasa λ .

□

Lema 9.1.7. Ausencia de saltos en tiempos fijos de Lévy. Si $L = (L_t : t \geq 0)$ es un proceso de Lévy, entonces para todo $t > 0$ se cumple que $\Delta L_t = 0$ casi seguramente.

Demostración. Note que por la continuidad en probabilidad del proceso, se tiene que

$$\lim_{s \rightarrow t} \mathbb{P}(|L_s - L_t| > \varepsilon) = 0$$

de forma que si $s \nearrow t$, se tiene que

$$\mathbb{P}(|L_{t-} - L_t| > \varepsilon) \lim_{s \nearrow t} \mathbb{P}(|L_s - L_t| > \varepsilon) = 0, \quad \forall \varepsilon > 0.$$

en cuyo caso $\Delta L_t = 0$ c.s.

□

Lema 9.1.8. Martingala de Lévy con media cero. Suponga que $(L_t : t \geq 0)$ es un proceso de Lévy con media 0, es decir $\mathbb{E}(L_t) = 0 \forall t > 0$, y que $(\mathcal{F}_t : t \geq 0)$ es su filtración natural. Entonces $(L_t : t \geq 0)$ es una $(\mathcal{F}_t)$ -martingala.

Demostración. Tome $0 \leq s \leq t$, entonces por independencia de los procesos se sigue que

$$\mathbb{E}(L_t | \mathcal{F}_s) = \mathbb{E}(L_t - L_s + L_s | \mathcal{F}_s) = \mathbb{E}(L_t - L_s) + L_s = L_s$$

□

Corolario 9.1.2. Martingala compensada del proceso de Poisson. Suponga que $(N_t : t \geq 0)$ es de Poisson y $(\mathcal{F}_t : t \geq 0)$ su filtración natural. Entonces, el proceso compensado de Poisson $(N_t - \lambda t : t \geq 0)$ es una $(\mathcal{F}_t)$ -martingala.

Demostración. Realizando la misma analogía que lo anterior se tiene que

$$\mathbb{E}(N_t - t\lambda | \mathcal{F}_s) = N_s - t\lambda + \mathbb{E}(N_t - N_s) = N_s - t\lambda + t\lambda - s\lambda.$$

Utilizando el hecho que la suma de Poisson es Poisson.

□

9.2 Procesos Compuestos de Poisson

Definición 9.2.1. Proceso compuesto de Poisson. Sea $(N_t : t \geq 0)$ un proceso de Poisson con parámetro $\lambda > 0$ y sean $X_1, X_2, \dots$ i.i.d. que son independientes de $(N_t : t \geq 0)$. Sea $S_0 = 0$ y $S_n = X_1 + \dots + X_n$ para $n \geq 1$. El proceso compuesto de Poisson es el proceso $(Y_t : t \geq 0)$ definido por

$$Y_t(\omega) = S_{N_t(\omega)}(\omega) := \sum_{k=1}^{N_t(\omega)} X_k(\omega), \quad (9.9)$$

donde la suma se interpreta como 0 si $N_t(\omega) = 0$.

Teorema 9.2.1. Proceso compuesto de Poisson como proceso de Lévy. El proceso compuesto de Poisson $(Y_t : t \geq 0)$ es un proceso de Lévy.

Demostración. La primera propiedad es clara por definicion, sumado a ello la suma de funciones continuas es continua, en esta caso cadlag. Ahora para incrementos estacionarios sea $0 \leq t_0 < t_1$ con $B_0, B_1 \in \mathcal{B}(\mathbb{R})$, se tiene que

$$\begin{aligned} \mathbb{P}(Y_{t_0} \in B_0, Y_{t_1} - Y_{t_0} \in B_1) &= \mathbb{P}(S_{N_{t_0}} \in B_0, S_{N_{t_1}} - S_{N_{t_0}} \in B_1) \\ &= \sum_{n_0 \in \mathbb{N}} \sum_{n_1 \in \mathbb{N}} \mathbb{P}(S_{n_0} \in B_0, S_{n_1+n_0} - S_{n_0} \in B_1, N_{t_0} = n_0, N_{t_1} - N_{t_0} = n_1) \end{aligned}$$

Por la independencia de las variables $N, X_1, \dots, X_n$ y los incrementos de N se tiene que

$$= \sum_{n_0 \in \mathbb{N}} \sum_{n_1 \in \mathbb{N}} \mathbb{P}(S_{n_0} \in B_0) \mathbb{P}(S_{n_1+n_0} - S_{n_0} \in B_1) \mathbb{P}(N_{t_0} = n_0) \mathbb{P}(N_{t_1} - N_{t_0} = n_1)$$

Por lo incrementos estacionarios y la independencia de N de los X_i se tiene que

$$= \sum_{n_0 \in \mathbb{N}} \sum_{n_1 \in \mathbb{N}} \mathbb{P}(N_{t_0} = n_0, S_{n_0} \in B_0) \mathbb{P}(N_{t_1-t_0} = n_1, S_{n_1} \in B_1)$$

$$\mathbb{P}(S_{N_{t_0}} \in B_0) \mathbb{P}(S_{N_{t_1-t_0}} \in B_1) = \mathbb{P}(Y_{t_0} \in B_0) \mathbb{P}(Y_{t_1-t_0} \in B_1)$$

Para la independencia se hace lo mismo pero sobre $n_0, \dots, n_k$.

□

Lema 9.2.1. Existencia de momentos en el proceso compuesto de Poisson. Si las variables aleatorias X_k tienen momento de orden $p \geq 1$, el proceso compuesto de Poisson ($Y_t : t \geq 0$) tiene también momentos de orden p . Es decir, si $\mathbb{E}(|X_k|^p) < \infty$, entonces $\mathbb{E}(|Y_t|^p) < \infty \forall t \geq 0$.

Demostración. Note que

$$\begin{aligned} \mathbb{E}[|Y_t|^p] &= \sum_{n=0}^{\infty} \mathbb{E} \left[\left| \sum_{k=1}^n X_k(\omega) \right|^p \right] \mathbb{E}[N_t = n] = \sum_{n=0}^{\infty} \mathbb{E} \left[\left| \sum_{k_1+\dots+k_n=p} \binom{p}{k_1, \dots, k_n} X_1^{n_1} \dots X_k^{n_k} \right|^p \right] \frac{e^{-\lambda t} (\lambda t)^n}{n!} \\ &\leq \sum_{n=0}^{\infty} \max_{k_1+\dots+k_n=p} (\mathbb{E}[X_1^{n_1}] \dots \mathbb{E}[X_k^{n_k}]) \frac{e^{-\lambda t} (\lambda t)^n}{n!} n^p \end{aligned}$$

□

Lema 9.2.2. Función característica del proceso compuesto de Poisson. Sea $\psi : \mathbb{R} \rightarrow \mathbb{C}$ la función característica común de las variables $X_1, X_2, \dots$, es decir $\psi(u) = \mathbb{E}(e^{iuX_1}) \forall u \in \mathbb{R}$. Sea ($Y_t : t \geq 0$) el proceso compuesto de Poisson. Entonces, para cada $t \geq 0$, la función característica de Y_t está dada por

$$\mathbb{E}(e^{iuY_t}) = \exp(\lambda t(\psi(u) - 1)), \quad \forall u \in \mathbb{R}. \quad (9.10)$$

Demostración. Note que

$$\mathbb{E}(e^{iuY_t}) = \sum_{n=0}^{\infty} \mathbb{E}(e^{iuS_n}) \mathbb{P}(N_t = n) = \sum_{n=0}^{\infty} (\mathbb{E}(e^{iuX_1}))^n \frac{e^{-\lambda t} (\lambda t)^n}{n!} = \sum_{n=0}^{\infty} (\psi(u))^n \frac{e^{-\lambda t} (\lambda t)^n}{n!} = e^{\lambda t(\psi(u) - 1)}$$

□

9.3 El Movimiento Browniano

9.3.1 Movimiento Browniano y Procesos Gaussianos

Definición 9.3.1. Movimiento Browniano estándar. Un proceso estocástico $B = (B_t : t \geq 0)$ se llama un movimiento Browniano estándar (también llamado proceso de Wiener) si satisface

1. $B_0 = 0$ c.s.
2. B tiene incrementos independientes.
3. $\forall 0 \leq s \leq t, B_t - B_s \stackrel{d}{=} \mathcal{N}(0, t - s)$, donde $\mathcal{N}(0, t - s)$ denota la distribución Gaussiana con media 0 y varianza $t - s$.
4. B tiene trayectorias continuas.

Teorema 9.3.1. Movimiento Browniano estándar como proceso de Lévy. El movimiento Browniano estándar ($B_t : t \geq 0$) es un proceso de Lévy con función característica $\varphi(u) = \exp(-tu^2/2)$.

Demostración. Las trayectorias continuas implica que es cadlag primero que todo. La primera y segunda propiedad se cumplen, además note que sus trayectorias son estacionarias ya que

$$B_t - B_s \stackrel{d}{=} \mathcal{N}(0, t - s) \stackrel{d}{=} B_{t-s} - B_0 = B_{t-s}$$

y dado que $\varphi_X(t) = \exp(i\mu t - \frac{\sigma^2 t^2}{2})$ se cumple la igualdad de la función característica.

□

Proposición 9.3.1. Martingalas y el Browniano. Si $(B_t : t \geq 0)$ es Browniano estándar y $(\mathcal{F}_t : t \geq 0)$ es su filtración natural, los siguientes procesos son una $(\mathcal{F}_t)$ -martingala

1. $(B_t : t \geq 0)$.
2. $(B_t^2 - t : t \geq 0)$.
3. $\left(\exp\left(uB_t - \frac{u^2 t}{2}\right) : t \geq 0\right)$ para cada $u \in \mathbb{R}$.

Demostración. La primera es consecuencia del lema de martingalas de Levy con media cero. Para el segundo note que $B_t^2 = B_s^2 + 2B_s(B_t - B_s) + (B_t - B_s)^2$, entonces se sigue (procedimiento mecánico) que

$$\mathbb{E}(B_t^2 - t \mid \mathcal{F}_s) = B_s^2 + 2B_s\mathbb{E}(B_t - B_s) + \mathbb{E}((B_t - B_s)^2) - t = B_s^2 + 2B_s \cdot 0 + (t - s) - t$$

Para la tercera note que

$$\mathbb{E}(e^{uB_t - \frac{u^2 t}{2}} \mid \mathcal{F}_s) = e^{uB_s} \mathbb{E}(e^{u(B_t - B_s)}) e^{\frac{u^2 s}{2}} = e^{uB_s - \frac{u^2 s}{2}}$$

□

Definición 9.3.2. Distribución Gaussiana multivariada. Un vector aleatorio d -dimensional $V = (v_1, v_2, \dots, v_d)^T$ se dice que tiene distribución Gaussiana multivariada d -dimensional con media μ y covarianza Σ si tiene densidad conjunta

$$(2\pi)^{-d/2} (\det \Sigma)^{-1/2} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right), \quad \forall x \in \mathbb{R}^d.$$

donde $\mu = (\mu_1, \mu_2, \dots, \mu_d)^T$ con $\mu_i = \mathbb{E}(v_i)$ para $i = 1, \dots, d$, y $\Sigma = (\sigma_{ij})_{i,j=1,\dots,d}$ con $\sigma_{ij} = \text{Cov}(v_i, v_j) = \mathbb{E}[(v_i - \mu_i)(v_j - \mu_j)]$ para $i, j = 1, \dots, d$.

Lema 9.3.1. Independencia Gaussiana. Si $V = (v_1, v_2, \dots, v_d)^T$ es Gaussiana multivariada, las variables aleatorias $v_1, v_2, \dots, v_d$ son independientes si y sólo si Σ es una matriz diagonal.

Demostración. Si las variables son independientes, entonces la covarianza es 0 a menos que las variables sean la misma. Ahora, si la matriz es diagonal, note que entonces

$$(x - \mu)^T \Sigma^{-1} (x - \mu) = (x_1 - \mu_1, x_2 - \mu_2, \dots, x_d - \mu_d) \begin{pmatrix} \sigma_{11}^{-1} & 0 & \dots & 0 \\ 0 & \sigma_{22}^{-1} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_{dd}^{-1} \end{pmatrix} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \\ \vdots \\ x_d - \mu_d \end{pmatrix} = \sum_{i=1}^d \frac{(x_i - \mu_i)^2}{\sigma_{ii}}$$

por lo tanto las distribuciones se puede factorizar, en cuyo caso, las distribuciones son independientes. □

Proposición 9.3.2. Caracterización Gaussiana. Un vector aleatorio d -dimensional V es Gaussiano multivariado si y sólo si toda combinación lineal $\theta_1 v_1 + \dots + \theta_n v_n$ tiene distribución Gaussiana univariada.

Demostración. Si $\theta = (\theta_1, \dots, \theta_n) \in \mathbb{R}^d$, $Z_\theta = \theta_1 v_1 + \dots + \theta_n v_n$ gaussiano univariado. Entonces $\mathbb{E}(Z_\theta) = \theta^T \mu$, $\text{Var}(Z_\theta) = \theta^T \Sigma \theta$. En cuyo caso

$$\mathbb{E}(e^{i\theta^T V}) = \mathbb{E}(e^{iZ_\theta}) = \exp(i\theta^T \mu - \frac{1}{2}\theta^T \Sigma \theta),$$

de donde V tiene función característica Gaussiana multivariada.

En la otra dirección, si V es Gaussiano multivariado, dado $s \in \mathbb{R}$ y $\theta \in \mathbb{R}^d$, aplicando (3.8) al vector $s\theta$ y repitiendo los cálculos en orden inverso, se concluye que Z_θ es Gaussiano univariado con parámetros $\alpha = \theta^T \mu$, $\beta^2 = \theta^T \Sigma \theta$. □

Definición 9.3.3. Gaussiano. Un proceso estocástico $(X_t : t \geq 0)$ se dice Gaussiano si para cada escogencia $0 \leq t_1 < t_2 < \dots < t_d$, el vector aleatorio $(X_{t_1}, X_{t_2}, \dots, X_{t_d})$ es Gaussiano multivariado. Su función de media se define por $\mu(t) = \mathbb{E}X_t$ y su función de covarianza por $\gamma(s, t) = \text{Cov}(X_s, X_t)$.

Teorema 9.3.2. Caracterización del Movimiento Browniano. Un proceso estocástico $(B_t : t \geq 0)$ es un movimiento Browniano si y sólo si es un proceso Gaussiano con función de media $\mu_t = 0 \ \forall t \geq 0$, con función de covarianza $\gamma(s, t) = s \wedge t \ \forall s, t \geq 0$, y con trayectorias continuas.

Demostración. (“ $\Rightarrow$ ”) Suponga que $(B_t : t \geq 0)$ es Browniano. Para probar que el proceso es Gaussiano, sean $0 \leq t_1 < t_2 < \dots < t_d$ y $\theta = (\theta_1, \dots, \theta_d) \in \mathbb{R}^d$. Se tiene

$$\theta_1 B_{t_1} + \dots + \theta_d B_{t_d} = \sum_{j=1}^d (\theta_j + \dots + \theta_d) (B_{t_j} - B_{t_{j-1}}),$$

con $t_0 = 0$. Cada incremento es Gaussiano independiente, por lo que la combinación lineal es Gaussiana. Así, el vector $(B_{t_1}, \dots, B_{t_d})$ es Gaussiano multivariado y (B_t) es Gaussiano. Además, $\mu(t) = \mathbb{E}[B_t] = 0$ y si $0 \leq s < t$ entonces $\text{Cov}(B_s, B_t) = \mathbb{E}(B_s B_t) = \mathbb{E}(B_s^2) + \mathbb{E}(B_s(B_t - B_s)) = s + 0$ de forma que $\text{Cov}(B_s, B_t) = s \wedge t$.

(“ $\Leftarrow$ ”) Note que para la primera propiedad se cumple

$$\mathbb{E}[B_0^2] = \text{Cov}(B_0, B_0) = 0.$$

Para la tercera propiedad, si $0 \leq s, t$, como el proceso es Gaussiano, por la proposición anterior se tiene que $B_{t+s} - B_s$ es Gaussiano univariado. Además,

$$\mathbb{E}[B_{t+s} - B_s] = \mathbb{E}[B_{t+s}] - \mathbb{E}[B_s] = 0,$$

$$\text{Var}(B_{t+s} - B_s) = \text{Var}(B_{t+s}) + \text{Var}(B_s) - 2\text{Cov}(B_{t+s}, B_s) = (t+s) + s - 2s = t.$$

Por tanto, $B_{t+s} - B_s \sim \mathcal{N}(0, t)$, lo que demuestra la propiedad 3. En cuanto a la segunda propiedad, corresponde a la independencia de los incrementos. Sean $0 \leq t_1 < t_2 < \dots < t_d$. El vector de incrementos

$$(B_{t_1}, B_{t_2} - B_{t_1}, \dots, B_{t_d} - B_{t_{d-1}})$$

tiene matriz de covarianza diagonal. En efecto, si $i < j$, como $\gamma(s, t) = s \wedge t$, se cumple

$$\mathbb{E}[(B_{t_i} - B_{t_{i-1}})(B_{t_j} - B_{t_{j-1}})] = \mathbb{E}[B_{t_i} B_{t_j}] - \mathbb{E}[B_{t_i} B_{t_{j-1}}] - \mathbb{E}[B_{t_{i-1}} B_{t_j}] + \mathbb{E}[B_{t_{i-1}} B_{t_{j-1}}] = t_i - t_i - t_{i-1} + t_{i-1} = 0$$

De este modo se concluye que B tiene incrementos independientes. Finalmente, la cuarta propiedad, la continuidad de trayectorias, está incluida dentro de las suposiciones. □

Proposición 9.3.3. Invariancias del Movimiento Browniano. Sea $B = (B_t : t \geq 0)$ el movimiento Browniano estándar. Los siguientes procesos estocásticos son un movimiento Browniano estándar

1. (Reflexión) $(-B_t : t \geq 0)$.
2. (Traslación en el tiempo) $(B_{t+a} - B_a : t \geq 0)$ para toda $a > 0$.
3. (Auto-similitud) $(cB_{t/c^2} : t \geq 0)$ para todo $c > 0$.
4. (Inversión en el tiempo) $(\tilde{B}_t : t \geq 0)$ definido como $\tilde{B}_0 = 0$ y $\tilde{B}_t = tB_{1/t}$ si $t > 0$.

Demostración. La primera es inmediata. Para la segunda simplemente note que dado que es un proceso de Levy esos incrementos estacionarios son independientes con la misma distribución que el teorema de

Movimiento Browniano estandar como proceso de Levy. Para la tercera note que la primera propiedad se cumple $cB_{0/c^2} = cB_0 = 0$; para la independencia note simplemente que si $0 \leq s < t$ entonces $0 \leq s/c^2 < t/c^2$ y de ahí mismo se deriva la independencia de los incrementos; para la tercera note que $cB_{t/c^2 - cB_{s/c^2}} \stackrel{d}{=} \mathcal{N}(0, c^2(t/c^2 - s/c^2)) = \mathcal{N}(0, t - s)$; y por ultimo dado que la transformación es una función monotona, las trayectorias siguen siendo continuas.

Sea Ω_0 un conjunto de probabilidad 1 tal que para cada $\omega \in \Omega_0$ la trayectoria $s \mapsto B_s(\omega)$ es continua en $(0, \infty)$. Note que para $t = 0$ la continuidad se obtiene de dos hechos: primero, como $\mathbb{Q}$ es contable, la distribución de $(B_t : t \in \mathbb{Q} \cap [0, \infty))$ coincide con la de $(B_t : t \in [0, \infty))$, y por tanto para casi todo $\omega \in \Omega_0$,

$$\lim_{s \downarrow 0, s \in \mathbb{Q}} B_s(\omega) = 0.$$

Segundo, como $\mathbb{Q} \cap (0, \infty)$ es denso y $s \mapsto B_s(\omega)$ es continua en $(0, \infty)$, se concluye que para casi todo $\omega \in \Omega_0$,

$$0 = \lim_{s \downarrow 0, s \in \mathbb{Q}} B_s(\omega) = \lim_{s \downarrow 0} B_s(\omega).$$

De este modo las trayectorias de B son continuas casi seguramente. Finalmente, por el teorema anterior se concluye que B es un movimiento Browniano estándar. □

Proposición 9.3.4. Construcción de Wiener del Browniano. Sea $a_k, k \in \mathbb{N}$, una sucesión de variables aleatorias i.i.d. con distribución normal estándar. Defina, para $t \in [0, \pi]$,

$$W_t = \frac{ta_0}{\pi} + \frac{2}{\pi} \sum_{k=1}^{\infty} \frac{a_k}{k} \sin(kt). \quad (9.11)$$

La serie converge uniformemente en $[0, \pi]$ con probabilidad 1 y el proceso $(W_t : t \in [0, \pi])$ satisface las condiciones del teorema anterior, siendo por tanto un movimiento Browniano estándar en $[0, \pi]$. Para extenderlo a $[0, \infty)$, se consideran copias independientes $W^{(n)}$ y se define B_t por concatenación en intervalos de longitud π .

Proposición 9.3.5. Browniano en dimensión d . Un proceso estocástico en $\mathbb{R}^d$ es una colección de vectores aleatorios $(X_t : t \in T)$ con valores en $\mathbb{R}^d$. Cada X_t puede escribirse como

$$X_t = (X_t^1, \dots, X_t^d), \quad (9.12)$$

donde X_t^k son las componentes reales. Así, $(X_t : t \in T)$ puede verse como un vector formado por d procesos reales $(X_t^k : t \in T)$, $k = 1, \dots, d$.

Definición 9.3.4. Movimiento Browniano estándar d -dimensional. Un proceso estocástico $B = (B_t : t \geq 0)$ en $\mathbb{R}^d$ se llama un movimiento Browniano estándar d -dimensional si satisface

1. $B_0 = 0$ c.s.
2. B tiene incrementos independientes.
3. $\forall 0 \leq s \leq t$, $B_t - B_s$ tiene distribución Gaussiana d -dimensional con vector de medias $\mu = 0$ y matriz de covarianza $\Sigma = (t - s)I_d$, donde I_d es la identidad $d \times d$.
4. B tiene trayectorias continuas.

Teorema 9.3.3. Equivalencia del Browniano Multidimensional. Sea $B = (B_t : t \geq 0)$ un proceso estocástico en $\mathbb{R}^d$ y sean $B^k = (B_t^k : t \geq 0)$ con $k = 1, \dots, d$ sus componentes. Son equivalentes

1. $B = (B_t : t \geq 0)$ es un movimiento Browniano estándar d -dimensional.
2. Para cada $k = 1, \dots, d$, $(B_t^k : t \geq 0)$ es un movimiento Browniano estándar (unidimensional) y los procesos $B^1, \dots, B^d$ son independientes.

La demostración es casi directa usando la independencia gaussiana.

9.3.2 Las Trayectorias del Movimiento Browniano

Definición 9.3.5. Varianza. Sea $X = (X_t : t \geq 0)$ un proceso estocástico con trayectorias càdlàg. Sean $0 \leq a < b$ y dada una partición $\Delta_n : a = t_{n,0} < t_{n,1} < \dots < t_{n,N(n)} = b$ de $[a, b]$

1. La variación del proceso X en la partición Δ_n se define como

$$\text{Var}_{\Delta_n}(X)(\omega) = \sum_{k=1}^{N(n)} |X_{t_{n,k}}(\omega) - X_{t_{n,k-1}}(\omega)|.$$

Se dice que X es un proceso de variación finita en $[a, b]$ si

$$\mathbb{P}\left(\sup_{\Delta_n} \text{Var}_{\Delta_n}(X) < \infty\right) = 1.$$

2. Se dice que X es de variación cuadrática finita si existe un proceso estocástico $([X]_t : t \geq 0)$ tal que para cada t y cada sucesión Δ_n de particiones de $[0, t]$ con $|\Delta_n| \rightarrow 0$

$$[X]_t(\omega) = \mathbb{P}\text{-}\lim_{|\Delta_n| \rightarrow 0} \sum_{k=1}^{N(n)} (X_{t_{n,k}}(\omega) - X_{t_{n,k-1}}(\omega))^2.$$

Teorema 9.3.4. Variación del Movimiento Browniano. El movimiento Browniano estándar es de variación cuadrática finita y de hecho $[B]_t = t$ (convergencia en $L^2(\Omega)$). Por otro lado, las trayectorias del movimiento Browniano estándar son c.s. de variación infinita en todo subintervalo de $[0, \infty)$.

Demostración. Sea Δ_n una sucesión de particiones de $[0, t]$ tal que $|\Delta_n| \rightarrow 0$. Definimos

$$Y_n(\omega) = \sum_{k=1}^{N(n)} (B_{t_{n,k}}(\omega) - B_{t_{n,k-1}}(\omega))^2, \quad \forall \omega \in \Omega.$$

Como el Browniano tiene incrementos independientes y gaussianos, se cumple

$$\mathbb{E}[Y_n] = \sum_{k=1}^{N(n)} \mathbb{E}[(B_{t_{n,k}} - B_{t_{n,k-1}})^2] = \sum_{k=1}^{N(n)} (t_{n,k} - t_{n,k-1}) = t.$$

Además,

$$\text{Var}(Y_n) = \sum_{k=1}^{N(n)} \text{Var}((B_{t_{n,k}} - B_{t_{n,k-1}})^2).$$

Como $B_{t_{n,k}} - B_{t_{n,k-1}} \sim \mathcal{N}(0, t_{n,k} - t_{n,k-1})$, su momento de cuarto orden es $3(t_{n,k} - t_{n,k-1})^2$, y por tanto

$$\text{Var}(Y_n) \leq 3t|\Delta_n| \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

De este modo,

$$\lim_{n \rightarrow \infty} \mathbb{E}[|Y_n - t|^2] = 0,$$

lo que implica que $Y_n \rightarrow t$ en probabilidad. En conclusión, el Browniano es de variación cuadrática finita y se cumple

$$[B]_t = t \quad \text{c.s.}$$

Por otro lado, para probar que las trayectorias del Browniano son c.s. de variación infinita en cualquier intervalo, basta considerar $[0, t]$. Si la variación fuese finita, la continuidad de las trayectorias implicaría que

$$\sum_{k=1}^{N(n)} |B_{t_{n,k}} - B_{t_{n,k-1}}| \rightarrow 0,$$

cuando $|\Delta_n| \rightarrow 0$, lo cual contradice el hecho de que $[B]_t = t$ c.s. Por tanto, las trayectorias tienen variación infinita en todo intervalo. $\square$

Definición 9.3.6. Hölder continuidad. Sea $f : [a, b] \rightarrow \mathbb{R}$. Se dice que f es Hölder continua de orden $0 < \alpha < 1$ si existe una constante $c > 0$ tal que

$$|f(s) - f(t)| \leq c|s - t|^\alpha, \quad \forall a < s < t < b. \quad (9.13)$$

Teorema 9.3.5. Regularidad Hölder del Browniano. Para todo $0 < \alpha < 1/2$, el conjunto de todos los $\omega \in \Omega$ para los cuales la función $t \mapsto B_t(\omega)$ es Hölder continua de orden α tiene probabilidad 1.

Corolario 9.3.1. No Regularidad Hölder del Browniano. Si $\alpha > 1/2$, el conjunto de todos los $\omega \in \Omega$ para los cuales las trayectorias del Browniano estándar no son Hölder continuas de orden α para ningún intervalo tiene probabilidad 1.

Demostración. Es suficiente verificar el resultado para las trayectorias en el intervalo $[0, T]$. Procedemos por contradicción como en la última parte de la prueba del teorema anterior. Sea Δ_n una sucesión de particiones de $[0, T]$ tal que $|\Delta_n| \rightarrow 0$.

Supongamos que $|B_t(\omega) - B_s(\omega)| \leq c|t - s|^\alpha$ para todo $0 \leq s, t \leq T$ y que $\alpha > 1/2$. Por la condición de Hölder se obtiene

$$\sum_{k=1}^{N(n)} (B_{t_{n,k}}(\omega) - B_{t_{n,k-1}}(\omega))^2 \leq c^2 T |\Delta_n|^{2\alpha-1}.$$

El lado derecho converge a 0 cuando $n \rightarrow \infty$. Esto contradice que $[B]_t = t$ c.s.

En conclusión, las trayectorias del Browniano no pueden ser Hölder continuas de orden $\alpha > 1/2$. $\square$

Teorema 9.3.6. Módulo de continuidad de Lévy. Para el módulo de continuidad del Browniano en $[0, 1]$

$$m(\epsilon) = \sup\{|B_s - B_t| : 0 < s < t \leq 1, |s - t| \leq \epsilon\}, \quad (9.14)$$

se cumple que

$$\mathbb{P}\left(\limsup_{\epsilon \rightarrow 0} \frac{m(\epsilon)}{\sqrt{2\epsilon \ln(1/\epsilon)}} = 1\right) = 1. \quad (9.15)$$

Corolario 9.3.2. No Diferenciabilidad del Browniano. El conjunto de todos los $\omega \in \Omega$ para los cuales la función $t \mapsto B_t(\omega)$ no es diferenciable para ningún $t \geq 0$ tiene probabilidad 1.

Demostración. Consideremos las trayectorias del Browniano en el intervalo $[0, 1]$. Sea

$$G(c, \epsilon) = \{\omega \in \Omega : \exists s \in [0, 1] \text{ tal que } |B_s(\omega) - B_t(\omega)| \leq c|s - t|, \forall t \text{ con } |s - t| \leq \epsilon\}.$$

Sea D el conjunto de todos los $\omega \in \Omega$ para los cuales existe algún $s \in [0, 1]$ tal que la función $t \mapsto B_t(\omega)$ es diferenciable en s . Usando propiedades básicas de la diferenciación en una variable real se verifica que

$$D \subseteq \bigcup_{j=1}^{\infty} \bigcup_{k=1}^{\infty} G(j, 1/k).$$

Por el teorema anterior (caso $\alpha = 1$), cada evento $G(j, 1/k)$ tiene probabilidad cero. Como D es una unión contable de estos eventos, también tiene probabilidad cero.

En conclusión, las trayectorias del Browniano son casi seguramente no diferenciables en todo punto de $[0, 1]$. $\square$

Teorema 9.3.7. No Monotonía del Browniano. El conjunto de todos los $\omega \in \Omega$ para los cuales la función $t \mapsto B_t(\omega)$ no es monótona en ningún intervalo tiene probabilidad 1.

Demostración. Sea $[a, b] \subseteq [0, \infty)$ y Ω_0 un conjunto de probabilidad 1 tal que para cada $\omega \in \Omega_0$ la trayectoria $s \mapsto B_s(\omega)$ es continua. Definimos

$$A[a, b] = \{\omega \in \Omega_0 : s \mapsto B_s(\omega) \text{ es creciente en } [a, b]\}.$$

Para cada $n \geq 1$, sea $t_{n,k} = a + k(b-a)/n$ y

$$A_{n,k} = \{\omega \in \Omega_0 : B_{t_{n,k-1}}(\omega) \leq B_{t_{n,k}}(\omega)\}.$$

Por continuidad se tiene

$$A[a, b] = \bigcap_{n=1}^{\infty} \bigcap_{k=1}^n A_{n,k}.$$

Como $B_{t_{n,k}} - B_{t_{n,k-1}} \sim \mathcal{N}(0, (b-a)/n)$, se cumple $\mathbb{P}(A_{n,k}) = 1/2$. Además, los eventos $A_{n,k}$ son independientes, por lo que

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{n,k}\right) = \left(\frac{1}{2}\right)^n.$$

De aquí se deduce que $\mathbb{P}(A[a, b]) = 0$.

Finalmente, para un intervalo cualquiera $I \subseteq [0, \infty)$, el conjunto de trayectorias crecientes en I se expresa como unión de eventos $A[a, b]$ con $a, b \in \mathbb{Q} \cap I$, y por tanto también tiene probabilidad 0. De manera análoga se prueba que las trayectorias decrecientes en I tienen probabilidad 0. $\square$

Teorema 9.3.8. Comportamiento en el largo plazo. Suponga $t_n \nearrow \infty$

$$\mathbb{P}\left(\limsup_{n \rightarrow \infty} B_{t_n} = \infty\right) = 1 \quad (9.16)$$

$$\mathbb{P}\left(\liminf_{n \rightarrow \infty} B_{t_n} = -\infty\right) = 1 \quad (9.17)$$

Teorema 9.3.9. Comportamiento en el corto plazo. Sean

$$T_0^+(\omega) = \inf\{t > 0 : B_t(\omega) > 0\}, \quad T_0^-(\omega) = \inf\{t > 0 : B_t(\omega) < 0\}. \quad (9.18)$$

Se cumple que $\mathbb{P}(T_0^+ = 0) = 1$ y $\mathbb{P}(T_0^- = 0) = 1$.

Teorema 9.3.10. Descomposición de Lévy-Itô. Suponga que $(L_t : t \geq 0)$ es un proceso de Lévy. Existen dos números $b \in \mathbb{R}$ y $\sigma > 0$, un movimiento Browniano estándar $(B_t : t \geq 0)$, una martingala cuadrado integrable $(M_t : t \geq 0)$ que es a su vez un proceso de Lévy, y un proceso compuesto de Poisson $(Y_t : t \geq 0)$, todos los anteriores procesos estocásticos independientes, tales que

$$L_t = bt + \sigma^{1/2} B_t + M_t + Y_t, \quad \forall t \geq 0. \quad (9.19)$$

Demostración. La idea es verificar que la generadora de momentos de B_{t+s} condicionada a $\mathcal{F}_t$ coincide con la generadora de momentos condicionada respecto a B_t . Como la generadora de momentos determina en forma única la distribución de una variable aleatoria, esto prueba la propiedad de Markov.

En efecto, para $u \in \mathbb{R}$, $s, t \geq 0$:

$$\mathbb{E}[e^{uB_{t+s}} | B_t] = e^{uB_t} \mathbb{E}[e^{u(B_{t+s}-B_t)}].$$

Usando que $B_{t+s} - B_t \sim \mathcal{N}(0, s)$, se obtiene

$$= e^{uB_t} \exp\left(\frac{u^2 s}{2}\right).$$

Por otro lado, de la proposición anterior sabemos que

$$\mathbb{E}[e^{uB_{t+s}} | \mathcal{F}_t] = \exp\left(uB_t - \frac{u^2 t}{2}\right) \exp\left(\frac{u^2(t+s)}{2}\right).$$

Ambas expresiones coinciden, y por lo explicado al inicio se concluye que B es un proceso de Markov respecto a su filtración natural. $\square$

9.3.3 Movimiento Browniano y Procesos de Markov

Definición 9.3.7. Proceso de Markov. Sea $(X_t : t \geq 0)$ un proceso adaptado a la filtración $(\mathcal{F}_t : t \geq 0)$. Se dice que $(X_t : t \geq 0)$ es un proceso de Markov si $\forall s, t \geq 0$, $y \in \mathbb{R}$, se verifica la propiedad de Markov

$$\mathbb{P}(X_{t+s} \leq y | \mathcal{F}_t) = \mathbb{P}(X_{t+s} \leq y | X_t) \quad (\text{c.s.}) \quad (9.20)$$

Teorema 9.3.11. Propiedad de Markov del Browniano. El movimiento Browniano estándar $B = (B_t : t \geq 0)$ es un proceso de Markov respecto a su filtración natural $(\mathcal{F}_t : t \geq 0)$.

Definición 9.3.8. Función de transición. Sea $(X_t : t \geq 0)$ un proceso de Markov. Su función de transición se define como:

$$p_{s,t}(x, A) = \mathbb{P}(X_t \in A | X_s = x), \quad \forall 0 \leq s \leq t, A \in \mathcal{B}(\mathbb{R}), x \in \mathbb{R}. \quad (9.21)$$

Las ecuaciones de Chapman-Kolmogorov son

$$p_{r,t}(x, A) = \int_{\mathbb{R}} p_{s,t}(y, A) p_{r,s}(x, dy), \quad \forall 0 \leq r \leq s \leq t, A \in \mathcal{B}(\mathbb{R}), x \in \mathbb{R}. \quad (9.22)$$

Definición 9.3.9. Densidad de transición. Se dice que el proceso de Markov $(X_t : t \geq 0)$ tiene una densidad de transición si para cada $0 \leq s \leq t$, $x \in \mathbb{R}$, existe una función Borel-medible $y \mapsto k_{s,t}(x, y)$ tal que

$$p_{s,t}(x, A) = \int_A k_{s,t}(x, y) dy. \quad (9.23)$$

Si el proceso posee densidad de transición, las ecuaciones de Chapman-Kolmogorov se expresan como

$$k_{r,t}(x, z) = \int_{\mathbb{R}} k_{r,s}(x, y) k_{s,t}(y, z) dy, \quad \forall 0 \leq r \leq s \leq t, \quad x, z \in \mathbb{R}. \quad (9.24)$$

Teorema 9.3.12. Principio de Reflexión. Si τ es un tiempo de parada con respecto a la filtración natural $(\mathcal{F}_t : t \geq 0)$ del Browniano estándar $B = (B_t : t \geq 0)$, entonces el proceso $\tilde{B} = (\tilde{B}_t : t \geq 0)$ definido por

$$\tilde{B}_t(\omega) = \begin{cases} B_t(\omega) & \text{si } t < \tau(\omega), \\ B_{\tau(\omega)} - (B_t(\omega) - B_{\tau(\omega)}) & \text{si } t \geq \tau(\omega), \end{cases} \quad (9.25)$$

es también un movimiento Browniano estándar.

Parte III

10

Inferencia

Definición 10.0.1. Modelo estadístico. Un modelo estadístico es una representación matemática que nos ayuda a entender y analizar fenómenos aleatorios. Este está formado de los siguientes elementos

1. La relación entre una variable observable X_t y una hipotéticamente observable Y_t (la variable real)

$$\underbrace{X_t}_{\text{Observable}} = \underbrace{Y_t}_{\text{Hipotética}} + \underbrace{\epsilon_t}_{\text{Error}} \quad (10.1)$$

2. Distribución conjunta de una muestra de variables observables.
3. Parámetros que se asumen desconocidos y se consideran hipotéticamente observables (desconocidos).
4. (Opcional) La especificación de la distribución de ese parámetro consiste en una identificación de variables aleatorias.

Un estimador de un parámetro θ es una variable aleatoria ya que se construye a partir de los datos. Es esencial tener en cuenta su distribución condicionada a los datos observados.

Definición 10.0.2. V.A. Hipotéticamente observable. El término hipotéticamente observable se utiliza para una variable aleatoria que requeriría recursos infinitos para ser observada, como por ejemplo el límite (cuando $n \rightarrow \infty$) de los promedios muestrales de las primeras n observaciones.

Definición 10.0.3. Distribución conjunta. Es la probabilidad conjunta que ocurra cierto evento para dos o más v.a.

Definición 10.0.4. Inferencia estadística. La inferencia estadística es un proceso que nos permite hacer afirmaciones basadas en probabilidades sobre ciertas partes o la totalidad de un modelo estadístico.

Definición 10.0.5. Datos o muestra. Una muestra o conjunto de datos se refiere a una secuencia de variables aleatorias independientes, denotadas como $X_1, \dots, X_m$, que describen un fenómeno particular. Estas variables tienen una distribución que, en muchos casos, es desconocida.

Sin esto no tenemos modelo.

Definición 10.0.6. Parámetros. Un parámetro es una característica o conjunto de características que determinan la distribución conjunta de las variables aleatorias que estamos estudiando. El conjunto total de estos parámetros se denomina espacio paramétrico, y se denota como Ω .

10.1 Tipos de inferencia

Definición 10.1.1. Predicción. Una predicción es un tipo de inferencia estadística que consiste en tratar de anticipar el comportamiento de variables aleatorias que aún no han sido observadas $X_{n+1}, \dots$ con el comportamiento de las anteriores $X_1, \dots, X_n$. Cuando lo que se desea predecir es un parámetro de una distribución, este proceso se denomina estimación.

Definición 10.1.2. Problemas de Decisión Estadística. Un problema de decisión estadística es aquel en el que, tras analizar los datos, se debe elegir una decisión dentro de una clase disponible, cuyas consecuencias dependen del valor desconocido de algún parámetro. Este tipo de inferencia está estrechamente relacionado con la prueba de hipótesis.

Este anterior es el enfoque del curso

Definición 10.1.3. Diseños Experimentales. Un diseño experimental es un tipo de inferencia estadística en el que se determina la forma en que se recolectarán los datos, incluyendo el número de unidades experimentales y las condiciones bajo las cuales se obtendrán, con el fin de garantizar un grado de confianza adecuado en los resultados.

Definición 10.1.4. Estadístico. Función que toma $X_1, \dots, X_n$ y la convierte en un real.

$$T := r(X_1, \dots, X_n) \quad (10.2)$$

10.2 Densidades previas y conjugadas

En el modelo Bayesiano el parámetro θ tiene una distribución $\theta \sim \pi(\theta)$ y esta misma, es llamada la distribución previa. Antes de dar los datos, hay que tener una idea de como es la distribución del parámetro (La historia antes de los datos).

Definición 10.2.1. Distribución previa. La distribución previa definida sobre ω es la distribución del parámetro θ se denota por

$$\pi(\theta). \quad (10.3)$$

Definición 10.2.2. Análisis de Sensibilidad. El análisis de sensibilidad consiste en comparar las distribuciones posteriores que surgen de diferentes distribuciones previas, con el fin de evaluar cuánto efecto tiene la elección de la distribución previa en las respuestas a preguntas importantes.

Definición 10.2.3. Densidad impropia. Sea π una función positiva cuyo dominio esta en Ω . Si la integral de $\pi(\theta)$ sobre Ω es ∞ i.e. $\int \pi d\theta = \infty$, la distribución es llamada impropia.

Definición 10.2.4. Verosimilitud. Dado $X_1, \dots, X_n$ i.i.d. se define la verosimilitud de las v.a. como

$$L(\theta | X) := f(X | \theta) = f(X_1, \dots, X_n | \theta) = \prod_{i=1}^n f(X_i | \theta). \quad (10.4)$$

con $X = (X_1, \dots, X_n)$

10.3 Distribucion posterior

Definición 10.3.1. Distribución Posterior. En un problema de inferencia estadística con parámetro θ y variables aleatorias $X_1, \dots, X_n$ observadas, la distribución condicional de θ dado $X_1, \dots, X_n$ se denomina distribución posterior de θ . La función de probabilidad se denota por

$$\pi(\theta | x_1, \dots, x_n). \quad (10.5)$$

Teorema 10.3.1. Distribucion posterior. Dado $X_1, \dots, X_n$ i.i.d. se puede definir la distribución previa como

$$\pi(\theta | X) = \frac{L(\theta | X)\pi(\theta)}{g_n(X)} \quad (10.6)$$

donde g_n es la constante de normalización.

El teorema anterior es consecuencia del Teorema de Bayes. A los parámetros de la previa se les llama hiperparámetros.

Se va a entender como modelo a la unión de

1. El conjunto de datos $X_1, \dots, X_n$
2. La función de densidad.
3. El parámetro de la densidad θ .

Para identificar y trabajar con este modelo, lo desglosamos en las siguientes partes

1. Información previa ($\pi(\theta)$).
2. Verosimilitud.
3. Densidad posterior

$$\pi(\theta | X) \propto \pi(\theta)f_n(X | \theta) \quad (10.7)$$

4. Predicciones con datos nuevos

$$\pi(\theta | X_1, \dots, X_n) \propto f(X_n | \theta)\pi(\theta | X_1, \dots, X_{n-1}) \quad (10.8)$$

Bajo la suposición de independencia condicional, no hay diferencia en la posterior si los datos se obtienen secuencialmente.

$$g_n(X) = \int_{\Omega} f(X_n | \theta) = \mathbb{P}(X_n | X_1, \dots, X_{n-1}) \quad (10.9)$$

10.4 Distribuciones previas conjugadas

Definición 10.4.1. Familia conjugada. Si, independientemente de los datos observados, la densidad posterior pertenece a la misma familia que ψ , entonces decimos que ψ es una familia conjugada de previas.

Teorema 10.4.1. Conjugación en el modelo Bernoulli. Si $X \sim \text{Bernoulli}(\theta)$ y la previa es $\theta \sim \text{Beta}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Beta}(\alpha + x, \beta + 1 - x). \quad (10.10)$$

Demostración.

$$\begin{aligned} \pi(\theta) &\propto \theta^{\alpha-1}(1-\theta)^{\beta-1}. \\ \Rightarrow \pi(\theta \mid x) &\propto L(\theta \mid x) \pi(\theta) = \theta^x(1-\theta)^{1-x} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} = \theta^{\alpha+x-1}(1-\theta)^{\beta-x} \end{aligned}$$

□

Teorema 10.4.2. Conjugación en el modelo Binomial. Si $X \sim \text{Binomial}(n, \theta)$ y la previa es $\theta \sim \text{Beta}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Beta}(\alpha + x, \beta + n - x). \quad (10.11)$$

Demostración.

$$\begin{aligned} \pi(\theta) &\propto \theta^{\alpha-1}(1-\theta)^{\beta-1}. \\ \Rightarrow \pi(\theta \mid x) &\propto L(\theta \mid x) \pi(\theta) = \theta^x(1-\theta)^{n-x} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} = \theta^{\alpha+x-1}(1-\theta)^{\beta-x+n+1} \end{aligned}$$

□

Teorema 10.4.3. Conjugación en el modelo Binomial Negativa. Si $X \sim \text{Binomial Negativa}(r, \theta)$ y la previa es $\theta \sim \text{Beta}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Beta}(\alpha + r, \beta + x). \quad (10.12)$$

La demostración se deja al lector.

Teorema 10.4.4. Conjugación en el modelo Poisson. Si $X \sim \text{Poisson}(\theta)$ y la previa es $\theta \sim \text{Gamma}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Gamma}(\alpha + \sum x_i, \beta + n). \quad (10.13)$$

Demostración.

$$\begin{aligned} \pi(\theta) &\propto \theta^{\alpha-1}e^{-\beta\theta}. \\ \Rightarrow \pi(\theta \mid x) &\propto L(\theta \mid x) \pi(\theta) = \theta^{\sum x_i}e^{-n\theta} \cdot \theta^{\alpha-1}e^{-\beta\theta} = \theta^{\sum x_i + \alpha - 1}e^{-(n+\beta)\theta} \end{aligned}$$

□

Teorema 10.4.5. Conjugación en el modelo Exponencial. Si $X \sim \text{Exponencial}(\theta)$ y la previa es $\theta \sim \text{Gamma}(\alpha, \beta)$, entonces la posterior es

$$\theta \mid x \sim \text{Gamma}(\alpha + n, \beta + \sum x_i). \quad (10.14)$$

Demostración.

$$\pi(\theta) \propto \theta^{\alpha-1}e^{-\beta\theta}.$$

$$\Rightarrow \pi(\theta | x) \propto L(\theta | x) \pi(\theta) = \theta^n e^{-\theta \sum x_i} \cdot \theta^{\alpha-1} (1-\theta)^{\beta-1} = \theta^{n+\alpha-1} e^{-(\sum x_i + \beta)\theta}$$

□

Teorema 10.4.6. Conjugación en el modelo Normal con varianza conocida. Si $X \sim N(\theta, \sigma^2)$ con σ^2 conocida y la previa es $\theta \sim N(\mu_0, \sigma_0^2)$, entonces la posterior es

$$\theta | x \sim N\left(\frac{\mu_0/\sigma_0^2 + n\bar{x}/\sigma^2}{1/\sigma_0^2 + n/\sigma^2}, (1/\sigma_0^2 + n/\sigma^2)^{-1}\right). \quad (10.15)$$

Demostración.

$$\pi(\theta) \propto \exp\left(-\frac{1}{2\sigma_0^2}(\theta - \mu_0)^2\right).$$

$$\Rightarrow \pi(\theta | x) \propto L(\theta | x) \pi(\theta) = \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2\right) \cdot \exp\left(-\frac{1}{2\sigma_0^2}(\theta - \mu_0)^2\right).$$

donde

$$\begin{aligned} \sum_{i=1}^n (x_i - \theta)^2 &= \sum_{i=1}^n x_i^2 - 2\theta \sum_{i=1}^n x_i + n\theta^2 \\ \Rightarrow \pi(\theta | x) &\propto \exp\left(-\frac{1}{2\sigma^2}(-2\theta\bar{x} + n\theta^2) - \frac{1}{2\sigma_0^2}(\theta^2 - 2\theta\mu_0)\right) \\ &= \exp\left(-\frac{1}{2}\left(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}\right)\theta^2 + \left(\frac{n\bar{x}}{\sigma^2} + \frac{\mu_0}{\sigma_0^2}\right)\theta\right) \end{aligned}$$

□

Teorema 10.4.7. Conjugación en el modelo Normal con media conocida. Si $X \sim N(\mu, \theta)$ con μ conocida y la previa es $\theta \sim \text{Gamma Inversa}(\alpha, \beta)$, entonces la posterior es

$$\theta | x \sim \text{Gamma Inversa}\left(\alpha + \frac{n}{2}, \beta + \frac{1}{2} \sum (x_i - \mu)^2\right). \quad (10.16)$$

La demostración se deja al lector.

Teorema 10.4.8. Posterior de la normal. Si $X_1, \dots, X_n \sim N(\theta, \sigma^2)$ con σ^2 conocido y la previa es $\theta \sim N(\mu_1, V_1^2)$ entonces

$$\mu_1 = \frac{\sigma^2 \mu_0 + n V_0^2 \bar{X}_n}{\sigma^2 + n V_0^2}, \quad V_1^2 = \frac{\sigma^2 V_0^2}{\sigma^2 + n V_0^2} \quad (10.17)$$

La demostración se deja al lector.

Corolario 10.4.1. Si definimos

$$\mu_1 = \underbrace{\frac{\sigma^2}{\sigma^2 + nV_0^2}}_{W_1} \mu_0 + \underbrace{\frac{nV_0^2}{\sigma^2 + nV_0^2}}_{W_2} \bar{X}_n \quad (10.18)$$

Entonces

1. Si V_0^2 y σ^2 son fijos, entonces $W_1 \xrightarrow[n \rightarrow \infty]{} 0$ (la importancia de la media empírica crece conforme aumenta n).
2. Si V_0^2 y n son fijos, entonces $W_2 \xrightarrow[\sigma^2 \rightarrow \infty]{} 0$ (la importancia de la media empírica decrece conforme la muestra es menos precisa).
3. Si σ^2 y n son fijos, entonces $W_2 \xrightarrow[V_0^2 \rightarrow \infty]{} 1$ (la importancia de la media empírica crece conforme la previa es menos precisa).

La demostración se deja al lector.

10.5 Estimador bayesiano y las funciones de pérdida

Definición 10.5.1. Estimador. Sean $X_1, \dots, X_n$ datos observables cuyo modelo está indexado por $\theta \in \Omega$. Un estimador de θ es cualquier estadístico de la forma $\delta(X_1, \dots, X_n)$.

Definición 10.5.2. Estimación. La estimación o estimado es

$$\delta(X_1, \dots, X_n)(\omega) = \delta(x_1, \dots, x_n) \quad (10.19)$$

Definición 10.5.3. Función de pérdida. Una función de pérdida es una función de dos variables tal que

$$L(\theta, a), \quad \theta \in \Omega \quad (10.20)$$

con a un número real.

Definición 10.5.4. Pérdida esperada y estimador bayesiano. Suponga que θ tiene previa. La pérdida esperada viene dada por

$$\mathbb{E}[L(\theta, a)] = \int_{\Omega} L(\theta, a) \pi(\theta) d\theta \quad (10.21)$$

Asuma que a se selecciona al minimizar esta esperanza, al estimador $a = \delta^*(X_1, \dots, X_n)$ se le llama estimador bayesiano, si ponderamos los parámetros con respecto a la posterior

$$\mathbb{E}[L(\theta, \delta^*) | X] = \min_a \mathbb{E}[L(\theta, a) | X] \quad (10.22)$$

Proposición 10.5.1. Pérdida cuadrática. Si $L(\theta, a) = (\theta - a)^2$ entonces

$$a = \mathbb{E}[\theta | X]. \quad (10.23)$$

Demostración. Note que

$$\mathbb{E}[L(\theta, a)] = \int_{\Omega} (\theta - a)^2 \pi(\theta | X) d\theta$$

$$\begin{aligned}
 &= \int_{\Omega} \theta^2 \pi(\theta | X) d\theta - 2a \int_{\Omega} \theta \pi(\theta | X) d\theta + \int_{\Omega} a^2 \pi(\theta | X) d\theta \\
 &= \mathbb{E}[\theta^2 | X] - 2a\mathbb{E}[\theta | X] + a^2
 \end{aligned}$$

Darivando con respecto a la variable que queremos minimizar

$$\frac{d\mathbb{E}[L(\theta, a)]}{da} = 0 \Rightarrow -2\mathbb{E}[\theta | X] + 2a = 0$$

□

Proposición 10.5.2. Perdida absoluta. Si $L(\theta, a) = |\theta - a|$ entonces

$$F_{\theta|X}(a) = \frac{1}{2}. \quad (10.24)$$

Demostración. Note que

$$\begin{aligned}
 \mathbb{E}[L(\theta, a)] &= \int_{\Omega} |\theta - a| \pi(\theta | X) d\theta \\
 &= \int_{-\infty}^a (\theta - a) \pi(\theta | X) d\theta - \int_a^{\infty} (\theta - a) \pi(\theta | X) d\theta
 \end{aligned}$$

Derivando con respecto de a (aplicando Leibniz)

$$\begin{aligned}
 \frac{d\mathbb{E}[L(\theta, a)]}{da} &= 0 \Rightarrow \int_{-\infty}^a \pi(\theta | X) d\theta - \int_a^{\infty} \pi(\theta | X) d\theta \\
 &= F_{\theta|X}(a) - (1 - F_{\theta|X}(a)) = 0
 \end{aligned}$$

□

Proposición 10.5.3. Perdida 0-1. Si se tiene que

$$L(\theta, a) = \begin{cases} 0, & \text{si } |\theta - a| < \epsilon \\ 1, & \text{si } |\theta - a| \geq \epsilon \end{cases} \quad (10.25)$$

entonces $a = \max_{\theta} \pi(\theta | x)$.

10.6 Estimador de bayes para muestras grandes

10.6.1 Consistencia

Definición 10.6.1. Estimador consistente. Un estimador de $\delta(X_1, \dots, X_n)$ es consistente si

$$\delta(X_1, \dots, X_m) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta. \quad (10.26)$$

Teorema 10.6.1. Bayesiano consistente. Los estimadores bayesianos son consistentes.

La demostracion se deja al lector.

Definición 10.6.2. Estimador. Si $X_1, \dots, X_n$ es una muestra en un modelo indexado por θ , $\theta \in \Omega$ (k-dimensional), sea

$$h : \Omega \rightarrow H \subset \mathbb{R}^d \quad (10.27)$$

Definase $\psi = h(\theta)$. Un estimador de ψ es una función o estadístico $\delta(X_1, \dots, X_n) \in H$.

10.7 Estimadores de máxima verosimilitud y sus propiedades

Definición 10.7.1. Estimador de Máxima Verosimilitud. Un estimador de máxima verosimilitud (MLE) de θ es cualquier estadístico $\hat{\theta} = \delta(x)$ que maximice $L(X | \theta)$ con respecto a θ .

Definición 10.7.2. Generalización del MLE. Sea $g(\theta)$ una función arbitraria del parámetro θ , y sea G la imagen de Ω bajo g . Para cada $t \in G$, definimos

$$G_t := \{\theta \in \Omega : g(\theta) = t\}. \quad (10.28)$$

Se define además

$$L^*(t) := \max_{\theta \in G_t} \ln f_n(x | \theta). \quad (10.29)$$

El estimador de máxima verosimilitud de $g(\theta)$ es el valor $\hat{t}$ tal que

$$L^*(\hat{t}) := \max_{t \in G} L^*(t). \quad (10.30)$$

Teorema 10.7.1. Invarianza del MLE. Si $\hat{\theta}$ es el estimador de máxima verosimilitud de θ y g es una función biyectiva, entonces el MLE de $g(\theta)$ está dado por

$$g(\hat{\theta}). \quad (10.31)$$

Definición 10.7.3. Consistencia de un estimador. Sea $\{\delta_n(X)\}$ una sucesión de estimadores para un parámetro θ . Se dice que δ_n es consistente si

$$\delta_n(X) \xrightarrow{\mathbb{P}} \theta \quad \text{cuando } n \rightarrow \infty. \quad (10.32)$$

Teorema 10.7.2. Consistencia del MLE. Sea $\hat{\theta}_n$ el estimador de máxima verosimilitud de θ basado en una muestra de tamaño n . Bajo condiciones regulares, basta garantizar que

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0 \quad \text{y} \quad \lim_{n \rightarrow \infty} \text{Bias}(\hat{\theta}_n) = 0. \quad (10.33)$$

En tal caso, se cumple que

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta. \quad (10.34)$$

Teorema 10.7.3. Consistencia del estimador bayesiano. Bajo condiciones generales, la sucesión de estimadores bayesianos $\{\delta_n^{Bayes}\}$ también es consistente. En particular, para una distribución previa fija y n suficientemente grande,

$$\delta_n^{Bayes} \xrightarrow{\mathbb{P}} \theta \quad \text{cuando } n \rightarrow \infty. \quad (10.35)$$

Definición 10.7.4. Método de Newton. Sea $f(\theta)$ una función real de variable real. Para resolver la ecuación

$$f(\theta) = 0, \quad (10.36)$$

se parte de una aproximación inicial θ_0 . El método de Newton actualiza la aproximación mediante

$$\theta_{k+1} := \theta_k - \frac{f(\theta_k)}{f'(\theta_k)}. \quad (10.37)$$

Teorema 10.7.4. Convergencia local. Si f es dos veces diferenciable y $f'(\theta^*) \neq 0$ en la raíz θ^* , entonces para θ_0 suficientemente cercano a θ^* , la sucesión $\{\theta_k\}$ converge cuadráticamente a θ^* .

Corolario 10.7.1. Aplicación a MLE. El método de Newton puede emplearse para resolver la ecuación de primer orden de máxima verosimilitud

$$\frac{\partial}{\partial \theta} \ell(\theta | X) = 0, \quad (10.38)$$

donde $\ell(\theta | X) = \log L(\theta | X)$ es la log-verosimilitud.

Definición 10.7.5. Método de Momentos. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución indexada por un parámetro $\theta \in \mathbb{R}^k$, que posee al menos k momentos finitos. Para $j = 1, \dots, k$, definimos

$$\mu_j(\theta) := \mathbb{E}[X_1^j | \theta]. \quad (10.39)$$

Sea

$$\mu(\theta) := (\mu_1(\theta), \dots, \mu_k(\theta)), \quad (10.40)$$

y supongamos que $\mu(\theta)$ es una función biyectiva de θ . Definimos la función inversa

$$\theta = M(\mu_1(\theta), \dots, \mu_k(\theta)). \quad (10.41)$$

Los momentos muestrales se definen como

$$m_j := \frac{1}{n} \sum_{i=1}^n X_i^j, \quad j = 1, \dots, k. \quad (10.42)$$

El estimador por el método de momentos de θ está dado por

$$\hat{\theta}_{MoM} := M(m_1, \dots, m_k). \quad (10.43)$$

Teorema 10.7.5. Consistencia del estimador de momentos. Sea $\{\hat{\theta}_n^{MM}\}$ la sucesión de estimadores de momentos de $\theta \in \mathbb{R}^k$, basada en muestras de tamaño n . Si existen los primeros k momentos finitos y la función de momentos es continua e invertible, entonces

$$\hat{\theta}_n^{MM} \xrightarrow{\mathbb{P}} \theta \quad \text{cuando } n \rightarrow \infty. \quad (10.44)$$

10.8 Estadístico suficiente

Definición 10.8.1. Estadístico suficiente. Sea $X_1, \dots, X_n$ una muestra aleatoria con distribución dependiente de un parámetro θ . Un estadístico $T(X_1, \dots, X_n)$ se dice suficiente para θ si la distribución condicional de la muestra dado T no depende de θ .

Teorema 10.8.1. Teorema de Factorización de Neyman–Fisher. Sea $X_1, \dots, X_n$ una muestra aleatoria de función de probabilidad $f(X | \theta)$, donde θ es un parámetro desconocido. Un estadístico $T = r(X_1, \dots, X_n)$ es suficiente para θ si y solo si la función conjunta $L(\theta | X)$ puede factorizarse como

$$L(\theta | X) = u(x) v(r(x), \theta), \quad (10.45)$$

para todo $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ y todo θ en el espacio paramétrico.

Teorema 10.8.2. Caracterización bayesiana de suficiencia. T es suficiente para θ si y solo si, para cualquier distribución previa $\pi(\theta)$, la distribución posterior de θ depende de los datos únicamente a través del valor de T . Es decir

$$\pi(\theta | X) = \pi(\theta | T(X)). \quad (10.46)$$

10.9 Estimadores insesgados

Definición 10.9.1. Estimador insesgado. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución indexada por θ , y sea $\delta(X_1, \dots, X_n)$ un estimador de θ . Se dice que δ es *insesgado* para θ si

$$\mathbb{E}_\theta[\delta(X_1, \dots, X_n)] = \theta \quad \text{para todo } \theta. \quad (10.47)$$

Definición 10.9.2. Estadísticos conjuntamente suficientes. Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución indexada por θ . Un conjunto de estadísticos $(T_1, \dots, T_k)$ es conjuntamente suficiente para θ si, para todo θ y todo valor posible $(t_1, \dots, t_k)$, la distribución condicional conjunta de $X_1, \dots, X_n | (T_1, \dots, T_k) = (t_1, \dots, t_k)$ no depende de θ .

Teorema 10.9.1. Teorema de Factorización de Neyman–Fisher para estadísticos conjuntamente suficientes. Sean $r_1, \dots, r_k$ funciones de n variables reales. Los estadísticos $T_i = r_i(X)$, $i = 1, \dots, k$, son conjuntamente suficientes para θ si y solo si

$$L(x | \theta) = u(x) v(r_1(x), \dots, r_k(x), \theta). \quad (10.48)$$

Definición 10.9.3. Ordenamientos (Order Statistics). Sea $X_1, \dots, X_n$ una muestra aleatoria. Definimos los *ordenamientos* como las variables aleatorias $Y_1, \dots, Y_n$, donde

$$Y_1 := \min\{X_1, \dots, X_n\}, \quad Y_n := \max\{X_1, \dots, X_n\}, \quad (10.49)$$

y en general Y_j es el j -ésimo menor valor de la muestra.

Para la definición anterior también se utiliza la notación $X_{(i)}$.

Teorema 10.9.2. Suficiencia de los ordenamientos. Los ordenamientos $Y_1, \dots, Y_n$ son conjuntamente suficientes para θ .

La demostración es trivial.

Definición 10.9.4. Estadístico suficiente mínimo (minimal). Un estadístico T es minimal para θ si es suficiente y además es función de todo otro estadístico suficiente.

Teorema 10.9.3. MLE y estadísticos suficientes. Sea $T = r(X_1, \dots, X_n)$ un estadístico suficiente para θ . Entonces el estimador de máxima verosimilitud $\hat{\theta}$ depende de los datos únicamente a través de T . Además, si $\hat{\theta}$ es suficiente, entonces es suficiente mínimo.

Teorema 10.9.4. Estimador bayesiano y estadísticos suficientes. Sea $T = r(X)$ un estadístico suficiente para θ . Entonces todo estimador bayesiano $\hat{\theta}$ depende de los datos únicamente a través de T . Además, si $\hat{\theta}$ es suficiente, entonces es suficiente mínimo.

Teorema 10.9.5. Varianza muestral insesgada. Sea $X_1, \dots, X_n \sim F_\theta$ con varianza finita σ^2 . Entonces

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad (10.50)$$

es un estimador insesgado de σ^2 .

Teorema 10.9.6. Cota de Cramér–Rao. Sea $X_1, \dots, X_n$ una muestra aleatoria con función de densidad (o masa) $f(x | \theta)$, y sea $\delta(X)$ un estimador insesgado de θ . Bajo condiciones de regularidad, la varianza de δ satisface

$$\text{Var}_\theta(\delta) \geq \frac{1}{I_n(\theta)}, \quad (10.51)$$

donde $I_n(\theta) = n I(\theta)$ es la información de Fisher de la muestra, con

$$I(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(X | \theta) \right)^2 \right] = -\mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta) \right]. \quad (10.52)$$

Un estimador insesgado que alcanza esta cota se denomina *eficiente*.

Proposición 10.9.1. Distribución de Poisson estimadores insesgados. Si $X_1, \dots, X_n \sim \text{Poisson}(\theta)$, entonces tanto

$$\bar{X}_n \quad \text{y} \quad s^2 \quad (10.53)$$

son estimadores insesgados de θ . Además, cualquier combinación lineal

$$T = \alpha \bar{X}_n + (1 - \alpha) s^2 \quad (10.54)$$

también resulta insesgada.

Proposición 10.9.2. Distribución normal comparación de estimadores de σ^2 por MSE. Sea $X_1, \dots, X_n \sim N(\mu, \sigma^2)$. Definimos

$$T_c = c \sum_{i=1}^n (X_i - \bar{X}_n)^2. \quad (10.55)$$

El valor óptimo en términos de error cuadrático medio es

$$c^* = \frac{1}{n+1}, \quad (10.56)$$

de modo que

$$T_{1/(n+1)} = \frac{1}{n+1} \sum_{i=1}^n (X_i - \bar{X}_n)^2. \quad (10.57)$$

Sin embargo, este estimador resulta inadmisibile.

Definición 10.9.5. Inadmisibilidad en términos de MSE. Un estimador δ_1 es inadmisibile si existe otro estimador δ_2 tal que

$$\text{MSE}(\delta_2) \leq \text{MSE}(\delta_1) \quad \text{para todo } \theta, \quad (10.58)$$

y la desigualdad es estricta para al menos un valor de θ . En ese caso, se dice que δ_2 domina a δ_1 .

Proposición 10.9.3. Conexión con Rao–Blackwell. Si $\delta(X)$ es insesgado y T es suficiente para θ , entonces

$$\delta^*(T) = \mathbb{E}[\delta(X) | T] \quad (10.59)$$

es también insesgado y cumple

$$\text{Var}_\theta(\delta^*) \leq \text{Var}_\theta(\delta). \quad (10.60)$$

10.10 Mejorando el estimador

Definición 10.10.1. Función de riesgo. Para un estimador $\delta(X)$ de una función $h(\theta)$, la función de riesgo bajo pérdida cuadrática se define como

$$R(\theta, \delta) := \mathbb{E}_\theta \left[(\delta(X) - h(\theta))^2 \right] = \mathbb{E} \left[(\delta(X) - h(\theta))^2 | \theta \right]. \quad (10.61)$$

Definición 10.10.2. Estimador de Rao–Blackwell. Sea $\delta(X)$ un estimador de θ , y sea T un estadístico suficiente para θ . Definimos el estimador mejorado como

$$\delta_0(T) := \mathbb{E}[\delta(X) | T]. \quad (10.62)$$

Teorema 10.10.1. Teorema de Rao–Blackwell. Sea $\delta(X)$ un estimador de θ , y sea $\delta_0(T)$ el estimador definido anteriormente a partir de un estadístico suficiente T . Entonces, para todo θ ,

$$R(\theta, \delta_0) \leq R(\theta, \delta), \quad (10.63)$$

Además, si $R(\theta, \delta) < \infty$, la desigualdad es estricta salvo que $\delta(X)$ sea función de T .

Definición 10.10.3. Admisibilidad e inadmisibilidad. Sea $R(\theta, \delta)$ el riesgo de un estimador δ . Un estimador δ es inadmisble si existe otro estimador δ_0 tal que

$$R(\theta, \delta_0) \leq R(\theta, \delta) \quad \text{para todo } \theta, \quad (10.64)$$

y la desigualdad es estricta para al menos un valor de θ . En este caso, se dice que δ_0 domina a δ . Un estimador δ es admisible si no existe ningún otro estimador que lo domine.

11

Distribuciones Muestrales de Estimadores

Definición 11.0.1. Distribución χ^2 . Para $m > 0$ definimos

$$\chi_m^2 \sim \Gamma\left(\frac{m}{2}, \frac{1}{2}\right),$$

donde m representa los grados de libertad.

Proposición 11.0.1. Propiedades de la distribución χ^2 . Si $X_i \sim \chi_{m_i}^2$ independientes, entonces

$$\sum_{i=1}^k X_i \sim \chi_{\sum m_i}^2.$$

Además, si $X \sim N(0, 1)$, entonces $Y = X^2 \sim \chi_1^2$. Si $X_i \sim \text{i.i.d. } N(0, 1)$, entonces

$$\sum_{i=1}^m X_i^2 \sim \chi_m^2.$$

Proposición 11.0.2. Distribución muestral de la varianza. Sea $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ con μ desconocido. Si

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2,$$

entonces

$$\frac{n\hat{\sigma}^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Proposición 11.0.3. Independencia en muestras normales. Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, entonces $\bar{X}_n$ y s_n^2 son independientes, donde

$$s_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

Proposición 11.0.4. Matrices ortogonales. Una matriz $A_{n \times n}$ es ortogonal si $A^{-1} = A^T$ (equivalentemente $A^T A = I$). En ese caso $\det(A) = \pm 1$ y si $Y = AX$ con A ortogonal, entonces

$$\|Y\|_2^2 = \|X\|_2^2.$$

Teorema 11.0.1. Transformación ortogonal de normales. Si $X_1, \dots, X_n \sim N(0, 1)$ y A es ortogonal $n \times n$, entonces para $Y = AX$ se cumple

$$Y_1, \dots, Y_n \sim N(0, 1).$$

11.1 Distribución t de Student

Definición 11.1.1. Distribución t de Student. Sean $Y \sim \chi_m^2$ y $Z \sim N(0, 1)$ independientes. Definimos

$$X = \frac{Z}{\sqrt{Y/m}}.$$

Entonces $X \sim t_m$, distribución t de Student con m grados de libertad.

Proposición 11.1.1. Propiedades de la distribución t .

- Es simétrica.
- La media existe solo si $m > 1$, en cuyo caso es 0.
- La varianza existe si $m > 2$, y es

$$\text{Var}(X) = \frac{m}{m-2}.$$

- Si $m = 1$, $X \sim \text{Cauchy}$.
- Cuando $m \rightarrow \infty$, $t_m \rightarrow N(0, 1)$.

Proposición 11.1.2. Estadístico t en muestras normales. Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, entonces

$$\frac{n(\bar{X}_n - \mu)}{s_n} \sim t_{n-1},$$

donde

$$s_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

12

Anexo

12.1 Distribuciones de probabilidad discretas

12.1.1 Distribución de Bernoulli

Definición 12.1.1. Distribución Bernoulli. La notación $X \sim \text{Bernoulli}(p)$ indica que la variable aleatoria X tiene distribución Bernoulli con parámetro p , donde $0 < p < 1$. Esta distribución modela un experimento con dos posibles resultados éxito ($x = 1$) y fracaso ($x = 0$).

Teorema 12.1.1. Propiedades de la distribución Bernoulli. La función de masa de probabilidad de X es

$$f_X(x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}. \quad (12.1)$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1-p & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases} \quad (12.2)$$

La función de supervivencia de X es

$$S_X(x) = \begin{cases} 1 & x \leq 0 \\ p & 0 < x \leq 1 \\ 0 & x > 1 \end{cases} \quad (12.3)$$

La función de riesgo de X es

$$h_X(x) = \begin{cases} 1-p & x = 0 \\ 1 & x = 1 \end{cases} \quad (12.4)$$

La función de riesgo acumulada de X es

$$H_X(x) = \begin{cases} 0 & x \leq 0 \\ -\ln p & 0 < x \leq 1 \end{cases} \quad (12.5)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \begin{cases} 0 & 0 < u < 1-p \\ 1 & 1-p \leq u < 1 \end{cases} \quad (12.6)$$

La función generadora de momentos de X es

$$\phi_X(t) = (1-p) + pe^t, \quad t \in \mathbb{R}. \quad (12.7)$$

La función característica de X es

$$\varphi_X(t) = (1-p) + pe^{it}, \quad t \in \mathbb{R}. \quad (12.8)$$

La esperanza de X es

$$\mathbb{E}[X] = p. \quad (12.9)$$

La varianza de X es

$$\text{Var}(X) = p(1-p). \quad (12.10)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X-\mu}{\sigma} \right)^3 \right] = \frac{1-2p}{\sqrt{p(1-p)}}, \quad \mathbb{E} \left[\left(\frac{X-\mu}{\sigma} \right)^4 \right] = \frac{3p^2-3p+1}{p(1-p)}. \quad (12.11)$$

La demostración queda al lector.

12.1.2 Distribución binomial

Definición 12.1.2. Distribución Binomial. La notación $X \sim \text{Binomial}(n, p)$ indica que la variable aleatoria X tiene distribución Binomial con parámetro entero positivo n y parámetro real p , donde $0 < p < 1$. Esta distribución modela el número de éxitos en n ensayos de Bernoulli mutuamente independientes, cada uno con probabilidad de éxito p .

Teorema 12.1.2. Propiedades de la distribución Binomial. La función de masa de probabilidad de X es

$$f_X(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x \in \{0, 1, \dots, n\}. \quad (12.12)$$

La función de distribución acumulada de X es

$$F_X(x) = \sum_{k=0}^x \binom{n}{k} p^k (1-p)^{n-k}, \quad x \in \{0, 1, \dots, n\}. \quad (12.13)$$

La función de supervivencia de X es

$$S_X(x) = \sum_{k=x}^n \binom{n}{k} p^k (1-p)^{n-k}, \quad x \in \{0, 1, \dots, n\}. \quad (12.14)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \min\{x \in \{0, 1, \dots, n\} : F_X(x) \geq u\}, \quad 0 < u < 1. \quad (12.15)$$

La función generadora de momentos de X es

$$\phi_X(t) = ((1-p) + pe^t)^n, \quad t \in \mathbb{R}. \quad (12.16)$$

La función característica de X es

$$\varphi_X(t) = ((1-p) + pe^{it})^n, \quad t \in \mathbb{R}. \quad (12.17)$$

La esperanza de X es

$$\mathbb{E}[X] = np. \quad (12.18)$$

La varianza de X es

$$\text{Var}(X) = np(1-p). \quad (12.19)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{1-2p}{\sqrt{np(1-p)}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3+1-6p(1-p)}{np(1-p)}. \quad (12.20)$$

La demostración queda al lector.

12.1.3 Distribución Geométrica

Definición 12.1.3. Distribución geométrica. La notación $X \sim \text{Geometric}(p)$ indica que la variable aleatoria X tiene distribución Geométrica con parámetro real p , donde $0 < p < 1$. Esta distribución modela el número de fracasos antes del primer éxito en ensayos de Bernoulli repetidos e independientes, cada uno con probabilidad de éxito p .

Teorema 12.1.3. Propiedades de la distribución Geométrica. La función de masa de probabilidad de X es

$$f_X(x) = p(1-p)^x, \quad x \in \{0, 1, 2, \dots\}. \quad (12.21)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - (1-p)^{x+1}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.22)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{\ln(1-u)}{\ln(1-p)}, \quad 0 < u < 1. \quad (12.23)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{p}{1 - (1-p)e^t}, \quad t < -\ln(1-p). \quad (12.24)$$

La función característica de X es

$$\varphi_X(t) = \frac{p}{1 - (1-p)e^{it}}, \quad t \in \mathbb{R}. \quad (12.25)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{1-p}{p}. \quad (12.26)$$

La varianza de X es

$$\text{Var}(X) = \frac{1-p}{p^2}. \quad (12.27)$$

La función de supervivencia de X es

$$S_X(x) = (1-p)^x, \quad x \in \{0, 1, 2, \dots\}. \quad (12.28)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = p, \quad x \in \{0, 1, 2, \dots\}. \quad (12.29)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln(S_X(x)) = -\ln((1-p)^x), \quad x \in \{0, 1, 2, \dots\}. \quad (12.30)$$

El sesgo poblacional de X es

$$\text{Skewness}(X) = \frac{2-p}{\sqrt{1-p}}. \quad (12.31)$$

La kurtosis poblacional de X es

$$\text{Kurtosis}(X) = \frac{9+p^2}{1-p}. \quad (12.32)$$

La demostración queda al lector.

12.1.4 Distribución de Poisson

Definición 12.1.4. Distribución Poisson. La notación $X \sim \text{Poisson}(\lambda)$ indica que la variable aleatoria X tiene distribución Poisson con parámetro positivo λ . Esta distribución modela el número de eventos que ocurren en un intervalo de tiempo o espacio, bajo un proceso aleatorio con tasa constante λ .

Teorema 12.1.4. Propiedades de la distribución Poisson. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.33)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\Gamma(x+1, \lambda)}{\Gamma(x+1)}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.34)$$

La función de supervivencia de X es

$$S_X(x) = \Gamma(x+1) - x\Gamma(x, \lambda), \quad x \in \{0, 1, 2, \dots\}. \quad (12.35)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\lambda^x e^{-\lambda}}{\Gamma(x+1) - x\Gamma(x, \lambda)}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.36)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln(S_X(x)) = -\ln(\Gamma(x+1) - x\Gamma(x, \lambda)), \quad x \in \{0, 1, 2, \dots\}. \quad (12.37)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \min\{x \in \mathbb{N}_0 : F_X(x) \geq u\}, \quad 0 < u < 1. \quad (12.38)$$

La función generadora de momentos de X es

$$\phi_X(t) = e^{\lambda(e^t - 1)}, \quad t \in \mathbb{R}. \quad (12.39)$$

La función característica de X es

$$\varphi_X(t) = e^{\lambda(e^{it} - 1)}, \quad t \in \mathbb{R}. \quad (12.40)$$

La esperanza de X es

$$\mathbb{E}[X] = \lambda. \quad (12.41)$$

La varianza de X es

$$\text{Var}(X) = \lambda. \quad (12.42)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \lambda^{-1/2}, \quad \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = 3 + \lambda^{-1}. \quad (12.43)$$

La demostración queda al lector.

12.1.5 Distribución hipergeométrica

Definición 12.1.5. Distribución Hipergeométrica. La notación $X \sim \text{Hypergeometric}(n_1, n_2, n_3)$ indica que la variable aleatoria X tiene distribución Hipergeométrica con parámetros enteros no negativos n_1, n_2, n_3 , donde $n_1, n_2 \in \{0, 1, 2, \dots, n_3\}$. Esta distribución modela el número de elementos con una característica específica (por ejemplo, defectuosos) en una muestra de tamaño n_2 , extraída sin reemplazo de una población finita de n_3 elementos que contiene n_1 elementos con dicha característica.

Teorema 12.1.5. Propiedades de la distribución Hipergeométrica. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\binom{n_1}{x} \binom{n_3 - n_1}{n_2 - x}}{\binom{n_3}{n_2}}, \quad x \in \{\max(0, n_1 + n_2 - n_3), \dots, \min(n_1, n_2)\}. \quad (12.44)$$

La función de distribución acumulada de X es

$$F_X(x) = \sum_{k=0}^x \frac{\binom{n_1}{k} \binom{n_3 - n_1}{n_2 - k}}{\binom{n_3}{n_2}}, \quad x \in \{\max(0, n_1 + n_2 - n_3), \dots, \min(n_1, n_2)\}. \quad (12.45)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \min \{x \in \mathbb{N}_0 : F_X(x) \geq u\}, \quad 0 < u < 1. \quad (12.46)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{\binom{n_3 - n_1}{n_2}}{\binom{n_3}{n_2}} \cdot {}_2F_1(-n_2, -n_1, n_3 - n_1 - n_2 + 1, e^t), \quad (12.47)$$

donde ${}_2F_1(a, b, c, z)$ es la función hipergeométrica de Gauss.

La esperanza de X es

$$\mathbb{E}[X] = \frac{n_1 n_2}{n_3}. \quad (12.48)$$

La varianza de X es

$$\text{Var}(X) = \frac{n_2 n_1 (n_3 - n_1) (n_3 - n_2)}{n_3^2 (n_3 - 1)}. \quad (12.49)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{(n_3 - 2n_1)(n_3 - 1)^{1/2}(n_3 - 2n_2)}{[n_2 n_1 (n_3 - n_1) (n_3 - n_2)]^{1/2} (n_3 - 2)}. \quad (12.50)$$

La demostracion queda al lector.

12.1.6 Distribución de Pascal

Definición 12.1.6. Distribución Pascal. La notación $X \sim \text{Pascal}(n, p)$ indica que la variable aleatoria X tiene distribución Pascal con parámetro entero positivo n y parámetro real p , donde $0 < p < 1$. Esta distribución modela el número de fracasos antes del n -ésimo éxito en ensayos de Bernoulli repetidos e independientes, cada uno con probabilidad de éxito p .

Teorema 12.1.6. Propiedades de la distribución Pascal. La función de masa de probabilidad de X es

$$f_X(x) = \binom{n-1+x}{x} p^n (1-p)^x, \quad x \in \{0, 1, 2, \dots\}. \quad (12.51)$$

La función generadora de momentos de X es

$$\phi_X(t) = \left(\frac{p}{1 - (1-p)e^t} \right)^n, \quad t < -\ln(1-p). \quad (12.52)$$

La función característica de X es

$$\varphi_X(t) = \left(\frac{p}{1 - (1-p)e^{it}} \right)^n, \quad t \in \mathbb{R}. \quad (12.53)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n(1-p)}{p}. \quad (12.54)$$

La varianza de X es

$$\text{Var}(X) = \frac{n(1-p)}{p^2}. \quad (12.55)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{2-p}{\sqrt{np(1-p)}}, \quad \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = \frac{p^2 - 6p - 3np + 3n + 6}{n(1-p)}. \quad (12.56)$$

La demostración queda al lector.

12.1.7 Distribución uniforme discreta

Definición 12.1.7. Distribución Uniforme Discreta. La notación $X \sim \text{Uniforme Discreta}(a, b)$ indica que la variable aleatoria X tiene distribución uniforme discreta con parámetros enteros a y b , donde $a < b$. Esta distribución modela una selección aleatoria equiprobable entre los valores enteros $a, a + 1, \dots, b$.

Teorema 12.1.7. Propiedades de la distribución Uniforme Discreta. La función de masa de probabilidad de X es

$$f_X(x) = \frac{1}{b - a + 1}, \quad x \in \{a, a + 1, \dots, b\}. \quad (12.57)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{x - a + 1}{b - a + 1}, \quad x \in \{a, a + 1, \dots, b\}. \quad (12.58)$$

La función de supervivencia de X es

$$S_X(x) = \frac{b - x + 1}{b - a + 1}, \quad x \in \{a, a + 1, \dots, b\}. \quad (12.59)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{b - x + 1}, \quad x \in \{a, a + 1, \dots, b\}. \quad (12.60)$$

La función inversa de distribución de X es

$$F^{-1}(u) = a + \lfloor u(b - a + 1) \rfloor, \quad 0 < u < 1. \quad (12.61)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{e^{at} - e^{(b+1)t}}{(b - a + 1)(1 - e^t)}, \quad t \in \mathbb{R}. \quad (12.62)$$

La función característica de X es

$$\varphi_X(t) = \frac{e^{ait} - e^{(b+1)it}}{(b - a + 1)(1 - e^{it})}, \quad t \in \mathbb{R}. \quad (12.63)$$

La mediana de X es

$$\text{Mediana}(X) = \frac{a + b}{2}. \quad (12.64)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{a + b}{2}. \quad (12.65)$$

La varianza de X es

$$\text{Var}(X) = \frac{(b - a + 1)^2 - 1}{12}. \quad (12.66)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = 0, \quad \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = \frac{6[(b - a + 1)^2 + 1]}{5[(b - a + 1)^2 - 1]}. \quad (12.67)$$

La demostración queda al lector.

12.1.8 Distribución zeta

Definición 12.1.8. Distribución Zeta. La notación $X \sim \text{Zeta}(\alpha)$ indica que la variable aleatoria X tiene distribución Zeta con parámetro $\alpha > 1$. Esta distribución modela fenómenos discretos con comportamiento de cola pesada, y está definida sobre los enteros positivos.

Teorema 12.1.8. Propiedades de la distribución Zeta. La función de masa de probabilidad de X es

$$f_X(x) = \frac{1}{x^\alpha \zeta(\alpha)}, \quad x \in \{1, 2, 3, \dots\}. \quad (12.68)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{\zeta(\alpha)} \sum_{i=1}^x \frac{1}{i^\alpha}, \quad x \in \{1, 2, 3, \dots\}. \quad (12.69)$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{\zeta(\alpha)} \sum_{i=x}^{\infty} \frac{1}{i^\alpha}, \quad x \in \{1, 2, 3, \dots\}. \quad (12.70)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{x^\alpha \sum_{i=x}^{\infty} \frac{1}{i^\alpha}}, \quad x \in \{1, 2, 3, \dots\}. \quad (12.71)$$

La función de riesgo acumulada de X es

$$H_X(x) = \ln(\zeta(\alpha)) - \ln\left(\sum_{i=x}^{\infty} \frac{1}{i^\alpha}\right), \quad x \in \{1, 2, 3, \dots\}. \quad (12.72)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{1}{\zeta(\alpha)} \sum_{x=1}^{\infty} \frac{e^{tx}}{x^\alpha}, \quad t \in \mathbb{R}. \quad (12.73)$$

La función característica de X es

$$\varphi_X(t) = \frac{1}{\zeta(\alpha)} \sum_{x=1}^{\infty} \frac{e^{itx}}{x^\alpha}, \quad t \in \mathbb{R}. \quad (12.74)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\zeta(\alpha-1)}{\zeta(\alpha)}, \quad \alpha > 2. \quad (12.75)$$

La varianza de X es

$$\text{Var}(X) = \frac{\zeta(\alpha)\zeta(\alpha-2) - \zeta(\alpha-1)^2}{\zeta(\alpha)^2}, \quad \alpha > 3. \quad (12.76)$$

La demostración queda al lector.

12.1.9 Distribución zipf

Definición 12.1.9. Distribución Zipf. La notación $X \sim \text{Zipf}(\alpha, n)$ indica que la variable aleatoria X tiene distribución Zipf con parámetros $\alpha \geq 0$ y $n \in \mathbb{N}^+$. Esta distribución modela fenómenos donde unos pocos elementos tienen alta frecuencia o popularidad, mientras que la mayoría son poco frecuentes.

Teorema 12.1.9. Propiedades de la distribución Zipf. La función de masa de probabilidad de X es

$$f_X(x) = \frac{1}{x^\alpha H_{n,\alpha}}, \quad x \in \{1, 2, \dots, n\}, \quad (12.77)$$

donde $H_{n,\alpha} = \sum_{i=1}^n \frac{1}{i^\alpha}$.

La función de distribución acumulada de X es

$$F_X(x) = \frac{H_{x,\alpha}}{H_{n,\alpha}}, \quad x \in \{1, 2, \dots, n\}. \quad (12.78)$$

La función de supervivencia de X es

$$S_X(x) = \frac{x^\alpha H_{n,\alpha} - x^\alpha H_{x+1,\alpha}}{x^\alpha H_{n,\alpha}}, \quad x \in \{1, 2, \dots, n\}. \quad (12.79)$$

La función de riesgo de X es

$$h_X(x) = \frac{1}{x^\alpha H_{n,\alpha} - x^\alpha H_{x+1,\alpha}}, \quad x \in \{1, 2, \dots, n\}. \quad (12.80)$$

La función de riesgo acumulada de X es

$$H_X(x) = \ln(x^\alpha H_{n,\alpha}) - \ln(x^\alpha H_{n,\alpha} - x^\alpha H_{x+1,\alpha}), \quad x \in \{1, 2, \dots, n\}. \quad (12.81)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{1}{H_{n,\alpha}} \sum_{j=1}^n \frac{e^{tj}}{j^\alpha}, \quad t \in \mathbb{R}. \quad (12.82)$$

La función característica de X es

$$\varphi_X(t) = \frac{1}{H_{n,\alpha}} \sum_{j=1}^n \frac{e^{itj}}{j^\alpha}, \quad t \in \mathbb{R}. \quad (12.83)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{H_{n,\alpha-1}}{H_{n,\alpha}}. \quad (12.84)$$

La varianza de X es

$$\text{Var}(X) = \frac{H_{n,\alpha} H_{n,\alpha-2} - H_{n,\alpha-1}^2}{H_{n,\alpha}^2}. \quad (12.85)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{H_{n,\alpha-3} H_{n,\alpha} - 3 H_{n,\alpha-1} H_{n,\alpha-2} + 2 H_{n,\alpha-1}^3}{(H_{n,\alpha} H_{n,\alpha-2} - H_{n,\alpha-1}^2)^{3/2}} \quad (12.86)$$

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = \frac{H_{n,\alpha} H_{n,\alpha-4} - 4 H_{n,\alpha-1} H_{n,\alpha-3} + 6 H_{n,\alpha-1}^2 H_{n,\alpha-2} - 3 H_{n,\alpha-1}^4}{(H_{n,\alpha} H_{n,\alpha-2} - H_{n,\alpha-1}^2)^2}. \quad (12.87)$$

La demostración queda al lector.

12.1.10 Distribución beta-binomial

Definición 12.1.10. Distribución Beta-Binomial. La notación $X \sim \text{BetaBinomial}(a, b, n)$ indica que la variable aleatoria X tiene distribución Beta-Binomial con parámetros $a > 0$, $b > 0$ y $n \in \mathbb{N}^+$. Esta distribución modela el número de éxitos en n ensayos de Bernoulli donde la probabilidad de éxito p sigue una distribución Beta con parámetros a y b .

Teorema 12.1.10. Propiedades de la distribución Beta-Binomial. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\Gamma(x+a)\Gamma(n-x+b)\Gamma(a+b)\Gamma(n+2)}{(n+1)\Gamma(a+b+n)\Gamma(a)\Gamma(b)\Gamma(x+1)\Gamma(n-x+1)}, \quad x \in \{0, 1, \dots, n\}. \quad (12.88)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{na}{a+b}. \quad (12.89)$$

La varianza de X es

$$\text{Var}(X) = \frac{nab(a+b+n)}{(a+b)^2(a+b+1)}. \quad (12.90)$$

El sesgo poblacional de X es

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{(a+b+2n)(b-a)\sqrt{1+a+b}}{(a+b+2)(a+b)^2(a+b+1)\sqrt{nab(n+a+b)}}. \quad (12.91)$$

La demostración queda al lector.

12.1.11 Distribución hipergeométrica negativa

Definición 12.1.11. Distribución Hipergeométrica Negativa. La notación $X \sim \text{NegHypergeometric}(n_1, n_2, n_3)$ indica que la variable aleatoria X tiene distribución Hipergeométrica Negativa con parámetros $n_1, n_2, n_3 \in \mathbb{N}^+$, donde $n_1 \leq n_2$. Esta distribución modela el número de éxitos obtenidos antes de observar n_1 fracasos en un muestreo sin reemplazo de una población finita de n_3 elementos, de los cuales n_2 son exitosos.

Teorema 12.1.11. Propiedades de la distribución Hipergeométrica Negativa. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\binom{n_1+x-1}{x} \binom{n_3-n_1+n_2-x-1}{n_2-x}}{\binom{n_3+n_2-1}{n_2}}, \quad x \in \{0, 1, \dots, n_2\}. \quad (12.92)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n_1 n_2}{n_3}. \quad (12.93)$$

La varianza de X es

$$\text{Var}(X) = \frac{n_1 n_2 (n_3 + n_2) (n_3 - n_1)}{n_3^2 (n_3 + 1)}. \quad (12.94)$$

La demostración queda al lector.

12.1.12 Distribución de Polya

Definición 12.1.12. Distribución Polya. La notación $X \sim \text{Polya}(n, p, \beta)$ indica que la variable aleatoria X tiene distribución Polya con parámetros $n \in \mathbb{N}^+$, $0 < p < 1$, y $\beta > 0$. Esta distribución modela el número de éxitos en n ensayos de Bernoulli con probabilidad de éxito variable, influenciada por los parámetros p y β .

Teorema 12.1.12. Propiedades de la distribución Polya

La función de masa de probabilidad de X es

$$f_X(x) = \binom{n}{x} \cdot \frac{\prod_{j=0}^{x-1} (p + j\beta) \cdot \prod_{k=0}^{n-x-1} (1 - p + k\beta)}{\prod_{i=0}^{n-1} (1 + i\beta)}, \quad x \in \{0, 1, \dots, n\}. \quad (12.95)$$

La esperanza de X es

$$\mathbb{E}[X] = - \frac{\sin\left(\frac{\pi(-1+\beta+p)}{\beta}\right) \cdot pn \cdot \sin\left(\frac{\pi(n\beta+1)}{\beta}\right)}{\sin\left(\frac{\pi}{\beta}\right) \cdot \sin\left(\frac{\pi(n\beta-\beta-p+1)}{\beta}\right)}. \quad (12.96)$$

La demostración queda al lector.

12.1.13 Distribución logarítmica

Definición 12.1.13. Distribución Logarítmica. La notación $X \sim \text{Logarithm}(c)$ indica que la variable aleatoria X tiene distribución logarítmica con parámetro $0 < c < 1$. Esta distribución discreta se utiliza para modelar fenómenos con alta probabilidad de valores pequeños y decaimiento exponencial.

Teorema 12.1.13. Propiedades de la distribución Logarítmica. La función de masa de probabilidad de X es

$$f_X(x) = -\frac{(1-c)^x}{x \ln c}, \quad x \in \{1, 2, 3, \dots\}. \quad (12.97)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{\ln(1 - e^t + ce^t)}{\ln c}, \quad t \in \mathbb{R}. \quad (12.98)$$

La función característica de X es

$$\varphi_X(t) = \frac{\ln(1 - e^{it} + ce^{it})}{\ln c}, \quad t \in \mathbb{R}. \quad (12.99)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{-c}{(1-c) \ln c}. \quad (12.100)$$

La varianza de X es

$$\text{Var}(X) = \frac{(c-1)(\ln c + 1 - c)}{(\ln c)^2 c^2}. \quad (12.101)$$

La demostración queda al lector.

12.1.14 Distribución gamma-poisson

Definición 12.1.14. Distribución Gamma-Poisson. La notación $X \sim \text{Gamma-Poisson}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución Gamma-Poisson con parámetros positivos α y β . Esta distribución modela una variable Poisson con parámetro aleatorio $\mu \sim \text{Gamma}(\alpha, \beta)$, y se utiliza para representar conteos con sobredispersión.

Teorema 12.1.14. Propiedades de la distribución Gamma-Poisson. La función de masa de probabilidad de X es

$$f_X(x) = \frac{\Gamma(x + \beta) \cdot \alpha^x}{\Gamma(\beta) \cdot (1 + \alpha)^{\beta+x} \cdot x!}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.102)$$

La función de distribución acumulada de X es

$$F_X(x) = \sum_{w=0}^x \frac{\Gamma(w + \beta) \cdot \alpha^w}{\Gamma(\beta) \cdot (1 + \alpha)^{\beta+w} \cdot w!}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.103)$$

La función generadora de momentos de X es

$$\phi_X(t) = (1 + \alpha - \alpha e^t)^{-\beta}, \quad t \in \mathbb{R}. \quad (12.104)$$

La función característica de X es

$$\varphi_X(t) = (1 + \alpha - \alpha e^{it})^{-\beta}, \quad t \in \mathbb{R}. \quad (12.105)$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha\beta. \quad (12.106)$$

La varianza de X es

$$\text{Var}(X) = \alpha\beta + \alpha^2\beta. \quad (12.107)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{1 + 2\alpha}{\sqrt{\alpha\beta(1 + \alpha)}}, \quad \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = \frac{3\alpha^2\beta + 6\alpha^2 + 3\alpha\beta + 6\alpha + 1}{\alpha\beta(1 + \alpha)}. \quad (12.108)$$

La demostración queda al lector.

12.1.15 Distribución beta-pascal

Definición 12.1.15. Distribución Beta-Pascal. La notación $X \sim \text{BetaPascal}(n, a, b)$ indica que la variable aleatoria X tiene distribución Beta-Pascal con parámetros $n \in \mathbb{N}^+$, $a > 0$, y $b > 0$. Esta distribución modela el número de fracasos antes del n -ésimo éxito en ensayos de Bernoulli, donde la probabilidad de éxito p sigue una distribución Beta con parámetros a y b .

Teorema 12.1.15. Propiedades de la distribución Beta–Pascal. La función de masa de probabilidad de X es

$$f_X(x) = \binom{n-1+x}{x} \cdot \frac{B(n+a, b+x)}{B(a, b)}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.109)$$

La función de distribución acumulada de X es

$$F_X(x) = \sum_{w=0}^x \binom{n-1+w}{w} \cdot \frac{B(n+a, b+w)}{B(a, b)}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.110)$$

La función de supervivencia de X es

$$S_X(x) = \sum_{w=x}^{\infty} \binom{n-1+w}{w} \cdot \frac{B(n+a, b+w)}{B(a, b)}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.111)$$

La demostración queda al lector.

12.1.16 Distribución power series

Definición 12.1.16. Distribución Power Series. Una variable aleatoria X tiene distribución Power Series si su función de masa de probabilidad depende de una secuencia $a_x > 0$, un parámetro $c > 0$, y una función generadora de la serie $A(c) = \sum_{x=0}^{\infty} a_x c^x$. Esta familia incluye distribuciones como binomial, Poisson, y negativa binomial como casos especiales.

Teorema 12.1.16. Propiedades de la distribución Power Series. La función de masa de probabilidad de X es

$$f_X(x) = \frac{a_x c^x}{A(c)}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.112)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{A(c)} \sum_{w=0}^x a_w c^w. \quad (12.113)$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{A(c)} \sum_{w=x}^{\infty} a_w c^w. \quad (12.114)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{a_x c^x}{\sum_{w=x}^{\infty} a_w c^w}. \quad (12.115)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{A(c e^t)}{A(c)}, \quad t > 0. \quad (12.116)$$

La esperanza de X es

$$\mathbb{E}[X] = c \cdot \frac{d}{dc} [\ln A(c)]. \quad (12.117)$$

La demostración queda al lector.

12.1.17 Distribución Weibull discreta

Definición 12.1.17. Distribución Weibull Discreta. La notación $X \sim \text{Weibull Discreta}(p, \beta)$ indica que la variable aleatoria X tiene distribución Weibull Discreta con parámetro de escala $0 < p < 1$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza para modelar tiempos discretos de falla o eventos con comportamiento de cola pesada.

Teorema 12.1.17. Propiedades de la distribución Weibull Discreta. La función de masa de probabilidad de X es

$$f_X(x) = (1-p)^{x^\beta} - (1-p)^{(x+1)^\beta}, \quad x \in \{0, 1, 2, \dots\}. \quad (12.118)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - (1-p)^{(x+1)^\beta}. \quad (12.119)$$

La función de supervivencia de X es

$$S_X(x) = (1-p)^{x^\beta}. \quad (12.120)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = 1 - (1-p)^{(x+1)^\beta - x^\beta}. \quad (12.121)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = -x^\beta \ln(1-p). \quad (12.122)$$

La función generadora de momentos de X es

$$\phi_X(t) = \sum_{x=0}^{\infty} [(1-p)^{x^\beta} - (1-p)^{(x+1)^\beta}] e^{tx}. \quad (12.123)$$

La esperanza de X es

$$\mathbb{E}[X] = \sum_{x=0}^{\infty} [(1-p)^{x^\beta} - (1-p)^{(x+1)^\beta}] x. \quad (12.124)$$

La demostración queda al lector.

12.1.18 Distribución rectangular discreta

Definición 12.1.18. Distribución Rectangular Discreta. La notación $X \sim \text{Rectangular}(n)$ indica que la variable aleatoria X tiene distribución rectangular discreta con parámetro entero positivo n . Esta distribución asigna igual probabilidad a cada uno de los valores enteros $x \in \{0, 1, \dots, n\}$.

Teorema 12.1.18. Propiedades de la distribución Rectangular Discreta. La función de masa de probabilidad de X es

$$f_X(x) = \frac{1}{n+1}, \quad x \in \{0, 1, \dots, n\}. \quad (12.125)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{x+1}{n+1}, \quad x \in \{0, 1, \dots, n\}. \quad (12.126)$$

La función de supervivencia de X es

$$S_X(x) = \frac{n+1-x}{n+1}, \quad x \in \{0, 1, \dots, n\}. \quad (12.127)$$

La función de riesgo de X es

$$h_X(x) = \frac{1}{n+1-x}, \quad x \in \{0, 1, \dots, n\}. \quad (12.128)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln\left(\frac{n+1-x}{n+1}\right), \quad x \in \{0, 1, \dots, n\}. \quad (12.129)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \lfloor (n+1)u \rfloor, \quad 0 < u < 1. \quad (12.130)$$

La mediana de X es

$$\text{Mediana}(X) = \frac{n-1}{2}, \quad \text{si } n \text{ es par.} \quad (12.131)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{e^{t(n+1)} - 1}{(e^t - 1)(n+1)}, \quad t \in \mathbb{R}. \quad (12.132)$$

La función característica de X es

$$\varphi_X(t) = \frac{e^{it(n+1)} - 1}{(e^{it} - 1)(n+1)}, \quad t \in \mathbb{R}. \quad (12.133)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n}{2}. \quad (12.134)$$

La varianza de X es

$$\text{Var}(X) = \frac{n(n+2)}{12}. \quad (12.135)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3}{5} \cdot \frac{3n^2 + 6n - 4}{n(n+2)}. \quad (12.136)$$

La demostración queda al lector.

12.1.19 Distribución Benford

Definición 12.1.19. Distribución Benford. La notación $X \sim \text{Benford}$ indica que la variable aleatoria X tiene distribución Benford. Esta distribución modela la probabilidad de aparición de los dígitos iniciales en datos reales, y es útil en auditorías, detección de fraudes y análisis de datos empíricos.

Teorema 12.1.19. Propiedades de la distribución Benford. La función de masa de probabilidad de X es

$$f_X(x) = \log_{10} \left(1 + \frac{1}{x} \right), \quad x \in \{1, 2, \dots, 9\}. \quad (12.137)$$

La función de distribución acumulada de X es

$$F_X(x) = \log_{10}(1 + x), \quad x \in \{1, 2, \dots, 9\}. \quad (12.138)$$

La función de supervivencia de X es

$$S_X(x) = 1 - \log_{10}(x), \quad x \in \{1, 2, \dots, 9\}. \quad (12.139)$$

La función de riesgo de X es

$$h_X(x) = \frac{\log_{10} \left(1 + \frac{1}{x} \right)}{1 - \log_{10}(x)}, \quad x \in \{1, 2, \dots, 9\}. \quad (12.140)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln(1 - \log_{10}(x)), \quad x \in \{1, 2, \dots, 9\}. \quad (12.141)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \lfloor 10^u \rfloor, \quad 0 < u < 1. \quad (12.142)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{2 \ln(2) - 4 \ln(3) + 8 \ln(5) - \ln(7)}{\ln(2) + \ln(5)}. \quad (12.143)$$

La varianza de X es

$$\text{Var}(X) \approx 6.0565. \quad (12.144)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] \approx 0.7956, \quad \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] \approx 2.4518. \quad (12.145)$$

La demostración queda al lector.

12.2 Distribuciones de probabilidad continuas

12.2.1 Distribución normal

Definición 12.2.1. Distribución Normal. La notación $X \sim \mathcal{N}(\mu, \sigma^2)$ indica que la variable aleatoria X tiene distribución normal con media $\mu \in \mathbb{R}$ y varianza $\sigma^2 > 0$. Esta distribución es fundamental en estadística y modela fenómenos naturales como alturas, pesos, errores de medición y resultados agregados por el teorema central del límite.

Teorema 12.2.1. Propiedades de la distribución Normal. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}. \quad (12.146)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2} \left[1 + \operatorname{erf}\left(\frac{x-\mu}{\sqrt{2}\sigma}\right) \right], \quad x \in \mathbb{R}. \quad (12.147)$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{2} \left[1 - \operatorname{erf}\left(\frac{x-\mu}{\sqrt{2}\sigma}\right) \right], \quad x \in \mathbb{R}. \quad (12.148)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{\sigma\sqrt{2\pi}} \cdot \frac{\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)}{1 - \operatorname{erf}\left(\frac{x-\mu}{\sqrt{2}\sigma}\right)}, \quad x \in \mathbb{R}. \quad (12.149)$$

La función de riesgo acumulada de X es matemáticamente intractable.

La función inversa de distribución de X es

$$F^{-1}(u) = \mu + \sigma\sqrt{2} \cdot \operatorname{erf}^{-1}(2u - 1), \quad 0 < u < 1. \quad (12.150)$$

La mediana de X es

$$\operatorname{Mediana}(X) = \mu. \quad (12.151)$$

La función generadora de momentos de X es

$$\phi_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right), \quad t \in \mathbb{R}. \quad (12.152)$$

La función característica de X es

$$\varphi_X(t) = \exp\left(i\mu t - \frac{\sigma^2 t^2}{2}\right), \quad t \in \mathbb{R}. \quad (12.153)$$

La esperanza de X es

$$\mathbb{E}[X] = \mu. \quad (12.154)$$

La varianza de X es

$$\operatorname{Var}(X) = \sigma^2. \quad (12.155)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3. \quad (12.156)$$

La demostración queda al lector.

12.2.2 Distribución exponencial

Definición 12.2.2. Distribución Exponencial. La notación $X \sim \text{Exponencial}(\alpha)$ indica que la variable aleatoria X tiene distribución exponencial con parámetro de escala $\alpha > 0$. Alternativamente, puede parametrizarse por su tasa $\lambda = 1/\alpha$. Esta distribución modela tiempos entre eventos en procesos de Poisson, y es la única distribución continua con la propiedad de falta de memoria.

Teorema 12.2.2. Propiedades de la distribución Exponencial. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\alpha} e^{-x/\alpha}, \quad x > 0. \quad (12.157)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-x/\alpha}, \quad x > 0. \quad (12.158)$$

La función de supervivencia de X es

$$S_X(x) = e^{-x/\alpha}, \quad x > 0. \quad (12.159)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{\alpha}, \quad x > 0. \quad (12.160)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \frac{x}{\alpha}, \quad x > 0. \quad (12.161)$$

La función inversa de distribución de X es

$$F^{-1}(u) = -\alpha \ln(1 - u), \quad 0 < u < 1. \quad (12.162)$$

La mediana de X es

$$\text{Mediana}(X) = \alpha \ln 2. \quad (12.163)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{1}{1 - \alpha t}, \quad t < \frac{1}{\alpha}. \quad (12.164)$$

La función característica de X es

$$\varphi_X(t) = \frac{1}{1 - \alpha i t}, \quad t \in \mathbb{R}. \quad (12.165)$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha. \quad (12.166)$$

La varianza de X es

$$\text{Var}(X) = \alpha^2. \quad (12.167)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = 3. \quad (12.168)$$

La demostración queda al lector.

12.2.3 Distribución uniforme continua

Definición 12.2.3. Distribución Uniforme Continua. La notación $X \sim \mathcal{U}(a, b)$ indica que la variable aleatoria X tiene distribución uniforme continua con parámetros $a < b$, donde $a, b \in \mathbb{R}$. Esta distribución modela una variable que tiene igual probabilidad de tomar cualquier valor dentro del intervalo (a, b) .

Teorema 12.2.3. Propiedades de la distribución Uniforme Continua. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{b-a}, \quad a < x < b. \quad (12.169)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{x-a}{b-a}, \quad a < x < b. \quad (12.170)$$

La función de supervivencia de X es

$$S_X(x) = \frac{b-x}{b-a}, \quad a < x < b. \quad (12.171)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{b-x}, \quad a < x < b. \quad (12.172)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(b-a) - \ln(b-x), \quad a < x < b. \quad (12.173)$$

La función inversa de distribución de X es

$$F^{-1}(u) = a + u(b-a), \quad 0 < u < 1. \quad (12.174)$$

La mediana de X es

$$\text{Mediana}(X) = \frac{a+b}{2}. \quad (12.175)$$

La función generadora de momentos de X es

$$\phi_X(t) = \begin{cases} \frac{e^{bt}-e^{at}}{t(b-a)}, & t \neq 0 \\ 1, & t = 0 \end{cases} \quad (12.176)$$

La función característica de X es

$$\varphi_X(t) = \begin{cases} \frac{e^{ibt}-e^{iat}}{it(b-a)}, & t \neq 0 \\ 1, & t = 0 \end{cases} \quad (12.177)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{a+b}{2}. \quad (12.178)$$

La varianza de X es

$$\text{Var}(X) = \frac{(b-a)^2}{12}. \quad (12.179)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{9}{5}. \quad (12.180)$$

12.2.4 Distribución gamma

Definición 12.2.4. Distribución Gamma. La notación $X \sim \text{Gamma}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución Gamma con parámetro de escala $\beta > 0$ y parámetro de forma $\alpha > 0$. Esta distribución se utiliza para modelar tiempos de servicio, tiempos de vida útil y procesos de reparación, y posee una cola derecha exponencial.

Teorema 12.2.4. Propiedades de la distribución Gamma. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)}, \quad x > 0. \quad (12.181)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\Gamma(\alpha, \beta x)}{\Gamma(\alpha)}, \quad x > 0, \quad (12.182)$$

donde $\Gamma(\alpha, \beta x)$ es la función gamma incompleta superior.

La función de supervivencia de X es

$$S_X(x) = 1 - \frac{\Gamma(\alpha, \beta x)}{\Gamma(\alpha)}, \quad x > 0. \quad (12.183)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{x^{\alpha-1} e^{-\beta x} \beta^\alpha}{\Gamma(\alpha) - \Gamma(\alpha, \beta x)}, \quad x > 0. \quad (12.184)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = -\ln \left(1 - \frac{\Gamma(\alpha, \beta x)}{\Gamma(\alpha)} \right), \quad x > 0. \quad (12.185)$$

La función inversa de distribución de X no tiene forma cerrada.

La función generadora de momentos de X es

$$\phi_X(t) = \left(1 - \frac{t}{\beta} \right)^{-\alpha}, \quad t < \beta. \quad (12.186)$$

La función característica de X es

$$\varphi_X(t) = \left(1 - \frac{it}{\beta} \right)^{-\alpha}, \quad t \in \mathbb{R}. \quad (12.187)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\alpha}{\beta}. \quad (12.188)$$

La varianza de X es

$$\text{Var}(X) = \frac{\alpha}{\beta^2}. \quad (12.189)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{2}{\sqrt{\alpha}}, \quad \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = 3 + \frac{6}{\alpha}. \quad (12.190)$$

La demostración queda al lector.

12.2.5 Distribución beta

Definición 12.2.5. Distribución Beta. La notación $X \sim \text{Beta}(\beta, \gamma)$ indica que la variable aleatoria X tiene distribución Beta con parámetros de forma positivos $\beta > 0$ y $\gamma > 0$. Esta distribución se utiliza para modelar proporciones, tasas de éxito, y como distribución a priori en inferencia bayesiana.

Teorema 12.2.5. Propiedades de la distribución Beta/ La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\Gamma(\beta + \gamma)}{\Gamma(\beta)\Gamma(\gamma)} x^{\beta-1} (1-x)^{\gamma-1}, \quad 0 < x < 1. \quad (12.191)$$

La función de distribución acumulada de X es

$$F_X(x) = I_x(\beta, \gamma) = \frac{B_x(\beta, \gamma)}{B(\beta, \gamma)}, \quad 0 < x < 1, \quad (12.192)$$

donde $B_x(\beta, \gamma) = \int_0^x t^{\beta-1} (1-t)^{\gamma-1} dt$ es la función beta incompleta y $B(\beta, \gamma) = \frac{\Gamma(\beta)\Gamma(\gamma)}{\Gamma(\beta+\gamma)}$ es la función beta completa.

La función de supervivencia de X es

$$S_X(x) = 1 - I_x(\beta, \gamma), \quad 0 < x < 1. \quad (12.193)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\Gamma(\beta + \gamma)}{\Gamma(\beta)\Gamma(\gamma)} \cdot \frac{x^{\beta-1} (1-x)^{\gamma-1}}{1 - I_x(\beta, \gamma)}, \quad 0 < x < 1. \quad (12.194)$$

La mediana de X es el valor $m \in (0, 1)$ tal que $I_m(\beta, \gamma) = 0.5$.

La esperanza de X es

$$\mathbb{E}[X] = \frac{\beta}{\beta + \gamma}. \quad (12.195)$$

La varianza de X es

$$\text{Var}(X) = \frac{\beta\gamma}{(\beta + \gamma)^2 (\beta + \gamma + 1)}. \quad (12.196)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{2(\gamma - \beta) \sqrt{1 + \beta + \gamma}}{\sqrt{\beta\gamma(\beta + \gamma + 2)}} \quad (12.197)$$

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = \frac{3(\beta^2\gamma + \beta\gamma^2 - 2\beta\gamma + 2\beta^2 + 2\gamma^2)(1 + \beta + \gamma)}{\beta\gamma(\beta + \gamma + 2)(\beta + \gamma + 3)}. \quad (12.198)$$

La demostración queda al lector.

12.2.6 Distribución chi-cuadrado

Definición 12.2.6. Distribución Chi-cuadrado. La notación $X \sim \chi^2(n)$ indica que la variable aleatoria X tiene distribución chi-cuadrado con $n > 0$ grados de libertad. Esta distribución surge como la suma de los cuadrados de n variables normales estándar independientes, y se utiliza ampliamente en pruebas de hipótesis, análisis de varianza y teoría de confiabilidad.

Teorema 12.2.6. Propiedades de la distribución Chi-cuadrado. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{x^{n/2-1} e^{-x/2}}{2^{n/2} \Gamma(n/2)}, \quad x > 0. \quad (12.199)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\Gamma(n/2, x/2)}{\Gamma(n/2)}, \quad x > 0, \quad (12.200)$$

donde $\Gamma(s, x)$ es la función gamma incompleta superior.

La función de supervivencia de X es

$$S_X(x) = 1 - \frac{\Gamma(n/2, x/2)}{\Gamma(n/2)}, \quad x > 0. \quad (12.201)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)}, \quad x > 0. \quad (12.202)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x), \quad x > 0. \quad (12.203)$$

La moda de X es

$$\text{Moda}(X) = \max\{n-2, 0\}. \quad (12.204)$$

La función generadora de momentos de X es

$$\phi_X(t) = (1 - 2t)^{-n/2}, \quad t < \frac{1}{2}. \quad (12.205)$$

La función característica de X es

$$\varphi_X(t) = (1 - 2it)^{-n/2}, \quad t \in \mathbb{R}. \quad (12.206)$$

La esperanza de X es

$$\mathbb{E}[X] = n. \quad (12.207)$$

La varianza de X es

$$\text{Var}(X) = 2n. \quad (12.208)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \sqrt{\frac{8}{n}}, \quad \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = 3 + \frac{12}{n}. \quad (12.209)$$

La demostración queda al lector.

12.2.7 Distribución t de student

Definición 12.2.7. Distribución t de Student. La notación $X \sim t(n)$ indica que la variable aleatoria X tiene distribución t de Student con $n > 0$ grados de libertad. Esta distribución surge en pruebas de hipótesis sobre medias, especialmente cuando la varianza poblacional es desconocida y el tamaño de muestra es pequeño.

Teorema 12.2.7. Propiedades de la distribución t de Student

La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad x \in \mathbb{R}. \quad (12.210)$$

La función de distribución acumulada de X es

$$F_X(x) = \int_{-\infty}^x \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} dt. \quad (12.211)$$

La función de supervivencia de X es

$$S_X(x) = \int_x^{\infty} \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} dt. \quad (12.212)$$

La mediana de X es

$$\text{Mediana}(X) = 0. \quad (12.213)$$

La esperanza de X es

$$\mathbb{E}[X] = 0, \quad \text{si } n > 1. \quad (12.214)$$

La varianza de X es

$$\text{Var}(X) = \frac{n}{n-2}, \quad \text{si } n > 2. \quad (12.215)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0, \quad \text{si } n > 3, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{3(n-2)}{n-4}, \quad \text{si } n > 4. \quad (12.216)$$

La demostración queda al lector.

12.2.8 Distribución F de Fisher-Snedecor

Definición 12.2.8. Distribución F de Fisher-Snedecor. La notación $X \sim F(n_1, n_2)$ indica que la variable aleatoria X tiene distribución F con $n_1 > 0$ y $n_2 > 0$ grados de libertad en el numerador y denominador, respectivamente. Esta distribución se utiliza para comparar varianzas entre dos poblaciones normales o tasas entre poblaciones exponenciales.

Teorema 12.2.8. Propiedades de la distribución F

La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} \left(\frac{n_1}{n_2}\right)^{n_1/2} \cdot \frac{x^{n_1/2-1}}{\left(1 + \frac{n_1}{n_2}x\right)^{(n_1+n_2)/2}}, \quad x > 0. \quad (12.217)$$

La moda de X es

$$\text{Moda}(X) = \frac{n_2(n_1 - 2)}{n_1(n_2 + 2)}, \quad \text{si } n_1 > 2. \quad (12.218)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n_2}{n_2 - 2}, \quad \text{si } n_2 > 2. \quad (12.219)$$

La varianza de X es

$$\text{Var}(X) = \frac{2n_2^2(n_1 + n_2 - 2)}{n_1(n_2 - 2)^2(n_2 - 4)}, \quad \text{si } n_2 > 4. \quad (12.220)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{(2n_1 + n_2 - 2)\sqrt{8(n_2 - 4)}}{(n_2 - 6)\sqrt{n_1(n_1 + n_2 - 2)}}, \quad \text{si } n_2 > 6, \quad (12.221)$$

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = \frac{3(n_2 - 4)}{n_2 - 8} \cdot \frac{10n_2^2 + 1n_2 - 20n_1 + 8n_1n_2 + n_1n_2^2 + 16 - 16n_2 + 4n_2^2}{n_1(n_1 + n_2 - 2)(n_2 - 6)(n_2 - 8)}, \quad \text{si } n_2 > 8. \quad (12.222)$$

La demostración queda al lector.

12.2.9 Distribución Log-normal

Definición 12.2.9. Distribución Log-normal. La notación $X \sim \text{Lognormal}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución log-normal con parámetros $\alpha > 0$ y $\beta > 0$. Esta distribución modela variables positivas cuyo logaritmo sigue una distribución normal, y es útil para representar tiempos de vida, ingresos, tamaños biológicos y productos de variables independientes.

Teorema 12.2.9. Propiedades de la distribución Log-normal. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{x\beta\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{\ln(x/\alpha)}{\beta}\right)^2\right), \quad x > 0. \quad (12.223)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2} + \frac{1}{2} \operatorname{erf}\left(\frac{\ln(x) - \alpha}{\sqrt{2}\beta}\right), \quad x > 0. \quad (12.224)$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{2} - \frac{1}{2} \operatorname{erf}\left(\frac{\ln(x) - \alpha}{\sqrt{2}\beta}\right), \quad x > 0. \quad (12.225)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{x\beta\sqrt{2\pi}} \exp\left(-\frac{(\ln(x) - \alpha)^2}{2\beta^2}\right) \left[\frac{1}{1 - \operatorname{erf}\left(\frac{\ln(x) - \alpha}{\sqrt{2}\beta}\right)} \right], \quad x > 0. \quad (12.226)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(2) + i\pi - \ln\left(1 - \operatorname{erf}\left(\frac{\ln(x) - \alpha}{\sqrt{2}\beta}\right)\right), \quad x > 0. \quad (12.227)$$

La mediana de X es

$$\text{Mediana}(X) = \alpha. \quad (12.228)$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha e^{\beta^2/2}. \quad (12.229)$$

La varianza de X es

$$\text{Var}(X) = \alpha^2 e^{\beta^2} (e^{\beta^2} - 1). \quad (12.230)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = (e^{\beta^2} + 2)\sqrt{e^{\beta^2} - 1}, \quad \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = e^{4\beta^2} + 2e^{3\beta^2} + 3e^{2\beta^2} - 3. \quad (12.231)$$

La demostración queda al lector.

12.2.10 Distribución Weibull

Definición 12.2.10. Distribución Weibull. La notación $X \sim \text{Weibull}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución Weibull con parámetro de escala $\alpha > 0$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza ampliamente en análisis de supervivencia y confiabilidad para modelar tiempos de vida, fallas y servicios.

Teorema 12.2.10. Propiedades de la distribución Weibull. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\beta}{\alpha} x^{\beta-1} e^{-(x/\alpha)^\beta}, \quad x > 0. \quad (12.232)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-(x/\alpha)^\beta}, \quad x > 0. \quad (12.233)$$

La función de supervivencia de X es

$$S_X(x) = e^{-(x/\alpha)^\beta}, \quad x > 0. \quad (12.234)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\beta}{\alpha} x^{\beta-1}, \quad x > 0. \quad (12.235)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \left(\frac{x}{\alpha}\right)^\beta, \quad x > 0. \quad (12.236)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \alpha [-\ln(1-u)]^{1/\beta}, \quad 0 < u < 1. \quad (12.237)$$

La mediana de X es

$$\text{Mediana}(X) = \alpha (\ln 2)^{1/\beta}. \quad (12.238)$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha \Gamma\left(1 + \frac{1}{\beta}\right). \quad (12.239)$$

La varianza de X es

$$\text{Var}(X) = \alpha^2 \left[\Gamma\left(1 + \frac{2}{\beta}\right) - \left(\Gamma\left(1 + \frac{1}{\beta}\right)\right)^2 \right]. \quad (12.240)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{\Gamma\left(1 + \frac{3}{\beta}\right) - 3\Gamma\left(1 + \frac{1}{\beta}\right)\Gamma\left(1 + \frac{2}{\beta}\right) + 2\left(\Gamma\left(1 + \frac{1}{\beta}\right)\right)^3}{\left[\Gamma\left(1 + \frac{2}{\beta}\right) - \left(\Gamma\left(1 + \frac{1}{\beta}\right)\right)^2\right]^{3/2}}, \quad (12.241)$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{\Gamma\left(1 + \frac{4}{\beta}\right) - 4\Gamma\left(1 + \frac{1}{\beta}\right)\Gamma\left(1 + \frac{3}{\beta}\right) + 6\left(\Gamma\left(1 + \frac{1}{\beta}\right)\right)^2\Gamma\left(1 + \frac{2}{\beta}\right) - 3\left(\Gamma\left(1 + \frac{1}{\beta}\right)\right)^4}{\left[\Gamma\left(1 + \frac{2}{\beta}\right) - \left(\Gamma\left(1 + \frac{1}{\beta}\right)\right)^2\right]^2}. \quad (12.242)$$

La demostración queda al lector.

12.2.11 Distribución Laplace Asimétrica

Definición 12.2.11. Distribución Laplace Asimétrica. La notación $X \sim \text{Laplace}(\alpha_1, \alpha_2)$ indica que la variable aleatoria X tiene distribución Laplace con parámetros de escala positivos $\alpha_1 > 0$ (lado izquierdo) y $\alpha_2 > 0$ (lado derecho). Esta distribución es una alternativa a la normal, con colas más pesadas, útil en modelado de errores, tiempos de servicio y fenómenos con discontinuidad en la pendiente.

Teorema 12.2.11. Propiedades de la distribución Laplace Asimétrica. La función de densidad de probabilidad de X es

$$f_X(x) = \begin{cases} \frac{1}{\alpha_1 + \alpha_2} \exp\left(-\frac{x}{\alpha_1}\right), & x < 0 \\ \frac{1}{\alpha_1 + \alpha_2} \exp\left(-\frac{x}{\alpha_2}\right), & x \geq 0 \end{cases} \quad (12.243)$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} \frac{\alpha_1}{\alpha_1 + \alpha_2} \exp\left(-\frac{x}{\alpha_1}\right), & x < 0 \\ 1 - \frac{\alpha_2}{\alpha_1 + \alpha_2} \exp\left(-\frac{x}{\alpha_2}\right), & x \geq 0 \end{cases} \quad (12.244)$$

La función de supervivencia de X es

$$S_X(x) = \begin{cases} 1 - \frac{\alpha_1}{\alpha_1 + \alpha_2} \exp\left(-\frac{x}{\alpha_1}\right), & x < 0 \\ \frac{\alpha_2}{\alpha_1 + \alpha_2} \exp\left(-\frac{x}{\alpha_2}\right), & x \geq 0 \end{cases} \quad (12.245)$$

La función de riesgo de X es

$$h_X(x) = \begin{cases} \frac{\exp(x/\alpha_1)}{\alpha_1 + \alpha_2 + \alpha_1 \exp(x/\alpha_1)}, & x < 0 \\ \frac{1}{\alpha_2}, & x \geq 0 \end{cases} \quad (12.246)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \begin{cases} -\alpha_1 [-\ln(\alpha_1 + \alpha_2) + \ln(\alpha_1) - \ln(u)], & 0 < u < \frac{\alpha_1}{\alpha_1 + \alpha_2} \\ -\alpha_2 [\ln(\alpha_1 + \alpha_2) - \ln(\alpha_2) + \ln(1 - u)], & \frac{\alpha_1}{\alpha_1 + \alpha_2} \leq u < 1 \end{cases} \quad (12.247)$$

La mediana de X es

$$\text{Mediana}(X) = 0. \quad (12.248)$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha_2 - \alpha_1. \quad (12.249)$$

La varianza de X es

$$\text{Var}(X) = \frac{\alpha_1^2 + \alpha_2^2}{1}. \quad (12.250)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{-2(\alpha_1^3 - \alpha_2^3)}{(\alpha_1^2 + \alpha_2^2)^{3/2}}, \quad \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = \frac{3(3\alpha_1^4 + 2\alpha_1^2\alpha_2^2 + 3\alpha_2^4)}{(\alpha_1^2 + \alpha_2^2)^2}. \quad (12.251)$$

La demostración queda al lector.

12.2.12 Distribución logística generalizada

Definición 12.2.12. Distribución Logística Generalizada. La notación $X \sim \text{Logistic}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución logística con parámetro de escala $\lambda > 0$ y parámetro de forma $\kappa > 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento sigmoideal, colas pesadas y saturación, como tiempos de adopción, respuestas biológicas y modelos de supervivencia.

Teorema 12.2.12. Propiedades de la distribución Logística Generalizada. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\lambda \kappa^\kappa e^{\kappa x}}{(1 + (\lambda e^x)^\kappa)^2}, \quad x \in \mathbb{R}. \quad (12.252)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\lambda \kappa e^{\kappa x}}{1 + \lambda \kappa e^x}, \quad x \in \mathbb{R}. \quad (12.253)$$

La función de supervivencia de X es

$$S_X(x) = \frac{1 + \lambda \kappa e^x - \lambda \kappa e^{\kappa x}}{1 + \lambda \kappa e^x}, \quad x \in \mathbb{R}. \quad (12.254)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\kappa e^{\kappa x} (\lambda \kappa + \lambda^2 \kappa e^x)}{(1 + (\lambda e^x)^\kappa)^2 (1 + \lambda \kappa e^x - \lambda \kappa e^{\kappa x})}, \quad x \in \mathbb{R}. \quad (12.255)$$

La función inversa de distribución de X es

$$F^{-1}(u) = -\frac{1}{\kappa} \ln \left(\frac{u}{1-u} \right) - \ln \lambda, \quad 0 < u < 1. \quad (12.256)$$

La función generadora de momentos de X es

$$\phi_X(t) = \int_{-\infty}^{\infty} \frac{\lambda \kappa^\kappa e^{x(t+\kappa)}}{(1 + (\lambda e^x)^\kappa)^2} dx. \quad (12.257)$$

La función característica de X es

$$\varphi_X(t) = \int_{-\infty}^{\infty} \frac{\lambda \kappa^\kappa e^{x(it+\kappa)}}{(1 + (\lambda e^x)^\kappa)^2} dx. \quad (12.258)$$

La esperanza de X es

$$\mathbb{E}[X] = -\ln \lambda. \quad (12.259)$$

La varianza de X es

$$\text{Var}(X) = \frac{\pi^2}{3\kappa^2}. \quad (12.260)$$

El sesgo y la curtosis poblacional de X son expresiones más complejas y no se presentan en forma cerrada.

La demostración queda al lector.

12.2.13 Distribución Rayleigh

Definición 12.2.13. Distribución Rayleigh. La notación $X \sim \text{Rayleigh}(\alpha)$ indica que la variable aleatoria X tiene distribución Rayleigh con parámetro de escala $\alpha > 0$. Esta distribución se utiliza para modelar tiempos de vida, tiempos de servicio y magnitudes de vectores bidimensionales con componentes normales independientes.

Teorema 12.2.13. Propiedades de la distribución Rayleigh. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{2x}{\alpha} e^{-x^2/\alpha}, \quad x > 0. \quad (12.261)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-x^2/\alpha}, \quad x > 0. \quad (12.262)$$

La función de supervivencia de X es

$$S_X(x) = e^{-x^2/\alpha}, \quad x > 0. \quad (12.263)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{2x}{\alpha}, \quad x > 0. \quad (12.264)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \frac{x^2}{\alpha}, \quad x > 0. \quad (12.265)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \sqrt{-\alpha \ln(1-u)}, \quad 0 < u < 1. \quad (12.266)$$

La mediana de X es

$$\text{Mediana}(X) = \sqrt{\alpha \ln 2}. \quad (12.267)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\alpha \pi^{1/2}}{2}. \quad (12.268)$$

La varianza de X es

$$\text{Var}(X) = \alpha \left(1 - \frac{\pi}{4}\right). \quad (12.269)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{2\sqrt{\pi(\pi-3)}}{(4-\pi)^{3/2}}, \quad \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = \frac{6\pi(4-\pi) - 16}{(4-\pi)^2}. \quad (12.270)$$

La demostración queda al lector.

12.2.14 Distribución gaussiana inversa

Definición 12.2.14. Distribución Gaussiana Inversa. La notación $X \sim \text{InverseGaussian}(\lambda, \mu)$ indica que la variable aleatoria X tiene distribución gaussiana inversa con parámetros $\lambda > 0$ (precisión) y $\mu > 0$ (media). Esta distribución se utiliza para modelar tiempos de vida, trayectorias de partículas en movimiento browniano y procesos de decisión estocásticos.

Teorema 12.2.14. Propiedades de la distribución Gaussiana Inversa. La función de densidad de probabilidad de X es

$$f_X(x) = \sqrt{\frac{\lambda}{2\pi x^3}} \exp\left(-\frac{\lambda(x-\mu)^2}{2x\mu^2}\right), \quad x > 0. \quad (12.271)$$

La función generadora de momentos de X es

$$\phi_X(t) = \exp\left(\frac{\lambda}{\mu} \left[1 - \sqrt{1 - \frac{2\mu^2 t}{\lambda}}\right]\right), \quad t < \frac{\lambda}{2\mu^2}. \quad (12.272)$$

La función característica de X es

$$\varphi_X(t) = \exp\left(\frac{\lambda}{\mu} \left[1 - \sqrt{1 - \frac{2\mu^2 it}{\lambda}}\right]\right), \quad t \in \mathbb{R}. \quad (12.273)$$

La esperanza de X es

$$\mathbb{E}[X] = \mu. \quad (12.274)$$

La varianza de X es

$$\text{Var}(X) = \frac{\mu^3}{\lambda}. \quad (12.275)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 3\sqrt{\frac{\mu}{\lambda}}, \quad \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = 3 + \frac{15\mu}{\lambda}. \quad (12.276)$$

La demostración queda al lector.

12.2.15 Distribución Pareto

Definición 12.2.15. Distribución Pareto. La notación $X \sim \text{Pareto}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución Pareto con parámetros $\lambda > 0$ (mínimo) y $\kappa > 0$ (forma). Esta distribución se utiliza para modelar ingresos, duraciones mínimas, tiempos de vida con garantía, y fenómenos con comportamiento de cola pesada.

Teorema 12.2.15. Propiedades de la distribución Pareto. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\kappa \lambda^\kappa}{x^{\kappa+1}}, \quad x > \lambda. \quad (12.277)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \left(\frac{\lambda}{x}\right)^\kappa, \quad x > \lambda. \quad (12.278)$$

La función de supervivencia de X es

$$S_X(x) = \left(\frac{\lambda}{x}\right)^\kappa, \quad x > \lambda. \quad (12.279)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\kappa}{x}, \quad x > \lambda. \quad (12.280)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = -\kappa(\ln \lambda - \ln x), \quad x > \lambda. \quad (12.281)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \lambda(1-u)^{-1/\kappa}, \quad 0 < u < 1. \quad (12.282)$$

La mediana de X es

$$\text{Mediana}(X) = \lambda \cdot 2^{1/\kappa}. \quad (12.283)$$

La función generadora de momentos de X es

$$\phi_X(t) = \kappa(-\lambda t)^\kappa \Gamma(-\kappa, -\lambda t), \quad t < 0. \quad (12.284)$$

La función característica de X es

$$\varphi_X(t) = \kappa(-\lambda i t)^\kappa \Gamma(-\kappa, -\lambda i t), \quad t \in \mathbb{R}. \quad (12.285)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\kappa \lambda}{\kappa - 1}, \quad \text{si } \kappa > 1. \quad (12.286)$$

La varianza de X es

$$\text{Var}(X) = \frac{\kappa \lambda^2}{(\kappa - 1)^2(\kappa - 2)}, \quad \text{si } \kappa > 2. \quad (12.287)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{2\kappa + 1}{\kappa - 3}, \quad \text{si } \kappa > 3, \quad (12.288)$$

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = \frac{3(\kappa - 2)(3\kappa^3 + \kappa + 2)}{\kappa(\kappa - 3)(\kappa - 4)}, \quad \text{si } \kappa > 4. \quad (12.289)$$

La demostracion queda al lector.

12.2.16 Distribución Cauchy

Definición 12.2.16. Distribución Cauchy. La notación $X \sim \text{Cauchy}(a, \alpha)$ indica que la variable aleatoria X tiene distribución Cauchy con parámetro de localización $a \in \mathbb{R}$ y parámetro de escala $\alpha > 0$. Esta distribución es conocida por sus colas pesadas y por el hecho de que no tiene momentos definidos.

Teorema 12.2.16. Propiedades de la distribución Cauchy. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\alpha\pi \left[1 + \left(\frac{x-a}{\alpha}\right)^2\right]}, \quad x \in \mathbb{R}. \quad (12.290)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2\pi} \left[\pi - 2 \arctan \left(\frac{a-x}{\alpha} \right) \right], \quad x \in \mathbb{R}. \quad (12.291)$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{2\pi} \left[\pi + 2 \arctan \left(\frac{a-x}{\alpha} \right) \right], \quad x \in \mathbb{R}. \quad (12.292)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{2\alpha(\alpha^2 - 2xa + a^2 + x^2 - 1)}{\pi + 2 \arctan \left(\frac{a-x}{\alpha} \right)}, \quad x \in \mathbb{R}. \quad (12.293)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(2\pi) - \ln \left[\pi + 2 \arctan \left(\frac{a-x}{\alpha} \right) \right], \quad x \in \mathbb{R}. \quad (12.294)$$

La función inversa de distribución de X es

$$F^{-1}(u) = a - \alpha \cot(\pi u), \quad 0 < u < 1. \quad (12.295)$$

La mediana de X es

$$\text{Mediana}(X) = a. \quad (12.296)$$

La demostración queda al lector.

12.2.17 Distribución Gompertz

Definición 12.2.17. Distribución Gompertz. La notación $X \sim \text{Gompertz}(\delta, \kappa)$ indica que la variable aleatoria X tiene distribución Gompertz con parámetros de forma $\delta > 0$ y $\kappa > 1$. Esta distribución se utiliza en análisis actuarial para modelar tiempos de vida de adultos y en estudios de supervivencia con tasas de riesgo crecientes.

Teorema 12.2.17. Propiedades de la distribución Gompertz. La función de densidad de probabilidad de X es

$$f_X(x) = \delta \kappa^x \exp\left(-\frac{\delta(\kappa^x - 1)}{\ln \kappa}\right), \quad x > 0. \quad (12.297)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \exp\left(-\frac{\delta(\kappa^x - 1)}{\ln \kappa}\right), \quad x > 0. \quad (12.298)$$

La función de supervivencia de X es

$$S_X(x) = \exp\left(-\frac{\delta(\kappa^x - 1)}{\ln \kappa}\right), \quad x > 0. \quad (12.299)$$

La función de riesgo de X es

$$h_X(x) = \delta \kappa^x, \quad x > 0. \quad (12.300)$$

La función de riesgo acumulada de X es

$$H_X(x) = \frac{\delta(\kappa^x - 1)}{\ln \kappa}, \quad x > 0. \quad (12.301)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{-\ln \delta - \ln(\delta - \ln(1 - u) \ln \kappa)}{\ln \kappa}, \quad 0 < u < 1. \quad (12.302)$$

La mediana de X es

$$\text{Mediana}(X) = \frac{-\ln \delta - \ln(\delta + \ln 2 \cdot \ln \kappa)}{\ln \kappa}. \quad (12.303)$$

La demostración queda al lector.

12.2.18 Distribución valor extremo

Definición 12.2.18. Distribución de Valor Extremo. La notación $X \sim \text{ExtremeValue}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución de valor extremo con parámetro de escala $\alpha > 0$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza para modelar fenómenos extremos como niveles de inundación, magnitudes sísmicas y máximos de muestras.

Teorema 12.2.18. Propiedades de la distribución de Valor Extremo. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\beta}{\alpha} e^{\beta x - e^{\beta x}/\alpha}, \quad x \in \mathbb{R}. \quad (12.304)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \exp\left(-\frac{e^{\beta x}}{\alpha}\right), \quad x \in \mathbb{R}. \quad (12.305)$$

La función de supervivencia de X es

$$S_X(x) = \exp\left(-\frac{e^{\beta x}}{\alpha}\right), \quad x \in \mathbb{R}. \quad (12.306)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \beta e^{\beta x}, \quad x \in \mathbb{R}. \quad (12.307)$$

La función de riesgo acumulada de X es

$$H_X(x) = \frac{e^{\beta x}}{\alpha}, \quad x \in \mathbb{R}. \quad (12.308)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{\ln(-\alpha \ln(1-u))}{\beta}, \quad 0 < u < 1. \quad (12.309)$$

La demostración queda al lector.

12.2.19 Distribución gamma generalizada

Definición 12.2.19. Distribución Gamma Generalizada. La notación $X \sim \text{GammaGeneralizada}(\alpha, \beta, \gamma)$ indica que la variable aleatoria X tiene distribución gamma generalizada con parámetros positivos: escala $\alpha > 0$, forma $\beta > 0$, y potencia $\gamma > 0$. Esta distribución incluye como casos especiales la gamma, la Weibull y la exponencial, y se utiliza para modelar tiempos de vida, servicios y fenómenos con flexibilidad en la forma de la cola.

Teorema 12.2.19. Propiedades de la distribución Gamma Generalizada. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\gamma x^{\gamma\beta-1} \exp\left(-\left(\frac{x}{\alpha}\right)^\gamma\right)}{\alpha^{\gamma\beta} \Gamma(\beta)}, \quad x > 0. \quad (12.310)$$

La esperanza de X es

$$\mathbb{E}[X] = \alpha \cdot \frac{\Gamma\left(\beta + \frac{1}{\gamma}\right)}{\Gamma(\beta)}. \quad (12.311)$$

La varianza de X es

$$\text{Var}(X) = \alpha^2 \left[\frac{\Gamma\left(\beta + \frac{2}{\gamma}\right)}{\Gamma(\beta)} - \left(\frac{\Gamma\left(\beta + \frac{1}{\gamma}\right)}{\Gamma(\beta)} \right)^2 \right]. \quad (12.312)$$

12.2.20 Distribución Pareto generalizada

Definición 12.2.20. Distribución Pareto Generalizada. La notación $X \sim \text{ParetoGeneralizada}(\delta, \kappa, \gamma)$ indica que la variable aleatoria X tiene distribución Pareto generalizada con parámetros de forma $\delta > 0$, $\gamma \geq 0$, y $\kappa \geq -\delta\gamma$. Esta distribución se utiliza para modelar fenómenos con colas pesadas y tasas de riesgo variables, como ingresos extremos, tiempos de espera prolongados y duraciones de eventos raros.

Teorema 12.2.20. Propiedades de la distribución Pareto Generalizada. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\gamma + \frac{\kappa}{x+\delta}}{\left(1 + \frac{x}{\delta}\right)^\kappa} e^{-\gamma x}, \quad x > 0. \quad (12.313)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-\gamma x} \left(1 + \frac{x}{\delta}\right)^{-\kappa}, \quad x > 0. \quad (12.314)$$

La función de supervivencia de X es

$$S_X(x) = e^{-\gamma x} \left(1 + \frac{x}{\delta}\right)^{-\kappa}, \quad x > 0. \quad (12.315)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \gamma + \frac{\kappa}{x + \delta}, \quad x > 0. \quad (12.316)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \gamma x + \kappa \ln \left(1 + \frac{x}{\delta}\right), \quad x > 0. \quad (12.317)$$

La demostración queda al lector.

12.2.21 Distribución t no central

Definición 12.2.21. Distribución t No Central. La notación $X \sim t_{\text{no central}}(n, \delta)$ indica que la variable aleatoria X tiene distribución t no central con $n \in \mathbb{N}^+$ grados de libertad y parámetro de no centralidad $\delta \in \mathbb{R}$. Esta distribución surge en pruebas de hipótesis cuando la media poblacional no es cero, y se utiliza en inferencia estadística bajo desviaciones sistemáticas.

Teorema 12.2.21. Propiedades de la distribución t No Central. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\sqrt{n}^{n/2} e^{-\delta^2/2}}{\pi \Gamma(n/2) (n + x^2)^{(n+1)/2}} \cdot \sum_{i=0}^{\infty} \frac{\Gamma\left(\frac{n+i+1}{2}\right)}{i!} \left(\frac{x\delta\sqrt{2}}{\sqrt{n+x^2}} \right)^i, \quad x \in \mathbb{R}. \quad (12.318)$$

La esperanza de X es

$$\mathbb{E}[X] = \delta \cdot \sqrt{\frac{n}{2}} \cdot \frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)}, \quad \text{si } n > 1. \quad (12.319)$$

La varianza de X es

$$\text{Var}(X) = \left[\frac{n(1 + \delta^2)}{n-2} - \delta^2 \cdot \frac{n}{2} \left(\frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} \right)^2 \right], \quad \text{si } n > 2. \quad (12.320)$$

12.2.22 Distribución F no central

Definición 12.2.22. Distribución F No Central. La notación $X \sim F_{\text{no central}}(n_1, n_2, \delta)$ indica que la variable aleatoria X tiene distribución F no central con parámetros $n_1, n_2 \in \mathbb{N}^+$ y parámetro de no centralidad $\delta > 0$. Esta distribución surge en pruebas de hipótesis sobre varianzas cuando hay un efecto sistemático presente, como en análisis de varianza con medias desplazadas.

Teorema 12.2.22. Propiedades de la distribución F No Central. La función de densidad de probabilidad de X es

$$f_X(x) = \sum_{i=0}^{\infty} \frac{e^{-\delta/2} \left(\frac{\delta}{2}\right)^i}{i!} \cdot \frac{\Gamma\left(\frac{2i+n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_2}{2}\right) \Gamma\left(\frac{2i+n_1}{2}\right)} \cdot \left(\frac{n_1}{n_2}\right)^{(2i+n_1)/2} \cdot \frac{x^{(2i+n_1-2)/2}}{\left(1 + \frac{n_1}{n_2}x\right)^{(2i+n_1+n_2)/2}}, \quad x > 0. \quad (12.321)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{n_2(n_1 + \delta)}{n_1(n_2 - 2)}, \quad \text{si } n_2 > 2. \quad (12.322)$$

La varianza de X es

$$\text{Var}(X) = \frac{2[(n_1 + \delta)^2 + (n_1 + 2\delta)(n_2 - 2)]}{n_1^2(n_2 - 2)^2(n_2 - 4)}, \quad \text{si } n_2 > 4. \quad (12.323)$$

La demostración queda al lector.

12.2.23 Distribución chicuadrado no central

Definición 12.2.23. Distribución Chi-cuadrado No Central. La notación $X \sim \chi_{\text{no central}}^2(\delta, n)$ indica que la variable aleatoria X tiene distribución chi-cuadrado no central con $n \in \mathbb{N}^+$ grados de libertad y parámetro de no centralidad $\delta \geq 0$. Esta distribución surge cuando se suman los cuadrados de variables normales independientes con medias distintas de cero, y se utiliza en pruebas de hipótesis bajo desviaciones sistemáticas.

Teorema 12.2.23. Propiedades de la distribución Chi-cuadrado No Central. La función de densidad de probabilidad de X es

$$f_X(x) = e^{-(\delta+x)/2} \sum_{k=0}^{\infty} \frac{(\delta/2)^k}{k!} \cdot \frac{x^{(n+2k)/2-1}}{2^{(n+2k)/2} \Gamma\left(\frac{n+2k}{2}\right)}, \quad x > 0. \quad (12.324)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{e^{\delta t/(1-2t)}}{(1-2t)^{n/2}}, \quad t < \frac{1}{2}. \quad (12.325)$$

La función característica de X es

$$\varphi_X(t) = \frac{e^{\delta it/(1-2it)}}{(1-2it)^{n/2}}, \quad t \in \mathbb{R}. \quad (12.326)$$

La esperanza de X es

$$\mathbb{E}[X] = n + \delta. \quad (12.327)$$

La varianza de X es

$$\text{Var}(X) = 2(n + 2\delta). \quad (12.328)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{2^{3/2}(n + 3\delta)}{(n + 2\delta)^{3/2}}, \quad \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = 3 + \frac{12(n + 4\delta)}{(n + 2\delta)^2}. \quad (12.329)$$

La demostración queda al lector.

12.2.24 Distribución beta no central

Definición 12.2.24. Distribución Beta No Central. La notación $X \sim \text{Beta}_{\text{no central}}(\beta, \gamma, \delta)$ indica que la variable aleatoria X tiene distribución beta no central con parámetros positivos $\beta > 0$, $\gamma > 0$, y parámetro de no centralidad $\delta > 0$. Esta distribución surge en pruebas de hipótesis relacionadas con proporciones bajo desviaciones sistemáticas, y en modelos de razón de varianzas con efectos fijos.

Teorema 12.2.24. Propiedades de la distribución Beta No Central. La función de densidad de probabilidad de X es

$$f_X(x) = e^{-\delta/2} \sum_{i=0}^{\infty} \frac{1}{i!} \left(\frac{\delta}{2}\right)^i \cdot \frac{\Gamma(i + \beta + \gamma)}{\Gamma(\gamma)\Gamma(i + \beta)} \cdot x^{i+\beta-1}(1-x)^{\gamma-1}, \quad 0 < x < 1. \quad (12.330)$$

La demostración queda al lector.

12.2.25 Distribución F doble no central

Definición 12.2.25. Distribución F Doble No Central. La notación $X \sim F''(n_1, n_2, \delta, \gamma)$ indica que la variable aleatoria X tiene distribución F doblemente no central con parámetros $n_1, n_2 \in \mathbb{N}^+$ y parámetros de no centralidad $\delta > 0$, $\gamma > 0$. Esta distribución surge en pruebas de hipótesis sobre varianzas cuando tanto el numerador como el denominador están desplazados por efectos sistemáticos.

Teorema 12.2.25. Propiedades de la distribución F Doble No Central. La función de densidad de probabilidad de X es

$$f_X(x) = \sum_{j=0}^{\infty} \sum_{k=0}^{\infty} \frac{e^{-\delta/2}(\delta/2)^j}{j!} \cdot \frac{e^{-\gamma/2}(\gamma/2)^k}{k!} \cdot \frac{n_1^{n_1/2+j} \cdot n_2^{n_2/2+k}}{B\left(\frac{n_1}{2} + j, \frac{n_2}{2} + k\right)} \cdot \frac{x^{n_1/2+j-1}}{(n_2 + n_1 x)^{(n_1+n_2-j-k)/2}}, \quad x > 0. \quad (12.331)$$

La demostración queda al lector.

12.2.26 Distribución log-gamma

Definición 12.2.26. Distribución Log-gamma. La notación $X \sim \text{LogGamma}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución log-gamma con parámetro de escala $\alpha > 0$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento exponencial modulado por una transformación logarítmica, como tiempos de espera, procesos de servicio y datos con asimetría extrema.

Teorema 12.2.26. Propiedades de la distribución Log-gamma. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{e^{\beta x} \cdot e^{-e^x/\alpha}}{\alpha^{\beta} \Gamma(\beta)}, \quad x \in \mathbb{R}. \quad (12.332)$$

La demostración queda al lector.

12.2.27 Distribución log-logística

Definición 12.2.27. Distribución Log-logística. La notación $X \sim \text{LogLogística}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución log-logística con parámetro de escala $\lambda > 0$ y parámetro de forma $\kappa > 0$. Esta distribución se utiliza para modelar tiempos de vida, duraciones de servicio y fenómenos con tasas de riesgo no monótonas.

Teorema 12.2.27. Propiedades de la distribución Log-logística. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\lambda\kappa(\lambda x)^{\kappa-1}}{(1 + (\lambda x)^\kappa)^2}, \quad x > 0. \quad (12.333)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{(\lambda x)^\kappa}{1 + (\lambda x)^\kappa}, \quad x > 0. \quad (12.334)$$

La función de supervivencia de X es

$$S_X(x) = \frac{1}{1 + (\lambda x)^\kappa}, \quad x > 0. \quad (12.335)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\lambda\kappa(\lambda x)^{\kappa-1}}{1 + (\lambda x)^\kappa}, \quad x > 0. \quad (12.336)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln[1 + (\lambda x)^\kappa], \quad x > 0. \quad (12.337)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{1}{\lambda} \left(\frac{u}{1-u} \right)^{1/\kappa}, \quad 0 < u < 1. \quad (12.338)$$

La mediana de X es

$$\text{Mediana}(X) = \frac{1}{\lambda}. \quad (12.339)$$

La función generadora de momentos de X es

$$\phi_X(t) = \int_0^\infty e^{tx} \cdot \frac{\lambda\kappa(\lambda x)^{\kappa-1}}{(1 + (\lambda x)^\kappa)^2} dx, \quad t > 0. \quad (12.340)$$

La función característica de X es

$$\varphi_X(t) = \int_0^\infty e^{itx} \cdot \frac{\lambda\kappa(\lambda x)^{\kappa-1}}{(1 + (\lambda x)^\kappa)^2} dx, \quad t \in \mathbb{R}. \quad (12.341)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\pi}{\lambda\kappa \sin\left(\frac{\pi}{\kappa}\right)}, \quad \text{si } \kappa > 1. \quad (12.342)$$

La varianza de X es

$$\text{Var}(X) = \left[\frac{\pi^2}{\kappa^2} \left(\frac{1 - \cos\left(\frac{\pi}{\kappa}\right)}{2} + \frac{\sin\left(\frac{\pi(\kappa+2)}{\kappa}\right)}{\sin\left(\frac{\pi(\kappa+2)}{\kappa}\right) \cos\left(\frac{\pi}{\kappa}\right)} - 1 \right) \right] \cdot \frac{1}{(\lambda\kappa)^2}, \quad \text{si } \kappa > 2. \quad (12.343)$$

La demostración queda al lector.

12.2.28 Distribución hiperexponencial

Definición 12.2.28. Distribución Hiperexponencial. La notación $X \sim \text{Hiperexponencial}(\alpha, p)$ indica que la variable aleatoria X tiene distribución hiperexponencial con parámetros de escala $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)$ y probabilidades $p = (p_1, p_2, \dots, p_n)$, donde $\alpha_i > 0$, $p_i > 0$, y $\sum_{i=1}^n p_i = 1$. Esta distribución modela tiempos de espera con múltiples fases exponenciales y es útil en teoría de colas y confiabilidad.

Teorema 12.2.28. Propiedades de la distribución Hiperexponencial. La función de densidad de probabilidad de X es

$$f_X(x) = \sum_{i=1}^n \frac{p_i}{\alpha_i} e^{-x/\alpha_i}, \quad x > 0. \quad (12.344)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \sum_{i=1}^n p_i e^{-x/\alpha_i}, \quad x > 0. \quad (12.345)$$

La función de supervivencia de X es

$$S_X(x) = \sum_{i=1}^n p_i e^{-x/\alpha_i}, \quad x > 0. \quad (12.346)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\sum_{i=1}^n \frac{p_i}{\alpha_i} e^{-x/\alpha_i}}{\sum_{i=1}^n p_i e^{-x/\alpha_i}}, \quad x > 0. \quad (12.347)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = -\ln \left(\sum_{i=1}^n p_i e^{-x/\alpha_i} \right), \quad x > 0. \quad (12.348)$$

La función generadora de momentos de X es

$$M_X(t) = \sum_{i=1}^n \frac{p_i}{1 - \alpha_i t}, \quad |t| < \frac{1}{\max_j \alpha_j}. \quad (12.349)$$

La esperanza de X es

$$\mathbb{E}[X] = \sum_{i=1}^n p_i \alpha_i. \quad (12.350)$$

La demostración queda al lector.

12.2.29 Distribución hipoexponencial

Definición 12.2.29. Distribución Hipoexponencial. La notación $X \sim \text{Hipoexponencial}(\alpha)$ indica que la variable aleatoria X tiene distribución hipoexponencial con vector de parámetros positivos $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)$, donde $\alpha_i \neq \alpha_j$ para $i \neq j$. Esta distribución representa la suma de n variables exponenciales independientes con tasas distintas, y se utiliza en teoría de colas y análisis de confiabilidad.

Teorema 12.2.29. Propiedades de la distribución Hipoexponencial. La función de densidad de probabilidad de X es

$$f_X(x) = \sum_{i=1}^n \left(\frac{1}{\alpha_i} e^{-x/\alpha_i} \prod_{\substack{j=1 \\ j \neq i}}^n \frac{\alpha_i}{\alpha_i - \alpha_j} \right), \quad x > 0. \quad (12.351)$$

Para el caso $n = 2$, la función de distribución acumulada es

$$F_X(x) = 1 - \frac{1}{\alpha_1 - \alpha_2} (\alpha_2 e^{-x/\alpha_2} - \alpha_1 e^{-x/\alpha_1}), \quad x > 0. \quad (12.352)$$

La esperanza de X es

$$\mathbb{E}[X] = \sum_{i=1}^n \alpha_i. \quad (12.353)$$

La varianza de X es

$$\text{Var}(X) = \sum_{i=1}^n \alpha_i^2. \quad (12.354)$$

El sesgo poblacional de X es

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{2 \sum_{i=1}^n \alpha_i^3}{\left(\sum_{i=1}^n \alpha_i^2 \right)^{3/2}}. \quad (12.355)$$

La demostración queda al lector.

12.2.30 Distribución Makeham

Definición 12.2.30. Distribución Makeham. La notación $X \sim \text{Makeham}(\delta, \kappa, \gamma)$ indica que la variable aleatoria X tiene distribución Makeham con parámetros $\delta > 0$, $\kappa > 1$, y $\gamma > 0$. Esta distribución se utiliza principalmente en estudios actuariales para modelar la duración de la vida adulta, incorporando tanto un componente exponencial como uno de crecimiento Gompertziano.

Teorema 12.2.30. Propiedades de la distribución Makeham. La función de densidad de probabilidad de X es

$$f_X(x) = (\gamma + \delta\kappa x) \cdot e^{-\gamma x - \delta(\kappa x - 1)/\ln(\kappa)}, \quad x > 0. \quad (12.356)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{-(\gamma x \ln(\kappa) + \delta\kappa x - \delta)/\ln(\kappa)}, \quad x > 0. \quad (12.357)$$

La función de supervivencia de X es

$$S_X(x) = e^{-(\gamma x \ln(\kappa) + \delta\kappa x - \delta)/\ln(\kappa)}, \quad x > 0. \quad (12.358)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \gamma + \delta\kappa x, \quad x > 0. \quad (12.359)$$

La función de riesgo acumulada de X es

$$H_X(x) = \frac{\gamma x \ln(\kappa) + \delta\kappa x - \delta}{\ln(\kappa)}, \quad x > 0. \quad (12.360)$$

La demostración queda al lector.

12.2.31 Distribución lomax

Definición 12.2.31. Distribución Lomax. La notación $X \sim \text{Lomax}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución Lomax con parámetro de escala $\lambda > 0$ y parámetro de forma $\kappa > 0$. Esta distribución es una versión desplazada de la Pareto tipo II y se utiliza para modelar datos con colas pesadas, como ingresos, tiempos de espera y fallas en sistemas.

Teorema 12.2.31. Propiedades de la distribución Lomax. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\lambda\kappa}{(1 + \lambda x)^{\kappa+1}}, \quad x > 0. \quad (12.361)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - (1 + \lambda x)^{-\kappa}, \quad x > 0. \quad (12.362)$$

La función de supervivencia de X es

$$S_X(x) = (1 + \lambda x)^{-\kappa}, \quad x > 0. \quad (12.363)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\lambda\kappa}{1 + \lambda x}, \quad x > 0. \quad (12.364)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \kappa \ln(1 + \lambda x), \quad x > 0. \quad (12.365)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{(1 - u)^{-1/\kappa} - 1}{\lambda}, \quad 0 < u < 1. \quad (12.366)$$

La mediana de X es

$$\text{Mediana}(X) = \frac{2^{1/\kappa} - 1}{\lambda}. \quad (12.367)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\lambda}{\kappa - 1}, \quad \text{si } \kappa > 1. \quad (12.368)$$

La demostración queda al lector.

12.2.32 Distribución Muth

Definición 12.2.32. Distribución Muth. La notación $X \sim \text{Muth}(\kappa)$ indica que la variable aleatoria X tiene distribución Muth con parámetro $\kappa \in (0, 1]$. Esta distribución se utiliza para modelar tiempos de vida con tasas de riesgo crecientes y se ha aplicado en estudios actuariales y confiabilidad.

Teorema 12.2.32. Propiedades de la distribución Muth. La función de densidad de probabilidad de X es

$$f_X(x) = (e^{\kappa x} - \kappa) \cdot \exp \left[- \left(\frac{e^{\kappa x}}{\kappa} + \frac{\kappa x + 1}{\kappa} \right) \right], \quad x > 0. \quad (12.369)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - \exp \left[- \left(\frac{e^{\kappa x}}{\kappa} + \frac{\kappa x + 1}{\kappa} \right) \right], \quad x > 0. \quad (12.370)$$

La función de supervivencia de X es

$$S_X(x) = \exp \left[- \left(\frac{e^{\kappa x}}{\kappa} + \frac{\kappa x + 1}{\kappa} \right) \right], \quad x > 0. \quad (12.371)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = e^{\kappa x} - \kappa, \quad x > 0. \quad (12.372)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \frac{e^{\kappa x}}{\kappa} - \frac{\kappa x + 1}{\kappa}, \quad x > 0. \quad (12.373)$$

La esperanza de X es

$$\mathbb{E}[X] = 1. \quad (12.374)$$

La demostración queda al lector.

12.2.33 Distribución Von Mises

Definición 12.2.33. Distribución Von Mises. La notación $X \sim \text{Von Mises}(\kappa, \mu)$ indica que la variable aleatoria X tiene distribución von Mises con parámetro de forma $\kappa \in \mathbb{R}$ y parámetro de localización $\mu \in (0, 2\pi)$. Esta distribución se utiliza para modelar datos angulares o direccionales, como orientaciones, fases o direcciones en estadística circular.

Teorema 12.2.33. Propiedades de la distribución Von Mises. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{e^{\kappa \cos(x-\mu)}}{2\pi I_0(\kappa)}, \quad 0 < x < 2\pi, \quad (12.375)$$

donde $I_0(\kappa)$ es la función de Bessel modificada de primera especie y orden cero:

$$I_0(\kappa) = \sum_{i=0}^{\infty} \frac{(\kappa^2)^i}{(2^{2i})(i!)^2}. \quad (12.376)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2\pi I_0(\kappa)} \int_0^x e^{\kappa \cos(t-\mu)} dt, \quad 0 < x < 2\pi. \quad (12.377)$$

La esperanza de X es

$$\mathbb{E}[X] = \mu. \quad (12.378)$$

La demostración queda al lector.

12.2.34 Distribución arcsin

Definición 12.2.34. Distribución Arcsin. La notación $X \sim \text{Arcsin}$ indica que la variable aleatoria X tiene distribución arcsin sobre el intervalo $(0, 1)$. Esta distribución se utiliza en estadística bayesiana, teoría de probabilidad y análisis de proporciones, especialmente cuando se requiere una forma simétrica con densidad infinita en los extremos.

Teorema 12.2.34. Propiedades de la distribución Arcsin. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\pi\sqrt{x(1-x)}}, \quad 0 < x < 1. \quad (12.379)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\pi + 2 \arcsin(2x - 1)}{2\pi}, \quad 0 < x < 1. \quad (12.380)$$

La función de supervivencia de X es

$$S_X(x) = \frac{\pi - 2 \arcsin(2x - 1)}{2\pi}, \quad 0 < x < 1. \quad (12.381)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{1}{\sqrt{x(1-x)} \cdot (\pi - 2 \arcsin(2x - 1))}, \quad 0 < x < 1. \quad (12.382)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{1}{2} - \frac{1}{2} \cos(\pi u), \quad 0 < u < 1. \quad (12.383)$$

La esperanza de X es

$$\mathbb{E}[X] = 1. \quad (12.384)$$

La varianza de X es

$$\text{Var}(X) = 1. \quad (12.385)$$

El sesgo y la curtosis poblacional de X son

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = 0, \quad \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = \frac{3}{2}. \quad (12.386)$$

La demostración queda al lector.

12.2.35 Distribución arctangent

Definición 12.2.35. Distribución Arctangent. La notación $X \sim \text{Arctangent}(\lambda, \varphi)$ indica que la variable aleatoria X tiene distribución arctangent con parámetro de localización $\lambda > 0$ y parámetro de fase $\varphi \in \mathbb{R}$. Esta distribución se utiliza para modelar fenómenos con colas pesadas y simetría desplazada, como en análisis de señales y modelos de dispersión.

Teorema 12.2.35. Propiedades de la distribución Arctangent. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\lambda}{(\arctan(\lambda\varphi) + \frac{1}{2}\pi)(1 + \lambda^2(x - \varphi)^2)}, \quad x \geq 0. \quad (12.387)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{2 \arctan(\lambda\varphi) - \arctan(-\lambda x + \lambda\varphi)}{2 \arctan(\lambda\varphi) + \pi}, \quad x \geq 0. \quad (12.388)$$

La función de supervivencia de X es

$$S_X(x) = \frac{\pi + 2 \arctan(-\lambda x + \lambda\varphi)}{2 \arctan(\lambda\varphi) + \pi}, \quad x \geq 0. \quad (12.389)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{2\lambda}{(1 + \lambda^2 x^2 - 2\lambda^2 \varphi x + \lambda^2 \varphi^2)(\pi + 2 \arctan(-\lambda x + \lambda\varphi))}, \quad x \geq 0. \quad (12.390)$$

La función de riesgo acumulada de X es

$$H_X(x) = \ln(2 \arctan(\lambda\varphi) + \pi) - \ln(\pi + 2 \arctan(\lambda(-x + \varphi))), \quad x \geq 0. \quad (12.391)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \frac{\lambda\varphi + \tan\left(-\arctan(\lambda\varphi) + u \arctan(\lambda\varphi) + \frac{1}{2}u\pi\right)}{\lambda}, \quad 0 < u < 1. \quad (12.392)$$

La demostración queda al lector.

12.2.36 Distribución power

Definición 12.2.36. Distribución Power. La notación $X \sim \text{Power}(\alpha, \beta)$ indica que la variable aleatoria X tiene distribución power con parámetro de escala $\alpha > 0$ y parámetro de forma $\beta > 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento polinomial dentro de un intervalo finito, como tiempos de falla, proporciones y datos normalizados.

Teorema 12.2.36. Propiedades de la distribución Power. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\beta x^{\beta-1}}{\alpha^\beta}, \quad 0 < x < \alpha. \quad (12.393)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{x^\beta}{\alpha^\beta}, \quad 0 < x < \alpha. \quad (12.394)$$

La función de supervivencia de X es

$$S_X(x) = 1 - \frac{x^\beta}{\alpha^\beta}, \quad 0 < x < \alpha. \quad (12.395)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\beta x^{\beta-1} \alpha^{-\beta}}{1 - x^\beta \alpha^{-\beta}}, \quad 0 < x < \alpha. \quad (12.396)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln \left(1 - \left(\frac{x}{\alpha} \right)^\beta \right), \quad 0 < x < \alpha. \quad (12.397)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \alpha u^{1/\beta}, \quad 0 < u < 1. \quad (12.398)$$

La mediana de X es

$$\text{Mediana}(X) = \alpha \left(\frac{1}{2} \right)^{1/\beta}. \quad (12.399)$$

La función generadora de momentos de X es

$$\phi_X(t) = \frac{-\beta \Gamma(\beta, -t\alpha) - \Gamma(1 + \beta)}{(-t)^\beta \alpha^\beta}, \quad -\infty < t < \infty. \quad (12.400)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\alpha \beta}{1 + \beta}. \quad (12.401)$$

La varianza de X es

$$\text{Var}(X) = \frac{\alpha^2 \beta}{(2 + \beta)(1 + \beta)^2}. \quad (12.402)$$

El sesgo poblacional de X es

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{2(\beta - 1)}{(2 + \beta)(3 + \beta)} \sqrt{\frac{(3 + \beta)}{\beta}}. \quad (12.403)$$

La curtosis poblacional de X es

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = \frac{3(2 - \beta + 3\beta^2)}{\beta(2 + \beta)(3 + \beta)(4 + \beta)}. \quad (12.404)$$

12.2.37 Distribución power estándar

Definición 12.2.37. Distribución Power estándar. La notación $X \sim \text{Power}(1, \beta)$ indica que la variable aleatoria X tiene distribución power estándar con parámetro de forma $\beta > 0$. Esta distribución se define sobre el intervalo $(0, 1)$ y se utiliza para modelar proporciones, tiempos normalizados y fenómenos con crecimiento polinomial.

Teorema 12.2.37. Propiedades de la distribución Power estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \beta x^{\beta-1}, \quad 0 < x < 1. \quad (12.405)$$

La función de distribución acumulada de X es

$$F_X(x) = x^\beta, \quad 0 < x < 1. \quad (12.406)$$

La función de supervivencia de X es

$$S_X(x) = 1 - x^\beta, \quad 0 < x < 1. \quad (12.407)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\beta x^{\beta-1}}{1 - x^\beta}, \quad 0 < x < 1. \quad (12.408)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln(1 - x^\beta), \quad 0 < x < 1. \quad (12.409)$$

La función inversa de distribución de X es

$$F^{-1}(u) = u^{1/\beta}, \quad 0 < u < 1. \quad (12.410)$$

La mediana de X es

$$\text{Mediana}(X) = \left(\frac{1}{2}\right)^{1/\beta}. \quad (12.411)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\beta}{\beta + 1}. \quad (12.412)$$

La varianza de X es

$$\text{Var}(X) = \frac{\beta}{(\beta + 2)(\beta + 1)^2}. \quad (12.413)$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{2(1 - \beta)}{(\beta + 2)(\beta + 3)}\sqrt{\beta}. \quad (12.414)$$

La curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = \frac{3(3\beta^2 - \beta + 2)}{\beta(\beta + 2)(\beta + 3)(\beta + 4)}. \quad (12.415)$$

La demostración queda al lector.

12.2.38 Distribución normal estándar

Definición 12.2.38. Distribución Normal Estándar. La notación $X \sim \mathcal{N}(0, 1)$ indica que la variable aleatoria X tiene distribución normal estándar con media $\mu = 0$ y varianza $\sigma^2 = 1$. Esta distribución surge al estandarizar una variable normal cualquiera mediante la transformación $Z = \frac{X - \mu}{\sigma}$, y se utiliza ampliamente en estadística, probabilidad y teoría de errores.

Teorema 12.2.38. Propiedades de la distribución Normal Estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{e^{-x^2/2}}{\sqrt{2\pi}}, \quad x \in \mathbb{R}. \quad (12.416)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{1}{2} + \frac{1}{2} \operatorname{erf}\left(\frac{x}{\sqrt{2}}\right), \quad x \in \mathbb{R}, \quad (12.417)$$

donde la función error es $\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt$. La función de supervivencia de X es

$$S_X(x) = \frac{1}{2} - \frac{1}{2} \operatorname{erf}\left(\frac{x}{\sqrt{2}}\right), \quad x \in \mathbb{R}. \quad (12.418)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{-e^{-x^2/2}}{\sqrt{2\pi} \left(-1 + \operatorname{erf}\left(\frac{x}{\sqrt{2}}\right)\right)}, \quad x \in \mathbb{R}. \quad (12.419)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(2) - \ln\left(1 - \operatorname{erf}\left(\frac{x}{\sqrt{2}}\right)\right), \quad x \in \mathbb{R}. \quad (12.420)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \sqrt{2} \cdot \operatorname{erf}^{-1}(2u - 1), \quad 0 < u < 1. \quad (12.421)$$

La mediana y la moda de X son

$$\operatorname{Mediana}(X) = \operatorname{Moda}(X) = 0. \quad (12.422)$$

La función característica de X es

$$\varphi_X(t) = e^{-t^2/2}, \quad t \in \mathbb{R}. \quad (12.423)$$

La esperanza de X es

$$\mathbb{E}[X] = 0. \quad (12.424)$$

La varianza de X es

$$\operatorname{Var}(X) = 1. \quad (12.425)$$

El sesgo y la curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = 0. \quad (12.426)$$

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = 3. \quad (12.427)$$

12.2.39 Distribución Cauchy estándar

Definición 12.2.39. Distribución Cauchy estándar. La notación $X \sim \text{Cauchy}(1, 0)$ indica que la variable aleatoria X tiene distribución Cauchy estándar con parámetro de escala $\gamma = 1$ y parámetro de localización $x_0 = 0$. Esta distribución se caracteriza por colas pesadas y se utiliza en estadística robusta, física y teoría de señales.

Teorema 12.2.39. Propiedades de la distribución Cauchy estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}. \quad (12.428)$$

La función de distribución acumulada de X es

$$F_X(x) = \frac{\pi + 2 \arctan(x)}{2\pi}, \quad x \in \mathbb{R}. \quad (12.429)$$

La función de supervivencia de X es

$$S_X(x) = \frac{\pi - 2 \arctan(x)}{2\pi}, \quad x \in \mathbb{R}. \quad (12.430)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{2}{(1+x^2)(\pi - 2 \arctan(x))}, \quad x \in \mathbb{R}. \quad (12.431)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = \ln(2) + \ln(\pi) - \ln(\pi - 2 \arctan(x)), \quad x \in \mathbb{R}. \quad (12.432)$$

La función inversa de distribución de X es

$$F^{-1}(u) = -\cot(\pi u), \quad 0 < u < 1. \quad (12.433)$$

La mediana de X es

$$\text{Mediana}(X) = 0. \quad (12.434)$$

La función característica de X es

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = e^{-|t|}, \quad t \in \mathbb{R}. \quad (12.435)$$

La demostración queda al lector.

12.2.40 Distribución triangular estándar

Definición 12.2.40. Distribución Triangular estándar. La notación $X \sim \text{Triangular}(-1, 0, 1)$ indica que la variable aleatoria X tiene distribución triangular estándar con mínimo $a = -1$, modo $c = 0$, y máximo $b = 1$. Esta distribución se utiliza para modelar incertidumbre cuando se conocen los valores extremos y el valor más probable.

Teorema 12.2.40. Propiedades de la distribución Triangular estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \begin{cases} x+1, & -1 < x < 0, \\ 1-x, & 0 \leq x < 1, \end{cases} \quad (12.436)$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} \frac{1}{2}(2x^2 + x + 1), & -1 < x < 0, \\ \frac{1}{2}(2x^2 - x + 1), & 0 \leq x < 1, \end{cases} \quad (12.437)$$

La función de riesgo de X es

$$h_X(x) = \begin{cases} \frac{x+1}{\frac{1}{2}(2x^2 - x + 1)}, & -1 < x < 0, \\ \frac{1-x}{\frac{1}{2}(2x^2 + x + 1)}, & 0 \leq x < 1, \end{cases} \quad (12.438)$$

La función de riesgo acumulada de X es

$$H_X(x) = \begin{cases} -\ln\left(\frac{1}{2}(2x^2 - x + 1)\right), & -1 < x < 0, \\ -\ln\left(\frac{1}{2}(2x^2 + x + 1)\right), & 0 \leq x < 1, \end{cases} \quad (12.439)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \begin{cases} -1 + \sqrt{2u}, & 0 < u < \frac{1}{2}, \\ 1 - \sqrt{2(1-u)}, & \frac{1}{2} \leq u < 1, \end{cases} \quad (12.440)$$

La mediana, la moda y la esperanza de X son

$$\text{Mediana}(X) = \text{Moda}(X) = \mathbb{E}[X] = 0. \quad (12.441)$$

La función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{tX}] = \frac{e^{-t} - 2 + e^t}{t^2}, \quad t \in \mathbb{R}. \quad (12.442)$$

La varianza de X es

$$\text{Var}(X) = \frac{1}{6}. \quad (12.443)$$

El sesgo y la curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0. \quad (12.444)$$

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{12}{5}. \quad (12.445)$$

La demostración queda al lector.

12.2.41 Distribución Wald estándar

Definición 12.2.41. Distribución Wald estándar. La notación $X \sim \text{standardWald}(\lambda)$ indica que la variable aleatoria X tiene distribución Wald estándar con parámetro $\lambda > 0$. Esta distribución también es conocida como distribución inversa gaussiana estándar y se utiliza en modelos de tiempo de decisión, procesos estocásticos y análisis de supervivencia.

Teorema 12.2.41. Propiedades de la distribución Wald estándar. La función de densidad de probabilidad de X es

$$f_X(x) = \sqrt{\frac{\lambda}{2\pi x^3}} \cdot \exp\left(-\frac{\lambda(x-1)^2}{2x}\right), \quad x > 0. \quad (12.446)$$

La función de distribución acumulada de X es

$$F_X(x) = \int_0^x \sqrt{\frac{\lambda}{2\pi t^3}} \cdot \exp\left(-\frac{\lambda(t-1)^2}{2t}\right) dt, \quad x > 0. \quad (12.447)$$

La función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{tX}] = \exp\left(\lambda \left(1 - \sqrt{1 - \frac{2t}{\lambda}}\right)\right), \quad t < \frac{\lambda}{2}. \quad (12.448)$$

La función característica de X es

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \exp\left(\lambda \left(1 - \sqrt{1 - \frac{2it}{\lambda}}\right)\right), \quad t \in \mathbb{R}. \quad (12.449)$$

La esperanza de X es

$$\mathbb{E}[X] = 1. \quad (12.450)$$

La varianza de X es

$$\text{Var}(X) = \frac{1}{\lambda}. \quad (12.451)$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{3}{\sqrt{\lambda}}. \quad (12.452)$$

La curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = 3 + \frac{15}{\lambda}. \quad (12.453)$$

La demostración queda al lector.

12.2.42 Distribución minimax

Definición 12.2.42. Distribución Minimax. La notación $X \sim \text{Minimax}(\beta, \gamma)$ indica que la variable aleatoria X tiene distribución minimax con parámetros de forma positivos $\beta > 0$ y $\gamma > 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento polinomial y decaimiento controlado en el intervalo unitario.

Teorema 12.2.42. Propiedades de la distribución Minimax. La función de densidad de probabilidad de X es

$$f_X(x) = \beta\gamma x^{\beta-1}(1-x^\beta)^{\gamma-1}, \quad 0 < x < 1. \quad (12.454)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - (1-x^\beta)^\gamma, \quad 0 < x < 1. \quad (12.455)$$

La función de supervivencia de X es

$$S_X(x) = (1-x^\beta)^\gamma, \quad 0 < x < 1. \quad (12.456)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = \frac{\beta\gamma x^{\beta-1}}{1-x^\beta}, \quad 0 < x < 1. \quad (12.457)$$

La función inversa de distribución de X es

$$F^{-1}(u) = [1 - (1-u)^{1/\gamma}]^{1/\beta}, \quad 0 < u < 1. \quad (12.458)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{\Gamma(\gamma+1) \cdot \Gamma\left(\frac{\beta+1}{\beta}\right)}{\Gamma\left(\frac{\beta\gamma+\beta+1}{\beta}\right)}. \quad (12.459)$$

La demostración queda al lector.

12.2.43 Distribución IDB

Definición 12.2.43. Distribución IDB. La notación $X \sim \text{IDB}(\delta, \kappa, \gamma)$ indica que la variable aleatoria X tiene distribución IDB con parámetros $\delta > 0$, $\kappa > 0$, y $\gamma \geq 0$. Esta distribución se utiliza para modelar fenómenos con crecimiento polinomial y decaimiento exponencial, y aparece en contextos de confiabilidad y procesos estocásticos.

Teorema 12.2.43. Propiedades de la distribución IDB. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{((1+\kappa x)^{\delta x + \gamma}) \cdot \exp\left(-\frac{1}{2\delta x^2}\right)}{(1+\kappa x)^{\gamma/\kappa+1}}, \quad x > 0. \quad (12.460)$$

La demostración queda al lector.

12.2.44 Distribución error

Definición 12.2.44. Distribución Error. La notación $X \sim \text{Error}(a, b, c)$ indica que la variable aleatoria X tiene distribución error con parámetro de localización $a \in \mathbb{R}$, parámetro de escala $b > 0$, y parámetro de forma $c > 0$. Esta distribución generaliza la forma de la normal y la Laplace, y se utiliza para modelar errores de medición y fenómenos con simetría central.

Teorema 12.2.44. Propiedades de la distribución Error. La función de densidad de probabilidad de X es

$$f_X(x) = \frac{\exp\left(-\frac{1}{2}\left(\frac{|x-a|}{b}\right)^{2/c}\right)}{b \cdot 2^{c/2+1} \cdot \Gamma(c/2 + 1)}, \quad x \in \mathbb{R}. \quad (12.461)$$

La función de distribución acumulada de X es

$$F_X(x) = \int_{-\infty}^x \frac{\exp\left(-\frac{1}{2}\left(\frac{|t-a|}{b}\right)^{2/c}\right)}{b \cdot 2^{c/2+1} \cdot \Gamma(c/2 + 1)} dt, \quad x \in \mathbb{R}. \quad (12.462)$$

La mediana y la moda de X son

$$\text{Mediana}(X) = \text{Moda}(X) = a. \quad (12.463)$$

La esperanza de X es

$$\mathbb{E}[X] = a. \quad (12.464)$$

La varianza de X es

$$\text{Var}(X) = \frac{2cb^2\Gamma(3c/2)}{\Gamma(c/2)}. \quad (12.465)$$

El sesgo poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = 0. \quad (12.466)$$

La curtosis poblacional de X es

$$\mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{\Gamma(5c/2) \cdot \Gamma(c/2)}{(\Gamma(3c/2))^2}. \quad (12.467)$$

La demostración queda al lector.

12.2.45 Distribución exponential power

Definición 12.2.45. Distribución Exponential Power. La notación $X \sim \text{ExponentialPower}(\lambda, \kappa)$ indica que la variable aleatoria X tiene distribución exponential power con parámetro de escala $\lambda > 0$ y parámetro de forma $\kappa > 0$. Esta distribución es notable por su capacidad de modelar funciones de riesgo con forma de bañera, lo que la hace útil en análisis de confiabilidad y supervivencia.

Teorema 12.2.45. Propiedades de la distribución Exponential Power.

La función de densidad de probabilidad de X es

$$f_X(x) = e^{1-e^{\lambda x^\kappa}} \cdot e^{\lambda x^\kappa} \cdot \lambda \kappa x^{\kappa-1}, \quad x > 0. \quad (12.468)$$

La función de distribución acumulada de X es

$$F_X(x) = 1 - e^{1-e^{\lambda x^\kappa}}, \quad x > 0. \quad (12.469)$$

La función de supervivencia de X es

$$S_X(x) = e^{1-e^{\lambda x^\kappa}}, \quad x > 0. \quad (12.470)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)} = e^{\lambda x^\kappa} \cdot \lambda \kappa x^{\kappa-1}, \quad x > 0. \quad (12.471)$$

La función de riesgo acumulada de X es

$$H_X(x) = -\ln S_X(x) = e^{\lambda x^\kappa} - 1, \quad x > 0. \quad (12.472)$$

La función inversa de distribución de X es

$$F^{-1}(u) = \left[\frac{1}{\lambda} \ln(1 - \ln(1 - u)) \right]^{1/\kappa}, \quad 0 < u < 1. \quad (12.473)$$

La mediana de X es

$$\text{Mediana}(X) = \left[\lambda \cdot \ln \left(1 - \ln \left(\frac{1}{2} \right) \right) \right]^{-1/\kappa}. \quad (12.474)$$

La función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{tX}] = \int_0^\infty e^{tx} \cdot f_X(x) dx. \quad (12.475)$$

La función característica de X es

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \int_0^\infty e^{itx} \cdot f_X(x) dx. \quad (12.476)$$

Nota: La esperanza, varianza, sesgo y curtosis de X son matemáticamente intratables.

La demostración queda al lector.

12.2.46 Distribución triangular

Definición 12.2.46. Distribución Triangular. La notación $X \sim \text{Triangular}(a, m, b)$ indica que la variable aleatoria X tiene distribución triangular con mínimo a , modo m , y máximo b , donde $a < m < b$. Esta distribución se utiliza como modelo aproximado cuando no hay datos disponibles, pero se conocen los valores extremos y el valor más probable.

Teorema 12.2.46. Propiedades de la distribución Triangular. La función de densidad de probabilidad de X es

$$f_X(x) = \begin{cases} \frac{2(x-a)}{(b-a)(m-a)}, & a < x < m, \\ \frac{2(b-x)}{(b-a)(b-m)}, & m \leq x < b, \end{cases} \quad (12.477)$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} \frac{(x-a)^2}{(b-a)(m-a)}, & a < x < m, \\ 1 - \frac{(b-x)^2}{(b-a)(b-m)}, & m \leq x < b, \end{cases} \quad (12.478)$$

La función de supervivencia de X es

$$S_X(x) = \begin{cases} 1 - \frac{(x-a)^2}{(b-a)(m-a)}, & a < x < m, \\ \frac{(b-x)^2}{(b-a)(b-m)}, & m \leq x < b, \end{cases} \quad (12.479)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)}, \quad \text{con expresiones específicas según el intervalo.} \quad (12.480)$$

La función generadora de momentos de X es

$$\phi_X(t) = \mathbb{E}[e^{tX}] = \frac{-2(-me^{ta} + be^{ta} + be^{tm} + ae^{tm} - ae^{tb} + me^{tb})}{(a-m)(a-b)(m-b)t^2}, \quad t > 0. \quad (12.481)$$

La función característica de X es

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \frac{2(-me^{ita} + be^{ita} + be^{itm} + ae^{itm} - ae^{itb} + me^{itb})}{(a-m)(a-b)(m-b)t^2}, \quad t \in \mathbb{R}. \quad (12.482)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{a + m + b}{3}. \quad (12.483)$$

La varianza de X es

$$\text{Var}(X) = \frac{a^2 + m^2 + b^2 - ab - am - mb}{18}. \quad (12.484)$$

El sesgo poblacional de X es

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{2(a + b - 2m)(2a - b - m)(a - 2b + m)}{5(a^2 + b^2 + m^2 - ab - am - bm)^{3/2}}. \quad (12.485)$$

La curtosis poblacional de X es

$$\mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] = \frac{12}{5}. \quad (12.486)$$

La demostración queda al lector.

12.2.47 Distribución TSP

Definición 12.2.47. Distribución TSP. La notación $X \sim \text{TSP}(a, b, m, n)$ indica que la variable aleatoria X tiene distribución TSP con parámetros $a < m < b$ y $n > 0$. Esta distribución generaliza la triangular mediante polinomios segmentados, y se utiliza en modelado cuando se desea controlar la forma de la densidad en cada tramo.

Teorema 12.2.47. Propiedades de la distribución TSP. La función de densidad de probabilidad de X es

$$f_X(x) = \begin{cases} \frac{n(x-a)^{n-1}}{(b-a)(m-a)^{n-1}}, & a < x < m, \\ \frac{n(b-x)^{n-1}}{(b-a)(b-m)^{n-1}}, & m \leq x < b, \end{cases} \quad (12.487)$$

La función de distribución acumulada de X es

$$F_X(x) = \begin{cases} \frac{(x-a)^n}{(b-a)(m-a)^{n-1}}, & a < x < m, \\ 1 - \frac{(b-x)^n}{(b-a)(b-m)^{n-1}}, & m \leq x < b, \end{cases} \quad (12.488)$$

La función de supervivencia de X es

$$S_X(x) = \begin{cases} 1 - \frac{(x-a)^n}{(b-a)(m-a)^{n-1}}, & a < x < m, \\ \frac{(b-x)^n}{(b-a)(b-m)^{n-1}}, & m \leq x < b, \end{cases} \quad (12.489)$$

La función de riesgo de X es

$$h_X(x) = \frac{f_X(x)}{S_X(x)}, \quad \text{con expresiones específicas según el intervalo.} \quad (12.490)$$

La esperanza de X es

$$\mathbb{E}[X] = \frac{b-m+mn+a}{n+1}. \quad (12.491)$$

La varianza de X es

$$\text{Var}(X) = \frac{-2mnb + 2m^2n + a^2n + b^2n - 2mna + 2bm - 2ba + 2am - 2m^2}{(n+1)^2(n+2)}. \quad (12.492)$$

La demostración queda al lector.

12.3 Transformadas

Definición 12.3.1. Transformada de Laplace. Sea $f(t)$ definida para $t \geq 0$. La transformada de Laplace $\mathcal{L}\{f(t)\}(s)$ se define como

$$\mathcal{L}\{f(t)\}(s) = \int_0^{\infty} f(t)e^{-st} dt \mid s \in \mathbb{C}. \quad (12.493)$$

Definición 12.3.2. Transformada de Fourier. Sea $f(t)$ definida en $\mathbb{R}$. La transformada de Fourier $\mathcal{F}\{f(t)\}(\omega)$ se define como

$$\mathcal{F}\{f(t)\}(\omega) = \int_{-\infty}^{\infty} f(t)e^{-i\omega t} dt \mid \omega \in \mathbb{R}. \quad (12.494)$$

Definición 12.3.3. Transformada de Mellin. Sea $f(t)$ definida para $t > 0$. La transformada de Mellin $\mathcal{M}\{f(t)\}(s)$ se define como

$$\mathcal{M}\{f(t)\}(s) = \int_0^{\infty} t^{s-1} f(t) dt \mid s \in \mathbb{C}. \quad (12.495)$$

Definición 12.3.4. Transformada de Hilbert. Sea $f(t)$ definida en $\mathbb{R}$. La transformada de Hilbert $\mathcal{H}\{f(t)\}(t)$ se define como

$$\mathcal{H}\{f(t)\}(t) = \frac{1}{\pi} \text{PV} \left\{ \int_{-\infty}^{\infty} \frac{f(\tau)}{t - \tau} d\tau \right\} \mid t \in \mathbb{R}. \quad (12.496)$$

Definición 12.3.5. Transformada de Abel. Sea $f(r)$ definida para $r \geq 0$. La transformada de Abel $F(p)$ se define como

$$F(p) = \int_p^{\infty} \frac{f(r)}{\sqrt{r^2 - p^2}} dr \mid p \geq 0. \quad (12.497)$$

Definición 12.3.6. Transformada de Stieltjes. Sea $f(t)$ definida para $t \geq 0$. La transformada de Stieltjes $S\{f(t)\}(s)$ se define como

$$S\{f(t)\}(s) = \int_0^{\infty} \frac{f(t)}{t + s} dt \mid s \in \mathbb{C}, \text{Re}(s) > 0. \quad (12.498)$$

Definición 12.3.7. Transformada de Weierstrass (Gauss-Weierstrass). Sea $f(t)$ definida en $\mathbb{R}$. La transformada de Weierstrass $\mathcal{W}\{f(t)\}(\tau)$ se define como

$$\mathcal{W}\{f(t)\}(\tau) = \frac{1}{\sqrt{4\pi\tau}} \int_{-\infty}^{\infty} f(t) e^{-\frac{(t-\tau)^2}{4\tau}} dt \mid \tau > 0. \quad (12.499)$$

Lema 12.3.1. Linealidad. Sean $\mathcal{T}$ cualquiera de las transformadas definidas anteriormente, f, g funciones en el dominio correspondiente y $\alpha, \beta \in \mathbb{C}$. Entonces

$$\mathcal{T}\{\alpha f + \beta g\} = \alpha \mathcal{T}\{f\} + \beta \mathcal{T}\{g\}. \quad (12.500)$$

La demostración se deja al lector.

Teorema 12.3.1. Transformada de Laplace de la derivada. Sea f diferenciable con transformada de Laplace existente. Entonces

$$\mathcal{L}\{f^{(n)}(t)\}(s) = s^n \mathcal{L}\{f(t)\}(s) - s^{n-1}f(0) - s^{n-2}f'(0) - \dots - f^{(n-1)}(0). \quad (12.501)$$

Demostración. Basta probar el caso $n = 1$ e iterar. Integrando por partes,

$$\mathcal{L}\{f'(t)\}(s) = \int_0^\infty f'(t)e^{-st} dt = [f(t)e^{-st}]_0^\infty + s \int_0^\infty f(t)e^{-st} dt = -f(0) + s\mathcal{L}\{f(t)\}(s),$$

donde el término de frontera se anula pues $f(t)e^{-st} \rightarrow 0$ cuando $t \rightarrow \infty$ para $\text{Re}(s)$ suficientemente grande. Aplicando este resultado iteradamente se obtiene la fórmula general. $\square$

Lema 12.3.2. Transformada de Laplace de la integral. Sea f con transformada de Laplace existente. Entonces

$$\mathcal{L}\left\{\int_0^t f(\tau) d\tau\right\}(s) = \frac{\mathcal{L}\{f(t)\}(s)}{s}. \quad (12.502)$$

Demostración. Sea $g(t) = \int_0^t f(\tau) d\tau$, de modo que $g'(t) = f(t)$ y $g(0) = 0$. Aplicando el teorema anterior con $n = 1$,

$$\mathcal{L}\{f(t)\}(s) = \mathcal{L}\{g'(t)\}(s) = s\mathcal{L}\{g(t)\}(s) - g(0) = s\mathcal{L}\{g(t)\}(s),$$

de donde se despeja $\mathcal{L}\{g(t)\}(s) = \mathcal{L}\{f(t)\}(s)/s$. $\square$

Teorema 12.3.2. Convolución de Laplace. Sean f y g con transformadas de Laplace existentes. Entonces

$$\mathcal{L}\{(f * g)(t)\}(s) = \mathcal{L}\{f(t)\}(s) \cdot \mathcal{L}\{g(t)\}(s), \quad (12.503)$$

donde $(f * g)(t) = \int_0^t f(\tau)g(t - \tau) d\tau$.

Demostración. Escribimos el producto de transformadas e intercambiamos el orden de integración usando Fubini

$$\mathcal{L}\{f\}(s) \cdot \mathcal{L}\{g\}(s) = \int_0^\infty f(\tau)e^{-s\tau} d\tau \int_0^\infty g(\sigma)e^{-s\sigma} d\sigma = \int_0^\infty \int_0^\infty f(\tau)g(\sigma)e^{-s(\tau+\sigma)} d\tau d\sigma.$$

Haciendo el cambio de variable $t = \tau + \sigma$ y reordenando la región de integración a $0 \leq \tau \leq t < \infty$,

$$= \int_0^\infty \left(\int_0^t f(\tau)g(t - \tau) d\tau \right) e^{-st} dt = \mathcal{L}\{(f * g)(t)\}(s).$$

$\square$

Teorema 12.3.3. Valor inicial y final de Laplace. Sea f con transformada de Laplace $F(s)$. Entonces

$$\lim_{t \rightarrow 0^+} f(t) = \lim_{s \rightarrow \infty} sF(s), \quad \lim_{t \rightarrow \infty} f(t) = \lim_{s \rightarrow 0^+} sF(s), \quad (12.504)$$

siempre que los límites existan.

Demostración. Del teorema de la derivada con $n = 1$,

$$\mathcal{L}\{f'(t)\}(s) = sF(s) - f(0).$$

Tomando $s \rightarrow \infty$ y usando que $\mathcal{L}\{f'\}(s) \rightarrow 0$, se obtiene $\lim_{s \rightarrow \infty} sF(s) = f(0) = \lim_{t \rightarrow 0^+} f(t)$. Tomando $s \rightarrow 0^+$ y usando que $\mathcal{L}\{f'\}(s) \rightarrow \int_0^\infty f'(t) dt = \lim_{t \rightarrow \infty} f(t) - f(0)$, se obtiene $\lim_{s \rightarrow 0^+} sF(s) = \lim_{t \rightarrow \infty} f(t)$.

□

Teorema 12.3.4. Inversión de Laplace (fórmula de Bromwich). Si $F(s) = \mathcal{L}\{f(t)\}(s)$, entonces

$$f(t) = \frac{1}{2\pi i} \int_{\gamma-i\infty}^{\gamma+i\infty} F(s) e^{st} ds, \quad (12.505)$$

donde γ es mayor que la parte real de todas las singularidades de F .

La demostración se deja al lector.

Teorema 12.3.5. Transformada de Fourier de la derivada. Sea f diferenciable con $f \in L^1(\mathbb{R})$. Entonces

$$\mathcal{F}\{f^{(n)}(t)\}(\omega) = (i\omega)^n \mathcal{F}\{f(t)\}(\omega). \quad (12.506)$$

Demostración. Para $n = 1$, integrando por partes y usando que $f \in L^1(\mathbb{R})$ implica $f(t) \rightarrow 0$ cuando $|t| \rightarrow \infty$,

$$\mathcal{F}\{f'(t)\}(\omega) = \int_{-\infty}^{\infty} f'(t) e^{-i\omega t} dt = [f(t) e^{-i\omega t}]_{-\infty}^{\infty} + i\omega \int_{-\infty}^{\infty} f(t) e^{-i\omega t} dt = i\omega \mathcal{F}\{f(t)\}(\omega).$$

Iterando se obtiene el caso general.

□

Teorema 12.3.6. Convolución de Fourier. Sean $f, g \in L^1(\mathbb{R})$. Entonces

$$\mathcal{F}\{(f * g)(t)\}(\omega) = \mathcal{F}\{f(t)\}(\omega) \cdot \mathcal{F}\{g(t)\}(\omega), \quad (12.507)$$

donde $(f * g)(t) = \int_{-\infty}^{\infty} f(\tau) g(t - \tau) d\tau$.

Demostración. Por Fubini, ya que $f, g \in L^1(\mathbb{R})$,

$$\mathcal{F}\{f * g\}(\omega) = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} f(\tau) g(t - \tau) d\tau \right) e^{-i\omega t} dt = \int_{-\infty}^{\infty} f(\tau) \left(\int_{-\infty}^{\infty} g(t - \tau) e^{-i\omega t} dt \right) d\tau = \int_{-\infty}^{\infty} f(\tau) e^{-i\omega \tau} \mathcal{F}\{g\}(\omega) d\tau =$$

donde en el penúltimo paso se usó el cambio de variable $u = t - \tau$.

□

Teorema 12.3.7. Identidad de Parseval-Plancherel. Sea $f \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$. Entonces

$$\int_{-\infty}^{\infty} |f(t)|^2 dt = \frac{1}{2\pi} \int_{-\infty}^{\infty} |\mathcal{F}\{f\}(\omega)|^2 d\omega. \quad (12.508)$$

La demostración se deja al lector.

Teorema 12.3.8. Inversión de Fourier. Si $f \in L^1(\mathbb{R})$ y $\mathcal{F}\{f\} \in L^1(\mathbb{R})$, entonces

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \mathcal{F}\{f\}(\omega) e^{i\omega t} d\omega \quad \text{c.s.} \quad (12.509)$$

La demostración se deja al lector.

Teorema 12.3.9. Principio de incertidumbre de Heisenberg. Sea $f \in L^2(\mathbb{R})$ con $\|f\|_2 = 1$. Entonces

$$\left(\int_{\mathbb{R}} t^2 |f(t)|^2 dt \right) \left(\int_{\mathbb{R}} \omega^2 |\mathcal{F}\{f\}(\omega)|^2 d\omega \right) \geq \frac{1}{4}. \quad (12.510)$$

Demostración. Por la identidad de Parseval y la desigualdad de Cauchy-Schwarz,

$$\frac{1}{2} = \left| \int_{\mathbb{R}} f(t) \overline{f(t)} dt \right| = \left| \int_{\mathbb{R}} t f(t) \cdot \frac{\overline{f(t)}}{t} dt \right| \leq \|t f(t)\|_2 \cdot \left\| \frac{f(t)}{t} \right\|_2.$$

Combinando con Parseval-Plancherel para relacionar $\|t f(t)\|_2$ con $\|\omega \mathcal{F}\{f\}(\omega)\|_2$ se obtiene la desigualdad. $\square$

Lema 12.3.3. Relación entre Mellin y Fourier. Sea f definida para $t > 0$. Entonces

$$\mathcal{M}\{f(t)\}(\sigma + i\tau) = \mathcal{F}\{f(e^u)e^{\sigma u}\}(\tau), \quad (12.511)$$

donde el cambio de variable es $t = e^u$.

Demostración. Haciendo $t = e^u$, $dt = e^u du$,

$$\mathcal{M}\{f\}(\sigma + i\tau) = \int_0^\infty t^{\sigma + i\tau - 1} f(t) dt = \int_{-\infty}^\infty e^{(\sigma + i\tau - 1)u} f(e^u) e^u du = \int_{-\infty}^\infty f(e^u) e^{\sigma u} e^{-i(-\tau)u} du = \mathcal{F}\{f(e^u)e^{\sigma u}\}(\tau).$$

$\square$

Teorema 12.3.10. Inversión de Mellin. Si $\mathcal{M}\{f(t)\}(s) = \phi(s)$, entonces

$$f(t) = \frac{1}{2\pi i} \int_{c-i\infty}^{c+i\infty} \phi(s) t^{-s} ds, \quad (12.512)$$

para c en la franja de analiticidad de ϕ .

La demostración se deja al lector.

Teorema 12.3.11. Acotación de la transformada de Hilbert en L^p . Sea $1 < p < \infty$ y $f \in L^p(\mathbb{R})$. Entonces $\mathcal{H}\{f\} \in L^p(\mathbb{R})$ y existe una constante $C_p > 0$ tal que

$$\|\mathcal{H}\{f\}\|_p \leq C_p \|f\|_p. \quad (12.513)$$

La demostración se deja al lector.

Teorema 12.3.12. Involución de la transformada de Hilbert. Si $f \in L^p(\mathbb{R})$ con $1 < p < \infty$, entonces

$$\mathcal{H}\{\mathcal{H}\{f\}\}(t) = -f(t) \quad \text{c.s.} \quad (12.514)$$

Demostración. Usando la relación con Fourier del lema siguiente,

$$\mathcal{F}\{\mathcal{H}\{\mathcal{H}\{f\}\}\}(\omega) = (-i \operatorname{sgn}(\omega))^2 \mathcal{F}\{f\}(\omega) = -\mathcal{F}\{f\}(\omega),$$

y aplicando la inversión de Fourier se concluye $\mathcal{H}\{\mathcal{H}\{f\}\} = -f$ c.s. $\square$

Lema 12.3.4. Relación de Hilbert con Fourier. Sea $f \in L^2(\mathbb{R})$. Entonces

$$\mathcal{F}\{\mathcal{H}\{f\}\}(\omega) = -i \operatorname{sgn}(\omega) \mathcal{F}\{f\}(\omega). \quad (12.515)$$

La demostración se deja al lector.

Lema 12.3.5. Relación entre Laplace y Stieltjes. Sea f con transformada de Laplace F . Entonces

$$S\{f(t)\}(s) = \mathcal{L}\{F(t)\}(s) = \int_0^\infty F(t) e^{-st} dt. \quad (12.516)$$

La demostración se deja al lector.

Lema 12.3.6. Relación entre Abel y Fourier. Sea f radialmente simétrica e integrable. La transformada de Abel satisface

$$\mathcal{F}_{\mathbb{R}^2}\{f\}(\rho) = 2\pi \mathcal{F}_{\mathbb{R}}\{F(p)\}(\rho), \quad (12.517)$$

donde $F(p)$ es la transformada de Abel de f y $\mathcal{F}_{\mathbb{R}^2}$ denota la transformada de Fourier bidimensional en coordenadas polares.

La demostración se deja al lector.

Teorema 12.3.13. Transformada de Weierstrass como solución del calor. La función $u(x, t) = \mathcal{W}\{f\}(x, t)$ es solución de la ecuación del calor

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2}, \quad u(x, 0) = f(x). \quad (12.518)$$

Demostración. Diferenciando bajo el signo integral,

$$\frac{\partial u}{\partial t} = \frac{\partial}{\partial t} \left(\frac{1}{\sqrt{4\pi t}} \int_{-\infty}^{\infty} f(s) e^{-(x-s)^2/4t} ds \right),$$

y análogamente para $\partial^2 u / \partial x^2$. Un cálculo directo muestra que el núcleo gaussiano $K(x, t) = (4\pi t)^{-1/2} e^{-x^2/4t}$ satisface $\partial_t K = \partial_{xx} K$, luego por linealidad u también lo satisface. La condición inicial $u(x, 0) = f(x)$ se sigue de que $K(\cdot, t) \rightarrow \delta_0$ cuando $t \rightarrow 0^+$. □

Lema 12.3.7. Relación entre Weierstrass y Fourier. Sea $f \in L^2(\mathbb{R})$. Entonces

$$\mathcal{F}\{\mathcal{W}\{f\}(\cdot, \tau)\}(\omega) = e^{-\tau\omega^2} \mathcal{F}\{f\}(\omega). \quad (12.519)$$

Demostración. Como $\mathcal{W}\{f\}(x, \tau) = (K_\tau * f)(x)$ con $K_\tau(x) = (4\pi\tau)^{-1/2} e^{-x^2/4\tau}$, por el teorema de convolución de Fourier

$$\mathcal{F}\{\mathcal{W}\{f\}(\cdot, \tau)\}(\omega) = \mathcal{F}\{K_\tau\}(\omega) \cdot \mathcal{F}\{f\}(\omega).$$

Un cálculo directo da $\mathcal{F}\{K_\tau\}(\omega) = e^{-\tau\omega^2}$, de donde se obtiene el resultado. □