

Analisis numerico

Anthony Flores Rojas

13 de agosto de 2026

Contenido

1	Errores numéricos	3
1.1	Binario	3
1.2	Aritmética de punto fijo	4
1.3	Aritmética de punto flotante	5
1.4	Estabilidad	5
1.5	Álgebra lineal y errores	7
2	Ecuaciones no lineales	9
2.1	Bisección	9
2.2	Punto fijo	10
2.3	Fuerza de convergencia	11
2.4	Algoritmo de Newton	11
2.5	Algoritmo secante	12
3	Interpolación y aproximación de funciones	13
4	Integración numérica	16
5	Factorización de matrices	19
6	Condición y estabilidad	23
7	Aplicaciones de sistemas de ecuaciones	26
8	Ecuaciones diferenciales ordinarias	28
9	Valores y vectores propios	30

1

Errores numéricos

El análisis numérico es una forma de aproximar soluciones a problemas de tal manera que no se busque una solución exacta, sino un método eficiente de búsqueda aproximada o exacta de la solución. La eficiencia en estas soluciones permite que el peso computacional de los algoritmos implementados tenga un costo computacional mucho menor al de la solución exacta, ya que, en general, un método generalizado para una computadora que depende de precisiones numéricas y capacidades limitadas muchas veces no sirve como solución. No porque la solución no sea buena —teóricamente debería ser exacta—, sino porque el costo de correr estos algoritmos generalizados exactos muchas veces se dispara a grandes órdenes de magnitud, y en muchos casos con un costo infinito.

Un ejemplo de esto es la solución de ecuaciones polinomiales. Por el teorema fundamental del álgebra se sabe que cualquier ecuación polinomial de grado « n » tiene esa misma cantidad de soluciones complejas. Sin embargo, las formas de encontrar estas soluciones exactas en el mundo real son más complejas de lo que parecen. En cursos como Cálculo I se enseña normalmente el método de Newton para la solución de estas ecuaciones bajo ciertos supuestos.

1.1 Binario

Las computadoras digitales normalmente trabajan en módulo 2, o sea, solo poseen dos estados para la representación de información. Esta limitación, se debe a que los microprocesadores trabajan con márgenes de errores tan altos de voltaje, que la información representada en diferentes estados por diferentes voltajes se corrompería con facilidad, por lo mismo, las computadoras trabajan con «0» como no voltaje y «1» como voltaje. Ahora, por temas de teoría de conjuntos, se sabe que el infinito más pequeño $\mathbb{N}$ se puede representar mediante series de 0's y 1's, de forma que, este sistema es suficiente para representar la información de nuestro universo, ya que del mismo, desconocemos si es infinito, y si lo es, de igual forma se pueden realizar representaciones de información del mismo.

Definición 1.1.1. Palabra. Se define como *palabra* a cualquier cadena finita de bits (información de módulo 2) que son la unidad de información de la máquina.

Definición 1.1.2. Sin signo. En la representación *sin signo* todos los bits se utilizan para el valor como tal, por lo que no existen números negativos. En cuyo caso un número x con i bits se representaría de la forma

$$(x)_{10} \equiv (b_i \cdots b_{15} b_{14} b_{13} b_{12} b_{11} b_{10} b_9 b_8 b_7 b_6 b_5 b_4 b_3 b_2 b_1)_2 \quad (1.1)$$

donde $x = b_i 2^{i-1} + \cdots + b_1 2^0$ con $b_j \in \{0, 1\}, \forall j$

Ejemplo de esto con 16 bits para el número 40 en base 10

0000 0000 0010 1000

Definición 1.1.3. Signo-magnitud. En la representación *signo-magnitud* el primer bit se utiliza como el signo del número, y todos los demás como la magnitud del mismo número. En cuyo caso un número x con i bits se representaría de la forma

$$(x)_{10} \equiv (\overbrace{b_i}^{\text{signo}} b_{i-1} \cdots b_{15} b_{14} b_{13} b_{12} b_{11} b_{10} b_9 b_8 b_7 b_6 b_5 b_4 b_3 b_2 b_1)_2 \quad (1.2)$$

donde $x = (-1)^{b_i} (b_{i-1} 2^{i-2} + \cdots + b_1 2^0)$ con $b_j \in \{0, 1\}, \forall j$.

Definición 1.1.4. Complemento a dos. En la representación *complemento a dos* el primer bit también indica el signo, pero el valor se obtiene invirtiendo los bits de la magnitud y sumando 1. En cuyo caso un número x con i bits se representaría de la forma

$$(x)_{10} \equiv (b_i b_{i-1} \cdots b_{15} b_{14} b_{13} b_{12} b_{11} b_{10} b_9 b_8 b_7 b_6 b_5 b_4 b_3 b_2 b_1)_2 \quad (1.3)$$

donde

$$x = \sum_{j=1}^{i-1} b_j 2^{j-1}, \quad b_i = 0 \quad (\text{número positivo}) \quad (1.4)$$

$$x = - \left(2^{i-1} - \sum_{j=1}^{i-1} b_j 2^{j-1} \right), \quad b_i = 1 \quad (\text{número negativo}) \quad (1.5)$$

con $b_j \in \{0, 1\}, \forall j$.

1.2 Aritmética de punto fijo

Definición 1.2.1. Aritmética de punto fijo. En la representación *punto fijo* la palabra se divide en tres campos: el primer bit indica el signo, mientras que la parte entera y fraccionaria de la magnitud del número se guardan en un segundo y tercer campo, respectivamente. En cuyo caso un número x con i bits se representaría de la forma

$$(x)_{10} \equiv (\overbrace{b_i}^{\text{signo}} \overbrace{b_{i-1} \cdots b_m}^{\text{parte entera}} \overbrace{b_{m-1} \cdots b_1}^{\text{parte fraccionaria}})_2 \quad (1.6)$$

donde

$$x = (-1)^{b_i} \left(\sum_{j=1}^m b_j 2^{j-1} + \sum_{k=1}^n b_{-k} 2^{-k} \right), \quad (1.7)$$

con m bits para la parte entera y n bits para la parte fraccionaria, y $b_j \in \{0, 1\}, \forall j$.

1.3 Aritmética de punto flotante

Definición 1.3.1. Aritmética de punto flotante. En la representación *punto flotante* la palabra se divide en tres campos: el primer bit indica el signo, mientras que un segundo y tercer campo almacenan el exponente E y la mantisa S , respectivamente. En cuyo caso un número real $x \neq 0$ se representaría de la forma

$$x = \pm S \cdot 2^E, \quad 1 \leq S < 2, \quad E \in \mathbb{Z}, \quad (1.8)$$

donde S es la mantisa y E el exponente. Un número está escrito en forma normalizada si el primer bit de la mantisa es siempre 1.

Definición 1.3.2. Épsilon de la máquina. En cuyo caso se define como la distancia entre 1 y el siguiente número mayor que 1 que puede representarse en el sistema de punto flotante. Si la precisión es p , entonces

$$\epsilon_m = 2^{-(p-1)}. \quad (1.9)$$

Teorema 1.3.1. Error. Sea $x \in \mathbb{R}$ un número que puede ser representado de manera normal en un sistema de punto flotante con precisión p . Entonces, existe $\delta \in \mathbb{R}$ tal que

$$fl(x) = x(1 + \delta), \quad |\delta| < \frac{\epsilon_m}{2}. \quad (1.10)$$

La demostración es trivial.

Definición 1.3.3. Derivada por definición. Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función. La derivada en x_0 puede aproximarse numéricamente mediante

$$D_1 f(h) := \frac{f(x_0 + h) - f(x_0)}{h}, \quad D_2 f(h) := \frac{f(x_0 + h) - f(x_0 - h)}{2h}. \quad (1.11)$$

Proposición 1.3.1. Aproximación de Taylor. Utilizando polinomios de Taylor, se cumple que

$$f'(x_0) = \frac{f(x_0 + h) - f(x_0)}{h} + O(h), \quad f'(x_0) = \frac{f(x_0 + h) - f(x_0 - h)}{2h} + O(h^2). \quad (1.12)$$

La demostración es trivial.

1.4 Estabilidad

Definición 1.4.1. Número de condición absoluto. Sea $f : X \rightarrow Y$. El número de condición absoluto en $x \in X$ se define como

$$\kappa(x) := \lim_{\delta \rightarrow 0} \sup_{\|\delta x\| \leq \delta} \frac{\|f(x + \delta x) - f(x)\|}{\|\delta x\|}. \quad (1.13)$$

Definición 1.4.2. Número de condición relativo. Para $f : X \rightarrow Y$, el número de condición relativo en $x \in X$ se define como

$$\kappa(x) := \lim_{\delta \rightarrow 0} \sup_{\|\delta x\| \leq \delta} \frac{\|f(x + \delta x) - f(x)\|}{\|f(x)\|} \cdot \frac{\|x\|}{\|\delta x\|}. \quad (1.14)$$

Definición 1.4.3. Número de condición de una matriz. Para $A \in \mathbb{F}^{n \times n}$ no singular,

$$\kappa(A) = \|A\| \cdot \|A^{-1}\|. \quad (1.15)$$

Definición 1.4.4. Estabilidad de algoritmo. Un algoritmo $\tilde{f}$ para un problema f es estable si para cada $x \in X$ existe $\tilde{x}$ tal que

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\epsilon_M), \quad \frac{\|f(\tilde{x}) - \tilde{f}(x)\|}{\|f(\tilde{x})\|} = O(\epsilon_M). \quad (1.16)$$

Definición 1.4.5. Estabilidad hacia atrás. Un algoritmo es estable hacia atrás si

$$\tilde{f}(x) = f(\tilde{x}), \quad \frac{\|\tilde{x} - x\|}{\|x\|} = O(\epsilon_M). \quad (1.17)$$

Teorema 1.4.1. Resolución de sistemas lineales. Sea $A \in \mathbb{F}^{n \times n}$ no singular. El número de condición del problema de resolver $Ax = b$ respecto de b es

$$\kappa = \|A\| \cdot \|A^{-1}\|. \quad (1.18)$$

Teorema 1.4.2. Inversa de una matriz. El número de condición del problema de calcular A^{-1} es

$$\kappa(A) = \|A\| \cdot \|A^{-1}\|. \quad (1.19)$$

Teorema 1.4.3. Eliminación Gaussiana con pivoteo parcial. Si se utiliza este método para resolver $Ax = b$, la solución $\tilde{x}$ satisface

$$(A + \delta A)\tilde{x} = b, \quad \frac{\|\delta A\|}{\|A\|} \leq \varphi(n)\gamma\epsilon_M. \quad (1.20)$$

Teorema 1.4.4. Error relativo en algoritmos estables hacia atrás. Si un problema f tiene número de condición $\kappa(x)$ y se aplica un algoritmo estable hacia atrás, entonces

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\kappa(x)\epsilon_M). \quad (1.21)$$

Corolario 1.4.1. Distancia relativa a la singularidad. Para $A \in \mathbb{F}^{n \times n}$ no singular,

$$\frac{1}{\kappa_2(A)} = \min \left\{ \frac{\|\delta A\|_2}{\|A\|_2} : A + \delta A \text{ singular} \right\}. \quad (1.22)$$

Es decir, $1/\kappa_2(A)$ representa la distancia relativa de A al conjunto de matrices singulares.

1.5 Álgebra lineal y errores

Definición 1.5.1. Rango de una matriz. Sea $A \in \mathbb{C}^{m \times n}$. Se llama rango de A , y se denota $\text{Rng}(A)$, al número de filas no nulas de la única matriz en forma escalonada reducida equivalente a A .

Definición 1.5.2. Espacio nulo. Para $A \in \mathbb{C}^{m \times n}$, el espacio nulo de A , denotado $\text{null}(A)$, es el conjunto de vectores x tales que $Ax = 0$. Las entradas de $x \in \text{null}(A)$ corresponden a coeficientes de una combinación lineal nula de las columnas de A .

Teorema 1.5.1. Equivalencias para la inversa de una matriz. Sea $A \in \mathbb{C}^{m \times m}$. Las siguientes condiciones son equivalentes

1. A tiene inversa A^{-1} .
2. $\text{Rng}(A) = m$.
3. $\text{null}(A) = \{0\}$.
4. 0 no es valor propio de A .
5. 0 no es valor singular de A .
6. $\det(A) \neq 0$.

Definición 1.5.3. Producto interno. Para $x, y \in \mathbb{C}^m$, el producto interno se define como

$$x^*y = \sum_{i=1}^m \overline{x_i}y_i. \quad (1.23)$$

La norma euclídea de x se define por

$$\|x\| = \sqrt{x^*x} = \left(\sum_{i=1}^m |x_i|^2 \right)^{1/2}. \quad (1.24)$$

Teorema 1.5.2. Independencia lineal en conjuntos ortogonales. Los vectores de un conjunto ortogonal S son linealmente independientes.

Definición 1.5.4. Matriz unitaria. Una matriz cuadrada $Q \in \mathbb{C}^{m \times m}$ es unitaria si

$$Q^*Q = I. \quad (1.25)$$

En el caso real, se dice ortogonal. Las columnas de Q forman una base ortonormal de $\mathbb{C}^m$.

Teorema 1.5.3. Invariancia de normas bajo multiplicación unitaria. Para cualquier $A \in \mathbb{C}^{m \times n}$ y matriz unitaria $Q \in \mathbb{C}^{m \times m}$,

$$\|QA\|_2 = \|A\|_2, \quad \|QA\|_F = \|A\|_F. \quad (1.26)$$

Definición 1.5.5. Errores de aproximación. Sea x el valor exacto y $\tilde{x}$ una aproximación. El error absoluto se define como

$$E_a = |x - \tilde{x}|, \quad (1.27)$$

y el error relativo como

$$E_r = \frac{|x - \tilde{x}|}{|x|}. \quad (1.28)$$

Definición 1.5.6. Dígitos significativos correctos. Se dice que $\tilde{x}$ aproxima a $x \neq 0$ con t dígitos significativos si

$$\frac{|x - \tilde{x}|}{|x|} < 5 \times 10^{-t}. \quad (1.29)$$

Teorema 1.5.4. Cotas del error de representación. Suponga que x se escribe en forma normalizada y el sistema conserva t dígitos significativos.

- Si $fl(x)$ se obtiene por truncamiento

$$\frac{|x - fl(x)|}{|x|} < 10^{1-t}. \quad (1.30)$$

- Si $fl(x)$ se obtiene por redondeo

$$\frac{|x - fl(x)|}{|x|} \leq \frac{1}{2} \cdot 10^{1-t}. \quad (1.31)$$

Teorema 1.5.5. Modelo fundamental de redondeo. Si no ocurre desbordamiento y la operación se redondea al número representable más cercano, una operación elemental puede modelarse como

$$fl(x \circ y) = (x \circ y)(1 + \delta), \quad |\delta| \leq u, \quad (1.32)$$

donde $\circ \in \{+, -, \times, /\}$ y u es la unidad de redondeo del sistema.

2

Ecuaciones no lineales

2.1 Bisección

Teorema 2.1.1. Teorema del Valor Intermedio. Sea $f : [a, b] \rightarrow \mathbb{R}$ una función continua en el intervalo cerrado $[a, b]$. Si $f(a)f(b) < 0$ entonces existe al menos un punto $c \in (a, b)$ tal que $f(c) = 0$.

Definición 2.1.1. Algoritmo de bisección. El método de bisección se basa en una aplicación directa del Teorema del Valor Intermedio. Dada una función continua $f : [a_0, b_0] \rightarrow \mathbb{R}$ con $f(a_0)f(b_0) < 0$, sabemos que existe al menos una raíz $c \in (a_0, b_0)$. El procedimiento consiste en

1. Calcular el punto medio $c_0 = \frac{a_0 + b_0}{2}$.
2. Si $f(c_0) = 0$, entonces c_0 es la raíz buscada.
3. En caso contrario, determinar el subintervalo donde ocurre el cambio de signo

$$I_1 = \begin{cases} (a_0, c_0), & \text{si } f(a_0)f(c_0) < 0, \\ (c_0, b_0), & \text{si } f(c_0)f(b_0) < 0. \end{cases} \quad (2.1)$$

4. Repetir el proceso con I_1 , obteniendo una sucesión de intervalos anidados $I_k \subset I_{k-1} \subset \dots \subset I_0$, cuya longitud se reduce a la mitad en cada paso

$$|I_k| = \frac{1}{2^k} |I_0| = \frac{1}{2^k} (b_0 - a_0). \quad (2.2)$$

La sucesión de puntos medios $\{c_k\}$ converge a la raíz c de la ecuación $f(x) = 0$.

Teorema 2.1.2. Convergencia de bisección. Suponga que la sucesión $\{c_k\}$ definida por el método de bisección satisface que $c_k \neq c \forall k \in \mathbb{N}$. Entonces se tiene que c_k converge a c ; esto es, para todo $\varepsilon > 0$ existe $N_\varepsilon \in \mathbb{N}$ tal que si $k > N_\varepsilon$ entonces $|c_k - c| < \varepsilon$.

La demostración es consecuencia de la convergencia acotada.

2.2 Punto fijo

Definición 2.2.1. Contracción. Sea (X, d) un espacio métrico. Se dice que $x \in X$ es un *punto fijo* de un mapeo $g : X \rightarrow X$ si $g(x) = x$. Además, g se llama *contracción* si existe $L \in (0, 1)$ tal que

$$d(g(x), g(y)) \leq L d(x, y), \quad \forall x, y \in X. \quad (2.3)$$

Teorema 2.2.1. Teorema de Punto Fijo de Brouwer. Sea K un subconjunto convexo, compacto y no vacío de un espacio euclídeo. Entonces, toda función continua $g : K \rightarrow K$ posee al menos un punto fijo.

En clase no se prueba xd. Para otro día.

Teorema 2.2.2. Teorema de Punto Fijo de Banach. Sea (X, d) un espacio métrico completo y considere una contracción $g : X \rightarrow X$ donde X es cerrado. Entonces, g tiene exactamente un punto fijo.

Definición 2.2.2. Iteración simple. Sea g una función continua $g : [a, b] \rightarrow [a, b]$. Dado un valor inicial $c_0 \in [a, b]$, la recursión

$$c_{k+1} = g(c_k), \quad k \geq 1, \quad (2.4)$$

es llamada *iteración simple*.

Corolario 2.2.1. Cotas de error en iteración de punto fijo. Si φ satisface las hipótesis del Teorema del Punto Fijo, se cumple que

$$|x_n - c| \leq L^n \max\{x_0 - a, b - x_0\}, \quad (2.5)$$

y también

$$|x_n - c| \leq \frac{L^n}{1 - L} |x_1 - x_0|, \quad n \geq 1. \quad (2.6)$$

Teorema 2.2.3. Unicidad del punto fijo. Sea $g : [a, b] \rightarrow [a, b]$ una función continua. Suponga además que g es diferenciable con

$$|g'(x)| \leq L < 1, \quad \forall x \in (a, b). \quad (2.7)$$

Entonces g tiene un único punto fijo $c \in [a, b]$ y el proceso de iteración simple converge a c .

2.3 Fuerza de convergencia

Definición 2.3.1. Lineal. Considere una sucesión $\{c_k\}_{k=0}^{\infty}$ tal que $\lim_{k \rightarrow \infty} c_k = c$ con $c_k \neq c \forall k \in \mathbb{N}$. Suponga que

$$\lim_{k \rightarrow \infty} \frac{|c_{k+1} - c|}{|c_k - c|} = \mu \geq 0. \quad (2.8)$$

Entonces se dice que c_k converge a c

- (a) *sublinealmente* si $\mu = 1$.
- (b) *superlinealmente* si $\mu = 0$.
- (c) *linealmente* si $\mu \in (0, 1)$, y $\rho := -\log \mu$ se define como la *razón de convergencia asintótica*.

En el caso de convergencia superlineal, se dice que c_k converge a c con *orden* $q > 1$ si

$$\lim_{k \rightarrow \infty} \frac{|c_{k+1} - c|}{|c_k - c|^q} \quad (2.9)$$

existe. En particular, la convergencia se llama *cuadrática* si $q = 2$.

Teorema 2.3.1. Convergencia cuadrática. Suponga que $c \in (a, b)$ es un punto fijo de una función derivable $g : [a, b] \rightarrow [a, b]$, tal que $g'(c) = 0$. Suponga además que g'' es continua en un intervalo abierto $I := (c - h, c + h) \subset [a, b]$ y

$$\sup_{x \in I} |g''(x)| \leq M \quad (2.10)$$

para algún $M > 0$. Entonces existe $\delta > 0$ tal que, si $c_0 \in (c - \delta, c + \delta)$, la sucesión definida por

$$c_k = g(c_{k-1}), \quad \text{para } k \geq 1, \quad (2.11)$$

converge (al menos) cuadráticamente a c .

2.4 Algoritmo de Newton

Definición 2.4.1. Algoritmo de Newton. El método de Newton se interpreta geométricamente como sigue: dado un punto $(c_k, f(c_k))$ en la gráfica de f , se traza la recta tangente en dicho punto. La intersección de esta recta con el eje x determina el siguiente valor c_{k+1} . El procedimiento es:

1. Elegir un valor inicial c_0 cercano a la raíz buscada.
2. Para cada iteración $k = 0, 1, 2, \dots$ calcular

$$c_{k+1} = c_k - \frac{f(c_k)}{f'(c_k)}. \quad (2.12)$$

3. Detener el proceso cuando $|f(c_k)|$ sea menor que una tolerancia prefijada.

Bajo condiciones adecuadas de suavidad y cercanía del punto inicial, la sucesión $\{c_k\}$ converge cuadráticamente a la raíz c de la ecuación $f(x) = 0$.

Teorema 2.4.1. Método de Newton. Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función continua y derivable. Supongamos que c es una raíz de f , es decir $f(c) = 0$, y que $f'(c) \neq 0$. Si se toma un valor inicial c_0 suficientemente cercano a c , la sucesión definida por

$$c_{k+1} = c_k - \frac{f(c_k)}{f'(c_k)}, \quad k = 0, 1, 2, \dots \quad (2.13)$$

converge cuadráticamente hacia c .

2.5 Algoritmo secante

Teorema 2.5.1. Convergencia de Newton. Suponga que $f \in C^2(I_\delta)$, donde $I_\delta := [c-\delta, c+\delta]$, $\delta > 0$, tal que $f(c) = 0$, $f'(c) \neq 0$. Entonces, si tomamos c_0 lo suficientemente cerca de c , la sucesión $\{c_k\}$ definida en el pasado converge a c de manera cuadrática.

Definición 2.5.1. Algoritmo de la Secante. El método de la secante se interpreta geométricamente como sigue: dada una función continua f , se consideran dos puntos $(c_{k-1}, f(c_{k-1}))$ y $(c_k, f(c_k))$ en la gráfica de f . La recta secante que pasa por estos dos puntos corta al eje x en el punto $(c_{k+1}, 0)$, el cual se toma como la siguiente aproximación de la raíz. El procedimiento es:

1. Elegir dos valores iniciales c_0 y c_1 cercanos a la raíz buscada.
2. Para cada iteración $k = 1, 2, \dots$ calcular

$$c_{k+1} = c_k - f(c_k) \frac{c_k - c_{k-1}}{f(c_k) - f(c_{k-1})}. \quad (2.14)$$

3. Detener el proceso cuando $|f(c_k)|$ sea menor que una tolerancia prefijada.

Bajo condiciones adecuadas de cercanía de los puntos iniciales, la sucesión $\{c_k\}$ converge superlinealmente a la raíz c de la ecuación $f(x) = 0$.

Teorema 2.5.2. Método de la Secante. Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función continua. Supongamos que c es una raíz de f , es decir $f(c) = 0$. Si se toman dos valores iniciales c_0 y c_1 suficientemente cercanos a c , la sucesión definida por

$$c_{k+1} = c_k - f(c_k) \frac{c_k - c_{k-1}}{f(c_k) - f(c_{k-1})}, \quad k = 1, 2, \dots \quad (2.15)$$

converge hacia c bajo condiciones adecuadas. La convergencia es superlineal, con orden aproximado $\varphi = \frac{1+\sqrt{5}}{2}$ (el número áureo).

Teorema 2.5.3. Convergencia secante. Sea $f \in C^3([c-h, c+h])$, para algún $h > 0$. Suponga que $f(c) = 0$ y $f'(c) \neq 0$. Entonces, la secuencia definida en el algoritmo anterior converge superlinealmente si c_0 y c_1 se toman suficientemente cerca de c .

3

Interpolación y aproximación de funciones

Definición 3.0.1. Polinomio de interpolación de Lagrange. Sea f una función continua en un intervalo $[a, b]$. Dados $n + 1$ valores distintos $x_i \in [a, b]$ ($i \in \{0, \dots, n\}$), el polinomio de interpolación de Lagrange de orden n de f se define como

$$p_n(x) := \sum_{k=0}^n f(x_k) L_k(x) \in \mathbb{P}_n, \quad (3.1)$$

donde los polinomios $L_k(x)$ vienen dados por

$$L_k(x) := \prod_{i=0, i \neq k}^n \frac{x - x_i}{x_k - x_i}. \quad (3.2)$$

Teorema 3.0.1. Error de interpolación de Lagrange. Sea $f \in C^{n+1}([a, b])$. Entonces existe $\xi = \xi(x) \in (a, b)$ tal que

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \pi_{n+1}(x) \quad \forall x \in [a, b], \quad (3.3)$$

donde $\pi_{n+1}(x) := (x - x_0) \cdots (x - x_n) \in \mathbb{P}_{n+1}$.

Definición 3.0.2. Polinomio de interpolación de Hermite. Sea $f \in C^1([a, b])$. Dados $n + 1$ valores distintos $x_i \in [a, b]$ ($i \in \{0, \dots, n\}$), el polinomio de interpolación de Hermite de orden n de f se define como

$$h_{2n+1}(x) := \sum_{k=0}^n f(x_k) H_k(x) + f'(x_k) K_k(x) \in \mathbb{P}_{2n+1}. \quad (3.4)$$

Teorema 3.0.2. Error de interpolación de Hermite. Sea $f \in C^{2n+2}([a, b])$. Entonces existe $\xi = \xi(x) \in (a, b)$ tal que

$$f(x) - h_{2n+1}(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \pi_{n+1}^2(x) \quad \forall x \in [a, b], \quad (3.5)$$

donde $\pi_{n+1}(x) := (x - x_0) \cdots (x - x_n) \in \mathbb{P}_{n+1}$.

Teorema 3.0.3. Error en la derivada del polinomio de interpolación. Sea $f \in C^{n+2}([a, b])$ y considere un nodo de interpolación x_i , $i \in \{0, \dots, n\}$. Entonces existe $\xi_i = \xi(x_i) \in (a, b)$ tal que

$$f'(x_i) = \sum_{k=0}^n f(x_k) L'_k(x_i) + \frac{f^{(n+1)}(\xi_i)}{(n+1)!} \prod_{k=0, k \neq i}^n (x_i - x_k), \quad (3.6)$$

donde

$$L'_k(x) = \sum_{\substack{j=0 \\ j \neq k}}^n \frac{1}{x_k - x_j} \prod_{\substack{m=0 \\ m \neq k, j}}^n \frac{x - x_m}{x_k - x_m}. \quad (3.7)$$

Definición 3.0.3. Fórmula de $n + 1$ puntos para la derivada. Sea f una función derivable en un intervalo $[a, b]$ y considere una partición del intervalo $[a, b]$ de $n + 1$ puntos

$$a = x_0 < x_1 < \cdots < x_n = b. \quad (3.8)$$

Se define la fórmula de $n + 1$ puntos para aproximar la derivada de f en un nodo x_i como la aproximación

$$f'(x_i) \approx \sum_{k=0}^n f(x_k) \sum_{\substack{j=0 \\ j \neq k}}^n \frac{1}{x_k - x_j} \prod_{\substack{m=0 \\ m \neq k, j}}^n \frac{x_i - x_m}{x_k - x_m}. \quad (3.9)$$

Definición 3.0.4. Polinomio y puntos de Chebyshev. Sea $n \geq 0$. Para $x \in [-1, 1]$, definimos el polinomio de Chebyshev (de primer tipo) de grado n como

$$T_n(x) := \cos(n \arccos(x)). \quad (3.10)$$

Además, consideraremos los correspondientes puntos de Chebyshev (de segundo tipo), los cuales se definen como los ceros de T'_n . Dichos puntos vienen dados por

$$x_j = \cos\left(\frac{j\pi}{n}\right), \quad j \in \{0, 1, \dots, n\}. \quad (3.11)$$

Teorema 3.0.4. Fórmula de interpolación baricéntrica. El polinomio de interpolación de Lagrange se puede escribir como

$$p_n(x) = \sum_{j=0}^n \frac{\lambda_j f(x_j)}{x - x_j} \bigg/ \sum_{j=0}^n \frac{\lambda_j}{x - x_j}, \quad \text{para } x \notin \{x_0, \dots, x_n\}. \quad (3.12)$$

Lema 3.0.1. Para los puntos de Chebyshev se tiene que

$$\lambda_k = \frac{2^{n-1}}{n} (-1)^k, \quad 1 \leq k \leq n-1, \quad (3.13)$$

y

$$\lambda_k = \frac{2^{n-2}}{n} (-1)^k, \quad k \in \{0, n\}. \quad (3.14)$$

Teorema 3.0.5. Fórmula baricéntrica en puntos de Chebyshev. El polinomio de interpolación de Lagrange en los puntos de Chebyshev se puede escribir como

$$p_n(x) = \sum_{j=0}^n \prime \frac{(-1)^j f(x_j)}{x - x_j} \bigg/ \sum_{j=0}^n \prime \frac{(-1)^j}{x - x_j}, \quad \text{para } x \notin \{x_0, \dots, x_n\}, \quad (3.15)$$

donde el símbolo de prima en la sumatoria significa que el primer y último término se deben dividir por dos. Se entiende además que $p_n(x_j) = f(x_j)$ al ser los datos de interpolación.

4

Integración numérica

Lema 4.0.1. Generalización del valor medio para integrales. Considere f continua en $[a, b]$ y g integrable en (a, b) , tal que g no cambia de signo en $[a, b]$. Entonces, existe $\xi \in (a, b)$ tal que

$$\int_a^b f(x)g(x) dx = f(\xi) \int_a^b g(x) dx. \quad (4.1)$$

Teorema 4.0.1. Error de la regla del trapecio. Sea $f \in C^2([a, b])$. Entonces, existe $\xi \in [a, b]$ tal que

$$\int_a^b f(x) dx = \frac{b-a}{2} (f(a) + f(b)) - \frac{(b-a)^3}{12} f''(\xi). \quad (4.2)$$

Teorema 4.0.2. Error de la regla de Simpson. Suponga que $f \in C^4([a, b])$. Entonces existe $\xi \in (a, b)$ tal que

$$\int_a^b f(x) dx = \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right] - \frac{f^{(4)}(\xi)}{2880} (b-a)^5. \quad (4.3)$$

Teorema 4.0.3. Error de la fórmula compuesta del trapecio. Considere una función $f \in C^2([a, b])$ y la partición uniforme de $n + 1$ puntos de $[a, b]$. Entonces existe $\xi \in (a, b)$ tal que

$$I_f - \tilde{I}_{TC} = -\frac{(b-a)^3}{12n^2} f''(\xi), \quad (4.4)$$

donde

$$\tilde{I}_{TC} := \frac{b-a}{n} \sum_{i=0}^n {}' f(x_i) \quad (4.5)$$

se define como la fórmula compuesta del trapecio, donde el símbolo de prima en la sumatoria significa que el primer y último término se deben dividir por dos.

Teorema 4.0.4. Error de la fórmula compuesta de Simpson. Considere $f \in C^4([a, b])$ y la partición uniforme de $n + 1$ puntos de $[a, b]$. Entonces existe $\xi \in (a, b)$ tal que

$$I_f - \tilde{I}_{SC} = -\frac{(b-a)^5}{2880n^4} f^{(4)}(\xi), \quad (4.6)$$

donde

$$\tilde{I}_{SC} := \frac{b-a}{6n} \sum_{i=1}^n \left(f(x_{i-1}) + 4f\left(\frac{x_{i-1} + x_i}{2}\right) + f(x_i) \right) \quad (4.7)$$

se define como la fórmula compuesta de Simpson.

Definición 4.0.1. Función peso y producto interno. Sea $w : (a, b) \rightarrow \mathbb{R}^+$ una función integrable, la cual llamaremos función peso. Dadas dos funciones f, g definimos

$$(f, g)_w := \int_a^b f(x)g(x)w(x) dx. \quad (4.8)$$

Es fácil ver que $(f, g)_w$ es un producto interno definido en el espacio de funciones integrables con respecto al peso w , por lo que induce la norma natural

$$\|f\| = (f, f)_w^{1/2}. \quad (4.9)$$

Definición 4.0.2. Sistema de polinomios ortogonales. Sea $\{\varphi_j\}_{j=0}^\infty$ un conjunto de polinomios, donde cada φ_j tiene exactamente grado j . Dicho conjunto se llama un sistema de polinomios ortogonales en el intervalo $[a, b]$ si $(\varphi_j, \varphi_k)_w = 0$ si y solo si $j \neq k$.

Teorema 4.0.5. Ceros de polinomios ortogonales. Considere un sistema de polinomios ortogonales $\{\varphi_j\}_{j=0}^\infty$ en el intervalo $[a, b]$ con respecto a un peso dado $w(x)$. Entonces φ_j ($j \geq 1$) tiene exactamente j ceros reales y distintos, los cuales se encuentran en el intervalo (a, b) .

Definición 4.0.3. Cuadratura de Gauss. Considere f una función continua en (a, b) y w una función positiva, continua e integrable en (a, b) . La cuadratura de Gauss de f de orden n en el intervalo $[a, b]$ se define como la suma

$$G_n(f) := \sum_{k=0}^n W_k f(x_k), \quad (4.10)$$

donde los nodos $\{x_k\}_{k=0}^n$ son los $n+1$ ceros distintos de un polinomio de grado $n+1$ que pertenece a un sistema de polinomios ortogonal con respecto a $w(x)$ en $[a, b]$, y los pesos W_k vienen dados por

$$W_k = \int_a^b L_k(x) w(x) dx > 0. \quad (4.11)$$

Teorema 4.0.6. Error de la cuadratura de Gauss. Sea $f \in C^{2n+2}([a, b])$ y w una función positiva e integrable en (a, b) . Entonces

$$\left| \int_a^b f(x) w(x) dx - G_n(f) \right| \leq \frac{M}{(2n+2)!} \int_a^b \pi_{n+1}^2(x) w(x) dx, \quad (4.12)$$

donde $\pi_{n+1}(x) := (x - x_0) \cdots (x - x_n) \in \mathbb{P}_{n+1}$ y $M = \max_{x \in [a, b]} |f^{(2n+2)}(x)|$.

Teorema 4.0.7. Convergencia de la cuadratura de Gauss. Sea f una función continua en $[a, b]$ y w una función positiva, continua e integrable en (a, b) . Entonces,

$$\lim_{n \rightarrow \infty} G_n(f) = \int_a^b f(x) w(x) dx. \quad (4.13)$$

5

Factorización de matrices

Definición 5.0.1. Matrices reales. Considere una matriz con entradas reales $A \in \mathbb{R}^{m \times n}$.

1. Su matriz traspuesta A^T es la matriz que se obtiene al intercambiar sus filas por sus columnas; esto es, $a_{ij}^T := a_{ji}$.
2. Una matriz cuadrada $A \in \mathbb{R}^{m \times m}$ se llama simétrica si $A^T = A$.
3. Una matriz cuadrada $A \in \mathbb{R}^{m \times m}$ se llama ortogonal si $AA^T = A^T A = I_{m \times m}$, donde I es la matriz identidad. Note que si a_i es una columna de A , entonces $a_i^T a_j = \delta_{ij}$; esto es, sus columnas forman un conjunto ortonormal de vectores. Además, la inversa de A es A^T .

Definición 5.0.2. Matrices complejas. Considere una matriz con entradas complejas $A \in \mathbb{C}^{m \times n}$.

1. Su matriz conjugada traspuesta o adjunta $A^* \in \mathbb{C}^{n \times m}$ se define como la matriz con entradas $a_{ij}^* := (a_{ji})^*$. Recuerde que el conjugado de un número complejo $z = a + bi$ viene dado por $z^* = a - bi$.
2. Una matriz cuadrada $A \in \mathbb{C}^{m \times m}$ se llama Hermitiana o Hermítica si $A^* = A$.
3. Una matriz cuadrada $A \in \mathbb{C}^{m \times m}$ se llama unitaria si $AA^* = A^* A = I_{m \times m}$, donde I es la matriz identidad.

Definición 5.0.3. Norma. Considere un espacio vectorial V sobre un cuerpo $\mathbb{K}$. Una norma es una función

$$\|\cdot\| : V \rightarrow [0, \infty) \quad (5.1)$$

tal que, para todo $x, y \in V$ y $\alpha \in \mathbb{K}$, se tiene que

- (a) $\|x\| = 0 \iff x = 0$,
- (b) $\|\alpha x\| = |\alpha| \|x\|$,
- (c) $\|x + y\| \leq \|x\| + \|y\|$.

Lema 5.0.1. Considere dos matrices $A_{m \times p}$, $B_{p \times n}$. Entonces, se cumple que

$$\|AB\|_{(m,n)} \leq \|A\|_{(m,p)} \|B\|_{(p,n)}. \quad (5.2)$$

Lema 5.0.2. Considere $A \in \mathbb{C}^{m \times n}$ y $Q \in \mathbb{C}^{m \times m}$ unitaria. Entonces,

$$\|QA\|_2 = \|A\|_2 \quad \text{y} \quad \|QA\|_F = \|A\|_F. \quad (5.3)$$

Definición 5.0.4. Factorización en valores singulares. Se dice que $A \in \mathbb{C}^{m \times n}$ admite una factorización en valores singulares si existen $U \in \mathbb{C}^{m \times m}$ unitaria, $V \in \mathbb{C}^{n \times n}$ unitaria y $\Sigma \in \mathbb{R}^{m \times n}$ diagonal tales que

$$A = U\Sigma V^*, \quad (5.4)$$

donde las entradas de la diagonal de Σ satisfacen $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$, con $p := \min\{m, n\}$. Los números $\{\sigma_k\}_{k=1}^p$ son llamados valores singulares, las columnas de U son llamadas vectores singulares izquierdos y las columnas de V son llamadas vectores singulares derechos.

Teorema 5.0.1. Existencia de la descomposición en valores singulares. Toda matriz $A \in \mathbb{C}^{m \times n}$ admite una descomposición en valores singulares. Además, los valores singulares $\{\sigma_k\}_{k=1}^p$ son únicos.

Teorema 5.0.2. Unicidad. Considere $A \in \mathbb{C}^{m \times m}$ donde todos sus valores singulares son diferentes. Entonces, los valores singulares izquierdos y derechos están determinados de manera única, a excepción de multiplicación por constantes complejas de magnitud 1.

Lema 5.0.3. Sea $A = U\Sigma V^*$ una factorización en valores singulares de A y defina r como el número de valores singulares positivos de A . Entonces, podemos expresar la matriz A como suma de r matrices de rango 1. Explícitamente,

$$A = \sum_{j=1}^r \sigma_j u_j v_j^*, \quad (5.5)$$

donde $\{u_j\}_{j=1}^r$ y $\{v_j\}_{j=1}^r$ son los r vectores singulares izquierdos y derechos, respectivamente, asociados a los valores singulares $\{\sigma_j\}_{j=1}^r$.

Lema 5.0.4. Sea $A = U\Sigma V^* \in \mathbb{C}^{m \times n}$. La imagen de A es generada por $\{u_1, \dots, u_r\}$ y el núcleo de A es generado por $\{v_{r+1}, \dots, v_n\}$. De esta forma, el rango r de una matriz $A \in \mathbb{C}^{m \times n}$ es igual al número de valores singulares positivos.

Lema 5.0.5. Considere una matriz $A \in \mathbb{C}^{m \times n}$ con valores singulares positivos $\sigma_1, \dots, \sigma_r$. Entonces,

$$\|A\|_2 = \sigma_1 \quad \text{y} \quad \|A\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_r^2}. \quad (5.6)$$

Lema 5.0.6. El conjunto de valores singulares positivos de $A \in \mathbb{C}^{m \times n}$ es igual al conjunto de las raíces cuadradas de los valores propios no nulos de A^*A o AA^* .

Lema 5.0.7. Si $A = A^*$, el conjunto de valores singulares de A es igual al conjunto de valores absolutos de los valores propios de A .

Lema 5.0.8. Para $A \in \mathbb{C}^{m \times m}$, $|\det(A)| = \prod_{i=1}^m \sigma_i$.

Teorema 5.0.3. Aproximación de bajo rango. Para cualquier ν con $1 \leq \nu \leq r$, defina la aproximación

$$A_\nu := \sum_{j=1}^{\nu} \sigma_j u_j v_j^*. \quad (5.7)$$

Entonces,

$$\sigma_{\nu+1} = \|A - A_\nu\|_2 = \inf_{B \in \mathbb{C}^{m \times n}, \text{rank}(B) \leq \nu} \|A - B\|_2, \quad (5.8)$$

donde $\sigma_{\nu+1} = 0$ si $\nu = r$. De esta manera, A_ν brinda la mejor aproximación en la 2-norma para A en el espacio de matrices de rango ν .

Teorema 5.0.4. Existencia de la factorización QR. Toda matriz $A \in \mathbb{C}^{m \times n}$ ($m \geq n$) admite una descomposición reducida $A = \hat{Q}\hat{R}$, donde $\hat{Q} \in \mathbb{C}^{m \times n}$, $\hat{Q}^*\hat{Q} = I$ y $\hat{R}$ es triangular superior. Además admite una factorización completa $A = QR$, con $Q \in \mathbb{C}^{m \times m}$ unitaria y $R \in \mathbb{C}^{m \times n}$ triangular superior.

Teorema 5.0.5. Unicidad de la factorización QR. Toda matriz $A \in \mathbb{C}^{m \times n}$ ($m \geq n$) de rango completo tiene una única factorización reducida $A = \hat{Q}\hat{R}$ donde las entradas de la diagonal de $\hat{R}$ son positivas.

Lema 5.0.9. El número de operaciones en aritmética de punto flotante (flops) para calcular la factorización QR de una matriz $A \in \mathbb{C}^{m \times n}$ dada en los Algoritmos 5 y 6 es de orden $O(2mn^2)$.

Definición 5.0.5. Factorización LU. Considere $A \in \mathbb{C}^{m \times m}$. Diremos que A admite una factorización LU si existen $U \in \mathbb{C}^{m \times m}$ triangular superior, $L \in \mathbb{C}^{m \times m}$ triangular inferior unitaria (todos sus elementos de la diagonal son unos) tales que $A = LU$.

Teorema 5.0.6. Factorización LU con pivoteo parcial. Toda matriz $A \in \mathbb{C}^{m \times m}$ tiene una factorización $PA = LU$, donde P es una matriz de permutaciones de fila, L es una matriz unitaria triangular inferior donde todas sus entradas están acotadas por 1, y U es una matriz triangular superior.

Definición 5.0.6. Matriz definida positiva. Una matriz Hermitiana $A \in \mathbb{C}^{m \times m}$ es definida positiva si $x^*Ax > 0$ para todo $x \neq 0$.

Lema 5.0.10. Una matriz Hermitiana es definida positiva si y solo si todos sus valores propios son positivos.

Lema 5.0.11. Sean $A \in \mathbb{C}^{m \times m}$ Hermitiana y $X \in \mathbb{C}^{m \times n}$ con $m \geq n$. Suponga que A es definida positiva y que las columnas de X son linealmente independientes. Entonces X^*AX es Hermitiana y definida positiva.

Teorema 5.0.7. Existencia y unicidad de la factorización de Cholesky. Toda matriz $A \in \mathbb{C}^{m \times m}$ Hermitiana definida positiva tiene una única factorización de Cholesky $A = R^*R$ donde las entradas de la diagonal de R son positivas.

6

Condición y estabilidad

Definición 6.0.1. Número de condición absoluto. Denote por δx una pequeña perturbación en x , y escriba $\delta f = f(x + \delta x) - f(x)$. El número de condición absoluto de f se define como

$$\hat{\kappa}(x) = \hat{\kappa} := \lim_{\delta \rightarrow 0} \sup_{\|\delta x\| < \delta} \frac{\|\delta f\|}{\|\delta x\|}. \quad (6.1)$$

Si f es diferenciable, entonces podemos reducir la definición anterior a

$$\hat{\kappa} = \|J_f(x)\|, \quad (6.2)$$

donde $J_f(x)$ es el Jacobiano de f .

Definición 6.0.2. Número de condición relativo. El número de condición relativo se define como el cociente

$$\kappa(x) := \lim_{\delta \rightarrow 0} \sup_{\|\delta x\| < \delta} \frac{\|\delta f\|}{\|f(x)\|} \frac{\|x\|}{\|\delta x\|}. \quad (6.3)$$

Si f es diferenciable, entonces

$$\kappa = \frac{\|J_f(x)\|}{\|f(x)\|/\|x\|}. \quad (6.4)$$

Definición 6.0.3. Número de condición de una matriz. Dada una matriz $A \in \mathbb{C}^{m \times m}$, se define el número de condición de la matriz como

$$\kappa(A) := \|A\| \|A^{-1}\|. \quad (6.5)$$

Si A no es invertible, es usual escribir $\kappa(A) = \infty$.

Definición 6.0.4. Algoritmo estable. Se dice que el algoritmo $\tilde{f}$ para resolver f es estable si para todo $x \in X$,

$$\frac{\|\tilde{f}(x) - f(\tilde{x})\|}{\|f(\tilde{x})\|} = O(\epsilon_m) \quad (6.6)$$

para algún $\tilde{x}$ con

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\epsilon_m). \quad (6.7)$$

En palabras sencillas, un algoritmo estable da casi la respuesta correcta a casi el mismo problema.

Definición 6.0.5. Algoritmo estable hacia atrás. Se dice que el algoritmo $\tilde{f}$ para resolver f es estable hacia atrás si para todo $x \in X$,

$$\tilde{f}(x) = f(\tilde{x}) \quad (6.8)$$

para algún $\tilde{x}$ con

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\epsilon_m). \quad (6.9)$$

En palabras sencillas, un algoritmo estable hacia atrás da la respuesta correcta a casi el mismo problema.

Teorema 6.0.1. Precisión de un algoritmo estable hacia atrás. Suponga que $\tilde{f}$ es un algoritmo estable hacia atrás para resolver $f : X \rightarrow Y$. Sea κ el número de condición de f . Entonces, el error relativo satisface

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\kappa(x)\epsilon_m). \quad (6.10)$$

Teorema 6.0.2. Estabilidad hacia atrás de la sustitución hacia atrás. Sea $R \in \mathbb{C}^{m \times m}$ una matriz triangular superior invertible. Considere el método de sustitución hacia atrás dado en el Algoritmo 13 para resolver el sistema $Rx = b$. Dicho algoritmo es estable hacia atrás; específicamente, existe una matriz triangular superior $\delta R \in \mathbb{C}^{m \times m}$ tal que

$$(R + \delta R)\tilde{x} = b, \quad (6.11)$$

donde $\tilde{x}$ es la salida del algoritmo, y

$$\frac{\|\delta R\|}{\|R\|} = O(\epsilon_m). \quad (6.12)$$

Teorema 6.0.3. Estabilidad hacia atrás de la factorización QR. Sea $A = QR \in \mathbb{C}^{m \times n}$. Si $\tilde{Q}$ y $\tilde{R}$ son las matrices obtenidas del Algoritmo 7 (con Householder), entonces existe $\delta A \in \mathbb{C}^{m \times n}$ tal que

$$\tilde{Q}\tilde{R} = A + \delta A, \quad \text{con} \quad \frac{\|\delta A\|}{\|A\|} = O(\epsilon_m). \quad (6.13)$$

Teorema 6.0.4. Estabilidad hacia atrás del cálculo de Q^*b . Sea $y = Q^*b$. Si $\tilde{y}$ es el vector producido por el Algoritmo 8, entonces existe $\delta Q \in \mathbb{C}^{m \times n}$ tal que

$$(Q + \delta Q)\tilde{y} = b, \quad \text{con} \quad \|\delta Q\| = O(\epsilon_m). \quad (6.14)$$

Teorema 6.0.5. Estabilidad hacia atrás de la factorización de Cholesky. Sea $A = R^*R \in \mathbb{C}^{m \times m}$ la factorización de Cholesky de A . Si $\tilde{R}$ es la matriz obtenida del Algoritmo 12, entonces existe $\delta A \in \mathbb{C}^{m \times m}$ tal que

$$\tilde{R}^* \tilde{R} = A + \delta A, \quad \text{con} \quad \frac{\|\delta A\|}{\|A\|} = O(\epsilon_m). \quad (6.15)$$

Teorema 6.0.6. Estabilidad de la factorización LU con pivoteo parcial. Sea $A \in \mathbb{C}^{m \times m}$, donde $PA = LU$ es la factorización LU de A . Si $\tilde{L}$, $\tilde{U}$ y $\tilde{P}$ son las matrices obtenidas del Algoritmo 11 (con pivoteo parcial), entonces existe $\delta A \in \mathbb{C}^{m \times m}$ tal que

$$\tilde{L} \tilde{U} = \tilde{P}A + \delta A, \quad \text{con} \quad \frac{\|\delta A\|}{\|A\|} = O(\rho \epsilon_m), \quad (6.16)$$

donde ρ es el factor de crecimiento de A , definido como

$$\rho(A) = \frac{\max_{i,j} |u_{ij}|}{\max_{i,j} |a_{ij}|}. \quad (6.17)$$

Teorema 6.0.7. Estabilidad hacia atrás en la resolución de $Ax = b$. Dados $A \in \mathbb{C}^{m \times m}$ invertible y $b \in \mathbb{C}^m$, considere el problema de resolver el sistema $Ax = b$ mediante el algoritmo descrito anteriormente. Existe $\Delta A \in \mathbb{C}^{m \times m}$ tal que

$$(A + \Delta A)\tilde{x} = b, \quad \text{con} \quad \frac{\|\Delta A\|}{\|A\|} = O(\epsilon_m), \quad (6.18)$$

donde $\tilde{x}$ es la solución numérica del algoritmo.

Teorema 6.0.8. Error en la solución de $Ax = b$. La solución $\tilde{x}$ del algoritmo anterior satisface que

$$\frac{\|x - \tilde{x}\|}{\|x\|} = O(\kappa(A)\epsilon_m). \quad (6.19)$$

Teorema 6.0.9. Error en la solución de $Ax = b$ (forma general). Al resolver el sistema de ecuaciones $Ax = b$ (ya sea mediante la factorización en valores singulares, QR o Cholesky), la solución $\tilde{x}$ satisface que

$$\frac{\|x - \tilde{x}\|}{\|x\|} = O(\kappa(A)\epsilon_m). \quad (6.20)$$

En el caso de la factorización LU con pivoteo, se tiene que

$$\frac{\|x - \tilde{x}\|}{\|x\|} = O(\rho \kappa(A)\epsilon_m). \quad (6.21)$$

Aplicaciones de sistemas de ecuaciones

Teorema 7.0.1. Caracterización del problema de mínimos cuadrados. Sean $A \in \mathbb{C}^{m \times n}$ ($m > n$) y $b \in \mathbb{C}^m$ dados. Un vector $x \in \mathbb{C}^n$ minimiza el residuo

$$\|r\|_2 = \|Ax - b\|_2 \quad (7.1)$$

si y solo si $Pb = Ax$ donde $P \in \mathbb{C}^{m \times m}$ es el proyector ortogonal sobre $\text{Rang}(A)$.

Teorema 7.0.2. Unicidad de la solución de mínimos cuadrados. El problema de mínimos cuadrados tiene solución única si y solo si A tiene rango completo (i.e., si sus columnas son linealmente independientes).

Teorema 7.0.3. Mejor aproximación polinomial en L^2 . Dada $f \in L^2(a, b)$, existe un único polinomio $p_n \in \mathbb{P}_n$ tal que

$$\|f - p_n\|_{L^2(a,b)} = \min_{q \in \mathbb{P}_n} \|f - q\|_{L^2(a,b)}. \quad (7.2)$$

Teorema 7.0.4. Caracterización de la mejor aproximación en L^2 . Un polinomio $p_n \in \mathbb{P}_n$ minimiza $\|f - p_n\|_{L^2(a,b)}$ si y solo si

$$\langle f - p_n, q \rangle = 0 \quad \forall q \in \mathbb{P}_n. \quad (7.3)$$

Geoméricamente, p_n es la L^2 -proyección de f sobre el espacio de polinomios de grado a lo sumo n .

Teorema 7.0.5. Convergencia de la iteración de punto fijo en $\mathbb{R}^n$. Suponga g es continua en un cerrado $D \subset \mathbb{R}^n$ y sea $c \in D$ un punto fijo de g . Suponga que las primeras derivadas parciales son continuas en un vecindario abierto $N(c) \subset D$ de c , con

$$\|J_g(c)\|_\infty < 1. \quad (7.4)$$

Entonces, existe $\epsilon > 0$ tal que $g(\bar{B}_\epsilon(c)) \subset \bar{B}_\epsilon(c)$, donde $\bar{B}_\epsilon(c)$ es la bola cerrada de centro c y radio ϵ . Además, la secuencia definida en (7.1) converge a c para todo $x^{(0)} \in \bar{B}_\epsilon(c)$.

Teorema 7.0.6. Convergencia del método de Newton en varias variables. Suponga que $f(c) = 0$ con $f \in C^2(N(c))$, donde $N(c)$ es un vecindario abierto que contiene a c . Asuma que $J_f(c)$ es invertible. Entonces, la secuencia definida en el Algoritmo 18 converge a c si $x^{(0)}$ se encuentra suficientemente cerca de c . Además, la convergencia es cuadrática.

Definición 7.0.1. Matriz tridiagonal. Una matriz T se llama tridiagonal si $t_{ij} = 0$ para $|i - j| > 1$; esto es, sus elementos no nulos se encuentran en la diagonal, en la superdiagonal (elementos encima de la diagonal) y en la subdiagonal (elementos debajo de la diagonal). En general, la escribiremos de la forma

$$T = \begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{pmatrix}. \quad (7.5)$$

Lema 7.0.1. Suponga que $T \in \mathbb{R}^{n \times n}$ ($n \geq 3$) es tridiagonal, con

$$|b_j| > |a_j| + |c_j|, \quad j = 1, \dots, n, \quad (7.6)$$

donde por conveniencia definimos $a_1 \equiv 0$, $c_n \equiv 0$. Entonces T es invertible.

8

Ecuaciones diferenciales ordinarias

Teorema 8.0.1. Convergencia del método de Euler. La iteración (8.3) converge a la solución de la ecuación diferencial (8.1).

Definición 8.0.1. Orden de un método. Se dice que un método para resolver la ecuación diferencial (8.1) tiene orden p si dicho método obtiene de manera exacta soluciones polinomiales de grado p .

Teorema 8.0.2. Orden del método de Euler. El Método de Euler es de orden 1; esto es, si la solución de la ecuación diferencial (8.1) es un polinomio de grado 1, entonces el método recupera dicha solución de manera exacta.

Teorema 8.0.3. Convergencia y orden del método del trapecio. La iteración (8.4) es convergente y tiene orden dos.

Lema 8.0.1. Considere $c_1, \dots, c_\nu$ dados. Defina

$$q(t) := \prod_{j=1}^{\nu} (t - c_j), \quad q_l(t) = \frac{q(t)}{t - c_l} \quad (l = 1, \dots, \nu), \quad (8.1)$$

$$a_{i,j} = \int_0^{c_i} \frac{q_j(\tau)}{q_j(c_j)} d\tau \quad (i, j = 1, \dots, \nu), \quad (8.2)$$

$$b_i = \int_0^1 \frac{q_i(\tau)}{q_i(c_i)} d\tau \quad (i = 1, \dots, \nu). \quad (8.3)$$

Teorema 8.0.4. Orden de los métodos de Runge-Kutta implícitos de colocación. Sean $c_1, \dots, c_\nu$ los nodos del polinomio de Legendre de grado ν en el intervalo $[0, 1]$. Entonces, el método de Runge-Kutta implícito (8.15), (8.16) con constantes definidas en el Lema anterior tiene orden 2ν .

9

Valores y vectores propios

Definición 9.0.1. Matrices similares. Dos matrices $A \in \mathbb{C}^{m \times m}$, $B \in \mathbb{C}^{m \times m}$ se llaman similares si existe una matriz $P \in \mathbb{C}^{m \times m}$ invertible tal que $P^{-1}AP = B$.

Definición 9.0.2. Discos de Gerschgorin. Considere $A \in \mathbb{C}^{m \times m}$. Para $i = 1, \dots, m$ se define el disco de Gerschgorin

$$D_i := \{z \in \mathbb{C} : |z - a_{ii}| \leq R_i\}, \quad \text{donde} \quad R_i := \sum_{j=1, j \neq i}^m |a_{ij}|. \quad (9.1)$$

Teorema 9.0.1. Teorema de Gerschgorin. Todos los valores propios de una matriz $A \in \mathbb{C}^{m \times m}$ ($m \geq 2$) se encuentran en la unión de los discos de Gerschgorin de la matriz A .

Definición 9.0.3. Factorización de Schur. Dada $A \in \mathbb{C}^{m \times m}$, se dice que A admite una factorización de Schur si existen $Q \in \mathbb{C}^{m \times m}$ unitaria y $T \in \mathbb{C}^{m \times m}$ triangular superior tales que

$$A = QTQ^*. \quad (9.2)$$

Teorema 9.0.2. Existencia de la factorización de Schur. Toda matriz $A \in \mathbb{C}^{m \times m}$ admite una factorización de Schur.

Definición 9.0.4. Matriz en forma de Hessenberg. Se dice que $H \in \mathbb{C}^{m \times m}$ es una matriz en forma de Hessenberg si todos sus elementos por debajo de la subdiagonal son nulos; esto es, si

$$h_{ij} = 0 \quad \text{si} \quad i - j > 1. \quad (9.3)$$

Teorema 9.0.3. Estabilidad hacia atrás de la reducción a forma de Hessenberg. Sean $\tilde{H}$ la aproximación de H obtenida al utilizar el Algoritmo 19 y $\tilde{Q}$ la matriz unitaria de transformación. Entonces, existe $\delta A \in \mathbb{C}^{m \times m}$ tal que

$$\tilde{Q}\tilde{H}\tilde{Q}^* = A + \delta A, \quad \text{con} \quad \frac{\|\delta A\|}{\|A\|} = O(\varepsilon_m). \quad (9.4)$$

Definición 9.0.5. Secuencia de Sturm. Considere la matriz T dada en (9.1). Los determinantes de los menores principales de $T - \lambda I$, los cuales vienen dados recursivamente por

$$p_0(\lambda) \equiv 1, \quad (9.5)$$

$$p_1(\lambda) = a_1 - \theta, \quad (9.6)$$

$$p_r(\lambda) = (a_r - \lambda)p_{r-1}(\lambda) - b_r^2 p_{r-2}(\lambda) \quad \text{para} \quad r = 2, \dots, m, \quad (9.7)$$

generan una sucesión $\{p_r(\lambda)\}_{r=0}^m$ llamada secuencia de Sturm.

Teorema 9.0.4. Separación de raíces de la secuencia de Sturm. Sea $n \geq 3$. Las raíces de $p_r(\lambda)$ separan las raíces de $p_{r+1}(\lambda)$ ($r = 1, 2, \dots, m-1$); esto es, entre dos raíces consecutivas de p_{r+1} se ubica una única raíz de p_r . En particular, las raíces de p_r son simples para todo $r = 1, \dots, m$.

Teorema 9.0.5. Teorema de Sturm. Sea $\theta \in \mathbb{R}$. Considere la secuencia de Sturm $\{p_r(\theta)\}_{r=0}^m$ de la Definición anterior. Entonces, el número de concordancias de signo entre términos consecutivos de la secuencia de Sturm es igual al número de valores propios de T mayores que θ .

Definición 9.0.6. Matriz de rotación de Jacobi. Dados $m \in \mathbb{N}$ y $1 \leq p < q \leq m$, defina la matriz $R^{(pq)}(\theta) \in \mathbb{R}^{m \times m}$ como la matriz cuyas entradas no nulas vienen dadas por

$$r_{pp} = \cos(\theta), \quad r_{pq} = \sin(\theta), \quad (9.8)$$

$$r_{qp} = -\sin(\theta), \quad r_{qq} = \cos(\theta), \quad (9.9)$$

$$r_{ii} = 1 \quad \text{para} \quad i \notin \{p, q\}. \quad (9.10)$$

Es fácil ver que $(R^{(pq)}(\theta))^T = R^{(pq)}(-\theta)$ y que es ortogonal.

Lema 9.0.1. Sea $A \in \mathbb{R}^{m \times m}$ simétrica. Dados $1 \leq p < q \leq m$, existe $\phi \in [-\pi/4, \pi/4]$ tal que la entrada (p, q) de $(R^{(pq)}(\phi))^T A R^{(pq)}(\phi)$ es cero.

Lema 9.0.2. Considere $A \in \mathbb{R}^{m \times m}$. Defina $R^{(pq)}(\phi) \in \mathbb{R}^{m \times m}$ como en el lema anterior y sea

$$B = (R^{(pq)}(\phi))^T A R^{(pq)}(\phi). \quad (9.11)$$

Se tiene que

$$\sum_{\substack{i,j=1 \\ i \neq j}}^m b_{ij}^2 = \sum_{\substack{i,j=1 \\ i \neq j}}^m a_{ij}^2 - 2a_{pq}^2; \quad (9.12)$$

esto es, la suma de los cuadrados de elementos fuera de la diagonal de B disminuye en $2a_{pq}^2$ con respecto a la suma de los cuadrados de elementos fuera de la diagonal de A .

Teorema 9.0.6. Convergencia del método de Jacobi. Considere la sucesión $\{A^{(k)}\}_{k=0}^{\infty}$ obtenida en el Algoritmo 20. Se cumple que

$$\lim_{k \rightarrow \infty} \sum_{\substack{i,j=1 \\ i \neq j}}^m (a_{ij}^{(k)})^2 = 0. \quad (9.13)$$

Teorema 9.0.7. Convergencia de la iteración de potencias. Suponga que $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_m| \geq 0$ y que $q_1^T v^{(0)} \neq 0$. Entonces, la sucesión $\{v^{(k)}\}_{k \geq 0}$ converge a q_1 . Además,

$$\|v^{(k)} - q_1\| = O\left(\left|\frac{\lambda_2}{\lambda_1}\right|^k\right) \quad \text{y} \quad |\lambda^{(k)} - \lambda_1| = O\left(\left|\frac{\lambda_2}{\lambda_1}\right|^{2k}\right), \quad (9.14)$$

donde $\lambda^{(k)} = (v^{(k)})^T A v^{(k)}$ es el cociente de Rayleigh de $v^{(k)}$.

Teorema 9.0.8. Convergencia de la iteración inversa de potencias. Suponga que $|\mu - \lambda_J| < |\mu - \lambda_K| \leq |\mu - \lambda_j| \forall j \neq J$. Suponga además que $q_J^T v^{(0)} \neq 0$. Entonces, la iteración del Algoritmo 23 satisface que

$$\|v^{(k)} - q_J\| = O\left(\left|\frac{\mu - \lambda_J}{\mu - \lambda_K}\right|^k\right) \quad \text{y} \quad |\lambda^{(k)} - \lambda_J| = O\left(\left|\frac{\mu - \lambda_J}{\mu - \lambda_K}\right|^{2k}\right). \quad (9.15)$$

Teorema 9.0.9. Convergencia del método del cociente de Rayleigh. El Método del cociente de Rayleigh converge a un valor propio λ_J y su correspondiente vector propio q_J . Además, la convergencia es cúbica:

$$\|v^{(k+1)} - q_J\| = O(\|v^{(k)} - q_J\|^3), \quad |\lambda^{(k+1)} - \lambda_J| = O(|\lambda^{(k)} - \lambda_J|^3). \quad (9.16)$$

Resultado 9.0.1. Algoritmo 4: Método adaptivo de Simpson.

Require: Función continua f , intervalo de integración $[a, b]$, tolerancia ε

Ensure: Aproximación $\tilde{I}_{SA}$ de la integral de f sobre $[a, b]$

1: Calcule los valores de S_i y $\tilde{S}_i$ para el intervalo $[a, (a+b)/2]$

2: **if** $|\tilde{S}_i - S_i| < \frac{15h_i}{b-a} \cdot \varepsilon$ **then**

3: Tome $\tilde{S}_i$ como la aproximación de $\int_a^{(a+b)/2} f(x) dx$

4: **else**

5: Calcule de manera separada $\int_a^{(a+b)/4} f(x) dx$ y $\int_{(a+b)/4}^{(a+b)/2} f(x) dx$

6: **end if**

7: Repita para calcular la integral sobre $[(a+b)/2, b]$

Resultado 9.0.2. Algoritmo 5: Ortogonalización de Gram-Schmidt (inestable).**Require:** Matriz $A \in \mathbb{C}^{m \times n}$ **Ensure:** Matriz unitaria Q y triangular superior R tales que $A = QR$

```

1: for  $j = 1 : n$  do
2:    $v_j = a_j$ 
3:   for  $i = 1 : j - 1$  do
4:      $r_{ij} = q_i^* a_j$ 
5:      $v_j = v_j - r_{ij} q_i$ 
6:   end for
7:    $r_{jj} = \|v_j\|_2$ 
8:    $q_j = v_j / r_{jj}$ 
9: end for

```

Resultado 9.0.3. Algoritmo 6: Ortogonalización de Gram-Schmidt (estable).**Require:** Matriz $A \in \mathbb{C}^{m \times n}$ **Ensure:** Matriz unitaria Q y triangular superior R tales que $A = QR$

```

1:  $V = A$ 
2: for  $i = 1 : n$  do
3:    $r_{ii} = \|v_i\|_2$ 
4:    $q_i = v_i / r_{ii}$ 
5:   for  $j = i + 1 : n$  do
6:      $r_{ij} = q_i^* v_j$ 
7:      $v_j = v_j - r_{ij} q_i$ 
8:   end for
9: end for

```

Resultado 9.0.4. Algoritmo 7: Triangularización de Householder.**Require:** Matriz $A \in \mathbb{C}^{m \times n}$ **Ensure:** Matriz unitaria Q y triangular superior R tales que $A = QR$

```

1: for  $j = 1 : n$  do
2:    $x = A_{j:m,j}$  ▷ vector de valores entre filas  $j$  y  $m$  de la columna  $j$ 
3:    $v_j = \text{sign}(x_1) \|x\|_2 e_1 + x$ 
4:    $v_j = v_j / \|v_j\|_2$ 
5:    $A_{j:m,j:n} = A_{j:m,j:n} - 2v_j (v_j^* A_{j:m,j:n})$ 
6: end for

```

Resultado 9.0.5. Algoritmo 8: Cálculo implícito de Q^*b .**Require:** Matriz $A = QR \in \mathbb{C}^{m \times n}$, vector $b \in \mathbb{C}^m$ **Ensure:** Producto Q^*b

```

1: for  $j = 1 : n$  do
2:    $b_{j:m} = b_{j:m} - 2v_j (v_j^* b_{j:m})$ 
3: end for

```

Resultado 9.0.6. Algoritmo 9: Cálculo implícito de Qx .**Require:** Matriz $A = QR \in \mathbb{C}^{m \times n}$, vector $x \in \mathbb{C}^n$ **Ensure:** Producto Qx

```

1: for  $j = n : 1$  do
2:    $x_{j:m} = x_{j:m} - 2v_j (v_j^* x_{j:m})$ 
3: end for

```

Resultado 9.0.7. Algoritmo 10: Eliminación Gaussiana sin pivoteo.**Require:** Matriz $A \in \mathbb{C}^{m \times m}$ **Ensure:** Factorización $A = LU$

```

1:  $U = A, L = I$ 
2: for  $k = 1 : m - 1$  do
3:   for  $j = k + 1 : m$  do
4:      $L_{j,k} = U_{j,k} / U_{k,k}$ 
5:      $U_{j,k:m} = U_{j,k:m} - L_{j,k} U_{k,k:m}$ 
6:   end for
7: end for

```

Resultado 9.0.8. Algoritmo 11: Eliminación Gaussiana con pivoteo parcial.**Require:** Matriz $A \in \mathbb{C}^{m \times m}$ **Ensure:** Factorización $PA = LU$

```

1:  $U = A, L = I, P = I$ 
2: for  $k = 1 : m - 1$  do
3:   Seleccione  $i \geq k$  tal que  $|U_{i,k}|$  es máximo
4:    $U_{k,k:m} \leftrightarrow U_{i,k:m}$ 
5:    $L_{k,1:k-1} \leftrightarrow L_{i,1:k-1}$ 
6:    $P_{k,:} \leftrightarrow P_{i,:}$ 
7:   for  $j = k + 1 : m$  do
8:      $L_{j,k} = U_{j,k} / U_{k,k}$ 
9:      $U_{j,k:m} = U_{j,k:m} - L_{j,k} U_{k,k:m}$ 
10:  end for
11: end for

```

Resultado 9.0.9. Algoritmo 12: Factorización de Cholesky.**Require:** Matriz $A \in \mathbb{C}^{m \times m}$ **Ensure:** Factorización $A = R^* R$

```

1:  $R = \text{triu}(A)$ 
2: for  $k = 1 : m$  do
3:   for  $j = k + 1 : m$  do
4:      $R_{j,j:m} = R_{j,j:m} - R_{k,j:m} R_{k,j} / R_{k,k}$ 
5:   end for
6:    $R_{k,k:m} = R_{k,k:m} / \sqrt{R_{k,k}}$ 
7: end for

```

Resultado 9.0.10. Algoritmo 13: Sustitución hacia atrás.**Require:** Matriz $R \in \mathbb{C}^{m \times m}$ triangular superior, $b \in \mathbb{C}^m$ **Ensure:** Solución $x = R^{-1}b$

```

1: for  $k = m : 1$  do
2:    $x_k = (b_k - \sum_{j=k+1}^m R_{k,j} x_j) / R_{k,k}$ 
3: end for

```

Resultado 9.0.11. Algoritmo 14: Sustitución hacia adelante.**Require:** Matriz $L \in \mathbb{C}^{m \times m}$ triangular inferior, $b \in \mathbb{C}^m$ **Ensure:** Solución $x = L^{-1}b$

```

1: for  $k = 1 : m$  do
2:    $x_k = (b_k - \sum_{j=1}^{k-1} L_{k,j} x_j) / L_{k,k}$ 
3: end for

```

Resultado 9.0.12. Algoritmo 15: Mínimos cuadrados con ecuaciones normales.**Require:** Matriz $A \in \mathbb{C}^{m \times n}$, $b \in \mathbb{C}^m$ **Ensure:** $x \in \mathbb{C}^n$ tal que $\|b - Ax\|_2 \rightarrow \min$

- 1: Forme A^*A , A^*b
- 2: Factorice $A^*A = R^*R$
- 3: Resuelva el sistema triangular inferior $R^*w = A^*b$ para w
- 4: Resuelva el sistema triangular superior $Rx = w$ para x

Resultado 9.0.13. Algoritmo 16: Mínimos cuadrados con factorización QR.**Require:** Matriz $A \in \mathbb{C}^{m \times n}$, $b \in \mathbb{C}^m$ **Ensure:** $x \in \mathbb{C}^n$ tal que $\|b - Ax\|_2 \rightarrow \min$

- 1: Factorice $A = \hat{Q}\hat{R}$
- 2: Calcule $\hat{Q}^*b$
- 3: Resuelva el sistema triangular superior $\hat{R}x = \hat{Q}^*b$ para x

Resultado 9.0.14. Algoritmo 17: Mínimos cuadrados con valores singulares.**Require:** Matriz $A \in \mathbb{C}^{m \times n}$, $b \in \mathbb{C}^m$ **Ensure:** $x \in \mathbb{C}^n$ tal que $\|b - Ax\|_2 \rightarrow \min$

- 1: Factorice $A = \hat{U}\hat{\Sigma}V^*$
- 2: Calcule $\hat{U}^*b$
- 3: Resuelva el sistema diagonal $\hat{\Sigma}w = \hat{U}^*b$ para w
- 4: Calcule $x = Vw$

Resultado 9.0.15. Algoritmo 18: Método de Newton en varias variables.**Require:** Función continua y derivable f , valor inicial $x^{(0)}$ **Ensure:** Aproximación $x^{(k)}$ de la raíz c de f

- 1: **for** $k = 1, 2, \dots$ **do**
- 2: $x^{(k)} := x^{(k-1)} - (J_f(x^{(k-1)}))^{-1} f(x^{(k-1)})$
- 3: **end for**

Resultado 9.0.16. Algoritmo 19: Forma de Hessenberg.**Require:** $A \in \mathbb{C}^{m \times m}$ **Ensure:** Matriz de Hessenberg H similar a A

- 1: $H = A$
- 2: **for** $k = 1 : m - 2$ **do**
- 3: $x = H_{k+1:m,k}$
- 4: $v_k = \text{sign}(x_1)\|x\|_2 e_1 + x$
- 5: $v_k = v_k / \|v_k\|_2$
- 6: $H_{k+1:m,k:m} = H_{k+1:m,k:m} - 2v_k(v_k^* H_{k+1:m,k:m})$
- 7: $H_{1:m,k+1:m} = H_{1:m,k+1:m} - 2(H_{1:m,k+1:m} v_k) v_k^*$
- 8: **end for**

Resultado 9.0.17. Algoritmo 20: Método de Jacobi.**Require:** $A \in \mathbb{R}^{m \times m}$ simétrica**Ensure:** Aproximación de una matriz diagonal similar a A

```

1:  $A^{(0)} = A$ 
2: for  $k = 1, 2, 3, \dots$  do
3:   Encuentre  $p < q$  tales que  $|a_{pq}| = \max_{i,j} |a_{i,j}|$ 
4:   Calcule  $\phi_k = \frac{1}{2} \arctan \left( \frac{2a_{pq}^{(k)}}{a_{qq}^{(k)} - a_{pp}^{(k)}} \right)$ 
5:   Defina  $A^{(k+1)} := (R^{(pq)}(\phi_k))^T A^{(k)} R^{(pq)}(\phi_k)$ 
6: end for

```

Resultado 9.0.18. Algoritmo 21: Método de Jacobi modificado.**Require:** $A \in \mathbb{R}^{m \times m}$ simétrica**Ensure:** Aproximación de una matriz diagonal similar a A

```

1: for  $k = 1, 2, 3, \dots$  do
2:   for  $i = 1 : m$  do
3:     for  $j = i + 1 : m$  do
4:       Construya la matriz  $R^{(ij)}$  donde la entrada  $ij$  de  $(R^{(ij)})^T A R^{(ij)}$  es cero
5:       Haga  $A \leftarrow (R^{(ij)})^T A R^{(ij)}$ 
6:     end for
7:   end for
8: end for

```

Resultado 9.0.19. Algoritmo 22: Método de iteración de potencias.**Require:** $A \in \mathbb{R}^{m \times m}$ simétrica, $v^{(0)} \in \mathbb{R}^m$ unitario**Ensure:** Aproximación del mayor valor propio (en valor absoluto) y su correspondiente vector propio

```

1: for  $k = 1, 2, 3, \dots$  do
2:    $w = A v^{(k-1)}$ 
3:    $v^{(k)} = w / \|w\|$ 
4:    $\lambda^{(k)} = (v^{(k)})^T A v^{(k)}$ 
5: end for

```

Resultado 9.0.20. Algoritmo 23: Método de iteración inversa de potencias.**Require:** $A \in \mathbb{R}^{m \times m}$ simétrica, $v^{(0)} \in \mathbb{R}^m$ unitario, $\mu \in \mathbb{R}$ **Ensure:** Aproximación del valor propio más cercano a μ y su correspondiente vector propio

```

1: for  $k = 1, 2, 3, \dots$  do
2:   Resuelva  $(A - \mu I)w = v^{(k-1)}$  para  $w$ 
3:    $v^{(k)} = w / \|w\|$ 
4:    $\lambda^{(k)} = (v^{(k)})^T A v^{(k)}$ 
5: end for

```

Resultado 9.0.21. Algoritmo 24: Método del cociente de Rayleigh.**Require:** $A \in \mathbb{R}^{m \times m}$ simétrica, $v^{(0)} \in \mathbb{R}^m$ unitario, $\lambda^{(0)} := (v^{(0)})^T A v^{(0)}$ **Ensure:** Aproximación del valor propio más cercano a $\lambda^{(0)}$ y su correspondiente vector propio

```

1: for  $k = 1, 2, 3, \dots$  do
2:   Resuelva  $(A - \lambda^{(k-1)} I)w = v^{(k-1)}$  para  $w$ 
3:    $v^{(k)} = w / \|w\|$ 
4:    $\lambda^{(k)} = (v^{(k)})^T A v^{(k)}$ 
5: end for

```

Resultado 9.0.22. Algoritmo 25: Método QR.**Require:** $A \in \mathbb{C}^{m \times m}$ **Ensure:** Aproximación $\tilde{T}$ de la matriz triangular superior de la factorización de Schur de $A = QTQ^*$

- 1: **for** $k = 1, 2, 3, \dots$ **do**
- 2: Factorice $Q^{(k)}R^{(k)} = A^{(k-1)}$
- 3: Defina $A^{(k)} = R^{(k)}Q^{(k)}$
- 4: **end for**

Resultado 9.0.23. Algoritmo 26: Método QR práctico.**Require:** $A \in \mathbb{C}^{m \times m}$ Hermitiana**Ensure:** Aproximación $\tilde{T}$ de la matriz diagonal de la factorización de Schur de $A = QTQ^*$

- 1: Calcule la forma de Hessenberg $(Q^{(0)})^T A^{(0)} Q^{(0)} = A$ (T tridiagonal)
- 2: **for** $k = 1, 2, 3, \dots$ **do**
- 3: Escoja $\mu^{(k)}$ (por ejemplo, $\mu^{(k)} = A_{mm}^{(k-1)}$)
- 4: Factorice $Q^{(k)}R^{(k)} = A^{(k-1)} - \mu^{(k)}I$
- 5: Calcule $A^{(k)} = R^{(k)}Q^{(k)} + \mu^{(k)}I$
- 6: Si algún elemento bajo la diagonal $A_{j,j+1}^{(k)}$ es cercano a cero, haga $A_{j,j+1}^{(k)} = A_{j+1,j}^{(k)} = 0$ y utilice deflación
- 7: **end for**